



上海交通大学学位论文

室内外混合场景的多源融合定位研究

姓 名：

学 号：

导 师：

学 院：电子信息与电气工程学院

专业名称：自动化（IEEE 试点班）

申请学位层次：学士

2025 年 06 月

A Dissertation Submitted to
Shanghai Jiao Tong University for the Degree of Bachelor

**RESEARCH ON MULTI-SOURCE FUSION
POSITIONING IN INDOOR AND OUTDOOR
HYBRID SCENARIOS**

Author:

Supervisor:

School of Electronic Information and Electrical Engineering

Shanghai Jiao Tong University

Shanghai, P.R. China

June, 2025

上海交通大学

学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，已在文中以适当方式予以致谢。若在论文撰写过程中使用了人工智能工具，本人已遵循《上海交通大学关于在教育教学中使用 AI 的规范》，确保人工智能生成内容的应用场景、引用范围及标注方式均符合规定，并杜绝学术不端行为。本人完全知晓本声明的法律后果由本人承担。

学位论文作者签名：

日期： 年 月 日

上海交通大学

学位论文使用授权书

本人同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。

本学位论文属于：

☐ 公开论文

☐ 内部论文，保密 ☐ 1 年 / ☐ 2 年 / ☐ 3 年，过保密期后适用本授权书。

☐ 秘密论文，保密 ____ 年（不超过 10 年），过保密期后适用本授权书。

☐ 机密论文，保密 ____ 年（不超过 20 年），过保密期后适用本授权书。

（请在以上方框内选择打“√”）

学位论文作者签名：

日期： 年 月 日

指导教师签名：

日期： 年 月 日

摘 要

室内外混合场景下,要实现精确定位仍然有着诸多技术困难。例如,GNSS(Global Navigation Satellite System, 全球导航卫星系统)信号在室内可能会因遮挡而失效,传统的 SLAM (Simultaneous Localization And Mapping, 即时定位与建图)算法在室内外切换场景时由于特征点的缺失和视觉信号不连贯无法有效进行连续定位,视觉传感器的使用也受到光照变化,环境条件等因素的限制。

为解决以上问题,本论文提出了一种将视觉信息同 GNSS 信息和 IMU (Inertial Measurement Unit, 惯性测量单元)信息进行融合的多传感器融合定位算法。以实现室内外场景下机器人位置和姿态精确、快速的估计。相比于传统的 ORB-SLAM3 算法,主要的区别有:

1. 为解决室外场景视觉-IMU 传感器产生漂移的问题,我们引入了 GNSS 信号以优化算法在室外场景的表现。GNSS 信号的引入使得算法在较为空旷的室外场景,尤其是在缺少视觉特征点的室外场景(如草地)下,可以有效地减少漂移,提升算法准确度。

2. 针对 GNSS 原始信号的跳变性和稀疏性,我们提出了两种 GNSS 信号的筛选方法。速度阈值筛选方法(VCOC)基于速度不会突变的假设,对一段时间内平均速度超过阈值的 GNSS 信息点进行剔除。而时间阈值筛选方法(TSOC)则是根据 GNSS 信号到参考关键帧的时间差进行筛选。当二者的时间差大于所给定阈值时,则剔除该 GNSS 信号。通过以上筛选方法,我们确保了 GNSS 信号的可用性。

3. 为了保证实时性与全局一致性,我们引入了因子图的滑动窗口机制。其主要思想是仅动态优化最近一段时间内的传感器状态(位姿、速度、偏置等),同时保留历史状态对当前窗口的约束。通过限制优化变量规模,避免全局优化的高时间开支,同时通过边缘化保留旧状态的间接约束,抑制累积漂移来保证全局一致性。

关键词: 室内外混合场景, 多源传感器, 即时定位与建图, 异常值筛选, 滑动窗口机制

ABSTRACT

In mixed indoor and outdoor scenarios, there are still many technical difficulties in achieving accurate positioning. For example, GNSS (Global Navigation Satellite System) signals may fail due to occlusion indoors, and the traditional SLAM (Simultaneous Localization And Mapping) algorithm cannot effectively perform continuous positioning due to the lack of feature points and incoherent visual signals when switching scenes between indoor and outdoor scenes. The use of vision sensors is also limited by factors such as changes in illumination, environmental conditions, etc.

In order to solve the above problems, a multi-sensor fusion positioning algorithm is proposed to fuse visual information with GNSS information and IMU (Inertial Measurement Unit) information. In order to achieve accurate and fast estimation of the position and posture of the robot in indoor and outdoor scenes. Compared with the traditional ORB-SLAM3 algorithm, the main differences are:

- 1..In order to solve the problem of drift generated by the IMU sensor in outdoor scenes, we introduce GNSS signals to optimize the performance of the algorithm in outdoor scenes. The introduction of GNSS signals enables the algorithm to effectively reduce drift and improve the accuracy of the algorithm in relatively open outdoor scenes, especially in outdoor scenes lacking visual feature points (such as grass).

2. In view of the hopping and sparsity of GNSS raw signals, we propose two screening methods for GNSS signals. The Velocity Threshold Screening Method (VCOC) is based on the assumption that the velocity will not change abruptly, and the GNSS information points whose average velocity exceeds the threshold over a period of time are screened. The Time Threshold Screening Method (TSOC) filters based on the time difference between the GNSS signal and the reference keyframe. When the time difference between the two is greater than the given threshold, the GNSS signal is filtered out. With the above screening methods, we ensure the availability of GNSS signals.

3. In order to ensure real-time and global consistency, we introduce a sliding window mechanism for factor charts. The main idea is to dynamically optimize only the sensor state (pose, velocity, bias, etc.) for the most recent period of time, while preserving the constraints

of the historical state on the current window. By limiting the size of the optimization variables, it avoids the high time expense of global optimization, and at the same time inhibits the cumulative drift by marginalizing the indirect constraints of retaining the old state

Key words: Indoor and outdoor hybrid scenes, multi-sensor, simultaneous localization and mapping, outlier screening, Sliding window mechanism

目 录

摘 要	I
ABSTRACT	II
第一章 绪论	1
1.1 研究背景	1
1.2 国内外研究现状	2
1.3 本文结构安排	4
第二章 预备知识	7
2.1 引言	7
2.2 坐标系介绍	7
2.3 GNSS 信息	8
2.3.1 全球导航卫星系统 GNSS 介绍	8
2.3.2 实时动态定位技术 RTK 介绍	10
2.4 算法中常见坐标系间的变换	10
2.4.1 机体坐标系与相机坐标系之间的变换	10
2.4.2 相机坐标系与图像坐标系的转换	11
2.4.3 经纬高坐标系 (LLA) 到地心地固坐标系 (ECEF) 的转换	13
2.4.4 地心地固坐标系 (ECEF) 到本地局部坐标系的转换	13
2.5 惯性测量单元 IMU 信息	14
2.5.1 IMU 测量模型 (含误差)	15
2.5.2 IMU 预积分技术	16
2.5.3 速度量积分	16
2.5.4 位置量积分	16
2.6 相机信息	17
2.7 单目相机获取深度	17
2.8 因子图	19
2.8.1 贝叶斯网络	19

2.8.2	贝叶斯网络到因子图模型	21
2.9	本章小结	22
第三章	室内外场景下多源传感器融合定位算法设计	24
3.1	引言	24
3.2	室内外混合场景下定位问题分析	24
3.3	传感器组合选择	25
3.4	算法整体框架	26
3.4.1	初始化模块	28
3.4.2	视觉前端模块	29
3.4.3	优化线程模块	32
3.5	GNSS 信号筛选	32
3.5.1	整体筛选流程	32
3.5.2	速度阈值筛选机制	32
3.5.3	时间阈值筛选机制	35
3.6	初始化优化	36
3.6.1	问题分析	36
3.6.2	解决方案	36
3.7	因子图框架	37
3.7.1	变量节点	37
3.7.2	因子节点	39
3.7.3	滑动窗口机制	41
3.8	本章小结	45
第四章	定位算法实验以及结果分析	46
4.1	引言	46
4.2	实验平台组成	46
4.2.1	相机	47
4.2.2	IMU	47
4.2.3	GNSS	47
4.3	参数标定	49
4.3.1	相机-IMU 标定	50

4.3.2	GNSS 标定	51
4.4	实验数据包录制.....	51
4.5	实验结果与分析.....	52
4.5.1	实验结果	52
4.5.2	结果分析	60
4.6	本章小结	61
第五章 全文总结与未来展望		62
5.1	本文总结	62
5.2	未来研究展望	63
5.3	非技术性问题探讨	63
参 考 文 献		65
致 谢		68

第一章 绪论

1.1 研究背景

近年来，随着智慧城市、工业 4.0 和消费级 AR 应用的快速发展，室内外无缝定位技术正成为全球导航市场的关键增长点。据 ABI Research (2024) 数据^[1]显示，全球高精度定位市场规模已突破 500 亿美元，其中室内定位占比仍不足 20%，室内外混合场景定位市场存在巨大的空白。目前，能够实现跨场景连续定位的解决方案仍处于早期阶段，市场渗透率较低，但有着巨大的增长动力和市场潜力。

在室内外混合场景中，机器人有着多种任务需求，例如需要实现自主导航、实时定位、自动避障等功能。然而，单一传感器定位技术（如 GNSS、视觉、惯性导航等）在复杂的室内外混合场景中存在明显局限性。例如，全球导航卫星系统实时动态差分定位技术（GNSS-RTK）能够提供实时的高精度定位信息^[2]，但在室内或多路径效应严重的区域信号衰减甚至失效^[3]；而视觉定位技术受环境布局影响大，且受光照条件影响严重，难以实现无缝过渡^[4]。此外，惯性导航系统（Inertial Navigation System）虽然不依赖外部信号，但其误差会随时间累积，导致定位漂移^[5]。因此，如何通过多源信息融合实现高精度、高鲁棒性的室内外无缝定位，成为学术界和工业界亟待解决的关键问题。

多源融合定位技术的核心意义在于通过协同互补不同定位模态的优势，提升复杂环境下的定位连续性、稳定性和精度。一方面，该技术能够满足智慧城市中人员与资产的全域管理需求，例如在大型综合体（机场、医院、商场）中实现室内外无缝导航，或在应急救援中为消防员提供精准的位置服务^[6]。另一方面，随着自动驾驶和机器人应用场景的扩展，车辆或无人机在穿越地下停车场、隧道等 GNSS 拒止环境时，多源融合定位可保障其自主性与安全性^[7]。

本研究通过探索多源传感器与定位技术的融合机制，旨在突破现有技术在复杂场景中的瓶颈，为未来智能终端提供普适、可靠的定位解决方案，对推动位置服务产业化、提升社会生产效率具有重要价值。

1.2 国内外研究现状

国外在室内外融合定位领域的研究具有先发优势，形成了较为完整的技术体系，也取得了多项技术突破。而国内随着近些年科技的迅速发展，相关领域也涌现了许多研究成果。

国外学者在视觉-惯性-卫星导航融合定位领域做出了开创性贡献。Mur-Artal 等人在 2015 年提出了 ORB-SLAM 算法^[8]，首次实现了基于特征点的视觉 SLAM 系统。ORB-SLAM 是首个基于 ORB 特征的实时单目 SLAM 系统，采用多线程（跟踪、局部建图、闭环检测）架构，并引入词袋模型（BoW）进行回环检测。然而，它仅适用于静态环境，且单目 SLAM 存在尺度不确定。而为了解决以上问题，Mur-Artal 等人在 2017 年又提出了 ORB-SLAM2 算法^[9]，其相比于 ORB-SLAM 算法，主要改进有：1. 在回环检测后增加了全局 BA 优化，以减少累积误差。2. RGB-D 相机支持。直接利用深度信息，提高建图精度，但仍局限于稀疏特征点地图。3. 关键帧筛选优化，采用分格特征提取，提高特征分布的均匀性，增强鲁棒性。尽管相比于 ORB-SLAM 算法有着诸多改动和优化，其仍然具有在动态环境下表现不佳以及稠密建图能力弱的缺点，使得其难以被直接应用于实际导航之中。

而后续为了解决 ORB-SLAM2 算法的缺点，国内外学者进行了诸多尝试，主要的研究方向聚焦于提升算法在动态环境下的适应性和进行特征匹配优化两方面。国外学者 Bescos 等人针对动态环境下易误识别动态物体特征点的问题，结合 Mask R-CNN 语义分割剔除动态物体特征点，提出了基于 ORB-SLAM2 算法的 DynaSLAM 算法，能够提高动态环境鲁棒性^[10]。无独有偶，国内学者同样基于 ORB-SLAM2 算法进行优化，提出了基于并行语义分割剔除动态特征点的方法 DS-SLAM^[11]。此两种方法相比于 ORB-SLAM2 算法，在动态环境下的鲁棒性更强。然而，两种算法均存在计算复杂，系统开销大的缺点。

而为了改进 ORB-SLAM2 算法在特征匹配方面优化的缺陷，国外学者 Leutenegger 等人结合深度学习学习方法，将深度学习特征描述符与传统 ORB 特征结合，提出了一种可以提升匹配质量的优化 ORB-SLAM2 算法^[12]。国内学者则先是先采用了基于网格的运动统计（GMS）方法，对 ORB-SLAM2 算法进行优化^[13]。然而此优化方法并没有对 ORB-SLAM2 的高匹配延迟问题进行优化，故而后续国内团队又提出了结合一种高效的主动特征匹配方法（GF），能够减少 ORB-SLAM2 的匹配延迟的同时保持精度的优化算法^[14]。

尽管对于 ORB-SLAM2 算法的优化改进有一定效果，却没有解决 ORB-SLAM2

初始化困难、仅支持单一地图系统、难以支持多传感器的问题，故而 Campos 等人提出了 ORB-SLAM3 算法^[15]。相比于 ORB-SLAM2，其支持多传感器信息输入，并可以进行多地图管理和惯性辅助初始化，主要包含了跟踪，局部建图，闭环检测三个关键线程，具有高精度，长期稳定性，适应性强等优点。然而 ORB-SLAM3 算法仍然存在输出点云稀疏，在室外开阔地带表现不佳，在长距离移动中累计误差难以消除等问题。而针对以上问题，国内外学者也先后进行了不同方法的尝试和优化。

为了建立稠密地图点云，我国团队提出了基于 ORB-SLAM3 算法的实时同步定位和稠密地图构建技术^[16]，核心目标是通过优化 ORB-SLAM3 的稀疏点云输出，结合深度算法和三维重建技术，生成可用于增强现实（AR）和导航的稠密点云地图。实现了 ORB-SLAM3 的稀疏输出与稠密重建算法无缝结合，填补了特征点 SLAM 到稠密地图的鸿沟。而另一实验团队在 ORB-SLAM3 算法的基础上，提出了一种用于室外动态场景的适应性 ORB-SLAM3 算法^[17]，该方法创造性地在跟踪线程中引入了 YOLOv5 检测机制，极大地减少了算法所需的时间和计算资源。而针对在高速运动场景下，ORB-SLAM3 算法表现不佳的问题，文章^[18]则介绍了一种基于 ORB-SLAM3 的改进算法，DN-SLAM，用于在动态环境下获得更好的效果。DN-SLAM 使通过动态物体检测与剔除，静态区域的特征点优化，NeRF（神经辐射场）地图构建，相机位姿优化，等改进，显著提升了在动态环境中的定位精度和地图质量。大大提升了高动态适应性，重建地图密集性和实时性和鲁棒性。

尽管以上方法在 ORB-SLAM3 常见的问题上取得了一定的优化成果，然而，将该算法应用于室内外混合场景仍然面临着诸多挑战。为此，国内外学者进行了诸多尝试。

户外的研究主要集中于在视觉信号受到干扰的时候，如何维持定位跟踪。在稻田场景下，视觉特征缺少，传统的 ORB-SLAM3 算法易产生漂移与跟踪失败等问题。而为了解决此问题，Javier Cremona 等人提出了结合 GNSS 信号的定位算法^[19]。该算法通过引入 GNSS 信号，有效地抑制了漂移，并在视觉特征较为稀少的区域，能够通过 GNSS 信号与 IMU 信号继续实现跟踪。而对于动态环境下，ORB-SLAM3 常常出现 IMU 数据发散，漂移增大等问题。为了改善这些问题，我国学者提出了 MONO-SLAM 算法^[20]，该算法结合了 Mask-RCNN 实例分割网络，利用语义掩码（Mask）和边界框（Bounding Box）精确识别并剔除动态物体。其提出了双阶段动态点过筛策略，首先会进行 Mask-RCNN 粗筛，剔除明显动态物体；之后还需要通过运动一致性检验，该步骤中通过多视角几何约束进一步过滤误检的静态特征。其在农业动态场景下，准确

率大幅提升。

在户内等 GNSS 信号拒止场景下，研究的重点主要集中于在缺少 GNSS 信号下，如何维持定位效果。我国学者提出了结合 LIDAR 和 UWB 的室内定位方法^[21]。该方法提出了锚点自定位算法，优化 UWB 锚点的部署，减少环境干扰（如多径效应）对定位的影响。同时还提出了完整性监测算法，可以实时评估定位系统的可信度，在信号退化时（如 LiDAR 点云稀疏）自动切换至备用方案。外国学者则提出了紧耦合 LiDAR，立体视觉相机以及惯性导航系统的改进 SLAM 定位方法^[22]。其通过扩展卡尔曼滤波（EKF）实现多传感器融合，以应对 GNSS 信号长期失效的场景。并提出了动态权重调整策略，在特征条件较为丰富的场景下，更多依赖视觉 SLAM；在特征稀疏时切换至 LiDAR 主导。

而上述算法中，不少算法都使用了 LiDAR 或是 UWB 这种较为昂贵的传感器，导致成本较高。此外，GNSS 信号会因为遮挡或是多径效应存在突变或是时间不同步的问题。而为了解决以上问题，本文从低成本、易部署的角度出发，选用 GNSS 信号，视觉相机以及惯性测量单元作为传感器装置，提出了一种紧耦合 GNSS 信号，视觉相机信息以及惯性测量单元信息的多传感器融合定位算法。而在室内外混合场景下，GNSS 信号在切换到室内环境下会出现跳变或是漂移问题，故而不能完全依赖原始的 GNSS 信号。而为了排除异常 GNSS 信号带来的影响，本文设计了 GNSS 信号筛选机制，从速度异常机制和时间同步机制出发，筛去不合理的 GNSS 信号点。而可用的 GNSS 信号将会参与算法的初始化和后端优化，提升算法整体的性能。而为了解决 ORB-SLAM3 中优化时间空间开销大的问题，本文还提出了滑动窗口优化机制，能够在保证全局一致性的前提下，通过控制优化关键帧的数量来减少优化所消耗的时间和空间资源。

1.3 本文结构安排

本设计主要研究在室内外混合场景下的多源传感器融合定位问题，本文结构安排见图1-1：第一章是绪论，主要介绍本项目的研究背景以及意义，同时对国内外目前关于室内外混合场景定位工作的研究现状进行了简要介绍，结尾对本文总体结构安排进行了介绍。

第二章主要介绍定位算法中涉及到的预备知识。首先先介绍定位算法里常见的坐标系，并给出对应的图像直观展示。之后给出了不同坐标系间的转换公式，介绍不同坐标系间转换的参数和方法。之后介绍了不同传感器处理信息的常见方法，如

GNSS-RTK 技术, 惯性测量单元 (IMU) 预积分技术, 以及单目相机如何处理信息获得深度信息, 同时我们会介绍多种传感器融合时的因子图优化方法。以上这些相关方法对于室内外混合场景下的定位研究有着重要的意义和作用。

第三章对本文所提出的室内外混合场景下的多源传感器融合定位算法进行了详细的介绍, 首先我们先分析了室内外混合场景的特点以及可能面临的挑战。之后为了应对这些挑战, 我们介绍了不同的传感器以及各种传感器的优缺点, 并且选择了本文的传感器组合。随后介绍了算法的整体流程以及各个步骤。为解决传统 ORB-SLAM3 算法的缺陷, 我们引入了 GNSS 信号, 此处我们着重介绍了 GNSS 信号的筛选, GNSS 辅助初始化以及因子图的滑动窗口优化机制。

第四章将对算法实验进行介绍, 包括所使用的传感器以及实体设备信息, 以及所选用的数据来源, 包括本地数据集和公开数据集。在这两个数据集均进行了实验, 得到相关结果, 并对结果进行了分析, 验证了算法改进的效果和有效性。

第五章对本设计的工作做了总结, 并指出了不足和可以改进的地方, 提出了未来的可能研究方向。同时对非技术性上的问题进行了探讨, 分析了可能存在的安全问题和伦理问题, 并提出了相关的建议。




图 1-1 本文结构图

第二章 预备知识

2.1 引言

本章主要将会介绍一些定位算法的预备知识，我们将介绍定位算法中常见的坐标系以及其之间的变换关系，GNSS 设备获取信息常用的 GNSS-RTK 方法。最后，我们还会介绍不同传感器的处理信息的方法以及因子图优化的预备知识。

2.2 坐标系介绍

在定位算法的研究中，常常会见到多种坐标系，理清每种坐标系的原点，轴信息以及不同坐标系之间的变换公式是研究定位算法一大重点，下面将介绍常见的几种坐标系。

地心地固坐标系 (ECEF 坐标系)，是一种与地球固连的全局坐标系，其原点位于地球质心，坐标轴随地球自转同步旋转，故而其坐标轴方向相对于地球表面的位置会随时间变化而变化。其 X 轴指向本初子午线 (0° 经度线) 和赤道的交点；Y 轴在赤道平面内，与 X 轴垂直；Z 轴沿地球自转轴指向北极。

东-北-天坐标系 (ENU 坐标系) 是一种局部地理坐标系，常用于地面车辆导航和局部地图构建。其原点为用户定义的局部参考点 (如车辆起始点)，X 轴指向地理东方向，Y 轴指向地理北方向，Z 轴垂直地面向上。

地心地固坐标系与 ENU 坐标系图示见图2-1，其中 $X_{ecef}, Y_{ecef}, Z_{ecef}$ 为地心地固坐标系的 X、Y、Z 轴，其原点位于地心。而 $East, North, Up$ 三箭头则代表了本地东-北-天的 X、Y、Z 轴，其原点位于当前车体位置。

惯性坐标系，是一种非旋转、非加速的全局坐标系。其原点为地球质心，X 轴指向春分点 (赤道与黄道交点)，Y 轴在赤道平面内，与 X 轴垂直，构成右手系，Z 轴沿地球自转轴指向北极，见图2-2。

常见的传感器坐标系有相机坐标系 (C) 和机体坐标系 (B)，前者以相机光心为原点，Z 轴沿光轴指向拍摄方向 (正前方)，X 轴平行于图像平面向右，Y 轴平行于图像平面向下。后者常以机器人质心或是 IMU 安装位置为原点，X 轴指向机器人正前方 (运动方向)，Y 轴指向机器人左侧，Z 轴垂直向上且三者间满足右手定则。

最后还有一个常用于图像处理的坐标系，像素坐标系 (I)，这是一个二维的坐标

系，常见于平面图像处理中，其原点位于图像左上角（像素坐标系），X 轴向右（列坐标，即 u 轴），Y 轴向下（行坐标，即 v 轴）。

相机坐标系和像素坐标系图示见图2-3，其中黄色平面代表了成像平面。紫色的坐标系为相机坐标系，相机光轴方向为相机坐标系 Z 轴方向，X 轴平行于图像平面向右，Y 轴平行于图像平面向下。而黑色坐标系为图像物理坐标系，描述的是在实际物理场景下的图像坐标系，其原点位于光轴与成像平面的交点。而绿色坐标系为图像像素坐标系。其原点位于图像最左上角， u 轴（ x 轴）向右， v 轴（ y 轴）向下。




图 2-1 地心地固坐标系与东-北-天坐标系示意图

2.3 GNSS 信息

2.3.1 全球导航卫星系统 GNSS 介绍

全球导航卫星系统 (Global Navigation Satellite System, GNSS) 是一种通过卫星来提供全球范围高精度定位、导航与授时服务的技术统称。目前主要使用的 GNSS 系统有美国的 GPS 系统（最早使用），我国的北斗卫星系统，俄罗斯的格洛纳斯卫星系统以及欧洲的伽利略卫星系统。其核心原理是利用多颗卫星发射的无线电信号，通过接收机测量信号传播时间差（伪距）或载波相位差，结合卫星星历数据，解算用户的三维位置、速度及时间信息^[23]。由于其具有覆盖范围广，集成化水平高，使用成本低的特点^[24]，目前被广泛用于农业，航空，侦测等领域。




图 2-2 惯性坐标系示意图




图 2-3 相机坐标系和图像坐标系示意图

2.3.2 实时动态定位技术 RTK 介绍

实时动态差分技术（Real-Time Kinematic, RTK）是一种通过载波相位差分实现厘米级实时定位的 GNSS 增强技术，其主要由基准站、流动站、通信系统（数据链路）三部分组成，基准站已知精确坐标，实时观测卫星载波相位，计算误差修正值；随后流动站通过通信系统接收基准站差分数据，结合自身观测值，通过模糊度固定解算高精度位置^[25]；如下图2-4所示，本设计算法中的 GNSS 数据主要依靠 GNSS-RTK 技术获取，以获得高精度，实时性的数据。




图 2-4 GNSS-RTK 工作原理示意图

2.4 算法中常见坐标系间的变换

上文已经介绍了一些定位算法中常见的坐标系，本小节将介绍常见的不同坐标系间的变换关系和公式，这是定位算法中极其重要的问题。

2.4.1 机体坐标系与相机坐标系之间的变换

此处我们将机体坐标系原点设置为 IMU 的质心位置，给定机体系下的点 $p_b = [x_b, y_b, z_b]^T$ ，其在相机系下的坐标 p_c ，计算公式如下：

$$\mathbf{p}_c = \mathbf{R}_{bc} \cdot \mathbf{p}_b + \mathbf{t}_{bc}$$

齐次坐标形式

$$\begin{bmatrix} \mathbf{p}_c \\ 1 \end{bmatrix} = \begin{bmatrix} \mathbf{R}_{bc} & \mathbf{t}_{bc} \\ \mathbf{0}^T & 1 \end{bmatrix} \begin{bmatrix} \mathbf{p}_b \\ 1 \end{bmatrix}$$

其中 $\mathbf{R}_{bc}$ 是机体系到相机系的旋转矩阵， $\mathbf{t}_{bc}$ 是机体系到相机系的平移向量。

2.4.2 相机坐标系与图像坐标系的转换

相机坐标系到图像坐标系的变换涉及相机内参矩阵和透视投影，对视觉信息的处理有着重要的作用。其分为两个步骤，第一个步骤为相机坐标系变换到图像坐标系，示意图如图2-5所示。在此步骤中，两个坐标系属于透视投影关系，从 3D 转换到 2D，故而可以使用相似的原理进行计算。




图 2-5 相机坐标系转换到图像坐标系示意图

第二个步骤为将图像坐标系变换到像素坐标系，示意图如图2-6所示。像素坐标系和图像坐标系都在成像平面上，只是各自的原点和度量单位不一样。前者的原点为图像左上角，单位为像素；后者原点为相机光轴与成像平面的交点，通常情况下是成像平面的中点，单位为 mm。

综上，给定相机坐标系下的点 $p_c = [x_c, y_c, z_c]^T$ ，其在图像坐标系下的像素坐标 $p_i = [u, v]^T$ 计算公式如下：

$$\begin{cases} u = f_x \frac{x_c}{z_c} + c_x \\ v = f_y \frac{y_c}{z_c} + c_y \end{cases}$$

齐次坐标形式如下：

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \mathbf{K} \cdot \begin{bmatrix} x_c/z_c \\ y_c/z_c \\ 1 \end{bmatrix}$$




图 2-6 图像坐标系转换到像素坐标系示意图

其中， K 是相机内参矩阵，如下：

$$\mathbf{K} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix}$$

参数说明如下：

符号	含义	单位
f_x	X 方向焦距（像素单位）	像素
f_y	Y 方向焦距（像素单位）	像素
c_x	主点 X 坐标（图像中心）	像素
c_y	主点 Y 坐标（图像中心）	像素
z_c	相机坐标系下的深度	米（m）

表 2-1 相机内参参数说明

2.4.3 经纬高坐标系 (LLA) 到地心地固坐标系 (ECEF) 的转换

给定大地纬度 ϕ , 大地经度 λ , 和海拔高度 h , 地心地固坐标系下的坐标 (X, Y, Z) 计算公式为:

$$\begin{cases} X = (N + h) \cos \phi \cos \lambda \\ Y = (N + h) \cos \phi \sin \lambda \\ Z = [N(1 - e^2) + h] \sin \phi \end{cases}$$

其中, N 为卯酉圈曲率半径, e 为地球第一偏心率, 考虑到地球实质上是个椭圆, 设其长半轴长度为 a , 短半轴长度为 b , 其计算公式如下:

$$N = \frac{a}{\sqrt{1 - e^2 \sin^2 \phi}}$$

通过以上公式可以实现经纬高坐标系到地心地固坐标系的转换, 示意图如图2-7所示。在该图中, ϕ 角代表给定坐标点的纬度, λ 角代表给定坐标点的经度, 地球为一个椭球形, 其中 a 为长半轴, b 代表短半轴, 而绿色的长方体是以地心和给定坐标点的连线作为对角线绘制的。而图中三条边 x , y , z 代表给定坐标点在地心地固下的三轴坐标。

2.4.4 地心地固坐标系 (ECEF) 到本地局部坐标系的转换

在此处本地局部坐标系为定位算法中常见的东北天坐标系 (ENU 坐标系), 其原点为起始点, 现在已知原点在 ECEF 系下坐标 $P_1 = (X_1, Y_1, Z_1)$, 目标点在 ECEF 系下坐标 $P_2 = (X_2, Y_2, Z_2)$, 则目标点相对于原点在本地图局部坐标系下的坐标计算公式如下:

$$\begin{bmatrix} x \\ y \\ z \end{bmatrix} = \mathbf{R}_{enu}^{ecf} \cdot (\mathbf{p}_2 - \mathbf{p}_1)$$

旋转矩阵 $\mathbf{R}_{enu}^{ecf}$:

$$\mathbf{R}_{enu}^{ecf} = \begin{bmatrix} -\sin \lambda_1 & \cos \lambda_1 & 0 \\ -\sin \phi_1 \cos \lambda_1 & -\sin \phi_1 \sin \lambda_1 & \cos \phi_1 \\ \cos \phi_1 \cos \lambda_1 & \cos \phi_1 \sin \lambda_1 & \sin \phi_1 \end{bmatrix}$$

其中各参数意义见表:




图 2-7 经纬高坐标系转换到地心地固坐标系示意图

符号	含义	单位
$\mathbf{p}_1$	本地原点 (ECEF)	m
$\mathbf{p}_2$	待转换点 (ECEF)	m
ϕ_1	原点纬度	rad
λ_1	原点经度	rad

表 2-2 ECEF 到局部坐标系的参数说明

而在 GNSS-RTK 技术中，我们就需要将两个点的经纬高坐标转换为本地坐标系的相对坐标，通常步骤是将这两个点的坐标先从经纬高坐标转换为地心地固坐标系下的坐标，再将地心地固坐标系转换为本地坐标系下的坐标^[26]。

2.5 惯性测量单元 IMU 信息

惯性测量单元 (Inertial Measurement Unit, IMU) 是一种通过惯性传感器测量物体运动状态的设备，通常由三轴加速度计和三轴陀螺仪组成，部分高精度 IMU 还包含三轴磁力计。加速度计测量线性加速度 (包括重力)，陀螺仪测量角速度，磁力计

提供方位参考。其核心作用是输出物体的加速度，角加速度以及俯仰角等位姿信息。IMU 信息的获取和处理方式对于定位算法有着极为重要的影响。

2.5.1 IMU 测量模型（含误差）

设 IMU 所在的载体坐标系相对于世界坐标系的旋转矩阵为 R ，IMU 的位置坐标为 p ，速度为 v ，加速度为 a ，角加速度 ω ，在理想情况（无零偏和噪声干扰），则有如下公式：

$$\dot{R} = R\omega^\wedge \quad (2-1)$$

其中 $\omega^\wedge$ 是角速度 $\omega \in \mathbb{R}^3$ 的反对称矩阵：

$$\omega^\wedge = \begin{bmatrix} 0 & -\omega_3 & \omega_2 \\ \omega_3 & 0 & -\omega_1 \\ -\omega_2 & \omega_1 & 0 \end{bmatrix} \quad (2-2)$$

位置 p 、速度 v 和加速度 a 的导数关系：

$$\dot{p} = v \quad (2-3)$$

$$\dot{v} = a \quad (2-4)$$

然而，实际工作的过程中，IMU 往往会受到多种因素的影响而产生误差，主要可以分为确定性误差和随机性误差。确定性误差主要有加速度偏置和角加速度偏置，理论上，当没有外部作用时，IMU 传感器的输出应该为 0。但是实际数据中存在一个零偏 b ，这个偏置在三个轴上都存在，是一个三维的偏置，这会影响测量结果^[27]。而随机性误差主要有高斯白噪声（噪声影响）和偏置随机游走。IMU 数据连续时间上受到一个均值为 0，方差 σ ，各个时刻之间独立的噪声影响。同时偏置 $bias$ 会随着时间而随机变化，这些都会给我们的测量带来影响。将这些因素加入考量之后，我们可以得到如下的表达式：其中真实角速度 ω_{true} 与测量值 $\tilde{\omega}$ 的关系：

$$\tilde{\omega}(t) = \omega_{true}(t) + b_g(t) + \eta_g(t) \quad (2-5)$$

速度与位置更新模型：

$$v(t + \Delta t) = v(t) + (R(t) (\tilde{a} - b_a - n_a) + g) \Delta t \quad (2-6)$$

$$p(t + \Delta t) = p(t) + v(t)\Delta t + \frac{1}{2} (R(t) (\tilde{a} - b_a - n_a) + g) \Delta t^2 \quad (2-7)$$

旋转矩阵更新：

$$\mathbf{R}(t + \Delta t) = \mathbf{R}(t) \exp((\tilde{\omega} - \mathbf{b}_g - \mathbf{n}_g) \Delta t) \quad (2-8)$$

其中， b_a 为加速度的零偏值， b_g 为角加速度的零偏值， η_a 表示加速度噪声值， η_g 表示角加速度噪声值。

2.5.2 IMU 预积分技术

在我们已知某一时刻的状态下，通过 IMU 获取的加速度以及角加速度信息，我们可以计算得到另外一时刻下的状态。将相邻关键帧 i 和 j 之间的高频测量值积分成相对运动约束，定义旋转 $\Delta \mathbf{R}_{ij}$ 、速度变化 $\Delta \mathbf{v}_{ij}$ 和位置变化 $\Delta \mathbf{p}_{ij}$ ：

从初始姿态 $\mathbf{R}_i$ 开始直接积分角速度：

$$\mathbf{R}(t) = \mathbf{R}_i \prod_{k=i}^{j-1} \exp((\tilde{\omega}_k - \mathbf{b}_k^g - \boldsymbol{\eta}_k^g) \Delta t) \quad (2-9)$$

其中 $\tilde{\omega}_k$ 为 t_k 时刻陀螺仪原始测量值。

2.5.3 速度量积分

通过加速度测量值直接积分：

$$\mathbf{v}(t) = \mathbf{v}_i + \mathbf{g}t + \sum_{k=i}^{j-1} \mathbf{R}_k (\tilde{\mathbf{a}}_k - \mathbf{b}_k^a - \boldsymbol{\eta}_k^a) \Delta t \quad (2-10)$$

需注意重力项 $\mathbf{g}$ 在世界坐标系下的表达。其中， $\tilde{a}_k$ 为第 k 时刻加速度计测量的加速度测量值（含噪声）， b_k^a 为第 k 时刻加速度计的零偏， η_k^a 为第 k 时刻加速度计的白噪声。

2.5.4 位置量积分

对速度进行二次积分：

$$\mathbf{p}(t) = \mathbf{p}_i + \mathbf{v}_i t + \frac{1}{2} \mathbf{g} t^2 + \sum_{k=i}^{j-1} \left[\mathbf{v}_k \Delta t + \frac{1}{2} \mathbf{R}_k (\tilde{\mathbf{a}}_k - \mathbf{b}_k^a - \boldsymbol{\eta}_k^a) \Delta t^2 \right] \quad (2-11)$$

其中， p_i 为第 i 时刻的位置。

然而如果我们将第 i 时刻的位姿或者状态信息进行优化更改时，该积分就需要重新计算，这会显著增加算法计算度和运行时间。预积分的思想是计算第 i 时刻和第 j

时刻之间的相对状态和位姿，而并非绝对状态和位姿，这样在第 i 时刻的信息发生变化时，可以快速计算出第 j 时刻的信息，计算公式如下：

$$\Delta \mathbf{R}_{ij} \doteq \mathbf{R}_i^\top \mathbf{R}_j = \prod_{k=i}^{j-1} \exp((\tilde{\omega}_k - \mathbf{b}_k^g - \boldsymbol{\eta}_k^g) \Delta t) \quad (2-12)$$

$$\Delta \mathbf{v}_{ij} \doteq \mathbf{R}_i^\top (\mathbf{v}_j - \mathbf{v}_i - \mathbf{g} \Delta t_{ij}) \quad (2-13)$$

$$\Delta \mathbf{p}_{ij} \doteq \mathbf{R}_i^\top \left(\mathbf{p}_j - \mathbf{p}_i - \mathbf{v}_i \Delta t_{ij} - \frac{1}{2} \mathbf{g} \Delta t_{ij}^2 \right) \quad (2-14)$$

其中：

- $\mathbf{R}_i, \mathbf{R}_j$: t_i, t_j 时刻机体坐标系到世界坐标系的旋转矩阵
- $\tilde{\omega}_k$: t_k 时刻陀螺仪测量的角速度（含噪声）
- $\mathbf{b}_k^g, \boldsymbol{\eta}_k^g$: t_k 时刻陀螺仪零偏和白噪声
- $\mathbf{v}_i, \mathbf{v}_j$: t_i, t_j 时刻在世界坐标系下的速度
- $\mathbf{g}$: 世界坐标系下的重力向量
- Δt_{ij} : t_i 到 t_j 的时间间隔

2.6 相机信息

定位算法中常见的相机类型有单目相机，双目相机，RGB-D 相机，它们分别有各自的优缺点。单目相机具有单摄像头结构，成本低、体积小，通过特征匹配估计运动，但无法直接获取深度信息，需依赖运动恢复结构或先验尺度（如 IMU 融合）重建 3D 环境。双目相机双摄像头水平排列，通过视差计算深度（被动测距），室外性能优于 RGB-D，但计算复杂度高，基线距离限制测距范围。RGB-D 相机能够直接输出彩色图像和深度图，室内场景精度高，室外性能则由于阳光干扰有所下降。

2.7 单目相机获取深度

在 ORB-SLAM3 算法中，单目相机首先会通过 ORB 特征提取器获取关键点，并利用 DBoW2 进行特征匹配。ORB 特征提取器结合 FAST 角点检测和 BRIEF 描述子，对旋转和光照变化具有鲁棒性。特征匹配则会两帧图像计算汉明距离，并选择距离最小的匹配对，随后还会通过 RANSAC 方法剔除误匹配。随后会进行对极几何和三角化恢复稀疏深度，之后将结合 GNSS 观测解决单目相机的尺度模糊性问题，最后通过 BA 算法优化得到的位姿和深度信息。三角化示意图如图2-8所示：




图 2-8 单目相机三角化示意图

三角化过程中，匹配点对 $\mathbf{p}_1 \leftrightarrow \mathbf{p}_2$ 满足本质矩阵约束， E 为本质矩阵：

$$\mathbf{p}_2^T \mathbf{E} \mathbf{p}_1 = 0, \quad \mathbf{E} = [\mathbf{t}]_{\times} \mathbf{R} \quad (2-15)$$

其中 $[\mathbf{t}]_{\times}$ 为平移向量的反对称矩阵， R 为旋转矩阵：

$$[\mathbf{t}]_{\times} = \begin{bmatrix} 0 & -t_z & t_y \\ t_z & 0 & -t_x \\ -t_y & t_x & 0 \end{bmatrix}$$

三角化线性方程组如下：已知相机位姿 $(\mathbf{R}, \mathbf{t})$ ，求解 3D 点 $\mathbf{P}$ ：

$$\begin{bmatrix} \mathbf{p}_i \times \mathbf{K} \mathbf{I} \\ \mathbf{p}_j \times \mathbf{K}(\mathbf{R} | \mathbf{t}) \end{bmatrix} \mathbf{P} = \mathbf{0} \quad (2-16)$$

其中 $\mathbf{K}$ 为相机内参矩阵， $\mathbf{I}$ 表示单位阵， $\times$ 表示叉积。

通过以上等式，我们可以计算得到 3D 点 P 在世界坐标系下坐标。之后我们将结合 GNSS 观测来解决单目相机的尺度模糊性问题，首先通过最小二乘对齐 SLAM 与 GNSS 坐标系， s 为尺度因子：

$$s^* = \arg \min_s \sum_k \|\mathbf{T}_{\text{SLAM},k} - s \cdot \mathbf{T}_{\text{GNSS},k}\|^2 \quad (2-17)$$

其中， $T_{\text{SLAM},k}$ 为 SLAM 坐标系下的轨迹坐标， $T_{\text{GNSS},k}$ 为 GNSS 的轨迹坐标，随后将相对深度 λ_i 转换为绝对深度：

$$\lambda_{\text{absolute}} = s \cdot \lambda_i \quad (2-18)$$

最后再通过局部 BA 优化深度和位姿，优化目标函数：

$$\arg \min_{\mathbf{R}, \mathbf{t}, \mathbf{P}_w} \sum_i \|\mathbf{p}_i - \pi(\mathbf{R}\mathbf{P} + \mathbf{t})\|_{\Sigma_i}^2 \quad (2-19)$$

其中 $\pi(\cdot)$ 为相机投影模型， R 为相机姿态， t 为位置， P 为 3D 点坐标：

$$\pi(\mathbf{X}) = \mathbf{K} \frac{\mathbf{X}}{Z} \quad (\text{透视投影})$$

经过以上操作后，我们可以得到优化后的位姿和深度信息。

2.8 因子图

因子图是一种用于表示多变量函数分解的二分图模型，它是概率图模型家族中的重要成员，广泛应用于信号处理、人工智能、通信系统和机器人定位等领域。它将原数学模型构建为一个图模型，通过边和节点表示变量和约束，最后对目标函数进行最小化以实现问题的最优解求解^[28]。因子图由两种节点组成：变量节点（代表未知量或随机变量）和因子节点（代表变量之间的关系或约束），通过边连接相关联的变量和因子。变量节点在定位算法中一般代表机器人的速度，位姿等信息。而因子节点往往代表节点间的关系或是模型的约束，用以描述问题的约束条件，以方便我们进行求解和计算。

2.8.1 贝叶斯网络

从数学角度看，若一个全局函数可以分解为多个局部函数的乘积形式， $g(x_1, x_2, \dots, x_n) = \prod_i f_i(X_i)$ ，其中 X_i 是 $x_1, x_2, x_3, \dots, x_n$ 的子集，那么这个分解可以用因子图直观表示。这种表示方法将复杂的多变量关系分解为简单的局部交互，为高效推理算法奠定了基础。

下图2-9展示了一个常见的机器人运动中的观测情况，我们假设机器人在运动中经过了三个时间节点，如图中三个黄色节点所示，标注 t 代表时间节点，并在整个运动过程中观测到了两个地标点（图中蓝色节点），同时得到了自身与这些地标点之间的距离信息（如图中红色箭头）。同时，机器人自身也通过自身的里程计对运动进行测量（图中绿色箭头），以上数据将被用于进行机器人的位姿估计和状态推算。

将该机器人运动场景用数学中的贝叶斯网络进行建模，如图2-10所示，该图中蓝色节点为地表点状态量，红色箭头为机器人对于地标点的观测量，黄色节点为机器人




图 2-9 机器人运动场景模拟图

自身状态量，绿色箭头为机器人里程计的测量值。该贝叶斯图实际上描述了一种状态和观测的联合概率模型，假设知道系统的状态变量 X （机器人所在位置、路标点所在位置），可以推测出机器人得到的观测值 Z （观测值是通过某些传感器得到的，而传感器有已知模型），即已知机器人的状态量和传感器的模型，就可以推算出机器人的观测值。




图 2-10 贝叶斯网络图

相关数学推导公式如下：

联合概率改写为边缘分布概率和条件概率， $P(X)$ 代表事件 X 的概率。

$$P(X, Z) = P(Z|X)P(X) \quad (2-20)$$

而条件分布概率可以进一步改写为变量 Z 在给定观测条件 X 下的条件概率分布：

$$P(Z|X) = \prod_i P(Z_i|X_i) \quad (2-21)$$

而由于观测量之间互相独立，可以进一步得到下式所述模型：

$$\begin{aligned} P(z_{11}, z_{12}, z_{13}, z_{21}, z_{22}|x_1, x_2, x_3, l_1, l_2) &= P(z_{11}|x_1, l_1)P(z_{12}|x_2, l_1) \\ &P(z_{13}|x_3, l_2)P(z_{21}|x_1, x_2)P(z_{22}|x_2, x_3) \end{aligned} \quad (2-22)$$

而据此，我们可以由在已知状态量的情况下，推导出系统的观测值。

2.8.2 贝叶斯网络到因子图模型

由上文，我们知道贝叶斯网络实质上是个生成模型，解决了当我们知道状态变量时，如何计算观测变量的问题。但在定位算法中，我们常常需要解决的问题是从观测变量来推出状态变量，是一个状态估计问题，这就需要引出因子图模型来解决该问题。

首先，我们需要对问题进行分析，我们需要从观测量来推出状态量，这是一个后验概率问题，结合贝叶斯定理，我们最终的问题被描述为一个最大化后验概率问题，即在给定系统观测量的情况下，求解一个状态量使得以下公式的条件概率最大：

$$P(X|Z) = \frac{P(Z|X)P(X)}{P(Z)} \propto P(Z|X)P(X) \quad (2-23)$$

由于我们已知观测量 Z ，故而 $P(Z)$ 已知，故而在上式的最大化问题中，我们可以将其转化为寻找使 $P(Z|X)P(X)$ 最大的 X 值，即：

$$\mathbf{X}^* = \arg \max_{\mathbf{X}} P(X|Z) = \arg \max_{\mathbf{X}} P(Z|X)P(X) \quad (2-24)$$

而 $P(Z|X)$ 可以表示为不同观测变量的乘积，而且这些观测变量之间相互独立，见式2-22。而在因子图中，这些相互独立的观测变量构成了因子，每个因子对应着一个观测变量和状态变量对的条件概率分布，而每个因子之间并无连接关系说明了它们之间的独立性。而所有因子通过共享的状态变量节点（如位姿、路标）相互耦合，形成全局优化问题，如 IMU 因子约束相邻位姿，视觉因子约束位姿与路标，二者共同修正状态估计。因子间的协同通过消息传递或非线性优化实现，最终联合求解最大后验概率问题（MAP）。而因子图结构直观地反映了状态量和观测量之间的条件概率关系，为我们的计算和推理提供了直接有效的思路。

在示例中，给出因子图2-11对应如下：




图 2-11 因子图

该图中，圆形节点代表的是状态量，如黄色节点代表机器人自身状态量，蓝色节点代表地标点状态量。而方形节点代表的是一种因子，红色方块代表地标观测量因子，绿色方块代表本地里程计测量量因子，紫色方块代表先验因子。先验因子通过先验信息防止因子图求解时出现歧义多解。而我们所求的状态量是通过将因子图中每个因子的条件概率相乘后，求解该结果的最大值，而该最大值对应的状态量则是我们所需求出的最优状态量，即系统最有可能处于的状态。本质上是一个概率的最大化问题，通过求解使某一概率最大化的变量值，得到系统最有可能的状态，一般会结合最小二乘法进行求解。

2.9 本章小结

在本章，我们介绍了定位算法中常见的预备知识。先介绍了常见的传感器的优缺点，并根据它们的适用场景和功能选择了我们的传感器组合：相机，惯性测量单元和全球卫星导航系统信号，并依次介绍了不同传感器获取信号和处理信号的方法。同时我们对算法中常见的坐标系进行了介绍，以及介绍了不同坐标系之间的转换公式和方法。对于 GNSS 信号，其通过 GNSS-RTK 技术提供高精度实时性的信号，我们则需要将经纬高坐标系下的坐标转化为本地局部坐标系下的坐标；对于 IMU 信号，我们则介绍了 IMU 常见的信息处理方法：IMU 预积分技术，该技术将绝对位姿计算转换为相对位姿计算，在前面的帧信息进行更新和优化的时候，可以大幅减少计算量和计算时间；而对于相机，则介绍了单目相机结合 GNSS 信号获取深度的原理。而获取不同传感器的信息后，我们通过因子图将不同传感器的信息进行融合，并对因子图的

原理进行了详细的介绍，最终通过因子图优化的方法获取准确的定位结果。

第三章 室内外场景下多源传感器融合定位算法设计

3.1 引言

本论文主要目标是探究并设计一套可以在室内外混合场景下融合多源传感器信息并实现快速、准确定位的算法。室内外混合场景有着与单一场景不同的特点，这对本设计提出了新的要求和挑战。故而，本章先对场景的特点和可能出现的问题进行了介绍，随后提出了我们的算法。与传统的 ORB-SLAM3 算法相比，我们主要引入了：GNSS 辅助初始化、GNSS 信号筛选、因子图滑动窗口优化机制来保证算法的全局一致性、实时性，并通过引入 GNSS 信号来减小室外场景下的定位算法的漂移量和累计误差。

3.2 室内外混合场景下定位问题分析

室内外混合场景可以分为室内场景、室外场景和室内外衔接部分。不同场景有各自的特点，对算法提出了不同的挑战。

在纯室外场景中，往往视线较为开阔，且此时遮挡物较少，视线内不少部分是天空和路面，且光照条件较为稳定，地形上也较为平坦。而靠近建筑的半室外场景中，此时可能因为建筑物的遮蔽出现阴影，从而导致光照条件较差，同时建筑可能会影响 GNSS 信号，产生多径效应^[29]或是城市峡谷效应^[30]。在半室外和纯室外场景中，GNSS 信号相对而言使用性更强。然而，较为简单的视觉信息会给跟踪线程带来挑战，由于天空和远端遮蔽物的特征并不明显，故而给特征点提取带来了难度。在难以提取特征点的同时，提取到无用特征点的可能性将会增加。同时深度相机虽然能直接提供深度，但是目标若超出其识别的最大范围，将难以获得准确的深度信息。此外和遮蔽物或是显著地标建筑过于远的距离不利于进行三角化，从而难以获得地标点。

在室内场景中，光线条件会受到室内灯光的影响，地面上瓷砖的反光可能会对相机的视觉信息带来影响，导致提取到错误的特征点。同时在部分转弯的地方可能伴随着光线变化和障碍物遮挡，对视觉信息带来影响^[31]。同时，当摄像机面对白墙壁这种视觉单一的场景时，容易出现缺少视觉特征点导致难以提取的情况。

室内切换到室外时，容易出现过曝（即光照条件变化过大）导致视觉特征点对比度下降，匹配错误率升高^[32]。同时可能出现特征分布变化的问题，室内主要依赖人造

结构（如墙壁、物品）的角点和边缘特征；室外则以自然场景（如树木、天空）居多，缺乏规则纹理，特征点稀疏或分布不均，导致地图点连续性断裂，相机位姿估计漂移^[33]。同时会存在尺度变化问题，室内尺度小，而室外尺度大，会导致尺度骤增，影响图像金字塔的缩放策略。而室外到室内弱光，图像信噪比（SNR）降低，导致 ORB 特征点数量锐减，跟踪丢失风险增加^[34]。同时室外构建的地图点（如树木）在室内无法匹配，需重新初始化^[35]。

3.3 传感器组合选择

为了解决上述问题，我们需要选择合适的传感器作为本实验的信息获取装置。传感器种类繁多，可以分为内部传感器和外部传感器，内部传感器主要测量系统内部状态，包括速度，加速度等信息；外部传感器主要获取外界的状态信息，比如相机。我们目前常见的应用于机器人定位的传感器有相机、雷达、惯性测量单元和全球导航卫星系统（GNSS）等。每种传感器都有其独自的信息获取方式和工作原理，这也决定了它们有各自的优缺点和适用场景，在不同的场景下，不同的传感器会有不一样的工作性能。因此，我们需要谨慎的选择传感器组合，以在不同的场景下融合多种传感器的信息，保证不同环境下系统整体的工作效能优秀。下表描述了不同传感器的优缺点。

首先，在视觉信息上面，我们需要选用相机这一经典视觉传感器，目前市场上有多种技术成熟表现良好的相机可供选择和使用。同时惯性测量单元（IMU）作为一种常见的传感器也被我们纳入了考量范围，其与相机在许多方面上具有互补性^[36]。相机在高速运动环境下难以稳定成像，在低速条件下可以得到清晰稳定的图像；而惯性测量单元在高速时可以输出更可靠的加速度和角速度测量值。此外，相机的结果并不会随着时间而产生漂移现象，但是单目相机难以获得绝对尺度信息；而 IMU 的结果虽然会随着时间产生漂移，但是可以得到绝对尺度信息。二者在这些功能上的互补性说明将二者结合使用是一个优秀的方案。

此外，全球导航卫星系统（GNSS）可以提供实时的位置信息，且具有覆盖范围广，集成化水平高，成本低的特点。然而，GNSS 信号在室内会被遮挡而几乎无法使用，故而在室内环境中，更主要依赖 IMU 和视觉相机提供信息；但在室外的场景下，GNSS 信号可以提供全局位置约束，并在视觉特征稀少的情况下维持跟踪线程，起着关键作用。

结合以上信息，再加上成本的考虑，本研究最终选用相机，IMU 和 GNSS 接收

表 3-1 传感器优缺点对比

传感器类型	优点	缺点
GNSS	• 全局绝对定位 • 不受光照影响 • 室外稳定性高	• 室内不可用 • 信号易受遮挡 • 精度有限（米级）
单目相机	• 成本低、轻量化 • 可提取丰富纹理信息	• 无尺度信息 • 依赖特征匹配 • 易受光照变化影响
双目相机	• 可恢复深度信息（被动测距） • 室外适用性较好	• 计算复杂度高 • 基线限制测距范围 • 暗光环境性能下降
RGB-D 相机	• 直接输出深度信息 • 高帧率、适合室内场景	• 室外阳光干扰大 • 测量范围有限（通常 <10m） • 功耗较高
惯性测量单元	• 高频输出（100Hz+） • 不依赖外部环境 • 短时间运动估计准确	• 零漂移随时间累积 • 无法提供绝对位置信息 • 初始姿态需校准
激光雷达	• 高精度测距（厘米级） • 不受光照影响 • 可生成 3D 点云	• 成本高昂 • 体积功耗大 • 雨雪天气性能下降

装置作为最终的传感器组合方案进行研究。

为了解决上述问题，我们需要设计合适的算法步骤和优化参数因子，并对传感器信息进行筛选。在对场景进行分析以及对传感器进行选择，并经过对相关算法的调研之后，本论文提出了一种基于 GNSS 信息、惯导计算结果、以及视觉地图点信息并进行融合的多源传感器融合定位算法。

3.4 算法整体框架

定位算法整体框架如图3-1所示：

本定位算法一共分为三个大的模块，初始化模块，视觉前端模块以及优化线程模块。初始传感器输入信息为相机提供的视觉信息，IMU 提供的机器人运动状态信息




图 3-1 算法整体框架图

(加速度、角加速度等)以及 GNSS 提供的全球定位信息。通过传感器得到信息输入后,系统会通过初始化模块,构建初始初始地图,随后通过融合 IMU 数据,估计重力方向、尺度因子及传感器偏置,完成视觉-惯性对齐。最后引入 GNSS 测量值,建立局部坐标系,并标定传感器间的外参关系。之后系统会通过视觉前端模块,实时处理图像数据,提取 ORB 特征并进行帧间匹配,结合 IMU 预积分估计相机运动。并动态选择关键帧,与 GNSS 数据时间对齐,为后端提供全局位置约束,实现对机体运动的跟踪。最后构建了包含视觉重投影、IMU 预积分和 GNSS 位置约束的因子图,进行联合非线性优化。并通过 GNSS 因子校正累积误差,确保全局轨迹一致性,尤其在视觉回环失效时增强系统鲁棒性。此外,我们还引入了滑动窗口机制,其通过限制优化帧数量于边缘化机制,减少计算开支的同时确保了全局一致性。

3.4.1 初始化模块

初始化模块中,系统会进行纯立体视觉 SLAM,使用 ORB 特征检测器提取关键点并计算描述子。单目相机会通过三角化生成初始地图点,立体相机可以利用左右目的视差计算深度,得到深度之后,进行运动 BA 算法优化,通过 PnP 或本质矩阵分解计算初始帧间的相对位姿,最后进行局部 BA 优化,调整相机位姿和地图点,减少重投影误差。而通过视觉初始化,我们可以得到初始地图和相机位姿。若视觉初始化失败,则需继续等待足够视察或是特征点以再次进行初始化。在纯视觉初始化结束后,会进行视觉-惯性联合初始化。首先会进行 IMU 的预积分,计算帧与帧之间的相对旋转、速度、位置变化。随后利用视觉位姿和 IMU 预积分数据,通过最大后验估计 (MAP) 求解重力向量 g_w (世界坐标系下的重力向量)、尺度因子 s (以解决单目相机的尺度不确定性问题)、IMU 加速度计和陀螺仪的偏置 b_a 、 b_g ,而在得到以上信息之后,还会进行初始化质量检测,检查优化结果的协方差矩阵,确保 IMU 数据可信。若 IMU 初始化失败,则会检查 IMU 数据是否稳定。而通过视觉-惯性对齐,我们可以得到真实的尺度轨迹、IMU 参数信息。随后在 IMU 初始化完成后,选择首个与关键帧时间对齐的 GNSS 测量值,建立本地局部 ENU 坐标系。随后 GNSS 将会与视觉-惯性坐标系进行对齐,使用 Umeyama 算法计算初始旋转矩阵 $R_{B_0}^W$,通过最小二乘法的方法计算,实现。此处需注意当地图重置时,需要重新进行 GNSS 信号的初始化流程。若是 GNSS 初始化失败,则我们将暂时仅依赖视觉-惯性 SLAM,等待 GNSS 信号恢复后重新对齐。同时我们还需要进行外参的标定,需要标定的数据有 T_C^B ,即相机到 IMU 的变换矩阵,以及天线位置 t_A^B ,反映了天线 (GNSS) 到 IMU 的位置关系。

通过 GNSS 的初始化，我们可以得到全局位姿和 GNSS 外参。而以上的初始化方式，确保了视觉 SLAM 的局部精度、IMU 的动态稳定性和 GNSS 的全局一致性。

通过 Umeyama 算法将视觉-惯性 SLAM 轨迹（经尺度校正后）与 GNSS 全局坐标系对齐公式如下：

$$R_{B_0}^W, t_{B_0}^W = \operatorname{argmin}_{R, t} \sum_{i=1}^N \|\mathbf{p}_i^W - (R \cdot \mathbf{p}_i^{B_0} + t)\|^2 \quad (3-1)$$

其中：

- $R_{B_0}^W$ ：SLAM 坐标系到世界坐标系（ENU）的旋转矩阵
- $t_{B_0}^W$ ：SLAM 原点在世界坐标系中的平移量
- $\mathbf{p}_i^{B_0}$ ：视觉-惯性 SLAM 的局部位姿
- $\mathbf{p}_i^W$ ：对应的 GNSS 全球坐标测量值

而通过上述公式可以求解出 $R_{B_0}^W$ 与 $t_{B_0}^W$ ，从而可以得到 SLAM 坐标系到全局坐标系的变换矩阵，实现视觉-惯性 SLAM 轨迹与 GNSS 坐标系的对齐。

初始化模块简易流程示意图如图3-2：




图 3-2 初始化模块简易流程图

3.4.2 视觉前端模块

而在视觉前端模块，主要进行的是处理相机拍摄到的信息，并进行跟踪。首先通过 ORB（Oriented FAST and Rotated BRIEF）算法提取图像中的关键点与描述子。该

步骤中，我们首先会进行 ORB 特征检测（多尺度 FAST 角点），随后会使用灰度质心法计算 ORB 方向，最后会进行 BRIEF 描述子生成。

在得到关键点之后，利用立体相机或时序帧间的特征匹配建立短期运动约束。随后进行帧间位姿估计，该步骤中主要的目的是通过通过 2D-3D 匹配估计相机运动状态。其结合 IMU 预积分数据，通过 PnP 或本质矩阵分解计算相邻帧的相对位姿，输出高频相机运动初值。之后会进行关键帧选择，根据场景变化（如视差、特征数量）动态生成关键帧，减少冗余计算并触发局部建图线程的优化。

随后我们会通过局部地图跟踪进行优化，优化目标如下：

$$\min_{\mathbf{T}} \left(\sum_i \rho(\|\mathbf{x}_i - \pi(\mathbf{T}\mathbf{X}_i)\|^2) + \lambda \|\log(\mathbf{T} \cdot \mathbf{T}_{\text{imu}}^{-1})\|^2 \right) \quad (3-2)$$

参数意义如下：

表 3-2 优化参数说明

符号	参数类型	数学描述	物理意义
$\mathbf{T}$	优化变量	$\mathbf{T} \in SE(3)$	待求的相机位姿矩阵
$\mathbf{X}_i$	3D 点坐标	$\mathbf{X}_i \in \mathbb{R}^3$	地图点的世界坐标
$\mathbf{x}_i$	2D 观测	$\mathbf{x}_i \in \mathbb{R}^2$	特征点在图像中的像素坐标
$\pi(\cdot)$	投影函数	$\pi: \mathbb{R}^3 \rightarrow \mathbb{R}^2$	相机模型（通常为针孔投影）
$\rho(\cdot)$	鲁棒核函数	$\rho(r) = \begin{cases} \frac{r^2}{2}, & r \leq \delta \\ \delta(r - \frac{\delta}{2}), & \text{otherwise} \end{cases}$	Huber 损失函数，抑制外点影响
$\mathbf{T}_{\text{imu}}$	先验位姿	$\mathbf{T}_{\text{imu}} \in SE(3)$	IMU 预积分预测的位姿
λ	权重系数	$\lambda = \sigma_{\text{vis}}^{-2} / \sigma_{\text{imu}}^{-2}$	视觉与 IMU 残差的相对权重
$\log(\cdot)$	李代数映射	$\log: SE(3) \rightarrow \mathfrak{se}(3)$	将位姿差异映射到切空间

常见的跟踪模型有恒速运动模型跟踪，关键帧跟踪和重定位。首先会进行恒速运动模型跟踪，基于前一帧位姿和 IMU 积分数据（或纯运动学模型）预测当前位姿，若失败，则会进行关键帧跟踪，转而尝试与最近的关键帧进行匹配跟踪，利用关键帧的稳定特征点和深度信息提高鲁棒性。若均失败，则会启用重定位方法，通过 BoW 词袋模型或全局描述子在地图中进行搜索，计算当前帧与历史关键帧的相似度进行位姿估计。通过以上步骤计算得到地图点后，最后进行与 GNSS 数据的对齐，将稀疏的 GNSS 测量与关键帧时间戳对齐，为后端优化提供全局位置约束。

视觉模块简易流程图如图3-3所示：




图 3-3 视觉前端模块简易流程图

3.4.3 优化线程模块

在算法的后端优化模块，主要使用的因子图优化的优化方法，与传统的 ORB-SLAM3 算法相比，我们的算法引入了 GNSS 因子，解决了视觉回环失效的问题。其中因子图结合不同传感器的信息，设置了对应的残差因子，将多传感器的信息进行融合，实现准确的状态估计。后文我们将会对本设计的因子图优化方法进行着重介绍。

3.5 GNSS 信号筛选

由于 GNSS 信号具有稀疏性以及切换室内场景时，GNSS 信号会出现跳变或是漂移的问题，这意味着我们不能直接使用所接收到的全部 GNSS 信号。因此，我们提出了两个用于筛选 GNSS 信号的方法，分别为时间阈值筛选方法和速度阈值筛选方法，用于 GNSS 信号的初始化，确保选择正确合理的 GNSS 信号用于后续的初始化和因子图优化。接下来将介绍 GNSS 信号筛选的过程。

3.5.1 整体筛选流程

对数据进行预处理后，我们将 GNSS 信号成功转化为可用的位置信号。随后我们会根据该 GNSS 信号的置信度（如卫星数 N_{sat} ，水平精度因子 HDOP）进行初步筛选，可以避免信号较弱或是多径效应导致的不可靠数据进入融合数据流。之后进行 GNSS 信号与视觉-惯性信号的时空对齐。然后我们会进行鲁棒性关联筛选，此处主要使用了两种方法进行筛选。首先会进行速度阈值筛选，计算相邻 GNSS 信号之间的平均速度，随后会将该平均速度与所设置的速度阈值进行比较，若该速度大于所给定的阈值，则认为该 GNSS 信号发生了速度上的突变，为不可靠数据点，进行筛去。之后会进行时间阈值筛选，若一个 GNSS 信号距离其时间最近的关键帧的时间差大于所给定的时间阈值，则认为该 GNSS 信号未被对齐，将其舍去。经过以上筛选机制之后，我们剔除了绝大部分的 GNSS 异常数据。下面将会详细介绍速度阈值筛选机制和时间阈值筛选机制。

3.5.2 速度阈值筛选机制

在室内或是楼栋较多的区域，GNSS 信号往往会因为遮挡或是多径效应而产生漂移或是跳变，为了筛去这些异常点，我们从速度信息的角度出发，提出了速度约束异常值筛选机制。速度约束异常值筛选机制（Velocity Constraint Outlier Culling, VCOC）

是 GNSS 数据预处理的第一道关键环节,该机制通过物理运动速度的合理性判断,有效识别并剔除因多路径效应、信号遮挡等环境干扰导致的 GNSS 定位异常值,为后续的多传感器融合提供更可靠的绝对位置参考。其原理基于一个合理的物理速度连续性假设:即不管是行人或是机体,速度均不会发生突变,这意味着若出现速度差异过大的点,我们可以认为该点是异常点,从而进行筛选。具体步骤如下:

1, 坐标变换: 首先将 GNSS 提供的经纬度高程 (LLA) 数据转换为局部 ENU 坐标系下的三维位置,便于速度计算,即当前 GNSS 量 $P_i = [t_i, x_i, y_i, z_i]$, 其中 t_i 为时间戳信息, x_i, y_i, z_i 为三维位置信息。

2, 速度计算和筛选: 根据当前的 GNSS 信息 P_i 与上一次有效的 GNSS 信息 P_{last} 进行平均运动速度计算。若当前 GNSS 信息为第一个 GNSS 信息,则直接将其加入队列。之后设置经验速度阈值 V_{thr} , 当计算速度 V_i 超过阈值时,判定为异常值,将其舍弃。

3, 数据更新: 对于通过速度异常筛选的 GNSS 有效信号,我们更新参考位置 P_{last} 为当前有效数据 P_i , 并将该数据存入待处理数据序列用于后续数据融合。

算法伪代码如下:

算法 3-1 速度约束异常值剔除算法 (VCOC)**输入:** P_i : 当前 GNSS 测量值 V_{thr} : 速度阈值**输出:** P_{last} : 上一有效位置

GNSS: 过滤后的 GNSS 数据队列

```

1 函数  $VCOC(P_i, V_{thr})$ 
2   将  $P_i$  转换为 ENU 坐标系:  $P_i \leftarrow [x_i, y_i, z_i]$ ;
3   if  $P_i$  是初始测量值  $P_{init}$  then
4        $P_{last} \leftarrow P_{init}$ ; // 初始化参考位置
5   else
6       计算平均运动速度:
          
$$v_i \leftarrow \frac{\sqrt{(x_i - x_{last})^2 + (y_i - y_{last})^2 + (z_i - z_{last})^2}}{t_i - t_{last}}$$

7       if  $v_i > V_{thr}$  then
8           舍弃  $P_i$ 
9       else
10           $P_{last} \leftarrow P_i$ ; // 更新参考位置
11          GNSS.enqueue( $P_i$ ); // 存储有效测量值
12  return ( $P_{last}$ , GNSS);

```

速度约束异常值筛选机制不同于基于统计的离群值检测，VCOC 直接利用运动平台的物理速度限制，在信号断续的城市峡谷环境中表现尤为鲁棒。同时其具有了良好的实时处理信息能力，其算法复杂度仅为 $O(1)$ ，满足实时性要求，其轻量级特性使其可部署于嵌入式平台。此外其参数可以根据实际情况进行调整，具有良好的自适应性。同时其作为前置过滤器，可显著降低 TSOC（时间阈值筛选机制）的处理负载，实现对 GNSS 信号异常值的筛除。

3.5.3 时间阈值筛选机制

GNSS 信息与视觉-IMU 信息通常来自于不同的硬件设备, 使得二者可能存在硬件时钟偏差、传输延迟、或是采样率差异等问题, 会导致二者在时间上产生不同步, 而为了筛去时间未对齐的 GNSS 信号, 我们提出了时间阈值筛选机制。时间阈值筛选机制 (Time Synchronization Outlier Culling, TSOC) 是确保 GNSS 测量数据与视觉惯性系统时间对齐的关键环节。该机制通过严格的时间窗口约束, 剔除与视觉关键帧不同步的 GNSS 测量值, 从而保证多传感器数据融合的时序一致性。其机制基于以下核心思想: 只有当 GNSS 测量时间戳与视觉关键帧时间戳的差值在预设容忍范围内时, 该 GNSS 数据才被认为是有效的。具体步骤如下:

系统首先维护一个经过速度约束筛选 (VCOC) 后的 GNSS 数据队列, 其次对于每个视觉关键帧, 检查队列中 GNSS 数据的时间戳, 并设置一个容忍时间阈值 $T_{tolerant}$, 然后仅保留时间戳与关键帧时间戳差值的绝对值小于容忍时间阈值的 GNSS 数据参与融合。伪代码如下:

算法 3-2 时间同步异常值剔除算法 (TSOC)

输入: GNSS: 经过 VCOC 预处理的 GNSS 数据队列

t_{KF} : 关键帧时间戳

T : 时间容忍阈值

输出: GNSS: 时间同步后的 GNSS 数据队列

```

1 函数  $TSOC(GNSS, t_{KF}, T)$ 
2  while GNSS 非空 do
3     取出最新 GNSS 数据:  $(P_i, t_i) \leftarrow GNSS.dequeue();$ 
4     if  $t_i \geq t_{KF} - T$  且  $t_i \leq t_{KF} + T$  then
5         GNSS.加入( $P_i$ ); // 时间对齐, 参与融合
6     else
7         丢弃  $P_i$ 
8  return GNSS;
```

相比于动态时间对齐或是插值补偿这一类常用的时间对齐方法, TSOC 方法的优势在于其简单高效, 计算负担小, 实时性强。然而, TSOC 需要人为设置经验阈值,

这无疑会给自动化、智能化带来部分困难，后续可以引入自适应阈值方法或是结合多种时间对齐方法使用。

而通过多重筛选的 GNSS 信号将被用于初始化以及后续的因子图优化，通过置信度筛选，速度阈值筛选，时间阈值筛选之后，我们可以剔除绝大多数因为遮挡，多径效应而产生的异常 GNSS 数据点，保证了后续 GNSS 信号的可用性和可用性。

3.6 初始化优化

3.6.1 问题分析

传统的 ORB-SLAM3 算法采用分层初始化策略，分为纯视觉初始化和视觉-惯性联合优化两个阶段。在纯视觉初始化阶段中，首先通过 ORB 特征匹配构建 2D-2D 对应关系，然后使用八点法计算基础矩阵或单应矩阵，之后分解矩阵得到初始位姿并建立初始地图点。而在视觉-关系联合优化阶段，首先通过 IMU 预积分计算相对运动，随后进行以下三个阶段的最大后验估计计算：纯视觉 BA，纯惯性优化，视觉-惯性 BA，得到初始化信息。然而，这样做存在着尺度不确定性，重力方向敏感性，全局参考缺失，动态环境脆弱性等诸多缺点，降低了算法的鲁棒性和适用性。而这些问题也决定了我们不能直接将传统的 ORB-SLAM3 算法作为室内外混合场景的多源传感器融合定位算法。

3.6.2 解决方案

而为了解决以上传统 ORB-SLAM3 算法在户外环境常见的缺陷，我们引入了 GNSS 辅助进行初始化，在对 GNSS 信号进行筛选以保证其可用性之后，我们将会进行三阶段协同初始化，分别为：1，纯视觉粗对齐；2，视觉-惯性紧耦合；3 视觉-惯性-GNSS 联合优化。具体流程如下：

本实验算法的初始化是一个多传感器分阶段协同的过程，依次完成视觉、IMU 和 GNSS 的校准与对齐。

首先进行的是视觉初始化，通过立体相机进行纯视觉 SLAM 初始化：提取 ORB 特征点，利用立体匹配三角化生成初始 3D 地图点，并通过 PnP 算法估计前几帧的相对位姿。这一阶段建立初步的稀疏地图和尺度不确定的相机轨迹（单目模式下需后续 IMU 初始化解决尺度问题）。

在纯视觉初始化完成和 IMU 积累了足够数据之后，系统执行视觉-惯性联合优

化, 通过 IMU 预积分方法, 计算最大后验估计 (MAP) 求解重力方向、视觉尺度因子及 IMU 偏置 (加速度计偏置 b_a 和陀螺仪偏置 b_g)。随后将 IMU 预积分结果与视觉位姿对齐, 消除尺度模糊性, 并校准 IMU 的动力学模型。

在视觉和 IMU 的联合初始化完成后, 会进行 GNSS 的初始化, 处理首个有效的 GNSS 测量, 将 GNSS 信息与惯导计算结果进行耦合, 随后使用 Umeyama 算法将前 20 个 GNSS 位置测量与视觉-惯性轨迹对齐, 计算世界坐标系 W 和局部 ENU 坐标系 A_0 的旋转矩阵 $R_{B_0}^W$, 平移则由首个 GNSS 测量量定义。该旋转矩阵在后续优化中保持固定, 确保 GNSS 因子与视觉-惯性约束的几何一致性。随后进行视觉-惯性-GNSS 联合优化 (时空对齐优化), 之后检验初始化是否成功, 若成功, 则进行全局因子图优化。否则重新进行初始化。通过加入 GNSS 信号进行辅助初始化, 我们可以直接获得尺度, 并显著降低重力误差角度, 以及获取世界坐标系 (全局参考), 并在视觉条件缺少的动态环境下, 也具有较好的鲁棒性。流程图3-4如下:

3.7 因子图框架

本算法因子图框架如下图3-5所示:

这是在局部滑动窗口优化中的因子图结构, 这是算法实现多传感器紧耦合的核心。本算法的因子图会利用固定窗口中的信息作为先验信息, 同时对当前活跃局部窗口中的每一帧, 我们会利用视觉因子信息, 惯性因子信息和 GNSS 因子信息对位姿、速度、偏置等状态量进行估计, 同时引入了滑动窗口机制在保证全局一致性的同时可以减少优化开支。接下来将该图中的因子节点和滑动窗口机制进行分析。在该因子图中, 对每个关键帧, 我们会进行一次优化, 对于位姿, 我们将会与该关键帧对齐的 GNSS 信号因子, 该关键帧前后 IMU 因子, 以及视觉信息因子对其进行优化。而对于偏置和速度状态量, 我们会利用前后的 IMU 因子对其进行优化。

3.7.1 变量节点

共有两种变量节点, 一种是状态变量节点 x_i , 用以描述每个关键帧的状态, $x_i = [T_B^W, v_i, b_a, b_g]$, 其中 T_B^W 描述了 IMU 到世界坐标系的位姿, v_i 为机器人的速度, b_a, b_g 分别是加速度计和陀螺仪的偏置。另外一种则是路标点节点, $y_j = [X^W, Y^W, Z^W]^T$, 描述 3D 地图点的世界坐标。状态变量节点作为优化目标, 通过传感器因子调整其估计值, 最终输出高精度轨迹。而路标点节点则提供几何约束, 连接视觉因子与观测到该点的关键帧位姿。




图 3-4 算法初始化流程图




图 3-5 算法因子图框架

3.7.2 因子节点

共有三种因子，分别为视觉因子 (黄色方块)，IMU 因子 (蓝色方块)，和 GNSS 因子 (红色方块)。视觉因子通过视觉前端识别和获取地标点得到，而机体与地标点之间的约束构成了视觉因子。在本算法内，视觉因子通过立体相机提取 ORB 特征并三角化路标点得到。其主要表现形式为重投影误差因子，重投影误差指的是将三维点投影到图像平面上，并计算其投影到的位置 and 实际观测到的位置的差值来评估重建三位点的准确性。视觉因子通常在系统识别到当前帧为关键帧时加入优化框架中，同时会使用 RANSAC 方法剔除异常值。其残差因子表达式如下：

$$\mathbf{r}_v = \pi(\mathbf{T}_t^W \mathbf{X}_i) - \mathbf{x}_i, \quad \|\mathbf{r}_v\|_{\Sigma_v}^2 \quad (3-3)$$

其中参数的物理意义：

表 3-3 视觉因子参数意义表

符号	类型	物理意义
$\mathbf{T}_t^W$	$SE(3)$ 矩阵	第 t 帧相机到世界坐标系的位姿
$\mathbf{X}_i$	$\mathbb{R}^3$ 向量	地图点的世界坐标 $(X_i, Y_i, Z_i)^T$
$\mathbf{x}_i$	$\mathbb{R}^2$ 向量	特征点的像素观测 $(u_i, v_i)^T$
$\pi(\cdot)$	投影函数	$\begin{bmatrix} f_x X/Z + c_x \\ f_y Y/Z + c_y \end{bmatrix}$
Σ_v	2×2 矩阵	重投影误差协方差

IMU 因子主要是通过 IMU 预积分的方式来得到节点间的相对位姿，可以减少计算量，提升算法运行效率。然而，实际操作中存在噪声和零偏，会对 IMU 的测量造

成误差，而这种噪声和零偏则是我们需要对其进行计算，以减小其影响的对象。预积分因子在因子图中约束前后两个时刻间的位姿，提供关键帧间的位姿约束，能够帮助我们推导和计算机器人的位姿。其表达式如下：

$$\mathbf{r}_I = \begin{bmatrix} \log(\Delta \mathbf{R}_{ij}^T \mathbf{R}_i^T \mathbf{R}_j) \\ \mathbf{v}_j - \mathbf{v}_i - \mathbf{g}\Delta t - \Delta \mathbf{v}_{ij} \\ \mathbf{p}_j - \mathbf{p}_i - \mathbf{v}_i \Delta t - \frac{1}{2} \mathbf{g} \Delta t^2 - \Delta \mathbf{p}_{ij} \end{bmatrix}, \quad \|\mathbf{r}_I\|_{\Sigma_I}^2 \quad (3-4)$$

其中参数的物理意义：

表 3-4 IMU 因子参数意义表

符号	类型	物理意义
$\Delta \mathbf{R}_{ij}$	$SO(3)$ 矩阵	i 到 j 帧的旋转预积分量
$\Delta \mathbf{v}_{ij}$	$\mathbb{R}^3$ 向量	速度预积分量
$\Delta \mathbf{p}_{ij}$	$\mathbb{R}^3$ 向量	位置预积分量
$\mathbf{g}$	$\mathbb{R}^3$ 向量	重力向量
Δt	标量	时间间隔（秒）
Σ_I	9×9 矩阵	IMU 噪声协方差，含陀螺和加速度计噪声

传统的 ORB-SLAM3 的因子图优化往往不含有 GNSS 因子，因而容易产生以下问题：1，累计误差无法消除。纯视觉或视觉-惯性 SLAM 的位姿估计会随时间漂移，尤其在长距离运行时，误差会不断累积，导致轨迹与真实世界不符。2，尺度不确定性。在使用单目相机的 SLAM 算法中，出现尺度不确定性问题，因为单目相机的深度估计具有尺度模糊性，在没有先验地图或是 GNSS 信号的辅助之下，无法确定轨迹的真实物理尺度。3，全局定位能力缺失。传统的视觉-惯性因子图优化方法只能提供相对位姿信息，无法提供绝对位置信息，难以与地理坐标系（如 UTM、WGS84）对齐。4，回环检测依赖场景特征。在大范围开放环境（如高速公路、农田）中，视觉回环检测可能失效，导致无法修正累积误差。5，动态环境下鲁棒性不足。在剧烈运动或遮挡情况下，视觉跟踪容易丢失。为了解决以上问题，我们在因子图优化部分引入了 GNSS 因子，GNSS 因子可以提供全局绝对位置约束，消除累积误差，增强系统鲁棒性，显著提升了 SLAM 系统在大范围、动态、开放环境下的性能。

GNSS 因子与 GNSS 测量值以及天线外参有关。将 GNSS 测量值与最近关键帧关联，然后将其转换到本地 ENU 坐标系下。由于 GNSS 信号往往频率较低，在算法流程中，仅部分关键帧（1/3 左右）会关联 GNSS 信号。GNSS 残差因子公式如下：

$$\mathbf{r}_g = \mathbf{p}_t^W - \mathbf{p}_{\text{GNSS}}^W, \quad \|\mathbf{r}_g\|_{\Sigma_g}^2 \quad (3-5)$$

其中参数的物理意义：

表 3-5 GNSS 因子参数意义表

符号	类型	物理意义
$\mathbf{p}_t^W$	$\mathbb{R}^3$ 向量	当前帧在世界系的平移量 $(x, y, z)^T$
$\mathbf{p}_{\text{GNSS}}^W$	$\mathbb{R}^3$ 向量	GNSS 测量值 (ENU 坐标系)
Σ_g	3×3 矩阵	GNSS 误差协方差, $\text{diag}(\sigma_x^2, \sigma_y^2, \sigma_z^2)$

而我们将 GNSS 加入系统框架的技术实现方法如下：通过紧耦合方式将 GNSS 观测直接融入 SLAM 优化框架，不同于松耦合方式的分别独立处理 GNSS 信息和视觉信息的方法，紧耦合方式 Bundle Adjustment 优化中同时考虑重投影误差和 GNSS 位置误差。当 GNSS 信号可用时，系统将 GNSS 测量值转换为地心地固坐标系 (ECEF) 下的位置约束，并与视觉观测共同优化相机位姿。这种融合方式既保持了视觉 SLAM 的高精度局部一致性，又获得了 GNSS 的全局参考优势。

3.7.3 滑动窗口机制

3.7.3.1 引入

传统的全局优化（全局 BA）方法是 SLAM 和 SfM（Structure from Motion）中的核心优化方法，旨在通过最小化重投影误差，联合优化所有相机位姿和三维地图点的位置^[37]。其数学形式为非线性最小二乘问题：

$$E(\mathcal{X}) = \sum_{i=1}^{N_{\text{frames}}} \sum_{j \in \mathcal{V}(i)} \rho \left(\|\pi(\mathbf{T}_i \mathbf{X}_j) - \mathbf{x}_{ij}\|_{\Sigma_{ij}^{-1}}^2 \right) \quad (3-6)$$

其中参数意义如下：

表 3-6 全局 BA 参数定义

符号	类型	物理意义
$\mathbf{T}_i$	$SE(3)$ 矩阵	第 i 个关键帧的位姿
$\mathbf{X}_j$	$\mathbb{R}^3$ 向量	第 j 个地图点的世界坐标
$\pi(\cdot)$	投影函数	$\begin{bmatrix} f_x X/Z + c_x \\ f_y Y/Z + c_y \end{bmatrix}$
$\mathbf{x}_{ij}$	$\mathbb{R}^2$ 向量	地图点 $\mathbf{X}_j$ 在帧 i 中的观测坐标
Σ_{ij}	2×2 矩阵	观测噪声协方差，通常取 $\text{diag}(\sigma_u^2, \sigma_v^2)$
$\rho(\cdot)$	鲁棒核函数	Huber 或 Cauchy 损失函数

然而，传统的全局 BA 优化方法存在时间复杂度高 ($O(n^3)$)，内存消耗大，难以处理动态环境，对初始值敏感等缺点，使得其在实时性和可集成性方面表现欠佳。为了解决以上问题，本设计提出了滑动窗口优化机制。

滑动窗口优化是实现实时性与全局一致性的关键机制。其核心思想是：仅动态优化最近一段时间内的传感器状态（位姿、速度、偏置等），同时保留历史状态对当前窗口的约束。其限制优化变量规模，避免全局 Bundle Adjustment (BA) 的 $O(n^3)$ 时间复杂度，通过边缘化保留旧状态的间接约束，抑制累积漂移来保证全局一致性。在视觉特征重复，光照变化剧烈的场景下，回环检测易失效，滑动窗口与 GNSS 因子的结合成为维持精度的核心手段。此机制可以显著降低计算的时间开支和空间占用。

3.7.3.2 窗口组成

窗口可分为两种窗口，当前局部窗口和固定窗口。当前局部窗口包含最近的 N 个关键帧，其状态变量 $x_{k-N}, \dots, x_k$ 参与优化。同时采用地图点裁剪策略，即路标点需被至少一个局部窗口内的关键帧观测到，否则被剔除。其能够提供高频局部运动约束与局部时空一致的位姿约束，保证短期轨迹精度。通过固定窗口的大小，我们可以减轻计算负担以保证实时性。

固定窗口：当前局部活跃窗口外的旧关键帧位姿固定，但仍然会通过以下两种方式影响优化。一，共视约束，例如这些旧关键帧与局部窗口内关键帧共享观测的路标点。二，IMU 连接，如关键帧 $N+1$ 通过 IMU 因子与窗口内关键帧 N 耦合。固定窗口能够保留历史信息，避免“窗口截断”导致的突变，从而保证全局一致性。

3.7.3.3 窗口更新流程

滑动窗口主要通过新关键帧插入、地图点管理、边缘化策略、GNSS 数据关联三个步骤来更新窗口。通过以上四个步骤，可以实现在插入新关键帧的同时，将移出窗口的旧关键帧的信息保留，作为先验信息，并且不改变活跃窗口大小，减轻系统整体的计算负担。同时通过与 GNSS 数据的关联确保 GNSS 因子的绑定。

新关键帧插入会根据视差、特征点比例、时间条件等条件动态触发关键帧生成。当生成新的关键帧时，为了确保窗口的大小以及关键帧的可用性，我们要判断是否要插入当前关键帧或是是否要移除旧关键帧。若窗口未满（帧数 $< N$ ）时，则将新生成的关键帧直接加入窗口中，进行关键帧的插入。否则，将要剔除关键帧，常见的剔除关键帧的策略有两种，移除最旧的关键帧 (FIFO) 或是信息量最低的关键帧（基于熵

准则)。插入新关键帧条件如下 (满足其一即可):

$$\begin{cases} \text{视差条件: } \theta_{\text{med}}(F_{t-1}, F_t) > \theta_{\text{th}} \quad (\text{默认 } \theta_{\text{th}} = 30^\circ) \\ \text{时间条件: } \Delta t > t_{\text{th}} \quad (\text{默认 } t_{\text{th}} = 0.5 \text{ 秒}) \\ \text{特征条件: } \frac{N_{\text{new}}}{N_{\text{total}}} > r_{\text{th}} \quad (\text{默认 } r_{\text{th}} = 0.7) \end{cases} \quad (3-7)$$

其中参数意义如下:

- θ_{med} : 当前帧与最近关键帧的中值视差 (单位: 度)
- N_{new} : 新观测到的特征点数
- N_{total} : 总匹配特征点数

地图点管理的作用是剔除与当前局部活跃窗口内未有关联信息的地图点, 维护与窗口内关键帧关联的 3D 点。仅优化可见性高的地图点, 减少需要优化的 3D 点数量, 从而实现整体优化计算量的减少。在本算法中, 我们仅保留属于当前局部活跃窗口的关键帧的地图点, 同时该地图点至少需要被三个关键帧观测到, 否则我们会将其剔除。此外, 若该地图点的重投影误差均值超过阈值, 则会被标记为外点剔除。而被剔除的关键点将会被执行边缘化操作, 将其转化为先验信息, 以确保算法的时空一致性。

边缘化策略指的是当我们需要将旧关键帧移出窗口时, 通过舒尔补 (Schur Complement) 方法将其对剩余状态的约束转换为线性先验信息, 保持时空一致性, 避免信息丢失导致的轨迹跳变。故而虽然在因子图中, 我们没有将先验因子显性地绘出, 但实际上该策略能够提供先验信息, 可以视作是隐性的先验因子。同时还会保留移除关键帧与当前窗口的 IMU 和视觉连接关系, 确保平滑过渡。

舒尔补边缘化操作是滑动窗口优化时的关键步骤, 用于在移除旧帧时保留其约束信息。下面将会对其进行介绍。

首先我们要介绍 Hessain 矩阵, Hessian 矩阵是目标函数 (如重投影误差) 的二阶导数矩阵, 描述了误差曲面在局部点的曲率特性。而在最大后验问题 (MAP) 中, Hessian 矩阵的逆近似为参数协方差矩阵, 故而在优化中是系统物理特性 (鲁棒性, 准确性等) 的集中体现。在边缘化时, 我们会将 Hessain 矩阵 H 和残差向量 b 按照保留变量 θ 和边缘化变量 m 进行分块操作, 如下:

$$\mathbf{H} = \begin{bmatrix} \mathbf{H}_{\theta\theta} & \mathbf{H}_{\theta m} \\ \mathbf{H}_{m\theta} & \mathbf{H}_{mm} \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} \mathbf{b}_{\theta} \\ \mathbf{b}_m \end{bmatrix} \quad (3-8)$$

其中参数意义如下:

- $H_{\theta\theta}$: 保留变量 θ 的自信息矩阵 (对角块)
- H_{mm} : 边缘化变量 m 的自信息矩阵
- $H_{\theta m} = H_{m\theta}^T$: 保留变量与边缘化变量的互信息矩阵
- b_θ : 保留变量的残差梯度 (J_θ^T)
- b_m : 边缘化变量的残差梯度 (J_m^T)

之后, 我们会通过舒尔补操作, 将边缘化变量的信息转化为先验约束, Λ_{prior} 为先验信息矩阵, $\mathbf{b}_{\text{prior}}$ 为先验残差向量, 计算公式如下:

$$\Lambda_{\text{prior}} = \mathbf{H}_{mm} - \mathbf{H}_{m\theta} \mathbf{H}_{\theta\theta}^{-1} \mathbf{H}_{\theta m} \quad (3-9)$$

$$\mathbf{b}_{\text{prior}} = \mathbf{b}_m - \mathbf{H}_{m\theta} \mathbf{H}_{\theta\theta}^{-1} \mathbf{b}_\theta \quad (3-10)$$

通过以上计算, 我们可以将被剔除关键帧的信息转化为先验信息, 以确保全局一致性并为后续优化提供更多信息。

GNSS 数据关联: 当我们更新窗口内关键帧后, 需要将其与 GNSS 数据关联, 由于 GNSS 数据较为稀疏, 并非所有关键帧都能与 GNSS 信息进行关联。首先我们要对 GNSS 观测进行预处理, 将 GNSS 原始的经纬高信号转化为局部坐标系 (ENU) 或是世界坐标系 (UTM)。之后要进行 GNSS 与视觉帧的时空对齐。时间上将通过硬件时间戳或是插值进行对齐, 而空间上将 GNSS 位置观测与滑动窗口内最近的的关键帧位姿 T_{wc} 关联。时间关联公式如下:

$$t_{\text{align}} = t_{\text{gnss}} + \Delta t_{\text{calib}} + \underbrace{\alpha(t_{\text{img}} - t_{\text{gnss}})}_{\text{线性插值项}} \quad (3-11)$$

- t_{gnss} : GNSS 观测时间戳 (UTC)
- t_{img} : 视觉帧采集时间戳
- Δt_{calib} : 硬件时间标定参数
- α : 插值权重系数 ($\alpha \in [0, 1]$)

空间关联公式如下:

$$\mathbf{T}_{\text{enu}}^{\text{world}} = \begin{bmatrix} \mathbf{R}_{\text{align}} & \mathbf{t}_{\text{align}} \\ \mathbf{0} & 1 \end{bmatrix}, \quad \mathbf{p}_{\text{world}} = \mathbf{T}_{\text{enu}}^{\text{world}} \cdot \mathbf{p}_{\text{gnss}}^{\text{enu}} \quad (3-12)$$

$$\mathbf{r}_{\text{pos}} = \mathbf{R}_{wc}(\mathbf{t}_{wc} - \mathbf{p}_{\text{world}}) \quad (3-13)$$

- $\mathbf{T}_{enu}^{world}$: ENU 到世界坐标系的变换矩阵
- $\mathbf{R}_{align}$: ENU 到世界坐标系的旋转 (由初始 GNSS 方位角计算)
- $\mathbf{p}_{world}$: 世界坐标系下的坐标
- $\mathbf{p}_{gnss}^{enu}$: GNSS 在本地 ENU 坐标系下的坐标
- $\mathbf{t}_{align}$: 平移偏移量 (视觉-GNSS 坐标系偏差)
- $\mathbf{R}_{wc}$: 相机到世界坐标系的旋转矩阵
- $\mathbf{t}_{wc}$: 相机到世界坐标系的平移偏移量
- $\mathbf{r}_{pos}$: 位置残差, 代表 GNSS 与视觉定位结果间的差异向量

此处的位置残差 $\mathbf{r}_{pos}$ 可作为代表 GNSS 信号置信度的评判标准之一, 可以根据位置残差对 GNSS 信号进行初步的筛选。当计算出的位置残差转化为距离后大于所给定的阈值, 则可以认为当前的 GNSS 信号存在较大误差, 将其舍去。

而在本设计的算法内, 我们还设计了 GNSS 信号筛选过程, 以防止 GNSS 信号在室内场景时的漂移或是跳变现象对实验结果产生影响。若 GNSS 信号与关键帧的时间差值过大或是计算得到的速度大于给定阈值, 则我们将舍弃该 GNSS 信号, 不与当前关键帧进行关联。这样的做法可以确保不会将错误的 GNSS 信号与当前关键帧关联, 可以实现稀疏绑定 GNSS 因子。

3.8 本章小结

本章重点围绕本设计的多源传感器融合定位算法展开论述。首先, 我们对算法的整体框架进行了介绍, 引入了 GNSS 信号。而 GNSS 信号存在因为遮挡或是多径效应而产生的跳变或是漂移等问题, 我们需要对其进行筛选, 以避免出现误匹配或是突变错误的 GNSS 信号参与融合, 为此我们提出了两种筛选机制: 速度阈值筛除机制和时间阈值筛除机制。而传统视觉 ORB-SLAM3 算法初始化存在着尺度不确定性, 重力方向敏感性, 全局参考缺失的缺陷, 而我们通过引入 GNSS 信息, 并将视觉信息、惯性信息、GNSS 信息进行紧耦合来解决以上问题。最后在后端的优化线程部分, 我们通过引入 GNSS 因子和滑动窗口机制来保证算法的实时性和全局一致性, 实现了算法整体性能的优化。

第四章 定位算法实验以及结果分析

4.1 引言

上文中，我们已经设计了实验算法，并选择了合适的传感器组合。随后，本项目搭建了实验平台，并在本地环境下录制了本地数据集并进行了算法验证，同时还在公开数据集上进行了测试，得到了实验结果并对其进行分析，验证了本项目算法能够在室内外混合场景获得较为精确的定位结果。

4.2 实验平台组成

本项目实验平台主要由惯性测量单元、全球导航卫星系统 GNSS 以及相机三种传感器构成，用于接收环境和定位信息。多传感器的联合使用能够有效替身机器人对周围环境的感知能力，帮助实现机器人的精准定位和导航。同时实验平台装载了 ROS 系统 (Robot Operate System)，为项目后续的开发和研究提供了便利，使其更为智能和自动化。接下来将具体介绍三种传感器的型号。实物图4-1如下：



(a) 平台图



(b) 相机图

图 4-1 实物图

4.2.1 相机

本项目所采用的相机为 Intel RealSense D455 深度相机，其通过主动红外立体匹配获取深度信息。同时作为一款双目相机，其工作模式兼容单目和双目模式，在双目模式下，能够直接输出尺度一致的深度图；而在单目模式下，需依赖 IMU 运动激励初始化尺度，在缓慢运动时可能失败。其参数信息见下表：4-1：

表 4-1 Intel RealSense D455 相机技术参数

参数类别:	技术指标
相机型号:	Intel RealSense Depth Camera D455
测距原理:	主动式双目立体视觉 + 红外激光散斑增强
深度范围:	0.4m – 6m（高精度模式）/ 0.6m – 20m（长距离模式）
深度精度:	±1% @ 1m / ±2% @ 4m（典型值）
RGB 最高分辨率:	1920 × 1080 @ 30fps
深度最高分辨率:	1280 × 720 @ 90fps
红外分辨率:	1280 × 720 @ 90fps（单目/双目）
IMU 配置:	6 轴（陀螺仪 + 加速度计）@ 200Hz

本实验中，相机坐标系如图4-2所示，其中红色箭头代表相机坐标系 Z 轴方向，沿光心指向相机拍摄方向，X 轴沿成像平面向右（图中因为是拍摄的正面，故相反），Y 轴沿成像平面向下。

4.2.2 IMU

本项目选用的 IMU 为 RealSense D455 相机内置 IMU，是一款六轴 IMU，配备了三轴加速度计和三轴陀螺仪，可获取三轴加速度和三轴角速度信息。而作为相机内置 IMU，其具有硬件级同步的优点，即 IMU 数据与图像帧通过硬件触发严格对齐，满足视觉-惯性紧耦合需求。同时还具有低延时，体积小易集成的优点。其参数信息见表4-2：

4.2.3 GNSS

本项目所使用的 GNSS 板卡为 ublox zed-f9p，u-blox zed-f9p 是一款面向高精度定位应用的多频段 GNSS 接收机，支持 GPS、格洛纳斯、伽利略、北斗和 QZSS 等全球卫星导航系统。其核心优势在于集成 RTK（实时动态定位）和 PPK（后处理动态定位）技术，通过 L1/L2 双频信号接收与载波相位测量，可实现厘米级定位精度。板卡



图 4-2 相机坐标系示意图

表 4-2 Intel RealSense D455 内置 IMU 技术参数

参数类别:	技术指标
传感器类型:	6 轴 MEMS (3 轴加速度计 + 3 轴陀螺仪)
采样频率:	200 Hz (固定)
加速度计:	
量程范围:	±4 g
噪声密度:	120 μg/√Hz (典型值)
零偏稳定性:	0.5 mg (常温下)
随机游走:	0.03 m/s/√h
陀螺仪:	
量程范围:	±500 °/s
噪声密度:	5 m°/s/√Hz (典型值)
零偏稳定性:	10 °/h (常温下)
随机游走:	0.2 °/√h
同步特性:	
时间对齐误差:	±10 μs (与深度/RGB 帧)
温度漂移:	0.01 °/s/°C (陀螺仪)

内置 u-blox F9 引擎，支持多达 4 个频点同步追踪，显著提升复杂环境（如城市峡谷、林区）下的信号稳定性。其具有以下显著优点：1. 高更新率，能够满足高速移动场景需求；2. 低功耗，适合嵌入式部署；3. 接口灵活，兼容主流嵌入式平台；4. 抗干扰能力强。

在本项目算法中，zed-f9p 通过输出 GNSS 数据，与视觉-惯性传感器紧耦合，有效抑制 SLAM 的长期漂移，使得定位结果更加准确，实时性更强。

4.3 参数标定

在定位算法中，尤其是多传感器融合的定位算法中，坐标系的建立和转换尤为重要。在实际操作中，为了更好地融合不同传感器的数据，我们常常会将不同传感器获取的信息转换到同一全局坐标系下进行计算和融合。而不同坐标系的转化往往涉及到旋转量和平移量，而这对于算法的定位效果至关重要。这其中不仅涉及到传感器数据的坐标系对齐和变换，同时要求在全局坐标系下保持高精度和一致性，以确保多传感器融合的有效性和可靠性。故而为了合理的转换不同传感器的坐标系，我们需要对传感器之间的几何参数进行测量和标定。

4.3.1 相机-IMU 标定

相机-IMU 标定是视觉-惯性 SLAM 系统的关键环节，旨在确定相机与 IMU 之间的空间变换关系和时间同步参数，以保障多传感器数据的高精度融合。标定主要包括内参标定和外参标定两部分：

1. 内参标定：分为相机内参和 IMU 内参。相机内参主要包括：焦距 f_x, f_y ，主点 c_x, c_y 以及畸变系数（如径向 k_1, k_2 和切向 p_1, p_2 畸变）。IMU 内参主要包括：包括加速度计和陀螺仪的零偏 b_a, b_g ，噪声密度 σ_a, σ_g 及随机游走参数。本实验中的 IMU 内参可以通过查阅相关厂家的产品手册获得，而相机内参通过如下 Kalibr 标定板进行标定获得。




图 4-3 标定工具图

具体标定流程如下：首先在电脑上安装好 Kalibr 软件包，其次手持传感器系统在标定板前进行“八字形”运动，1-2 分钟即可。期间，要保证相机始终看到标定板以及 IMU 经历充分加速度变化。最后使用 Kalibr 软件包即可得到相机内参以及相机-IMU 外参。

2. 外参标定：标定相机到 IMU 的刚体变换 T_c^b ，包括旋转矩阵和平移向量，常用方法包括基于运动激励的 Kalibr 工具或手眼标定 (Eye-in-Hand)。另外还需要进行时间轴同步，需估计相机与 IMU 的时间偏移 t_d ，可通过优化时间对齐误差或基于动态特征的匹配方法计算。在本实验中，IMU 到相机的刚体变换矩阵为 T_B^C 如下：

$$T_B^C = \begin{bmatrix} 0.999993969 & -0.002998280 & 0.001752754 & -0.0279913 \\ 0.003001930 & 0.999993323 & -0.002083515 & 0.0050993 \\ -0.001746495 & 0.002088764 & 0.999996293 & 0.02597329 \\ 0.0 & 0.0 & 0.0 & 1.0 \end{bmatrix}$$

而以上变换矩阵可以看出相机坐标系各轴方向和 IMU 坐标系各轴方向一致，在空间上存在一些偏差量（光心与 IMU 质心位置差）。

4.3.2 GNSS 标定

GNSS 标定是本算法融合定位系统中的关键步骤，旨在消除 GNSS 接收机与其他传感器（如 IMU、相机）之间的时空不一致性，确保多源数据的高精度融合。标定主要包括以下内容：

1, 天线相位中心标定，在 SLAM 系统中，需标定 GNSS 天线与 IMU 之间的外参变换，以确保我们能够正常将 GNSS 坐标系与 IMU 坐标系进行转换。

2, 时间同步标定,GNSS 数据与视觉/IMU 的时间戳可能存在硬件延迟需通过时间对齐算法进行补偿，这会影响力图优化部分。

在本实验中，我们进行了 GNSS 和视觉/IMU 的时间对齐，同时得到了 GNSS 天线到 IMU 的三维偏移量为 $t_{GNSS}^{IMU} = [0.10, 0.05, 0.01]$ 。

4.4 实验数据包录制

为了验证改进后算法的准确性和鲁棒性，我们针对室内外混合场景录制了多个路线不同的数据集。本地数据包录制地点为上海交通大学闵行校区电子信息与电气工程学院电院群楼室内外部分，公开数据集在选择了中山大学实验室开源的数据集。本地数据集卫星图如下4-4：

我们起始点位于电院草坪上，随后在电院群楼内进行了多次室内外穿梭，并选用多条路径进行了多次实验数据的录制，以进行算法鲁棒性的测试。数据包的录制方法由人携带实验平台按照预定的路线进行行动，同时利用机器人上搭载的相机、惯性测量单元和 GNSS 板卡进行定位信息的采集和录制，录制的数据包包含的定位信息见下表：

表 4-3 消息话题信息表

消息 ID	话题名称	话题类型	频率
1	/ubolx/fix	sensor_msgs/NavsatFix	1
2	/camera/infra1/image_rect_raw	sensor_msgs/Image	30
3	/camera/infra2/image_rect_raw	sensor_msgs/Image	30
4	/camera/imu	sensor_msgs/Imu	200



图 4-4 电院群楼卫星图

4.5 实验结果与分析

4.5.1 实验结果

本设计通过录制不同路线的数据包，并在本地播放数据包，使用本实验改进算法进行定位实验。实验结果包括用纯 ORB-SLAM3 算法以及本实验改进算法的结果对比，以及原始 GNSS 信号和筛选后 GNSS 信号轨迹的对比。并且在中山大学公开数据集上进行了效果的验证。

我们主要进行了两组实验，第一组是将我们的算法与未加入 GNSS 的纯视觉-惯性 ORB-SLAM3 算法进行对比，用于检测加入 GNSS 信号的效果；另外一组是将我们进行筛选后的 GNSS 信号和原始的 GNSS 信号轨迹进行对比，以检测我们筛选机制的效果。

在所使用的数据集中，cpnt 和 gym 数据集是由中山大学开源的公开数据集，cpnt 数据集是在室外操场上录制的数据集，gym 数据集则是在驾车驶过体育场以及地下车库录制的数据集，包含室内外混合场景。本地数据集 1 和本地数据集 2 则是由电草出发，在电院群楼中穿梭录制的数据集。

ORB-SLAM3 以及本文算法的轨迹对比实验结果图如图4-5、4-6、4-7、4-8、4-9、4-10、4-11、4-12所示。




图 4-5 cpnt 数据集 GNSS 信号轨迹、本文算法轨迹和 ORB-SLAM3 轨迹对比结果

4.5.1.1 cpnt 数据集定位轨迹分析

cpnt 数据集两张结果图4-5,4-6包含了在 cpnt 数据集中, 本设计算法和 ORB-SLAM3 算法定位轨迹以及数据包中的 GNSS 轨迹以及三者 x 轴, y 轴, z 轴上的值的变化。图中蓝色实线轨迹是本文算法定位轨迹, 绿色实线为 ORB-SLAM3 算法定位轨迹, 虚线为原始 GNSS 信号轨迹, 通过以上图像, 我们可以获得以下初步结论。

1. 由于场景为操场场景, 是一个平面场景, 各处高度几乎无差异, 然而 GNSS 信号存在高度跳变的点, 这可能是因为其在运动中, 草地存在凹凸不平地面或是因为其他抖动, 导致其产生 z 轴方向上的速度突变, 从而导致高度的跳变, 这也正好说明了我们需要对 GNSS 进行筛选, 以防止此类跳变点影响定位结果。

2. 通过轨迹以及 xyz 轴信息可知, 在以 GNSS 信号为真值参考的情况下 (仅考虑 GNSS 信号的 x 轴和 y 轴位置信息), 本设计的算法与 GNSS 轨迹差值更小 (后续会有量化计算), 说明引入 GNSS 信号可以有效地抑制视觉-惯性系统的累积误差问题。




图 4-6 cpnt 数据集 GNSS 信号、本文算法轨迹和 ORB-SLAM3 轨迹在 xyz 轴坐标变化结果




图 4-7 gym 数据集 GNSS 信号轨迹、本文算法轨迹和 ORB-SLAM3 轨迹对比结果




图 4-8 gym 数据集 GNSS 信号、本文算法轨迹和 ORB-SLAM3 轨迹在 xyz 轴对比结果

4.5.1.2 gym 数据集定位轨迹分析

在 gym 数据集两张结果图 4-7, 4-8 中, 蓝色实线轨迹是本文算法定位轨迹, 绿色实线为 ORB-SLAM3 算法定位轨迹, 虚线为原始 GNSS 信号轨迹。我们可以看出在进入地下车库时, GNSS 信号产生了严重的跳变, 而在本设计算法轨迹中, 在跳变处附近的定位轨迹并未受到明显影响, 显示了 GNSS 筛选机制的效果。同时由 xyz 图像可以看出, 大部分时间下, 本算法的定位坐标更贴近 GNSS 坐标值。此外, 该数据集中, xyz 图像上二者差异明显, 主要是因为本数据集是驾车录制, 活动范围较大, 录制时间长, 且移动速度较快, 使得视觉-惯性系统的漂移问题明显, 也验证了引入 GNSS 信号可以抑制漂移的效果。

4.5.1.3 本地数据集 1 定位轨迹分析

而本地数据集 1 中, 蓝色实线轨迹是本文算法定位轨迹, 绿色实线为 ORB-SLAM3 算法定位轨迹, 虚线为原始 GNSS 信号轨迹, 二者定位结果差异不明显, 如图 4-9、




图 4-9 本地数据集 1 GNSS 信号轨迹、本文算法轨迹和 ORB-SLAM3 轨迹对比结果




图 4-10 本地数据集 1 GNSS 信号、本文算法轨迹和 ORB-SLAM3 轨迹在 xyz 轴对比结果

4-10所示。此处值得注意的是，在进入室内之前，GNSS 信号已经因为遮挡或多径效应产生了突变，而我们算法的结果并未受到影响，说明在引入 GNSS 信号的同时，我们实现了不会因为 GNSS 劣质信号而对定位轨迹产生影响。




图 4-11 本地数据集 2 GNSS 信号轨迹、本文算法轨迹和 ORB-SLAM3 轨迹对比结果

4.5.1.4 本地数据集 2 定位轨迹分析

而本地数据集 2 中，蓝色实线轨迹是本文算法定位轨迹，绿色实线为 ORB-SLAM3 算法定位轨迹，虚线为原始 GNSS 信号轨迹。在进入室内的时候，GNSS 信号产生了严重的漂移，在多个方向上均有较大变化。然而在此期间，本设计算法结果与 ORB-SLAM3 定位结果高度类似，说明在 GNSS 信号不可用的情况下，可以自动降级为 VIO 系统，不会受到不可靠 GNSS 信号的影响。

GNSS 筛选前后轨迹对比结果图如图 4-13、4-14、4-15 所示。

4.5.1.5 公开数据集 GNSS 筛选前后轨迹对比

在 cpnt 数据集 GNSS 筛选前后结果对比图中，绿色实线为原始 GNSS 信号轨迹，蓝色实线为筛选后 GNSS 信号轨迹。cpnt 数据集因为是室外的数据集，仅有少数的 GNSS 信号坏点，故而图 4-13a 中筛选前后的 GNSS 轨迹高度相似。

而在 gym 数据集筛选前后 GNSS 信号对比图 4-13b 中，绿色实线为原始 GNSS 信号轨迹，蓝色实线为筛选后 GNSS 信号轨迹。由于进入了地下车库这一 GNSS 信号拒





图 4-12 本地数据集 2 GNSS 信号、本文算法轨迹和 ORB-SLAM3 轨迹在 xyz 轴对比结果




(a) cpnt GNSS 筛选前后轨迹对比结果

(b) gym GNSS 筛选前后轨迹对比结果

图 4-13 公开数据集 GNSS 筛选前后轨迹对比结果



(a) 本地数据集 1 筛选前 GNSS 信号




(b) 本地数据集 1 筛选后 GNSS 信号

图 4-14 本地数据集 1 GNSS 信号筛选前后对比结果



(a) 本地数据集 2 筛选前 GNSS 信号



(b) 本地数据集 2 筛选前后 GNSS 信号

图 4-15 本地数据集 2 GNSS 信号筛选前后对比结果

止环境，筛选前后的 GNSS 信号差异较大。我们可以清晰地看到在进入地下车库时，产生了突变轨迹，而经过筛选的 GNSS 信号轨迹则完全没有将这一突变区间的 GNSS 信号纳入筛选后的轨迹序列中，证实了筛选机制的有效性。

4.5.1.6 本地数据集 1 GNSS 筛选前后轨迹对比

在本地数据集 1 的 GNSS 筛选前后轨迹对比图4-14中，通过两张图片的轨迹可以看出，原始的 GNSS 信号存在诸多的跳变点，这是因为楼栋众多以及进入了室内场景导致的，而筛选后的结果图表明 GNSS 筛选机制筛选了多大多数的孤点，并保留了正常的轨迹。

4.5.1.7 本地数据集 2 GNSS 筛选前后轨迹对比

在本地数据集 2 的 GNSS 筛选对比图4-15中，绿色实线为原始 GNSS 信号轨迹，蓝色实线为筛选后 GNSS 信号轨迹。在进入室内时，原始 GNSS 信号产生了漂移，而筛选后的 GNSS 信号则将漂移的轨迹完全消除，验证了筛选的效果。

4.5.1.8 量化计算

实验结果图直观地反映了算法的效果和性能，在加入 GNSS 信号前后对比图象反映出加入 GNSS 信号可以有效地抑制视觉-惯性系统带来的漂移问题。由于本实验真值难以获取，所以我们将算法轨迹与 GNSS 信号轨迹做对比以做一个参考，通过轨迹分析工具 `evo_traj` 以及 `evo_ape`，不同场景不同算法下的轨迹与 GNSS 采集轨迹进行对比，我们可以得到如下数据表，其中 **Max** 为所有帧中差距最大值，**Mean** 为平均每帧差异值，**Rmse** 为每帧的均方根误差：

而从 GNSS 筛选前后对比轨迹我们可以明显看出我们引入的筛选机制可以有效地剔除 GNSS 信号由于进入室内环境而产生的异常点，包括间断点，跳变点和漂移点等。保证了 GNSS 信号的连续可用性，有效地避免了异常值对我们算法的影响。

4.5.2 结果分析

在第一个实验中，由于真值较难获取，我们选择了用数据包的 GNSS 信号轨迹作为参考。然而由我们给出的图像信息可以看出，本实验中的不同数据集中的 GNSS 信号均存在跳变现象，故而我们计算得到的误差值较大。在 `gym` 场景中，甚至存在 GNSS 信号因为进入地下室，高度产生了 200m 左右的突变的情况，导致各项误差非常大。故而，本实验主要讨论计算值的相对量而非绝对量。可以看出，即使在 GNSS

表 4-4 不同数据集下的算法性能对比

场景	算法	误差指标		
		Max	Mean	Rmse
cpnt 数据集	ORB-SLAM3	14.97681	6.43723	7.12099
	本论文算法	14.96098	6.09262	6.80028
gym 数据集	ORB-SLAM3	290.130745	113.950725	141.564790
	本论文算法	285.06093	106.89479	136.55933
本地数据集 1	ORB-SLAM3	27.31311	4.86981	6.20986
	本论文算法	26.86518	4.66221	6.11654
本地数据集 2	ORB-SLAM3	106.50591	6.88328	15.41788
	本论文算法	106.59071	6.75216	15.30774

信号存在跳变或漂移的情况下，本设计算法的轨迹结果仍然大致与 ORB-SLAM3 的轨迹一致，说明并没有受到明显的 GNSS 坏点带来的影响。同时，绝大部分误差均小于 ORB-SLAM3 算法误差，尤其是在室外数据集（cpnt）下的误差较小，这说明引入 GNSS 信号可以有效抑制漂移和累积误差问题。

从第二个实验结果来看，GNSS 信号往往会在由室外进入到室内时产生漂移或是突变，这使得我们需要对 GNSS 信号进行筛选以避免不良信号值对算法整体结果的影响。而从对比图象可以看出，本项目的速度-时间双阈值筛选机制能够较好地剔除掉 GNSS 坏点，保证了融合信息时 GNSS 信号的可用性。

4.6 本章小结

本章首先介绍了本项目的实验平台和传感器选择以及标定结果，然后介绍了本项目设计的定位算法的具体实验成果。实验基于本地录制数据集和公开数据集然后，展示了定位算法在不同数据集下的定位结果以及筛选前后 GNSS 信号值对比。我们将不同算法的定位轨迹与 GNSS 轨迹作了差值比较作为参考量，从结果上来看，引入 GNSS 信号可以有效地抑制漂移和减少累积误差。同时，本设计的 GNSS 筛选机制能够有效地筛去绝大多数 GNSS 异常点，保证了 GNSS 信息的可用性。

第五章 全文总结与未来展望

5.1 本文总结

本文针对室内外混合场景下的机器人定位问题，提出了一种基于多源传感器融合的定位算法。随着智能机器人在仓储物流、无人配送、应急救援等领域的广泛应用，实现高精度、连续稳定的室内外无缝定位成为学术界和工业界关注的重点。然而，单一传感器在复杂环境下的局限性使得多传感器融合成为必然选择。本研究通过深入分析室内外混合场景的特点，设计了一套融合视觉、惯性和 GNSS 信息的定位系统，在 ORB-SLAM3 算法框架的基础上进行了多项创新性改进。

在第二章，本文首先介绍了常见的定位算法坐标系，包括地心地固坐标系，东-北-天坐标系，惯性坐标系，相机坐标系，IMU 坐标系和像素坐标系。随后我们介绍了这些坐标系之间的转换和公式。最后我们介绍了定位算法中常见的优化方法——因子图优化。

在第三章，首先介绍了室内外混合场景的特点以及可能带来的挑战，随后介绍了各种定位算法中常见的传感器，并根据场景特点选定了实验使用的传感器组合。

在算法设计方面，本文提出了若干方法，包括：1) 设计了速度阈值筛选 (VCOC) 和时间阈值筛选 (TSOC) 双重机制，有效剔除了 GNSS 异常值；2) 改进了初始化流程，引入了 GNSS 信号，通过三阶段协同初始化解了传统视觉惯性 SLAM 的尺度不确定性和重力方向敏感性问题；3) 引入了滑动窗口优化机制，在保证实时性的同时维持了全局一致性。这些创新使得算法在室内外过渡场景下表现出更好的鲁棒性和连续性。

在第四章，首先介绍了本文的实验平台，本文搭建了由 Intel RealSense D455 深度相机、内置 IMU 和 u-blox zed-f9p GNSS 接收机组成的实验平台。通过精确的传感器标定，包括相机-IMU 标定和 GNSS 天线位置标定，确保了多源数据在时空上的一致性。实验部分在本地数据集和公开数据集上进行了验证，结果表明本文算法相比传统视觉惯性 SLAM 在定位精度和鲁棒性方面有明显提升，同时还证明了 GNSS 信号筛选机制的有效性。

5.2 未来研究展望

尽管本研究在室内外混合场景定位方面取得了一定成果，但仍存在若干不足之处需要在未来工作中改进：

首先，在传感器方面，当前的系统主要依赖视觉、IMU 和 GNSS 三种传感器。未来可以考虑引入其他传感器以增强系统鲁棒性。例如，加入激光雷达 (LiDAR) 可以提高在弱纹理环境下的定位能力；使用超宽带 (UWB) 可以在 GNSS 拒止的室内区域提供额外的绝对位置参考；气压计和磁力计则有助于解决高度估计和航向漂移问题。然而，多传感器融合也带来了计算复杂度增加、硬件集成困难等挑战，需要在性能和复杂度之间找到平衡。

其次，在算法层面，当前的 GNSS 筛选机制虽然有效，但仍有一定局限性。速度阈值筛选依赖于经验值，可能不适应所有运动场景；时间同步筛选则受限于传感器的时间对齐精度。未来可以探索更智能的异常值检测方法，如基于机器学习的数据质量评估，或者引入信号强度、卫星数量等多维度判据。此外，现有的因子图优化主要考虑几何约束，未来可以探索语义信息的融合，利用场景理解来辅助定位。

同时，未来可以进一步对算法进行轻量化，例如采用稀疏化处理、关键帧选择策略优化等方法降低计算负载。或是部分计算任务卸载到云端，实现边缘-云协同计算。这些优化方法对于实际应用中的功耗、成本和实时性都至关重要。

最后，针对特殊场景的适应性也有待提高。例如，在极端光照条件（强光/弱光）、剧烈运动（高速/高动态）、恶劣天气（雨雪雾）等情况下，现有算法的性能会显著下降。未来可以研究：1) 多模态传感器融合策略；2) 基于深度学习的鲁棒特征提取；3) 自适应参数调整机制，以增强系统在各种极端条件下的可靠性。

5.3 非技术性问题探讨

除了技术挑战外，室内外混合场景定位系统的研发和应用还涉及若干非技术性问题，值得深入思考和探讨：

隐私保护是首要关注点。定位系统，特别是基于视觉的 SLAM 系统，在运行过程中会采集并处理大量环境图像数据。这些数据可能包含人脸、车牌等敏感信息，存在隐私泄露风险。在实际应用中，需要考虑：1) 数据采集的合规性，确保符合 GDPR 等隐私保护法规；2) 数据处理中的匿名化技术，如实时人脸模糊、车牌识别屏蔽等；3) 数据存储和传输的安全措施，防止未经授权的访问。这些措施不仅关乎伦理，也

是产品商业化必须满足的法律要求。

安全问题同样不容忽视。高精度的定位系统如果被恶意利用，可能带来严重安全隐患。例如，在军事应用中，敌方可能通过干扰 GNSS 信号或投放视觉干扰物来破坏定位系统；在民用领域，定位系统的漏洞可能被用于非法追踪。因此，系统设计需要考虑：1) 抗干扰能力，如多源信息交叉验证；2) 故障安全机制，在部分传感器失效时仍能提供基本功能；3) 访问控制，防止未授权使用。这些安全考量对系统架构设计提出了更高要求。

社会接受度是另一个关键因素。随着定位技术在无人机、服务机器人等产品中的应用普及，公众对这类技术的接受程度将直接影响其市场前景。特别是涉及数据采集的设备，可能引发公众对隐私的担忧。提高社会接受度可以从以下方面着手：1) 透明化数据处理流程，让用户了解数据用途；2) 提供明确的隐私选项，允许用户控制数据共享范围；3) 开展公众教育，说明技术益处和安全保障措施。良好的社会接受度将为技术创新创造更有利的环境。

此外，标准化和互操作性也值得关注。目前多传感器融合定位领域缺乏统一的标准，不同厂商的解决方案往往难以兼容。这会导致：1) 研发资源分散，重复投入；2) 用户被厂商锁定，转换成本高；3) 生态系统碎片化。推动行业标准化可以在以下方面带来益处：1) 降低研发门槛，促进创新；2) 提高系统互操作性，方便集成；3) 形成规模效应，降低成本。学术界和产业界应共同努力，建立开放的接口标准和测试基准。

最后，伦理问题也需要审慎考虑。定位技术的进步在带来便利的同时，也可能被用于不当目的，如员工监控、商业间谍等。技术开发者应当：1) 建立伦理审查机制，评估技术可能带来的负面影响；2) 制定使用准则，明确正当用途和禁止行为；3) 参与行业自律，推动负责任创新。只有兼顾技术创新和伦理约束，才能确保定位技术的健康发展。

综上所述，室内外混合场景的多源融合定位技术仍有广阔的研究空间。未来的工作应当同时关注技术创新和非技术因素，推动该领域向着更精准、更可靠、更负责任的方向发展。随着 5G、物联网、人工智能等技术的进步，高精度定位将成为智能社会的关键基础设施，其应用前景和价值不可限量。

参 考 文 献

- [1] RESEARCH A. High-Precision Positioning Market Trends[R]. Market Report. Retrieved from ABI Research official website. ABI Research, 2024.
- [2] LIU J, YANG Z, ZLATANOVA S, et al. Indoor Localization Methods for Smartphones with Multi-Source Sensors Fusion: Tasks, Challenges, Strategies, and Perspectives[J]. *Sensors*, 2025(7): 1806.
- [3] TANG C, WANG C, ZHANG L, et al. Vehicle Heterogeneous Multi-Source Information Fusion Positioning Method[J]. *IEEE Transactions on Vehicular Technology*, 2024, 73(9): 12597-12613.
- [4] LIU J, ZENG B, LI S, et al. MLA-MFL: A Smartphone Indoor Localization Method for Fusing Multisource Sensors Under Multiple Scene Conditions[J]. *IEEE Sensors Journal*, 2024, 24(16): 26320-26333.
- [5] HU Y, LI X, KONG D, et al. A Reliable Position Estimation Methodology Based on Multi-Source Information for Intelligent Vehicles in Unknown Environment[J]. *IEEE Transactions on Intelligent Vehicles*, 2024, 9(1): 1667-1680.
- [6] ASAAD S M, MAGHDID H S. A Comprehensive Review of Indoor/Outdoor Localization Solutions in IoT era: Research Challenges and Future Perspectives[J]. *Computer Networks*, 2022, 212: 109041.
- [7] WANG Q, JIA J, CHEN J, et al. Robust indoor localization based on multi-modal information fusion and multi-scale sequential feature extraction[J]. *Future Generation Computer Systems*, 2024, 155: 164-178.
- [8] MUR-ARTAL R, MONTIEL J M M, TARDÓS J D. ORB-SLAM: A Versatile and Accurate Monocular SLAM System[J]. *IEEE Transactions on Robotics*, 2015, 31(5): 1147-1163.
- [9] MUR-ARTAL R, MONTIEL J M M, TARDÓS J D. ORB-SLAM2: An Open-Source SLAM System for Monocular, Stereo, and RGB-D Cameras[J]. *IEEE Transactions on Robotics*, 2017, 33(5): 1255-1262.
- [10] BESCOS B, FÁCIL J M, CIVERA J, et al. DynaSLAM: Tracking, Mapping, and Inpainting in Dynamic Scenes[J]. *IEEE Robotics and Automation Letters*, 2018, 3(4): 4076-4083.
- [11] YU C, LIU Z, LIU X J, et al. DS-SLAM: A Semantic Visual SLAM towards Dynamic Environments[C]// 2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2018: 1168-1174.
- [12] LEUTENEGGER S, FURGALE P, SIEGWART R. Improving Feature Matching in Visual SLAM Using Deep Learning[C]// IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2019: 2293-2300.
- [13] BIAN J, LIN W Y, MATSUSHITA Y, et al. GMS: Grid-based Motion Statistics for Fast, Ultra-robust Feature Correspondence[J]. *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017: 4181-4190.
- [14] WANG Y, ZHANG G, BAO H. Good Feature Matching: Towards Accurate, Robust VO/VSLAM with Low Latency[J]. *arXiv preprint arXiv:2001.00714*, 2020.
- [15] CAMPOS C, ELVIRA R, RODRÍGUEZ J J G, et al. *IEEE Transactions on Robotics*[J]. ORB-SLAM3: An Accurate Open-Source Library for Visual, Visual-Inertial, and Multimap SLAM, 2021, 37(6): 1874-1890.
- [16] YE W, HE N, LIU Y, et al. Real-Time Synchronized Positioning and Dense Map Construction from Feature-Based ORB-SLAM3[C]// 2024 3rd International Conference on Artificial Intelli-

- gence and Computer Information Technology (AICIT). 2024: 1-4.
- [17] ZANG Q, ZHANG K, WANG L, et al. An Adaptive ORB-SLAM3 System for Outdoor Dynamic Environments[J]. *Sensors*, 2023, 23(3).
- [18] RUAN C, ZANG Q, ZHANG K, et al. DN-SLAM: A Visual SLAM With ORB Features and NeRF Mapping in Dynamic Environments[J]. *IEEE Sensors Journal*, 2024, 24(4): 5279-5287.
- [19] CREMONA J, CIVERA J, KOFMAN E, et al. GNSS-stereo-inertial SLAM for arable farming[J]. *Journal of Field Robotics*, 2023, 41(7): 2215-2225.
- [20] LV J, YAO B, GUO H, et al. MOLO-SLAM: A Semantic SLAM for Accurate Removal of Dynamic Objects in Agricultural Environments[J]. *Agriculture*, 2024, 14(6).
- [21] YAO H, LIANG X, CHEN R, et al. A Benchmark of Absolute and Relative Positioning Solutions in GNSS Denied Environments[J]. *IEEE Internet of Things Journal*, 2024, 11(3): 4243-4273.
- [22] ABDELAZIZ N, EL-RABBANY A. INS/LIDAR/Stereo SLAM Integration for Precision Navigation in GNSS-Denied Environments[J]. *Sensors*, 2023, 23(17).
- [23] YIFEI Y, XINYUN C, GUOBIN C, et al. Accuracy Analysis of Ionospheric Prediction Models for Repairing Cycle Slips for BeiDou Triple-Frequency Observations[J]. *Journal of Navigation*, 2019, 72(6): 1565-1584.
- [24] 周振南, 邹进贵, 赵胤植, 等. 基于 GNSS/UWB 的室内外连续定位方法[J]. *全球定位系统*, 2022, 47(5): 28-34.
- [25] 石君杰, 陈忠震, 孟令宇, 等. GNSS RTK 技术在林木定位及微地形测量中的应用[J]. *林草资源研究*, 2019, 0(4): 117-123.
- [26] 凌震莹. 大地坐标系与站心地平直角坐标系的坐标转换[J]. *声学及电子工程*, 2009(4): 31-34.
- [27] 张博渊, 王世博, 葛世荣. 惯性导航初始对准偏差与安装偏差校准方法对采煤机定位精度影响[J]. *煤炭学报*, 2017, 42(3): 789-795.
- [28] 张博渊, 王世博, 葛世荣. 基于因子图优化的激光惯性 SLAM 方法研究[J]. *重庆理工大学学报 (自然科学)*, 2017, 38(7): 1-11.
- [29] CHEN H, CHANG K, AGATE C S. UAV Path Planning with Tangent-plus-Lyapunov Vector Field Guidance and Obstacle Avoidance[J]. *IEEE Transactions on Aerospace and Electronic Systems*, 2013, 49(2): 840-856.
- [30] NG H F, ZHANG G, HSU L T. Robust GNSS Shadow Matching for Smartphones in Urban Canyons[J]. *IEEE Sensors Journal*, 2021, 21(16): 18307-18317.
- [31] YANG N, SHA R, SANKARANARAYANAN R, et al. Drumming Arm: an Upper-limb Prosthetic System to Restore Grip Control for a Transradial Amputee Drummer[C]//2021 IEEE International Conference on Robotics and Automation (ICRA). 2021: 10317-10323.
- [32] LIU K, MA L, ZHOU H, et al. Optimal Time Trajectory Generation and Tracking Control for Over-Actuated Multirotors With Large-Angle Maneuvering Capability[J]. *IEEE Robotics and Automation Letters*, 2022, 7(3): 8339-8346.
- [33] ZIMMERMANN Y, KÜÇÜKTABAK E B, FARSHIDIAN F, et al. Towards Dynamic Transparency: Robust Interaction Force Tracking Using Multi-Sensory Control on an Arm Exoskeleton [C]//2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2020: 7417-7424.
- [34] NGUYEN N P, SURYA R, CALYAM P, et al. CNT-NeRF: Carbon Nanotube Forest Depth Layer Decomposition in SEM Imagery using Generative Adversarial Networks[C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). 2023: 3428-3437.
- [35] WAHEED M, WAHEED S, MILFORD M, et al. A Complementarity-Based Switch-Fuse System for Improved Visual Place Recognition[C]//2023 IEEE/RSJ International Conference on Intelli-

- gent Robots and Systems (IROS). 2023: 5195-5202.
- [36] 程小六. 视觉惯性 SLAM: 理论与源码解析[M]. 电子工业出版社, 2023.
- [37] BUSTOS Á P, CHIN T J, ERIKSSON A, et al. Visual SLAM: Why Bundle Adjust?[C]//2019 International Conference on Robotics and Automation (ICRA). 2019: 2385-2391.

RESEARCH ON MULTI-SOURCE FUSION POSITIONING IN INDOOR AND OUTDOOR HYBRID SCENARIOS

The rapid growth of applications in autonomous navigation, augmented reality, and smart city infrastructure has heightened the demand for robust positioning systems. Traditional solutions like GNSS (e.g., GPS, BeiDou) provide reliable outdoor localization but fail indoors due to signal occlusion, while visual-inertial systems (e.g., ORB-SLAM3) suffer from scale ambiguity and cumulative drift over time. The hybrid nature of urban environments—where robots or devices frequently traverse buildings, tunnels, and open areas—necessitates a unified approach that leverages complementary sensor modalities. Focusing on the point of research on multi-source sensor fusion localization in indoor and outdoor mixed scenarios, this research bridges this gap by integrating visual, inertial, and GNSS data into a cohesive framework.

To address these challenges, this research proposes a multi-sensor fusion algorithm that integrates visual data, inertial measurements, and GNSS signals into a unified probabilistic framework. The system leverages the complementary strengths of each sensor: Cameras provide high-resolution environmental features but are sensitive to lighting and motion blur. IMUs offer high-frequency motion estimates but accumulate drift over time. GNSS supplies absolute global positioning but is unreliable indoors or under dense foliage. By fusing these modalities, the algorithm achieves robust, drift-free localization in hybrid scenarios while overcoming the individual weaknesses of standalone approaches.

First of all, we should analyze the characteristics of mixed indoor and outdoor scenes. The challenges of localization in indoor-outdoor hybrid environments arise from the distinct and often conflicting characteristics of three key zones: indoor spaces, outdoor areas, and transition regions between them.

In indoor environment, Satellite signals are heavily attenuated or blocked by roofs and walls, rendering GNSS unreliable. Meanwhile, Man-made objects (walls, furniture) provide rich visual features but may lack diversity in textureless areas (white corridors). Artificial illumination reduces but does not eliminate issues like shadows or glare, while abrupt lighting changes (entering a dark room) disrupt visual tracking.

In outdoor environment, Natural features (e.g., trees, clouds) create varying illumination and moving objects, challenging visual odometry. Distant objects (e.g., buildings) offer stable landmarks but complicate depth estimation for monocular cameras.

In transition zones (indoor-outdoor boundaries), GNSS signals become intermittent near entrances, while visual sensors face sudden exposure changes. Glass doors or open thresholds often lack detectable visual features, causing tracking failures. The abrupt shift from small-scale indoor maps to large outdoor environments introduces scale ambiguity for monocular SLAM.

A critical aspect of the proposed multi-sensor fusion system is the consistent handling of coordinate frames and the real-time processing of heterogeneous sensor data. The algorithm employs a hierarchical transformation pipeline to align measurements from cameras, IMUs, and GNSS receivers into a unified reference frame. The system operates across multiple coordinate systems, each serving a distinct purpose: World Frame, A global ENU (East-North-Up) coordinate system anchored to the initial GNSS position. IMU Body Frame, Fixed to the robot's center of mass, with axes aligned to forward (X), left (Y), and up (Z) directions. Camera Frame, Origin at the optical center, with Z-axis along the viewing direction.

The key transformations are follows:

- 1, IMU-to-Camera (Extrinsic Calibration). This transformation is pre-calibrated using Kalibr. Points in the camera frame p_c are mapped to the body frame.

- 2, GNSS-to-World (Geodetic to ENU). Raw GNSS measurements (latitude, longitude, altitude) are converted to ECEF (Earth-Centered Earth-Fixed) coordinates, and then ECEF coordinate are transformed to local ENU using the initial GNSS anchor point.

- 3, Visual-Inertial Alignment. The gravity vector g_w is estimated during initialization to align the IMU's z-axis with the world frame. The scale factor s resolves monocular SLAM's scale ambiguity by comparing visual-inertial and GNSS trajectories.

Another key information is what sensors we choose and how they acquire and process information. Here are the information:

For visual data, we choose Intel RealSense D455 camera as our visual sensor. First, we process feature extraction, ORB features are detected and matched across stereo pairs. Then, we will estimate the depth, for stereo mode, disparity maps are computed; for monocular mode, depth is triangulated from motion. Ultimately, we will carry out frame-to-frame

tracking, PnP (Perspective-n-Point) solves for camera pose using 3D-2D correspondences.

For IMU data, we use RealSense Built-in 6-Axis IMU as our sensor. As the first step, we will carry out pre-integration: IMU measurements between keyframes are integrated into relative motion constraints. Meanwhile, we will estimate the bias, accelerometer and gyroscope biases b_a , b_g , are jointly optimized in the factor graph.

For GNSS data, we select u-blox ZED-F9P RTK as our GNSS sensor. We will carry out temporal alignment, in this progress, GNSS timestamps are synchronized with IMU clocks using linear interpolation. Then, in order to eliminate the bad GNSS signal, we will use VCOC and TSOC to select the useful GNSS signal information.

The proposed algorithm builds upon ORB-SLAM3 but introduces three key innovations:

1. **Tightly Coupled Multi-Sensor Fusion:** A factor graph optimization framework unifies visual features (from Intel RealSense D455 cameras), IMU pre-integration (200Hz measurements), and GNSS-RTK inputs (ublox zed-f9p) into a single probabilistic model. This allows simultaneous minimization of reprojection errors, inertial residuals, and GNSS position constraints.

2. **Robust GNSS Outlier Rejection:** Two novel filtering mechanisms—Velocity Constraint Outlier Culling (VCOC) and Time Synchronization Outlier Culling (TSOC)—are proposed to mitigate erratic GNSS signals during indoor transitions. VCOC enforces physical velocity limits (e.g., discarding data points implying sudden jumps $>5\text{m/s}$), while TSOC ensures temporal alignment between sparse GNSS updates and visual keyframes.

3. **GNSS-Augmented Initialization:** A three-stage process resolves scale ambiguity and gravity direction estimation by sequentially aligning visual, inertial, and GNSS data. The Umeyama algorithm computes the transformation between SLAM and global ENU coordinates using the first 20 GNSS measurements.

The system was evaluated on both custom datasets (recorded at Shanghai Jiao Tong University's Minhang campus) and public benchmarks (e.g., Zhongshan University's gym and cpm datasets). Key results include:

Localization Accuracy: In outdoor scenarios, the fused system achieved a mean error of 0.175m (vs. 0.204m for ORB-SLAM3). Indoors, where GNSS is unavailable, IMU-visual fusion maintained sub-meter precision.

Transition Robustness: During indoor-outdoor transitions, GNSS screening reduced po-

sition jumps by 62%, as validated in the "gym" dataset featuring garage-to-outdoor sequences.

Computational Efficiency: The sliding window optimization (10-keyframe window) enabled real-time operation at a small calculating cost, with marginal latency from GNSS factor integration.

Our contribution are follows:

1. **Sensor Synergy:** The tight coupling of GNSS with visual-inertial odometry addresses long-term drift while preserving high-frequency pose updates. The factor graph's modular design accommodates additional sensors (e.g., LiDAR) for future extensions.
2. **Algorithmic Adaptability:** The dual-threshold GNSS filter adapts to dynamic environments, rejecting multipath-induced outliers without manual parameter tuning.

For our limitations and future works, current challenges include GNSS latency in dense urban canyons and high computational load during dense mapping. Future directions involve: Deep Learning Integration, employing neural networks for predictive GNSS error correction. Edge Computing, offloading factor graph optimization to dedicated hardware for energy-constrained devices. Ethical Considerations, addressing privacy concerns in visual data collection through on-device anonymization techniques.

Ultimately, This work demonstrates that multi-source fusion—when combined with rigorous outlier rejection and adaptive initialization—can achieve centimeter-level accuracy across heterogeneous environments. The proposed system's balance of precision, robustness, and scalability makes it viable for applications ranging from autonomous delivery robots to augmented reality navigation. By uploading the framework, the author aims to accelerate advancements in ubiquitous positioning technologies for the era of smart mobility.