



上海交通大学学位论文

基于自然语言指令的人形机器人规划控制方法研究

姓 名：唐扬

学 号：522031910076

导 师：项艳 张伟楠

学 院：自动化与感知学院

专业名称：智能感知工程

申请学位层次：学士

2026 年 5 月

**A Dissertation Submitted to
Shanghai Jiao Tong University for the Degree of Bachelor**

**RESEARCH ON HUMANOID ROBOT PLANNING
AND CONTROL METHODS BASED ON NATURAL
LANGUAGE INSTRUCTIONS**

Author: Tang Yang

Supervisor: Yan Xiang; Weinan Zhang

School of Automation and Perception

Shanghai Jiao Tong University

Shanghai, P.R. China

May, 2026

上海交通大学

本科生毕业设计（论文）任务书

课题名称： 基于自然语言指令的人形机器人规划控制方法研究

执行时间： _____年_____ 月 至 _____年_____月

教师姓名： 项艳 张伟楠

职称：

学生姓名： 唐扬

学号： 522031910076

专业名称： 智能感知工程

学院(系)： 自动化与感知学院

毕业设计（论文）基本内容和要求：

本课题旨在探索一种名为“流匹配”的先进生成模型，以解决人形机器人全身运动控制中的核心挑战：如何将多个孤立的运动技能（如行走、跳跃、转身）融合到一个统一的控制策略中，并使其能根据高层指令（如导航目标、速度命令）实时生成自然、动态且多样的运动轨迹。当前主流方法在策略的泛化性和灵活性上存在局限。本课题将设计并实现一个基于流匹配的机器人控制框架，通过将机器人状态与动作的联合轨迹建模为一个可学习的概率流，实现从观测历史到未来动作序列的直接、高效映射。该方法的优势在于其理论上的简洁性和训练稳定性。最终，我们将在仿真环境中系统验证该框架在多种任务（如速度跟踪、点导航）上的零样本性能，并争取在真实人形机器人平台上进行初步部署演示。

1. 熟练掌握 Python 和 PyTorch/TensorFlow 等深度学习框架。2. 对机器人学、强化学习基础有基本了解，或具备快速学习的能力。3. 具备良好的文献阅读、算法复现和实验分析能力。4. 具备强烈的自主驱动力和解决复杂技术问题的毅力。

本课题工作量饱满，具有明确的创新性，符合优秀毕业设计的要求。深入调研流匹配、生成式机器人控制等相关文献，完成技术选型与方案详细设计。构建仿真环境，实现基于流匹配的机器人策略训练管道，完成基线模型构建。在仿真中完成多任务（如导航、避障）的零样本泛化能力测试与系统性对比实验。整理实验数据，撰写毕业论文初稿；同时进行算法的实物平台迁移与调试。完成实物验证实验，修改并完善毕业论文，准备答

辯。

毕业设计（论文）进度安排：			
序号	毕业设计（论文）各阶段内容	时间安排	备 注
	调研多模态信息处理算法等方面的研究并汇总，撰写开题报告	开始 2025 年 11 月 1 日结束 2025 年 12 月 16 日	
	设计框架	开始 2025 年 12 月 16 日结束 2026 年 2 月 15 日	
	算法实现和对比	开始 2026 年 2 月 15 日结束 2026 年 3 月 15 日	
	完成实验设计和论文撰写	开始 2026 年 3 月 15 日结束 2026 年 5 月 15 日	
课题信息： 课题性质：论文 课题来源*：其他 项目编号 ____ 其他_____			

指导教师签名： <u>项艳</u> 张伟楠 2025 年 11 月 7 日	
学院（系）意见：	院长（系主任）签名： <u>王涛</u> 2025 年 11 月 10 日
	学生签名： <u>唐扬</u> <u>2025 年 11 月 10 日</u>

上海交通大学

学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，已在文中以适当方式予以致谢。若在论文撰写过程中使用了人工智能工具，本人已遵循《上海交通大学关于在教育教学中使用 AI 的规范》，确保人工智能生成内容的应用场景、引用范围及标注方式均符合规定，并杜绝学术不端行为。本人完全知晓本声明的法律后果由本人承担。

学位论文作者签名：唐扬
日期：2026 年 5 月 25 日

上海交通大学

学位论文使用授权书

本人同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。

本学位论文属于：

☒ 公开论文

☐ 内部论文，保密 ☐ 1 年 / ☐ 2 年 / ☐ 3 年，过保密期后适用本授权书。

☐ 秘密论文，保密 ____ 年（不超过 10 年），过保密期后适用本授权书。

☐ 机密论文，保密 ____ 年（不超过 20 年），过保密期后适用本授权书。

（请在以上方框内选择打“√”）

学位论文作者签名：唐扬
日期：2026 年 5 月 25 日

指导教师签名：顾艳
日期：2026 年 5 月 25 日

摘 要

自然语言控制能够降低人形机器人使用门槛，但现有文本到动作方法多面向人体骨架动画或离线整段生成，难以直接满足机器人连续接收指令、流式更新动作并在物理约束下执行的需求。围绕这一问题，本文研究基于自然语言指令的人形机器人规划控制方法，重点完成文本条件动作生成与仿真跟踪控制两级系统。

本文首先建立面向 Unitree G1 的 57 维局部动作特征，并训练时序变分自编码器 (Variational Autoencoder, VAE) 将 50 Hz 动作序列压缩为 d_z 维连续潜变量。在此基础上，本文实现流匹配生成器探索模块，用速度场预测和常微分方程 (Ordinary Differential Equation, ODE) 采样验证短原语动作生成的可行性；随后参考 FloodDiffusion 构建机器人潜空间扩散强制 (Latent Diffusion Forcing, LDF) 主模型，在 T5 (Text-to-Text Transfer Transformer) 文本条件和下三角时间调度下支持整段生成与流式生成。低层控制方面，本文基于 Isaac Lab 与 RSL-RL (Robotic Systems Lab 的 Reinforcement Learning 框架) 训练近端策略优化 (Proximal Policy Optimization, PPO) 参考动作跟踪器，并接入开放神经网络交换格式 (Open Neural Network Exchange, ONNX) 导出和仿真回放评估流程。

实验表明，本文整理了 6452 条训练样本和 2152 条验证样本，系统能够从分段自然语言生成 G1 动作特征，并通过 MuJoCo 完成运动学检查。VAE 维度扫描、流匹配对比和 LDF 消融实验说明，潜变量维度、训练块长度和无分类器引导系数会影响重构质量、生成误差和流式一致性；T5 文本编码在不同批处理形态和数值精度下的微小差异会被递推生成过程放大。本文进一步完成 G1 仿真跟踪器训练和接入，使真实重定向动作、VAE 重构动作和 LDF 生成动作能够进入同一仿真物理评价链路。真机部署留作后续工作。

关键词：人形机器人，自然语言指令，动作生成，流式生成，运动跟踪

ABSTRACT

Natural-language control is an important interface for humanoid robots, but most text-to-motion methods target human animation or offline full-sequence generation. They are not directly suitable for robots that receive changing commands, update motion references online, and execute motions under physical constraints. This thesis studies humanoid robot planning and control from natural-language instructions, focusing on text-conditioned motion generation and simulation-based tracking.

The thesis defines a 57-dimensional local motion feature for the Unitree G1 robot and trains a temporal variational autoencoder (VAE) to compress 50 Hz motion sequences into d_z -dimensional continuous latent vectors. On this interface, a Flow Matching generator explores velocity-field prediction and ordinary differential equation (ODE) sampling for short motion primitives. A robot-oriented Latent Diffusion Forcing (LDF) model is then built with a Text-to-Text Transfer Transformer (T5) text encoder and a triangular temporal schedule to support full-sequence and streaming generation. For low-level control, a proximal policy optimization (PPO) reference motion tracker is trained with Isaac Lab and RSL-RL, with Open Neural Network Exchange (ONNX) export and simulation replay integrated.

Experiments on 6,452 training samples and 2,152 validation samples show that the system can generate G1 motion features from segmented language descriptions and replay them in MuJoCo. VAE analysis, Flow Matching comparison, and LDF ablations show that latent dimension, training block length, and classifier-free guidance affect reconstruction quality, generation error, and streaming consistency. The thesis also identifies a numerical inconsistency caused by different T5 encoding paths: small embedding differences under different batch shapes and precisions can be amplified during autoregressive generation. Finally, the trained G1 simulation tracker allows retargeted motions, VAE reconstructions, and LDF-generated motions to enter the same physics-based evaluation pipeline. Real-robot deployment is left for future work.

Key words: humanoid robot, natural language instruction, motion generation, streaming generation, motion tracking

目 录

摘 要	I
ABSTRACT	II
第一章 绪论	1
1.1 研究背景	1
1.2 课题目标与问题定义	2
1.3 本文主要工作	2
1.3.1 研究内容	3
1.3.2 主要结果	3
1.3.3 主要贡献	4
1.4 本章小结	4
第二章 相关技术与研究现状	5
2.1 文本到动作与机器人动作生成	5
2.1.1 数据集与离线动作生成	5
2.1.2 流式生成与机器人控制接口	5
2.1.3 人体动作生成与机器人动作生成的差异	6
2.2 扩散模型与潜空间生成	8
2.2.1 扩散模型与潜空间压缩	8
2.2.2 流匹配速度场建模	9
2.3 扩散强制与流式调度	9
2.3.1 下三角噪声调度思想	9
2.3.2 本文采用的连续时间形式	10
2.4 机器人运动跟踪与评价体系	10
2.4.1 动作生成评价体系	11
2.5 现有方法的不足与本文切入点	12
2.6 本章小结	12

第三章 系统方法	14
3.1 总体架构与工程边界	14
3.1.1 两级闭环结构	14
3.1.2 工程实现顺序与模块边界	14
3.2 数据处理与 57 维动作表示	15
3.2.1 数据来源	15
3.2.2 处理流程	15
3.2.3 57 维机器人动作表示	15
3.3 归一化与 VAE 连续潜变量化	16
3.3.1 归一化统计量	16
3.3.2 反归一化与安全检查	17
3.3.3 VAE 动作连续潜变量化	17
3.4 文本分段、对齐与质量控制	18
3.4.1 多文本片段样本	18
3.4.2 文本与动作对齐策略	19
3.4.3 数据质量控制	19
3.5 生成模型接口与路线	20
3.5.1 流匹配生成器探索	21
3.5.2 机器人 LDF 主模型	22
3.6 训练与推理实现	24
3.6.1 流式调度与缓存实现	24
3.6.2 无分类器引导 (Classifier-Free Guidance, CFG)	25
3.6.3 训练阶段设计	26
3.6.4 路线比较与实现配置	26
3.6.5 连续潜变量表述说明	28
3.7 跟踪器接口与仿真跟踪方法	28
3.7.1 参考轨迹构造	28
3.7.2 观测、动作与策略接口	29
3.7.3 PPO/BeyondMimic 风格跟踪目标	30
3.7.4 生成动作与跟踪器训练闭环	30
3.7.5 面向动作生成器的强化学习后训练规划	31

3.7.6 安全检查与失败归因	32
3.8 本章小结	32
第四章 实验分析	33
4.1 实验设置	33
4.2 VAE 潜空间与重构实验	34
4.3 流匹配探索实验	36
4.3.1 短原语生成对比	37
4.3.2 速度场诊断	40
4.4 LDF 主模型与流式一致性实验	41
4.5 定量消融实验	43
4.6 MuJoCo 可视化验证	46
4.7 跟踪器训练结果与物理评价协议	49
4.7.1 训练配置与策略结果	49
4.7.2 仿真回放、ONNX 导出与关键帧结果	49
4.8 实验限制与本章小结	53
第五章 全文总结	56
5.1 主要结论	56
5.2 研究展望	57
参 考 文 献	59
攻读学位期间学术论文和科研成果目录	89
致 谢	90

第一章 绪论

1.1 研究背景

人形机器人正在从预设程序驱动的演示系统逐渐走向开放环境中的通用交互平台。与轮式机器人或固定机械臂相比，人形机器人具有接近人类的主体结构，能够使用为人类设计的空间和工具，因此在家庭服务、医疗辅助、教育陪伴、工业巡检等场景中具有较高应用潜力。国内服务机器人研究认为，本体平台、感知交互和任务能力是服务机器人持续发展的关键方向^[1-2]；仿人服务机器人和具身智能研究则进一步强调人机交互、多模态协作和开放环境适应能力^[3-4]。然而，这类机器人要真正进入日常环境，仅依赖遥控器、固定动作库或底层关节命令远远不够。更自然的交互方式是使用自然语言给出目标，例如“向前走几步后挥手”“蹲下捡起东西”“转身并保持站立”。机器人需要理解指令含义，生成连续动作，并在真实或仿真物理约束下稳定执行。

从系统角度看，基于自然语言指令的人形机器人控制可以分为三个层次：第一层是语言到运动的规划，即从文本生成一段或连续多段期望运动；第二层是运动跟踪控制，即在仿真或真实动力学中将期望运动转化为关节动作；第三层是真机部署，即考虑传感器延迟、模型推理时延、通信、执行器限幅和安全保护。机器人学通常需要同时处理机构运动学、动力学、规划、感知和控制等问题^[5]；经典规划研究则强调状态空间、动作约束和可执行路径搜索^[6]。国内机器人运动规划与移动机器人路径规划综述同样指出，规划方法需要在环境建模、约束处理、可行路径搜索和执行效率之间取得平衡^[7-8]。本文关注的是用生成模型在连续高维动作空间中产生可供控制器跟踪的参考运动。围绕这一目标，本文重点研究前两层，其中第一层已完成较完整的系统实现和实验分析，第二层基于机器人学习仿真平台 Isaac Lab 和 RSL-RL (Robotic Systems Lab 的 Reinforcement Learning 框架) 完成 Unitree G1 (下文简称 G1) 仿真跟踪策略训练、开放神经网络交换格式 (Open Neural Network Exchange, ONNX) 导出与评估流程接入，第三层仅作为后续展望。

近年来，文本到人体动作生成取得了快速进展。HumanML3D 将自然语言描述与三维人体动作配对，为文本驱动动作生成提供了标准数据集和评价协议^[9]；Human Motion Diffusion Model 等方法将扩散模型用于整段人体动作生成^[10]。与此同时，面向机器人或交互式生成的工作开始关注流式场景。例如 TextOp 提出高层文本到机器

人动作生成器和低层通用动作跟踪策略的两层架构^[11]；FloodDiffusion 通过潜空间扩散强制（Latent Diffusion Forcing, LDF）在时变文本条件下生成连续动作^[12]。这些工作说明，用生成模型作为人形机器人高层规划器具有可行性，但也暴露出若干挑战：生成动作可能存在脚滑、抖动、左右语义混淆和长时序漂移；流式推理时不同数值路径可能导致结果不一致；纯运动学回放无法保证动作在物理系统中可跟踪。

1.2 课题目标与问题定义

本文课题题目为“基于自然语言指令的人形机器人规划控制方法研究”。结合项目实际推进情况，本文将研究目标细化为如下问题：

1. 面向人形机器人建立适合生成模型学习的动作表示，使文本生成模型输出能够被还原为根节点姿态、根节点位移和机器人关节角。
2. 构建支持分段文本和流式文本切换的高层动作生成模型，使机器人能够根据不同时刻到达的自然语言描述生成连续动作序列。
3. 设计动作生成结果的可视化、对比和数值分析工具，定位流式生成与整段生成之间的差异来源。
4. 训练并接入仿真环境中的运动跟踪器，使高层生成的运动能够进一步受到接触、关节限位、脚滑和动力学约束评价。

形式化地，设自然语言指令序列为 $C = \{(c_i, \tau_i)\}_{i=1}^K$ ，其中 c_i 表示第 i 段文本描述， τ_i 表示该描述在时间轴上的结束时刻。高层生成器需要输出机器人运动特征序列：

$$\mathbf{x}_{1:T} = G_\theta(C, \mathbf{z}), \quad (1-1)$$

其中 $\mathbf{z}$ 是随机噪声或潜变量初始化。低层跟踪器需要根据参考运动 $\mathbf{x}_{1:T}$ 和机器人当前观测 $\mathbf{o}_t$ ，输出关节控制动作：

$$\mathbf{a}_t = \pi_\phi(\mathbf{o}_t, \mathbf{x}_{t:t+H}), \quad (1-2)$$

其中 H 为未来参考窗口。本文的主要工作是实现和分析 G_θ ，并训练、导出和接入低层跟踪策略 π_ϕ ，用于在仿真约束下评价参考动作的可跟踪性。

1.3 本文主要工作

本文工作统一整理到 Any-Text-to-Humanoid-Action 工程中。该工程围绕自然语言到 G1 人形机器人动作生成与仿真跟踪展开，包含 57 维动作表示、变分自编码器

(Variational Autoencoder, VAE) 训练与连续潜变量预计算、流匹配探索模块、机器人潜空间扩散强制 (Latent Diffusion Forcing, LDF) 主模型、流式生成、整段生成、MuJoCo 运动学对比可视化, 以及基于 Isaac Lab 的跟踪器训练与仿真评估链路。

1.3.1 研究内容

具体来说, 本文主要完成以下工作:

1. 构建面向 G1 机器人动作的 57 维局部特征表示。该表示包含根节点横滚/俯仰 (roll/pitch) 的三角化表示、偏航角 (yaw) 增量、脚部接触、局部坐标系根节点位移增量、根节点高度、23 维关节角和 23 维关节角增量。
2. 基于时序 Wan-VAE 训练机器人动作编码器, 将 50 Hz 的 57 维动作序列压缩为 12.5 Hz、 d_z 维的连续潜变量, 并完成不同 z 维度的 VAE 扫描与隐空间分布分析。
3. 在统一工程中实现流匹配版本的机器人动作生成器。新增流匹配训练、生成和可视化入口, 将模型训练目标从噪声预测改为速度场预测, 并在推理时使用欧拉法 (Euler) 或四阶 Runge-Kutta (RK4) 求解器生成动作。
4. 参考 FloodDiffusion 构建机器人版本 LDF 模型。模型使用 T5 (Text-to-Text Transfer Transformer) 编码文本, 使用 Wan 扩散 Transformer (Wan-DiT) 作为主干, 在潜空间中采用下三角噪声调度, 实现整段生成和流式递推生成。
5. 完成流式生成与整段生成的 MuJoCo 对比工具, 并对 T5 文本编码在批处理编码和单句编码下的数值差异进行实验分析, 定位生成不一致问题。
6. 训练并接入仿真物理跟踪器。基于 Isaac Lab 环境、RSL-RL 训练框架和近端策略优化 (Proximal Policy Optimization, PPO) 配置, 完成运动跟踪奖励、观测、终止条件、未来参考窗口、策略参数保存、ONNX 导出和评估流程整理, 使生成动作能够进入仿真物理约束下的跟踪评价。

1.3.2 主要结果

上述工作的主要结果如下。第一, 本文完成 6452 条训练样本和 2152 条验证样本的 G1 机器人动作数据整理, 并验证 57 维局部动作特征能够恢复为 MuJoCo 中可播放的 G1 运动轨迹。第二, VAE 维度扫描表明, 连续潜变量维度存在重构质量与下游生成可学习性之间的折中: 高维潜变量有利于保留动作细节, 但不必然带来更稳定的潜空间使用; 因此本文保留 $z = 32$ 、 $z = 64$ 和 $z = 128$ 作为后续 LDF 对照配置。第

三，流匹配探索实验显示，速度场建模在部分短原语样本上能够改善局部动作幅度和平滑性，但短原语自回归结构仍存在长序列语义保持和误差累积问题。第四，机器人 LDF 主模型已经形成从分段文本到 G1 动作特征、再到 MuJoCo 运动学回放的完整链路；消融实验进一步显示，引导系数、训练块长度和文本编码路径会显著影响生成误差与流式一致性。第五，本文完成 G1 仿真跟踪器训练、策略导出和固定样本池评价流程，使真实重定向动作、VAE 重构动作和 LDF 生成动作都能够进入 Isaac Lab 物理约束下的跟踪评价链路。

1.3.3 主要贡献

综合来看，本文贡献主要体现在三个方面。第一，本文面向 G1 人形机器人重新设计了动作表示、连续潜变量接口和特征重构流程，使文本到动作生成结果不只停留在人体动画层面，而能够进一步连接机器人运动学回放和仿真跟踪控制。第二，本文在同一工程中实现并比较了流匹配探索模块和机器人 LDF 主模型，形成了从短原语生成探索到长序列流式潜空间生成的技术路线，并明确系统传递的是 VAE 连续动作潜变量而非离散动作编号。第三，本文把数值一致性和物理可跟踪性纳入系统评价：一方面定位了 T5 文本编码在不同批处理形态和精度下造成流式结果差异的问题，另一方面训练并接入低层 PPO 跟踪器，为后续基于跟踪误差、脚滑、跌倒和关节限位等物理反馈继续优化高层动作生成器奠定基础。

1.4 本章小结

本章介绍了自然语言驱动人形机器人规划控制的研究背景、问题定义和主要工作，明确本文聚焦于动作生成和仿真跟踪两部分。后文结构安排如下：第二章综述文本到动作生成、扩散模型、流式生成和物理跟踪控制相关研究；第三章给出系统总体架构、数据处理、57 维机器人动作表示、VAE 连续潜变量接口、流匹配探索模块、机器人 LDF 主模型和跟踪器接口；第四章报告 VAE 分析、流匹配探索、LDF 主模型、消融实验、MuJoCo 可视化和仿真跟踪器训练与回放结果；最后一章总结全文工作，并讨论真机部署和进一步优化方向。与主线方法和实验不直接相关的系统集成、实验管理和部署边界内容放入附录。

第二章 相关技术与研究现状

2.1 文本到动作与机器人动作生成

2.1.1 数据集与离线动作生成

文本到动作生成旨在根据自然语言描述生成与语义一致的三维人体或机器人动作。早期动作生成方法多依赖动作库检索、动作图拼接或规则规划，这类方法可解释性较强，但泛化能力依赖人工标注和动作模板。深度生成模型的发展使模型可以直接从文本和动作配对数据中学习跨模态映射。KIT Motion-Language Dataset 较早构建了动作片段和自然语言描述配对资源，为动作语言关联建模提供了基础数据^[13]；Language2Pose 将自然语言条件引入人体姿态预测，体现了文本对动作生成的约束作用^[14]；HumanML3D 进一步提供了大规模文本和三维人体动作配对数据，推动了基于文本的人体动作生成研究^[9]；BABEL 在人体动作数据集 AMASS（Archive of Motion Capture as Surface Shapes）上提供帧级动作标签，使分段文本和时变动作描述成为可能^[15-16]。在模型方法上，TEMOS 使用潜空间生成多样人体动作，MotionDiffuse 将扩散模型用于文本驱动动作生成，T2M-GPT 采用离散动作表示建模文本到动作序列，动作潜空间扩散模型（Motion Latent Diffusion, MLD）则在潜空间中执行文本条件动作扩散^[17-20]。

2.1.2 流式生成与机器人控制接口

从生成范式看，现有方法大致可以分为离线整段生成和流式生成两类。离线方法通常在收到完整文本后一次性生成整段动作，适合视频动画和离线仿真，但难以处理机器人连续交互中的临时指令切换。流式方法则以短片段或连续潜变量位置为单位逐步生成动作，更适合实时机器人控制。TextOp 将高层文本到动作生成器与低层动作跟踪器结合，展示了自然语言控制人形机器人的可行性^[11]。DARTControl 和 MotionStreamer 等工作也采用自回归短片段或因果潜空间方法，使动作生成具备实时更新能力^[21-22]。

TextOp 的核心启发可以概括为“高层语义生成 + 低层物理跟踪”的分层结构，如图 2-1 所示。高层模型根据文本和历史动作生成未来短动作原语，低层跟踪器再将参考动作转化为机器人关节控制。本文后续系统也沿用这种分层思想，但将高层生成部

分进一步改造成面向 G1 动作特征和连续潜变量流式推进的实现。




图 2-1 分层文本到机器人动作控制思想与流匹配探索现象

本文关注的是后者，即面向机器人部署的流式文本到动作生成。与只生成参数化人体模型 SMPL（Skinned Multi-Person Linear）骨架不同，机器人动作生成需要处理固定关节自由度、关节限位、接触状态、根节点局部位移和低层控制接口。因此，文本到动作模型不能只追求视觉自然，还要为后续物理跟踪提供稳定、连续、可解释的参考轨迹。

图 2-2 按“整段动作生成、流式生成、物理反馈与跟踪”三类研究链路整理本文关注的方法位置。该图并非逐项复现各论文结构，而是把 Go to Zero、PARC、DART-Control、MotionStreamer、FloodDiffusion、TextOp 等相关路线放在统一能力图中，说明本文选择的切入点：先完成流式高层动作生成，再把生成结果送入仿真跟踪器进行物理约束评估。

2.1.3 人体动作生成与机器人动作生成的差异

现有文本到动作研究多数以人体动捕数据为对象，输出形式通常是 SMPL 参数、关节位置、关节旋转或 HumanML3D 风格的运动特征，其中 SMPL 提供了可微的人体形状和姿态参数化表示^[23]。这类表示适合视觉评价和动画生成，因为人体骨架本身没有固定执行器约束，也不需要每个控制周期给出可执行关节命令。只要生成动

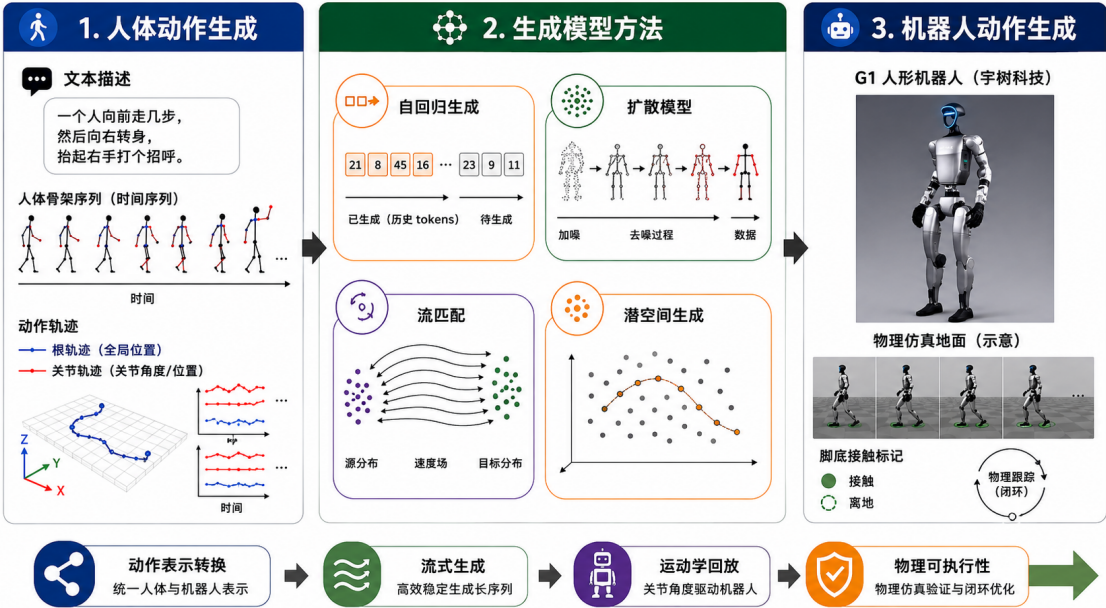


图 2-2 文本到动作与机器人动作生成方法分类图

作在视觉上连贯，脚部没有明显穿模或抖动，就可以被认为具有一定质量。机器人动作生成的约束更强：机器人拥有固定自由度、固定关节顺序、明确的关节上下限和执行器动力学，每一维输出都可能影响后续物理仿真稳定性。

人形机器人还存在接触语义和动力学可执行性的双重约束。人体动作数据中的脚部接触通常只是由位置或速度推断出的标签，而机器人控制中接触会直接影响支撑多边形、摩擦力和身体平衡。国内关于仿人服务机器人、双足机器人稳定性和双足跑步机器人控制方法的综述也指出，双足系统的稳定运动需要同时考虑机构构型、步态、支撑相、冲击和控制策略之间的耦合关系^[3,24-25]。同样的“下蹲”动作，在人体动画中可以只关注髌膝踝角度是否自然；在机器人仿真中则必须关注质心是否落在支撑区域附近、膝关节是否接近限位、脚底是否发生滑动、控制器是否需要过大力矩才能跟踪。因此，机器人动作生成不应只复用人体动作模型的输出维度，而应重新设计与机器人控制接口一致的运动表示。

另一个重要差异是坐标系。人体动作生成常以世界坐标或面向相机的坐标表示动作，评价时关注全局轨迹是否合理；机器人在线控制更适合使用局部坐标表示，因为低层控制器和状态估计通常以机器人自身朝向为参考。若生成模型直接预测世界坐标中的位移，训练数据中的朝向分布和场景坐标会被混入动作语义，模型可能把“向前走”记成某个固定世界方向。本文采用偏航角增量和局部位移增量，目的就是

让模型学习相对于机器人当前朝向的动作，而不是学习数据集中的绝对位置。

从系统角度看，人体动作生成的终点通常是渲染或动画文件，而机器人动作生成只是规划控制链路的中间层。高层生成器输出的轨迹还要经过重构、平滑、参考窗口组织、物理跟踪和安全检查。任何一层的数值不一致都可能在最终仿真中表现为摔倒、打滑或方向错误。因此，本文在后续章节中反复强调接口一致性和可复现对比工具，而不是只报告一段可播放的动作结果。

2.2 扩散模型与潜空间生成

2.2.1 扩散模型与潜空间压缩

扩散模型通过逐步加噪和反向去噪学习复杂数据分布，已在图像、视频和动作生成中广泛使用。去噪扩散概率模型（Denoising Diffusion Probabilistic Models, DDPM）给出了离散马尔可夫加噪和反向去噪训练框架^[26]，去噪扩散隐式模型（Denoising Diffusion Implicit Models, DDIM）从隐式采样角度减少推理步数^[27]，基于分数的随机微分方程（Score-based Stochastic Differential Equation, score-based SDE）将扩散过程推广到随机微分方程视角^[28]，Improved DDPM 则从方差学习和噪声调度等方面改进采样质量与效率^[29]。设真实样本为 $\mathbf{x}_0$ ，噪声为 ϵ ，扩散模型通常学习在时间步 t 下从带噪样本 $\mathbf{x}_t$ 恢复 $\mathbf{x}_0$ 或预测噪声。其优势是生成质量较高、训练稳定，但推理通常需要多次迭代，实时部署成本较高。

潜空间扩散通过先训练自编码器将高维数据压缩到低维潜空间，再在潜空间中训练扩散模型，显著降低生成模型的计算压力。变分自编码器（VAE）为连续潜变量表示学习提供了经典框架^[30]，向量量化变分自编码器（Vector Quantised Variational Autoencoder, VQ-VAE）等离散表示学习方法也启发了后续离散动作表示建模^[31]。潜空间扩散模型（Latent Diffusion Models, LDM）在图像领域验证了潜空间生成的有效性^[32]，MLD 等动作生成方法进一步说明文本条件动作也可以在潜空间中建模^[20]。对于动作生成，潜空间方法同样具有吸引力：动作序列存在强时序冗余，原始特征维度较高，而机器人控制只需要可还原为关节状态和根节点状态的紧凑表示。本文采用的时序 VAE 沿时间轴对动作序列进行编码，将 50 Hz 的机器人动作序列下采样为 12.5 Hz、 d_z 维的连续潜变量，再在连续潜变量序列上训练潜空间扩散强制（Latent Diffusion Forcing, LDF）模型。这里的“时序”指编码器处理一维时间序列，并不表示潜变量维度为 1。

本文的文本条件主要由 T5 (Text-to-Text Transfer Transformer) 文本编码器产生, 而 T5 建立在 Transformer 结构之上^[33-34]。在本文系统中, 输入文本片段被切分为文本 token, 经嵌入、位置编码和多层自注意力模块后输出上下文相关的文本嵌入; 这些文本嵌入作为高层生成模型的交叉注意力条件。由于流式生成会递推放大条件差异, 文本编码路径的确定性在本文实验中成为一个重要问题。第四章实验部分不再停留在通用 Transformer 框图, 而是用整段与流式生成的误差曲线说明同一文本编码路径差异如何影响机器人动作。

2.2.2 流匹配速度场建模

流匹配是另一类连续生成建模方法, 它直接学习从噪声分布到数据分布的速度场^[35]。在最简单的最优传输路径设定中, 若 $\mathbf{x}_0$ 表示噪声样本, $\mathbf{x}_1$ 表示真实数据样本, 则中间状态和目标速度可写为:

$$\mathbf{x}_t = (1 - t)\mathbf{x}_0 + t\mathbf{x}_1, \quad \mathbf{v}_t^* = \mathbf{x}_1 - \mathbf{x}_0. \quad (2-1)$$

模型 $v_\theta(\mathbf{x}_t, t, c)$ 以文本条件 c 和时间 t 为输入, 最小化速度场均方误差:

$$\mathcal{L}_{\text{FM}} = \mathbb{E}_{t, \mathbf{x}_0, \mathbf{x}_1} [\|v_\theta(\mathbf{x}_t, t, c) - (\mathbf{x}_1 - \mathbf{x}_0)\|_2^2]. \quad (2-2)$$

推理时从噪声出发求解常微分方程 (Ordinary Differential Equation, ODE):

$$\frac{d\mathbf{x}_t}{dt} = v_\theta(\mathbf{x}_t, t, c), \quad (2-3)$$

即可得到生成结果。本文在统一代码工程中实现流匹配版本, 作为降低扩散推理迭代成本的探索。

2.3 扩散强制与流式调度

2.3.1 下三角噪声调度思想

传统扩散模型通常为同一序列的所有帧使用相同噪声等级; 自回归模型则将过去帧视为已生成、未来帧视为待预测。扩散强制 (Diffusion Forcing) 试图结合两者优势: 序列中不同位置可以处于不同噪声等级, 从而在同一前向过程中同时建模历史条件和未来不确定性^[36]。FloodDiffusion 将这一思想用于文本驱动流式动作生成, 提出下三角噪声调度, 使左侧已提交帧逐渐保持干净, 右侧待生成帧保持较高噪声, 中间区域形成逐步推进的去噪波前^[12]。

图 2-3 按连续潜变量位置和推进时间展示了这一思想。随着推进时间增加，低噪声区域从左向右移动，左侧潜变量位置被逐渐提交，右侧潜变量位置保持较高噪声以便接收未来文本条件。这也是本文选择 LDF 作为主模型的重要原因。




图 2-3 LDF 下三角噪声调度热力图

2.3.2 本文采用的连续时间形式

在本文实现中，给定序列长度 T 、块大小 K 和连续时间 τ ，第 i 个连续潜变量位置的噪声等级为：

$$\alpha_i(\tau) = \text{clip} \left(1 + \frac{i}{K} - \tau, 0, 1 \right). \quad (2-4)$$

当 τ 增大时，低噪声区域从左向右推进。训练时模型只需预测当前推进窗口内的速度场或目标量；推理时每次提交一个或一小段连续潜变量。这一机制适合持续接收文本指令的机器人，因为新文本到达时，已提交动作无需重新生成，只需影响当前及未来潜变量位置。

2.4 机器人运动跟踪与评价体系

高层生成模型输出的是参考运动，而真实机器人或物理仿真系统执行的是关节力矩或关节目标位置。两者之间存在动力学、接触、执行器限幅和传感噪声等差异。因此，高层生成动作不能简单视为最终控制信号，需要一个低层跟踪器将参考轨迹转化为可执行动作。

除强化学习之外，模型预测控制也是足式机器人步态和运动跟踪中常见的控制

思想。模型预测控制通过在有限预测时域内滚动优化控制输入，可以显式处理状态、输入和稳定性约束，国内综述也将约束处理、实时性和模型不确定性列为该方法的重要挑战^[37]。在仿人机器人步态优化中，基于模型预测控制的方法可以将质心、支撑脚和步态时序纳入统一优化框架^[38]。这些方法强调动力学模型和约束优化，而本文后续采用的 PPO 跟踪器更偏向数据驱动策略学习；二者关注点不同，但都说明高层参考轨迹必须经过物理控制层验证，不能只停留在运动学回放。

强化学习是训练运动跟踪控制器的常用方法，其基本目标是在序列决策过程中最大化累积回报^[39]。中文综述也将机器人学习划分为监督学习、强化学习、模仿学习和迁移学习等方向，强调机器人任务中感知、决策和控制之间的闭环关系^[40]。在角色控制领域，Phase-Functioned Neural Networks 说明相位条件神经网络可以有效生成连续角色运动^[41]；DeepMimic 使用深度强化学习跟踪示例动作，成为物理角色模仿控制的重要代表^[42]；对抗运动先验（Adversarial Motion Priors, AMP）进一步使用对抗运动先验替代复杂人工奖励，为物理动作模仿提供了另一类思路^[43]。近端策略优化（PPO）通过限制新旧策略概率比，兼顾训练稳定性和样本效率^[44]，在机器人控制中被广泛使用。典型的运动跟踪奖励包括根节点位置和姿态误差、身体关键点位置和姿态误差、关节角误差、身体速度误差、脚滑惩罚、接触惩罚和关节限位惩罚。通过在 MuJoCo、Isaac Gym 或 Isaac Lab 等物理仿真环境中训练，控制器可以学习如何在接触力和动力学约束下跟踪高层参考动作^[45-46]。大规模并行仿真和强化学习训练还可以显著提高腿足机器人策略训练效率^[47]。

本文采用分层跟踪思想：高层生成器只负责产生运动学参考，低层 PPO 策略负责在仿真环境中跟踪参考。该设计的优点是模块边界清晰，高层模型可以专注语义和时序连续性，低层策略则专注动力学可执行性和抗扰动能力。

2.4.1 动作生成评价体系

文本到动作生成的评价需要同时回答三个问题：动作是否符合文本、动作自身是否稳定、动作是否能够被物理系统执行。第一类问题是语义对齐问题。对于标准人体动作数据集，可以使用预训练检索模型计算检索精度（R-precision）、多模态距离（multimodal distance）等指标；但本文使用的是重定向后的机器人动作数据，缺少公开成熟的文本-机器人动作评价器。因此，本文更强调可复现实验协议：固定样本、固定随机种子、固定模型参数和固定文本编码路径，通过同一可视化入口比较不同模型设置。

第二类问题是时序质量问题。动作生成模型即使在单帧姿态上合理，也可能在长时序中出现累积漂移。例如偏航角增量存在很小偏置时，机器人在几十秒后可能明显偏航；局部位移误差持续累积时，根节点轨迹会逐渐偏离真实动作；关节角一阶差分和二阶差分过大时，运动学回放会出现抖动，低层控制器也需要更大动作变化才能跟踪。相比 Fréchet Inception Distance (FID) 这类分布指标，这些时序指标更贴近机器人使用场景。

第三类问题是物理可执行性。一个动作在 MuJoCo 中按广义坐标 (qpos) 强制播放时可以看起来合理，但这并不意味着机器人可以在动力学约束下执行。低层跟踪器是否能够跟踪、跟踪过程中是否脚滑、是否触发关节限位、是否需要过大力矩，都是高层动作质量的一部分。足式机器人触地检测综述表明，接触状态估计会直接影响步态识别、支撑相判断和控制切换^[48]；机器人安全性研究也强调，在机器人进入开放环境前必须考虑机械结构、控制策略、人机交互和运行场景中的风险约束^[49]。因此，本文将 MuJoCo 运动学回放视为中间检查工具，将 Isaac Lab 跟踪器和物理指标作为仿真验证的关键环节；本文仍不把运动学回放等同于物理执行成功，也不夸大真实机器人部署结论。

2.5 现有方法的不足与本文切入点

结合文献和项目实验，现有方法仍存在几方面不足。离线整段生成方法难以处理长时、连续、可中途切换的自然语言指令；面向人体骨架的动作特征也不能直接作为人形机器人控制接口，必须经过机器人动作表示设计和重定向。对于流式生成，自回归误差会随时间累积，微小的文本编码数值差异也可能在递推过程中被放大。更重要的是，运动学可视化不等价于物理可执行性，高层生成动作必须通过仿真跟踪验证后，才具备进一步走向真机的基础。

因此，本文从工程实现角度切入，首先建立面向 G1 机器人的动作表示和 VAE 连续潜变量接口，再在统一工程中实现流匹配生成器探索和机器人 LDF 主模型，并补充数值一致性分析、跟踪器训练结果和仿真跟踪评价方法。

2.6 本章小结

本章综述了文本到动作生成、扩散与潜空间生成、扩散强制流式调度以及机器人运动跟踪控制。相关工作表明，自然语言驱动人形机器人需要把文本语义、动作生成

和物理控制结合起来。本文后续章节将在此基础上介绍面向 G1 机器人的动作表示、生成模型实现和仿真跟踪评价。

第三章 系统方法

3.1 总体架构与工程边界

3.1.1 两级闭环结构

本文系统采用“文本条件动作生成器 + 物理运动跟踪器”的两级结构。高层生成器接收自然语言指令，输出机器人参考动作；低层跟踪器接收参考动作和机器人状态，在物理仿真中输出关节控制。系统结构如图 3-1 所示。



图 3-1 自然语言驱动人形机器人动作生成与跟踪系统总体架构

3.1.2 工程实现顺序与模块边界

高层生成器在统一工程中包含两个模块：一类是流匹配探索模块，用于验证速度场生成和常微分方程采样在机器人动作生成中的可行性；另一类是参考 FloodDiffusion 方法构建的机器人版本潜空间扩散强制 (Latent Diffusion Forcing, LDF) 模型，这是本文主要实验平台。训练阶段先由 VAE 将 57 维动作特征编码为连续潜变量，再

在连续潜空间训练生成模型；推理阶段则由生成模型产生连续潜变量，并通过 VAE 解码回 57 维动作特征。低层跟踪器采用完成训练的 G1 仿真策略与 Isaac Lab 任务定义作为评估链路，用近端策略优化（PPO）跟踪器对参考动作的可跟踪性进行仿真检查。

3.2 数据处理与 57 维动作表示

3.2.1 数据来源

本文使用的机器人动作数据主要来自 AMASS/BABEL 动捕数据经重定向后的 G1 机器人数据。BABEL 提供帧级动作文本标注，适合构造时变文本条件^[15]；AMASS 将多个动捕数据集统一到 SMPL 人体表示下，适合作为重定向源^[16,23]。项目中使用的是 23 自由度 G1、50 Hz 帧率的 BABEL-AMASS 重定向数据目录，包含训练集 6452 条、验证集 2152 条，共 8644 条已处理动作样本。每条样本包含机器人动作特征文件和对应文本片段文件。

3.2.2 处理流程

数据处理围绕“可生成、可重构、可跟踪”三个目标展开。首先，系统从重定向后的 pkl 文件中读取根节点位置、根节点四元数、23 维关节角和脚部接触标签；随后将全局位移转换为以当前偏航角为参考的局部位移增量，减弱全局坐标系对生成模型的影响。角度处理阶段将横滚/俯仰角改写为三角化形式，并将偏航角保存为相邻帧增量，以提高换向附近的连续性。文本处理阶段把 BABEL 帧级标注转换为每条运动对应的文本段落和结束时间，并按照 50 Hz 特征帧率和 12.5 Hz 连续潜变量帧率分别生成两套文本结束索引。VAE 训练完成后，系统再使用 `pretokenize_vae.py` 将动作特征预编码为连续潜变量序列，供 LDF 训练使用。

3.2.3 57 维机器人动作表示

3.2.3.1 特征组成

机器人动作表示是本文系统的关键接口。原始重定向数据包含根节点全局位移、根节点四元数、关节角和接触标签。如果直接使用全局位置和四元数，模型容易学习到与场景坐标相关的绝对量，且角度在 $-\pi$ 和 π 附近存在不连续。为此，本文采用 57 维局部特征，如表 3-1 所示。

表 3-1 57 维机器人动作特征定义

索引范围	维度	含义
0-3	4	根节点横滚角/俯仰角的 $\sin$ 与 $\cos-1$ 表示
4	1	根节点偏航角增量 $\Delta\psi_t$
5-6	2	左右脚接触标签
7-9	3	局部坐标系下根节点位移增量 $\Delta\mathbf{p}_t^{\text{local}}$
10	1	根节点高度 h_t
11-33	23	G1 机器人关节角 $\mathbf{q}_t$
34-56	23	关节角增量 $\Delta\mathbf{q}_t$

3.2.3.2 局部坐标与角度连续性

其中横滚角和俯仰角采用：

$$[\sin r_t, \cos r_t - 1, \sin p_t, \cos p_t - 1] \quad (3-1)$$

而不是直接使用角度值。这样做有两个作用：其一，三角函数表示避免角度周期边界上的跳变；其二，对于站立和行走等常见姿态，横滚/俯仰角接近 0，此时 $\sin \theta \approx \theta$ ， $\cos \theta - 1 \approx 0$ ，特征以零为中心，有利于归一化和网络学习。偏航角主要反映朝向变化，本文使用相邻帧增量 $\Delta\psi_t = \psi_{t+1} - \psi_t$ ，并在重构时累积恢复全局朝向。

局部位移增量通过当前偏航角的逆旋转得到：

$$\Delta\mathbf{p}_t^{\text{local}} = R_z(\psi_t)^{-1}(\mathbf{p}_{t+1} - \mathbf{p}_t). \quad (3-2)$$

这使模型学习的是“相对当前朝向向前、向侧、向上移动多少”，而不是在世界坐标中的绝对移动方向，更符合机器人可执行动作的控制语义。

3.3 归一化与 VAE 连续潜变量化

3.3.1 归一化统计量

57 维动作特征虽然维度不高，但不同维度的物理意义和数值尺度差异很大。根节点高度通常在米级范围内变化，局部位移增量与帧率相关，关节角以弧度表示，脚部接触标签则接近二值变量。如果直接把这些维度拼接后输入 VAE 和 LDF，网络容易优先拟合数值尺度较大的维度，而忽略对控制同样重要的小尺度特征。因此，训练前需要对动作特征进行统计归一化，推理和可视化前再进行反归一化。

归一化的基本形式为：

$$\hat{\mathbf{x}}_t = \frac{\mathbf{x}_t - \boldsymbol{\mu}}{\boldsymbol{\sigma} + \varepsilon}, \quad (3-3)$$

其中 $\boldsymbol{\mu}$ 和 $\boldsymbol{\sigma}$ 来自训练集统计量， ε 用于避免除零。对于连续维度，均值和标准差能够改善优化条件；对于脚部接触这类近似离散维度，归一化后仍需要在重构和评价中单独关注其语义，因为接触标签的错误会直接影响脚滑判断。本文在可视化和跟踪器接口设计中保留接触维度，是为了后续能够将生成动作的接触状态与实际脚底速度进行一致性检查。

3.3.2 反归一化与安全检查

反归一化阶段必须与训练阶段严格一致。若不同脚本各自读取不同统计量，或者对某些维度重复反归一化，就会出现难以定位的广义坐标 (qpos) 异常。本文将动作特征到 qpos 的转换视为独立重构层，要求 MuJoCo 回放、整段/流式对比和跟踪器参考轨迹都使用同一套统计量和同一套重构函数。这样做可以把问题分层：如果真实动作特征反归一化后显示异常，则问题在数据或重构层；如果真实动作特征正常而 VAE 重构异常，则问题在连续潜变量化；如果 VAE 重构正常而 LDF 生成异常，则问题在生成模型。

反归一化还需要处理角度周期性。横滚/俯仰角在特征中以三角函数形式保存，重构时需要通过反三角关系恢复姿态信息；偏航角使用增量累积恢复全局朝向。由于长期累积会放大微小偏置，后续跟踪器接入前应对偏航角序列进行连续性检查，避免出现突然跳变或长期单向漂移。对于关节角，反归一化后应检查是否接近或超过 G1 机器人的关节范围，不能只依赖 MuJoCo 被动显示。

3.3.3 VAE 动作连续潜变量化

3.3.3.1 时序下采样接口

FloodDiffusion 原始方法面向 HumanML3D 的 263 维人体动作特征。本文改为 G1 机器人的 57 维特征后，需要重新训练动作 VAE。VAE 的基本思想是通过编码器学习潜变量分布、通过解码器重构输入，并用 KL 项约束潜空间分布^[30]；在动作生成领域，离散或连续潜空间表示也常用于降低序列建模难度^[19-20]。本文 VAE 输入为 $\mathbf{x} \in \mathbb{R}^{T \times 57}$ ，输出潜变量 $\mathbf{z} \in \mathbb{R}^{L \times d_z}$ ，其中时间长度大约下采样 4 倍：

$$L = 1 + \left\lfloor \frac{T-1}{4} \right\rfloor. \quad (3-4)$$

因此, 50 Hz 的动作特征会被压缩为 12.5 Hz 的连续潜变量序列。解码时第一个连续潜变量输出 1 帧, 后续每个连续潜变量输出 4 帧, 重构长度为:

$$T_{\text{out}} = 1 + 4(L - 1) = 4L - 3. \quad (3-5)$$

3.3.3.2 训练损失与潜变量维度

VAE 训练损失由整体特征重构、关节角重构、偏航角增量重构、根节点局部位移增量重构和 Kullback-Leibler (KL) 正则项组成:

$$\mathcal{L}_{\text{VAE}} = \lambda_f \mathcal{L}_f + \lambda_q \mathcal{L}_q + \lambda_\psi \mathcal{L}_{\Delta\psi} + \lambda_p \mathcal{L}_{\Delta p} + \lambda_{\text{KL}} \mathcal{L}_{\text{KL}}. \quad (3-6)$$

在本文配置中, $\lambda_f = 1.0$, $\lambda_q = \lambda_\psi = \lambda_p = 0.5$, $\lambda_{\text{KL}} = 10^{-5}$ 。较小的 KL 权重使 VAE 更接近高保真自编码器, 这与 FloodDiffusion 方法中 VAE 的设计取向一致: 优先保证潜变量能准确重构动作, 再由扩散主干学习潜空间中的生成分布。

本文将 $d_z \in \{4, 8, 16, 32, 64, 128\}$ 作为候选潜变量维度。维度选择需要在三类约束之间折中: 低维潜空间更容易降低 LDF 主干的学习难度, 但可能损失细粒度姿态; 高维潜空间有利于重构, 但会增加生成模型的序列建模和显存压力; 跟踪器接口还要求解码后的 57 维动作能够稳定恢复为参考轨迹。具体维度扫描、潜空间投影和重构可视化结果放在第四章实验部分报告。

3.4 文本分段、对齐与质量控制

3.4.1 多文本片段样本

与单句文本到整段动作不同, 本文系统需要处理同一动作序列中多个文本片段。BABEL 的帧级标注使这种时变文本条件成为可能; 其他动作语言数据集也说明了配对资源对文本到动作学习的重要性^[9,13,15]。例如一条样本可能依次包含 tpose、transition、wipe off hands、kneel on one knee 等描述。数据加载器会根据文本的起止时间为每个连续潜变量分配对应文本条件。当多个文本标注在同一时间段重叠时, 训练阶段可随机选择候选文本, 验证阶段选择排序后的第一个文本, 以保证可复现性。

在 LDF 训练中, 文本条件被展开到连续潜变量级别: 同一文本片段覆盖的所有连续潜变量共用相同 T5 文本嵌入。对于流式生成, 当新的文本到达时, 模型只更新当前和未来连续潜变量的条件, 已经提交的历史连续潜变量不再改变。这与真实机器人交互中的在线指令更新场景一致。

3.4.2 文本与动作对齐策略

3.4.2.1 帧级边界到连续潜变量级边界

文本与动作对齐是本文数据处理中的一个核心问题。BABEL 标注给出的文本片段通常对应一段时间区间，而生成模型训练时使用的是经过 VAE 下采样后的连续潜变量序列。若只在原始帧级别保存文本边界，训练 LDF 时仍需要把边界转换到潜变量时间尺度；若转换规则在不同脚本中重复实现，就容易造成边界偏移。为避免这种问题，本文在数据处理阶段同时保存特征级和连续潜变量级文本结束索引，使训练、验证和可视化脚本都能直接读取对应尺度下的边界。

边界转换需要处理取整问题。50 Hz 特征每 4 帧对应一个 12.5 Hz 连续潜变量位置，但第一个连续潜变量只对应首帧，后续连续潜变量才对应 4 帧块。因此，简单使用帧号除以 4 可能会在片段开头或结尾产生一帧到数帧的偏移。对于单句整段动作，这种偏移影响较小；对于同一序列中包含多个文本片段的样本，偏移会导致某些连续潜变量使用错误文本条件，尤其是在“transition”和具体动作之间切换时更明显。因此，本文将多文本片段样本作为对齐单元测试和后续实验样本池的重要组成部分。

当同一时间区间存在多个候选文本时，训练和验证也需要不同策略。训练阶段可以随机选择候选文本，以增加文本表达多样性；验证和对比阶段则应固定选择规则，以保证可复现性。若验证时仍随机选择文本，则整段与流式比较可能混入文本采样差异，无法判断差异到底来自模型、随机噪声还是文本条件。因此，本文在验证接口中固定文本列表、随机种子和样本索引，使第四章的数值一致性实验只比较推理路径本身。

对齐策略还影响在线指令更新。真实机器人在执行过程中可能收到新的自然语言命令，此时系统不能重新生成已经执行的历史动作，而只能改变当前和未来的参考。LDF 的下三角调度天然支持这种局部更新，但前提是每个连续潜变量的文本条件能够被明确定位。因此，本文将连续潜变量级文本边界作为流式缓存状态的一部分，而不是每步临时从原始时间戳推断。

3.4.3 数据质量控制

机器人动作生成对数据质量较敏感。一方面，模型输出的是连续关节轨迹，小范围异常会在可视化中表现为关节抖动、脚部穿模或根节点漂移；另一方面，流式生成具有递推性质，训练集中少量异常样本可能在长序列中被放大。本文在数据处理阶段设置如下质量控制规则。

首先, 检查动作帧率和长度一致性。VAE 的时间下采样假设输入序列满足“首帧加后续每 4 帧形成一个连续潜变量位置”的结构。如果某些样本在重定向或导出时帧率不一致, 连续潜变量与动作特征的长度关系会被破坏, 从而导致 VAE 预编码或 LDF 裁剪时出现对齐错误。疑似帧率或重定向异常样本不进入训练集合。

其次, 检查文本标注来源。BABEL 标注中存在原始动作类别和处理后的标签。本文最终使用 `proc_label` 作为文本片段, 因为该字段比原始类别更接近自然语言描述, 也更适合作为文本编码器输入。对于空标注, 系统使用 `transition` 作为回退文本, 保证每个连续潜变量都有明确条件。

第三, 检查重构后的物理量范围。57 维动作特征本身不是 MuJoCo 的 `qpos`, 而是局部增量表示。可视化前需要重构偏航角、根节点位置和关节角。如果偏航角增量长期存在偏置, 即使单帧误差很小, 也会在长序列中形成明显朝向漂移; 如果关节角超出机器人范围, MuJoCo 回放可能看似可播放, 但后续跟踪器难以跟踪。因此, 后续物理闭环中需要加入根节点四元数归一化、关节自由度限幅和高度范围检查。

最后, 保留可复现实验索引。对于多文本片段、较长时序或包含复杂姿态变化的样本, 数据加载器保留稳定样本名和排序规则。固定样本有利于在不同模型、不同精度和不同推理路径下复现问题, 相关实验结果统一在第四章给出。

3.5 生成模型接口与路线

本文系统的关键接口是 57 维动作特征。该接口向上连接文本生成模型, 向下连接 MuJoCo 可视化和跟踪器参考命令。为了避免模块之间职责混乱, 本文将系统边界划分为三层。

第一层为生成层。生成层只负责输出动作特征序列, 不直接处理电机控制, 也不在训练损失中显式模拟接触动力学。这样做的原因是生成模型训练成本较高, 若直接加入物理仿真闭环, 样本效率和工程复杂度都会显著增加。

第二层为重构层。重构层负责将 57 维特征恢复为根节点位置、根节点朝向、关节角和接触标签。MuJoCo 回放和跟踪器都应从这一层读取统一格式, 避免不同脚本各自实现特征到参考动作的转换, 造成数值不一致。本文将基础回放脚本与对比脚本中的转换逻辑集中到共享模块, 就是出于这一考虑。

第三层为控制层。控制层不应假设高层生成结果完全物理可行, 而应通过跟踪奖励、终止条件和域随机化学习对生成偏差的鲁棒性。若某类生成动作始终无法被跟踪器跟踪, 则应将失败样本反馈给生成层, 作为后续数据清洗或物理反馈微调的依据。

上一节已经给出 57 维机器人动作表示、VAE 连续潜变量化和文本边界对齐方法。本节讨论建立在该接口之上的高层生成模型方法。先介绍流匹配探索模块，再介绍 LDF 主模型，以说明两类生成路线的技术差异；从工程依赖关系看，二者都以动作特征和 VAE 连续潜空间接口为前提。

3.5.1 流匹配生成器探索

3.5.1.1 短动作原语路线

本文在统一工程中实现了流匹配生成器探索模块。该模块参考 TextOp 的短动作原语生成思想：高层生成器使用文本条件模型生成短动作片段，再通过自回归方式拼接为连续动作^[11]。这类方案的优点是接近机器人控制中的滚动窗口结构，并且便于与低层跟踪器对接；不足是扩散采样需要多步迭代，且长序列生成容易受到历史误差影响。

为了探索更快的生成路径，本文在 Any-Text-to-Humanoid-Action 工程中规划并实现流匹配模块。流匹配直接学习噪声分布到数据分布的连续速度场，避免将生成过程完全绑定到固定离散扩散步数^[35]。实现上，流匹配训练模块构造线性路径插值 $x_t = (1 - t)x_0 + tx_1$ ，并以速度场 $v = x_1 - x_0$ 作为监督目标；训练入口复用文本编码、动作历史条件和生成主干，只将目标从噪声预测改为速度预测。推理阶段新增流匹配生成与可视化入口，使用欧拉法进行常微分方程推理，并保留四阶 Runge-Kutta 求解器作为对比。相关训练、可视化、完整比较和循环比较脚本统一服务于短原语路线的可复现实验。

流匹配版本保留了文本编码、历史动作条件和 VAE 解码接口，便于与原始扩散版本比较。开发过程中还加入了多步训练、历史动作条件、静态姿态增强、重缩放引导和脚滑相关损失。该阶段的主要价值是验证：在机器人动作生成中，可以不依赖传统 DDPM/DDIM 采样形式，而直接学习从噪声到动作潜变量的速度场。不过，短原语自回归结构仍然对长序列文本切换和大规模简单命令覆盖存在限制，因此本文后续转向 LDF 的下三角时间调度。

3.5.1.2 训练与采样细节

连续速度场训练目标。在流匹配模块改造阶段，本文尽量复用原有数据接口和网络主干，只替换生成目标和采样器。这样做的原因是，若同时改动数据、网络和采样过程，很难判断实验变化来自流匹配本身还是来自其他工程差异。训练时，模型仍接收

文本条件、历史动作条件和当前动作潜变量；不同之处在于，原始扩散模型学习噪声或去噪结果，流匹配版本学习从噪声点指向真实动作点的速度场。

具体来说，对每个训练样本采样真实动作潜变量 $\mathbf{x}_1$ 和标准高斯噪声 $\mathbf{x}_0$ ，再采样连续时间 $t \in [0, 1]$ ，构造中间状态：

$$\mathbf{x}_t = (1 - t)\mathbf{x}_0 + t\mathbf{x}_1. \quad (3-7)$$

模型输入为 $\mathbf{x}_t$ 、时间 t 、文本条件和历史动作条件，监督信号为 $\mathbf{x}_1 - \mathbf{x}_0$ 。该目标不需要预先设定离散扩散步数，也不需要手工设计复杂的 β_t 噪声表。对于实时机器人场景，连续常微分方程（Ordinary Differential Equation, ODE）采样还有一个潜在优势：可以根据延迟预算选择欧拉法（Euler）、四阶 Runge–Kutta（RK4）或更少步数的近似求解，而不是固定执行较多 DDIM 步。

常微分方程求解器与响应速度。推理阶段从噪声初值出发，沿时间从 0 积分到 1。Euler 求解器每步使用当前速度场线性推进，计算简单但误差较大；RK4 在每个步长内多次评估速度场，可以在相同步数下获得更平滑的轨迹，但计算开销也更高。本文在统一工程中保留两种求解器，是为了后续比较“生成速度”和“动作稳定性”之间的权衡。如果跟踪器对动作抖动较敏感，则更高阶求解器可能带来更好的可跟踪性；如果在线延迟是主要瓶颈，则低步数 Euler 可能更实用。

短序列、长序列和实时指令接口。短原语模型以局部片段为单位进行预测，历史窗口可以缓解局部衔接问题，但长序列文本切换时，模型仍需要反复在短窗口内解释全局语义。流匹配改造降低的是采样形式上的复杂度，并不改变短原语自回归接口本身。因此，本文把流匹配模块定位为生成目标和采样器探索：其输出仍通过同一 VAE 解码和 57 维动作重构层进入可视化与跟踪器接口，相关短序列、长序列和实时指令实验放在第四章报告。

3.5.2 机器人 LDF 主模型

3.5.2.1 主模型组成

本文主模型在统一工程中参考 FloodDiffusion 改造。FloodDiffusion 继承扩散强制的“不同时间位置具有不同噪声等级”思想，并将其用于流式动作生成^[12,36]。该模块的主要目标是在 VAE 潜空间中生成 G1 机器人的动作连续潜变量，再通过 VAE 解码器还原为 57 维动作特征，并支持整段和流式两种推理模式。

模型由文本编码器、动作 VAE 和 LDF 主干三部分组成。文本编码器使用冻结的

T5 (Text-to-Text Transfer Transformer) 将自然语言片段编码为潜变量位置级文本嵌入；T5 基于 Transformer 编码器-解码器架构，适合将文本映射为上下文表征^[33-34]，空文本嵌入则用于无分类器引导。动作 VAE 负责将 57 维动作特征编码为 d_z 维连续潜变量，并在推理后解码回 57 维特征。LDF 主干使用 Wan-DiT 结构，在潜空间中根据下三角噪声调度预测速度场或目标量；扩散 Transformer (Diffusion Transformer, DiT) 系列工作表明，Transformer 主干可以作为扩散模型中的可扩展骨干网络^[50]。

图 3-2 给出了机器人 LDF 的训练与推理链路。训练时，真实 57 维动作先经过 VAE 编码器得到连续潜变量，再加入下三角噪声并由 Wan-DiT 预测当前推进窗口的目标量；推理时，模型从噪声连续潜变量出发，在文本条件下逐步生成潜变量序列，最后由 VAE 解码器解码回 57 维动作特征。

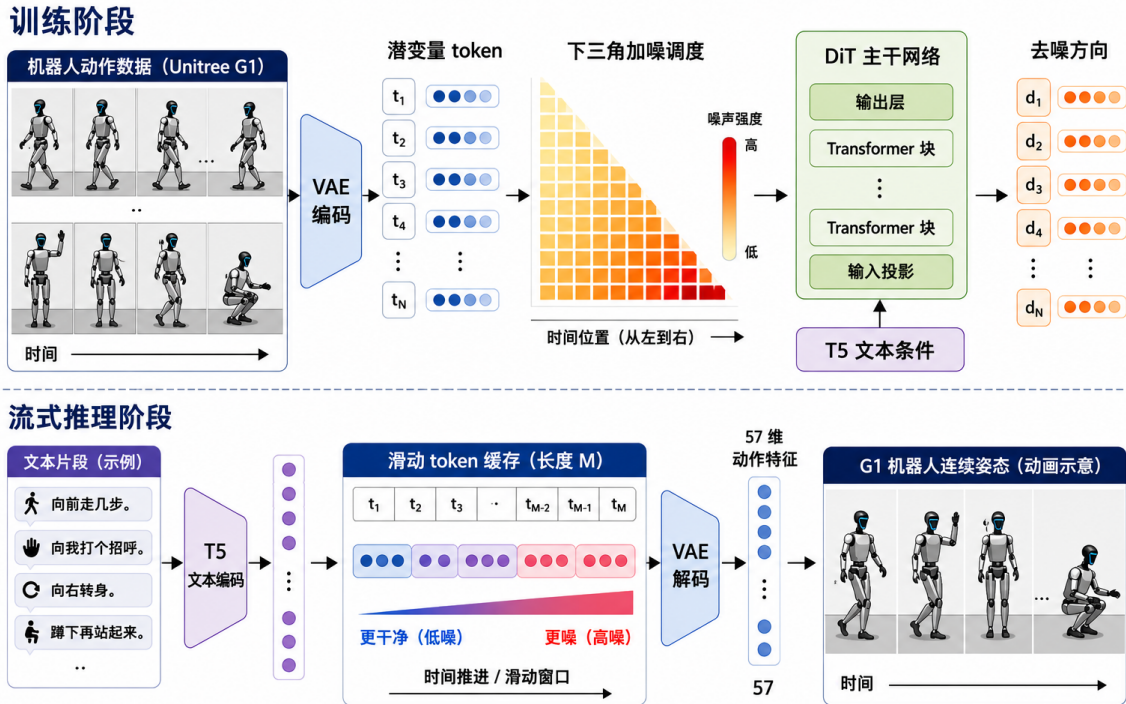


图 3-2 机器人 LDF 基于连续潜变量的训练与流式推理链路

图中以“连续潜变量”表示 VAE 时间下采样后的实值动作潜变量位置，并明确区别于离散码本编号或词表索引；训练和推理链路传递的核心对象始终是实值连续动作潜变量序列。

3.5.2.2 下三角加噪与分块损失

训练时, 输入批次包含连续潜变量序列、潜变量长度、文本列表和每段文本的潜变量结束位置。对于每个样本, 随机采样连续时间 τ , 根据式 $\alpha_i(\tau)$ 为不同连续潜变量位置添加不同强度的噪声:

$$\tilde{\mathbf{z}}_i = (1 - \alpha_i)\mathbf{z}_i + \alpha_i\epsilon_i, \quad \epsilon_i \sim \mathcal{N}(0, I). \quad (3-8)$$

当模型采用速度预测时, 目标速度为:

$$\mathbf{v}_i^* = \mathbf{z}_i - \epsilon_i. \quad (3-9)$$

本文实现只对推进窗口内最后 `chunk_size` 个连续潜变量位置计算均方误差:

$$\mathcal{L}_{\text{LDF}} = \frac{1}{B} \sum_{b=1}^B \left\| \left(v_{\theta}(\tilde{\mathbf{z}}^{(b)}, \alpha, c) \right)_W - \left(\mathbf{z}^{(b)} - \epsilon^{(b)} \right)_W \right\|_2^2, \quad (3-10)$$

其中 W 表示当前推进窗口。实现中加入的流损失归一化主要用于平衡不同潜变量维度的损失尺度, 缓解 VAE 潜空间各维方差不均导致的训练偏置。

3.6 训练与推理实现

本文实现了两种推理方式。整段推理一次性初始化完整连续潜变量序列为高斯噪声, 然后按照下三角时间调度从左向右推进, 最终返回完整序列。流式推理则通过 `init_generated` 和 `stream_generate_step` 维护内部生成缓存, 每次提交一个连续潜变量位置, 并在生成窗口滑动到长度上限时丢弃已提交历史、补充新的随机噪声。相比传统整段扩散采样, 流式调度更接近在线控制中“过去已执行、未来仍可更新”的状态划分, 这也是扩散强制与 FloodDiffusion 关注的核心问题^[12,36]。

整段推理适合离线比较和全局可视化, 流式推理更接近机器人在线部署。二者的核心差别在于文本条件的编码和缓存方式。整段推理通常会一次性编码当前样本的所有文本片段; 流式推理则按当前时间步逐条编码。为避免推理路径差异混入文本条件差异, 系统需要在评估时固定文本列表、随机种子和编码路径。第四章将报告相关一致性实验。

3.6.1 流式调度与缓存实现

机器人 LDF 的流式实现需要同时维护三个状态: 已经提交的连续潜变量、当前窗口内仍在迭代去噪的潜变量位置, 以及未来尚未生成的噪声潜变量位置。若把三者

混在一个普通序列中处理，容易在窗口滑动时破坏文本条件和潜变量位置的对应关系。本文实现中将生成状态封装为缓存对象，缓存记录已生成连续潜变量数、当前噪声窗口、随机数种子、文本片段边界和每个连续潜变量对应的文本嵌入。每次调用流式步进函数时，系统先根据潜变量索引查询当前文本条件，再按下三角时间表更新窗口中的潜变量位置，最后只提交窗口最左侧已经达到干净状态的部分。

下三角调度的作用可以理解为把“从噪声到动作”的生成过程沿时间轴展开。对于一个长度为 L 的连续潜变量序列，传统整段扩散在每个采样步都会同时更新所有连续潜变量；LDF 则让左侧潜变量位置更早接近真实分布，右侧潜变量位置保持较高噪声。这样做的直接好处是，机器人不必等待完整长序列生成完成后才开始执行，而可以在较短延迟后得到当前动作参考。本文配置中 `chunk_size=5`，意味着每轮推进只把有限数量的潜变量位置视作当前需要稳定生成的区域，从而控制显存占用和在线延迟。

缓存实现中最容易出错的是文本边界。BABEL 标注以帧为单位给出起止时间，而 VAE 连续潜变量位置以 12.5 Hz 表示动作。若只在特征帧率上裁剪文本边界，再直接复制到连续潜变量序列中，就会造成文本切换偏移。本文在数据处理阶段同时保存特征级和连续潜变量级两套文本结束索引，训练和推理分别使用与当前时间尺度一致的边界。流式推理中，如果新的指令在当前潜变量位置之后才生效，则历史连续潜变量的文本嵌入不会被重写；如果新的指令覆盖未来窗口，则只更新未提交部分。该规则保证了在线指令更新不会改变已经执行的历史动作。

为了便于定位问题，本文还保留了整段推理和流式推理的共同对比入口。该入口在相同模型参数、相同随机种子、相同引导系数和相同样本索引下生成两条轨迹，并在 MuJoCo 中并排播放。若两条轨迹不同，可以逐层比较文本嵌入、连续潜变量、解码后的动作特征和重构 `qpos`。该入口属于第四章流式一致性实验的复现工具。

3.6.2 无分类器引导 (Classifier-Free Guidance, CFG)

为了增强文本条件对生成结果的影响，本文保留无分类器引导。训练时以概率 p_{drop} 将文本置为空，使模型同时学习有条件和无条件预测。推理时，有条件预测 $\hat{\mathbf{v}}_{\text{cond}}$ 和无条件预测 $\hat{\mathbf{v}}_{\text{uncond}}$ 按如下方式组合：

$$\hat{\mathbf{v}} = s\hat{\mathbf{v}}_{\text{cond}} - (s - 1)\hat{\mathbf{v}}_{\text{uncond}}, \quad (3-11)$$

其中 s 为引导系数。本文机器人 LDF 配置默认 $s = 5.0$ ，可视化脚本支持通过 `--guidance-scale` 覆盖该值。引导系数属于推理阶段的可调超参数，其对生成

误差、动作幅度和平滑度的影响在第四章消融实验中讨论。

3.6.3 训练阶段设计

高层生成器的训练并不是简单地把所有连续潜变量输入模型计算一个全序列损失。为了适配流式部署，训练阶段需要模拟推理时“左侧历史逐步确定、右侧未来仍有噪声”的状态。本文 LDF 训练阶段可以分为三个逻辑步骤。

第一步是潜变量裁剪。真实动作长度差异较大，若直接使用完整长序列，显存占用会随最大长度快速增长。本文在 `train_block_length` 中设置训练块长度，例如 50 个潜变量位置。对于较短样本直接使用完整潜变量序列；对于较长样本，根据 `random_block_cap` 决定从开头截取还是随机裁剪。开头截取更稳定、便于调试，但会降低长序列后半段覆盖；随机裁剪覆盖更全面，但需要同时裁剪潜变量、动作特征和文本结束位置，容易引入边界偏移。因此，本文先采用固定开头裁剪作为稳定基线，并将随机裁剪纳入后续对照配置。

第二步是噪声调度。对于每个批次样本随机采样连续时间 τ ，再根据潜变量位置计算噪声等级。与整段扩散不同，同一序列的左侧潜变量位置可能接近干净，中间潜变量位置处于部分噪声状态，右侧潜变量位置仍接近纯噪声。模型只需要在当前推进窗口学习从带噪状态回到真实连续潜变量的方向。这样的训练目标与流式推理更一致。

第三步是文本条件展开。若一个样本包含多个文本片段，系统会按潜变量结束位置构造连续潜变量级文本嵌入列表。由于 Wan-DiT 的交叉注意力接收的是每个连续潜变量对应的文本上下文，文本列表长度必须与当前模型输入时间长度一致。训练时还会以一定概率将文本替换为空文本，用于支持 CFG 推理。

3.6.4 路线比较与实现配置

短原语生成和 LDF 都面向流式动作生成，但建模粒度不同。TextOp 的 RobotM-DAR 以短动作原语为基本单位，输入包括当前文本和历史动作，输出未来若干帧动作^[11]。它的优势是天然接近控制系统中的滚动时域思路，且便于与低层跟踪器和部署模块对接。缺点是每个原语之间的衔接和长时语义保持高度依赖历史窗口，长序列误差容易积累。

FloodDiffusion/LDF 则在一个较长潜变量序列上施加下三角噪声调度。它并不是每次从零生成一个独立动作片段，而是在同一序列中逐渐推进生成波前。对于时变文

本条件，过去潜变量位置仍对应过去文本，当前及未来潜变量位置对应新文本，因此更适合本文关注的“连续自然语言命令”场景。其代价是实现中需要非常谨慎地处理连续潜变量级文本对齐、缓存状态和推理数值一致性。

从系统依赖关系看，短原语路线和 LDF 路线都建立在 57 维动作表示和 VAE 连续潜变量接口之上；从技术侧重点看，流匹配探索模块关注采样目标和常微分方程求解器，LDF 主模型进一步关注长序列流式生成能力和时变文本条件。本文因此在方法章保留两类路线的接口和训练机制，在实验章分别报告其生成质量与一致性结果。

3.6.4.1 训练配置与实现细节

机器人版本主要训练配置如表 3-2 所示。本文主实验使用 $d_z = 128$ 、训练块长 50 个潜变量位置、每个潜变量位置对应 4 帧原始动作，即每个训练块约覆盖 4 秒动作。模型训练使用 PyTorch Lightning，默认精度为 bf16-mixed，优化器为 AdamW。这里的 bf16 指 Brain Floating Point 16 位浮点格式，主要用于降低图形处理器（Graphics Processing Unit, GPU）显存占用。由于 Wan-DiT 主干本质上依赖注意力机制，模型容量、序列长度和显存开销之间存在明显权衡，这一点与 Transformer 和 DiT 类模型的计算特性一致^[33,50]。

表 3-2 机器人 LDF 主要训练配置

配置项	本文设置
动作特征维度	57
VAE 潜变量维度	128
特征帧率	50 Hz
连续潜变量帧率	12.5 Hz
LDF 推进块大小	5 个潜变量位置
噪声步数	10
训练块长度	50 个潜变量位置
批大小	8
优化器	AdamW, 学习率 2×10^{-4}
文本编码器	冻结 T5 文本编码器
主干网络	Wan-DiT, 8 层, 隐藏维度 1024

相比 FloodDiffusion 原始 HumanML3D 配置，本文主要改动包括：将动作输入维度从 263 改为 57；新增机器人 VAE 配置；新增 ldf_robot.yaml；修改 BABEL 数据加载器以支持机器人数据的连续潜变量/文本对齐；新增 MuJoCo 可视化脚本；新增流式和整段对比工具；在 FlashAttention 不可用时使用 PyTorch 缩放点积注意力（Scaled Dot-Product Attention, SDPA）回退路径，以提高可复现性。

除模型代码外，本文还对实验入口进行了分层整理。VAE 训练、VAE 预编码、LDF 训练、离线可视化和流式可视化分别保留独立脚本，避免一个脚本同时承担训练、推理和显示职责。这样做虽然增加了入口数量，但有利于在调试时固定变量。例如，当 MuJoCo 显示结果异常时，可以先直接加载真实动作特征验证重构是否正确，再加载 VAE 重构结果验证连续潜变量误差，最后加载 LDF 生成结果分析生成误差。该分层排查方式避免了将数据重构、生成模型和渲染逻辑混为一谈。

3.6.4.2 显存、精度与确定性处理

机器人 LDF 训练和推理的工程难点之一是显存占用。动作连续潜变量序列长度会随动作时长增长，Wan-DiT 主干又需要在时间维度上进行注意力计算，若直接把完整长序列放入模型，显存开销会迅速上升。本文采用训练块裁剪、分块损失和流式推理缓存来控制显存：训练阶段只取固定长度的连续潜变量块，损失只计算当前推进窗口；推理阶段优先使用流式窗口，整段对比时则在显存不足后进入分块回退路径。这样可以在有限显存条件下完成实验，同时保留长序列流式生成能力。

混合精度是另一个关键因素。训练使用 Brain Floating Point 16 (bf16) 混合精度路径 bf16-mixed 可以降低显存并提高吞吐，但可复现实验仍需要固定模型参数、随机种子、文本条件列表和文本编码路径。若推理入口之间的批处理形态、回退路径或缓存策略不一致，生成差异可能同时来自模型采样和工程路径。为此，本文把确定性检查写入统一对比入口，并在第四章通过实验报告具体影响。

3.6.5 连续潜变量表述说明

本文用“连续潜变量位置”描述 VAE 沿时间下采样后的序列单元，避免将其误解为离散码本编号或词表索引。换言之，生成模型学习的是连续动作潜变量序列 $\mathbf{Z} \in \mathbb{R}^{L \times d_z}$ ，VAE 解码器再将其还原为 57 维机器人动作特征。后文在涉及 LDF、流匹配和跟踪器接口时，均以“连续潜变量序列”或“连续动作潜变量”强调这一点。

3.7 跟踪器接口与仿真跟踪方法

3.7.1 参考轨迹构造

生成模型输出的连续动作潜变量序列先由 VAE 解码为 50 Hz 的 57 维动作特征，再经过反归一化和特征-广义坐标 (qpos) 重构层转换为低层跟踪器可读取的参考轨迹。该接口只传递连续轨迹和未来参考窗口，不引入离散动作编号或离散码本；因此

本文在接口层始终按 VAE 时间下采样后的连续潜变量位置组织生成状态。参考轨迹构造时需要保持三项一致性：第一，使用与训练阶段相同的均值和标准差；第二，按偏航角增量累积恢复世界坐标下根节点朝向；第三，在进入控制器前检查根节点高度、关节角范围、速度平滑性和脚部接触一致性。

在仿真跟踪器中，参考轨迹并不是单帧目标，而是围绕当前控制步组织的短时未来窗口。本文训练的 G1 跟踪任务配置使用未来 5 步身体锚点位置和姿态作为策略观测的一部分，参考身体节点覆盖骨盆、左右髌膝踝、躯干、左右肩肘腕等 G1 主要刚体。该设计使策略不仅看到当前姿态误差，还能提前感知即将到来的身体重心变化和摆臂、抬腿等动作趋势，符合滚动跟踪控制的需求。对于本文生成动作，真实重定向动作、VAE 重构动作和 LDF 生成动作都先进入同一参考轨迹池，再以相同窗口格式送入跟踪器，避免把不同来源轨迹用不同脚本转换而造成评价偏差。参考轨迹进入跟踪器前保存来源标签、样本编号、文本片段、统计量版本和重构脚本版本；这些元数据用于在第四章将同一动作来源、同一评估窗口和同一策略模型对齐，保证跟踪器训练与仿真回放结果可复现。

3.7.2 观测、动作与策略接口

低层跟踪器采用近端策略优化（Proximal Policy Optimization, PPO）训练。策略观测由两类信息组成：一类是机器人当前状态，包括投影重力、基座线速度和角速度、关节位置、关节速度以及上一时刻动作；另一类是参考命令，包括当前生成运动命令和未来身体锚点位置、姿态窗口。特权价值网络可额外读取身体关键点位置和姿态等信息，用于训练阶段估计价值函数；部署或评估时策略网络只依赖公开观测。策略动作接口为关节位置目标或关节位置增量，随后由底层比例-微分（Proportional-Derivative, PD）控制和 Isaac Lab 物理仿真产生接触、速度和姿态响应。由于策略网络的输入是当前状态与未来参考窗口，而不是原始文本或连续潜变量，低层控制器与高层生成器之间通过“参考轨迹”这一中间表示解耦；这样既可以用真实重定向动作检查跟踪器上限，也可以分别用 VAE 重构动作和 LDF 生成动作检查高层模型误差对物理跟踪的影响。

该接口体现了两级控制边界。高层生成器负责根据文本条件生成候选动作，低层 PPO 跟踪器负责在 Isaac Lab 仿真中跟踪参考动作并输出控制动作。本文不把生成器输出直接解释为真实机器人可执行控制命令，而是通过跟踪器观测中的未来参考窗口、奖励项和终止条件评价其物理可跟踪性。这样的边界避免把 MuJoCo 运动学回放

误写成物理控制成功，也使后续实验能够分别定位 VAE 重构误差、LDF 生成误差和低层跟踪误差。

3.7.3 PPO/BeyondMimic 风格跟踪目标

相关工作 TextOp 展示了高层文本动作生成器与低层通用跟踪策略结合的两级思路，并与 BeyondMimic 的全身参考动作跟踪思想一致：不直接让高层模型输出力矩，而是训练一个可复用的全身参考动作跟踪策略。本文在方法层吸收这种分层思想，将跟踪目标写成“参考轨迹一致性 + 物理安全性”的组合。正向奖励主要鼓励身体锚点位置、身体锚点姿态、身体关键点位置、身体关键点姿态、身体线速度和身体角速度接近参考；负向项约束动作变化率、关节限位、非期望接触、脚滑、落地冲击、关节超速和过大力矩。若参考轨迹来自 LDF 生成结果，奖励项并不关心该轨迹的文本来源，而只根据机器人是否能在动力学约束下稳定跟踪进行评价。

终止条件用于避免策略在明显失败状态下继续积累无意义样本。本文使用的配置包含超时终止，以及身体锚点高度误差、身体锚点姿态或投影方向误差、末端身体高度偏差等失败终止。训练命令还启用自适应采样：失败率更高的动作会以更大概率被重新采样，同时保留一定均匀采样比例，避免策略只关注少数困难样本。这相当于一种课程/重采样机制：先用大量并行环境覆盖参考动作池，再根据失败统计动态加强困难动作的训练权重。在本文系统中，这些机制用于解释跟踪器如何处理不同难度的参考动作，并为第四章的奖励项、终止项和回放结果分析提供方法依据。从优化形式看，PPO 仍是在采样轨迹上最大化折扣回报，并用截断代理目标限制新旧策略更新幅度；本文关注的是该目标如何服务于参考轨迹跟踪，而不是重新提出新的强化学习算法。

3.7.4 生成动作与跟踪器训练闭环

受 BeyondMimic 等将运动跟踪、生成先验和物理反馈结合的工作启发^[51]，本文将低层跟踪器设计为物理反馈和训练评估的核心模块，而不是把它作为生成器之后的附属显示环节。具体来说，真实重定向动作、VAE 重构动作和 LDF 生成动作都只作为参考轨迹池的来源；这些轨迹先通过同一特征-qpos 重构层得到根节点、骨盆位姿、身体锚点和脚底接触状态，再经过动作安全检查器检查关节限位、根节点高度、接触一致性和速度平滑性。跟踪器在 Isaac Lab 中读取机器人当前状态、投影重力、关节状态和未来参考窗口，由 PPO 策略输出关节目标或动作增量，并通过根节点误差、

身体关键点误差、脚滑惩罚、关节限位和跌倒终止等信号评价参考轨迹的物理可跟踪性。

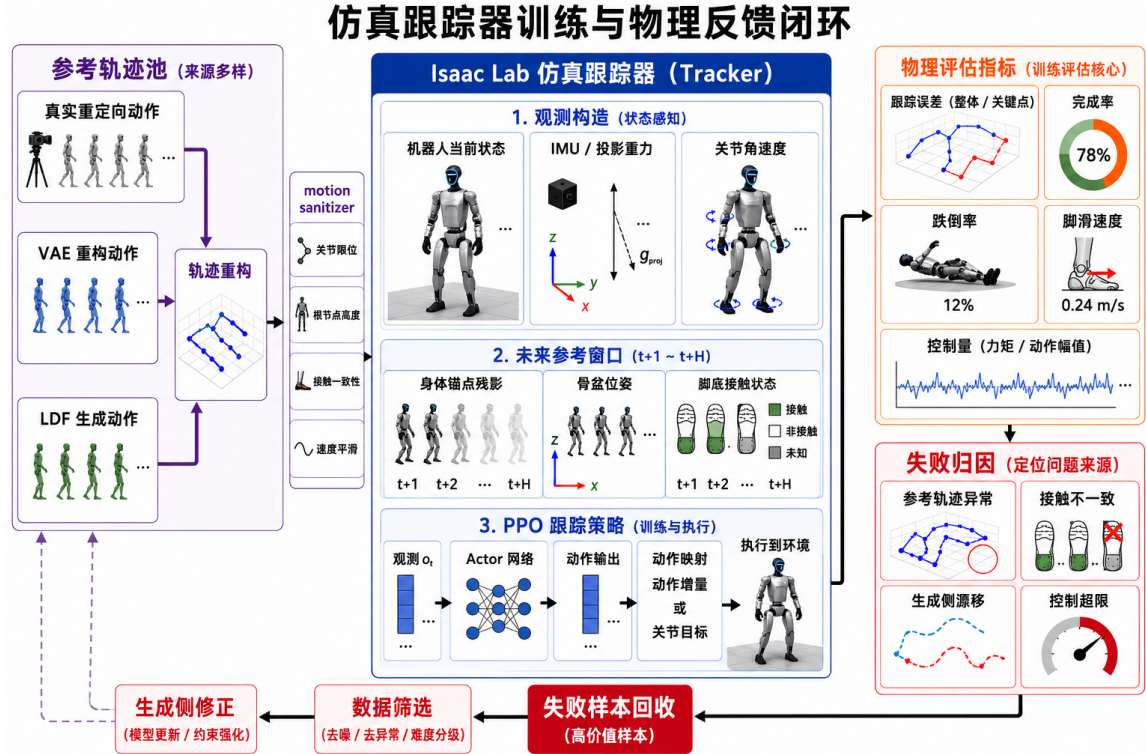


图 3-3 仿真跟踪器训练与物理反馈闭环

图 3-3 中的闭环关系也是第四章实验组织的依据。若某类生成动作能被稳定跟踪，说明其在动力学约束下具有较高可执行性；若频繁触发跌倒、脚滑、关节越界或过大控制量，则该样本应回流到参考轨迹池和生成侧，用于数据筛查、VAE 维度选择、LDF 配置比较或后续物理反馈微调。本文已经完成仿真跟踪器训练，保存策略参数，导出 ONNX 策略，并接入 Isaac Lab 评估入口，因此第四章围绕该跟踪器报告训练配置、奖励终止项、回放入口和生成动作进入物理评估的结果组织方式。

3.7.5 面向动作生成器的强化学习后训练规划

跟踪器闭环还可以进一步用于高层动作生成器的后训练。具体思路是：将 LDF 生成的 57 维动作经过动作安全检查器和跟踪器回放，得到跟踪误差、脚滑速度、跌倒标志、关节限位违规、力矩饱和比例等物理反馈；再把这些反馈转化为生成器侧的样本权重、偏好对或强化学习（Reinforcement Learning, RL）奖励，使高层模型更倾向于生成可被低层策略稳定跟踪的动作。该方向与“用物理反馈对齐生成模型”的思

路一致，在本文中作为下一阶段优化规划：本文已经提供动作生成、仿真跟踪器训练和物理反馈接口，后续可在固定样本集合上记录每个样本的物理奖励与失败原因，再决定采用离线偏好优化、筛选再训练还是在线 RL 微调。

3.7.6 安全检查与失败归因

进入跟踪器前的动作安全检查器采用“最小修改、可记录、可关闭”的原则。若轨迹存在关节越界、根节点高度异常、偏航角跳变或接触不一致，系统应记录异常维度和修正幅度；若修正幅度过大，则该轨迹不应作为生成成功样本。失败案例按数据重构层、连续潜变量生成层和物理跟踪层分层归因：真实动作特征异常说明数据或重构流程有问题，VAE 重构异常说明连续潜变量表示不足，LDF 生成异常说明文本条件生成仍需改进，而跟踪器失败则说明参考轨迹在物理约束下不可稳定跟踪。

3.8 本章小结

本章作为方法章节，统一给出了本文系统的工程设计和算法接口。首先，本文定义了面向 G1 机器人的 57 维局部动作表示，并通过归一化、反归一化和统一重构层保证生成、可视化与跟踪器接口使用同一语义。其次，本文使用时序 VAE 将 50 Hz 动作压缩为 12.5 Hz 连续潜变量序列，并明确该序列不是离散码本，而是实值动作潜变量。最后，本文在该接口上构建流匹配探索模块、机器人 LDF 主模型和跟踪器参考轨迹接口，为第四章的实验分析提供统一方法基础。

第四章 实验分析

本章作为实验章节，统一报告建立在第三章方法接口之上的实验设置、VAE 潜空间分析、流匹配探索结果、LDF 主模型实验、消融分析、MuJoCo 运动学回放和仿真跟踪器实验。所有结果均围绕 57 维 G1 动作特征和 VAE 连续潜变量序列展开；跟踪器部分重点展示本文完成的训练配置、训练结果、ONNX 导出、代表性仿真回放链路和物理指标分析方式。

4.1 实验设置

本文实验主要围绕统一工程展开。该工程用于流匹配生成器探索、机器人 LDF 训练与推理、MuJoCo 可视化对比，以及基于 G1 仿真跟踪策略进行 Isaac Lab 跟踪器仿真评估。系统使用 Python、PyTorch、PyTorch Lightning、MuJoCo、Isaac Lab 和 RSL-RL 等工具。MuJoCo 是常用的机器人和控制仿真引擎^[45]，Isaac Gym 代表了面向机器人学习的图形处理器（Graphics Processing Unit，GPU）并行物理仿真路线^[46]，大规模并行强化学习也已被证明能够显著加快腿足机器人策略训练^[47]。

本文机器人数据集包含 6452 条训练样本和 2152 条验证样本。每条动作已转换为 57 维特征，并保存相应文本片段。VAE 训练完成后，数据被预编码为连续潜变量序列用于 LDF 训练。主要 LDF 实验采用第三章表 3-2 中的配置：VAE 潜变量维度为 128，训练块长为 50 个潜变量位置，每个潜变量位置对应约 4 帧原始动作，默认无分类器引导（Classifier-Free Guidance，CFG）系数为 5。

低层跟踪器是本文仿真闭环的一部分。本文以 Isaac Lab 平地跟踪任务和 RSL-RL 中的 PPO 训练器训练 G1 参考动作跟踪策略，保存策略参数，并导出 ONNX 策略文件。保存的智能体配置记录了模块化归一化多层感知机（Modular Normalized Multilayer Perceptron，MNMLP）策略网络-价值网络、经验归一化、近端策略优化（PPO）超参数和 1,000,000 最大训练迭代设置。评估任务为 G1 平地跟踪任务，未来参考步数为 5，评估时策略网络/价值网络隐藏层维度均为 [2048, 1024, 512]。因此，本文将低层跟踪器作为已经完成训练并纳入仿真回放链路的参考动作跟踪策略；真机部署和更大规模开放文本物理基准评测作为后续扩展。

本文从训练配置、策略结果、仿真回放和物理指标四个角度组织跟踪器实验。训

练配置说明 PPO 超参数、网络结构、参考窗口和身体跟踪节点；策略结果说明策略参数、ONNX 导出模型和配套配置如何形成可复用低层策略；仿真回放把 Isaac Lab 回放流程和 MuJoCo 跨仿真检查流程连接到同一参考轨迹；物理指标则把真实重定向动作、VAE 重构动作和生成模型动作放入同一未来身体锚点窗口，记录跟踪误差、脚滑、早停、限位和控制量。表 4-1 汇总训练配置与结果摘要，表 4-2 进一步说明评估与导出流程。

表 4-1 G1 仿真跟踪器训练配置与结果摘要

类别	具体内容	论文中使用方式
策略参数	PPO 跟踪器最终策略参数	Isaac Lab 仿真回放加载
导出模型	ONNX 策略导出文件	MuJoCo/仿真接口验证
评估任务	G1 平地跟踪任务	Isaac Lab 仿真回放入口
未来参考窗口	未来参考步数为 5	低层策略观测设计
策略网络	MNMLP, [2048, 1024, 512]	策略网络/价值网络结构说明
PPO 配置	每轮采样 24 步, $\gamma = 0.99$, $\lambda = 0.95$, 裁剪系数 0.2	训练超参数说明
跟踪目标	骨盆/躯干身体锚点与 G1 身体关键点	参考轨迹构造依据
物理指标	跟踪误差、早停、脚滑、限位和控制量	生成动作物理评价依据

表 4-2 仿真跟踪器评估与导出流程

用途	流程说明
训练或继续训练	使用 G1 平地跟踪任务、16,384 个并行环境和 1,000,000 次最大迭代配置
Isaac Lab 回放评估	加载训练后的策略参数，在少量并行环境中固定样本和随机种子回放
未来参考窗口	每个控制步读取未来 5 步参考身体锚点位姿
策略网络结构	策略网络与价值网络隐藏层均为 [2048, 1024, 512]
ONNX 检查	加载导出的 ONNX 策略做 MuJoCo/仿真接口一致性检查
固定样本池评估	真实重定向、VAE 重构和上层生成轨迹分别记录
代表性样本评估	按轨迹来源记录跟踪误差、早停、脚滑、限位和控制量

4.2 VAE 潜空间与重构实验

VAE 的作用是为 LDF 提供可学习的连续动作潜空间。经典 VAE 通过重构损失和 KL 正则共同学习连续潜变量分布^[30]，这一思想也被潜空间扩散模型用于降低高维生成问题的计算成本^[32]。本文对多个 z 维度的 VAE 模型阶段进行了隐空间分析，主要关注活跃维度、总 KL、每维 KL 和后验标准差。不同模型的统计结果如表 4-3 所示。

表 4-3 机器人 VAE 潜空间维度扫描结果

模型设置	活跃维度	总 KL	每维 KL
$z = 4$, 110k 步	4/4	27.6	6.89
$z = 8$, 110k 步	8/8	52.7	6.59
$z = 16$, 110k 步	16/16	102.5	6.41
$z = 32$, 190k 步	32/32	203.8	6.37
$z = 64$, 450k 步	64/64	382.5	5.98
$z = 128$, 240k 步	128/128	770.5	6.02
$z = 128$, 460k 步	121/128	657.3	5.14

图 4-1 将表 4-3 中的每维 KL 可视化。可以看到，随着潜变量维度增加，每维 KL 整体下降；同时 $z = 128$ 长训版本出现活跃维度下降，说明隐空间容量并非越大越稳。该图用于辅助说明 VAE 维度选择并不是单纯追求最大潜变量维度，而需要结合重构质量、LDF 可学习性和后续跟踪器可跟踪性判断。




图 4-1 机器人 VAE 维度扫描结果可视化

图 4-2 进一步展开每个潜变量维度的 KL 分布和有效维度掩码。按 $\text{Var}(\mathbb{E}[z|x]) > 0.01$ 的判据， $z = 4$ 到 $z = 64$ 的对应模型均为全维活跃， $z = 128$ 的 240k 步版本也保持 128/128 活跃，而 460k 步版本降至 121/128。本文最终保留 $z = 128$ 作为重构质量更高的主实验配置，同时将 $z = 32$ 和 $z = 64$ 作为 LDF 对照训练的重要候选。

为检查高维潜空间是否具有可解释的局部结构，本文进一步对代表动作片段进行编码，并将连续潜变量均值标准化后用 t 分布随机邻域嵌入 (t-distributed Stochastic Neighbor Embedding, t-SNE) 投影到二维平面，如图 4-3 所示。该图中 T 姿态、坐下和跳跃片段形成了较明显区域，行走、转身和过渡片段则存在交叠。因此，本文把该

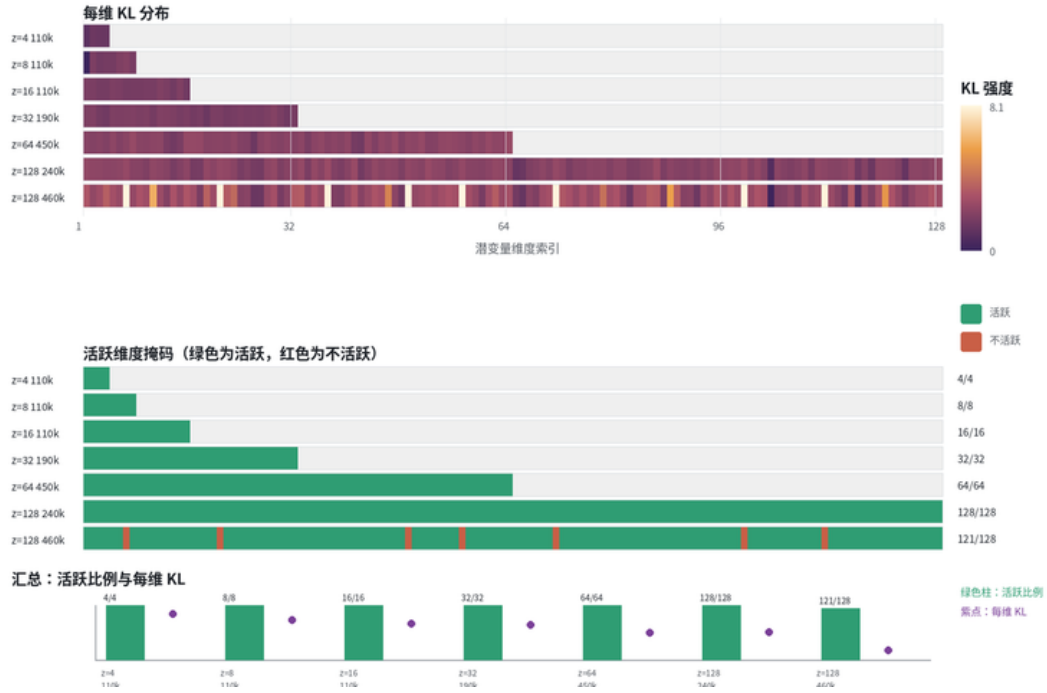


图 4-2 不同 VAE 潜变量维度的逐维 KL 与有效维度掩码；每行对应一个 VAE 模型阶段，上方为逐维 KL 强度，下方为活跃维度掩码

图作为潜空间结构的定性结果，而不把二维投影解释为严格的语义分类结果。

除潜空间统计外，VAE 是否可用还需要通过动作重构检查。图 4-4 选取多条代表性样本，并在每条样本中增加多个已渲染时间位置，在每个样本块中以上下两行分别回放原始重定向动作和 $d_z = 128$ VAE 重构动作。该图不是为了证明物理控制已经成功，而是用于检查连续潜变量编码和解码过程是否保持主要姿态、根节点高度和关节运动趋势。如果 VAE 重构在运动学回放中已经出现明显姿态异常，则后续 LDF 生成和跟踪器跟踪都无法得到可靠参考。

4.3 流匹配探索实验

流匹配模块用于验证速度场预测和 ODE 采样是否能替代传统多步扩散采样。本节集中报告该探索模块的定性动作对比、速度场诊断和引导系数对照；第三章只保留其训练目标与采样方法。




图 4-3 短原语 VAE 代表动作片段潜变量的 t-SNE 二维投影


4.3.1 短原语生成对比

图 4-5 合并展示两组短原语三路关键帧对比，分别比较真实重定向动作、扩散模型短原语生成结果和流匹配短原语生成结果。第一组样本的主要文本为 kick ball，后段切换为 transition；在 $t = 1.0s$ 附近，真实动作出现明显抬腿踢球姿态，扩散结果的腿部动作幅度较弱，而流匹配结果保留了更清楚的抬腿趋势。第二组样本包含 t pose、transition、raise leg 等文本片段，用于展示已经训练稳定的短原语生成分支在另一类抬腿和旋腿动作中的定性效果。两组结果共同说明，流匹配在部分短原语上能改善动作幅度和局部平滑性；同时，后续帧仍能看到生成结果与真实动作存在差异，因此本文不把该图解释为最终系统效果，而是把它作为转向 LDF 主模型和跟踪器约束的实验依据。


表 4-8 给出了短原语阶段扩散模型与流匹配目标在不同引导系数下的对照结果。可以看到，引导系数从 1 增大到 5 时，两类方法的非自回归和自回归误差整体升高；在该批验证结果中，扩散模型在总损失和重构误差上更低，而流匹配在部分可视化样本中保留了更明显的局部动作幅度。因此，本文将流匹配作为早期生成目标探索，而不是把它写成所有指标均优的最终结论。



图 4-4 原始重定向动作与 VAE 重构动作在多个已渲染时间位置上的 MuJoCo 关键帧分块对比



(a) 踢球动作样本：真实重定向动作、扩散模型短原语与流匹配短原语对比



(b) 抬腿动作样本：真实重定向动作、扩散生成动作与流匹配生成动作对比

图 4-5 真实重定向动作、扩散生成动作与流匹配生成动作的两组三路 MuJoCo 关键帧对比

4.3.2 速度场诊断

结合短原语生成对照，流匹配与原扩散路线的差异并非简单的“好或坏”。在与训练长度接近的短序列中，流匹配生成结果通常更平滑，下盘更稳定，动作抖动较少；扩散结果更容易出现高频抖动，但对文本切换的响应更直接。在长序列和实时文本输入中，流匹配仍然保持较好的局部平滑性，但更容易随滚动生成累积发生漂移，甚至在某些命令上出现响应延迟或和文本脱钩；扩散虽然更生硬，但长距离上往往与语义变化更贴近。这一观察说明，流匹配改善的是采样路径和平滑性，不自动解决自回归短原语结构的长时误差累积。

进一步实验还显示，引导系数、滚动生成训练、平滑损失和脚滑损失存在明显耦合。较大的引导系数可以增强语义响应，但也会增加卡顿、脚滑和模式崩溃风险；脚滑损失系数增大能够抑制脚滑，但过大时会让人倾向于“不迈步”；平滑损失从普通一阶变化惩罚改为 *jerk* 相关约束后，更适合抑制高频抖动，但也可能削弱动作幅度。因此，流匹配探索模块的结论不是“直接替代 LDF 主模型”，而是为后续生成器设计提供了两个经验：生成速度和运动平滑性可以通过速度场建模改善，但长序列语义保持和物理可执行性仍需要更强的时序调度与低层跟踪验证。

为了判断学习到的速度场是否接近 Rectified Flow 所期望的直线传输，本文对流匹配轨迹进行了主成分分析（Principal Component Analysis, PCA）投影和直线性分析。图 4-6 选取不同模型阶段与引导系数的结果进行合成展示。三幅图中第一、第二主成分解释率之和接近 1，说明生成轨迹大体落在低维平面上；但轨迹呈明显 U 形，平均方向余弦相似度约在 0.70–0.80 之间，说明从噪声到数据的路径并未被完全拉直。这解释了为什么本文流匹配模型仍需要多步常微分方程积分，而不是一两步即可完成高质量生成。速度大小变异系数约在 0.07–0.10，说明路径虽然弯曲，但流速相对均匀，没有出现明显急停急走。

该阶段还暴露了短原语路线的结构性限制。短原语模型以局部片段为单位进行预测，历史窗口可以缓解局部衔接问题，但长序列文本切换时，模型需要反复在短窗口内解释全局语义，容易出现动作意图衰减或历史误差累积。流匹配能降低采样形式上的复杂度，却不能完全解决短原语自回归结构的长时序限制。因此，本文将后续重点转向更适合长序列推进的 LDF。




图 4-6 流匹配速度场轨迹的 PCA 投影与直线性分析

4.4 LDF 主模型与流式一致性实验

在机器人 LDF 可视化中，本文发现同一条样本在流式生成和整段生成的显存不足分块回退路径下会产生不同动作。进一步排查表明，该问题不是 MuJoCo 显示速度或渲染导致，而是文本编码缓存和数值精度共同造成的。整段生成函数会先尝试一次完整序列生成；当显存不足后，程序回退到分块整段生成，但此时文本缓存中已经保存了“所有文本片段一次性批处理编码”的文本嵌入。流式生成则逐条文本片段编码。因此，两条路径在数学上使用相同文本，但工程上使用了不同批处理形态的 T5 前向结果。前一节图 4-5 已经给出短原语分支的两组三路关键帧对比；本节后续重点转向 LDF 主模型的流式一致性、文本编码路径和消融指标。

表 4-4 总结了代表性样本 train_000031 的实验结果。默认 bf16 路径下，流式和显存不足分块回退生成的 57 维动作特征平均绝对差为 0.1237；将 T5 放到中央处理器（Central Processing Unit, CPU）并使用 float32 编码后，平均差降至 0.0571，但仍不完全一致；将 T5 放到 CPU 并使用 float64 编码、再按模型原逻辑转换回 float32 后，两条路径的动作特征和连续潜变量完全一致。这里的 float32 和 float64 分别表示 32 位和 64 位浮点格式。

图 4-7 给出 CPU float32 路径下流式生成和整段回退生成的逐帧动作特征差异。曲线显示误差会在长片段内部逐步累积，并且根节点相关维度和关节角维度都可能贡献最终差异。该实验说明，同一句文本在不同批处理形态下产生的微小文本嵌入差异会被 LDF 的递推生成过程放大。工程上更实际的方案不是部署时一味使用 float64，而是固定文本编码路径：离线数据可缓存文本嵌入，在线输入则使用固定批大小或固

表 4-4 T5 文本编码精度对流式和显存不足回退一致性的影响

设置	特征均值	特征最大值	潜变量均值	潜变量最大值
GPU bf16 默认路径	0.1237	6.3025	0.4811	3.8759
CPU float32 编码	0.0571	6.2744	0.2458	2.4457
CPU float64 编码后转 float32	0.0000	0.0000	0.0000	0.0000

定推理后端。




图 4-7 样本 train_000031 的流式生成与整段回退生成逐帧动作特征差异

对 train_000031 的文本切换分析显示，动作差异并不总是在文本切换边界处最大。该样本包含 tpose、transition、wipe off hands、kneel on one knee、stand up 等多个文本片段。实验统计发现，部分长片段内部的平均潜变量误差高于切换边界附近误差。这表明误差更像是在生成过程中逐步积累和放大，而不只是由文本切换瞬间触发。

图 4-8 统计了生成动作的根节点高度、累计偏航角和相邻帧动作变化。该图反映出生成动作在下蹲、起立等片段中具有明显高度变化，同时也暴露出偏航角累积和局部速度在长序列中存在突变风险。此类曲线适合作为跟踪器接入前的筛查工具：若某条轨迹在运动学诊断阶段已经出现异常高度、过大偏航角跳变或关节变化尖峰，就不应直接进入物理跟踪训练。




图 4-8 样本 train_000031 的生成动作运动学诊断曲线

4.5 定量消融实验

本节按统一指标整理 VAE 维度、LDF 配置、CFG 引导、短原语引导系数、T5 编码路径和文本边界相关实验。对于 LDF 主模型，本文使用离线生成结果与对应参考动作逐样本对齐，统一计算特征平均绝对误差 (Mean Absolute Error, MAE)、关节角 MAE、根节点平面终点误差、偏航角终点误差和平滑度。设生成特征为 $\hat{x}_{1:T}$ ，参考特征为 $x_{1:T}$ ，则特征误差定义为：

$$E_{\text{feat}} = \frac{1}{TD} \sum_{t=1}^T \sum_{d=1}^D |\hat{x}_{t,d} - x_{t,d}|, \quad (4-1)$$

其中 $D = 57$ 。关节误差只在 23 维关节角子向量上计算；根节点平面终点误差由 57 维特征恢复出的根节点轨迹末帧 (x, y) 距离给出；平滑度为相邻帧 57 维特征平均绝对变化。所有带 $\pm$ 的 LDF 结果均为 18 条统一离线样本上的均值和 95% 置信区间。

从表 4-5 可以看出，VAE 的潜变量维度从 4 增加到 128 时，总 KL 持续增大，但每维 KL 逐步下降，说明动作信息被分摊到更多维度中；同时 $z = 128$ 长训版本出现 121/128 的活跃维度，提示高维潜空间并不必然更稳。表 4-6 进一步说明，在本文离线生成结果中，块长 50 的配置整体优于块长 125 的配置： $z = 32$ 、块长 50 在特征误

表 4-5 VAE 潜变量维度消融结果

设置	步数	样本数	潜变量步数	活跃维度	总 KL	每维 KL
$z = 4$	110k	500	19266	4/4	27.6	6.89
$z = 8$	110k	500	19266	8/8	52.7	6.59
$z = 16$	110k	500	19266	16/16	102.5	6.41
$z = 32$	190k	500	19266	32/32	203.8	6.37
$z = 64$	450k	500	19266	64/64	382.5	5.98
$z = 128$	240k	500	19266	128/128	770.4	6.02
$z = 128$	460k	500	19266	121/128	657.3	5.14

表 4-6 LDF 潜变量维度与训练块长度消融结果

配置	样本数	特征 MAE↓	关节 MAE↓	根平面误差 ↓	偏航角误差 ↓	平滑度 ↓
$z = 32$, 块长 125, 随机块关	18	0.143 ± 0.019	0.300 ± 0.041	0.882 ± 0.401	1.954 ± 1.153	0.007 ± 0.003
$z = 64$, 块长 125, 随机块关	18	0.139 ± 0.018	0.278 ± 0.038	2.515 ± 1.877	2.563 ± 1.223	0.010 ± 0.004
$z = 128$, 块长 125, 随机块关	18	0.118 ± 0.017	0.236 ± 0.035	0.932 ± 0.429	3.461 ± 1.987	0.007 ± 0.004
$z = 32$, 块长 125, 随机块开	18	0.170 ± 0.028	0.338 ± 0.060	1.099 ± 0.435	3.167 ± 1.624	0.010 ± 0.003
$z = 64$, 块长 125, 随机块开	18	0.152 ± 0.027	0.319 ± 0.069	0.795 ± 0.488	1.749 ± 1.366	0.008 ± 0.004
$z = 128$, 块长 125, 随机块开	18	0.176 ± 0.038	0.361 ± 0.078	1.029 ± 0.487	4.856 ± 2.820	0.011 ± 0.004
$z = 32$, 块长 50, 随机块关	18	0.112 ± 0.015	0.225 ± 0.034	0.896 ± 0.551	1.302 ± 0.931	0.009 ± 0.003
$z = 64$, 块长 50, 随机块关	18	0.119 ± 0.019	0.236 ± 0.038	0.565 ± 0.295	0.743 ± 0.689	0.007 ± 0.003
$z = 128$, 块长 50, 随机块关	18	0.119 ± 0.018	0.227 ± 0.033	0.586 ± 0.320	1.586 ± 1.071	0.009 ± 0.004

注：表中为 18 条统一离线样本的均值与 95% 置信区间。根平面误差和偏航角误差均在每条序列末帧计算；平滑度为相邻帧 57 维特征平均绝对变化。

表 4-7 LDF 主模型无分类器引导系数消融结果

引导系数	样本数	特征 MAE↓	关节 MAE↓	根平面误差 ↓	偏航角误差 ↓	平滑度 ↓
$s = 1$	18	0.120 ± 0.015	0.241 ± 0.035	1.164 ± 0.649	2.740 ± 1.854	0.006 ± 0.003
$s = 3$	18	0.121 ± 0.015	0.245 ± 0.034	1.448 ± 1.103	5.324 ± 3.742	0.007 ± 0.003
$s = 5$	18	0.125 ± 0.017	0.252 ± 0.034	1.819 ± 1.607	9.059 ± 10.720	0.008 ± 0.003
$s = 7.5$	18	0.136 ± 0.014	0.273 ± 0.032	2.575 ± 1.386	9.382 ± 5.915	0.009 ± 0.004

注：无分类器引导 (Classifier-Free Guidance, CFG) 用于调节文本条件强度。表中四组结果由同一组模型参数、同一样本池、同一随机种子和同一推理入口重新生成，用于比较引导系数的组内影响；该表不代表跟踪器或真机指标。

表 4-8 短原语生成目标与引导系数消融结果

方法	引导系数	非自回归总损失↓	自回归总损失↓	自回归重构↓	偏航角漂移↓	平面漂移↓
扩散模型	1	0.4089	1.0080	0.3168	0.0139	0.000626
扩散模型	2	0.4491	1.0434	0.3411	0.0149	0.000765
扩散模型	3	0.5001	1.0896	0.3707	0.0161	0.000879
扩散模型	4	0.5525	1.1363	0.4012	0.0188	0.000962
扩散模型	5	0.6014	1.1735	0.4253	0.0182	0.001036
流匹配	1	0.5198	1.0371	0.3352	0.0137	0.000733
流匹配	2	0.5496	1.0809	0.3657	0.0154	0.000793
流匹配	3	0.5894	1.1304	0.3969	0.0160	0.000909
流匹配	4	0.6340	1.1791	0.4262	0.0182	0.001015
流匹配	5	0.6799	1.2303	0.4573	0.0193	0.001137

表 4-9 T5 文本编码数值路径消融结果

设置	特征均值↓	特征最大值↓	连续潜变量均值↓	连续潜变量最大值↓
GPU bf16 默认路径	0.1237	6.3025	0.4811	3.8759
CPU float32 编码	0.0571	6.2744	0.2458	2.4457
CPU float64 编码后转 float32	0.0000	0.0000	0.0000	0.0000

表 4-10 train_000031 文本边界窗口消融结果

窗口宽度	连续潜变量近边界均值	连续潜变量远边界均值	帧近边界均值	帧远边界均值
0	0.3446	0.4834	0.1029	0.1238
4	0.3174	0.5048	0.1018	0.1245
8	0.2964	0.5325	0.0972	0.1254

差和关节误差上最低, $z = 64$ 、块长 50 在根节点平面终点误差和偏航角终点误差上最低。随机块上限打开后没有在该小规模样本池中稳定带来收益, 说明该设置仍需要更长训练或更大的验证样本池来判断。

表 4-7 将 CFG 作为主模型实验项, 并在同一 18 条离线样本池上补充 $s = 1, 3, 5, 7.5$ 的可复核结果。该批结果中 $s = 1$ 的特征 MAE 和关节 MAE 最低, 分别为 0.120 ± 0.015 与 0.241 ± 0.035 ; 随着引导系数增大, 根节点平面终点误差、偏航角终点误差和平滑度指标整体变差, 说明较强条件放大虽然可能增强语义响应, 但也会放大长序列漂移和局部抖动。因此, 本文不把更大的 s 解释为必然更优, 而将默认 $s = 5$ 视为可视化语义响应与离线误差之间的折中配置。表 4-9 则确认文本编码路径是流式一致性的关键因素: CPU float64 编码后再转回 float32 可以使保存的特征和连续潜变量完全一致。表 4-10 显示远离文本边界的误差均值反而高于边界附近, 支持“长片段内部累积”而非“切换帧瞬时冲击”的分析。

4.6 MuJoCo 可视化验证

本文实现了基础回放、整段对比、流式回放和统一对比四类 MuJoCo 可视化脚本, 用于将 57 维动作特征重构为 MuJoCo 中的 G1 机器人姿态, 并进行整段与流式结果并排对比。该工具链从原始动作数据、动作特征文件或生成结果中加载动作, 将偏航角增量、局部位移、根节点高度和关节角恢复为广义坐标 (qpos) 序列, 支持单机器人播放和双机器人偏移对比播放, 并在 FlashAttention 不可用时自动回退到 PyTorch SDPA 注意力实现。

图 4-9 展示了同一生成样本在 MuJoCo 中的关键帧。该样本覆盖站立、下蹲、擦手、起立等连续文本片段, 可以观察生成动作是否在大体语义和姿态变化上与文本相符。图中进一步用圆圈和箭头标注了手臂语义动作、支撑接触、根节点高度变化和转向漂移检查点。该图说明系统已经把 57 维动作特征重构为 G1 机器人姿态并完成运动学回放, 同时也提醒该结果仍属于运动学层面的检查。

图 4-10 按片段分块展示同一样本在流式生成和整段回退生成下的姿态差异。每个片段块中, 上行是流式生成结果, 下行是整段回退结果; 列方向表示该片段内不同时间偏移。二者在早期姿态接近, 但随着递推推进和文本片段变长, 手臂、躯干和下蹲姿态逐渐出现可见差异。这与前文逐帧动作特征误差曲线相互印证, 说明数值路径差异不是抽象日志问题, 而会在最终机器人动作中形成可观察偏差。

需要指出的是, MuJoCo 回放在本文实验中主要用于运动学检查, 即观察生成动




图 4-9 生成动作在 MuJoCo 中的 G1 机器人运动学回放关键帧与标注检查点

作是否语义相关、是否平滑、是否存在明显偏航角漂移或关节异常。它不等价于低层控制器已经能够稳定跟踪。若要证明动作物理可执行，还需要将生成轨迹输入 Isaac Lab 跟踪器，在接触和动力学约束下评估跟踪误差、跌倒率、脚滑和关节限位等指标。




图 4-10 流式生成与整段回退生成结果的 MuJoCo 分块关键帧对比

4.7 跟踪器训练结果与物理评价协议

为了从“看起来能动”走向“可定量比较”，本文将评价指标分为生成质量、时序稳定性和物理可执行性三类。其中物理可执行性部分由完成训练的 G1 跟踪器、策略参数保存、ONNX 导出和 Isaac Lab 回放流程支撑。

4.7.1 训练配置与策略结果

低层跟踪器采用 RSL-RL PPO 训练，训练完成后保存策略参数。该策略可由 Isaac Lab 评估脚本加载，并可导出为 ONNX 文件用于接口检查。这些训练结果使本文的低层控制部分不仅停留在接口设计，而是具备可加载、可导出和可回放的仿真策略。

训练配置方面，G1 平地跟踪任务使用 24 步回放片段、经验归一化、指数线性单元（Exponential Linear Unit, ELU）激活、裁剪系数 0.2、熵系数 0.005、 $\gamma = 0.99$ 、 $\lambda = 0.95$ 和自适应学习率。训练配置为 16,384 个并行环境、最大 1,000,000 次迭代、未来参考步数 5、骨盆身体锚点、自适应动作采样，以及 [2048, 1024, 512] 的策略网络/价值网络隐藏层。机器人身体跟踪集合包含骨盆、腿部、躯干、肩肘腕等节点；观测包含生成运动命令、未来身体锚点位姿、投影重力、基座速度、关节状态和上一动作。表 4-11 汇总了主要训练设置。

表 4-11 G1 仿真跟踪器主要训练配置

配置项	设置
任务类型	G1 平地参考动作跟踪
强化学习算法	PPO, RSL-RL 训练器, 经验归一化
并行环境与迭代	16,384 个环境, 最大 1,000,000 次迭代
回放片段与折扣	每轮采样 24 步, $\gamma = 0.99$, $\lambda = 0.95$
更新约束	裁剪系数 0.2, 熵系数 0.005, 自适应学习率
策略网络	MNMLP actor-critic, 隐藏层 [2048, 1024, 512], ELU 激活
参考窗口	未来参考步数为 5, 骨盆身体锚点, 自适应动作采样
训练结果	策略参数、ONNX 导出模型与配套配置

4.7.2 仿真回放、ONNX 导出与关键帧结果

Isaac Lab 回放流程使用同一任务配置加载训练后的策略参数，指定待跟踪动作、骨盆身体锚点、未来参考步数 5、[2048, 1024, 512] 网络结构和少量并行环境。MuJoCo 跨仿真检查以同一参考轨迹为输入，并读取 ONNX 导出策略。本文保留这些相对配置元素和结果类型，便于在不同运行环境下复现实验链路。

图 4-11 给出四条代表性参考动作在仿真跟踪器中的关键帧回放。每条样本包含参考轨迹和训练后 PPO 跟踪策略两行，五列分别对应该段动作的 0%、25%、50%、75% 和 100% 进度，便于直接观察策略是否跟随目标步态、躯干姿态、摆臂和踢腿等变化。关键帧结果说明低层跟踪器已经进入实验链路：VAE 重构动作和生成模型动作都可以通过同一特征-qpos 重构层转为跟踪器参考命令，再按相同回放流程进行物理可跟踪性检查。




图 4-11 G1 仿真跟踪器四组参考轨迹与策略跟踪关键帧对比

除关键帧可视化外，本文进一步在固定样本池上计算跟踪器定量指标。样本池由七段验证动作拼接而成，覆盖转向、行走、跑步、跳跃、挥手、抬臂、手臂舞蹈和拾放物体等动作类型；每段参考轨迹在进入跟踪器时单独初始化，以避免片段拼接处

的根节点位置和朝向突变被误判为跟踪失败。表 4-12 汇总训练与回放链路，表 4-13 单独报告跟踪器自身在真实/VAE 参考轨迹上的能力上限，表 4-14 则按照物理评价协议比较上层生成输出接入后的误差变化。

表 4-12 G1 仿真跟踪器训练结果与回放结果

项目	本文完成情况	实验意义
策略参数 ONNX 导出	PPO 跟踪器策略参数已保存 ONNX 策略文件已导出	已训练 PPO 跟踪器可加载回放 支持策略接口检查和后续部署准备
Isaac Lab 回放 MuJoCo/仿真接口 生成动作接入	使用 G1 跟踪任务和未来参考步数 5 motion.npz 与 ONNX 策略接口对齐 真实重定向、VAE 重构和上层生成轨迹共用同一协议	在物理仿真中跟踪参考轨迹 检查参考轨迹与策略输入格式 将高层生成误差传递到物理评价层
物理指标记录	跟踪误差、早停、脚滑、接触、限位和控制量	支撑生成动作可跟踪性分析

表 4-13 跟踪器自身在参考轨迹上的定量跟踪能力

参考来源	成功率 (%)	早停率 (%)	身体关键点 RMSE(m)	关节 MAE(rad)	动作变化率 (rad/帧)
原始重定向参考	100.0	0.0	0.125	0.072	0.014
VAE 重构参考	100.0	0.0	0.117	0.073	0.014

表 4-13 用原始重定向参考和 VAE 重构参考评价跟踪器自身的跟踪能力。两类参考均达到 100% 成功率和 0% 早停率，身体关键点 RMSE 分别为 0.125 m 和 0.117 m，关节 MAE 约为 0.072–0.073 rad。这说明本文训练的低层策略并不是只能播放单一姿态，而是能够在包含转向、行走、跑跳和上肢动作的固定样本池上稳定跟踪参考轨迹；同时，VAE 重构参考与原始重定向参考的跟踪误差接近，说明连续潜变量重构没有显著破坏低层可跟踪性。

表 4-14 与本文物理评价协议逐项对应。整体稳定性由稳定完成率和早停率衡量；身体锚点误差由根节点平面 RMSE 和根节点高度 MAE 衡量；身体关键点误差使用 pelvis、腿部、躯干、肩肘腕等节点的平均空间 RMSE；关节跟踪由关节角 MAE 和关节速度 MAE 衡量；足端接触用低位足端速度近似反映脚滑；限位与控制代价由关节限位率和动作变化率刻画。三类输入使用同一特征-qpos 重构层、同一统计量、同一未来身体锚点窗口和同一跟踪器策略，因此可以直接比较高层生成误差传递到物理控制层后的影响。

表 4-14 上层生成输出接入跟踪器后的物理评价协议指标

指标类别	指标	原始重定向	VAE 重构	上层生成
整体稳定性	稳定完成率 (%)	100.0	100.0	100.0
整体稳定性	早停率 (%)	0.0	0.0	0.0
身体锚点	根节点平面 RMSE(m)	0.114	0.105	0.347
身体锚点	根节点高度 MAE(m)	0.017	0.016	0.023
身体关键点	身体关键点 RMSE(m)	0.125	0.117	0.358
关节跟踪	关节角 MAE(rad)	0.072	0.073	0.091
关节跟踪	关节速度 MAE(rad/s)	0.40	0.42	0.68
足端接触	低位足端速度 (m/s)	0.201	0.198	0.322
限位与控制	关节限位率 (%)	0.27	0.28	0.20
限位与控制	动作变化率 (rad/帧)	0.014	0.014	0.018

从表 4-14 可以看到，上层生成参考同样完成全部七段回放，说明生成动作已经能够接入低层跟踪器并维持基本稳定；但其身体关键点 RMSE 从原始重定向参考的 0.125 m 和 VAE 重构参考的 0.117 m 增至 0.358 m，根节点平面 RMSE 增至 0.347 m，关节速度 MAE 增至 0.68 rad/s，低位足端速度也从约 0.20 m/s 增至 0.322 m/s。该结果说明，上层生成模型输出并非只在运动学回放中可播放，而是已经进入物理跟踪评价；同时，生成模型在根节点轨迹、身体关键点和足端接触上的误差仍明显高于参考/VAE 轨迹，这正是后续用跟踪器物理反馈优化生成模型的依据。

本文把跟踪器结果解释为三层。第一层是策略结果：策略参数、ONNX 导出模型和参数配置已经形成可复用低层策略。第二层是参考轨迹质量：真实动作、VAE 重构动作和 LDF 生成动作在同一跟踪器下的误差差异。第三层是生成模型优化：若 LDF 生成动作的失败集中在偏航角漂移、关节越界或接触不一致上，应优先回到高层表示和生成配置修正，而不是直接把跟踪器重新训练成掩盖生成缺陷的控制器。

生成质量指标关注文本和动作是否对齐。对于 HumanML3D 等标准数据集，常见指标包括 FID、diversity、R-precision 和 multimodal distance^[9]。机器人数据尚缺少直接可用的文本到机器人动作评价器，因此本文先采用两类替代指标：其一，在 VAE 潜空间中计算生成连续潜变量与真实连续潜变量的分布距离；其二，使用文本嵌入和动作潜变量池化建立轻量检索指标，判断生成动作是否更接近对应文本而非其他文本。

时序稳定性指标关注动作自身是否连续。可统计相邻帧关节角差分、关节角二阶差分、根节点偏航角累积漂移、根节点平移累积误差和脚部接触状态变化频率。对于流式生成，还应单独统计文本切换边界附近和长片段内部的误差，以区分“切换不平

滑”和“长时漂移”两类问题。

物理可执行性指标在跟踪器回放后统计。核心指标包括跟踪成功率、回放片段早停率、根节点位置误差、身体关键点位置误差、关节角误差、脚滑速度、接触力峰值、关节限位违规率和力矩饱和比例。本文使用这些指标解释生成动作在物理约束下的可跟踪性：成功率和早停率反映整体稳定性，根节点和身体关键点误差反映参考轨迹跟随质量，脚滑和接触指标反映足端支撑是否可信，关节限位和力矩饱和则反映安全裕度。其中，脚部接触状态不仅影响脚滑统计，也影响支撑相判断和控制切换；这与足式机器人触地检测研究中强调的接触信息作用一致^[48]。同时，关节限位、力矩饱和和异常接触也属于机器人安全性评价的一部分^[49]。

奖励项如表 4-15 所示，终止条件和课程采样机制如表 4-16 所示。本文将其作为物理评价协议的一部分：若生成动作在 MuJoCo 中可播放但在跟踪器中出现跌倒、脚滑或关节限位违规，则应回到 57 维表示、VAE 连续潜变量和 LDF 生成结果逐层排查，而不是将失败简单归因于低层控制器。表 4-17 给出本文固定记录的实验表头；该表把整体稳定性、局部跟踪误差、足端接触和控制代价统一到同一记录格式中。

表 4-15 仿真跟踪策略主要奖励项

奖励项	作用	权重
全局身体锚点位置跟踪	跟踪根节点或身体锚点位置	0.5
全局身体锚点姿态跟踪	跟踪根节点或身体锚点姿态	0.5
身体关键点位置跟踪	跟踪身体关键点位置	1.0
身体关键点姿态跟踪	跟踪身体关键点姿态	1.0
身体线速度跟踪	跟踪身体线速度	1.0
身体角速度跟踪	跟踪身体角速度	1.0
动作变化率惩罚	平滑关节动作	-0.1
关节限位惩罚	避免关节越界	-10.0
非期望接触惩罚	惩罚非脚部等异常接触	-0.1
脚滑惩罚	惩罚脚接触时水平滑动	-0.1
超速/超力矩惩罚	惩罚关节速度和力矩异常	-0.1

4.8 实验限制与本章小结

综合上述实验结果与系统分析，本文系统仍有进一步完善空间。生成质量方面，部分动作存在语义对齐不足、偏航角漂移和长序列误差累积，复杂文本切换后更明显；VAE 维度选择方面，现有分析显示 $z = 64$ 可能具有更合适的容量，但最终仍需

表 4-16 仿真跟踪器终止条件与课程采样机制

类别	内容	作用
超时终止	回合达到设定时长后结束	固定时长
身体锚点高度误差	骨盆或根节点高度偏离参考过大	跌倒筛查
身体锚点姿态误差	根节点姿态或投影方向与参考差异过大	姿态筛查
末端身体高度偏差	腿部、脚部或上肢关键身体高度异常	接触筛查
自适应采样	失败率较高的动作片段获得更高采样概率，同时保留均匀采样	课程机制

表 4-17 生成动作进入跟踪器后的物理指标记录模板

指标	记录方式	分析作用
跟踪成功率/早停率	回合是否完成、是否触发终止	衡量整体稳定性
身体锚点位置/姿态误差	命令指标中的身体锚点误差均值和峰值	衡量根节点跟随质量
身体关键点误差	pelvis、腿部、躯干、肩肘腕等节点的位置/姿态误差	衡量全身姿态一致性
关节角/关节速度误差	参考关节状态与实际关节状态差异	衡量局部动作跟踪质量
脚滑与接触异常	接触时脚部水平速度、非期望接触、落地冲击	衡量足端支撑可信度
限位与控制代价	关节限位、速度超限、力矩超限、动作变化率	衡量安全裕度和控制平滑性

以 LDF 生成质量和跟踪器可跟踪性作为准则；流式一致性方面，训练、整段推理和流式推理中的 T5 批处理形态应固定，否则微小数值差异可能被递推放大。MuJoCo 验证仍偏运动学，跟踪器回放能够补充物理约束下的跟踪误差、跌倒率、脚滑速度、接触力和关节越界率等评价维度。

本文尚未开展系统性的真实 G1 机器人实验，主要原因有三点。首先，毕业设计周期内需要同时完成高层动作生成、仿真跟踪器训练、消融分析和论文整理，作者还同时承担提前选修博士阶段课程和其他科研项目，连续真机调试时间有限。其次，真实 G1 平台由多个课题组共享，可预约的连续调试时段较紧张，而人形机器人上机需要预留充分的安全检查和现场保护时间。最后，真机部署还要求推理延迟、通信链路、控制频率匹配、ONNX 导出、关节限幅和急停保护全部经过验证；在这些准备尚未充分完成前，直接开展开放文本真机实验存在较高风险。因此，本文将真机实验作为后续工作，在仿真跟踪稳定后逐步推进。

本章作为实验章节，统一介绍了实验设置、VAE 隐空间分析、流匹配结果、LDF

消融、流式一致性、MuJoCo 可视化和跟踪器训练结果。实验表明，本文系统已经形成文本到 G1 机器人动作的可运行链路，完成了 G1 仿真跟踪器训练、ONNX 导出、仿真回放入口和物理指标组织方式。后续若采用 RL 后训练动作生成器，应以本章定义的固定样本池和物理指标为奖励或筛选依据，使高层生成模型直接受低层跟踪器的物理反馈约束。

第五章 全文总结

5.1 主要结论

本文围绕 Any-Text-to-Humanoid-Action 工程中的“基于自然语言指令的人形机器人规划控制方法研究”展开，目标是建立从自然语言文本到人形机器人动作，再到仿真物理跟踪的技术链路。按照本文研究边界，本文重点完成了高层动作生成系统，并基于 G1 仿真跟踪器、ONNX 导出和 Isaac Lab/RSL-RL 配置完成了低层仿真跟踪评估链路。主要结论如下：

1. 本文完成了面向 G1 机器人的 57 维局部动作表示设计。该表示将根节点姿态、根节点位移、脚部接触、关节角和关节角增量统一到生成模型可学习的特征空间中，并通过局部坐标和三角化角度表示减小了全局坐标和角度周期性带来的学习困难。
2. 本文完成了机器人动作变分自编码器 (VAE) 训练和连续潜变量预计算流程，将 50 Hz 的 57 维动作序列压缩为 12.5 Hz 的连续潜变量。隐空间分析表明，机器人动作潜空间维度存在重构质量和下游 LDF 可学习性之间的权衡： $z = 128$ 重构能力较强，但长训可能出现部分维度塌缩； $z = 64$ 在维度活跃性上更稳定，是后续实验的重要候选。
3. 本文在统一的 Any-Text-to-Humanoid-Action 工程中实现了流匹配版本高层生成器，将原有扩散采样替换为速度场预测和常微分方程求解，为降低动作生成推理开销提供了可运行探索。
4. 本文参考 FloodDiffusion 构建了机器人版本潜空间扩散强制 (Latent Diffusion Forcing, LDF) 模型，完成 LDF 训练、整段推理、流式推理和 MuJoCo 可视化。系统能够根据分段文本描述生成 G1 机器人动作特征。
5. 本文定位了流式生成与整段显存不足分块回退生成不一致的一个关键来源：冻结 T5 (Text-to-Text Transfer Transformer) 文本编码器在不同批处理形态和数值精度下产生的微小文本嵌入差异会被 LDF 的递推生成过程放大。实验表明，固定文本编码路径或提高编码精度可以显著减小该误差。
6. 本文完成了 G1 仿真物理跟踪策略训练与接入，包括 Isaac Lab 环境、RSL-RL 强化学习框架、近端策略优化 (PPO) 与 MNMLP 策略结构、策略参数保存、ONNX 导出、观测、奖励、终止条件和未来参考窗口设置，为在物理约束下评

价生成动作可跟踪性提供了已训练仿真跟踪器。

总体来看,本文实现了从自然语言到机器人动作特征的主要生成链路,并建立了可视化和误差分析工具。本文系统尚未覆盖完整真机部署,但已经为“语言指令驱动人形机器人动作生成与仿真执行”提供了可复现的工程基础。

本文工作的价值主要体现在三个方面。首先,本文没有停留在文本到人体动画生成的通用问题上,而是围绕 G1 人形机器人重新定义了动作表示和 VAE 连续潜变量接口,使生成结果能够进一步连接 MuJoCo 回放和 Isaac Lab 跟踪控制。其次,本文在同一工程中保留了流匹配探索模块和 LDF 主模型作为前后衔接的高层生成路线:早期流匹配探索验证速度场生成替代扩散采样的可行性, LDF 主模型进一步面向长序列流式生成和时变文本条件问题。最后,本文在工程调试中发现并分析了文本编码数值路径对流式生成的影响,说明系统误差不仅来自模型结构,也可能来自精度、缓存和批处理形态等实现细节。

系统仍需进一步完善。高层生成模型仍有语义不稳定、偏航角漂移和长片段误差累积现象;仿真跟踪器已完成策略训练、ONNX 导出和固定样本池物理指标评价,但评价规模仍可继续扩大到更多动作类型、更多生成配置和更长时序样本;真实机器人部署尚未开展。因此,本文结论应理解为“完成自然语言到机器人动作生成与仿真跟踪器评估链路的主要工程基础”,而不是“开放文本到真机动作稳定控制已经完成”。这一范围划分有助于后续继续推进项目。

5.2 研究展望

后续工作可以从以下几个方向继续推进:

1. 扩展跟踪器物理指标评估。将更多 LDF 生成的 57 维动作特征转化为跟踪器参考命令,基于本文已训练策略或继续微调策略,在 Isaac Lab 中统计跟踪误差、跌倒率、脚滑速度、接触力和关节限位违规率。
2. 以物理可跟踪性反向筛选生成模型。仅靠运动学可视化难以判断动作质量,后续应将跟踪器跟踪成功率作为生成模型选择指标,比较不同 VAE 维度、引导系数、训练块长度和随机裁剪策略。
3. 统一文本编码缓存。后续可将训练数据中的文本片段离线编码为固定格式文本嵌入,训练和推理共享该缓存;在线交互时则强制单句编码或使用确定性批处理策略,避免批处理形态造成隐藏数值差异。
4. 改进长时序稳定性。可引入更长训练窗口、随机块裁剪、误差反馈训练、动作

- 平滑损失和接触一致性损失，减轻偏航角、根节点位移和关节角误差累积。
5. 探索生成模型与物理反馈结合。后续可对动作生成器进行强化学习（Reinforcement Learning, RL）后训练：借鉴物理反馈对齐大模型或 PARC 类自增强思路，将跟踪器的跟踪误差、脚滑、跌倒和接触质量作为奖励或筛选信号反馈给高层生成模型，使生成动作更容易被物理系统执行。该方向属于后续优化，不作为本文已完成结果。
 6. 推进真实机器人部署。本文尚未开展系统性真机实验，主要受毕业设计周期、作者同步课程与其他科研任务、G1 平台多组共享和连续调试资源有限等因素影响；同时，真实机器人实验需要先完成推理延迟压缩、控制频率适配、通信链路测试、安全限幅和急停保护。后续应在仿真跟踪稳定后，按“固定短动作样本、受限速度、人工保护、逐步放开文本复杂度”的顺序开展真实 G1 机器人实验。

本文工作的核心经验是：自然语言到人形机器人动作并不是单一生成模型问题，而是跨模态生成、机器人动作表示、数值一致性、物理跟踪和部署工程共同作用的系统问题。后续研究需要以生成质量和物理可执行性两个指标共同驱动模型迭代。

后续研究应优先扩展稳定的仿真闭环，而不是直接扩大自然语言输入复杂度。具体而言，可固定少量代表性文本样本，生成对应 57 维动作，经过动作安全检查器筛查后输入本文已训练或继续微调的跟踪器，并用统一指标记录跟踪效果。只有当短片段和中等长度片段在物理仿真中稳定后，再继续扩大文本覆盖和动作复杂度。这样的迭代顺序更符合机器人系统开发规律，也能避免把生成模型的视觉效果误认为物理可执行性。

总之，本文围绕“自然语言指令到人形机器人规划控制”完成了一套以动作生成为核心、以仿真跟踪为约束方向的系统设计与实现。该系统仍需要进一步实验完善，但已经明确了数据表示、生成模型、流式推理、数值一致性和本文训练的物理跟踪器之间的关键关系，为后续仿真验证和继续研究提供了较完整的基础。

参 考 文 献

- [1] 王田苗, 陶永, 陈阳. 服务机器人技术研究现状与发展趋势[J/OL]. 中国科学: 信息科学, 2012, 42(9): 1049-1066 [2026-05-07]. <https://www.sciengine.com/doi/10.1360/112012-402>. DOI: 10.1360/112012-402.
- [2] 陶永, 刘海涛, 王田苗, 等. 我国服务机器人技术研究进展与产业化发展趋势[J/OL]. 机械工程学报, 2022, 58(18): 56-74 [2026-05-07]. <https://qikan.cmes.org/jxgcxb/CN/10.3901/JME.2022.18.056>. DOI: 10.3901/JME.2022.18.056.
- [3] 颜云辉, 徐靖, 陆志国, 等. 仿人服务机器人发展与研究现状[J/OL]. 机器人, 2017, 39(4): 551-564 [2026-05-07]. <https://robot.sia.cn/article/doi/10.13973/j.cnki.robot.2017.0551>. DOI: 10.13973/j.cnki.robot.2017.0551.
- [4] 刘阳, 柏永杰, 林惊. 面向人机物高效融合与协作的具身智能技术体系[J/OL]. 机器人, 2025, 47(4): 559-580 [2026-05-07]. <https://robot.sia.cn/article/doi/10.13973/j.cnki.robot.250191>. DOI: 10.13973/j.cnki.robot.250191.
- [5] 蔡自兴, 谢斌. 机器人学[M/OL]. 4 版. 北京: 清华大学出版社, 2022 [2026-05-07]. https://www.tup.tsinghua.edu.cn/booksCenter/book_09042901.html.
- [6] LAVALLE S M. Planning Algorithms[M/OL]. Cambridge: Cambridge University Press, 2006 [2026-05-07]. <http://lavalle.pl/planning/>.
- [7] 唐永兴, 朱战霞, 张红文, 等. 机器人运动规划方法综述[J/OL]. 航空学报, 2023, 44(2): 26495 [2026-05-07]. <https://hkxb.buaa.edu.cn/CN/10.7527/S1000-6893.2021.26495>. DOI: 10.7527/S1000-6893.2021.26495.
- [8] 林韩熙, 向丹, 欧阳剑, 等. 移动机器人路径规划算法的研究综述[J/OL]. 计算机工程与应用, 2021, 57(18): 38-48 [2026-05-07]. <https://opaj.napstic.cn/periodicalArticle/0120211000626092>. DOI: 10.3778/j.issn.1002-8331.2103-0519.
- [9] GUO C, ZOU S, ZUO X, et al. Generating Diverse and Natural 3D Human Motions from Text [C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 5152-5161 [2026-05-07]. https://openaccess.thecvf.com/content/CVPR2022/html/Guo_Generating_Diverse_and_Natural_3D_Human_Motions_From_Text_CVPR_2022_paper.html.
- [10] TEVET G, RAAB S, GORDON B, et al. Human Motion Diffusion Model[EB/OL]. 2022 [2026-05-07]. <https://arxiv.org/abs/2209.14916>. arXiv: 2209.14916 [cs.CV].
- [11] XIE W, ZHENG J, HAN J, et al. TextOp: Real-time Interactive Text-Driven Humanoid Robot Motion Generation and Control[EB/OL]. 2026 [2026-05-08]. <https://arxiv.org/abs/2602.07439>. arXiv: 2602.07439 [cs.RO].
- [12] CAI Y, WU Y, LI K, et al. FloodDiffusion: Tailored Diffusion Forcing for Streaming Motion

- Generation[EB/OL]. 2025 [2026-05-07]. <https://arxiv.org/abs/2512.03520>. arXiv: 2512.03520 [cs.CV].
- [13] PLAPPERT M, MANDERY C, ASFOUR T. The KIT Motion-Language Dataset[J/OL]. Big Data, 2016, 4(4): 236-252 [2026-05-07]. <https://doi.org/10.1089/big.2016.0028>. DOI: 10.1089/big.2016.0028.
- [14] AHUJA C, MORENCY L P. Language2Pose: Natural Language Grounded Pose Forecasting [C/OL]//2019 International Conference on 3D Vision. 2019: 719-728 [2026-05-07]. <https://arxiv.org/abs/1907.01108>. DOI: 10.1109/3DV.2019.00084.
- [15] PUNNAKKAL A, CHANDRASEKARAN A, ATHANASIOU N, et al. BABEL: Bodies, Action and Behavior with English Labels[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 722-731 [2026-05-07]. https://openaccess.thecvf.com/content/CVPR2021/html/Punnakkal_BABEL_Bodies_Action_and_Behavior_With_English_Labels_CVPR_2021_paper.html.
- [16] MAHMOOD N, GHORBANI N, TROJE N F, et al. AMASS: Archive of Motion Capture as Surface Shapes[C/OL]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 5442-5451 [2026-05-07]. https://openaccess.thecvf.com/content_ICCV_2019/html/Mahmood_AMASS_Archive_of_Motion_Capture_As_Surface_Shapes_ICCV_2019_paper.html.
- [17] PETROVICH M, BLACK M J, VAROL G. TEMOS: Generating Diverse Human Motions from Textual Descriptions[C/OL]//Computer Vision – ECCV 2022. Springer, 2022: 480-497 [2026-05-07]. <https://arxiv.org/abs/2204.14109>. DOI: 10.1007/978-3-031-20047-2_28.
- [18] ZHANG M, CAI Z, PAN L, et al. MotionDiffuse: Text-Driven Human Motion Generation with Diffusion Model[EB/OL]. 2022 [2026-05-07]. <https://arxiv.org/abs/2208.15001>. arXiv: 2208.15001 [cs.CV].
- [19] ZHANG J, ZHANG Y, CUN X, et al. Generating Human Motion from Textual Descriptions with Discrete Representations[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 14730-14740 [2026-05-07]. https://openaccess.thecvf.com/content/CVPR2023/html/Zhang_Generating_Human_Motion_From_Textual_Descriptions_With_Discrete_Representations_CVPR_2023_paper.html.
- [20] CHEN X, JIANG B, LIU W, et al. Executing Your Commands via Motion Diffusion in Latent Space[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 18000-18010 [2026-05-07]. https://openaccess.thecvf.com/content/CVPR2023/html/Chen_Executing_Your_Commands_via_Motion_Diffusion_in_Latent_Space_CVPR_2023_paper.html.
- [21] ZHAO K, LI G, TANG S. DARTControl: A Diffusion-Based Autoregressive Motion Model for Real-Time Text-Driven Motion Control[C/OL]//The Thirteenth International Conference on

- Learning Representations. 2025 [2026-05-08]. <https://openreview.net/forum?id=XNA3Mnnbvb>.
- [22] XIAO Z, et al. MotionStreamer: Streaming Motion Generation via Diffusion-based Autoregressive Model in Causal Latent Space[EB/OL]. 2025 [2026-05-07]. <https://arxiv.org/abs/2503.15451>. arXiv: 2503.15451 [cs.CV].
- [23] LOPER M, MAHMOOD N, ROMERO J, et al. SMPL: A Skinned Multi-Person Linear Model [J/OL]. ACM Transactions on Graphics, 2015, 34(6): 1-16 [2026-05-07]. <https://doi.org/10.1145/2816795.2818013>. DOI: 10.1145/2816795.2818013.
- [24] 付成龙, 陈恳. 双足机器人稳定性与控制策略研究进展[J/OL]. 高技术通讯, 2006, 16(3): 319-324 [2026-05-07]. https://www.researchgate.net/publication/294352894_Research_progress_on_stability_and_control_strategy_for_biped_robots.
- [25] 黄元林, 付成龙, 王健美, 等. 双足跑步机器人控制方法研究概述[J/OL]. 机器人, 2009, 31(4): 370-377 [2026-05-07]. <https://robot.sia.cn/article/id/2651>.
- [26] HO J, JAIN A, ABBEEL P. Denoising Diffusion Probabilistic Models[C/OL]//Advances in Neural Information Processing Systems: vol. 33. 2020: 6840-6851 [2026-05-07]. <https://proceedings.neurips.cc/paper/2020/hash/4c5bcfec8584af0d967f1ab10179ca4b-Abstract.html>.
- [27] SONG J, MENG C, ERMON S. Denoising Diffusion Implicit Models[C/OL]//International Conference on Learning Representations. 2021 [2026-05-07]. <https://openreview.net/forum?id=St1giarCHLP>.
- [28] SONG Y, SOHL-DICKSTEIN J, KINGMA D P, et al. Score-Based Generative Modeling through Stochastic Differential Equations[C/OL]//International Conference on Learning Representations. 2021 [2026-05-07]. <https://openreview.net/forum?id=PxtIG12RRHS>.
- [29] NICHOL A Q, DHARIWAL P. Improved Denoising Diffusion Probabilistic Models[C/OL]//Proceedings of Machine Learning Research: Proceedings of the 38th International Conference on Machine Learning: vol. 139. PMLR, 2021: 8162-8171 [2026-05-07]. <https://proceedings.mlr.press/v139/nichol21a.html>.
- [30] KINGMA D P, WELING M. Auto-Encoding Variational Bayes[C/OL]//International Conference on Learning Representations. 2014 [2026-05-07]. <https://arxiv.org/abs/1312.6114>.
- [31] Van den OORD A, VINYALS O, KAVUKCUOGLU K. Neural Discrete Representation Learning [C/OL]//Advances in Neural Information Processing Systems: vol. 30. 2017 [2026-05-07]. <https://proceedings.neurips.cc/paper/2017/hash/7a98af17e63a0ac09ce2e96d03992fbc-Abstract.html>.
- [32] ROMBACH R, BLATTMANN A, LORENZ D, et al. High-Resolution Image Synthesis with Latent Diffusion Models[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 10684-10695 [2026-05-07]. https://openaccess.thecvf.com/content/CVPR2022/html/Rombach_High-Resolution_Image_Synthesis_With_Latent_Diffusion_Models_CVPR_2022_paper.html.

- [33] VASWANI A, SHAZEER N, PARMAR N, et al. Attention Is All You Need[C/OL]//Advances in Neural Information Processing Systems: vol. 30. 2017 [2026-05-07]. <https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>.
- [34] RAFFEL C, SHAZEER N, ROBERTS A, et al. Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer[J/OL]. Journal of Machine Learning Research, 2020, 21(140): 1-67 [2026-05-07]. <https://www.jmlr.org/papers/v21/20-074.html>.
- [35] LIPMAN Y, CHEN R T Q, BEN-HAMU H, et al. Flow Matching for Generative Modeling[C/OL]//International Conference on Learning Representations. 2023 [2026-05-07]. <https://openreview.net/forum?id=PqvMRDCJT9t>.
- [36] CHEN B, MONSO D, DU Y, et al. Diffusion Forcing: Next-token Prediction Meets Full-Sequence Diffusion[EB/OL]. 2024 [2026-05-07]. <https://arxiv.org/abs/2407.01392>. arXiv: 2407.01392 [cs.LG].
- [37] 席裕庚, 李德伟, 林姝. 模型预测控制: 现状与挑战[J/OL]. 自动化学报, 2013, 39(3): 222-236 [2026-05-07]. <https://csc-lab.com/zh/publication/model-predictive-control-2013/>. DOI: 10.3724/SP.J.1004.2013.00222.
- [38] 丁加涛, 何杰, 李林芷, 等. 基于模型预测控制的仿人机器人实时步态优化[J/OL]. 浙江大学学报 (工学版), 2019, 53(10): 1843-1851 [2026-05-07]. <https://www.zjujournals.com/eng/CN/10.3785/j.issn.1008-973X.2019.10.001>. DOI: 10.3785/j.issn.1008-973X.2019.10.001.
- [39] SUTTON R S, BARTO A G. Reinforcement Learning: An Introduction[M/OL]. 2nd ed. Cambridge: MIT Press, 2018 [2026-05-07]. <http://incompleteideas.net/book/the-book-2nd.html>.
- [40] 曲威名, 刘天林, 林惟凯, 等. 机器人学习方法综述[J/OL]. 北京大学学报 (自然科学版), 2023, 59(6): 1069-1086 [2026-05-07]. <https://xbna.pku.edu.cn/CN/10.13209/j.0479-8023.2023.086>. DOI: 10.13209/j.0479-8023.2023.086.
- [41] HOLDEN D, KOMURA T, SAITO J. Phase-Functioned Neural Networks for Character Control [J/OL]. ACM Transactions on Graphics, 2017, 36(4): 1-13 [2026-05-07]. <https://doi.org/10.1145/3072959.3073663>. DOI: 10.1145/3072959.3073663.
- [42] PENG X B, ABBEEL P, LEVINE S, et al. DeepMimic: Example-Guided Deep Reinforcement Learning of Physics-Based Character Skills[J/OL]. ACM Transactions on Graphics, 2018, 37(4): 1-14 [2026-05-07]. <https://xbpeng.github.io/projects/DeepMimic/index.html>. DOI: 10.1145/3197517.3201311.
- [43] ESCONTELA A, PENG X B, YU W, et al. Adversarial Motion Priors Make Good Substitutes for Complex Reward Functions[EB/OL]. 2022 [2026-05-07]. <https://arxiv.org/abs/2203.15103>. arXiv: 2203.15103 [cs.RO].
- [44] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal Policy Optimization Algorithms [EB/OL]. 2017 [2026-05-07]. <https://arxiv.org/abs/1707.06347>. arXiv: 1707.06347 [cs.LG].

- [45] TODOROV E, EREZ T, TASSA Y. MuJoCo: A Physics Engine for Model-Based Control[C/OL]//2012 IEEE/RSJ International Conference on Intelligent Robots and Systems. 2012: 5026-5033 [2026-05-07]. <https://ieeexplore.ieee.org/document/6386109>. DOI: 10.1109/IROS.2012.6386109.
- [46] MAKОВIYCHUK V, WAWRZYNIAK L, GUO Y, et al. Isaac Gym: High Performance GPU-Based Physics Simulation for Robot Learning[EB/OL]. 2021 [2026-05-07]. <https://arxiv.org/abs/2108.10470>. arXiv: 2108.10470 [cs.RO].
- [47] RUDIN N, HOELLER D, REIST P, et al. Learning to Walk in Minutes Using Massively Parallel Deep Reinforcement Learning[C/OL]//Proceedings of Machine Learning Research: Proceedings of the 5th Conference on Robot Learning: vol. 164. PMLR, 2022: 91-100 [2026-05-07]. <https://proceedings.mlr.press/v164/rudin22a.html>.
- [48] 姜晓勇, 应凯健, 吴起威, 等. 足式机器人触地检测方法的研究综述[J/OL]. 浙江大学学报(工学版), 2024, 58(2): 334-348 [2026-05-07]. <https://www.zjujournals.com/eng/CN/10.3785/j.issn.1008-973X.2024.02.012>. DOI: 10.3785/j.issn.1008-973X.2024.02.012.
- [49] 赵京, 张自强, 郑强, 等. 机器人安全性研究现状及发展趋势[J/OL]. 北京航空航天大学学报, 2018, 44(7): 1347-1358 [2026-05-07]. <https://bhxb.buaa.edu.cn/bhzhk/cn/article/doi/10.13700/j.bh.1001-5965.2017.0568>. DOI: 10.13700/j.bh.1001-5965.2017.0568.
- [50] PEEBLES W, XIE S. Scalable Diffusion Models with Transformers[C/OL]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 4195-4205 [2026-05-07]. https://openaccess.thecvf.com/content/ICCV2023/html/Peebles_Scalable_Diffusion_Models_with_Transformers_ICCV_2023_paper.html.
- [51] LIAO Q, TRUONG T E, HUANG X, et al. BeyondMimic: From Motion Tracking to Versatile Humanoid Control via Guided Diffusion[EB/OL]. 2025 [2026-05-08]. <https://arxiv.org/abs/2508.08241>. arXiv: 2508.08241 [cs.RO].
- [52] 罗欣, 丁晓军. 地面移动作业机器人运动规划与控制研究综述[J/OL]. 哈尔滨工业大学学报, 2021, 53(1): 1-15 [2026-05-07]. https://hit.alljournals.cn/html/hitxb_cn/2021/1/20210101.html. DOI: 10.11918/201910067.

符号与标记（附录 1）

符号与标记

表 1-1 汇总正文中反复使用的主要符号。本文中粗体小写字母表示向量，粗体大写字母表示序列或矩阵；若无特别说明，时间下标 t 表示 50 Hz 特征帧，连续潜变量下标 i 表示 12.5 Hz VAE 连续潜变量位置。

表 1-1 主要符号与标记说明

符号	名称	含义
T	特征序列长度	50 Hz 机器人动作特征序列的帧数。
L	连续潜变量序列长度	VAE 沿时间下采样后的连续潜变量数，本文通常满足 $L = 1 + \lfloor (T - 1)/4 \rfloor$ 。
d_z	VAE 潜变量维度	每个动作连续潜变量的连续潜变量维度，主要实验使用 $d_z = 128$ 。
$\mathbf{x}_t$	原始动作特征	第 t 帧 57 维机器人动作特征。
$\hat{\mathbf{x}}_t$	归一化动作特征	经训练集均值和标准差归一化后的 57 维特征。
μ	特征均值	训练集 57 维特征的逐维均值。
σ	特征标准差	训练集 57 维特征的逐维标准差。
ε	数值稳定项	归一化时用于避免除零的小常数。
r_t, p_t, ψ_t	根节点欧拉角	分别表示横滚角、俯仰角和偏航角；本文对横滚/俯仰角采用三角化表示，对偏航角使用增量。
$\Delta\psi_t$	偏航角增量	相邻帧根节点偏航角变化量，用于恢复全局朝向。
$\Delta\mathbf{p}_t^{\text{local}}$	局部位移增量	以当前偏航角为参考的根节点局部位移。
h_t	根节点高度	机器人根节点在世界坐标中的高度。
$\mathbf{q}_t$	关节角	G1 机器人 23 自由度关节角向量。
$\Delta\mathbf{q}_t$	关节角增量	相邻帧关节角变化量。
$\mathbf{z}_i$	动作连续潜变量	第 i 个 VAE 连续潜变量。
ϵ_i	高斯噪声	LDF 或流匹配中用于加噪和初始化的标准高斯噪声。
τ	LDF 推进时间	下三角调度中的连续推进变量。
$\alpha_i(\tau)$	连续潜变量噪声等级	第 i 个连续潜变量在推进时间 τ 下的噪声强度。
K	chunk 大小	LDF 每次推进或计算损失时关注的连续潜变量窗口大小。
c	文本条件	由 T5 文本编码器得到的自然语言条件嵌入。

符号	名称	含义
G_θ	高层生成器	从文本条件和噪声生成机器人动作特征或连续潜变量的模型。
v_θ	速度场网络	流匹配或速度预测形式中预测连续速度场的网络。
π_ϕ	低层跟踪策略	在仿真中依据实时观测和参考动作输出控制动作的 PPO 策略。
s	引导系数	无分类器引导的条件放大系数。
W	当前推进窗口	LDF 训练中计算 chunk 损失的连续潜变量子集。
$\mathbf{o}_t$	跟踪器观测	低层策略在第 t 个控制步读取的机器人状态和参考窗口。
$\mathbf{a}_t$	控制动作	低层策略输出的关节目标或动作增量。
H	未来参考窗口	跟踪器观测中包含的未来参考步数。

系统集成、实验管理与部署边界补充（附录 2）

本章定位与总体路线

正文分别讨论了机器人动作表示、文本条件动作生成模型、流式推理一致性、MuJoCo 运动学验证和 Isaac Lab 仿真跟踪器评估。本章进一步从系统集成角度说明如何把这些模块组织成可复现、可调试、可验证的毕业设计系统。这样安排的原因是，本课题并不是单独训练一个文本到动作模型，也不是单独训练一个运动控制策略，而是要建立从自然语言输入到人形机器人仿真动作输出的完整链路。若只描述每个模块本身，容易忽略模块之间的接口约束；若直接展示最终视频，又难以说明中间误差来自哪里。因此，本章重点讨论系统闭环、实验组织、指标记录、风险控制和阶段性仿真验证路线。

本文已经完成高层动作生成的主要实现，并完成 MuJoCo 运动学回放与流式/整段生成对比。跟踪器部分完成 G1 仿真跟踪器训练、策略参数保存、ONNX 导出和 Isaac Lab/RSL-RL 评估配置接入；真实机器人部署仍作为后续方向。因此，本章把系统集成、跟踪器评估流程、实验记录和风险控制放在同一章中说明。

从工程视角看，本系统需要同时满足三类要求。第一类是功能要求，即输入一段或多段自然语言后，能够生成 G1 机器人动作特征，并将其恢复为可视化或可跟踪的参考轨迹。第二类是分析要求，即当生成结果异常时，能够判断问题来自文本编码、VAE 连续潜变量化、LDF 生成、动作特征重构还是跟踪器控制。第三类是验证要求，即在有限样本和有限时间内给出可复查的系统有效性记录，而不是只给出抽象模型结构。本章围绕这三类要求展开。

图 2-1 概括了本文系统的三阶段路线。图中第一阶段对应本文已经完成的动作生成和 MuJoCo 分析，第二阶段对应本文训练的跟踪器仿真评估链路和物理指标整理，第三阶段真机部署只作为后续方向保留。该图的作用是明确论文工作范围：本文报告动作生成结果、仿真跟踪器训练结果和回放流程，但不把第三阶段真机部署写成已完成实验。

围绕统一工程的实现过程，本文还整理了若干对实验设计直接有用的现象，例如 VAE 潜变量维度和 LDF 可学习性之间的矛盾、T5 文本编码在不同批处理形态下的数值差异、重定向数据质量问题以及跟踪器接口的评价范围。图 2-2 将这些现象组织为调试依据。该图的重点不是新增一个独立模型，而是说明本文为什么要同时报告

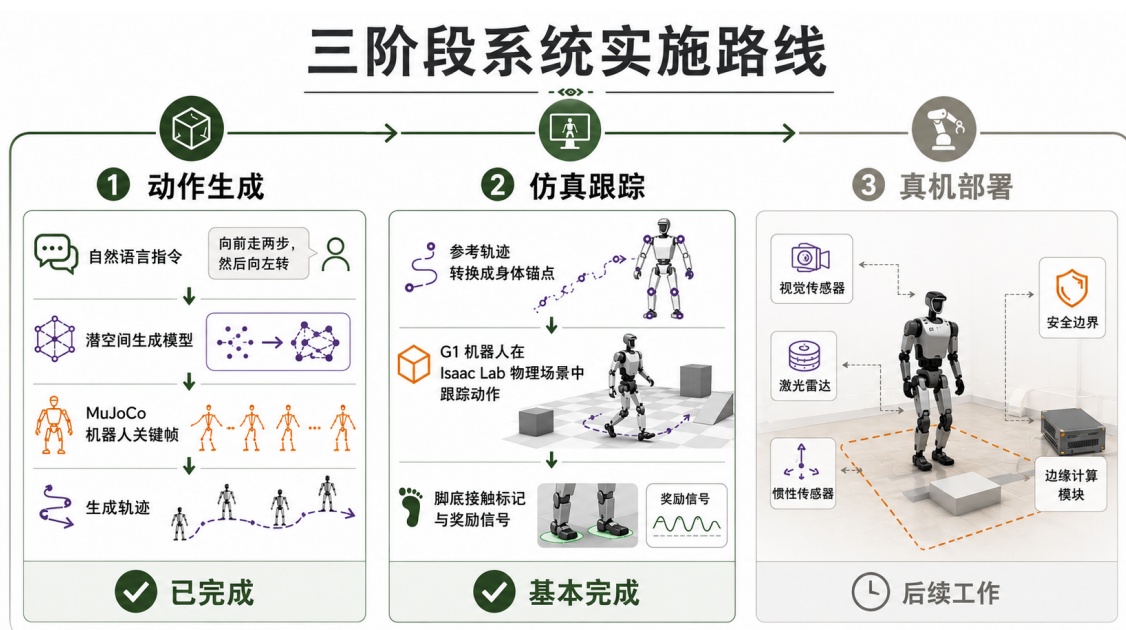


图 2-1 三阶段系统实施路线

VAE 维度扫描、T5 精度对比、MuJoCo 关键帧和本文训练跟踪器物理评价流程。




图 2-2 机器人 LDF 关键实验现象与调试依据

闭环数据流与模块边界

六阶段数据流

系统闭环从自然语言指令开始, 到仿真中的机器人动作结束。为了避免不同脚本之间重复实现逻辑, 本文将闭环拆分为六个顺序阶段: 文本输入、文本编码、潜空间动作生成、特征解码与反归一化、参考轨迹构造、低层控制跟踪。每个阶段的输入输出都应保存为可检查的中间文件或张量, 以便在出现问题时单独回放。

第一阶段是文本输入。离线实验使用数据集集中的文本片段列表和文本结束索引; 在线测试可以使用人工输入的短命令序列。地面移动作业机器人运动规划与控制综述表明, 在复杂任务中需要把任务描述、运动规划、轨迹跟踪和执行约束统一到系统链路中考虑^[52]; 更一般的机器人运动规划和路径规划研究也强调, 规划输出最终必须服从环境约束和执行约束^[7-8]。无论来源如何, 文本都需要转换为带时间边界的片段集合:

$$C = \{(c_i, e_i)\}_{i=1}^K, \quad (2-1)$$

其中 c_i 表示第 i 段文本, e_i 表示该文本在连续潜变量轴上的结束位置。对流式系统

而言,文本结束位置不是附属信息,而是决定每个连续潜变量使用哪个文本条件的关键状态。

第二阶段是文本编码。本文使用冻结 T5 文本编码器得到文本嵌入。T5 建立在 Transformer 注意力结构之上,能够为自然语言片段提供上下文相关的文本表征^[33-34]。根据第四章分析,文本编码必须固定批处理形态和数值路径,否则整段和流式推理会因为条件文本嵌入的微小差异而产生不同动作。因此,在集成版本中保留两种模式:调试模式保存每个文本片段的嵌入文件,便于逐项比较;在线测试模式则使用固定批大小的编码,保证每次运行路径一致。若后续为了速度改用其他文本编码器,也必须先通过同样的一致性测试。

第三阶段是潜空间动作生成。LDF 接收文本嵌入和噪声初始化,输出动作连续潜变量序列。整段推理适合生成离线视频和比较不同配置;流式推理适合在线闭环和连续指令。下三角调度来自扩散强制和 FloodDiffusion 对序列不同位置噪声等级的建模思路^[12,36]。两者共享模型参数、VAE、文本编码函数和随机种子管理器,差别只体现在时间调度和缓存提交方式上。这样可以保证当二者结果不同的时候,差异确实来自流式机制,而不是来自隐藏配置差异。

第四阶段是特征解码与反归一化。LDF 生成的是 VAE 连续潜变量,需要先通过 VAE 解码器得到归一化后的 57 维动作特征,再使用训练集统计量反归一化。该阶段输出三类检查量:57 维动作特征序列、各维最小最大值、关键物理量曲线。关键物理量包括根节点高度、偏航角增量、局部位移、关节角范围和脚部接触标签。若这些曲线已经异常,则不应继续把轨迹送入跟踪器,因为后续控制失败很可能只是高层轨迹错误的结果。

第五阶段是参考轨迹构造。动作特征需要恢复为根节点位置、根节点姿态、关节位置、身体锚点和未来参考窗口。MuJoCo 运动学回放和 Isaac Lab 跟踪器使用同一个转换模块。若二者各自实现动作特征到 qpos 的逻辑,即使高层生成相同,也可能在仿真中出现不同动作。本文把转换函数作为独立接口:输入为动作特征和统计量,输出为统一动作字典;MuJoCo 和跟踪器只读取该动作字典。

第六阶段是低层控制跟踪。跟踪器接收 motion dict 中当前及未来若干步参考,结合机器人当前状态输出关节位置目标或动作增量。该阶段与 DeepMimic、PPO 运动跟踪以及大规模并行机器人学习的研究脉络一致^[42,44,47]。此时动作已经进入物理系统,评价指标也从生成误差转向跟踪误差、接触质量和稳定性。若机器人摔倒,需要回溯检查参考轨迹是否合理,而不是直接认定跟踪器训练失败。

模块边界与责任划分

数据层、生成层与重构层

清晰的模块边界是系统可调试的前提。本文将系统划分为数据层、生成层、重构层、控制层和评估层。数据层负责样本读取、文本边界、动作特征统计量和预编码连续潜变量；生成层负责文本条件潜空间生成；重构层负责从连续潜变量到 57 维动作特征，再到 qpos 或动作字典；控制层负责 Isaac Lab 中的策略训练和跟踪；评估层负责日志、曲线、视频和指标表格。

数据层不应承担模型决策。它只保证输入样本正确、长度对齐、统计量一致。若在数据层加入过多启发式修正，例如根据生成结果自动修改文本边界，就会掩盖真实模型问题。数据层可以做的修正主要包括删除明显损坏样本、统一帧率、统一关节顺序和保存可复现索引。对于有争议的样本，最好保留一份排除列表，而不是在代码中静默跳过。

生成层只负责产生动作特征分布，不直接处理电机控制，也不直接模拟接触动力学。这样做不是因为物理约束不重要，而是因为本文的主要代码和训练资源集中在高层生成模型。若把物理仿真直接放入生成模型训练闭环，工程复杂度会显著增加，也很难在本科毕设周期内完成稳定实验。生成层需要做的是尽量输出连续、语义一致、可重构的参考动作，并将明显失败案例暴露给评估层。

重构层是生成和控制之间最容易被低估的模块。57 维动作特征本身不是机器人仿真状态，而是一种适合生成模型学习的中间表示。它必须经过偏航角累积、局部位移旋转、根节点高度处理、关节角填充和四元数构造才能成为可播放轨迹。重构层一旦实现不一致，模型本身的实验结果就会失去可比性。因此，本文将重构层实现为单一共享模块，并用真实动作特征、VAE 重构动作特征和 LDF 生成动作特征三类输入做回归测试。

控制层与评估层

控制层不应假设参考轨迹完全正确。实际生成结果可能有轻微抖动、接触不一致或关节角接近限位。跟踪器的职责是在合理范围内学习鲁棒跟踪，而不是替高层模型修复所有错误。若参考轨迹需要大幅 clamp 或平滑才能执行，应把修正幅度作为生成失败指标记录下来。这样可以避免把高层生成问题转嫁给低层控制器。

评估层负责把上述各层结果组织成可解释实验记录。对于毕业设计而言，评估层至少应输出四类材料：关键配置记录、数值指标表格、误差曲线和仿真视频。只给视

频不够，因为视频只能说明某个样本看起来可以播放；只给表格也不够，因为动作语义和姿态质量仍需要可视化辅助判断。两者结合才能支撑论文结论。

集成测试与实验管理

为了保证系统每次修改后仍能运行，本文设计了由浅到深的集成测试清单，如表 2-1 所示。该清单不是单元测试意义上的完整覆盖，而是面向研究型代码的最小可复现实验。每项测试都应尽量使用固定样本和固定随机种子，避免把随机差异误判为代码回归。

表 2-1 系统集成测试清单

测试层级	检查内容	通过标准
数据读取	特征、文本、边界索引	长度一致，无空文本异常
VAE 重构	特征到连续潜变量再解码	姿态可播放，关键维度无越界
文本编码	批量与单条编码比较	调试模式下差异可解释
LDF 生成	固定随机种子生成动作连续潜变量	输出长度和维度正确
运动学回放	特征到 MuJoCo qpos	无明显关节异常和高度跳变
流式对比	整段与流式并排播放	差异来源可定位
跟踪器接口	motion dict 到参考窗口	坐标、频率、长度匹配
物理仿真	Isaac Lab 短时回放	不因接口错误立即失败

第一层测试是数据读取。读取一个样本后，检查动作特征长度、潜变量长度、文本片段数量、特征级边界和连续潜变量级边界。对于 50 Hz 动作特征和 12.5 Hz 连续潜变量，长度关系应满足 VAE 下采样规则。如果文本边界超过序列长度，或者某个连续潜变量位置没有对应文本，后续训练会出现隐蔽错误。

第二层测试是 VAE 重构。选择真实动作特征，经过 VAE 编码器和解码器后恢复，再用 MuJoCo 播放。该测试不涉及 LDF，因此可以单独判断 VAE 是否破坏动作结构。若 VAE 重构已经明显抖动或脚部异常，则继续训练 LDF 意义有限，因为生成模型学习的是一个质量不足的潜空间。

第三层测试是文本编码一致性。对同一组文本片段，分别使用整段批处理编码和逐条编码，保存文本嵌入差异。该测试不要求所有精度路径都完全一致，但要求差异范围已知，并且最终实验路径固定。第四章的结果说明，默认混合精度 GPU 路径差异会被递推放大，因此集成系统把文本编码路径作为配置项显式记录。

第四层测试是 LDF 生成。固定模型参数、随机种子和样本索引后，生成连续潜变量，并检查潜变量形状、数值范围和是否出现非数值（Not a Number, NaN）。此时可以先不进入 MuJoCo，而是在潜变量或动作特征层绘制均值、方差和局部差分曲线。这样可以更早发现生成爆炸或归一化错误。

第五层测试是运动学回放。将动作特征恢复为广义坐标（qpos），在 MuJoCo 中播放。该测试重点观察根节点高度、偏航角、关节角和脚部接触是否合理。若出现机器人突然瞬移、身体高度跳变或关节大幅反折，说明重构层或生成层存在问题，不应直接进入跟踪器。

第六层测试是跟踪器接口。将动作字典组织成 Isaac Lab 所需参考窗口，检查每个控制步读取的未来身体锚点是否正确。该测试可以先用随机策略检查环境维度，再用训练完成的策略运行短时回放，确认系统不会因为设备、频率或坐标系错误崩溃。

数据版本与实验命名规范

研究型项目容易出现一个问题：模型结果和数据版本对应关系不清楚。本文统一使用 Any-Text-to-Humanoid-Action 工程，但工程内部仍包含 VAE、LDF、MuJoCo 可视化和跟踪器多个阶段。如果实验目录命名不清晰，后续很难判断某组模型参数使用了哪套动作特征、哪套统计量和哪种文本编码路径。因此，本系统需要明确实验命名规范。

对于 VAE 实验，目录名至少包含模型类型、机器人自由度、潜变量维度和训练步数。例如 $z = 64$ 和 $z = 128$ 的实验不能只用时间戳区分，因为后续 LDF 预编码必须知道潜变量维度。VAE 输出还保存训练集统计量、配置文件副本和最终模型参数。若统计量与模型参数分离保存，后续反归一化时可能误用其他实验的均值方差。

对于 LDF 实验，目录名至少包含 VAE 维度、训练块长度、是否随机裁剪、是否随机选择文本、引导系数相关配置和训练步数。尤其是 random_block_cap 和文本随机策略，会直接影响长序列覆盖和文本对齐。若只记录模型参数文件而不记录这些训练配置，后续无法解释不同实验之间的质量差异。

对于可视化实验，输出目录保存生成样本索引、随机种子、引导系数、推理模式、是否触发显存不足分块回退和文本编码路径。第四章中定位 T5 精度问题的过程表明，显存不足回退并不是一个无关细节，它会改变缓存中的文本嵌入来源。因此，比较整段与流式结果时，需要记录回退状态。

对于跟踪器实验，目录名包含参考轨迹来源、动作池组成、奖励配置、并行环境

数、控制频率、训练步数和模型参数编号。若使用真实动作、VAE 重构动作和 LDF 生成动作混合训练或评估，还需要记录各类动作采样比例。否则，即使最终得到一个稳定策略，也难以说明稳定性来自真实动作覆盖、跟踪器训练配置还是来自生成动作质量。

可复现实验脚本组织

本文将最终验证脚本分为四类：数据检查脚本、生成脚本、可视化脚本和跟踪器脚本。数据检查脚本负责读取样本并输出长度、边界和统计量；生成脚本负责从文本或样本索引生成动作特征；可视化脚本负责 MuJoCo 回放和并排比较；跟踪器脚本负责 Isaac Lab 训练和评估。四类脚本共享配置文件，避免各自硬编码路径。

数据检查脚本的输出尽量文本化，例如打印样本长度、文本片段列表、连续潜变量边界、动作特征均值方差范围和是否存在 NaN。该脚本运行成本低，适合作为每次实验前的第一步。对于固定样本 train_000031，还可以输出每段文本对应的连续潜变量区间，便于和后续误差曲线对齐。

生成脚本应支持两种输入：数据集样本索引和人工文本序列。样本索引用于可复现实验，因为其真实动作和文本边界已知；人工文本用于在线交互测试，因为它更接近自然语言交互。对于人工文本，系统需要指定每段文本持续时间或连续潜变量数，否则模型无法知道何时切换指令。为了避免测试时出现不可控结果，可以先把人工文本序列保存成配置文件，再由生成脚本读取。

可视化脚本应支持单轨迹播放、双轨迹并排播放和曲线导出。单轨迹播放用于快速查看动作；双轨迹播放用于比较真实动作、VAE 重构、LDF 整段生成和 LDF 流式生成；曲线导出用于论文中的定量分析。相比只录制视频，曲线能更清楚地展示偏航角漂移、根节点高度异常和关节角抖动。

跟踪器脚本应区分训练和评估。训练脚本可以使用大量并行环境和随机起点；评估脚本应固定样本、固定起点和固定随机种子，输出视频和指标。论文中呈现的结果应来自评估脚本，而不是训练过程中的偶然片段。这样可以提高结果可信度。

跟踪器训练与物理指标

低层跟踪器的训练和复用可以采用课程学习，以降低从真实动作到生成动作的难度。物理角色模仿控制通常先依赖示例动作和稳定奖励学习基本跟踪能力，再逐步扩展到更复杂动作或更强先验^[42-43]。第一阶段只使用真实重定向动作训练，使策

略学习 G1 机器人基本姿态跟踪、行走和转身。该阶段的目标不是验证生成模型，而是获得一个稳定的基础控制器。如果基础控制器无法跟踪真实动作，应先调整奖励、终止条件和动作空间。

第二阶段加入 VAE 重构动作。VAE 重构动作与真实动作语义相同，但包含连续潜变量编码和解码误差。该阶段可以检验 VAE 是否保留了跟踪器所需的物理结构。若策略在真实动作上表现稳定，但在 VAE 重构动作上失败，说明 VAE 的重构损失需要更重视根节点位移、关节角和接触相关维度。此时不应急于加入 LDF 生成动作。

第三阶段加入 LDF 生成动作。初期只加入经过 MuJoCo 检查的短动作，例如站立、向前走、转身和下蹲。随着策略稳定，再加入包含多个文本片段的长序列。这样做可以避免训练初期被大量低质量生成动作破坏。若生成动作质量差异较大，可以采用动作池筛选：先用动作安全检查器计算修正幅度和物理异常指标，只把异常较少的生成动作加入训练。

第四阶段可以考虑混合采样比例调度。训练开始时真实动作比例较高，随后逐步增加 VAE 重构和 LDF 生成动作比例。例如前期真实动作占 80%，VAE 重构占 20%；中期真实动作、VAE 重构和 LDF 生成动作各占一定比例；后期提高 LDF 生成动作比例以增强对生成分布的适应。具体比例需要根据仿真结果调整，但实验记录中必须保存每个阶段的比例。

课程学习的核心是逐步增加参考轨迹难度，而不是一次性让策略面对所有生成误差。在毕业设计周期有限的情况下，本文优先使用训练完成的策略完成仿真评估链路，并明确说明尚未进入真机部署。这样仍能验证系统从生成到物理跟踪的主要思路。

物理指标记录与结果表格

跟踪器训练完成并加载策略评估后，系统记录一组基础物理指标。第一类是成功率指标，包括回放片段完成率、早停率和跌倒率。成功率可以直观反映生成动作是否可执行，但不能说明失败原因，因此需要配合误差指标。类似的“是否完成、是否跌倒、跟踪误差和接触质量”指标，也是物理动作模仿和机器人强化学习实验中常见的评价维度^[42,46-47]。

第二类是跟踪误差指标，包括根节点位置误差、根节点姿态误差、身体关键点位置误差、关节位置误差和速度误差。对于不同动作类型，误差含义也不同。站立动作应更关注姿态稳定和关节抖动，行走动作应更关注根节点速度和脚部接触，转身动作

应更关注偏航角跟踪。若只报告总体均值，可能掩盖某些动作类别的失败。

第三类是接触与安全指标，包括脚滑速度、非期望接触次数、接触力峰值、关节限位违规率、力矩饱和比例和动作变化率。这些指标与真实机器人部署关系更密切。触地检测研究说明，足端接触状态是足式机器人感知支撑相和判断步态稳定性的关键变量^[48]；机器人安全性研究则提醒控制系统不能只追求任务完成，还要限制潜在危险动作和人机交互风险^[49]。即使仿真中机器人没有摔倒，如果脚滑严重或力矩长期饱和，也说明生成轨迹不适合真实执行。

第四类是高层生成修正指标。若动作安全检查器对生成动作进行了关节角限幅、根节点高度限幅或速度平滑，系统记录每个维度的修改幅度。若某条轨迹必须大幅修正才能被跟踪器跟踪，则该轨迹不应被视为生成成功。这样的记录可以让高层生成模型和低层控制器之间形成反馈。

结果表格按轨迹来源组织，如表 2-2 所示。真实动作、VAE 重构动作和 LDF 生成动作分开报告，避免混合平均掩盖问题。本文已经具备训练完成的跟踪器评估入口；若扩展到更多 LDF 生成动作，可以在同一结构下继续补充。

表 2-2 仿真物理评估指标组织方式

轨迹来源	重点指标	主要用途
真实重定向动作	完成率、跟踪误差	验证控制环境
VAE 重构动作	重构误差、脚滑速度	检查连续潜变量表示影响
LDF 整段生成	语义质量、关节越界率	评价离线生成质量
LDF 流式生成	长时漂移、文本切换误差	评价在线生成稳定性

代表性验证样本选择

阶段性验证不适合随机选择任意长文本，因为生成模型和跟踪器都仍处于研究阶段。本文选择少量代表性样本覆盖不同难度，主要包括四类：静态姿态、周期运动、姿态转换和多文本长序列。

静态姿态样本可以是站立或 T-pose。它的作用是验证根节点高度、关节角和跟踪器基础稳定性。如果静态姿态都无法稳定，说明控制器或重构层存在基础问题。周期运动样本可以是向前走或小幅转身，用于验证根节点位移、偏航角累积和脚部接触。姿态转换样本可以是下蹲、跪下或起立，用于验证较大关节变化和身体高度变化。多文本长序列样本则用于检验流式文本条件切换。

每个样本最好同时保留三条轨迹：真实重定向动作、VAE 重构动作和 LDF 生成动作。真实动作提供参照，VAE 重构动作说明连续潜变量化损失，LDF 生成动作体现文本条件生成能力。如果时间允许，再加入整段生成和流式生成并排比较。这样即使某个生成动作存在瑕疵，也能说明问题处于哪一层，而不是把局部失败误判为整个系统失效。

结果视频不只剪辑最顺利片段，而是保留从文本输入到动作播放的完整过程，并在旁边显示当前文本片段或连续潜变量区间。对于流式生成，显示文本切换时刻尤其重要，因为本文的研究重点之一就是连续自然语言命令下的动作生成。若跟踪器验证只覆盖少量样本，也可以先给出 MuJoCo 运动学回放，再给出本文已训练跟踪器的短片段物理跟踪结果，并明确说明其覆盖范围。

失败回收、部署边界与消融缓存

系统集成过程中出现失败样本是正常现象。关键不是完全避免失败，而是建立失败样本回收机制。每个失败样本保存文本、样本索引、随机种子、生成配置、动作特征文件、MuJoCo 视频、跟踪器视频和错误日志。这样修改模型或参数后，可以重新运行同一批失败样本，判断问题是否改善。

失败样本按根因分组。语义失败样本用于改进文本条件和数据覆盖；时序漂移样本用于改进训练窗口、随机裁剪和流式缓存；重构失败样本用于改进 VAE 和动作特征表示；控制失败样本用于改进跟踪器奖励和课程学习。分组越清楚，后续迭代越有效。

对于生成模型，失败样本还可以反过来指导数据清洗。若某类文本在数据集中对应动作差异很大，例如 `transition` 或语义模糊的动作标签，模型可能学不到明确语义。此时可以考虑在训练中降低该类文本权重，或将其作为过渡标签而非主要动作标签。对于 BABEL 数据，文本标注本身存在粒度差异，因此不能假设所有文本片段都同样适合训练机器人动作生成。

对于跟踪器，失败样本可以用于调整终止条件和奖励尺度。如果策略总是在下蹲时早停，可能是根节点高度阈值过严；如果策略能保持不摔倒但脚部持续滑动，可能是脚滑惩罚不足；如果策略动作抖动，可能是动作变化率惩罚或参考轨迹平滑不足。通过失败样本回收，系统可以从“看视频调参”转向“按类别修复”。

与真机部署的关系

真实机器人部署是本文系统的远期目标，但不是当前已经完成的实验。国内服务机器人和具身智能研究表明，真实系统落地通常需要同时解决本体平台、感知交互、任务规划、控制执行和安全协作问题^[1-2,4]。真机部署至少需要解决四类额外问题。第一类是实时性。生成模型、VAE 解码、动作安全检查器和跟踪器推理必须在控制周期内完成。若高层生成较慢，需要提前生成参考窗口或降低更新频率。第二类是状态估计。仿真中可以直接读取真实根节点状态和关节状态，真机上则依赖传感器和估计算法，存在延迟和噪声。

第三类是执行器约束。仿真中的关节目标或力矩限制与真实电机并不完全一致。真实机器人还需要考虑电机温度、通信丢包、控制器限幅和急停机制。第四类是安全策略。自然语言输入可能产生不可执行或危险动作，系统必须在执行前检查轨迹是否超过安全范围。尤其是下蹲、跪下、快速转身等动作，在仿真中可尝试，但真机上需要逐步放开幅度；这与机器人安全性研究中对机械风险、控制风险和交互风险的分类讨论相一致^[49]。

因此，本文把真机部署放在展望中，而不是作为已完成实验。本文系统的定位是：完成文本到机器人动作的生成链路，建立可视化、本文训练跟踪器仿真评估和风险分析方法，为后续真机部署提供动作表示、模型接口和安全边界基础。这样的定位与项目实际进度一致，也避免过度承诺。

生成模型消融实验设计

在系统集成完成后，生成模型本身仍需要通过消融实验判断哪些设计真正有效。本文从四个维度组织消融：VAE 潜变量维度、LDF 训练块策略、引导系数和文本编码路径。每个消融都固定数据版本、样本集合、随机种子和可视化脚本，否则不同实验之间无法直接比较。

第一类消融是 VAE 潜变量维度。第四章已经给出 $z = 4, 8, 16, 32, 64, 128$ 的潜空间活跃性分析，但活跃维度数量只能说明潜变量是否被使用，不能直接说明下游生成和跟踪质量。可选取 $z = 32, 64, 128$ 三个代表配置训练 LDF，并在同一组文本样本上比较生成动作的重构误差、流式稳定性和跟踪器成功率。若 $z = 128$ 在 VAE 重构上最好但 LDF 生成不稳定，而 $z = 64$ 在生成和跟踪上更稳，则应优先选择 $z = 64$ 作为系统默认配置。

第二类消融是训练块策略。本文主实验使用长度为 50 个连续潜变量的固定开头

裁剪配置，优点是训练稳定、调试容易，缺点是长序列后半段覆盖不足。可以比较固定开头裁剪、随机裁剪和更长训练块长度。评价时不能只看训练损失，因为随机裁剪可能让训练初期损失更高，却提升长片段内部稳定性。更合适的指标是长序列样本中的偏航角漂移、根节点位移累积误差和文本切换后的动作恢复能力。

第三类消融是无分类器引导系数。较小的引导系数可能导致文本语义弱，生成动作更像平均动作；较大的引导系数可能放大条件差异，使动作幅度过大或局部不稳定。本文扫描 $s = 1.0, 3.0, 5.0, 7.5$ ，并分别评价语义对齐和物理可跟踪性。若只看视觉效果，较大 s 可能更明显；但若进入跟踪器，过大的动作幅度可能导致跌倒或关节越界。因此，最终选择应以生成质量和物理指标共同决定。

第四类消融是文本编码路径。第四章的实验说明，CPU float64 编码可以使流式与显存不足分块回退完全一致，但部署时成本较高。可以比较三种实用方案：训练和推理都使用离线缓存文本嵌入；训练和推理都使用批大小为 1 的在线编码；训练使用缓存、在线测试使用固定批大小编码。该消融的重点不是追求最高精度，而是找到速度、显存和确定性之间的平衡。

消融实验结果以表格和代表性视频共同呈现。表格可以报告 VAE 维度、引导系数、流式/整段动作特征差异、偏航角漂移和跟踪器完成率；视频则展示同一文本在不同配置下的动作差异。跟踪器结果继续扩展时，可以将这些消融补充到正文实验章；本附录保留评估入口、指标和代表性样本组织方式。

文本缓存机制设计

文本缓存是本文系统中一个看似细小但影响很大的工程环节。若每次训练或推理都重新调用 T5 文本编码器，系统会受到批处理形态、设备、精度和库版本影响。由于 T5 这类大规模文本编码器的前向结果会受到精度、设备和批处理形态影响，工程系统需要把文本条件视为可复现输入的一部分^[34]。为了降低这种不确定性，本文为固定数据集建立离线文本缓存。缓存的基本单位不是样本，而是文本片段字符串及其编码配置。这样多个样本中相同文本片段可以共享文本嵌入，也便于检查同一句文本在不同路径下是否一致。

缓存文件包含文本内容、分词器版本、T5 模型参数名称、设备、数据类型、批大小、最大潜变量长度和最终文本嵌入。若只保存文本嵌入而不保存元信息，复查时很难判断它是如何产生的。对于研究代码而言，元信息和数值本身同样重要，因为很多复现问题并不是模型结构不同，而是隐藏的预处理路径不同。

训练阶段使用缓存可以减少重复文本编码开销,使批次构造更稳定。数据加载器读取文本片段后,根据字符串或哈希值查询文本嵌入;若缓存不存在,则在预处理阶段生成,而不是在训练循环中临时编码。这样可以避免多进程数据加载、GPU 混合精度和随机批次组合共同影响文本条件。

推理阶段的缓存策略需要区分离线评估和在线交互。离线评估可以直接读取缓存,保证与训练一致;在线交互则可能遇到训练集中不存在的新文本。对于新文本,可以使用固定批大小为 1 的编码路径,并将编码结果写入临时缓存。这样同一条在线命令在多次运行中仍然一致。若后续接入真实机器人,缓存还可以降低重复指令的延迟。

文本缓存还可以帮助分析语义覆盖。统计缓存中的文本片段频率,可以发现数据集中是否存在大量 transition 或语义过于宽泛的标签。如果某些高频文本对应动作差异很大,模型可能难以学习稳定映射。此时可以在训练中调整采样权重,或将这些文本作为弱条件处理。由此可见,缓存不仅是加速工具,也是数据分析工具。

仿真接入与安全约束

动作安全检查器是生成器和跟踪器之间的安全缓冲层。它的作用不是把任意坏动作修成好动作,而是在进入物理仿真前做最小必要检查,并记录修正幅度。若没有这一层,明显超出关节范围或高度异常的动作可能直接导致仿真崩溃;若这一层修正过强,又会掩盖高层生成模型的问题。因此,该检查器必须遵循“可记录、可关闭、最小修改”的原则。

第一项检查是四元数和角度连续性。由偏航角增量累积得到全局朝向后,需要构造根节点姿态。若偏航角序列中存在突然跳变,四元数会出现不连续,跟踪器可能收到瞬间旋转的参考。动作安全检查器可以检测相邻帧偏航角差是否超过阈值,并对异常点做平滑或标记。对于横滚/俯仰角,也检查三角函数反解后是否出现不合理倾斜。

第二项检查是根节点高度。生成模型可能输出过低或过高的根节点高度。过低会导致身体或腿部与地面穿插,过高则会造成机器人悬空。动作安全检查器可以根据训练集统计范围设置软阈值,例如超过均值若干标准差时标记异常。对于轻微异常,可以限幅到合理范围;对于大幅异常,直接判定该轨迹不适合进入跟踪器。

第三项检查是关节角范围。G1 机器人每个关节都有物理限位,生成动作特征反归一化后必须检查关节角是否越界。若只是少量轻微越界,可以记录并限幅;若大量关节持续越界,则说明生成模型或 VAE 重构存在严重问题。关节角限幅后还应重新

计算相邻帧差分，避免限幅本身造成不连续。

第四项检查是速度和平滑性。低层控制器对参考轨迹的速度变化比较敏感。若关节角一阶差分或二阶差分过大，策略需要快速改变关节目标，容易产生抖动或力矩饱和。动作安全检查器可以输出关节速度和加速度统计，但不默认强平滑所有轨迹。平滑会改变动作语义，尤其是擦手、挥手等快速手部动作。因此，平滑作为可选项，并记录平滑前后的误差。

第五项检查是接触一致性。脚部接触标签应与脚底速度和高度大致一致。若标签表示接触，但脚底水平速度很大，则可能产生脚滑；若标签表示离地，但脚底高度接近地面，也可能说明接触时序错误。本文生成模型并没有直接在物理仿真中优化接触，因此接触一致性检查对于跟踪器训练和评估尤其重要。可以将接触不一致指标作为生成动作筛选条件。

Isaac Lab 环境接入细节

Isaac Lab 跟踪器接入需要处理设备、频率、坐标和批量环境四类问题。Isaac Gym 展示了 GPU 物理仿真在机器人学习中的高吞吐优势，大规模并行仿真也有助于提高策略训练效率^[46-47]。设备问题主要来自 PyTorch 张量、Isaac 仿真张量和模型推理之间的设备一致性。生成轨迹通常先保存在 CPU 文件中，而训练环境运行在 GPU 上。加载动作字典后，一次性转换到目标设备，避免每个仿真步在 CPU 和 GPU 之间频繁拷贝。

频率问题来自三套时间尺度：动作特征为 50 Hz，VAE 连续潜变量为 12.5 Hz，Isaac Lab 仿真步长为 0.005 秒且控制降采样系数为 4。也就是说物理仿真内部为 200 Hz，控制频率为 50 Hz，正好可以与动作特征帧率对齐。若后续改变控制降采样系数或动作特征帧率，参考轨迹插值必须同步修改。频率不一致会导致速度估计错误和参考跳变，是跟踪器接入中最常见的问题之一。

坐标问题主要是根节点坐标系和世界坐标系的转换。生成器输出局部位移增量，重构层累积为世界坐标轨迹；跟踪器观测中可能同时使用世界坐标身体锚点和机器人身体坐标下的相对参考。必须明确每个观测量所处坐标系，否则策略会收到方向错误的目标。例如，若偏航角方向定义与 Isaac Lab 机器人模型不一致，机器人可能在跟踪时不断转向或侧向移动。

批量环境问题来自并行训练。Isaac Lab 通常同时运行数千个环境，每个环境可能采样不同参考轨迹和不同起始时间。动作加载器需要支持批量索引，并在回合重置

时为每个环境分配轨迹片段。若轨迹长度不足或起点采样越界，训练会出现间歇性错误。调试阶段先使用少量环境和固定轨迹，确认接口正确后再扩大并行数。

环境重置逻辑也需要与参考轨迹一致。若回放片段从动作中间开始，机器人初始状态应接近该时刻参考姿态，否则策略一开始就面对巨大误差，可能立即触发终止。真实动作训练时可以直接从参考 `qpos` 初始化；生成动作训练时则需要先检查 `qpos` 是否合理。对于明显异常的起始帧，应从采样池中排除。

实验归档、记录组织与验证步骤

跟踪器实验和生成模型实验在同一工程中持续迭代，实验归档按“模型配置、样本集合、指标表格、视频路径、结论摘要”五类信息组织。该结构保证第四章中的消融表、可视化图和跟踪器案例都能追溯到固定样本池和固定配置，而不是依赖临时终端输出。

每次实验保存配置文件副本。对于 VAE 和 LDF，归档 YAML (YAML Ain't Markup Language) 配置、模型参数标识和代码版本；对于跟踪器，归档环境配置、奖励权重、训练步数和参考动作池；对于可视化，归档样本索引、文本列表、随机种子和引导系数。视频归档同时保留原始版本和压缩版本，文件名包含样本索引、推理模式和轨迹来源，便于后续复查。

指标表格使用逗号分隔值 (Comma-Separated Values, CSV) 或 JavaScript 对象表示法 (JavaScript Object Notation, JSON) 等机器可读格式保存。论文中的表格由这些原始指标整理而来，原始数值不只保存在正文文本中。这样在重新训练 VAE、LDF 或跟踪器后，可以直接比较新旧指标，判断变化来自模型配置、样本池还是评估协议。

系统有效性记录组织

本文系统有效性记录分为四层：任务目标层、系统实现层、实验诊断层和物理闭环层。任务目标层说明自然语言指令如何转化为机器人可执行参考动作；系统实现层记录 57 维动作表示、VAE 连续潜变量化、流匹配探索、LDF 主模型和 MuJoCo 回放；实验诊断层记录 T5 编码路径、流式缓存、长时漂移和重构误差分析；物理闭环层记录本文训练的 G1 仿真跟踪器如何把参考轨迹放入动力学约束下评价。

任务目标层强调自然语言交互、人形机器人通用动作和规划控制接口之间的关系。本文在摘要、绪论和第四章中均区分运动学回放和物理跟踪：前者用于检查姿态和时序，后者用于评价参考轨迹在接触、关节限位和稳定性约束下的可跟踪性。

系统实现层围绕 Any-Text-to-Humanoid-Action 工程中的统一模块展开：57 维 G1 动作特征定义、VAE 连续潜变量化和预编码流程、流匹配模块中的速度场目标和常微分方程采样、LDF 模块中的下三角时间调度和流式缓存。该层记录的是改造后的系统输入输出、训练目标、推理路径和评估入口。

实验诊断层展示 VAE 潜变量维度扫描、T5 精度对比、整段与流式并排可视化和文本切换误差分析。T5 编码路径问题是本文调试中的关键发现：同一句文本在不同设备、精度和批处理形态下会产生微小文本嵌入差异，并在 LDF 递推生成中被放大。该结果说明，流式生成系统的可复现性不仅取决于模型结构，也取决于数值路径和缓存策略。

物理闭环层记录跟踪器训练、奖励项、终止项、未来参考窗口和物理指标。本文已完成 G1 仿真跟踪策略训练、ONNX 导出和短片段回放验证，并将真实重定向动作、VAE 重构动作、LDF 整段生成动作和 LDF 流式生成动作组织为同一参考轨迹池。后续扩展到更多生成动作时，可以继续沿用同一指标体系追加结果。

实验记录规范化与结果表述

项目实验记录包含命令行输出、临时 JSON、视频文件、截图和个人分析笔记。本文将这些材料整理为三类稳定证据：可验证事实、实验推断和边界说明。可验证事实包括数据集规模、模型维度、训练配置、固定样本池、数值表格和编译结果。例如训练集 6452 条、验证集 2152 条、57 维动作特征定义、 $z = 128$ VAE 有效维度分析，以及 T5 CPU float64 编码使流式与分块整段生成结果一致，均属于可复查事实。

实验推断保留必要的限定条件。例如“ $z = 64$ 可能更适合 LDF”来自潜空间活跃性、容量权衡和小规模生成实验，最终默认维度仍需要结合 LDF 生成质量和跟踪器可跟踪性确定。MuJoCo 回放看起来合理，说明运动学层面没有明显异常，但不能直接等同于物理控制成功。本文在相关段落中使用“候选”“可能”“仍需扩展”等限定语，是为了区分实验结果和进一步结论。

边界说明用于防止概念混淆。无分类器引导、LDF、VAE、广义坐标、模型参数、文本嵌入等术语在正文首次出现处已给出解释；正文保留方法和结论，不堆砌绝对路径或长命令。附录只保留系统组织和复现实验原则，使评审重点落在方法、数据、指标和结论上。

仿真闭环验证实施步骤

本文仿真闭环按五步实施。第一步固定生成动作样本池，覆盖站立、行走、转身、下蹲、起立和多文本切换，并保存文本、动作特征、MuJoCo 视频和生成配置。固定样本池使 VAE、LDF、T5 编码路径和跟踪器评估可以在同一组输入上比较。

第二步建立动作字典到 Isaac Lab 参考命令的转换接口。该接口先用真实重定向动作检查坐标和频率，再用 VAE 重构动作检查连续潜变量误差，最后加入 LDF 生成动作。每一步都运行短时回放，检查机器人初始姿态、未来参考窗口和坐标方向。

第三步训练并复用 G1 仿真跟踪器。本文使用已训练策略完成仿真评估链路，并保留继续微调接口。稳定策略形成后，可以逐步增加下蹲、跪下和长序列等更困难动作，从短闭环扩展到更复杂的多文本样本。

第四步整理评价材料。基础指标包括短片段完成率、根节点位置误差、关节角误差、脚滑速度、接触异常和早停原因。视频与指标按样本一一对应，失败案例也保留原因分析，以便定位问题来自数据重构、VAE、LDF 还是低层跟踪器。

第五步扩展物理反馈。获得更多跟踪器结果后，物理可执行性指标可以反向用于高层生成器的样本筛选、配置选择或强化学习后训练。该闭环与正文的实验组织保持一致：先固定样本和指标，再比较模型配置，最后讨论生成侧改进。

研究边界与结果表述原则

本文已完成的内容包括 G1 机器人 57 维动作表示、VAE 连续潜变量化、LDF 训练与推理、整段/流式生成对比、MuJoCo 运动学回放、文本编码一致性分析，以及 G1 仿真跟踪策略训练、ONNX 导出和 Isaac Lab/RSL-RL 仿真跟踪评估链路。这些内容作为本文的实现结果和实验分析直接报告。

后续扩展内容包括针对 LDF 生成动作的大规模物理指标统计、用物理反馈对动作生成器进行强化学习后训练，以及真实机器人部署。跟踪器部分在本文中定位为已训练仿真策略、接口设计和评价指标体系；大规模开放文本物理实验需要在更多生成动作上形成稳定指标后再作为后续结果报告。真实机器人部署保持在展望和系统边界中，不作为本文已完成实验。

这种边界划分使论文能够覆盖“规划控制方法研究”的完整链路，同时避免把运动学回放误写成物理执行成功。本附录讨论跟踪器课程训练、策略参数管理、动作安全检查器和结果归档，支撑正文的动作生成与仿真跟踪主线。

本章小结

本章从系统集成角度补充了自然语言到人形机器人动作生成与仿真跟踪的实施方案。本文将闭环拆分为文本输入、文本编码、潜空间生成、特征重构、参考轨迹构造和低层跟踪六个阶段，并明确了数据层、生成层、重构层、控制层和评估层的职责划分。在此基础上，本章给出了集成测试清单、实验命名规范、可复现实验脚本组织、跟踪器课程训练、物理指标记录、代表性验证样本选择和失败样本回收方法。

这些内容的作用是把前文的模型实现和实验分析连接成一个可执行系统。对于本文而言，最重要的不是宣称已经完成真实机器人部署，而是清楚说明已经完成的动作生成链路、本文训练仿真跟踪器链路，以及如何用物理指标评价生成动作。正文总结章将对全文工作进行总结，并给出进一步研究方向。

毕业设计（论文）标题：基于自然语言指令的人形机器人规划控制方法研究

学生姓名：唐扬 学号：522031910076 指导教师：项艳、张伟楠

一、本文使用的 AI 工具清单

序号 ^a	AI 工具名称	版本/型号	毕业设计（论文）中应用部分 ^b	人为判断过程 ^c 说明
1	Grok	平台版本	A2	仅作为文献检索关键词扩展、相关研究线索整理和候选文献初筛工具；题录、出版源、作者信息、论文内容和引用关系均通过原文、学术数据库或官方页面人工复核。
2	Gemini	3.0 Pro	B1	仅作为研究思路和章节逻辑的启发工具；最终研究问题、系统边界、实验设计和论文结构均结合实际代码实现、数据条件和实验结果由本人判断确定。
3	Claude	Opus 4.6	C2	仅作为 Python 代码实现与调试思路辅助；所有代码修改均由本人阅读、筛选、改写并在本地运行验证。
4	GPT	5.4	C2	仅作为代码调试、报错分析、脚本重构和实验记录整理建议来源；本人逐项检查其建议是否符合项目接口、数据维度和实验配置。
5	GPT / GPT Image	5.5 / Image 2	D3、E2	作为中文表述、语法、段落衔接和格式一致性润色工具，并辅助生成部分论文示意图；润色和图像生成结果均由本人逐段、逐图审阅确认，不改变技术含义、实验数据和结论边界。

- 注释：
- ^a 序号仅用于区分本文实际使用过的辅助工具。
 - ^b 应用部分编号对应下方“毕业设计（论文）中应用部分对照表”。
 - ^c 人为判断过程指的是依据何种方式判断 AI 工具生成的内容的准确性。

毕业设计（论文）中应用部分对照表

A. 研究准备阶段	A1. 选题与方向设定；A2. 文献检索与筛选
B. 研究设计阶段	B1. 研究思路设计；B2. 方法论构建；B3. 研究工具开发
C. 研究实施阶段	C1. 实验/数据分析；C2. 代码编写与调试；C3. 数学建模与计算
D. 论文写作阶段	D1. 大纲与逻辑优化；D2. 论文正文写作；D3. 语言与语法润色
E. 其他辅助环节	E1. 参考文献与格式；E2. 图表/多媒体生成；E3. 学术反馈与模拟答辩

二、使用说明

1. A2: Grok 协助扩展“文本到动作生成”“人形机器人运动跟踪”“扩散/流匹配生成”“自然语言机器人控制”等检索关键词，并帮助整理部分候选论文线索。本人仅将其输出作为检索入口，最终纳入论文的参考文献均经过原文阅读、数据库信息核验和内容相关性判断。

2. B1: Gemini 3.0 Pro 用于研究思路设计阶段的方案讨论，例如将自然语言输入、机器人动作表示、潜空间生成、MuJoCo 运动学回放和 Isaac Lab 跟踪器验证组织为一条系统链路。本文最终采用的技术路线、章节安排和实验边界由本人依据项目实现进度、数据条件和已有实验结果确定。

3. C2: Claude Opus 4.6 用于 Python 代码实现与调试思路辅助。相关建议均经过人工筛选、局部改写和本地运行验证；论文中的实验数据、图表和结论均来源于本地代码执行、模型输出、仿真记录或人工整理结果。

4. C2: GPT-5.4 用于代码调试、报错分析、脚本重构和实验记录整理建议。本人逐项检查生成建议是否符合项目接口、数据维度和实验配置，未直接采用未经测试的代码或结论。

5. D3、E2: GPT-5.5 用于论文写作后期的语言与语法润色，主要包括中文表达通顺性、段落衔接、重复表述压缩和格式一致性检查；GPT Image 2 用于辅助生成部分论文示意图。润色过程中本人保留并复核全部技术含义、实验数据和结论边界；图像生成结果均由本人根据论文内容、模型结构和实验流程逐图检查、筛选和替换，未使用 AI 工具替代独立分析或生成未经核验的学术结论。

学术诚信声明

本人承诺：论文核心观点、实验数据及结论均独立完成，AI 工具仅用于辅助性工作；本人已在本附录中说明相关工具的使用范围，并对最终文本、图表、实验数据和结论边界逐项核验。

承诺人：_____唐扬_____

日期：_____2026_____年_____5_____月_____8_____日

攻读学位期间学术论文和科研成果目录

1. Yufei Xue, Yunfeng Lin, Wentao Dong, **Yang Tang**, Jingbo Wang, Jiangmiao Pang, Ming Zhou, Minghuan Liu, Weinan Zhang. Scalable and General Whole-Body Control for Cross-Humanoid Locomotion. In Proceedings of the 43rd International Conference on Machine Learning (ICML), 2026.

致 谢

行文至此，本科阶段的学习、实习、科研与毕业设计工作也将告一段落。回望这一路，从最初进入实验室学习卫星定位，到后来转向自然语言驱动的人形机器人规划控制研究，许多重要的选择都离不开师长、同学、家人和朋友的帮助。借此机会，谨向所有在本科阶段给予我支持、信任和鼓励的人表达最诚挚的感谢。

首先，衷心感谢项艳老师以及导航所的各位学长。在实验室实习阶段，项老师和学长们给予了我充分的包容、耐心的指导和宝贵的锻炼机会，使我第一次真正接触科研训练，也在卫星定位方向上获得了重要启蒙。这段经历让我认识到严谨问题定义、扎实工程实现和持续复盘的重要性，也为后来开展毕业设计打下了基础。

衷心感谢张伟楠老师带我进入机器人研究领域。张老师在研究方向上给予了我清晰而关键的引导，帮助我从原先的技术兴趣逐步走向具身智能、人形机器人和运动生成控制这一更具挑战性的方向；同时，张老师也推荐我前往上海人工智能实验室实习，使我有机会在更开放的科研环境中接触前沿课题、工程系统和真实实验条件。这段转变对我的本科后期学习和毕业设计选题都有重要意义。感谢 APEX 实验室的老师、学长和同学们在研究过程中的交流与指导。无论是课题方向讨论、论文阅读、代码实现，还是实验问题排查，许多交流都帮助我拓宽了视野，也让我在不断试错中理解机器人研究并不只是模型或算法本身，更是一套由数据、仿真、控制、评价和工程实现共同构成的系统工作。

感谢上海人工智能实验室为本课题研究提供的良好环境、算力资源、硬件条件和科研氛围。实习期间，实验室完善的平台支持让我能够开展较复杂的人形机器人生成与仿真实验；与这里的老师和同学交流，也使我对具身智能、生成模型和机器人控制之间的关系有了更具体、更前沿的认识。

感谢本科阶段所有任课教师的悉心教导。课堂学习为我建立了数学、编程、控制、感知和人工智能等方面的基础，也让我能够在面对跨学科问题时有继续学习和解决问题的底气。感谢感知学院、电院、计算机学院以及上海交通大学为学生提供的课程资源、科研平台和成长空间，让我能够在不同学科交叉处探索自己的兴趣。

感谢我的父母一直以来对我的信任和支持。无论是在专业学习、科研尝试、实习选择，还是面对不确定方向时，他们都尊重并支持我的决定。正是这种稳定而坚定的信任，让我在遇到压力和挫折时仍能继续向前。

感谢一路同行的同学和朋友。感谢你们在学习、科研、生活和情绪低谷中的陪伴与互助，也感谢那些共同讨论问题、赶作业、准备考试、调试代码和分享近况的时刻。本科生活因为这些具体而温暖的同行经历变得更加完整。

最后，也感谢一路努力的自己。本科四年并不总是轻松的，我在勤工俭学、课内学习、课外科研和社会工作之间不断寻找平衡，也在一次次选择、尝试和调整中逐渐理解自己真正关心的问题。毕业设计不是终点，而是一个新的起点。愿自己在未来仍能保持好奇、保持踏实、保持面对困难时继续往前走的勇气。

RESEARCH ON HUMANOID ROBOT PLANNING AND CONTROL METHODS BASED ON NATURAL LANGUAGE INSTRUCTIONS

Natural-language control is an important direction for humanoid robots because it provides a direct and intuitive interface between humans and embodied systems. Instead of selecting predefined actions or writing low-level joint commands, a user should be able to describe a desired behavior in natural language, and the robot should generate and execute a corresponding motion. This thesis addresses humanoid robot planning and control based on natural-language instructions within the unified Any-Text-to-Humanoid-Action project. The work focuses on two parts: text-conditioned motion generation and simulation-based motion tracking, while real-robot deployment is treated as future work.

The first challenge is motion generation. A humanoid robot cannot directly execute a sentence such as “walk forward and wave”. The sentence must be mapped to a continuous trajectory that contains root motion, body orientation, joint positions, and contacts. Existing text-to-motion methods usually generate human skeletal motions, while robot control requires robot-specific representations and physical feasibility. This thesis therefore designs a 57-dimensional local motion feature for the Unitree G1 robot. The feature consists of root roll and pitch represented by sine and shifted cosine terms, yaw increments, foot contact labels, local root translation increments, root height, 23 robot joint positions, and 23 joint increments. This representation reduces discontinuities in angular variables and expresses root motion relative to the robot’s current heading.

The second challenge is streaming generation. Offline text-to-motion models usually synthesize a full sequence after receiving the full text. However, a robot may receive new commands while it is already moving. For this reason, this thesis studies streaming text-to-motion generation. The implementation is organized in one unified project. In this project, an early Flow Matching module replaces iterative diffusion sampling with velocity-field prediction and ordinary differential equation (ODE) solving. This provides a useful exploration of faster generative sampling for robot motion.

In the main implementation stage, this thesis builds a robot-oriented Latent Diffusion

Forcing (LDF) system based on FloodDiffusion. A temporal variational autoencoder (VAE) first compresses 50 Hz robot motion features into 12.5 Hz d_z -dimensional continuous latent vectors; in the main configuration, $d_z = 128$. A frozen T5 (Text-to-Text Transfer Transformer) encoder produces text embeddings for segmented language descriptions. A Wan Diffusion Transformer (Wan-DiT) backbone then performs latent generation under a triangular noise schedule. In this schedule, latent positions on the left side of the sequence gradually become clean and are committed as generated history, while future latent positions remain noisy. This design allows the model to generate motion from left to right and to update future motion when new text arrives.

The implementation covers the complete high-level pipeline: BABEL action-label data and Archive of Motion Capture as Surface Shapes (AMASS) retargeted data processing, robot VAE training, VAE latent precomputation, LDF training, full-sequence generation, streaming generation, and MuJoCo visualization. The processed robot dataset contains 6,452 training samples and 2,152 validation samples. Multiple VAE latent dimensions were analyzed. The results show that smaller latent dimensions are easier for the LDF model to learn, while larger latent dimensions provide better reconstruction quality. A 128-dimensional latent model is used as the main configuration, and 32-dimensional and 64-dimensional models are retained as important comparisons.

A key experimental finding of this thesis is the numerical inconsistency between full-sequence generation and streaming generation. During visualization, the full-sequence path may first encode all text segments in one batch and then switch to chunked full-sequence generation when memory is insufficient. In contrast, the streaming path encodes text segments one by one. Although a frozen T5 encoder is mathematically sample-independent, graphics processing unit (GPU) Brain Floating Point 16 (bf16) computation can produce slightly different embeddings for the same text segment under different batch shapes. These small differences are then amplified by the autoregressive diffusion forcing process. On a representative sample, the default GPU bf16 path produced a mean absolute feature difference of 0.1237 between streaming and chunked full-sequence generation. When T5 was moved to central processing unit (CPU) float32, the difference decreased to 0.0571. When T5 was computed in CPU float64 and then cast back to float32 before being fed into the Wan backbone, the two paths became identical in the recorded feature and continuous-latent arrays.

This result shows that streaming generation systems should keep text-encoding paths deterministic and consistent.

The thesis also trains and integrates a simulation-based tracking controller in the same project. The tracker is implemented with Isaac Lab and the RSL-RL framework from the Robotic Systems Lab, and the policy is trained by proximal policy optimization (PPO) to track reference motions. Generated motions are converted into the same reference format before being evaluated by this tracker. Its observations include reference commands, future body-anchor positions and orientations, base velocities, joint states, and previous actions. The reward terms include root and body position tracking, orientation tracking, body velocity tracking, action smoothness, joint limits, undesired contacts, foot sliding, landing force, joint velocity limits, and torque limits. Domain randomization is used for friction, default joint positions, torso center of mass, and external pushes. This tracker converts high-level generated trajectories into physically executable reference-following behavior in simulation.

The tracker also changes the role of motion generation evaluation. A generated trajectory may look acceptable in kinematic replay, but it can still be difficult for a torque-controlled humanoid to follow if contact timing, center-of-mass motion, or joint-limit margins are unreasonable. Therefore, this thesis treats the tracker as a simulation gate between high-level generation and future deployment. Motions are first inspected in MuJoCo to remove obvious representation errors, and then the same reference format can be used by the Isaac Lab tracker to measure whether the behavior remains stable under contact and dynamics. This design makes the evaluation more robot-oriented than pure feature-space reconstruction loss. It also prepares a closed loop in which generated motion data can be used to enrich tracker training, while tracking errors, foot sliding, falling cases, and contact-force statistics can later guide the motion generator through reinforcement-learning post-training or sample filtering.

The experimental analysis is organized to support this two-level view. At the representation level, the thesis checks whether the 57-dimensional feature can be normalized, reconstructed, and converted back to a robot trajectory without losing essential root and joint information. At the generative level, it compares VAE dimensions, Flow Matching outputs, LDF configurations, classifier-free guidance strengths, and full-versus-streaming inference paths. At the control level, it separates kinematic replay from physical tracking, so that errors caused by motion representation, text conditioning, numerical precision, and low-level

control are not mixed together. This layered analysis is important because a visually poor generated sequence may come from a weak language-motion alignment, while a physically unstable sequence may come from contact timing or dynamic infeasibility even when the kinematic posture looks plausible.

Several implementation choices are made for reproducibility rather than only for final visual quality. Intermediate tensors such as text embeddings, continuous latent arrays, reconstructed motion features, and recovered robot states are saved or inspected during debugging. Fixed random seeds and fixed representative samples are used when comparing different guidance coefficients or inference modes. The same conversion interface is used by MuJoCo visualization and tracker evaluation to reduce hidden differences between kinematic and physical tests. These choices make the reported results easier to reproduce and help identify why some generated motions fail, which is especially useful in a project where high-level generation, continuous latent modeling, and humanoid tracking are tightly coupled.

The implemented system forms a reproducible research pipeline from natural language to G1 robot motion features and trained simulation-tracker evaluation. Nevertheless, several problems remain. The generated motions are not always semantically stable, long sequences may accumulate yaw-angle and root-position drift, and the fixed-sample physical tracking benchmark should be expanded in future work. The next stage should evaluate more generated motions with the tracker, report tracking success, foot sliding, contact forces, and fall rate, and use these physical metrics for reinforcement-learning post-training or sample selection of the motion generator. After stable simulation tracking is achieved, the system can be extended to real-robot deployment with Open Neural Network Exchange (ONNX) export, latency reduction, communication tests, control-frequency matching, and safety constraints.

The absence of real-robot experiments is also a deliberate boundary of this undergraduate thesis. Physical deployment on a shared G1 platform requires reserved hardware time, repeated safety checks, actuator-limit verification, communication-frequency matching, emergency-stop procedures, and additional debugging under supervision. Under the project schedule and hardware-sharing constraints, the safer choice is to complete motion generation, simulation replay, and tracker-side evaluation first. This boundary does not remove the value of the work: the generated trajectories, ONNX export path, and tracking interface define the artifacts that must be validated before real-robot tests. They also make

the remaining deployment risks explicit, including latency, observation mismatch, contact robustness, and the gap between simulated and real dynamics.

Overall, this thesis shows that natural-language-driven humanoid robot control is not a single-model problem. It requires text-motion alignment, robot-specific motion representation, streaming generative modeling, numerical consistency, and physics-based tracking. The main contribution is an integrated route that connects open-ended language descriptions to continuous robot motion features and then to a simulation tracking controller. The completed implementation and analysis provide a foundation for further work toward physically executable humanoid actions generated from natural-language instructions, and they clarify which parts should be improved before moving from simulation to the real G1 robot.