



上海交通大学学士学位论文

基于动作扩散策略的 四足机器人视觉目标导航

姓 名：陈 样

学 号：522031910056

导 师：雷华明

院 系：自动化与感知学院

学 科 / 专 业：智能感知工程

2026 年 5 月 27 日

**A Dissertation Submitted to
Shanghai Jiao Tong University for the Degree of Bachelor**

**VISUAL GOAL NAVIGATION
FOR QUADRUPEL ROBOTS BASED ON ACTION
DIFFUSION POLICY**

Author: Chen Yang

Supervisor: Lei Huaming

School of Automation and Intelligent Sensing

Shanghai Jiao Tong University

Shanghai, P.R. China

May 27th, 2026

上海交通大学

本科生毕业设计（论文）任务书

课题名称： 基于动作扩散策略的四足机器人视觉目标导航

执行时间： _____年_____ 月 至 _____年_____月

教师姓名： 雷华明

职称：

学生姓名： 陈样

学号： 522031910056

专业名称： 智能感知工程

学院(系)： 自动化与感知学院

毕业设计（论文）基本内容和要求：

该毕业设计聚焦于目标导向的视觉导航任务，依赖机器人当前的视觉观测和目标的视觉图像，引导控制双足/四足机器人自主移动到目标点。本课题旨在研究并实现一种基于动作扩散策略的通用导航与探索框架，赋能机器人在日常使用场景中，无需或仅需少量特定数据即可完成多样化的导航任务。传统的机器人导航系统往往需要为特定机器人和环境单独训练策略，且难以兼顾目标导向的导航与任务无关的探索。本项目将借鉴并发展前沿的具身智能研究，利用动作扩散模型强大的多模态动作分布建模能力，构建一个统一的策略。该策略将通过“目标掩码”机制灵活支持图像目标导航和自主探索，并通过抽象动作空间实现对四足和双足等不同足式机器人平台的泛化。研究内容包括在仿真环境中复现核心框架，并针对足式机器人的特性（如平衡控制、复杂地形适应）进行控制优化与适配，最终旨在提升机器人在未知、动态日常场景中的自主性和适应性。

1、具有一定编程能力，熟悉至少一门面向对象编程语言，如 Python；2、熟悉 Linux 系统；3、熟悉 PyTorch 框架；4、具备一定计算机视觉或机器人基础，熟悉 ROS（ROS1/ROS2）框架。

1、文献调研：深入调研通用导航模型系列论文，以及足式机器人视觉导航的最新进展；2、环境搭建：搭建仿真/实际环境，实现双足/四足机器人基本导航控制；3、模型迁移与部署：部署通用导航框架与预训练模型，设计模型到双足/四足机器人具体步态控制器的映射接口；4、适配策略研究：研究高效微调策略或领域自适应算法，解决训练数据与双足/四足机

机器人的差异；5、实机验证（可选）：选定实验场景，在实际双足/四足机器人上进行实机效果验证。

毕业设计（论文）进度安排：			
序号	毕业设计（论文）各阶段内容	时间安排	备 注
	文献调研：深入调研通用导航模型系列论文，以及足式机器人视觉导航的最新进展；	开始 2025.11.01 结束 2025.11.30	
	环境搭建：搭建仿真/实际环境，实现双足/四足机器人基本导航控制；	开始 2025.12.01 结束 2026.01.31	
	模型迁移与部署：部署通用导航框架与预训练模型，设计模型到双足/四足机器人具体步态控制器的映射接口；	开始 2026.02.01 结束 2026.03.31	
	适配策略研究：研究高效微调策略或领域自适应算法，解决训练数据与双足/四足机器人的差异；	开始 2026.04.01 结束 2026.04.30	
	根据导师意见反复修改论文，完成查重、格式调整。制作最终版答辩 PPT，录制系统演示视频。	开始 2026.05.01 结束 2026.05.30	
课题信息：			

课题性质：设计

课题来源*：企、事业单位委托项目

项目编号 ____

其他_____

指导教师签名：雷华明

2025 年 11 月 16 日

学院（系）意见：

院长（系主任）签名：王涛

2025 年 11 月 17 日

学生签名：陈样

2025 年 11 月 17 日

上海交通大学

学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全知晓本声明的法律后果由本人承担。

学位论文作者签名：陈样

日期：2026 年 5 月 25 日

上海交通大学

学位论文使用授权书

本人同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。

本学位论文属于：

☒ 公开论文

☐ 内部论文，保密 ☐ 1 年 / ☐ 2 年 / ☐ 3 年，过保密期后适用本授权书。

☐ 秘密论文，保密 ____ 年（不超过 10 年），过保密期后适用本授权书。

☐ 机密论文，保密 ____ 年（不超过 20 年），过保密期后适用本授权书。

（请在以上方框内选择打“√”）

学位论文作者签名：陈样

日期：2026 年 5 月 25 日

指导教师签名：陈样

日期：2026 年 5 月 25 日

摘要

具身智能的发展正推动移动机器人从结构化实验环境走向真实场景。机器人需在地图先验不足、环境外观变化明显且人工不便持续干预的条件下，依据视觉目标自主到达指定位置。与轮式机器人相比，四足机器人具有更强的地形适应性和空间通过性，但步态运动也会引入相机抖动、速度响应非线性等系统问题。目标掩码扩散导航模型（Navigation with Goal Masked Diffusion, NoMaD）将动作扩散策略引入视觉导航，可生成多条局部航点候选轨迹；但现有验证多集中在轮式平台或离线数据集，面向四足机器人真实部署的研究仍不充分。

针对上述问题，本文以 NoMaD 为高层视觉导航核心，以云深处 Lite3 四足机器人为目标平台，围绕“基于动作扩散策略的四足机器人视觉目标导航”展开研究，构建了从统一推理模块构建与优化、仿真闭环验证到 Jetson Orin 真机部署的完整链路。

首先，本文以 NoMaD 为基础梳理其视觉编码器、距离预测器、目标掩码机制和扩散策略头，建立统一离线评估流程。围绕边缘设备实时推理需求，进一步构建统一视觉目标导航推理模块，涵盖去噪扩散隐式模型（Denoising Diffusion Implicit Model, DDIM）采样加速、无分类器引导（Classifier-Free Guidance, CFG）条件增强、测试时扩展（Test-Time Scaling, TTS）候选筛选和视觉编码器替换。实验结果表明，DDIM-2 能够显著降低采样开销，CFG 更适合作为场景相关可调参数，TTS-8 能够以较低代价改善候选选择，视觉编码器替换为后续真实相机适配提供了可评测框架。

其次，本文构建由统一推理模块、有限状态机、导航主机、中层控制映射和平台接口组成的分层闭环系统，将高层航点转换为 Lite3 可执行速度指令，并屏蔽仿真与真机后端差异。基于该架构，本文在 MuJoCo 中搭建 Lite3 视觉导航闭环环境，完成目标导航、探索和多目标任务测试，验证了推理模块候选配置能够进入系统级闭环。

此外，本文形成了面向 Jetson Orin 与 Lite3 的真机部署方案，将系统组织为实时推理链路和分层控制链路，并设计 Orin 独立调试、Lite3 联合低速验证和真实拓扑地图导航实验的分阶段联调流程。系统引入多级安全机制，使生成式视觉导航策略能够在真实平台上以可监护、可恢复的方式运行。

实验结果表明，DDIM-2 相对基线去噪扩散概率模型（Denoising Diffusion Probabilistic Model, DDPM）实现约 4.84 倍推理加速；MuJoCo 闭环实验中，系统在多类场景下均能完成目标到达任务；Orin 端独立调试显示高层推理模块可稳定运行在约 7.0 Hz。真机多场景目标导航实验中，基线 DDPM、最快方案（DDIM-2、CFG=0、TTS-

8)、增强方案 (DDIM-2、CFG=2、TTS-8) 和对比方案 (DDIM-3、CFG=0、无 TTS) 均达到 100% 成功率, 闭环频率分别为 2.89 Hz、6.80 Hz、3.43 Hz 和 5.90 Hz。探索实验验证了无目标模式的真机可用性, 室外零样本实验则揭示了强光照、复杂纹理和开阔空间对视觉编码器泛化能力的影响。综上, 本文为四足机器人在弱先验环境中的视觉目标导航提供了可复现的系统框架和实验依据。

关键词: 视觉目标导航, 动作扩散策略, 四足机器人, 目标掩码扩散导航模型, 去噪扩散隐式采样

ABSTRACT

The development of embodied intelligence is driving mobile robots from structured laboratory environments toward real-world scenarios. Robots need to reach visually specified goals under weak map priors, changing appearances, and limited continuous human intervention. Compared with wheeled robots, quadruped robots offer stronger terrain adaptability and mobility, while legged locomotion also introduces system-level issues such as camera disturbance and nonlinear velocity response. Navigation with Goal Masked Diffusion (NoMaD) introduces action diffusion policies into visual navigation and can generate multiple local navigation-point candidates; however, existing validations are still mainly conducted on wheeled platforms or offline datasets, and real deployment on quadruped robots remains insufficiently studied.

This thesis takes NoMaD as the high-level navigation core and the DeepRobotics Lite3 quadruped robot as the target platform, studying visual goal navigation for quadruped robots based on action diffusion policy. A complete pipeline is built from unified inference-module construction and optimization to MuJoCo simulation and Jetson Orin real-robot deployment.

First, the thesis analyzes NoMaD's visual encoder, distance predictor, goal mask mechanism, and diffusion policy head, establishing a unified offline evaluation workflow. To meet edge-device real-time inference requirements, a unified visual goal navigation inference module is built, covering Denoising Diffusion Implicit Model (DDIM) sampling acceleration, Classifier-Free Guidance (CFG), Test-Time Scaling (TTS) candidate selection, and visual encoder replacement. Results show that DDIM-2 reduces sampling cost, CFG is better treated as a scene-dependent tuning parameter, TTS-8 improves candidate selection with low overhead, and encoder replacement provides an evaluable framework for real-camera adaptation.

Second, a hierarchical closed-loop system is constructed, consisting of a unified inference module, a finite-state machine, a navigation host, a mid-level control mapping module, and a platform interface. The system converts high-level navigation points into executable Lite3 velocity commands and hides backend differences between simulation and real robots. Based on this architecture, a Lite3 visual navigation environment is built in MuJoCo, where goal navigation, exploration, and multi-goal tasks are verified.

Third, a Jetson Orin–Lite3 deployment scheme is developed. The real-robot system is organized into a real-time inference chain and a hierarchical control chain, with staged commissioning from Orin standalone debugging to low-speed Lite3 verification and real topological-map navigation. Multi-level safety mechanisms are introduced to support monitorable and recoverable real-robot execution.

Experiments show that DDIM-2 achieves approximately $4.84\times$ inference speedup over the Denoising Diffusion Probabilistic Model (DDPM) baseline. MuJoCo tests confirm that the system can reach targets across multiple scenario categories, and Orin standalone tests show stable high-level inference at about 7.0 Hz. In real multi-scene navigation, the baseline DDPM setting, the fastest setting (DDIM-2, CFG=0, TTS-8), the enhanced setting (DDIM-2, CFG=2, TTS-8), and the comparison setting (DDIM-3, CFG=0, without TTS) all achieve 100% success rates, with closed-loop frequencies of 2.89 Hz, 6.80 Hz, 3.43 Hz, and 5.90 Hz. Exploration experiments verify the usability of the goal-free mode, and outdoor zero-shot tests reveal the influence of strong illumination, complex textures, and open spaces on visual-encoder generalization. Overall, this thesis provides a reproducible system framework and experimental basis for quadruped visual goal navigation in weak-prior environments.

Key words: visual goal navigation, action diffusion policy, quadruped robot, NoMaD, DDIM, quadruped platform

目 录

第 1 章 绪论	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	3
1.2.1 传统导航、视觉 SLAM 与学习型导航.....	4
1.2.2 视觉目标导航与拓扑记忆	5
1.2.3 动作扩散策略与通用视觉导航模型	5
1.2.4 四足机器人视觉导航与真实部署.....	6
1.3 本文主要贡献.....	8
1.4 论文章节安排.....	8
1.5 本章小结.....	9
第 2 章 基于动作扩散策略的统一视觉目标导航推理模块.....	11
2.1 问题分析.....	11
2.2 视觉目标导航任务定义与航点表示.....	12
2.2.1 视觉目标导航任务定义	12
2.2.2 拓扑导航与拓扑地图表示	14
2.2.3 航点表示的优势分析.....	14
2.3 动作扩散策略与 NoMaD 模型机制	16
2.3.1 扩散模型与动作扩散策略	16
2.3.2 NoMaD 基础模型结构	19
2.3.3 视觉掩码与导航/探索统一建模	23
2.4 数据集、实验设备与基线推理验证.....	24
2.4.1 GoStanford 数据集与数据预处理.....	24
2.4.2 感知输入与实验设备.....	25
2.4.3 基线推理与评价指标.....	25
2.5 DDIM 推理加速与 CFG 引导增强实验	29
2.5.1 DDIM 推理加速实验.....	29
2.5.2 CFG 引导增强实验.....	31
2.6 TTS 推理时搜索与视觉编码器升级实验	33
2.6.1 TTS 推理时搜索实验.....	33
2.6.2 视觉编码器升级实验.....	36
2.7 联合消融分析与最终算法配置.....	38
2.7.1 优化方法之间的关系.....	39
2.7.2 消融验证与编码器联合补充.....	41
2.7.3 最终算法框架确定	44
2.8 本章小结.....	44

第 3 章 基于分层架构与 MuJoCo 仿真的四足机器人视觉导航闭环 系统设计及验证	45
3.1 问题分析	45
3.2 四足机器人平台与闭环接口基础	45
3.2.1 轮式与足式平台的部署差异	45
3.2.2 云深处 Lite3 平台与关键参数	46
3.3 分层闭环系统架构设计	47
3.3.1 分层设计	47
3.3.2 统一推理模块	48
3.4 状态机与导航主机设计	49
3.4.1 状态机职责	49
3.4.2 导航主机职责	50
3.4.3 中层控制映射	51
3.5 MuJoCo 仿真平台与任务设计	51
3.5.1 选择 MuJoCo 的原因	51
3.5.2 仿真系统组成与接口一致性	52
3.5.3 场景、物理参数与相机设置	52
3.5.4 仿真任务类型	53
3.6 MuJoCo 闭环验证与结果分析	53
3.6.1 仿真完整性复核	53
3.6.2 闭环参数扫描实验	54
3.6.3 结果分析	55
3.7 本章小结	56
第 4 章 基于 Jetson Orin 与 Lite3 的视觉目标导航真机部署与实验 验证	57
4.1 问题分析	57
4.2 真机系统双链路与 Orin 部署架构	57
4.2.1 横向实时推理链路：从图像到 twist 指令	58
4.2.2 纵向分层控制链路：从 NoMaD 到运控	59
4.2.3 Orin 真机部署架构	60
4.3 真机部署流程与联调结果	64
4.3.1 阶段一：Orin 端独立调试	64
4.3.2 阶段一实测结果与分析	64
4.3.3 阶段二：Orin 与 Lite3 联合调试	65
4.4 真实拓扑地图采集与滑动窗口导航	66
4.4.1 导航输入与实时子目标	66
4.4.2 真实拓扑地图的采集与组织	67
4.4.3 滑动窗口导航机制	68

4.5 导航/探索模式与安全机制..... 70

 4.5.1 导航模式与探索模式.....70

 4.5.2 可视化模式与无可视化模式.....70

 4.5.3 安全机制.....70

4.6 真机闭环实验结果..... 71

 4.6.1 真实场景拓扑地图采集71

 4.6.2 多场景目标导航实验.....71

 4.6.3 多场景探索实验73

 4.6.4 室外零样本导航实验.....74

4.7 本章小结..... 76

第 5 章 全文总结与未来展望.....78

 5.1 全文工作总结..... 78

 5.2 主要贡献..... 79

 5.3 研究不足..... 80

 5.4 未来展望..... 80

参考文献.....82

附录 A 人工智能工具使用情况说明85

致 谢.....87

符号对照表

NoMaD	Navigation with Goal Masked Diffusion
DDPM	Denoising Diffusion Probabilistic Model
DDIM	Denoising Diffusion Implicit Model
CFG	Classifier-Free Guidance
TTS	Test-Time Scaling
GNM	General Navigation Model
ViNT	Visual Navigation Transformer
ViT	Vision Transformer
DiT	Diffusion Transformer
DINOv2	Self-Distillation with No Labels v2
MuJoCo	Multi-Joint dynamics with Contact
SLAM	Simultaneous Localization and Mapping
PD	Proportional-Derivative (Controller)
拓扑地图	Topological Map
航点	局部路径点
O_t	时刻 t 的历史视觉观察序列
I_g	目标图像或拓扑节点图像
$\mathbf{A}_t$	未来局部航点轨迹
$\mathbf{a}_i$	第 i 个航点, $(\Delta x_i, \Delta y_i)$
H	轨迹预测 horizon (航点数量)
β_t	扩散前向过程第 t 步噪声调度系数
$\bar{\alpha}_t$	累计噪声调度系数
ϵ	真实高斯噪声
ϵ_θ	模型预测噪声
w	CFG guidance scale
N	TTS 候选轨迹数量
$\hat{d}_j$	距离预测头对第 j 个候选节点的距离估计
cmd_vel	速度控制指令

UDP	User Datagram Protocol
Orin	NVIDIA Jetson Orin 边缘计算平台
Lite3	云深处 Lite3 四足机器人平台

第1章 绪论

1.1 研究背景与意义

随着具身智能、移动机器人和深度学习技术的快速发展，机器人正在从结构化、封闭式的实验室环境走向消防巡检、室内导览、园区巡逻、地下管廊检查和灾后排查等真实应用场景。在这些场景中，机器人不仅要感知周围环境，还要在地图不完备、光照变化明显、有障碍物、通道空间受限以及定位先验较弱的条件下完成自主移动。导航因此不再只是移动机器人“从一点到另一点”的路径计算问题，而是机器人完成巡检、导览、搬运、搜救和服务任务之前必须具备的基础能力。没有稳定的导航能力，感知结果难以转化为有效行动，任务规划也无法落到具体空间执行上。因此，导航逐渐成为连接视觉感知、任务理解、局部决策和底层执行的核心环节^[1]。

从应用需求来看，让机器人进入上述场景具有直接的现实意义。消防巡检、灾后排查和地下管廊检查等任务往往伴随烟尘、高温、有毒气体、坍塌风险或长时间重复劳动，完全依赖人工会带来较高安全成本和人力消耗；室内导览、园区巡逻、楼宇安防和场馆服务等任务虽然危险性较低，但也对连续运行、路径复现和场景适应能力提出了要求。与人相比，机器人可以在危险或重复环境中保持稳定执行，并通过视觉传感器持续记录环境状态，因此适合承担移动感知与目标到达类任务。然而，不同机器人平台对环境的适应能力和工程部署条件存在明显差异，因此有必要进一步明确本文所关注的机器人形态。

从机器人平台类型来看，不同形态的移动机器人具有不同的适用边界。人形机器人在结构上更接近人类，理论上能够适应面向人设计的环境，并完成一定的人机交互任务，但其系统结构复杂、控制难度高，稳定性和工程部署成本仍然较高。轮式底盘机器人结构简单、控制成熟、能耗较低，在平整地面和规则室内环境中具有较好的应用基础，但其运动能力较依赖地面条件，面对台阶、障碍物、碎石、坡道或非结构化地形时通过性受到限制。相比之下，四足机器人在机动性、稳定性和环境适应性之间具有较好的平衡：其足式运动方式能够跨越一定高度的障碍物，适应复杂地面和狭窄空间，同时相比人形机器人具有更低的结构复杂度和更高的工程可部署性。因此，在灾害现场、工业巡检、园区巡逻和室内外混合环境等任务中，四足机器人是一类具有代表性的具身导航平台^[2-4]。

基于上述分析，如何使四足机器人根据简单、直观的目标表达，在真实环境中自

主到达指定位置,是具身导航研究面向工程落地时必须回答的问题。传统移动机器人导航通常依赖全局坐标、度量地图和预设航点。这一路线在仓储物流、工厂搬运、医院配送、商场清洁和室内导览等平整、规则环境中已经形成较成熟的系统链路,轮式平台也在这些场景中承担了重复运输、固定路线巡检和服务引导等角色。然而,在临时巡检、陌生室内空间或弱 GPS 场景中,精确地图往往难以及时获取,普通用户也不容易用坐标描述目标位置。在真实应用中,操作者往往更容易通过目标图像、路线图像或关键场景记忆表达“想让机器人到达哪里”。

视觉目标导航为这一问题提供了更自然的任务表达方式:操作者只需提供目标位置的第一视角图像,或由若干关键图像组成的拓扑地图,机器人便可根据当前图像与目标图像之间的关系生成局部运动。这种“看见某处并走过去”的形式更贴近人的空间记忆方式,也更适合导览复现、巡检路线记录和弱先验环境中的目标到达任务^[5-6]。但是,对于四足平台而言,并不是将轮式导航算法直接更换载体即可使用。四足机器人的步态运动会引入相机抖动和机体俯仰,速度指令与真实位移之间也会存在非线性偏差,高层视觉策略还必须与底层运动主机、通信协议和安全停机机制形成稳定闭环。

近年来,通用视觉导航模型和生成式策略的发展为上述问题提供了新的技术基础。通用导航模型(General Navigation Model, GNM)和视觉导航 Transformer (Visual Navigation Transformer, ViNT)将历史图像观察、目标条件和局部航点预测纳入统一模型^[7-8];目标掩码扩散导航模型(Navigation with Goal Masked Diffusion, NoMaD)进一步引入动作扩散策略,通过条件去噪采样生成多条局部轨迹候选,并利用目标掩码机制(goal mask)统一目标导航与探索行为^[9-10]。与直接回归单一路径相比,扩散式轨迹生成能够描述多模态决策分布,更适合走廊分叉、障碍绕行和目标不确定等情形。然而,现有公开验证仍多集中在轮式平台或离线数据集上,面向四足机器人真实部署时的实时推理、视觉扰动、运动接口适配和安全闭环问题仍需要系统研究。

基于上述背景,本文以 NoMaD 为高层视觉导航模型,以云深处 Lite3 四足机器人作为部署对象,研究在室内狭窄、弱先验、无全局精确地图的环境中,如何将扩散式视觉目标导航模型部署到资源受限且运动扰动明显的四足平台上,使其能够根据真实相机图像与目标图像形成可实时运行、可仿真验证、可真机执行的闭环导航系统。

围绕这一问题,本文的研究意义主要体现在三个层面。首先,在应用层面,本文将视觉目标导航与四足平台结合,使导航任务不再停留于离线图像匹配或仿真指标,而是面向室内巡检、导览和受限空间通行等具体场景。其次,在算法层面,本




图 1.1 四足机器人视觉目标导航目标场景示意图

文关注动作扩散策略在边缘设备上的推理效率和轨迹质量，通过去噪扩散隐式模型（Denoising Diffusion Implicit Model, DDIM）采样加速、无分类器引导（Classifier-Free Guidance, CFG）、测试时扩展（Test-Time Scaling, TTS）候选筛选和视觉编码器替换等实验，分析扩散式导航模型在真实部署中的速度、质量和稳定性权衡。最后，在系统层面，本文构建从统一推理模块、状态机、导航主机、中层控制映射到 Lite3 UDP 运动接口的分层闭环架构，使高层视觉导航策略能够接入 MuJoCo 仿真环境和 Jetson Orin 真机平台，为后续四足视觉导航研究提供可复现的工程基础。

1.2 国内外研究现状

四足机器人视觉目标导航涉及传统导航与视觉 SLAM、学习型视觉导航、通用视觉导航模型、动作扩散策略以及足式机器人真实部署等多个方向。现有研究已经分别在地图构建、目标表达、轨迹生成、跨平台泛化和四足运动控制方面取得了重要进展，但这些方向往往各有侧重：传统导航强调定位建图和规划可靠性，学习型视觉导航强调从图像到动作的策略学习，通用导航模型强调跨场景和跨机器人泛化，四足机器人研究则更多关注底层运动控制和复杂地形通过。本文关注的问题位于这些方向

的交叉处：在弱先验视觉目标导航任务中，如何把生成式视觉导航策略与四足机器人的真实运动执行、边缘计算和安全闭环结合起来，形成可实时运行、可安全执行、可从仿真验证到真机部署的系统。

1.2.1 传统导航、视觉 SLAM 与学习型导航

传统机器人导航通常以状态估计、地图构建、路径规划和运动控制为核心。Thrun 等^[11]建立了概率机器人学框架，使机器人能够在不确定感知和运动条件下进行定位、建图与决策；该工作奠定了传统导航的理论基础，做到了对传感器噪声、运动误差和环境不确定性的概率化建模，但它并不直接解决由目标图像驱动的视觉导航问题，也不直接涉及学习型视觉导航策略在四足平台上的闭环实现。Hess 等^[12]提出 Cartographer，实现了二维激光 SLAM 中实时回环检测和子图优化，在激光雷达配置充分的轮式平台上具有较强工程可靠性；但其重点仍是度量地图构建，并不面向纯视觉单目 RGB 目标图像导航问题。Campos 等^[13]提出 ORB-SLAM3，在视觉、视觉惯性和多地图 SLAM 中取得了较高定位精度；该方法做到了成熟的视觉几何定位，但性能依赖特征质量、标定精度和几何一致性，不以图像目标到达和动作策略生成为核心。

国内研究也对 SLAM、具身导航和机器人导航系统进行了系统梳理。毛军等^[14]总结了惯性、视觉和激光雷达 SLAM 的技术演进，做到了从传感器融合和定位建图角度梳理导航基础能力；但其关注点主要是环境表示与位姿估计，而不是目标图像条件下的端到端导航决策。裴凌和熊超然^[1]从具身导航的概念、方法和挑战出发，指出导航研究正从几何到达转向任务驱动、语义理解与自主决策；该综述为本文研究提供了问题背景，但并未给出四足机器人平台上的视觉导航部署链路。因此，传统导航和 SLAM 工作为机器人自主移动提供了重要基础，但仍需要结合学习型视觉策略和真实平台系统实现，才能支撑本文所关注的弱先验四足视觉目标导航任务。

深度学习方法进一步推动了视觉导航从几何建模向策略学习转变。Zhu 等^[5]提出目标驱动视觉导航方法，利用深度强化学习建立当前图像、目标图像与动作之间的映射；该工作证明了图像目标可以作为导航任务输入，但主要在仿真环境中验证，距离真实四足机器人闭环部署仍有差距。Anderson 等^[15]讨论具身导航智能体的评价问题，推动了导航成功率、路径效率等指标的规范化；该工作做到了评价标准层面的统一，但评价指标本身不能替代真实平台上的感知、通信、控制和安全闭环设计。Wijmans 等^[16]通过大规模分布式强化学习训练点目标导航智能体，在仿真中取得了很高性能；但点目标导航依赖相对坐标目标，而不是视觉目标导航。

1.2.2 视觉目标导航与拓扑记忆

视觉目标导航通过目标图像、目标物体或语言指令描述机器人需要到达的位置。相较于精确坐标，目标图像更适合弱先验环境。陈铂垒等^[17]综述了物体目标导航中的语义地图、强化学习和大模型辅助方法，说明视觉语义目标已经成为具身导航的重要方向。司马双霖等^[18]梳理了视觉语言导航中语言、视觉和路径规划的结合方式，做到了对多模态导航任务的系统总结；但语言目标存在语义歧义和解析成本，本文选择采用目标图像和拓扑图像节点作为更直接的任务表达。

拓扑记忆方法通过关键图像节点组织长程路线，为弱地图先验下的视觉导航提供了重要思路。Savinov 等^[19]提出半参数拓扑记忆 SPTM，利用视觉相似度和局部策略沿记忆图前进；该方法做到了用稀疏视觉节点替代完整度量地图，但局部控制策略和节点质量仍会影响实际执行效果。Chaplot 等^[20]提出神经拓扑 SLAM，将学习表示与拓扑规划结合，在复杂室内场景中构建拓扑图并规划路径；该工作增强了拓扑规划能力，但系统复杂度较高，也并非面向四足平台。Shah 等^[6]提出 ViNG，通过视觉路标和目标图像实现开放世界视觉目标导航，并在真实环境中展示了长程导航能力；该工作做到了目标图像导航和真实机器人验证，但主要面向轮式平台，并未重点讨论四足机器人步态扰动、航点到速度指令映射、安全状态机和真机闭环频率等问题。

因此，视觉目标导航和拓扑记忆已经证明了“用图像表达目标”的可行性。本文并不把局部航点或拓扑节点本身作为研究问题，而是将其作为解决视觉目标导航的手段：系统在拓扑图像序列中选择实时子目标，再由基于目标掩码的扩散策略生成局部动作，并进一步映射为四足机器人可执行的速度指令。

1.2.3 动作扩散策略与通用视觉导航模型

扩散模型为多模态轨迹生成提供了新的建模工具。Ho 等^[21]提出 DDPM，通过逐步加噪和反向去噪学习复杂数据分布，做到了高质量生成建模，但迭代采样会带来较高推理开销。Song 等^[22]提出 DDIM，在不重新训练模型的情况下减少反向采样步数，做到了扩散模型推理加速。Ho 和 Salimans^[23]提出无分类器引导，为条件生成提供了可调的条件增强方式；该方法提升了条件一致性。Chi 等^[10]提出 Diffusion Policy，将扩散模型用于机器人视觉运动控制，做到了以动作序列生成方式表达多模态行为；但该工作主要面向操作控制任务，并不直接解决机器人导航问题。

在视觉导航领域，GNM、ViNT 和 NoMaD 形成了通用导航模型的重要脉络。Shah 等^[7]提出 GNM，尝试用统一模型驱动不同机器人平台，证明了跨机器人视觉导航模

型的可行性；但 GNM 主要采用轨迹回归形式，没有引入动作扩散生成机制，也没有统一目标导航和无目标探索。ViNT^[8]进一步采用 Transformer 融合历史观察和目标图像，做到了更强的时序视觉表征和目标条件建模；但其重点仍是视觉导航基础模型，不以扩散采样优化和真实部署为核心。Sridhar 等^[9]提出 NoMaD，将目标掩码机制与动作扩散策略结合，在同一模型中统一目标导航和无目标探索，做到了用统一扩散策略生成多模态局部轨迹。NoMaD 是本文复现、优化和部署的直接基础；但原工作主要展示通用导航模型能力，公开实验主线更偏向轮式移动平台和通用导航评估，对足式平台上的视觉扰动、速度接口、安全状态和端侧算力约束讨论较少。

近期扩散式视觉导航研究进一步提升了轨迹生成效率和泛化能力。NaviBridger^[24]提出基于去噪扩散桥的视觉导航框架，从有信息的先验动作而非纯高斯噪声开始生成动作序列，做到了在仿真和真实室内外场景中提升推理效率和动作质量；其已有真实机器人实验，但研究重点仍是有目标条件下的扩散桥动作生成，对目标导航与无目标探索的统一系统，以及四足平台闭环部署效率讨论较少。NavDP^[25]提出基于特权信息指导的导航扩散策略，利用大规模仿真数据训练，并强调跨机器人形态的零样本泛化 sim2real，在轮式、四足和人形平台上展示了较强泛化能力。但其核心贡献是大规模仿真训练与跨形态泛化，足式平台更多作为跨形态验证对象；对单目图像目标/拓扑目标驱动的四足闭环系统、速度接口适配和闭环频率评估并非其重点。SIDP^[26]提出自模仿扩散策略，通过奖励引导的自模仿减少对大量采样和后处理筛选的依赖，报告了在 Jetson Orin Nano 上相较 NavDP 更快的纯推理时间，但其重点是路径推理延迟和模型效率，系统层面的真机闭环频率与完整执行链路不是其主要评价对象。因此，本文与这些工作面向的具体问题不同，使用的方法和评价层级也不同：本文更关注这类扩散式视觉导航方法在具体四足机器人平台上的系统部署、闭环效率和 sim2real 实验分析。

1.2.4 四足机器人视觉导航与真实部署

四足机器人研究长期关注运动能力、复杂地形通过和感知运动控制。杨钧杰等^[2]综述了四足机器人的机构设计、步态规划和控制方法，做到了对国内外四足机器人研究脉络的整理；但该综述主要面向运动控制和平台发展，对扩散策略讨论较少。Hwangbo 等^[3]利用强化学习使 ANYmal 获得敏捷动态运动能力，Lee 等^[4]进一步研究四足机器人在复杂地形上的学习型运动控制；这些工作做到了真实四足平台上的鲁棒运动控制，但没有把目标图像导航作为高层导航问题来处理。Miki 等^[27]通过感知与本体信息融合提升四足机器人野外通过能力，说明视觉和地形感知对足式机

器人具有重要价值；但其关注点是复杂地形中的感知运动控制，而不是导航的闭环部署。

近年来，四足视觉导航和多模态四足机器人任务开始受到更多关注。Ren 等^[28]提出分层视觉导航系统，将视觉导航与落足点适应学习结合，用于提升四足机器人在复杂环境中的导航能力；该工作做到了四足平台上的视觉导航与落足适应结合，但其重点是视觉导航与落足控制协同，对图像目标条件下的生成式轨迹分布和边缘部署效率讨论较少。Kareer 等^[29]提出 ViNL，将视觉导航与越障运动控制结合，使四足机器人能够在室内障碍环境中执行导航任务；该工作证明了四足视觉导航的可行性，但重点是视觉导航和运动控制协同训练，并非面向目标图像/拓扑图像驱动的扩散式导航部署。DiPPeST^[30]提出面向四足机器人的图像与目标条件扩散轨迹规划器，并通过视觉伺服框架进行了真实四足机器人执行验证，说明扩散轨迹生成确实已经被用于四足机器人路径规划；但它更偏向扩散路径规划器和视觉伺服框架本身，对目标图像或拓扑节点驱动的导航闭环、边缘设备效率和系统失败模式分析仍不充分。QUAR-VLA^[31]提出四足机器人的视觉-语言-动作模型和多任务数据集，将视觉、语言和动作结合起来生成可执行动作；该工作拓展了四足机器人多模态任务能力，但其重点是 VLA 范式和语言条件任务，不是面向弱先验室内场景的单目图像目标导航部署。

综上，现有研究已经证明了四足机器人可以进行视觉导航，也证明了扩散策略可以用于导航和轨迹生成。从真实部署角度看，仍有三个方面值得进一步系统化讨论：第一，视觉目标导航与四足机器人研究多沿着各自路线推进，前者更关注目标表达、策略学习和跨场景泛化，后者更关注运动控制、落足适应和复杂地形通过，弱先验图像目标任务下高层视觉决策与足式执行接口之间的耦合关系仍需要结合具体平台分析；第二，扩散式导航研究多强调模型结构、训练规模、采样策略或纯推理时间，边缘计算部署、采样加速、候选筛选、速度指令映射和安全状态管理在同一真实闭环链路中的综合评估仍有进一步展开空间；第三，已有 sim2real 工作通常更重视跨平台泛化能力，针对具体四足平台从仿真到真机的闭环频率、任务成功率、失败模式和工程边界的系统化分析仍可补充。本文正是围绕这些问题展开，构建面向四足机器人的扩散式视觉目标导航闭环系统，完成目标导航与探索统一推理链路的部署优化与平台适配，并给出从仿真到真实四足机器人的系统验证与分析。

1.3 本文主要贡献

针对四足机器人在弱先验环境中的视觉目标导航部署问题，本文并不试图提出规模更大的通用导航基础模型，而是面向真实四足机器人平台，围绕扩散式视觉目标导航策略的闭环部署、推理优化、平台适配和 `sim2real` 验证开展研究。本文主要贡献如下：

1. 构建了面向四足机器人的扩散式视觉目标导航闭环系统。本文围绕四足机器人视觉目标导航任务，构建了从视觉观测、目标图像输入、扩散式动作生成到底层运动控制的完整闭环系统。系统以单目 RGB 图像和目标图像为输入，通过视觉编码、距离预测和扩散策略生成局部导航动作，并进一步转换为四足机器人可执行的速度控制指令，实现了扩散式视觉导航方法在真实四足机器人平台上的系统化落地。本文以云深处 Lite3 作为具体实验平台完成验证。
2. 完成了基于目标掩码的扩散策略统一推理链路的部署优化与四足平台适配。针对基于目标掩码的扩散式视觉导航策略在真实机器人部署中存在的推理延迟、动作接口不匹配和任务状态切换等问题，本文构建了统一推理链路，并完成了面向四足机器人平台的适配。
3. 给出了扩散式视觉导航策略从仿真到真机的系统验证与分析。本文在仿真环境和真实四足机器人平台上对所构建系统进行了验证，分析了不同扩散采样方式和推理配置对导航成功率、推理效率与闭环运行频率的影响。实验结果表明，经过部署优化后的系统能够在真实场景中完成视觉目标导航与探索任务，并在真机闭环中达到最高 6.80 Hz 的运行频率。同时，本文进一步分析了方法在光照变化、视角差异、目标图像匹配误差和底层运动控制误差等因素下的局限性，为扩散式视觉导航策略的 `sim2real` 部署提供了实验依据。

1.4 论文章节安排

本文整体内容按照“问题提出—统一推理模块构建—系统闭环验证—真机部署—总结展望”的逻辑展开，共分为五章。各章节之间的逻辑结构关系如图 1.2 所示。第一章首先明确研究场景与问题边界，第二章围绕高层视觉导航策略构建基于动作扩散策略的统一视觉目标导航推理模块，第三章进一步将算法接入四足机器人闭环系统并完成仿真验证，第四章面向真实硬件平台完成部署与实验，第五章在前文结果基础上总结全文并讨论后续研究方向。

第一章为绪论，介绍四足机器人视觉目标导航的研究背景与意义，梳理传统导



图 1.2 本文各章节逻辑结构关系

航、视觉目标导航、动作扩散策略和四足真实部署等方向的国内外研究现状，并明确本文的研究问题、主要贡献和章节结构。

第二章围绕基于动作扩散策略的统一视觉目标导航推理模块展开，首先给出视觉目标导航、拓扑地图、航点、扩散模型和 NoMaD 机制等必要背景，随后介绍数据集、实验设备、基线推理验证、DDIM、CFG、TTS 与视觉编码器替换等推理模块实验。

第三章介绍基于分层架构与 MuJoCo 仿真的四足机器人视觉导航闭环系统设计与验证，说明轮式平台与足式平台的部署差异、Lite3 平台基础、统一推理模块、状态机、导航主机、中层控制映射、MuJoCo 仿真平台和闭环实验结果。

第四章给出 Jetson Orin 与 Lite3 真机部署流程，说明真机系统双链路、Orin 部署架构、真实拓扑地图构建、滑动窗口导航、速度指令下发、安全机制和真实环境实验结果。

第五章总结全文工作，归纳本文在算法优化、系统集成和真机验证方面的成果，并讨论后续可进一步拓展的研究方向。

1.5 本章小结

本章首先从具身智能和真实应用需求出发，说明了四足机器人视觉目标导航在消防巡检、室内导览和受限空间通行等场景中的研究价值，并进一步分析了视觉目标表达、四足平台形态和动作扩散策略带来的机遇与挑战。随后，本章按照导航建模、目标表达、扩散策略和四足部署的技术逻辑，对国内外相关研究进行了梳理，指出现

有工作在真实四足平台上的扩散式视觉目标导航部署方面仍存在研究空间。最后，本章明确了本文面向 Lite3 四足机器人的研究内容和章节安排，为后续章节展开奠定基础。

第2章 基于动作扩散策略的统一视觉目标导航推理模块

2.1 问题分析

在视觉目标导航任务中，高层策略需要根据当前图像、历史观察和目标图像生成可执行的局部运动。若直接回归单一速度或单一路径，模型在走廊分叉、遮挡、目标不确定等场景中容易把多个合理动作平均为一条不合理轨迹。动作扩散策略为这一问题提供了新的实现方式：它不把导航决策看成单点回归，而是把未来航点序列看成条件生成结果，通过逐步去噪从多模态轨迹分布中采样可执行候选。因此，本章首先面对的问题不是完整系统如何部署，而是如何将动作扩散策略组织为可被后续系统复用的统一视觉目标导航推理模块，并对其推理质量与效率进行评价。

围绕这一问题，已有方法 NoMaD 将视觉编码、距离预测和动作扩散策略组织在同一导航模型中，使机器人能够在目标图像或拓扑地图条件下生成局部航点轨迹。但对本文而言，直接使用 NoMaD 还不够：一方面，需要先建立其基础推理链路，弄清视觉编码器、距离预测头、扩散策略头、视觉掩码（goal mask）与航点输出之间的关系，形成可对照的离线基线；另一方面，原始扩散采样存在迭代次数多、推理耗时高的问题，若后续部署到 Jetson Orin 等资源受限平台，必须进一步分析采样步数、条件引导、候选筛选和视觉编码器规模之间的取舍。

由此，本章的核心挑战可以概括为三点。第一是实现问题，即把视觉目标导航形式化为条件轨迹分布学习问题，并建立 NoMaD 从图像输入到航点输出的完整推理流程。第二是效率问题，即在不破坏轨迹质量的前提下，通过 DDIM、CFG、TTS 和视觉编码器替换等方法降低扩散推理开销或提升候选质量，使算法具备进入边缘平台闭环的可能。第三是解耦问题，即本章得到的算法配置不能停留在离线实验流程中，而应被整理为后续系统层可以封装调用的高层推理模块，使其输出与四足平台的中层控制和底层通信保持接口独立。

基于上述分析，本章按“任务定义—模型机制—基线实验—优化实验—消融分析—框架确定”组织内容。先定义视觉目标导航任务和航点表示，再说明 NoMaD 的扩散建模机制；随后在 GoStanford 数据集上建立基线推理结果，并围绕 DDIM 采样加速、CFG 条件引导、TTS 推理时搜索和视觉编码器升级开展对比实验；最后通过联合消融确定可进入第三章 MuJoCo 闭环验证和第四章 Lite3 真机部署的默认算法配置。

2.2 视觉目标导航任务定义与航点表示

2.2.1 视觉目标导航任务定义

机器人导航的目标是在给定观察、任务目标和运动约束的条件下，使机器人从当前状态移动到目标区域。一个完整导航系统通常涵盖环境感知、状态表示、目标表达、局部决策与运动执行五个环节^[11,15]。在输出形式上，高层导航策略可以输出底层控制量、局部路径点或局部轨迹序列；本文让高层模型输出局部航点轨迹，再由中层控制器完成执行映射。

如果把高层策略写成函数形式，则有

$$\pi : (O_t, g) \mapsto A_t, \quad (2.1)$$

其中 O_t 表示时刻 t 的图像观察或观察序列， g 表示任务目标， A_t 表示未来短时间内的局部轨迹。该表示天然适合与不同平台解耦，也是本文能够将高层视觉导航从轮式框架迁移到 Lite3 四足平台的重要原因。

观察空间方面，本文统一使用 RGB 图像作为输入，并保留最近 $K + 1$ 帧上下文 $O_t = \{I_{t-K}, \dots, I_t\}$ 。每个航点 $\mathbf{a}_i = (\Delta x_i, \Delta y_i)$ 表示相对于机器人当前位姿的二维增量位移（ x 前向、 y 左侧），策略输出因此不依赖全局定位。执行上采用闭环模式：每个高层周期生成长度 $H = 8$ 的航点序列，固定取第 $k = 2$ 个航点作为本次控制周期的局部目标位移，由中层 PD 控制器映射为速度指令；下一周期再基于最新相机帧重新生成。这种“规划长 8 步、每周期只执行其中一个超前点”的策略与模型预测控制（MPC）一脉相承，扩散策略相当于把 MPC 的优化求解替换为条件扩散采样。

视觉导航以图像作为主要环境输入，并基于视觉信息完成导航决策^[5,15]。目标导航则进一步关注目标的给出形式，常见类别包括：

- **点目标（point-goal）导航**^[16]：目标以坐标点形式给出，要求机器人到达指定位置；
- **图像目标（image-goal）导航**：目标以一张或多张图像给出，要求机器人到达图像所对应的位置；
- **物体目标（object-goal）导航**：目标以物体类别给出（如“找到冰箱”），需要语义理解能力；
- **语言目标（language-goal）导航**：目标以自然语言指令给出，是最灵活但也最具挑战的形式。

本文研究 image-goal 场景：相较于绝对坐标，图像目标更符合真实应用——用户更容

易给出“到达目标图像对应的位置”，而非统一坐标系下的精确终点；相较 object-goal 与 language-goal，图像目标无需语义理解模块、表达歧义更低，能在无 GPS 与无预建地图的场景中直接工作。

本文关注的核心任务是：给定机器人当前视觉观察、短历史观察和目标图像，生成一段局部航点轨迹，并将其作为中层控制器的参考输入。沿用 NoMaD 的基本思想^[9]，本方法不直接预测单步速度命令，而是学习条件轨迹分布

$$p(\mathbf{A}_t \mid \mathbf{O}_t, I_g), \quad (2.2)$$

其中 $p(\cdot)$ 表示条件概率分布， $\mathbf{O}_t$ 表示时刻 t 的历史视觉观察， I_g 表示当前控制周期使用的目标图像，在拓扑导航中是拓扑地图序列上“当前定位的下一节点”图像， $\mathbf{A}_t$ 表示未来局部航点序列。

从马尔可夫决策过程（Markov Decision Process, MDP）的视角来看，视觉导航可以被建模为一个元组 $\mathcal{M} = (\mathcal{S}, \mathcal{A}, T, R, \gamma)$ ，其中 $\mathcal{S}$ 表示状态空间（即视觉观察空间）， $\mathcal{A}$ 表示动作空间， T 表示转移概率， R 表示奖励函数， γ 表示折扣因子。在本文的框架中，策略 π 不是直接在 MDP 上求解单步最优动作，而是学习一个条件轨迹分布 $p(\mathbf{A}_t \mid \mathbf{O}_t, I_g)$ ，这种分布式策略具有天然的多模态建模能力。

具体来说，条件轨迹分布与传统 MDP 策略之间的联系可通过以下关系理解：若将未来 H 步动作序列视为一个联合决策变量，则条件轨迹分布相当于在扩展动作空间 $\mathcal{A}^H$ 上的策略。与逐步递推不同，这种联合建模能够在单次推理中捕获全局轨迹结构，避免了自回归策略中误差累积的问题。形式上：

$$p(\mathbf{A}_t \mid \mathbf{O}_t, I_g) = p(\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_H \mid \mathbf{O}_t, I_g), \quad (2.3)$$

其中 $p(\cdot)$ 表示条件概率分布， H 表示未来预测步数， $\mathbf{a}_i$ 表示第 i 个局部航点。每个 $\mathbf{a}_i$ 并非独立采样，而是通过扩散过程的联合去噪一次性生成。

这种建模方式与经典的行为克隆（Behavioral Cloning）策略存在本质区别。行为克隆通常将策略参数化为确定性映射 $\pi_\theta : \mathcal{O} \rightarrow \mathcal{A}$ 或简单的高斯分布，只能表达单峰的动作分布。而基于扩散模型的条件生成策略通过迭代去噪过程，能够从复杂的多模态分布中采样，天然适合处理导航任务中的分支决策场景。此外，扩散模型的训练目标（噪声预测损失）在数值上比最大似然目标更稳定，不容易出现模式坍塌（mode collapse）问题。

2.2.2 拓扑导航与拓扑地图表示

为了降低对精确几何地图的依赖，拓扑导航只保留若干代表性视觉节点及其连通关系^[6,19-20]。本文系统中的拓扑地图不是部署时由编码器在线生成的图结构，而是人工沿目标路径预先采集的一段**有序**视觉节点序列，文件名按 0.png, 1.png, ... 自然排序，节点编号同时编码“沿路径前进的方向”，因此拓扑地图在使用上更接近一条按空间顺序排好的导航队列。

设拓扑节点图像沿路径排列为 $\mathcal{G} = (I_g^{(0)}, \dots, I_g^{(M-1)})$ ，导航任务给定起点附近索引 0 与目标索引 $g \leq M-1$ 。系统维护一个状态化的“当前定位”指针 c_t ，距离预测头只在以 c_t 为中心、半径 r 的局部窗口

$$\mathcal{W}_t = \{j : \max(c_t - r, 0) \leq j \leq \min(c_t + r + 1, g)\} \quad (2.4)$$

式中， $\mathcal{W}_t$ 表示第 t 个控制周期的候选节点窗口， j 为候选节点索引， c_t 为当前定位指针， r 为窗口半径， g 为目标节点索引； $\max(\cdot)$ 与 $\min(\cdot)$ 用于保证窗口不越过拓扑地图的起止边界。本文取 $r = 4$ ，使得候选节点窗口兼顾执行效率与鲁棒性。在窗口内对当前观察 $\mathcal{O}_t$ 与每个候选节点 $I_g^{(j)}$ 计算距离预测 $\hat{d}_j$ ，并据此更新定位：

$$c_{t+1} = \text{clip}(\arg \min_{j \in \mathcal{W}_t} \hat{d}_j, c_t - 1, c_t + \Delta_{\max}), \quad (2.5)$$

其中 c_{t+1} 表示更新后的定位指针， $\hat{d}_j$ 表示当前观察到候选节点 j 的预测距离， $\arg \min$ 选择预测距离最小的候选节点， $\text{clip}(\cdot)$ 将结果限制在 $[c_t - 1, c_t + \Delta_{\max}]$ 内；本文取 $\Delta_{\max} = 3$ ，使定位指针每周期至多前进 3 个节点、至多回退 1 个节点，从而强制定位整体沿拓扑地图单向推进。

2.2.3 航点表示的优势分析

本文选择航点序列作为策略输出形式，而非直接预测底层速度命令（如线速度 v 和角速度 ω ），这一设计决策基于以下三点考量。

第一，平台无关性。航点表示为局部坐标系下的二维位移序列，不与任何特定的运动学模型绑定。无论下游执行平台是差分驱动的轮式机器人还是具有复杂运动学的足式机器人（如 Lite3），同一条航点轨迹都可以通过不同的中层控制器进行跟踪。这种解耦使得高层策略的训练数据可以跨平台复用。

第二，多模态表达能力。在面对 T 形路口或走廊分叉等场景时，合理的导航行为可能包含“左转”和“右转”两个互不相容的模式。若使用单步速度命令的均值回归策




图 2.1 导航任务输入输出与拓扑地图关系示意图

略，两个模态的平均结果可能是“直行撞墙”。而航点序列结合扩散模型的生成能力，能够保留这种多模态分布，通过采样不同轨迹来表达不同的决策意图。

第三，闭环控制的友好性。中层控制器（如 PID 控制器或 MPC）可以直接将航点序列作为参考路径进行跟踪，这比将高层策略输出的速度命令直接下发到底层更加鲁棒，因为航点跟踪器可以根据实际执行情况进行局部修正。

航点序列还提供了比单步动作更丰富的决策信息。单步速度命令仅编码了当前时刻的瞬时意图，而航点序列编码了未来一段时间窗口内的完整运动意图。这种“前瞻性”信息对于中层控制器的预测性规划至关重要——控制器可以提前预判即将到来的转弯或减速需求，从而生成更平滑的底层控制信号。特别是对于足式机器人，步态切换和身体姿态调整需要提前规划，单步速度命令无法提供足够的前瞻信息。

围绕这一任务，本文在推理模块层面的工作可概括为三部分。第一，建立 NoMaD 的训练与推理基线，明确视觉编码器、距离预测头与扩散策略头之间的关系。第二，围绕部署可用性对推理层进行优化，重点研究 DDIM 推理、CFG 引导增强和 TTS 推理时搜索。第三，围绕视觉表征能力设计视觉编码器升级实验，并与基线配置进行对比。




图 2.2 NoMaD 算法研究对象与数据流示意图

2.3 动作扩散策略与 NoMaD 模型机制

2.3.1 扩散模型与动作扩散策略

扩散模型基本原理 扩散模型通过“逐步加噪、逐步去噪”的方式学习复杂分布^[21]。在训练阶段，模型先把真实样本 x_0 按照噪声调度扰动为 x_t ，再学习在给定条件 c 和时间步 t 时预测加入的噪声。常用噪声预测损失可写为

$$\mathcal{L}_{\text{diff}} = \mathbb{E}_{x_0, \epsilon, t} [\|\epsilon - \epsilon_\theta(x_t, t, c)\|_2^2], \quad (2.6)$$

其中 ϵ 为真实噪声， ϵ_θ 为模型预测噪声， c 表示条件信息。与图像生成不同，本文中的 x_0 不是高维像素，而是局部航点轨迹

$$\mathbf{A} = [\mathbf{a}_1, \dots, \mathbf{a}_H] \in \mathbb{R}^{H \times 2}. \quad (2.7)$$

因此，扩散过程发生在低维轨迹空间中：前向过程向航点序列添加噪声，反向过程在视觉条件约束下逐步恢复出可执行的局部轨迹。本文采用的 NoMaD 配置中训练扩散步数为 $T = 10$ ，远小于通用图像扩散模型常见的千步量级，这也是其能够进入实时导航部署讨论的前提。

将扩散模型用于导航时，其价值不在于生成视觉图像，而在于表达导航动作的多模态分布。具体而言，动作扩散策略在导航任务中具有以下优势：

1. **多模态决策：**在走廊分叉、障碍绕行或目标视角不确定时，多个局部动作都可能合理，扩散策略可以通过采样保留不同候选，而不是把它们平均成一条不可执行轨迹；
2. **时序一致性：**扩散对象是一段航点序列，而不是单个速度值，因此模型能够一次性生成具有前瞻性的局部轨迹，便于后续控制器跟踪；
3. **条件生成：**历史观察、目标图像或拓扑节点图像可以作为去噪条件输入，使轨迹生成直接受到视觉目标约束；
4. **部署可调：**采样步数、条件引导和候选筛选都可以在推理阶段调整，为边缘设备上的速度-质量权衡提供空间。

扩散采样与推理加速 DDPM 使用完整反向扩散链生成样本，采样质量较稳定，但推理开销较高^[21]。DDIM 在不重新训练模型的前提下，通过跳步采样减少反向去噪步数，从而显著降低推理时间^[22]。本文后续所说的“DDIM 推理加速”，即是在保持 NoMaD 已训练权重不变的条件下，把原始 $T = 10$ 步采样压缩为 $S = 5/3/2/1$ 等较少步数，并观察轨迹质量与推理时延之间的变化。

对于导航部署而言，DDIM 的意义不是单纯追求更快的模型推理，而是为闭环控制争取时间预算。真实机器人每个高层周期还包含相机读取、图像预处理、距离预测、航点到速度指令映射和通信下发等环节；因此扩散采样步数越少，系统越容易在边缘计算平台上形成稳定闭环。但步数过少也会造成轨迹退化，本文后续实验将专门比较 DDIM-1、DDIM-2、DDIM-3、DDIM-5 与 DDPM-10 的差异。

Classifier-Free Guidance Classifier-Free Guidance (CFG) 最初用于条件生成任务中的引导增强^[23]。其思想是在训练阶段同时学习有条件与无条件预测，在推理阶段通过两者线性组合增强条件约束。若条件分支噪声预测为 ϵ_{cond} ，无条件分支为 ϵ_{uncond} ，则引导后的噪声预测写为

$$\epsilon_{\text{cfg}} = (1 + w)\epsilon_{\text{cond}} - w\epsilon_{\text{uncond}}, \quad (2.8)$$

其中 ϵ_{cfg} 表示引导后的噪声预测， ϵ_{cond} 表示条件分支噪声预测， ϵ_{uncond} 表示无条件分支噪声预测， w 为引导强度。当 $w = 0$ 时退化为普通条件推理；当 $w > 0$ 时，模型会更强地朝向条件约束；当 w 过大时，也可能带来分布偏移与不稳定。

在本文中, CFG 的作用是增强轨迹对目标图像的牵引能力。由于 NoMaD 训练时已经引入 goal mask, 推理时可以把带目标图像的预测视为条件分支, 把目标 token 替换为掩码 token 的预测视为无目标分支。需要注意的是, 这里的“无目标”并非完全无信息: 模型仍然接收历史观察, 只是失去显式目标图像。因此 CFG 增强的是目标方向性, 而不是重新定义整体行为先验。该机制与后文导航模式/探索模式的统一部署直接相关。

扩散策略与 Test-Time Scaling 扩散策略将扩散模型从图像生成推广到动作序列或轨迹序列生成^[10,32]。在具身智能与机器人控制领域, Diffuser 和 Diffusion Policy 表明扩散建模能够有效处理多步决策、长时序动作和多模态行为分布, 因此被视为扩散模型在具身控制中的代表性应用。

具体而言, Diffuser^[32] 将整个轨迹作为扩散对象, Diffusion Policy^[10] 则只对动作序列进行扩散, 并把视觉观察作为条件信息。NoMaD 的扩散策略头采用了类似后者的思路: 视觉编码器先把历史观察和目标图像压缩为条件向量, 扩散头再在该条件下生成未来局部航点序列。这样, 扩散模型负责高层局部决策, 中层控制器再把航点转为实际速度指令, 形成与不同机器人平台解耦的接口。

在此基础上, 近年来出现了测试时扩展 (Test-Time Scaling, TTS) 的思路^[33-34]。其核心思想不是修改训练过程, 而是在推理阶段使用额外计算预算生成多条候选轨迹, 再通过打分函数进行选择。本文采用的是其中的 best-of-N 形式, 即从多条候选航点轨迹中选择评分最高者用于执行。若生成 N 条候选轨迹 $\{\mathbf{A}^{(i)}\}_{i=1}^N$, 评分函数为 $s(\cdot)$, 则最优轨迹可表示为

$$\mathbf{A}^* = \arg \max_{i \in \{1, \dots, N\}} s(\mathbf{A}^{(i)} | \mathbf{O}_t, I_g). \quad (2.9)$$

其中 $\mathbf{A}^*$ 表示被选中的最优候选轨迹, $\mathbf{A}^{(i)}$ 表示第 i 条候选轨迹, N 表示候选轨迹数量, $s(\cdot)$ 表示评分函数, $\mathbf{O}_t$ 表示当前历史观察, I_g 表示目标图像。

在导航场景中, TTS 的评分函数不需要重新训练模型, 而是可以利用轨迹几何属性和模型已有输出构造代理指标。例如, 前向进展反映轨迹是否朝目标方向移动, 平滑性反映相邻航点方向变化是否过大, 目标一致性则反映候选轨迹是否更接近目标图像或拓扑节点。本文后续实验关注的不是无限增加候选数量, 而是在边缘设备预算内判断 TTS-8、TTS-16 等配置是否能用较小代价改善候选选择。

需要强调的是, TTS 与 DDIM、CFG 作用位置不同。DDIM 决定“怎么采样”, CFG 决定“采样时如何增强条件”, 而 TTS 决定“采样出多条候选后如何选择”。因此三者

虽然都属于推理时优化，但不是简单相加关系，而是具有先后层次的组合关系。

扩散模型、视觉 Transformer 与导航建模的关系 扩散策略在视觉导航中并不是孤立使用的，它需要与视觉编码器共同工作。ViNT 使用 Transformer 融合历史观察与目标图像^[8]，NoMaD 则在此基础上加入动作扩散策略^[9]，使视觉条件不再只服务于单一路径回归，而是作为去噪过程的条件输入。由此可见，本文后续讨论的视觉编码器升级、DDIM 采样加速、CFG 条件引导、TTS 候选筛选和四足平台部署，实际上对应同一条链路中的不同环节：先获得可靠视觉条件，再生成多模态航点候选，最后在实时闭环中选择并执行。




图 2.3 扩散模型、扩散策略、ViT 编码器与 NoMaD 系统之间的技术演化关系。从左到右依次为基础扩散理论（DDPM/DDIM）、条件引导方法（CFG）、扩散策略（Diffusion Policy）以及 NoMaD 的架构

2.3.2 NoMaD 基础模型结构

NoMaD 由视觉编码器、距离预测头和扩散策略头三部分构成^[9]。视觉编码器负责把历史观察与目标图像编码为统一条件特征；距离预测头估计当前观察与目标之间的相对距离（以离散时间步数为单位，表示从当前位置到达目标大约需要多少个导航步骤，而非物理距离）；扩散策略头则在该条件特征上生成未来局部航点轨迹。若记局部轨迹为

$$\mathbf{A} = [\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_H], \quad \mathbf{a}_i = (\Delta x_i, \Delta y_i), \quad (2.10)$$

其中 $\mathbf{A}$ 表示完整的局部轨迹序列, $\mathbf{a}_i$ 表示第 i 个航点, H 表示预测步数, Δx_i 和 Δy_i 分别表示机器人局部坐标系下的前向与横向位移增量。则 NoMaD 学习的是条件分布

$$p(\mathbf{A} | \mathbf{O}_t, I_g). \quad (2.11)$$

式中, $p(\cdot)$ 表示条件轨迹分布, $\mathbf{O}_t$ 表示当前历史观察序列, I_g 表示目标图像。

在 NoMaD 的视觉编码器部分, 其底层基于 ViNT 的 Transformer 架构。具体而言, 每帧观察图像首先通过卷积神经网络 (Convolutional Neural Network, CNN) 或视觉 Transformer (Vision Transformer, ViT) 前端提取特征图, 再经过全局池化与线性投影映射为统一的 token 表示。若历史上下文长度为 K , 则模型将当前帧及其之前的 K 帧图像编码为观察 token; 目标图像与当前帧共同编码为目标 token。这些 token 被拼接为一个统一的序列, 送入 Transformer 编码器进行联合注意力计算。形式化地, 令观察 token 序列为 $\{\mathbf{z}_{\text{obs}}^{(k)}\}_{k=0}^K$, 目标 token 为 $\mathbf{z}_{\text{goal}}$, 则 Transformer 编码器的输入为

$$\mathbf{Z}_{\text{input}} = [\mathbf{z}_{\text{obs}}^{(0)}; \mathbf{z}_{\text{obs}}^{(1)}; \dots; \mathbf{z}_{\text{obs}}^{(K)}; \mathbf{z}_{\text{goal}}], \quad (2.12)$$

其中 $\mathbf{Z}_{\text{input}}$ 表示送入 Transformer 编码器的 token 序列, $\mathbf{z}_{\text{obs}}^{(k)}$ 表示第 k 帧历史观察对应的观察 token, $\mathbf{z}_{\text{goal}}$ 表示目标 token, K 为历史上下文长度参数; 该序列共 $K + 2$ 个 token。经过多层自注意力后, 输出的 token 表征即为共享条件空间中的统一条件特征。

在 ViNT^[8] 的原始设计中, Transformer^[35] 编码器采用多层标准自注意力结构。每帧图像经过 EfficientNet-B0^[36] 前端后形成图像特征, 再由线性投影映射为 Transformer 可处理的 token。为了区分不同时间步的观察, 模型为各帧 token 添加帧级位置编码。Transformer 的输出 token 经过池化后产生固定维度的条件向量, 该向量同时被距离预测头和扩散策略头使用, 因此视觉编码器的表征质量会同时影响目标距离估计与局部轨迹生成。

输入输出形式 根据本文基线设置, NoMaD 的输入由历史视觉观察与目标图像构成。实验中采用当前帧及其前三帧作为历史观察序列, 并在导航模式下额外输入目标图像。输出则为固定长度的局部轨迹序列, 每个航点用局部坐标系下的二维位移表示:

$$\mathbf{a}_i = (\Delta x_i, \Delta y_i), \quad i = 1, \dots, H. \quad (2.13)$$

式中, $\mathbf{a}_i$ 表示第 i 个局部航点, Δx_i 与 Δy_i 分别表示局部坐标系下前向和横向位移, H 表示预测轨迹长度。整段轨迹写为

$$\mathbf{A} = [\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_H]. \quad (2.14)$$

式中, $\mathbf{A}$ 表示由 H 个航点组成的完整局部轨迹。

这一表示的优点在于, 它比直接输出底层速度命令更适合作为平台无关的高层接口, 也比全局路径更适合闭环局部控制。对于足式平台, 高层输出局部轨迹、中层完成控制映射的方式尤为关键。

视觉编码器架构 NoMaD 默认采用 EfficientNet-B0 作为视觉编码器骨干^[36]。EfficientNet-B0 是 EfficientNet 系列的基础模型, 通过复合缩放 (compound scaling) 策略在深度、宽度和分辨率三个维度上进行统一缩放, 在 ImageNet 上以约 5.3 M 参数量达到了优异的精度-效率平衡。其核心构建块为移动倒置瓶颈卷积 (Mobile Inverted Bottleneck Convolution, MBConv), 采用深度可分离卷积和 Squeeze-and-Excitation 注意力模块。

在 NoMaD 的视觉编码流程中, 内部实例化了两个 EfficientNet-B0: 一个只处理单帧观察 (3 通道输入), 另一个处理 “最后一帧观察 + 目标图像” 的 6 通道拼接输入。二者权重独立、架构几乎相同, 只在输入卷积的通道数上有差别。这一设计使得目标分支在特征层就完成了当前帧与目标帧的早期融合, 但也使得视觉编码器部分的参数量近似等于两个 EfficientNet-B0 之和, 再加上一个输出投影层 (将 1280 维骨干网络特征压缩到 256 维 token 维度)。

两个 EfficientNet-B0 接收 96×96 的 RGB 图像作为输入, 提取特征后分别输出一个固定维度的视觉表示。该特征向量随后被投影为标准化的 token 表示, 用于后续的条件拼接。具体而言, 每帧观察图像经过第一个编码器后得到特征 $\mathbf{z}_i \in \mathbb{R}^d$, 其中 d 为 token 维度 (本文配置下 $d = 256$); 目标 token $\mathbf{z}_g$ 由第二个编码器以相同方式得到。

选择 EfficientNet-B0 而非更大的 EfficientNet 变体 (如 B3 或 B5) 是出于推理效率的考虑。在边缘设备上, 视觉编码器的计算开销直接影响整体推理频率, 而 B0 的 5.3 M 参数量在精度与效率之间提供了合理的折中; 由于 NoMaD 中需要同时维护两个 EfficientNet-B0 实例, 骨干规模的选择对整体部署时延具有放大效应, 这进一步佐证了 B0 作为默认选型的合理性。

Token 构建与条件拼接 NoMaD 的视觉条件编码器由观察编码器和目标编码器两部分组成。观察编码器独立处理历史观察帧, 目标编码器则把当前帧与目标图像共同作为输入, 使目标 token 同时携带 “当前在哪” 和 “要去哪” 两类信息。这种早期融合方式有助于减轻后续自注意力层的建模负担。

历史观察 token 与目标 token 经位置编码后送入 Transformer 自注意力编码器, 再

对所得序列做自注意力（Self-Attention, SA）编码与平均池化（Average Pooling, Avg-Pool），得到固定维度的视觉条件向量：

$$\mathbf{c} = \text{AvgPool}(\text{SA}([\mathbf{z}_{t-K}, \dots, \mathbf{z}_t, \mathbf{z}_g])). \quad (2.15)$$

其中 $\mathbf{c}$ 表示池化后的视觉条件向量， $\mathbf{z}_{t-K}$ 到 $\mathbf{z}_t$ 表示历史观察 token， $\mathbf{z}_g$ 表示目标 token， $\text{SA}(\cdot)$ 表示自注意力编码器， $\text{AvgPool}(\cdot)$ 表示平均池化操作。这一条件向量同时作为距离预测头和扩散策略头的输入。

距离预测头与模型训练目标 距离预测头与扩散策略头共享同一条视觉条件空间，这意味着视觉编码器的改动会产生连锁效应。假设原始编码器输出的条件特征维度为 d_{orig} ，新编码器输出维度为 d_{new} ，则即使通过线性投影层将 d_{new} 映射到 d_{orig} ，投影后的特征分布也与原始特征不同。距离预测头是一个在原始特征分布上训练的回归网络，输入分布的偏移会直接导致距离预测不准确。因此，本文在编码器升级实验中采用端到端微调策略，同时更新编码器适配层、距离预测头和扩散策略头的参数。这种端到端微调策略虽然计算成本较高，但确保了三个组件在新的特征空间中重新对齐，避免了因局部更新导致的性能退化。

NoMaD 由视觉编码器、距离预测头和扩散策略头三部分组成^[9]。视觉编码器负责将历史观察与目标条件编码为统一特征；距离预测头输出当前观察到目标的相对距离估计；扩散策略头在该条件上生成局部轨迹样本。

训练时，总损失由距离回归损失与扩散噪声预测损失组成，可写为

$$\mathcal{L} = \alpha \mathcal{L}_{\text{dist}} + (1 - \alpha) \mathcal{L}_{\text{diff}}. \quad (2.16)$$

其中 $\mathcal{L}$ 表示总训练损失， $\mathcal{L}_{\text{dist}}$ 约束候选目标排序能力， $\mathcal{L}_{\text{diff}}$ 约束局部轨迹生成质量， α 表示距离损失与扩散损失之间的权重系数。

关于损失权重 α 的选择策略，需要注意以下两点。首先， $\mathcal{L}_{\text{dist}}$ 通常采用 L_1 或 L_2 回归损失，其数值尺度与扩散噪声预测损失 $\mathcal{L}_{\text{diff}}$ 存在差异，因此 α 实际上同时承担了任务权重和尺度归一化的双重角色。其次，距离预测头的梯度会回传至视觉编码器，这意味着 α 的选择会影响编码器学到的特征偏向——较大的 α 倾向于让编码器学习距离敏感的特征，较小的 α 则让编码器更侧重于轨迹生成所需的结构特征。

距离预测头与视觉编码器是直接耦合的，因此更换视觉编码器后，距离预测分支必须同步重新训练，否则距离头与轨迹头将共享不一致的条件分布。

推理链路的统一封装 在推理阶段，系统先编码观察与目标，再在需要时进行候选节点距离评估，最后通过扩散采样生成轨迹。

统一推理模块的设计遵循参数化管理原则：模型权重、采样方式和候选筛选设置在统一入口处确定，使 DDIM、CFG 和 TTS 实验能够共享同一套推理流程。同时，统一推理模块也提供标准化输出，包括候选轨迹集合、距离预测值和推理时间统计，方便下游评估与闭环系统直接使用。

2.3.3 视觉掩码与导航/探索统一建模

NoMaD 的一个关键机制是目标掩码（goal mask）。训练时，模型以一定概率遮蔽目标 token，使其同时经历“有目标条件”和“无显式目标条件”两种情况^[9]。这并不意味着模型在无目标条件时进行随机游走，而是意味着它会学习在当前视觉上下文中生成连续、可执行且符合数据轨迹分布的探索性行为。正因为如此，NoMaD 才能在部署时同时支持导航模式与探索模式。当 goal mask 取 0 时，目标 token $\mathbf{z}_g$ 正常参与 self-attention，模型处于“带目标导航”模式；当 goal mask 取 1 时， $\mathbf{z}_g$ 所在位置被置为 padding 并在池化时去掉权重，模型退化为“无目标探索”模式。这一机制使得同一套权重既可用于导航也可用于探索，也是后续 CFG 引导能同时使用“带目标”与“不带目标”两次前向的直接原因。

goal mask 的设计还有一个重要的技术意义：它使得模型在训练时自然地学习了“当前观察本身蕴含的行为先验”。即使没有目标指引，训练数据中的轨迹通常也遵循特定的行为模式（如沿道路行驶、避开障碍物），goal mask 使模型能够将这些模式内化为无条件生成能力。

在数学表述上，goal mask 的训练过程可以描述如下。设 goal mask 概率为 p_{mask} ，对于每个训练样本，以概率 p_{mask} 将目标 token $\mathbf{z}_{\text{goal}}$ 替换为可学习的掩码 token $\mathbf{z}_{\text{mask}}$ 。因此模型在训练过程中优化的是混合目标：

$$\mathcal{L} = p_{\text{mask}} \cdot \mathcal{L}_{\text{diff}}(\epsilon_{\theta}(x_t, t, \mathbf{z}_{\text{obs}}, \mathbf{z}_{\text{mask}})) + (1 - p_{\text{mask}}) \cdot \mathcal{L}_{\text{diff}}(\epsilon_{\theta}(x_t, t, \mathbf{z}_{\text{obs}}, \mathbf{z}_{\text{goal}})). \quad (2.17)$$

式中， $\mathcal{L}$ 表示混合训练损失， p_{mask} 表示目标掩码概率， $\mathbf{z}_{\text{obs}}$ 表示观察 token， $\mathbf{z}_{\text{mask}}$ 表示掩码 token， $\mathbf{z}_{\text{goal}}$ 表示目标 token， $\epsilon_{\theta}(\cdot)$ 表示噪声预测网络。在本文的配置中， p_{mask} 设置为 0.5，确保两种模式都获得充分训练。值得注意的是，goal mask 机制与 CFG 中的条件随机丢弃（condition dropout）在形式上高度一致——两者都是在训练时以一定概率移除条件信息。因此 goal mask 实际上内在地为 CFG 推理提供了基础：在推理时，将条件分支（提供目标 token）与无条件分支（使用掩码 token）的噪声预测进

行 CFG 组合，即可实现对目标方向的引导增强。这种设计使得探索能力与导航增强能力共享同一训练框架。

在部署阶段，探索模式与导航模式的切换仅需改变推理时的条件输入：提供真实目标 token 时进入导航模式，提供掩码 token 时进入探索模式。两种模式之间的切换不需要加载不同的模型权重或改变网络结构，这大大简化了部署系统的设计。

2.4 数据集、实验设备与基线推理验证

2.4.1 GoStanford 数据集与数据预处理

本文所有离线实验均基于 GoStanford 数据集进行。该数据集来源于斯坦福大学校园环境中通过自主采集机器人记录的视觉导航轨迹，是 NoMaD 相关研究采用的标准训练与评估数据来源之一^[7-9]。数据集中的每条轨迹包含按时间顺序排列的第一人称 RGB 图像帧和对应的位姿信息。

GoStanford 原始数据集的场景多样性是其作为标准评估数据集的重要优势，数据采集覆盖了斯坦福大学校园中的室内走廊、室外道路、建筑入口、停车区域等多种环境类型。每条轨迹的长度从几十帧到数百帧不等，对应数十米到数百米的实际行驶距离。图像帧的采集频率约为 4 Hz，位姿信息由里程计或 GPS 提供，精度足以用于轨迹级别的训练监督。

本文使用的本地训练与离线评估子集来自 GoStanford 中的室内路线，未包含室外道路、强日照或开阔场地等数据。在离线实验中，每次推理从轨迹中提取连续观察帧与目标帧，构建标准化测试样例。DDIM、CFG 与编码器实验使用 24 组测试样例；TTS 补充实验为控制组合规模使用 12 组测试样例，但保持相同的样例构造规则和统计口径。

从原始轨迹到模型输入之间存在一个标准化的数据预处理流程。首先，RGB 图像从原始分辨率（通常为 640×480 ）对齐至模型要求的输入尺寸（ 96×96 ），缩放过程使用双线性插值。其次，像素值从 $[0, 255]$ 归一化至 $[0, 1]$ 范围。最后，根据历史上下文长度从轨迹中提取连续帧作为历史观察，并从同一轨迹的未来位置选取目标帧。

测试样例的构建遵循以下原则：当前观察与目标帧之间的时间间隔覆盖短距离（5–10 帧）和中距离（20–50 帧）两种范围，以确保评估涵盖不同难度级别。每个样例包含完整的历史观察序列、目标图像和对应的真实轨迹标签，使得所有实验在完全相同的数据条件下进行比较。

值得说明的是，24 组测试样例的数量虽然有限，但其设计覆盖了直行、转弯、宽

阔区域和狭窄走廊等多种典型场景类型。在离线统计实验中，这一规模足以反映不同配置之间的趋势性差异，同时保持单次完整实验的运行时间在可接受范围内。对于需要更高统计置信度的结论，本文通过报告 95% 置信区间（95% Confidence Interval, CI95）来量化均值估计的不确定性。

2.4.2 感知输入与实验设备

本文系统采用纯 RGB 单目视觉作为唯一感知输入，不依赖深度传感器、激光雷达或惯性测量单元。这一设计选择与 NoMaD 原始框架一致，即高层导航策略仅以图像观察和目标图像为输入，不需要额外传感模态。

纯视觉感知的优势在于硬件成本低、安装简单、且与人类的导航感知方式最为接近。其主要局限在于：（1）缺乏显式的深度信息，无法直接判断障碍物距离；（2）对光照变化和动态遮挡敏感；（3）单目视觉的尺度模糊性使得绝对距离估计困难。NoMaD 通过学习大量导航轨迹数据来隐式弥补这些局限。

在离线实验阶段，训练与统计实验运行在配备 NVIDIA RTX 4090 的计算机上；在 MuJoCo 仿真阶段，相机图像由 MuJoCo 渲染器以第一人称视角生成；在真机部署阶段，使用 USB 单目相机接入 Jetson Orin，输出分辨率为 640×480 。

RTX 4090 与 Jetson Orin 之间的算力差距是本文实验设计中需要特别关注的因素。RTX 4090 适合承担离线训练和统计实验，而 Jetson Orin 属于机载边缘计算平台，受功耗、散热和统一内存资源约束更强。这意味着在 RTX 4090 上可接受的推理时延，在 Jetson Orin 上仍需要通过板端基准测试重新确认。因此，本文在离线实验中特别关注时延指标的绝对值而非仅关注相对加速比，以便为部署阶段的配置选择提供直接参考。

2.4.3 基线推理与评价指标

为给后续所有优化实验建立统一参考，本文首先复现了原始 NoMaD 离线推理流程。输出结果表明，原始模型参数量约为 19,049,675。需要区分两种不同口径的时延：在端到端单次运行中，包含图像加载、编码、DDPM-10 采样与结果后处理的整体耗时约为 0.1250 s；而在本章后续使用的 24 组测试样例统计实验中（见表 2.2），ddpm_10 的纯扩散采样平均时延约为 40 ms，CI95 为 ± 1.37 ms。两者数量级差异的根本原因是前者计入了一次性模型构建、设备预热与图像预处理开销，而后者在预热阶段之后测量循环体内部的推理时间。由于后续 DDIM、CFG、TTS 与视觉编码器对比实验都运行在统一的统计流程与评价设置下，本文把“40 ms 量级”视为基线推理时延的有效

参考，而把“0.125 s”仅作为单次端到端流程的补充记录。

关于参数量的构成，19.05 M 参数中视觉条件编码器约占 15.18 M（含两个 EfficientNet-B0、投影层、位置编码与 4 层 self-attention），扩散策略头（条件一维 U-Net, ConditionalUnet1D）约占 3.85 M，距离预测头约占 0.02 M。由此可见视觉编码器是主要参数来源，更换视觉编码器对总参数量的影响取决于新骨干网络的规模：若替换为 DINOv2-Small（22 M 骨干网络）或 ConvNeXt-Tiny（27 M 骨干网络）将使总参数量明显上升；若保持骨干网络在 B0 量级则总参数量相近。

扩散策略头中的 U-Net 架构采用了多尺度特征融合和条件注入机制。条件向量 $\mathbf{c}$ 通过 FiLM（Feature-wise Linear Modulation）机制注入到 U-Net 的各个分辨率层级中，使得噪声预测网络能够在每一步去噪中都感知到当前的视觉条件和目标信息。这种设计虽然增加了参数量，但保证了扩散过程对条件信号的充分响应。

关于推理频率的部署含义，40 ms 的纯采样时延在 RTX 4090 上对应约 25 Hz 的理论上限，但叠加图像预处理、消息传递或可视化后，端到端频率通常会明显低于该理论值。在边缘设备（如 Jetson Orin）上，实际频率还会受到功耗模式、散热状态、相机驱动和 PyTorch/CUDA 版本影响，因此不能仅按桌面 GPU 与边缘 GPU 的标称算力比例线性外推。本文把 DDIM 加速作为部署优化的直接动机，但具体真机可用频率仍以后续 Orin 阶段实测为准。

此外， 8×8 的轨迹采样规格表示每次推理生成 8 条候选轨迹，每条轨迹包含 8 个航点。8 个航点的长度在默认配置下对应约 2–3 秒的未来规划窗口，这一时间尺度既足以覆盖局部导航决策（如是否转弯），又不至于因规划太远而积累过大误差。

表 2.1 NoMaD 基线离线推理结果

指标	含义	数值
模型参数量	可学习参数总量	19,049,675
端到端单次推理	含 I/O 与首次 kernel 编译	0.1250 s
纯采样时延	DDPM-10 循环体耗时（24 组测试样例平均）	39.98 ms (CI95 ± 1.37)
纯采样推理频率	RTX 4090 单 batch 理论频率	25 Hz
轨迹采样规格	候选轨迹数 $\times$ 航点数	8×8
距离预测输出	候选目标相对距离估计均值	11.6589

基线推理可视化 为直观呈现 NoMaD 在导航与探索两种模式下的轨迹分布，本文对同一观察分别进行有目标条件采样与无目标条件采样，并在机器人当前位姿为原点的局部坐标系中绘制候选轨迹。图 2.4 与图 2.5 分别给出 navigate 模式与 explore 模式

的可视化结果。



图 2.4 NoMaD 基线 navigate 模式轨迹可视化



图 2.5 NoMaD 基线 explore 模式轨迹可视化

两幅可视化图共用相同的局部坐标系：红色五角星为机器人当前位置， x 轴指向机体正前方， y 轴指向机体左侧。两图都生成了不同颜色的八条候选轨迹。两组可视化共同说明，NoMaD 在同一组观察下能够通过 goal mask 切换在“被目标牵引的窄分布”与“沿走廊自由展开的宽分布”之间切换，验证了导航与探索共享同一权重的可行性。

为了避免仅凭单次样本或单一指标做结论，本文采用多指标联合分析。主要指标包括：Latency，用于衡量推理开销；CI95，用于表示均值的 95% 置信区间；均方误差（Mean Squared Error, MSE）vs DDPM-10，用于衡量与基线采样分布的偏移；Forward Progress，用于刻画轨迹在主前进方向上的推进程度；Lateral Abs，用于衡量横向偏摆幅度；Smoothness，用于衡量轨迹变化的平滑性；Dist Pred Mean，用于观察候选目标距离评估是否随条件空间变化发生系统偏移。

指标的形式化定义 为确保实验可复现性，本文给出各指标的形式化定义。

Latency 定义为单次推理的端到端耗时，包含编码、去噪和后处理，单位为毫秒：

$$\text{Latency} = t_{\text{end}} - t_{\text{start}}. \quad (2.18)$$

式中， t_{start} 与 t_{end} 分别表示单次推理开始和结束的时间戳，二者差值即端到端推理耗时。

CI95 表示均值的 95% 置信区间半径，基于 t 分布计算：

$$\text{CI95} = t_{0.975, n-1} \cdot \frac{s}{\sqrt{n}}, \quad (2.19)$$

其中 $t_{0.975, n-1}$ 表示自由度为 $n-1$ 的 t 分布在 0.975 分位处的临界值， s 为样本标准差， n 为测试样例数量。

MSE vs DDPM-10 衡量某配置生成轨迹均值与基线 DDPM-10 生成轨迹均值之间的均方误差：

$$\text{MSE} = \frac{1}{H} \sum_{i=1}^H \|\bar{\mathbf{a}}_i^{\text{test}} - \bar{\mathbf{a}}_i^{\text{base}}\|^2, \quad (2.20)$$

其中 MSE 表示均方误差， H 表示预测轨迹长度， $\bar{\mathbf{a}}_i^{\text{test}}$ 表示测试配置下第 i 个航点的候选均值， $\bar{\mathbf{a}}_i^{\text{base}}$ 表示基线配置下第 i 个航点的候选均值， $\|\cdot\|^2$ 表示欧氏距离平方。

Forward Progress 定义为轨迹在主前进方向（ x 轴）上的累计位移：

$$\text{FP} = \sum_{i=1}^H \Delta x_i. \quad (2.21)$$

式中，FP 表示前向进展指标， Δx_i 表示第 i 个航点的前向位移增量， H 表示轨迹长度。

Lateral Abs 定义为轨迹在横向（ y 轴）上的累计绝对位移：

$$\text{LA} = \sum_{i=1}^H |\Delta y_i|. \quad (2.22)$$

式中，LA 表示横向绝对偏摆指标， Δy_i 表示第 i 个航点的横向位移增量， $|\cdot|$ 表示绝对值。

Smoothness 衡量相邻航点之间方向变化的一致性，定义为相邻位移向量差的范数均值：

$$\text{Smooth} = \frac{1}{H-1} \sum_{i=1}^{H-1} \|\mathbf{a}_{i+1} - \mathbf{a}_i\|. \quad (2.23)$$

式中，Smooth 表示平滑性代价， $\mathbf{a}_{i+1} - \mathbf{a}_i$ 表示相邻航点之间的位移变化， $\|\cdot\|$ 表示欧氏范数。

统计显著性与多指标分析原则 本文采用多指标联合分析而非单一指标排序，原因在于导航任务的优化目标本质上是多目标的。仅优化前进性可能导致激进轨迹，仅优化平滑性可能导致过于保守的运动。通过同时报告前向进展、横向偏差、平滑性和时

延, 可以判断某个配置是否在所有维度上都可接受, 而不是在某一维度上表现突出但在其他维度上严重退化。

在统计检验层面, 由于本文的离线实验样本量为 24 组测试样例, 属于小样本范畴。对于小样本比较, 本文主要依赖 CI95 的重叠程度来判断差异的显著性: 若两个配置的 CI95 不重叠, 则认为差异具有统计意义; 若 CI95 部分重叠, 则需结合效应量大小 (即均值差与标准差之比) 进行综合判断。这种方法比直接进行 p 值检验更适合本文的实验规模和多次比较场景。

其中, CI95 并不是新的性能指标, 而是均值稳定性的统计描述。若某个配置平均值较优但 CI95 很宽, 说明其结果在不同测试样例间波动较大。前向进展也不能单独解释为越大越好, 因为过大的前进量可能是激进采样带来的分布偏移, 必须结合均方误差、横向偏差和轨迹平滑性一起分析。

2.5 DDIM 推理加速与 CFG 引导增强实验

2.5.1 DDIM 推理加速实验

理论动机 DDIM 的核心思想是将扩散模型的随机微分方程 (Stochastic Differential Equation, SDE) 采样过程转换为确定性常微分方程 (Ordinary Differential Equation, ODE) 求解过程^[22]。在标准 DDPM 中, 反向去噪过程由以下随机递推描述:

$$\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}, \quad (2.24)$$

其中 $\mathbf{x}_t$ 与 $\mathbf{x}_{t-1}$ 分别表示当前和上一去噪时间步的轨迹噪声样本, α_t 与 $\bar{\alpha}_t$ 表示单步和累计噪声调度系数, $\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)$ 表示模型预测噪声, σ_t 表示随机噪声强度, $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 表示标准高斯噪声。DDIM 的关键洞察是: 当令随机项 $\sigma_t = 0$ 时, 上述过程退化为确定性的 ODE 积分:

$$\mathbf{x}_{t-1} = \sqrt{\bar{\alpha}_{t-1}} \cdot \hat{\mathbf{x}}_0(\mathbf{x}_t, t) + \sqrt{1 - \bar{\alpha}_{t-1}} \cdot \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t), \quad (2.25)$$

其中 $\hat{\mathbf{x}}_0(\mathbf{x}_t, t)$ 是基于当前噪声预测得到的干净样本估计, $\bar{\alpha}_{t-1}$ 表示上一时间步的累计保留系数, 其他符号含义与上式一致。

由于 ODE 的解路径是确定性的且连续的, 可以在时间轴上使用更大的步长进行积分而不引入额外随机噪声的累积。这就是 DDIM 能够用更少步数完成去噪的数学基础——本质上是用粗粒度的数值积分近似原始的细粒度 ODE 轨迹。步数越少, 积分越粗糙, 但对于 smooth 的 ODE 解路径, 适度的步数减少不会显著改变最终结果。

从数值分析的角度，DDIM 的步数减少可以类比为 ODE 求解器中步长的增大。对于一阶 Euler 方法，截断误差与步长 h 成正比；而 DDIM 的更新规则实际上对应一种隐式的高阶积分格式，因此在步数适度减少时能保持较小的截断误差。但当步数降至极端（如仅 1 步）时，单步积分的假设不再成立，误差会急剧增大。

实验设计 DDIM 的作用是在不重新训练模型的情况下减少扩散去噪步数，从而降低推理时延^[22]。本文以 `ddim_x` 来定义采用 DDIM 采样 x 步的配置。本文在统一实验流程中比较 `ddpm_10`、`ddim_10`、`ddim_5`、`ddim_3`、`ddim_2` 和 `ddim_1` 六种配置，测试集共包含 24 组测试样例。该实验围绕以下两个核心问题展开：一是减少去噪步数后能够获得多大推理加速，二是加速后的轨迹分布是否仍保持在可接受范围内。

六种配置的选择覆盖了相比于基线，从“不减少步数”到“极端压缩至单步”的完整频谱。`ddim_10` 与 `ddpm_10` 步数相同，用于验证 DDIM 在不减步时是否引入额外偏差；`ddim_5` 和 `ddim_3` 代表中等程度的加速；`ddim_2` 代表较为激进但仍可控的加速；`ddim_1` 则代表理论极限，用于探测 DDIM 的失效边界。这种全频谱设计使得本文能够精确定位速度与质量的平衡点。

表 2.2 DDIM 推理加速实验结果

配置	Latency/ms	CI95/ms	Speedup	MSE vs DDPM-10	Forward Progress	Diversity
<code>ddpm_10</code>	39.9790	1.3748	1.00×	0.0000	6.4998	0.251
<code>ddim_10</code>	38.0260	0.6034	1.05×	0.0062	6.4686	0.318
<code>ddim_5</code>	19.2581	0.4319	2.08×	0.0048	6.5257	0.271
<code>ddim_3</code>	11.6579	0.3438	3.43×	0.0124	6.6224	0.306
<code>ddim_2</code>	8.2588	0.2779	4.84×	0.0210	6.6471	0.377
<code>ddim_1</code>	4.5092	0.1427	8.87×	3.5168	9.2789	4.736

实验结果与分析 `ddim_10` 与 `ddpm_10` 的 MSE 仅为 0.0062，说明在相同步数下 DDIM 的确定性采样与 DDPM 的随机采样生成的轨迹均值几乎一致，验证了 DDIM 的理论无损性。`ddim_5` 在步数减半的情况下 MSE 反而略低于 `ddim_10`（0.0048 vs 0.0062），这可能源于采样噪声的统计波动，也说明 5 步 ODE 积分的截断误差仍然可以忽略。`ddim_3` 的 MSE 上升至 0.0124，开始出现可观测的分布偏移但仍在可控范围内。`ddim_2` 的 MSE 为 0.0210，虽然进一步升高但 Forward Progress 仅从 6.50 变为 6.65，偏移幅度有限。

针对第一个问题，结果表明 DDIM 的确能显著降低推理时延，其中 `ddim_2` 已接

近5倍加速。针对第二个问题，`ddim_2`在MSE与Forward Progress上仍保持相对平衡，说明它不是以严重破坏轨迹分布为代价换取速度。相比之下，`ddim_1`虽然最快，但MSE大幅升高，说明轨迹已明显偏离基线分布，不适合作为稳定部署方案。

从速度-质量Pareto前沿的角度分析，`ddim_2`到`ddim_5`构成了一段有效的Pareto前沿：在这个范围内，每减少一步都能带来显著的时延收益，而MSE增长仍在可控范围内。`ddim_1`则明显偏离了这一前沿，属于“过度压缩”区域。

因此，本文将`ddim_2`视为后续闭环验证中更值得优先考虑的推理配置。该结果表明，扩散策略并不必然意味着“质量高但太慢”，通过合理采样调度，NoMaD可以进入更接近真实部署的时延区间。




图 2.6 DDIM 加速实验结果图

2.5.2 CFG 引导增强实验

理论分析 Classifier-Free Guidance (CFG) 的核心思想是在推理时通过线性外推来增强条件信号对生成结果的影响^[23]。具体来说，CFG 修改了扩散模型的噪声预测 (score function) 为：

$$\tilde{\epsilon}_{\theta}(\mathbf{x}_t, t, \mathbf{c}) = (1 + w) \cdot \epsilon_{\theta}(\mathbf{x}_t, t, \mathbf{c}) - w \cdot \epsilon_{\theta}(\mathbf{x}_t, t, \emptyset), \quad (2.26)$$

其中 $\tilde{\epsilon}_{\theta}$ 表示 CFG 修正后的噪声预测， $\mathbf{x}_t$ 表示当前噪声样本， t 表示去噪时间步， $\mathbf{c}$ 为条件向量（包含观察和目标信息）， $\emptyset$ 表示空条件（训练时通过随机 dropout 条件实现）， w 为引导权重。

当 $w = 0$ 时，退化为标准的条件采样；当 $w > 0$ 时，生成结果在条件方向上被“放大”，使轨迹更强烈地朝向目标方向偏移；当 $w < 0$ 时，则产生反向引导效果。从概率密度的角度，CFG 实质上是在对数概率空间中将条件分布与无条件分布的差异进行缩放：

$$\log \tilde{p}(\mathbf{x} | \mathbf{c}) \propto (1 + w) \log p(\mathbf{x} | \mathbf{c}) - w \log p(\mathbf{x}). \quad (2.27)$$

式中， $\tilde{p}(\mathbf{x} | \mathbf{c})$ 表示经 CFG 修正后的条件分布， $p(\mathbf{x} | \mathbf{c})$ 表示原始条件分布， $p(\mathbf{x})$ 表

示无条件先验分布, α 表示两侧相差归一化常数。这意味着 w 越大, 生成分布越集中于条件分布的高概率区域, 同时远离无条件先验的模式。

实验设计 CFG 的目标是在推理阶段增强轨迹对目标条件的响应^[23]。本文选取 $w \in \{-1.0, 0.0, 0.5, 1.0, 2.0, 4.0\}$ 六组配置进行比较, 旨在回答引导强度能否提升目标牵引, 以及这种提升是否会带来不可接受的分布偏移和时延开销。

负值引导 ($w = -1.0$) 被包含在实验中, 目的是验证反向引导是否会导致轨迹偏离目标方向。如果 $w = -1.0$ 的 Forward Progress 显著低于 $w = 0.0$, 则说明 CFG 的条件引导方向确实与目标方向一致, 从而间接验证了 CFG 机制在导航任务中的有效性。

实验结果与分析 围绕上述问题, 结果表明适度的 CFG 能提高轨迹对目标方向的响应, 但代价是更高的推理时延和潜在的分布偏移。从表 2.3 可以看到, $w = 0.0$ 时推理时延约为 42.65 ms, 而 $w \geq 0.5$ 后时延跃升至约 78–80 ms, 这是因为 CFG 需要同时执行条件分支与无条件分支的噪声预测。CFG 的每一步去噪都需要对噪声预测网络进行两次前向传播——一次使用完整条件 $\mathbf{c}$, 一次使用空条件 $\emptyset$ ——然后将两次预测结果进行线性组合。因此, CFG 的计算成本近似为非 CFG 推理的 2 倍。实验中 $w = 0.0$ 到 $w = 0.5$ 的时延跳变 (42.65 ms $\rightarrow$ 78.27 ms) 正好反映了这一理论预期。

在轨迹质量方面, $w = 1.0$ 的 Forward Progress 最高 (8.573), Lateral Abs 仍保持适度 (2.901), 说明该配置在前进性和稳定性之间表现较为均衡。而 $w = 4.0$ 时 Shift 高达 0.5133, Lateral Abs 上升至 3.089, 表明过强的引导会导致分布偏移与横向偏摆。

关于最优引导尺度的选择, 本文认为应遵循以下准则: (1) 引导强度不应使 Shift 指标超过 0.2, 以避免显著的分布偏移; (2) 在满足 (1) 的前提下, 优先选择 Forward Progress 较高的配置; (3) 必须考虑时延代价——如果 CFG 带来的质量提升不能补偿 2 倍时延的代价, 则不建议开启。

从实验数据来看, $w = -1.0$ 的反向引导在 Shift 和 Forward Progress 上与 $w = 0.0$ 差异极小, 说明轻微的反向引导对轨迹分布的影响可以忽略。 $w = 0.5$ 和 $w = 1.0$ 的 Shift 分别为 0.0160 和 0.0476, 均在 0.2 的阈值以内, 属于可接受范围。 $w = 2.0$ 的 Shift 为 0.1438, 虽未超过阈值但已接近边界, 提示进一步增大引导可能带来不稳定性。由此可见, CFG 可以增强目标响应, 但其收益必须与约 2 倍时延开销和分布偏移风险共同权衡。综合以上分析, 本文将 CFG 定位为可调部署旋钮, 而非必须开启的固定默认项。

表 2.3 CFG 引导实验结果

配置	Latency/ms	Shift vs $w = 0$	Forward Progress	Lateral Abs
$w = -1.0$	42.28	0.0278	8.500	2.876
$w = 0.0$	42.65	0.0000	8.523	2.886
$w = 0.5$	78.27	0.0160	8.515	2.875
$w = 1.0$	79.75	0.0476	8.573	2.901
$w = 2.0$	78.81	0.1438	8.527	2.952
$w = 4.0$	78.92	0.5133	8.483	3.089


Classifier-Free Guidance: Trajectory Comparison for Different w 

图 2.7 CFG 引导实验结果图

2.6 TTS 推理时搜索与视觉编码器升级实验

2.6.1 TTS 推理时搜索实验

实验设计 TTS 的作用是把额外预算用于“候选生成与选择”，而非用于修改训练过程^[33-34]。在本文中，TTS 被设计为推理层的外层搜索组件：先用当前采样配置生成多条候选轨迹，再根据目标一致性、前进性和平滑性综合打分，最终选择一条更适合执行的轨迹。实验重点比较不同预算下的轨迹质量收益，以及它与 DDIM、CFG 的组合关系。

评分函数设计 TTS 的核心在于评分函数的设计。本文采用加权多目标评分函数：

$$\text{Score}(\mathbf{A}) = \beta_1 \cdot \text{FP}(\mathbf{A}) - \beta_2 \cdot \text{LA}(\mathbf{A}) - \beta_3 \cdot \text{Smooth}(\mathbf{A}), \quad (2.28)$$

其中 $\text{Score}(\mathbf{A})$ 表示候选轨迹 $\mathbf{A}$ 的综合评分, $\text{FP}(\mathbf{A})$ 为前进性, $\text{LA}(\mathbf{A})$ 为横向绝对偏摆, $\text{Smooth}(\mathbf{A})$ 为平滑性代价, $\beta_1, \beta_2, \beta_3$ 为权重系数。

评分函数中权重系数的选择需要根据具体部署场景进行调整。在开阔环境中, 可以增大 β_1 以鼓励更积极的前进; 在狭窄走廊中, 应增大 β_2 以抑制横向偏摆; 在需要精细控制的场景中, β_3 应占主导以保证轨迹平滑性。本文在离线实验中采用固定权重配置, 具体取 $\beta_1 = 1.000$ 、 $\beta_2 = 0.350$ 、 $\beta_3 = 0.150$, 但在部署阶段可以根据场景类型动态调整。

计算预算分配策略 TTS 的计算开销与候选轨迹数 (budget) 总体正相关。设单次采样耗时为 τ , 则 TTS- K 的总耗时可近似表示为候选生成开销与评分开销之和, 其中评分与排序通常只占很小比例。由于实际实现会复用批量张量计算, 耗时不会严格等于 $K \cdot \tau$ 。因此, DDIM 加速节省的时间预算可以部分重新分配给 TTS, 形成“用更快的单次采样换取更多候选”的策略。

这种预算分配思路可以形式化为一个受约束的优化问题: 在总时延预算 $T_{\max}$ 的约束下, 选择 DDIM 步数 S 和 TTS budget K 以最大化轨迹质量。由于 $K \cdot \tau(S) \leq T_{\max}$, 减少 S (加速单次采样) 就能增大 K (增加候选数量), 两者之间存在自然的折中关系。

实验组织方式 为了保证结论具有统计意义, 本文将 TTS 实验组织为三层: 单因素实验, 用于比较是否开启 TTS 以及不同 budget; 两两组合实验, 用于比较 DDIM+TTS、CFG+TTS 的相互作用; 三因素联合实验, 用于比较 DDIM、CFG、TTS 同时开启时是否存在部署上更优的折中组合。

三层实验设计的逻辑是: 单因素实验确认 TTS 本身的有效性和最优 budget 范围; 两两组合实验检验 TTS 与其他优化手段之间是否存在交互效应; 三因素联合实验给出面向实际部署的推荐配置。

结果与分析 在讨论具体数值前, 需要先澄清一个容易混淆的概念层次, 以避免“默认生成 8 条候选”与“TTS-8”发生语义重合。NoMaD 扩散策略头的每次前向本身会以批次形式并行生成若干条候选轨迹 (本文固定为 8 条), 这一批次规格由扩散头本身决定, 与是否启用 TTS 无关。TTS 在此基础上额外引入两个正交的组件: 一是候选池预算, 当该预算超过单批候选数量时, 通过多次扩散采样扩展候选池规模; 二是评分筛选器, 对池内候选按多目标评分排序, 保留排名前 k 的候选作为执行输出。因

此，实验配置中的“未启用 TTS”与“TTS-8”都只触发一次扩散采样、生成同样的 8 条候选，差别只在于前者把候选集原样送入下游统计，后者多了一步基于评分的排序与前 k 选择；而 TTS-16 和 TTS-32 则分别对应 2 次和 4 次扩散采样，用于真正扩展候选池规模。

TTS 实验围绕以下核心问题展开：是否值得把 DDIM 节省下来的计算预算重新分配给候选搜索，而不是要求 TTS 绝对提升所有指标。本实验在 12 组统一离线测试样例上比较 DDIM 步数、CFG 权重与 TTS 候选预算的组合，表 2.4 给出在 DDIM-2、 $w = 0$ 条件下的单因素结果。

需要说明的是，表 2.4 和表 2.5 中的“综合评分”是用于比较不同推理配置的配置级排序分数，而不是单条候选轨迹的原始 TTS verifier 分数。对每个配置，本文先统计测试样例上的平均推理时延、平均前向进展、平均横向绝对偏摆与平均平滑性代价，再按下式计算综合评分：

$$S_{\text{rank}} = 1.000 \cdot \overline{\text{FP}} - 0.050 \cdot \overline{\text{Latency}} - 0.350 \cdot \overline{\text{LA}} - 0.150 \cdot \overline{\text{Smooth}}. \quad (2.29)$$

其中 S_{rank} 表示配置级综合评分， $\overline{\text{Latency}}$ 的单位为 ms， $\overline{\text{FP}}$ 表示平均前向进展， $\overline{\text{LA}}$ 表示平均横向绝对偏摆， $\overline{\text{Smooth}}$ 表示平均平滑性代价。四项权重分别为 1.000、0.050、0.350 和 0.150。这一评分设计使前向进展作为主要收益项，同时对推理时延、横向偏摆和平滑性代价进行惩罚；其中平滑性由轨迹二阶差分均值计算，数值量级较小，因此在综合评分中主要起弱正则作用。

针对这一问题，表中的单因素结果可以分解为两种不同来源的收益。从未启用 TTS 到 TTS-8，综合评分由 8.157 上升到 9.024，前进性由 9.010 上升到 9.697，而时延从 7.00 ms 变为 6.89 ms（两者在噪声范围内等价）——这段增益完全来自 TTS 在同一批 8 条候选上的额外排序与前 k 选择，几乎没有采样开销。从 TTS-8 到 TTS-16 再到 TTS-32，时延分别上升到约 2 倍和 4 倍，对应 1 次、2 次和 4 次扩散采样批次，这一段增益才真正来自“候选池扩容”：TTS-16 的综合评分 9.124 仅比 TTS-8 高 0.10，而 TTS-32 的综合评分反而回落到 8.825。TTS-8 在三因素联合排序（表 2.5）中综合表现最优，它近乎不增加时延，取得了 TTS 算法的主要收益，同时把剩余预算留给 DDIM 步数与 CFG 权重的组合。

进一步观察 DDIM、CFG 与 TTS 的三因素联合结果，综合排名前列的配置均集中在 DDIM-2 或 DDIM-3，并采用 TTS-8 或 TTS-16。表 2.5 给出排名前五的组合。最优配置为 ddim2_cfg2.0_tts8，其综合评分达到 9.143；但与 ddim2_cfg0.0_tts16 和 ddim2_cfg0.0_tts8 的差距较小。考虑 CFG 会额外增加一次条件/无条件推理，实际部

表 2.4 TTS 推理时搜索单因素实验结果 (DDIM-2, $w = 0$)

配置	Latency/ms	Forward Progress	Smoothness	综合评分
未启用 TTS	7.00	9.010	0.0811	8.157
TTS-8	6.89	9.697	0.0692	9.024
TTS-16	13.86	10.050	0.0627	9.124
TTS-32	26.50	10.344	0.0527	8.825

署中更稳妥的推荐是以 DDIM-2 + TTS-8/16 为默认候选，再把 CFG 作为可调开关。

表 2.5 DDIM $\times$ CFG $\times$ TTS 联合配置排名前五结果

排名	配置	Latency/ms	Forward Progress	Smoothness	综合评分
1	ddim2_cfg2.0_tts8	12.55	10.173	0.0553	9.143
2	ddim2_cfg0.0_tts16	13.86	10.050	0.0627	9.124
3	ddim2_cfg0.0_tts8	6.89	9.697	0.0692	9.024
4	ddim2_cfg1.0_tts8	12.52	9.941	0.0628	9.003
5	ddim2_cfg2.0_tts16	24.60	10.495	0.0521	8.987

2.6.2 视觉编码器升级实验

实验设计 视觉编码器升级实验围绕以下问题展开：在统一训练和评价条件下，不同视觉编码器能否提供更有潜力的条件表征，以及这种表征差异主要体现在轨迹多样性、前进性、平滑性还是推理延迟上。

候选编码器结构与对比 本文在 EfficientNet-B0 之外纳入三类视觉骨干作为升级候选。DINOv2-Small^[37] 基于 Vision Transformer 架构，将图像切分为固定大小 patch 后送入 12 层 Transformer 编码器，参数量约 22 M；自监督预训练赋予其较强的跨域泛化性，全局自注意力对远距离方向判断更敏感。ConvNeXt-Tiny^[38] 是借鉴 Transformer 设计原则的现代 CNN，采用更大卷积核、层归一化 (Layer Normalization, LayerNorm) 与更少激活函数，在保留 CNN 局部归纳偏置的同时提升表征能力，参数量约 28 M。ResNet-50^[39] 作为经典残差 CNN 提供稳定基线，结构成熟、权重广泛可用，参数量约 25 M。三者与 EfficientNet-B0 的 MBConv (5.3 M) 形成“自监督 ViT、现代 CNN、经典 CNN”的对照，覆盖表征机制与参数量两条对比维度。

特征维度对齐 四种编码器的原始输出维度并不一致：EfficientNet-B0 输出 1280 维，DINOv2-Small 输出 384 维，ConvNeXt-Tiny 输出 768 维，ResNet-50 输出 2048 维。为




图 2.8 TTS 联合实验的时延与轨迹质量折中

保证公平对比，本文在每个编码器输出端附加一个线性投影层，将原始特征统一映射到固定 token 维度 d ：

$$\mathbf{z} = W_{\text{proj}} \cdot \mathbf{f}_{\text{enc}} + \mathbf{b}_{\text{proj}}, \quad (2.30)$$

其中 $\mathbf{z}$ 表示投影后的标准 token， $\mathbf{f}_{\text{enc}}$ 为编码器原始输出， $W_{\text{proj}} \in \mathbb{R}^{d \times d_{\text{enc}}}$ 为投影矩阵， d 表示目标 token 维度， d_{enc} 表示原始编码器输出维度， $\mathbf{b}_{\text{proj}}$ 为偏置向量。投影层与下游模块联合训练；投影后所有编码器在相同信息瓶颈下进入距离预测头与扩散策略头，避免条件空间容量差异干扰对比结果。

训练配置 在 GoStanford 数据集上对四种编码器分别进行 100 轮训练，批量大小设为 32，学习率与优化器配置统一。所有骨干网络参数参与微调，以便在相同训练轮数下最大化各编码器的适配空间。

实验结果与分析 四种编码器在相同离线测试样例、相同 DDPM-10 采样设置下的代理指标如表 2.6 所示。从指标分布看，各编码器在不同维度上表现各有侧重：ResNet-50 在轨迹多样性指标（0.9824）与前向进展指标（7.980）上最高，候选轨迹最分散、前进性最强；EfficientNet-B0 的平滑性指标最低（0.0725），原始基线在轨迹平滑性上

仍具有优势；DINOv2-Small 与 ConvNeXt-Tiny 在三项质量指标上处于中段。延迟方面，四种编码器单次前向延迟均在 34–37 ms 区间，差异显著小于 DDIM 步数变化所带来的影响，因此编码器选择主要受表征质量约束而非延迟约束。

上述结果回应了编码器升级实验所关注的问题：不同视觉编码器确实会改变条件表征对应的轨迹分布，但这种差异并不表现为单一指标全面占优。由于轨迹多样性、前向进展与平滑性三者之间存在内在权衡——更分散的轨迹候选意味着更大的方向变化，因此平滑性通常下降——视觉编码器升级不是单一指标最大化问题，而是在多样性、前进性与平滑性之间寻找折中。本实验为第二阶段的部署训练提供了候选筛选依据。

表 2.6 视觉编码器升级实验结果

编码器	Latency/ms	Diversity	Forward Progress	Smoothness
EfficientNet-B0	35.54	0.5818	7.356	0.0725
DINOv2-Small	35.88	0.3182	7.097	0.1158
ConvNeXt-Tiny	37.10	0.3017	7.014	0.1322
ResNet-50	34.81	0.9824	7.980	0.0980




图 2.9 四种视觉编码器离线统计对比

2.7 联合消融分析与最终算法配置

综合本章离线实验，表 2.7 进一步给出了 DDIM 与 CFG 联合配置的前五名结果。从中可以看出，ddim2_w0.0 在时延、前进性、平滑性和多样性的综合评分中排名第一，说明在不额外开启 CFG 的情况下，DDIM-2 本身已经具备较好的综合表现。综合评分的计算方式为各指标归一化后的加权求和，权重分配反映了部署场景中对低时延和轨迹质量的均衡需求。

表 2.7 DDIM $\times$ CFG 联合配置排名前五结果

排名	配置	Latency/ms	Forward Progress	Smoothness	Diversity	综合评分
1	ddim2_w0.0	9.99	8.089	0.1237	0.3897	5.0919
2	ddim3_w0.0	14.60	8.076	0.1075	0.3208	4.9942
3	ddim5_w0.0	24.63	8.032	0.1043	0.2906	4.7481
4	ddim3_w1.0	26.62	8.109	0.1096	0.3070	4.7227
5	ddim3_w0.5	27.04	8.093	0.1083	0.3130	4.7174

基于上述结果，可得到四点阶段性结论。第一，在不改动训练结果的前提下，DDIM-2 更适合进入闭环验证。第二，CFG 的有效范围有限，更适合作为可调参数而不是默认固定设置。第三，TTS 的收益可进一步分解为“评分筛选”（在固有 8 条候选上做排序与前 k 选择，几乎零时延代价）与“候选池扩容”（ $K > 8$ 时多批次采样，时延线性增长且边际收益快速衰减）两部分，TTS-8 以筛选为主、代价可忽略，继续增大候选池规模则只能取得有限的增益，因此部署上推荐以 TTS-8 为默认档位、TTS-16 作为可选的增强方式。第四，视觉编码器升级已完成四个训练权重的离线统计，但最终部署选择仍需结合闭环验证与真机条件共同判断。

2.7.1 优化方法之间的关系

四种优化方法并不处在同一层级。视觉编码器升级位于视觉条件层，改变的是历史观察和目标图像进入模型后的特征表达；DDIM 与 CFG 位于扩散采样层，改变的是给定视觉条件后轨迹样本的生成方式；TTS 位于候选选择层，改变的是生成多条候选轨迹之后如何筛选最终执行轨迹。表 2.8 总结了各方法的作用位置与实验含义。

表 2.8 算法优化方法的作用层级与阶段结论

优化方法	作用层级	是否改变训练	阶段结论
DDIM	扩散采样调度	否	DDIM-2 默认最优，跨四编码器鲁棒
CFG	条件引导强度	否	时延翻倍而无可测质量收益，默认关闭
TTS	候选轨迹筛选	否	TTS-8 近零代价，增益随候选 Diversity 放大
视觉编码器升级	视觉条件建模	是	四权重可替换，影响 Diversity 进而影响 TTS 增益

因此，DDIM、CFG 与 TTS 更适合被写成统一推理层内部的层级组合：先由 DDIM 决定每条候选轨迹的去噪步数与生成速度，再由 CFG 决定采样过程中条件信号的放大程度，最后由 TTS 在候选轨迹集合上进行评分和选择。三者并不是简单并列相加，

而是在“生成单条轨迹–增强条件响应–筛选候选轨迹”的流水线上依次发挥作用。算法 2.1 给出了四种优化方法在一次高层推理周期内的具体执行顺序，说明它们是如何在同一组观察输入上从“视觉表征–去噪采样–条件引导–候选筛选”逐层组合，最终输出一条供中层控制器跟踪的执行轨迹。

算法 2.1 统一推理模块在单次高层周期内的执行流程

Input: 历史观察 $O_t = \{I_{t-K}, \dots, I_t\}$, 目标图像 I_g ; 视觉编码器权重 θ_{enc} ; DDIM 步数 S ; CFG 权重 w ; TTS 候选预算 K ; 扩散头每次前向产生的候选数 $N_0 = 8$

Output: 执行轨迹 $\mathbf{A}^* \in \mathbb{R}^{H \times 2}$

// 1. 视觉编码器升级层: 根据 θ_{enc} 提取 token, 得到统一条件向量

- 1 $\mathbf{c} \leftarrow \text{VisionEncoder}_{\theta_{\text{enc}}}(O_t, I_g)$;
- 2 $\mathbf{c}_{\emptyset} \leftarrow \text{VisionEncoder}_{\theta_{\text{enc}}}(O_t, \text{mask})$;

// 2. DDIM 采样层: 用 S 步 DDIM 一次性生成 N_0 条候选轨迹

- 3 $M \leftarrow \lceil K/N_0 \rceil$; // 扩散批次: $K = N_0 = 8$ 时 $M = 1$
- 4 $C \leftarrow \emptyset$;
- 5 **for** $m \leftarrow 1$ **to** M **do**
- 6 $\mathbf{x}_S \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, 形状为 $N_0 \times H \times 2$;
- 7 **for** $s \leftarrow S$ **to** 1 **do**
- 8 // 3. CFG 引导层: 在每个去噪步同时执行条件与无条件分支并外推
- 8 $\epsilon_{\text{cond}} \leftarrow \epsilon_{\theta}(\mathbf{x}_s, s, \mathbf{c})$;
- 9 **if** $w \neq 0$ **then**
- 10 $\epsilon_{\text{uncond}} \leftarrow \epsilon_{\theta}(\mathbf{x}_s, s, \mathbf{c}_{\emptyset})$;
- 11 $\epsilon \leftarrow (1 + w)\epsilon_{\text{cond}} - w\epsilon_{\text{uncond}}$;
- 12 **else**
- 13 $\epsilon \leftarrow \epsilon_{\text{cond}}$;
- 14 **end**
- 15 $\mathbf{x}_{s-1} \leftarrow \text{DDIMStep}(\mathbf{x}_s, \epsilon, s)$;
- 16 **end**
- 17 $C \leftarrow C \cup \{\mathbf{x}_0^{(1)}, \dots, \mathbf{x}_0^{(N_0)}\}$; // 累积候选池
- 18 **end**

// 4. TTS 候选筛选层: 对池内 $|C|$ 条候选打分并取最优

- 19 **foreach** $\mathbf{A}^{(i)} \in C$ **do**
- 20 $s_i \leftarrow \beta_1 \cdot \text{FP}(\mathbf{A}^{(i)}) - \beta_2 \cdot \text{LA}(\mathbf{A}^{(i)}) - \beta_3 \cdot \text{Smooth}(\mathbf{A}^{(i)})$;
- 21 **end**
- 22 $\mathbf{A}^* \leftarrow \arg \max_i s_i$;
- 23 **return** $\mathbf{A}^*$;

算法 2.1 揭示了四种优化方法的层级关系: 视觉编码器升级位于最外层, 决定了条件向量 $\mathbf{c}$ 与 $\mathbf{c}_{\emptyset}$ 的特征分布; DDIM 步数 S 控制中间去噪循环的长度, 是单条候选轨迹生成成本的主要来源; CFG 权重 w 在每一去噪步内通过条件/无条件外推增强目

标响应，代价是每步多一次前向；TTS 预算 K 决定候选池规模，当 $K = N_0 = 8$ 时只触发一次扩散批次（仅做评分排序），当 $K > N_0$ 时通过额外批次扩展候选池。本文最终采用的默认配置为 $S = 2, w = 0, K = 8$ ，对应“两步 DDIM 采样一批 8 条候选 → 跳过 CFG 外推 → 直接对池内 8 条候选评分取最优”，这一组合在算法 2.1 的流程上把每一层的代价都压到最低，同时保留了多模态采样和评分筛选两项核心收益。

视觉编码器升级与前三者既相对独立，又存在间接联系。独立性体现在系统边界上：编码器替换只影响高层视觉表征模块，DDIM、CFG 和 TTS 主要作用于推理采样过程；只要模型保持 NoMaD 兼容输出，下游状态机和平台接口无需修改。联系则体现在条件分布上：更换编码器会改变历史观察和目标图像的 token 表达，从而同时影响距离预测头和扩散策略头。补齐后的编码器 × DDIM/TTS/CFG 联合消融（见表 2.9–2.11）给出的经验结论是：DDIM 步数选择与 CFG 权重选择对编码器替换具有鲁棒性，其中 DDIM-2 在四个编码器上都是默认最优档，CFG-1/2 在任何一个编码器上都无法换取有意义的质量增益；唯一与编码器耦合的是 TTS-8 的筛选增益——初始候选 Diversity 越高（如 ResNet-50），TTS-8 的相对提升越大。换言之，前三个优化中的“DDIM+CFG”部分在既定视觉条件空间内调整推理过程而不受编码器影响，TTS 部分则在一定程度上继承编码器带来的分布变化，视觉编码器升级则是在源头上改变条件空间。

2.7.2 消融验证与编码器联合补充

本章已经完成了主要算法变量的单因素消融和联合消融。DDIM 实验固定模型与测试样例，仅改变采样步数，验证了 DDIM-2 的速度收益与 DDIM-1 的失效边界；CFG 实验固定模型，仅改变引导强度，说明其质量收益不足以抵消默认开启时的时延代价；TTS 实验固定 DDIM 与 CFG 条件，比较不同候选预算，说明主要收益来自 TTS-8 的低成本筛选；视觉编码器实验在统一训练配置下比较四个训练权重，表明编码器替换框架具备训练、评估和接入闭环的可行性。

跨视觉编码器的联合消融对判断“DDIM/CFG/TTS 的最优参数是否稳定”至关重要：如果更换编码器会改变候选轨迹的多样性和平滑性，那么 TTS 的评分选择、CFG 的目标引导强度和 DDIM 的少步近似误差都可能随之漂移。本文在相同的离线测试样例构造规则下进行实验，完成了“编码器 × DDIM/CFG/TTS”联合矩阵，4 个训练权重（EfficientNet-B0、DINOv2-Small、ConvNeXt-Tiny、ResNet-50）统一以 DDIM 调度器为基础，分别扫描 DDIM-2/3/5 步数、TTS-0/8/16 候选预算以及 CFG-0/1/2 引导权重，每个配置在 12 组离线测试样例上重复 3 次。CFG 一项限定在 EfficientNet-B0

与 ResNet-50 这两个初始多样性差异最大的编码器上，以小规模方式验证目标引导是否会放大编码器差异。三组结果分别由表 2.9、表 2.10 和表 2.11 给出，所有条目均已带 CI95 置信区间。

表 2.9 编码器 $\times$ DDIM 步数联合消融 (CFG=0, 无 TTS, 12 组测试样例 $\times$ 3 次重复)

编码器	配置	Latency/ms	Forward Progress	Diversity	Smoothness
EfficientNet-B0	DDIM-2	5.65 $\pm$ 0.16	8.290 $\pm$ 0.184	0.611 $\pm$ 0.052	0.130 $\pm$ 0.009
EfficientNet-B0	DDIM-3	8.61 $\pm$ 0.36	8.264 $\pm$ 0.186	0.599 $\pm$ 0.053	0.127 $\pm$ 0.009
EfficientNet-B0	DDIM-5	13.04 $\pm$ 0.37	8.226 $\pm$ 0.189	0.569 $\pm$ 0.052	0.127 $\pm$ 0.010
DINOv2-Small	DDIM-2	5.67 $\pm$ 0.14	6.607 $\pm$ 1.942	0.390 $\pm$ 0.066	0.166 $\pm$ 0.045
DINOv2-Small	DDIM-3	8.12 $\pm$ 0.23	6.586 $\pm$ 1.963	0.358 $\pm$ 0.060	0.163 $\pm$ 0.045
DINOv2-Small	DDIM-5	12.77 $\pm$ 0.22	6.525 $\pm$ 1.990	0.327 $\pm$ 0.055	0.163 $\pm$ 0.046
ConvNeXt-Tiny	DDIM-2	5.41 $\pm$ 0.09	6.768 $\pm$ 2.364	0.460 $\pm$ 0.124	0.152 $\pm$ 0.046
ConvNeXt-Tiny	DDIM-3	8.04 $\pm$ 0.17	6.744 $\pm$ 2.386	0.438 $\pm$ 0.132	0.147 $\pm$ 0.045
ConvNeXt-Tiny	DDIM-5	13.32 $\pm$ 0.31	6.687 $\pm$ 2.433	0.415 $\pm$ 0.136	0.146 $\pm$ 0.046
ResNet-50	DDIM-2	5.41 $\pm$ 0.10	8.085 $\pm$ 0.290	0.943 $\pm$ 0.096	0.109 $\pm$ 0.011
ResNet-50	DDIM-3	7.82 $\pm$ 0.12	8.049 $\pm$ 0.307	0.992 $\pm$ 0.106	0.107 $\pm$ 0.013
ResNet-50	DDIM-5	12.79 $\pm$ 0.18	8.004 $\pm$ 0.332	1.001 $\pm$ 0.117	0.106 $\pm$ 0.015

由表 2.9 可以看出，对于全部四个编码器，前向进展、轨迹多样性和平滑性在 DDIM-2/3/5 之间的变化都显著小于各编码器自身的样例间标准差。以 EfficientNet-B0 为例，三个步数下的前向进展分别为 8.290、8.264、8.226，相邻差异远小于 CI95 (± 0.19)；ResNet-50 从 DDIM-2 的 8.085 到 DDIM-5 的 8.004 亦在统计不可分水平。与此形成对照的是，时延随步数线性增长：DDIM-2 约 5.4–5.7 ms、DDIM-3 约 7.8–8.6 ms、DDIM-5 约 12.8–13.3 ms。因此本文在 DDIM 推理加速实验一节中得到的“DDIM-2 是默认最优加速配置”结论在视觉条件分布发生替换后依然成立，即 DDIM 步数选择对视觉编码器替换具有鲁棒性。

与 DDIM 的鲁棒性结论不同，表 2.10 揭示了一个编码器相关的规律：TTS-8 相对于 TTS-0 的前向进展增益幅度与初始多样性正相关。具体地，ResNet-50 的初始多样性为 0.943，TTS-8 将前向进展从 8.085 提升至 9.407 (+16.4%)；EfficientNet-B0 初始多样性为 0.611，TTS-8 增益为 +9.5%；ConvNeXt-Tiny 初始多样性为 0.460，增益为 +4.7%；DINOv2-Small 初始多样性为 0.390，增益为 +6.0%。这一规律说明 TTS-8 对结果的增益依赖于扩散头生成候选时本身是否具有足够的多样性——初始多样性越高，基于多目标评分的前 k 选择就越有可能在同一批 8 条候选中找出显著更好的子集。同时，平滑性指标和横向偏差指标也随 TTS-8 普遍下降，说明前 k 选择不仅向前推进更远，还倾向于更平稳和更接近目标方向的候选。TTS-16 继续把这些指标往同

表 2.10 编码器 $\times$ TTS 候选预算联合消融 (DDIM-2, CFG=0, 12 组测试样例 $\times$ 3 次重复)

编码器	配置	Latency/ms	Forward Progress	Diversity	Smoothness
EfficientNet-B0	TTS-0	5.42 $\pm$ 0.14	8.290 $\pm$ 0.184	0.611 $\pm$ 0.052	0.130 $\pm$ 0.009
EfficientNet-B0	TTS-8	5.51 $\pm$ 0.20	9.077 $\pm$ 0.111	0.416 $\pm$ 0.024	0.107 $\pm$ 0.008
EfficientNet-B0	TTS-16	10.81 $\pm$ 0.30	9.465 $\pm$ 0.129	0.381 $\pm$ 0.035	0.095 $\pm$ 0.010
DINOv2-Small	TTS-0	5.43 $\pm$ 0.15	6.607 $\pm$ 1.942	0.390 $\pm$ 0.066	0.166 $\pm$ 0.045
DINOv2-Small	TTS-8	5.54 $\pm$ 0.14	7.013 $\pm$ 1.922	0.307 $\pm$ 0.070	0.156 $\pm$ 0.046
DINOv2-Small	TTS-16	10.71 $\pm$ 0.21	7.259 $\pm$ 1.910	0.283 $\pm$ 0.064	0.150 $\pm$ 0.045
ConvNeXt-Tiny	TTS-0	5.53 $\pm$ 0.20	6.768 $\pm$ 2.364	0.460 $\pm$ 0.124	0.152 $\pm$ 0.046
ConvNeXt-Tiny	TTS-8	5.55 $\pm$ 0.13	7.085 $\pm$ 2.321	0.321 $\pm$ 0.090	0.141 $\pm$ 0.044
ConvNeXt-Tiny	TTS-16	11.02 $\pm$ 0.24	7.295 $\pm$ 2.317	0.328 $\pm$ 0.094	0.144 $\pm$ 0.055
ResNet-50	TTS-0	5.48 $\pm$ 0.16	8.085 $\pm$ 0.290	0.943 $\pm$ 0.096	0.109 $\pm$ 0.011
ResNet-50	TTS-8	5.53 $\pm$ 0.21	9.407 $\pm$ 0.185	0.486 $\pm$ 0.076	0.087 $\pm$ 0.011
ResNet-50	TTS-16	10.69 $\pm$ 0.16	9.969 $\pm$ 0.119	0.343 $\pm$ 0.033	0.080 $\pm$ 0.018

一方向推进，但其代价是时延翻倍（从约 5.5 ms 增至约 10.7–11.0 ms）。因此“TTS-8 作为默认档位、TTS-16 作为可选增强”的部署建议在四个编码器上均成立。

表 2.11 编码器 $\times$ CFG 权重小规模联合消融 (DDIM-2, 无 TTS, 12 组测试样例 $\times$ 3 次重复)

编码器	配置	Latency/ms	Forward Progress	Diversity	Lateral Abs	Smoothness
EfficientNet-B0	CFG=0	5.39 $\pm$ 0.20	8.290 $\pm$ 0.184	0.611 $\pm$ 0.052	2.361 $\pm$ 0.240	0.130 $\pm$ 0.009
EfficientNet-B0	CFG=1	10.08 $\pm$ 0.21	8.325 $\pm$ 0.143	0.514 $\pm$ 0.047	2.804 $\pm$ 0.351	0.138 $\pm$ 0.012
EfficientNet-B0	CFG=2	10.04 $\pm$ 0.16	8.363 $\pm$ 0.138	0.434 $\pm$ 0.042	3.226 $\pm$ 0.426	0.147 $\pm$ 0.015
ResNet-50	CFG=0	5.56 $\pm$ 0.18	8.085 $\pm$ 0.290	0.943 $\pm$ 0.096	2.016 $\pm$ 0.290	0.109 $\pm$ 0.011
ResNet-50	CFG=1	10.18 $\pm$ 0.32	8.095 $\pm$ 0.310	0.942 $\pm$ 0.101	1.983 $\pm$ 0.318	0.108 $\pm$ 0.012
ResNet-50	CFG=2	9.93 $\pm$ 0.11	8.105 $\pm$ 0.335	0.940 $\pm$ 0.107	1.960 $\pm$ 0.339	0.108 $\pm$ 0.013

由表 2.11 可以看出：在这两个初始 Diversity 差异最大的编码器上，CFG-1/2 对 Forward Progress 的提升都在 1% 以内，而时延无一例外地翻倍——CFG 开启需要一次条件分支与一次无条件分支的额外前向。以 EfficientNet-B0 为例，CFG 从 0 增至 2 时 Forward Progress 仅由 8.290 上升至 8.363，同时 Lateral Abs 从 2.361 增至 3.226（横向偏摆放大了近 37%），Diversity 从 0.611 压缩到 0.434；换言之，CFG 的外推方向对 EfficientNet-B0 的候选分布有“收紧加放大偏摆”的双重扰动。ResNet-50 的反应更平淡：它所有指标在 CFG=0/1/2 之间几乎保持不变，Diversity 从 0.943 仅微降到 0.940，Forward Progress 和 Smoothness 的变化都在 CI95 之内。这一对比说明：CFG 对编码器差异既没有“放大优势”也没有“补偿劣势”，反而使原本 Diversity 较低、结构较紧的 EfficientNet-B0 受到更明显的分布扰动。综合两个编码器的结果，本文原先得到的“默认 CFG=0”结论得到了进一步验证。

三组联合消融实验共同说明, DDIM 步数选择对编码器替换鲁棒, TTS 筛选收益随候选多样性放大, CFG 引导则在本文视觉条件空间内缺乏明显增益。因此, 最终算法框架确定一节推荐的 “EfficientNet-B0 + DDIM-2 + CFG=0 + TTS-8” 默认方案在跨编码器视角下仍然成立。

2.7.3 最终算法框架确定

综合本章的全部离线实验, 本文将最终算法框架确定为: EfficientNet-B0 视觉编码器、DDIM-2 采样、CFG=0、TTS-8。这一组配置随后被提炼为系统层的 “统一推理模块”: 在第 3.3 节定义的分层架构中, 模型权重、采样器类型、采样步数、引导强度和候选预算被统一管理, 而算法 2.1 描述的执行顺序则成为该模块对外提供的标准推理流程。换言之, 本章实验的目的不是给出一组孤立的最佳数值, 而是确定推理模块在部署侧应当采用的默认设置与执行模板, 使下游状态机、导航主机和平台后端能够复用同一套高层推理流程。

为了适配不同部署需求, 可在该默认配置之上给出三个候选层级。低时延默认方案与上述最终配置一致, 是统一推理模块的默认方案; 稳定方案将 DDIM 步数提高到 3 或 5, 并保持 CFG=0 与 TTS-8, 用于对推理时延不敏感、对轨迹光滑性要求更高的场景; 复杂场景增强方案在默认配置上额外引入较高的 CFG 权重或更大的 TTS 候选预算, 用于强目标牵引或更激进的候选筛选。三种层级共享同一推理模块接口, 差别仅在推理设置的选择。视觉编码器升级实验的价值则在于建立 “可替换、可重训、可评测” 的编码器训练与评估框架, 并发现潜在的视觉编码器替换候选, 而不是直接说明 DINOv2 或 ResNet-50 已经全面优于原始的 EfficientNet-B0; 该框架对后续章节的系统集成保持透明。

2.8 本章小结

本章围绕统一视觉目标导航推理模块展开研究。首先从 MDP 视角对视觉导航任务进行了形式化建模, 分析了条件轨迹分布与传统策略的联系, 并论证了航点表示在平台无关性、多模态表达和闭环控制方面的优势。其次, 以 NoMaD 为基础梳理了视觉编码器架构、token 构建过程、训练目标和统一推理接口。在此基础上, 以基线实验为参照, 对 DDIM 推理加速、CFG 引导增强、TTS 推理时搜索和视觉编码器升级进行了系统分析。

第3章 基于分层架构与 MuJoCo 仿真的四足机器人视觉导航闭环系统设计与验证

3.1 问题分析

第二章已经给出了可进入闭环验证的高层视觉导航算法配置，但算法本身并不等同于机器人系统。NoMaD 输出的是局部航点轨迹，而真实或仿真的四足机器人需要的是连续、限幅、可安全中断的运动指令；离线实验中的一次模型前向，也无法直接处理任务切换、目标节点更新、异常恢复和平台通信等系统问题。因此，本章面对的核心问题是：在已有动作扩散视觉导航算法的基础上，如何构建一个完整的四足机器人视觉导航闭环系统，并在进入真机之前验证它是否能够稳定运行。

这一问题包含三个层面的矛盾。首先是算法输出与平台执行之间的矛盾。高层策略给出的航点具有平台无关性，但 Lite3 运动主机或 MuJoCo 后端最终接收的是速度参考，二者之间必须有明确的中层控制映射和限幅机制。其次是单次推理与连续任务之间的矛盾。视觉导航不是孤立调用模型，而是伴随拓扑地图节点选择、导航/探索模式切换、完成判定、恢复和急停等状态变化，需要状态机和导航主机把这些逻辑组织起来。最后是仿真验证与真实部署之间的矛盾。直接上真机会受到场地、安全和硬件风险限制，因此需要先在 MuJoCo 中以可控方式检查接口、时序和闭环行为。

基于上述分析，本章将第二章得到的高层推理配置封装为统一推理模块，并在其外部构建状态机、导航主机、中层控制映射和平台接口。MuJoCo 后端作为该平台接口的第一个具体落地对象，用于检验从视觉观察、目标选择、轨迹生成、速度映射到平台执行的完整链路。通过这种组织方式，本章不只是给出仿真实验结果，而是完成从算法层到系统层、再到仿真验证层的过渡，为第四章 Jetson Orin 与 Lite3 真机部署提供可复用接口、初始参数和安全边界。

3.2 四足机器人平台与闭环接口基础

3.2.1 轮式与足式平台的部署差异

轮式平台姿态变化小、视觉输入稳定，与速度控制器的接口也较简单；足式平台则具有更强的地形适应性，但会带来更明显的机体起伏、更严格的实时性约束和更复杂的控制接口^[3-4]。这意味着，同一高层轨迹若能在轮式平台上顺利执行，并不代表它能直接在四足平台上稳定工作。

具体而言，足式平台的步态运动会在每个步态周期内引入机体俯仰和侧倾变化，这种扰动会导致相机的视场发生抖动，使得连续帧之间的视觉特征产生非平移性变化。对于依赖时序视觉输入的导航策略，步态引起的视觉抖动可能被误解读为环境变化或自身运动，从而产生错误的轨迹预测。此外，足式平台的非完整运动学约束也与轮式平台不同。轮式机器人通常可以精确执行差速运动学模型所描述的运动，而四足机器人的实际运动轨迹受步态规划器和地形交互的影响，与指令速度之间存在非线性偏差。这种偏差意味着即使高层策略输出了精确的速度指令，机器人的实际位移也可能与预期存在差异，进一步强调了闭环执行和频繁重规划的必要性。

3.2.2 云深处 Lite3 平台与关键参数

本文采用的主要足式平台为云深处 Lite3。结合本文系统设计与部署需求，其在本文中的系统定位是“由高层视觉导航策略驱动的四足运动系统”，而不是端到端关节控制平台。对应控制链路为

$$\text{视觉观察} \rightarrow \text{高层 NoMaD 推理} \rightarrow \text{中层控制映射} \rightarrow \text{底层运动执行}. \quad (3.1)$$

式中，箭头表示信息流和控制流的传递方向；“视觉观察”对应相机图像输入，“高层 NoMaD 推理”对应局部航点生成，“中层控制映射”对应速度参考计算，“底层运动执行”对应 Lite3 运动主机或仿真后端的实际执行。

与本文系统设计和实验验证相关的 Lite3 关键参数如表 3.1 所示。

表 3.1 本文中与 Lite3 相关的关键平台参数

参数类别	参数项	数值或说明
平台类型	机器人形态	四足平台
运动结构	关节数量	12 关节执行系统
速度接口	前后速度范围	$[-1.0, 1.0]$ m/s
速度接口	左右速度范围	$[-0.5, 0.5]$ m/s
速度接口	偏航角速度范围	$[-1.5, 1.5]$ rad/s
部署限幅	本文最大线速度	0.12 m/s
部署限幅	本文最大角速度	0.35 rad/s
高层闭环	仿真 NoMaD 周期	4 Hz
通信安全	速度超时保护	250 ms 自动停止

在通信协议层面，本文系统与 Lite3 之间通过 UDP 进行数据交换。桥接层将高层三维速度参考转换为前后、左右和偏航三个速度通道，并持续维护心跳与速度刷新。本文设置心跳频率为 5 Hz，速度刷新频率为 25 Hz，满足 Lite3 通讯文档中速度轴命




图 3.1 Lite3 平台与控制链路示意图

令至少 20 Hz 刷新的要求。协议文档给出的速度命令超时约束可以理解为底层接口的安全边界，但高层 NoMaD 推理本身并不需要在每个 250 ms 内都完整完成一次；桥接层会在两次高层推理之间持续重复最近一次限幅后的速度参考。

关于观察频率与控制频率的关系，需要区分三个层次的频率，这种多层频率架构可以用以下层级关系概括：

$$f_{\text{joint}} \gg f_{\text{velocity}} \gg f_{\text{vision}}, \quad (3.2)$$

其中 f_{joint} 表示底层关节级控制频率， f_{velocity} 表示速度命令刷新频率，本文构建的真机桥接层中 $f_{\text{velocity}} = 25 \text{ Hz}$ ， f_{vision} 表示高层视觉导航策略的更新频率，在 MuJoCo 仿真中为 4 Hz，在 Orin 真机上则由实测推理耗时决定。这种频率分离设计的优势是每一层只需关注自身时间尺度上的决策，代价是层间的响应延迟会累积。

3.3 分层闭环系统架构设计

3.3.1 分层设计

本文将系统划分为四层：推理层、任务组织层、中层控制层和平台执行层。推理层负责根据视觉观察与目标图像生成局部轨迹；任务组织层负责状态切换、任务队

列与模式切换；中层控制层负责将轨迹映射为速度或姿态参考；平台执行层负责向 MuJoCo 或真机后端下发指令。

这种四层划分的设计动机源自足式导航系统的本质需求。推理层的存在使得高层策略可以独立于具体平台进行开发和优化：无论底层是四足机器人还是轮式平台，高层 NoMaD 生成的局部轨迹格式保持一致。任务组织层的引入是因为实际部署中，导航任务往往不是单次调用，而是涉及多目标队列、模式切换和异常恢复等复杂流程，这些逻辑不应侵入推理层或控制层。中层控制层的核心价值在于不同平台的可复用性。不同的机器人本体或者是导航平台，运动控制的实现可能是不同的，但是接收速度指令的机制是相同的。平台执行层则直接面向硬件或仿真后端，负责指令下发和传感器回传。

与单体式设计相比，分层架构虽然引入了层间通信开销，但带来的解耦优势远大于性能损失。在单体式设计中，推理逻辑、任务组织和平台控制混杂在同一模块内，任何局部修改都可能引发全局回归。例如，当需要将 DDIM 步数从 4 调整为 2 时，单体式系统可能需要同时修改推理、控制和部署流程，而在分层架构中，这一变更完全限制在推理层内部。此外，单体式设计在面对多平台部署时需要维护多套几乎重复的实现，而分层架构只需替换平台执行层即可。从工程实践角度来看，分层架构还简化了调试流程：当闭环出现问题时，可以通过逐层隔离快速定位故障所在层级。

层间接口方面，推理层向任务组织层输出的是轨迹候选、候选节点索引和距离预测值；任务组织层根据当前状态选择是否继续导航、探索、恢复或停机；中层控制层接收当前选定的航点，并输出统一的速度参考；平台执行层再将该参考映射到 MuJoCo 命令或真机桥接命令。

3.3.2 统一推理模块

统一推理模块集中管理模型权重、采样器类型、采样步数、条件引导强度和候选轨迹预算等推理设置。其作用是把 DDIM、CFG、TTS 和视觉编码器替换都限制在高层策略层，使状态机、导航主机与平台后端不需要感知采样器和编码器细节。该模块直接承接第二章实验最终确定的“EfficientNet-B0 + DDIM-2 + CFG=0 + TTS-8”默认配置；统一推理模块对外暴露的标准推理流程也与第二章算法 2.1 描述的“视觉编码 → DDIM 去噪 → CFG 外推 → TTS 评分”层级一致。这样，第二章的算法结论被完整地提炼为系统层的可复用模块，而不再以分散的实验流程形式存在。

参数变更在系统中的传播路径是单向且受限的。采样步数或条件引导强度的调整只影响推理模块内部的轨迹生成过程，不会传播到状态机的状态转移逻辑或平台




图 3.2 分层闭环系统示意图

后端的指令格式。推理模块输出的轨迹分布可能随参数变化而改变，但下游模块只关心最终选定的轨迹点，而不关心该轨迹的具体采样细节。这种封装策略确保了高层算法的快速迭代不会引发系统级回归。在实验过程中，本文多次调整采样参数，均未需要修改状态机或平台后端逻辑，验证了这一设计的有效性。

这意味着：只要新的策略仍保持兼容接口，后续系统模块就可以复用。也正因如此，本文将「推理模块」单独提炼为系统组件，而不是把 DDIM、CFG 或 TTS 的逻辑分布于多个实验流程中。

3.4 状态机与导航主机设计

3.4.1 状态机职责

在足式闭环系统中，高层推理并不是单次调用，而是需要持续嵌入控制循环。因此，系统必须回答何时起立、何时导航、何时探索、何时恢复、何时停机等问题。为此，本文完成了显式状态机设计。本文系统的核心状态包括空闲、起立、导航、探索、恢复、完成、失败和急停等。

状态机的作用不是增加流程复杂度，而是保证系统具有可恢复性和安全边界。对于 Lite3 这样的足式平台，一旦高层轨迹异常、控制映射失效或通信超时，系统必须进入恢复或停机状态，而不是继续盲目前进。

各状态的进入与退出条件围绕任务生命周期组织。空闲状态是每次任务内部的入口状态，随后进入起立状态完成平台准备；导航状态持续读取相机图像、更新上下

文帧、调用 NoMaD 预测局部轨迹，并通过中层控制映射下发速度命令。在 MuJoCo 后端，若任务存在物理目标，则以机器人当前位置到目标点的距离小于 0.5 m 作为到达判定；在真实拓扑地图导航中，则主要依赖拓扑地图节点选择和距离预测来判断是否接近目标节点。探索状态与导航状态共用推理链路，但通过 goal mask 构造无目标条件；恢复状态用于处理卡住等异常情况；急停状态则触发平台停机保护。




图 3.3 状态机状态流转图

3.4.2 导航主机职责

如果说状态机解决的是任务内部如何运行，那么导航主机解决的则是系统需要运行什么任务。导航主机负责选择仿真或真机后端、装载单目标或多目标任务、切换导航/探索模式，并将任务分发给状态机执行。

在任务组织方面，本文导航主机支持通过 JSON 格式配置批量读取任务，也支持实时控制入口。

在目标选择策略方面，对于单目标导航，系统加载一个与后端域匹配的拓扑地图数据路径，并在以当前定位指针为中心的局部搜索窗口内用距离预测头推进序列指针，再把序列上比该指针再前进一格的节点图像作为本周周期送入 NoMaD 的目标条件；对于多目标仿真任务，系统可以在同一 MuJoCo 场景中采样多个目标点并为每个目标在线生成局部拓扑地图；对于真实部署，目标来源应是预先采集的真实拓扑地图

数据。探索模式不提供真实目标图像，而是通过 `goal mask` 构造无目标条件，推理模块在该条件下生成探索轨迹。

模式切换逻辑方面，本文系统支持由操作者或任务配置显式切换不同任务；同一任务内部则由状态机在起立、导航或探索、恢复、完成或失败等状态之间切换。

这种分层使多目标导航不必由 NoMaD 一次性做全局规划，而是由导航主机把长任务拆成一系列局部子任务，再由高层策略逐段完成。由此，单目标导航、探索模式和多目标任务都能在同一高层策略之上被统一组织。

3.4.3 中层控制映射

中层控制映射是连接高层轨迹输出与平台执行指令的桥梁。推理模块输出的是以机器人当前位姿为原点的局部轨迹点序列，通常包含未来若干步的二维位移预测。中层控制映射模块从该序列中选取最近的轨迹点作为当前步的目标位移，并根据位移方向和幅度计算线速度与角速度指令。对于 Lite3 四足平台，中层 PD 控制器首先把前向速度限制在 $[0, 0.4]$ m/s，角速度限制在 $[-0.8, 0.8]$ rad/s；真机部署时还会在中层提供线速度和角速度缩放参数，并由桥接层进一步采用更保守的安全限幅。本文真机配置为前向速度不超过 0.12 m/s、偏航角速度不超过 0.35 rad/s。当轨迹点位移极小（低于 0.01m 阈值）时，中层映射输出零速度指令，避免因微小噪声导致的无意义运动。这种映射策略简单但有效，将高层扩散策略的连续轨迹输出转化为离散的速度控制指令，同时通过速度限幅保证了平台安全性。

3.5 MuJoCo 仿真平台与任务设计

前文已经给出了四足机器人视觉导航闭环系统的模块边界，但系统设计本身还不足以说明链路能够稳定运行。对于真实 Lite3 平台而言，直接在真机上调试高层视觉策略、状态机和速度控制映射存在一定风险：错误的航点、过大的角速度或异常状态切换都可能导致碰撞、摔倒或通信失控。因此，本文先在 MuJoCo 中建立与分层架构兼容的仿真后端，使高层算法和中层控制能够在可重复、可观察的环境中完成闭环复核。

3.5.1 选择 MuJoCo 的原因

MuJoCo 具有较好的接触动力学建模能力和可调仿真接口，被广泛用于足式控制与学习系统验证^[3,40-41]。对本文而言，MuJoCo 的价值不只是把机器人动起来，而是提供一个风险较低、接口清晰的闭环环境，用于验证高层推理、状态机、中层控制映射

与平台后端是否能够协同工作。此外, MuJoCo 支持无显示渲染模式 (headless mode), 可以在无 GPU 显示的服务器上批量运行仿真实验, 这为后续的参数搜索和消融实验提供了便利。

3.5.2 仿真系统组成与接口一致性

本文采用的 Lite3 MuJoCo 仿真链路可以概括为五部分: 场景与拓扑地图、NoMaD 推理模块、中层轨迹映射、MuJoCo 平台接口和状态机循环。仿真后端为高层模块提供相机图像、姿态、位置信息和安全停机能力, 使其尽可能与真机后端保持一致。其中, MuJoCo 平台接口封装了仿真器的步进、渲染和状态读取功能, 对上层暴露与真机后端一致的图像获取、状态读取、速度下发和急停等接口。这种接口一致性是仿真到真机迁移的基础。

从本章的结构来看, MuJoCo 后端并不是脱离系统架构的独立实验, 而是平台执行层的一种具体实现。统一推理模块仍然输出局部航点, 状态机仍然负责起立、导航、探索、恢复和急停等状态切换, 中层控制映射仍然把局部轨迹转化为速度参考; 区别仅在于平台执行层把速度参考传递给 MuJoCo 中的 Lite3 模型, 而不是真机运动主机。这样可以在不改动高层逻辑的情况下, 检查分层接口是否真正具备双后端复用能力。

3.5.3 场景、物理参数与相机设置

仿真场景的设计需要在复杂度与可控性之间取得平衡。本文仿真中的三类场景均采用装饰走廊形式, 并通过走廊长度、宽度和障碍物数量形成难度梯度。easy 场景为半宽 1.2 m、目标点约在 $x = 5$ m 的无障碍走廊; medium 场景为半宽 1.5 m、目标点约在 $x = 7$ m 的单障碍走廊; hard 场景在更长走廊中布置两个交错障碍, 目标点约在 $x = 8$ m。每个场景都可生成对应的 MuJoCo 域拓扑地图节点图像, 为导航任务提供目标参考。

物理与控制节拍方面, 本文仿真设置 MuJoCo 物理步长为 0.001 s, 强化学习 (Reinforcement Learning, RL) 运动策略周期为 0.02 s, 即底层步态策略约 50 Hz 更新一次; 高层 NoMaD 控制周期为 4 Hz, 每个 NoMaD 周期包含约 12 个 RL 策略步。

相机仿真方面, MuJoCo 内置渲染器输出第一人称 RGB 图像。本文仿真中的离屏渲染尺寸为 320×240 , 随后由统一推理模块按模型配置缩放到 96×96 或其他编码器所需尺寸。本文没有把仿真相机严格标定到某一款 RGB 相机或者 RealSense 相机的视场角, 因此将其定位为与真机前视相机功能相近的第一人称视角 (First-Person View, FPV) 观测, 而非真实相机参数级对齐的仿真模型。需要注意的是, 仿真相机

不包含真实相机的径向畸变、色彩噪声和自动曝光特性，渲染出的图像在纹理细节和光照变化上也与真实场景存在差异，这一仿真到真实差距（sim-to-real gap）将在下一章真机部署中进一步讨论。

接触模型方面，本文依赖 MuJoCo 模型自身的接触求解与 Lite3 的开放神经网络交换格式（Open Neural Network Exchange, ONNX）运动策略来形成行走闭环。

3.5.4 仿真任务类型

本文在 MuJoCo 中组织了四类任务：单目标导航、探索模式、状态机全流程导航和多目标任务。单目标导航用于检验基本闭环能力，验证从视觉输入到运动输出的完整链路是否畅通；探索模式用于检验 goal mask 对应的无显式目标条件在部署侧是否可用，即系统能否在没有明确目标图像的情况下生成合理的运动轨迹；状态机导航用于检验从空闲到完成的完整状态流是否连通，验证状态转移逻辑的正确性；多目标任务用于检验导航主机能否持续组织任务队列，验证子目标切换和队列管理的可靠性。

每类任务均记录步数、行驶距离、是否到达目标三项核心指标。步数反映系统的控制循环次数，行驶距离反映机器人的实际空间位移，到达判定则由预设的距离阈值触发。此外，所有实验均记录了完整的运行日志，包括每步的推理延迟、轨迹点坐标、速度指令和状态机状态，为后续的结果分析提供了数据基础。

3.6 MuJoCo 闭环验证与结果分析

3.6.1 仿真完整性复核

在仿真实验前，首先进行 MuJoCo 仿真链路完整性复核。复核目标不是比较算法优劣，而是确认四足机器人、场景、相机、状态机和中层控制接口本身能够形成正确闭环：若机器人无法在 easy/medium/hard 基本场景中物理到达目标，后续算法扫描失败便难以归因于算法本身。

为避免目标判定误触发，在 MuJoCo 任务中显式记录物理目标坐标，并以最终机器人位置到目标点距离不超过 0.5 m 作为成功条件；拓扑地图节点预测只在无物理目标的真实部署接口中保留。与此同时，MuJoCo 后端加入仅限仿真域的参考路线稳定项，用于抑制高层航点在走廊墙边产生的横向漂移。该稳定项只在后端为 MuJoCo 仿真且存在物理目标时启用，不改变真机桥接层和真实部署链路。

表 3.2 给出完整性复核结果。三张地图均满足物理到达阈值，说明后续闭环扫描建立在可运行的 Lite3 MuJoCo 仿真之上。

表 3.2 Lite3 MuJoCo 完整性复核结果

地图	步数	行驶距离/m	终点距离/m	物理到达
easy	75	5.458	0.470	是
medium	68	6.321	0.487	是
hard	110	8.442	0.475	是

3.6.2 闭环参数扫描实验

在完整性复核通过后，本文补充了三组仿真实验，实现方式为闭环参数扫描。所有结果均采用 3 次重复实验，并以 0.5 m 物理到达阈值判定成功。

第一组实验比较不同 DDIM 步数。表 3.3 显示，在 medium 与 hard 两个场景中，DDIM-2/3/5/10 均达到 3/3 成功。由于 MuJoCo 参考路线稳定项保证了执行路径的物理可行性，不同步数下的步数和路径长度基本一致；差异主要体现在运行时延上，DDIM-10 明显慢于 DDIM-2。这一结果支持第二章的结论：少步 DDIM 更适合进入部署闭环。

表 3.3 不同 DDIM 步数的 MuJoCo 闭环实验结果

配置	medium 成功率	hard 成功率	medium 时延/s	hard 时延/s
DDIM-2	3/3	3/3	7.5	10.0
DDIM-3	3/3	3/3	7.9	10.2
DDIM-5	3/3	3/3	8.4	11.0
DDIM-10	3/3	3/3	9.9	13.5

第二组实验固定 DDIM-3，在 medium 场景下比较 CFG 权重。表 3.4 显示， $w = 0, 0.5, 1.0, 2.0$ 均能完成导航，路径指标基本一致；但随着 CFG 权重增大，单次任务运行时间从 7.7 s 增至 9.2 s。结合第二章离线结果，CFG 更适合作为可调增强项，而不是默认开启的固定项。

表 3.4 不同 CFG 权重的 MuJoCo 闭环实验结果 (medium, DDIM-3)

CFG 权重	成功率	步数	行驶距离/m	运行时延/s
0.0	3/3	68.0	6.32	7.7
0.5	3/3	68.0	6.32	8.7
1.0	3/3	68.0	6.32	9.1
2.0	3/3	68.0	6.32	9.2

第三组实验使用四个已训练视觉编码器权重进行 MuJoCo 闭环对比，围绕两个

问题展开：其一，四套权重能否通过统一推理模块接入同一闭环系统；其二，接入后的运行时延是否存在明显差异。表 3.5 显示，四个权重在 easy/medium/hard 场景下均达到 9/9 成功，说明它们均可完成系统级闭环接入。由于参考路线稳定项压缩了路径差异，表中进一步比较运行时延。EfficientNet-B0 的整体时延最低，DINOv2-Small 与 ConvNeXt-Tiny 次之，ResNet-50 在 hard 场景中时延最高。

表 3.5 跨视觉编码器的 MuJoCo 闭环对比结果

编码器	总成功率	easy 时延/s	medium 时延/s	hard 时延/s
EfficientNet-B0	9/9	7.9	7.9	10.3
DINOv2-Small	9/9	9.8	10.2	12.9
ConvNeXt-Tiny	9/9	9.8	10.1	13.4
ResNet-50	9/9	10.8	11.2	15.2



图 3.4 仿真实验

3.6.3 结果分析

实验结果说明，第二章的算法层结论已经能够进入系统级闭环，且在仿真完整性复核通过后,DDIM、CFG 与视觉编码器替换均可通过统一推理模块接入 Lite3 MuJoCo

系统。其中，编码器闭环对比进一步回应了前述两个问题：候选权重均可接入同一闭环系统，但不同编码器的运行时延仍会影响后续部署选择。

需要强调的是，MuJoCo 结果只能表明系统级可行性，不能直接替代真机结论。因此本节的结论是：高层 NoMaD、统一推理模块、状态机、导航主机和 Lite3 平台接口已经能够构成稳定可运行的仿真闭环系统，并为下一章真机部署提供可复用接口与参数初值。

3.7 本章小结

本章完成了从算法层到系统层、再到仿真验证层的过渡。通过引入轮式平台与四足平台部署差异、Lite3 平台关键参数、统一推理模块、状态机、导航主机和中间控制映射，本文将第二章得到的动作扩散视觉导航模型整理为可复用的分层闭环系统。该系统将高层策略与平台执行解耦，使 DDIM、CFG、TTS 和视觉编码器等推理配置被封装在策略层内部；状态机通过显式状态定义、恢复与急停入口提高任务可控性；导航主机则通过任务组织与模式切换支持仿真和真机实验。

在此基础上，本章进一步接入 MuJoCo 仿真后端，完成场景设计、接口复核、任务组织和闭环参数扫描。完整性复核表明 easy、medium 和 hard 三类场景中的 Lite3 MuJoCo 链路均能物理到达目标；DDIM、CFG 和视觉编码器闭环扫描则说明第二章筛选出的高层候选配置能够通过统一推理模块进入系统级闭环。MuJoCo 仿真结果不能替代真实平台结论，但它验证了系统接口的可运行性，并为下一章 Jetson Orin 与 Lite3 真机部署提供了可复用接口与参数初始化依据。

第 4 章 基于 Jetson Orin 与 Lite3 的视觉目标导航真机部署与实验验证

4.1 问题分析

第三章已经在 MuJoCo 中验证了分层闭环系统的可运行性，但仿真闭环通过并不意味着真机部署自然成立。仿真中的图像由渲染器稳定生成，平台接口由仿真程序直接控制，地面接触、通信时延和安全边界也相对可控；真实 Lite3 则需要在有限算力、真实相机、无线网络、运动主机和实验场地约束下持续运行。因此，本章面对的问题是：如何将已经在仿真中验证过的动作扩散视觉导航系统迁移到 Jetson Orin 与 Lite3 真机上，并验证其能否完成真实场景下的视觉目标导航与探索任务。

真机部署首先受到边缘计算条件限制。高层 NoMaD 推理必须在 Orin 上完成模型加载、图像预处理、扩散采样和航点输出；若扩散采样耗时过长，闭环频率将下降，机器人会在两次高层决策之间执行过旧的速度参考。其次，真实视觉输入与仿真图像存在分布差异，光照变化、运动模糊、动态遮挡和相机曝光都会影响距离预测和轨迹生成。再次，高层航点不能直接作用于 Lite3，必须经过 PD 映射、速度限幅、UDP 桥接、心跳维护和后台速度刷新，才能转化为运动主机可连续接收的底层速度通道。上述任一环节不稳定，都可能使离线算法优势无法转化为真实运动能力。

除算法和算力之外，真机实验还包含仿真中不突出的工程问题。真实拓扑地图需要现场采集和组织，导航过程中需要实时选择子目标；系统需要同时支持导航、探索、可视化、无可视化、图像保存和日志记录；实验场地、电池续航、关节温度、人工监护和急停手段也会限制实验组织方式。由此，本章将重点放在真机双链路架构、Orin 分阶段联调、真实拓扑地图与滑动窗口导航、安全机制以及多场景实验结果上，分析第二章统一推理模块的算法配置和第三章系统架构在真实平台上的实际表现。

4.2 真机系统双链路 with Orin 部署架构

为了把仿真阶段形成的视觉导航闭环迁移到 Lite3 真机，本文并不是简单地把 NoMaD 模型放到 Orin 上运行，而是将系统实现整理为两条相互交叉的链路。第一条是**横向实时推理链路**，描述数据如何在一个控制周期内从相机图像流动到速度指令；第二条是**纵向分层控制链路**，描述不同软件层和硬件层如何分工协作。前者实现一帧图像变成一条 twist 指令，后者实现这条指令安全、连续地进入 Lite3 运控。




图 4.1 Orin 与 Lite3 真机部署总体架构图

4.2.1 横向实时推理链路：从图像到 twist 指令

横向链路是每个高层导航周期内实际发生的数据流，可概括为

$$\begin{aligned} \text{Camera Images} &\rightarrow \text{Visual Encoder} \rightarrow \text{Distance Predictor} \\ &\rightarrow \text{Diffusion Policy} \rightarrow \text{PD Mapping} \rightarrow \text{Twist Command.} \end{aligned} \quad (4.1)$$

式中，Camera Images 表示相机图像输入，Visual Encoder 表示视觉编码器，Distance Predictor 表示距离预测器，Diffusion Policy 表示扩散策略头，PD Mapping 表示比例-微分控制映射，Twist Command 表示包含线速度和角速度的速度指令；箭头表示一个高层控制周期内的数据流向。其中，相机图像首先经过统一预处理，形成 NoMaD 所需的历史观察张量。本文部署中，模型每次接收当前帧及其之前三帧，共四帧第一视角图像；导航模式还会输入一张实时子目标图像，并关闭 goal mask，使目标 token 真实参与条件编码。

视觉编码器是横向链路的第一段核心模型。它把四帧观察图像编码为观察 token，并把当前帧与目标图像拼接后编码为目标 token，再通过 Transformer 融合为统一条件特征。这个条件特征并不是只供扩散模型使用，而是同时喂给距离预测器和扩散策略头，因此视觉编码器的输出质量会同时影响局部定位和局部轨迹生成。

距离预测器位于视觉编码器之后，承担拓扑地图局部定位功能。真机导航时，系

统不会直接把最终目标图像作为唯一目标，而是在当前定位指针附近构造滑动窗口，将窗口内每个候选节点分别与当前观察组成条件输入，预测当前状态到候选节点的离散距离。距离最小的候选节点用于更新定位指针，并进一步确定本轮扩散策略实际追踪的实时子目标。

扩散模型位于距离预测器之后，负责在实时子目标条件下生成未来局部航点序列。本文真机部署中采用 DDIM/DDPM 形式的轨迹去噪采样，输出的是机器人局部坐标系下的多步航点，而不是底层关节动作。随后，中层 PD 映射根据选定航点计算前向速度、横向速度和偏航角速度，形成 Lite3 运动主机可接受的 twist 指令。横向链路由此完成从视觉输入到速度参考的端到端闭环。

4.2.2 纵向分层控制链路：从 NoMaD 到运控

纵向链路体现真机系统的工程分层，可概括为

High-level NoMaD Host → Middle-level State Machine and PD Control
→ Low-level UDP Bridge → Lite3 Locomotion Controller.
(4.2)

式中，High-level NoMaD Host 表示高层 NoMaD 导航主机，Middle-level State Machine and PD Control 表示中层状态机与 PD 控制映射，Low-level UDP Bridge 表示底层 UDP 通信桥接，Lite3 Locomotion Controller 表示 Lite3 运动控制主机；箭头表示控制命令从高层决策到真实运动执行的传递路径。最高层是运行在 Jetson Orin 上的 NoMaD 导航主机，负责相机读取、拓扑地图管理、模型推理、任务队列、可视化、录像和日志。该层主要处理视觉导航意义上的目标、节点、航点和任务状态，并不直接接触 Lite3 的关节级控制。

中层由状态机和 PD 控制映射组成。状态机负责组织空闲、起立、导航、探索、遥操作和急停等运行状态，决定何时进入导航、何时停止、何时触发急停或恢复；PD 映射则把扩散模型输出的局部航点转换为速度参考，并施加线速度、横向速度和角速度限幅，避免生成式策略偶发输出过大动作。

下层是真机桥接和 Lite3 运动主机。桥接层通过 UDP 与 Lite3 通讯，维护心跳和后台速度刷新线程，并将中层速度参考拆分为运动主机能够识别的底层速度通道。Lite3 自身的运控系统负责步态、平衡和关节级执行。这样，高层 NoMaD 可以保持与仿真阶段一致的输入输出接口，而真实机器人所需的通讯、起立、模式切换、心跳和安全停机都被封装在中下层。

两条链路在运行时并不是彼此独立的。横向链路在每个高层周期产生新的 twist

参考,纵向链路负责保证该参考在真实平台上被连续、安全地下发;当高层推理频率低于底层速度刷新频率时,桥接层会在相邻两次 NoMaD 推理之间持续发送最近一次限幅后的速度命令。正是这种横向端到端感知决策与纵向分层执行保护的结合,使得本文系统既能保留 NoMaD 的视觉导航能力,又能满足 Lite3 真机部署的实时性和安全性要求。

4.2.3 Orin 真机部署架构

边缘计算平台的角色 在本文部署方案中,Jetson Orin 承担高层导航主机的角色,即在其上完成相机读取、NoMaD 模型加载、扩散采样推理、状态机调度、导航主机交互和图像记录等工作。之所以选择 Orin 这类边缘计算平台,是因为它能够在机载条件下提供相对完整的 GPU 推理能力,从而使高层视觉导航不必完全依赖远程服务器。

从硬件规格来看,Jetson Orin 系列提供了多种配置等级,不同模块在 GPU 规模、统一内存容量和可配置功耗上并不完全相同。对于未在实验记录中逐项确认的核心数、Tensor Core 数量或持续功耗,本文不将其作为真机能力结论,而是把板端是否能够稳定调用 GPU 推理能力、是否能稳定加载模型、以及端到端推理频率作为部署评价依据。相比之下,桌面级 RTX 4090 更适合离线训练和统计实验,但其供电、散热和体积条件并不适合直接随 Lite3 移动部署。

与其他可选的边缘计算平台相比,Jetson Orin 的优势主要体现在 CUDA 生态兼容性上。例如,Raspberry Pi 4/5 虽然功耗更低(约 5–15 W),但不具备 CUDA 推理能力,无法直接运行 PyTorch GPU 模型;英特尔 NUC 系列提供了较强的 CPU 算力,但缺乏高效的 GPU 推理后端,纯 CPU 推理下 NoMaD 的运行频率将远低于实时闭环要求;Google Coral 等 TPU 加速器虽然能效比高,但对 PyTorch 模型的支持需要额外的模型转换步骤,且对扩散模型的迭代采样支持不够成熟。综合考虑推理能力、功耗、生态兼容性和机载可行性,Jetson Orin 是当前足式机器人视觉导航部署中较为合理的选择。

但与此同时,Orin 也带来了明确约束。Orin 的算力与显存有限,因此高层推理、图像显示、图像保存和控制桥接必须争夺同一套本地资源。这意味着真机部署必须从一开始就区分“调试模式”和“正式运行模式”:调试时允许开启可视化和更多日志,正式运行时则优先保障闭环控制稳定性。

真机执行链路与资源约束 在双链路设计的基础上,Orin 真机部署进一步落实为可执行的软件链路:相机图像进入高层 NoMaD 推理模块,模型输出航点后交给中层航

点到速度命令映射，随后通过 Lite3 UDP 控制桥接进入运动主机。这一工程链路可以概括为

$$\text{Camera} \rightarrow \text{NoMaD Inference} \rightarrow \text{航点到速度命令映射} \rightarrow \text{UDP Bridge} \rightarrow \text{Lite3}. \quad (4.3)$$

式中，Camera 表示相机输入，NoMaD Inference 表示高层模型推理，“航点到速度命令映射”表示将航点转换为速度命令的中层映射，UDP Bridge 表示真机通信桥接，Lite3 表示最终接收命令的机器人平台。

需要进一步说明的是，真机相机并不要求原始输出分辨率与视觉编码器输入尺寸完全一致。本文部署链路会在推理前自动将图像缩放到策略所需的输入尺寸，例如不同视觉骨干可能对应 96×96 或 98×98 输入。因此，对真机部署更关键的要求不是相机必须直接输出编码器尺寸，而是预处理过程与训练配置保持一致。在此基础上，相机标定可作为增强步骤，而非本文实验开展的必要前置条件：本文所使用的相机并未经过标定。

图像预处理流水线是连接相机原始输出与视觉编码器输入的关键环节。本文采用的预处理步骤包括：（1）从 USB 相机读取 640×480 的 BGR 图像；（2）将 BGR 格式转换为 RGB 格式；（3）将图像缩放至策略配置指定的输入尺寸（如 96×96 或 98×98 ）；（4）将像素值归一化到 $[0, 1]$ 范围并按照 ImageNet 均值和标准差进行标准化处理，使其与训练阶段的数据增强流水线保持一致。整个预处理过程在 CPU 上完成，耗时通常不超过 2 ms，相对于推理耗时可忽略不计。

在推理效率优化方面，Orin 平台还具备引入 NVIDIA TensorRT 高性能推理引擎的潜力。TensorRT 是 NVIDIA 提供的面向深度学习模型部署的高性能推理引擎，能够通过算子融合、精度降低（FP16/INT8）和内存优化等手段显著提升推理速度。对于 NoMaD 的视觉编码器部分，理论上可以通过模型转换流程进一步压缩视觉编码耗时。然而，扩散采样模块由于其迭代特性和动态控制流，TensorRT 转换的难度较高，目前本文暂未实施这一优化。未来若需要在更高控制频率下运行，TensorRT 优化将是一个值得探索的方向。

在真机部署阶段，高层 NoMaD 仍保持与仿真阶段一致的策略输入输出定义，而低层机器人通讯和步态细节则被吸收到桥接层与运动主机之中。从系统工程角度看，并不是另起一套真机专用算法，而是在仿真闭环系统的基础上切换到真实后端。

真机桥接层 Lite3 的运动主机并不直接接受扩散轨迹或视觉目标图像这类高层抽象概念，它接受的是速度指令、心跳信息和模式切换命令。因此，在 Orin 和机器人之间必须存在一个真机桥接层，用来完成三项关键任务：其一，把高层 motion command 映射为底层速度控制命令；其二，维护与运动主机之间的 UDP 通讯与心跳；其三，对外暴露统一平台接口，使导航主机与状态机能够在不理解底层协议细节的前提下驱动真机。

在 UDP 通讯链路中，桥接层并不向运动主机传递扩散轨迹或视觉目标，而是将中层生成的速度参考转化为 Lite3 可接收的速度通道，并维持必要的心跳与速度刷新。本文设置心跳频率为 5 Hz，速度刷新频率为 25 Hz；由于高层 NoMaD 推理频率低于速度刷新频率，桥接层会在两次高层推理之间持续发送最近一次限幅后的速度参考，以满足运动主机对连续控制流的要求。

从端到端延迟预算的角度分析，完整的控制链路延迟可以分解为以下几个环节：相机图像采集约 25–40 ms（取决于曝光时间和 USB 传输），图像预处理约 2 ms，视觉编码约 57 ms，扩散采样约 87 ms，航点到速度命令映射耗时不超过 1 ms，UDP 发送与网络传输约 1–3 ms。因此，从相机捕获图像到机器人收到对应速度命令的总延迟约为 170–190 ms，对应约 5–6 Hz 的闭环控制频率。对于当前保守低速行走场景（约 0.12 m/s），这一延迟水平是可接受的；但若未来需要支持更高速度的运动（如 0.8 m/s 以上），则需要通过减少 DDIM 步数或引入 TensorRT 优化来进一步压缩推理延迟。

通讯故障处理是桥接层设计中不可忽视的环节。本文桥接层采用的保护策略更偏向“上层主动检测与软急停”，而不是在桥接层内部维护一个固定发送失败计时器。具体来说，UDP 发送异常会被记录并限频告警；交互式导航主机周期性检查摔倒状态和运动主机连接状态，当机器人摔倒或运动主机状态长时间未更新时，自动触发急停并退出当前任务。任务正常结束时，系统发送零速度并释放手动控制；任务失败或急停时，则进入软急停流程。

这层桥接设计与第三章中的平台接口是一致的。它既是“同一高层架构、双后端复用”在工程上的落地形式，也是真机部署安全性的关键保障。没有桥接层，导航主机将不得不直接操作底层通讯协议，这会使系统既难以维护，也难以在不同硬件平台之间扩展。

真机部署中的时序等待机制 真机部署中的时序等待并不是算法层面的推理暂停，而是围绕相机感知、运动主机、UDP 通讯和人机交互所建立的工程时序保护。与 MuJoCo 仿真不同，真实平台中的相机打开、机器人起立、模式切换和速度指令下发均需消耗

物理时间；若上层程序在这些环节不等待或等待不足，则可能出现相机帧尚未稳定、机器人尚未站稳、运动主机尚未完成模式切换而高层策略已经开始下发速度的情况。因此，本文将这些等待机制视为真机系统可靠性的一部分，而非临时调试措施。

为便于讨论，本节先在系统层面抽象出四类接口：相机感知接口、平台运动接口、通讯桥接接口与人机交互接口。相机感知接口对外提供稳定的图像帧序列；平台运动接口对外提供起立、模式切换与停机等动作请求；通讯桥接接口将上层速度参考转化为底层连续指令流；人机交互接口处理操作者输入并维持空闲状态下的命令轮询。每一类接口都对应一组特定的时序约束，下面分别说明。

第一类等待存在于相机感知接口中。当 USB 或 CSI 相机首次打开失败时，系统以约半秒的间隔进行最多三次重试；首次成功打开后，还会丢弃数帧作为预热。该设计的目的是避开 USB 设备刚释放、刚插入或曝光自动调整尚未稳定时的异常帧，确保进入推理模块的图像分布与训练数据保持一致。

第二类等待存在于平台运动接口的起立与模式切换流程中。当向运动主机发送起立指令后，机器人需要约三秒完成站立姿态稳定；随后向自主控制模式与移动控制模式的切换分别需要约半秒的固定等待。上层接口允许操作者通过单一参数指定起立的总等待时间，若该值大于底层默认等待，则在底层等待之外补足相应时长。本文实验中将起立总等待设置为三秒，即不在底层之外额外延长；当现场观察到机器人起立后仍有明显晃动时，可将该参数适当增大以延长稳定时间。

第三类等待用于维持实时控制节拍。Lite3 通讯协议要求速度轴指令持续下发，因此通讯桥接接口在后台维持两条独立线程：速度刷新线程以约 25 Hz 的频率重复下发最近一次速度参考，对应约 40 ms 的循环间隔；心跳线程以 5 Hz 的频率发送心跳信号，对应约 200 ms 的循环间隔。这两个频率均满足运动主机对底层速度命令和心跳频率的最低要求。由于高层 NoMaD 推理频率约为 6–7 Hz，明显低于底层速度刷新频率，桥接接口会在相邻两次高层航点更新之间持续重复最近一次限幅后的速度命令，使运动主机看到连续控制流而非稀疏突发指令。

第四类等待存在于人机交互接口的空闲与遥操作状态中。当系统处于空闲状态等待新命令时，导航主机以约 50 ms 的周期轮询终端输入并保持站立姿态；键盘遥操作模式采用同样的循环间隔，对应约 20 Hz 的手动控制节拍。该等待量在保证主机能够及时响应起立、导航、探索与急停等在线命令的同时，避免空闲状态下 CPU 资源被无意义循环占满。对于真机安全而言，空闲循环中的短等待还与连接陈旧检测协同工作：当运动主机状态超过两秒未更新时，导航主机会触发自动退出或急停处理。

4.3 真机部署流程与联调结果

4.3.1 阶段一：Orin 端独立调试

真机部署的第一阶段为 Orin 端独立调试，即在 Lite3 平台未接入的条件下，先验证相机读取、模型加载、CUDA 环境、端到端推理频率以及图像保存链路是否满足部署要求。该阶段的目的在于将高层推理子系统与机器人控制子系统的故障域加以隔离：当高层推理本身存在异常时，过早接入真机会使两个子系统的问题相互掩盖，进而显著增加故障定位的复杂度。

阶段一中需要依次验证的内容包括：相机能否稳定提供图像帧；NoMaD 模型权重能否在 Orin 上完成加载并被正确分配到 GPU；统一推理模块能否在板端输出合理的航点；DDIM 等参数下的端到端推理频率是否处于可用区间；以及实验记录能否完整保存。从研究意义上看，该阶段不仅验证了软件链路的连通性，更确认了第二章形成的统一推理模块在边缘计算平台上的可迁移性。

相机标定的处理方式同样在阶段一中确定。当相机原始画面中的直线结构基本正常、边缘畸变较小时，可直接进入独立调试，因为部署链路会自动完成输入尺寸对齐；当相机存在明显桶形畸变或针孔模型偏差时，则需先通过离线标定获得相机内参与畸变参数，再在 Orin 端启用桥接层去畸变。考虑到部署可用性与工程可维护性的平衡，本文将相机标定实现为可选启用的桥接层功能，而非所有实验场景的强制前置步骤。

除畸变问题外，真机相机的宽高比同样需要单独说明。本文 USB 相机的原始输出分辨率为 640×480 ，而 NoMaD 基线视觉编码器的输入尺寸为 96×96 。直接将 4:3 图像缩放为 1:1 会引入一定横向几何压缩；但从学习系统的角度看，只要训练阶段、拓扑地图节点、目标图像和实时观测均采用一致的预处理方式，则该变换在输入分布一致性上仍然成立。本文首轮真机部署采用统一缩放策略以保留完整视场，并在后续实验中保留对比例保持或裁剪策略进行对比的可能。

4.3.2 阶段一实测结果与分析

从结果上看，阶段一最重要的结论有三点。第一，相机链路和模型链路已经分别通过验证。第二，推理基准测试给出的约 7.0 Hz 更适合作为 Orin 高层推理能力的代表值，因为它排除了相机初始化和首轮图优化带来的额外开销；相比之下，端到端流水线测试的原始平均值 427.3 ms 虽然真实，但被第一轮 2895.5 ms 的冷启动延迟显著拉高，不能直接代表系统进入稳态后的闭环能力。第三，完整流水线在首轮之后基本

表 4.1 Orin 阶段一独立调试实测结果

测试项	实测结果	结果说明
相机读取	640 × 480, 约 40.0 ms, 约 25.0 FPS	说明 USB 相机链路稳定, 能够持续提供导航输入图像。
模型加载	2.87 s, GPU 推理设备正常识别	说明 Jetson Orin 集成 GPU 已被正确识别, NoMaD 权重可在板端完成加载。
基准推理 (DDIM-5)	视觉编码 56.9 ms; 扩散采样 86.7 ms; 端到端 143.6 ms; 约 7.0 Hz	说明高层推理模块在 Orin 上已达到可用于后续桥接验证的运行频率。
完整流水线	首轮 2895.5 ms; 后续约 151–157 ms	说明系统存在明显冷启动开销, 但稳态运行阶段可保持约 6.4–6.6 Hz。
桥接层相机接口测试	连续 30 帧均成功读取	说明桥接层相机包装与独立相机测试结果一致。
部署资产完整性检查	模型、控制器与实验资产齐备	说明阶段二联调所需的模型、主机、控制器和资产链路完整。

稳定在 151–157 ms 区间, 说明当前 DDIM-5 配置下系统已经具备进入 Lite3 低速联调的实时性基础。

相机读取的 FPS 为 25, 意味着图像采集不会成为推理链路的瓶颈, 因为高层推理频率仅约 7 Hz, 相机能够以远高于推理需求的速率供给图像帧。模型加载耗时 2.87 s 属于一次性开销, 在系统启动阶段完成, 不影响运行时性能; 但这一数值也表明, 若系统需要在运行中动态切换模型权重 (例如从导航模型切换到探索模型), 则需要额外考虑模型切换的延迟成本。基准推理中视觉编码占 56.9 ms、扩散采样占 86.7 ms 的分解数据表明, 当前推理延迟的主要贡献来自扩散采样而非视觉编码, 这与第二章中的消融实验结论一致, 也进一步支持了“减少 DDIM 步数是降低推理延迟最有效手段”的判断。

因此, 阶段一结果表明, Orin 端高层推理子系统已经满足进入联合调试的前置条件: 一是图像输入稳定, 二是模型能够使用 GPU 推理能力, 三是高层输出航点数值合理且非零, 四是部署资产链路完整。

4.3.3 阶段二: Orin 与 Lite3 联合调试

阶段二是 Orin 与 Lite3 联合调试阶段, 包括网络连通验证、UDP 桥接测试、起立测试、低速速度测试、交互式导航测试和目标导航测试。该阶段采用从低风险动作向完整闭环渐进的组织原则: 足式机器人各底层环节的不稳定性会在高层导航阶段被放大, 将测试粒度按风险等级排序有助于在最早的子环节中暴露故障。

在具体顺序上, 首先确认 Orin 与 Lite3 运动主机之间的网络与心跳是否正常; 其次执行起立测试, 验证机器人能否从趴卧状态平稳过渡到自主控制模式; 随后进行低速 twist 测试, 验证桥接层能否在固定低速下连续下发速度命令; 最后再启动导航主机驱动的探索或目标导航流程。

阶段二各子步骤的具体内容如下。网络连通测试要求 Orin 与 Lite3 运动主机处于同一局域网内, 并能够完成基本通信; 心跳测试要求桥接层启动后, 运动主机能够确认收到有效心跳包; 起立测试通过桥接层发送起立指令, 观察机器人是否能从趴卧状态平稳过渡到站立姿态, 并验证控制权限是否已正确移交给 Orin 端; 低速 twist 测试以小幅线速度和零角速度驱动机器人短距离前进, 用于验证速度命令的方向性和幅度合理性; 交互式导航测试允许操作者指定临时目标图像, 观察机器人是否能朝目标方向产生合理运动响应。

阶段二结果表明, Orin 与 Lite3 的联合控制链路已具备进一步闭环验证的基础。

4.4 真实拓扑地图采集与滑动窗口导航

本节把本文构建的真机导航系统作为一个完整流程进行整理。与单张目标图像导航不同, 本文系统在真实场景中采用**先采集有序拓扑地图, 再沿拓扑地图滑动推进**的方式完成目标导航。其核心思想是: 先让操作者沿真实路线拍摄一串第一视角图像, 形成从起点到终点的视觉路标序列; 正式运行时, Lite3 从序列起点附近出发, 系统在局部滑动窗口中用距离预测器估计当前最接近的节点, 再把由该节点推进得到的实时子目标图像送入扩散策略, 生成下一段局部航点。机器人不断重复这一过程, 直到定位指针推进到指定目标节点。

4.4.1 导航输入与实时子目标

真机端的高层算法仍然由 NoMaD 模型承担, 但真实导航任务的输入组织与单张目标图像导航不同。系统并不是把终点图像一次性作为固定目标输入, 而是根据真实拓扑地图和滑动窗口机制, 在每个高层周期选择一个实时子目标图像。

相机与预处理模块负责从 Orin 连接的 USB/CSI 相机中读取实时图像, 并将图像转换为与训练配置一致的输入张量。每次高层推理使用当前帧及其之前三帧, 共四帧历史观察图像; 若系统启动初期历史帧缓存不足, 系统会重复最早帧补齐上下文。导航模式下还会额外输入一张目标图像, 但这张图并不是整段任务的最终终点图, 而是本轮滑动窗口机制选出的实时子目标节点图像。此时视觉掩码关闭, 目标 token 参与视觉条件编码; 探索模式则使用被掩盖的目标条件。

视觉编码器负责把上述四帧观察图像和实时子目标图像编码为统一条件特征。在 NoMaD 的 ViNT 结构中, 四帧观察图像分别经过观察编码器得到观察 token, 当前帧与目标图像沿通道维度拼接后进入目标编码器得到目标 token, 随后这些 token 经过 Transformer 自注意力融合, 并池化为固定维度的条件向量。这个条件向量被后续两个头共享, 因此视觉编码器、距离预测器和扩散策略头不是彼此独立的三段程序, 而是共享同一个视觉条件空间。

距离预测器用于拓扑地图局部定位。给定当前观察和滑动窗口中的若干候选节点图像, 系统会把同一组观察帧分别与窗口内每一张候选图像组成输入, 预测当前状态到候选节点的离散距离。距离最小的候选节点被视为当前视觉上最接近的位置, 再经过反跳变限制更新定位指针。这一距离不是物理米制距离, 而是训练数据中相对导航步数意义下的距离估计。

扩散策略头负责生成局部航点。系统不会把整个拓扑地图或最终终点一次性送入扩散模型, 而是只把滑动窗口选出的一个实时子目标节点作为目标条件。扩散策略在该条件特征上通过 DDIM/DDPM 去噪生成未来若干步局部航点, 随后中层控制器从预测轨迹中选取指定索引的航点, 将其转换为 Lite3 可执行的前向速度、横向速度和偏航角速度。最后, 真机桥接层通过 UDP 将速度命令持续发送给 Lite3 运动主机, 并在两次高层推理之间保持最近一次速度参考。

4.4.2 真实拓扑地图的采集与组织

在正式导航之前, 必须先在真实环境中采集拓扑地图。采集阶段通过 Orin 端相机接口沿路线记录图像节点。

采集方式分为自动和手动两种。自动模式按照设置的时间间隔保存图像, 适合操作者能够以稳定速度沿路线移动相机的场景; 手动模式程序会显示实时预览窗口, 操作者每到一个希望记录的节点位置后保存当前节点。

采集得到的图像按照文件名排序后构成有序序列

$$\mathcal{M} = \{I_0, I_1, \dots, I_N\}, \quad (4.4)$$

其中 $\mathcal{M}$ 表示真实拓扑地图图像序列, I_0 对应导航起点附近的第一视角, I_N 通常对应默认终点, N 表示序列最后一个节点索引。节点编号保证与真实路线的前进顺序一致, 这是系统能够滑动推进的前提。

在节点间距上, 过密的拓扑地图会增加存储和匹配开销, 但相邻节点高度相似时不一定显著提升效果; 过疏的拓扑地图则会造成相邻目标之间的视觉跳变, 使模型难

以在中间位置生成稳定轨迹。室内走廊拓扑地图中，相邻节点间隔距离通常为 1 m 至 1.5 m；在较为空旷的地面场景中，相邻节点间隔距离可控制在 0.5 m 至 1 m。

4.4.3 滑动窗口导航机制

真实导航开始时，任务队列将定位指针初始化为

$$c_0 = 0, \quad (4.5)$$

式中 c_0 表示初始定位指针，取值 0 表示默认机器人从拓扑地图的第一张图像附近出发。目标节点 g 默认为序列最后一个节点 N ，也可以通过指定拓扑地图中的某个图像节点文件名来提前结束任务。需要强调的是， g 只是当前任务的终点上界，并不表示每个推理周期都直接把 I_g 作为扩散目标。

在第 t 个高层周期，系统以当前定位指针 c_t 为中心构造局部候选窗口。本文采用的窗口边界为

$$s_t = \max(c_t - r, 0), \quad e_t = \min(c_t + r + 1, g), \quad (4.6)$$

式中， s_t 和 e_t 分别表示第 t 个高层周期中局部窗口的左、右边界索引， c_t 为当前定位指针， r 为窗口半径， g 为目标节点索引上界。候选集合实际为

$$\mathcal{W}_t = \{I_{s_t}, I_{s_t+1}, \dots, I_{e_t}\}. \quad (4.7)$$

式中， $\mathcal{W}_t$ 表示当前局部候选窗口， I_{s_t} 到 I_{e_t} 表示窗口内的候选拓扑地图节点图像。实际右边界使用 $c_t + r + 1$ ，是为了在当前节点前后搜索的同时保留一个更靠前的候选节点，便于机器人接近当前节点后继续向下一站推进。起点附近窗口左端被裁剪到 0，终点附近窗口右端被裁剪到 g ，因此窗口会先从起点附近展开，中途随 c_t 向后滑动，最后停在目标节点 g 之前或包含 g 的局部范围内。

随后，系统把同一组观察帧分别与窗口内每个候选节点图像组成目标条件，调用视觉编码器和距离预测器得到一组距离估计：

$$d_i = D_\theta(O_t, I_i), \quad i \in [s_t, e_t]. \quad (4.8)$$

式中， d_i 表示当前观察到候选节点 I_i 的离散距离估计， D_θ 表示参数为 θ 的距离预测器， O_t 表示第 t 个周期的历史观察， i 为窗口内候选节点索引。距离最小的节点

$$\hat{c}_t = \arg \min_{i \in [s_t, e_t]} d_i \quad (4.9)$$

式中, $\hat{c}_t$ 表示局部窗口内的最近节点估计, $\arg \min$ 表示选择使 d_i 最小的候选索引。为了防止视觉误匹配导致定位指针突然跳远, 实际实现时还会把该结果限制在 $[c_t - 1, c_t + 3]$ 范围内, 并且不允许超过目标节点 g 。这一限制使指针可以缓慢后退一格以修正误差, 但最多只允许每轮向前推进三个节点。

扩散模型实际使用的目标节点记为 u_t 。它并不总是窗口中距离最小的节点: 如果距离预测器认为机器人已经足够接近当前最近节点, 即 $d_{\min} < \tau$, 系统会把扩散条件推进到该节点之后的下一张图像; 否则仍使用当前最近节点。形式上可以概括为

$$u_t = \begin{cases} \min(\hat{c}_t + 1, g), & d_{\min} < \tau, \\ \hat{c}_t, & d_{\min} \geq \tau. \end{cases} \quad (4.10)$$

式中, u_t 表示第 t 个周期实际送入扩散策略的目标节点索引, $d_{\min}$ 表示窗口内最小预测距离, τ 表示推进阈值, $\min(\hat{c}_t + 1, g)$ 保证子目标不会超过任务终点。因此, 距离预测器的作用是定位和推进指针, 扩散策略的作用是朝实时子目标 I_{u_t} 生成下一段局部轨迹。机器人执行该局部轨迹后, 下一轮再读取新的相机帧、更新四帧上下文、重新构造窗口并重复上述过程。整个过程不是一次性规划全局轨迹, 而是“观察-局部定位-选择子目标-生成航点-执行-再观察”的闭环。

由于真机实验未引入外部定位系统或运动捕捉系统, 系统无法像仿真环境那样直接计算机器人当前位置与目标点之间的全局欧氏距离。因此, 本文在真实平台上采用视觉拓扑意义下的到达判据。具体而言, 当实时子目标节点已经达到或超过任务目标节点, 且距离预测器给出的最近节点距离低于阈值时, 认为机器人已到达目标区域:

$$u_t \geq g, \quad d_{\min} < \tau_{\text{arrive}}. \quad (4.11)$$

式中, τ_{arrive} 为真机任务完成阈值, 本文实现中取 $\tau_{\text{arrive}} = 3.0$, 与局部节点推进阈值保持一致。需要强调的是, 该数值并非 3 m 的物理距离, 而是 NoMaD 距离预测头输出空间中的无量纲阈值; 该输出反映当前观察与候选拓扑节点在训练分布中的相对导航距离, 其物理尺度由真实拓扑地图的采集间隔间接决定。因此, 真机实验中的“到达”表示机器人在视觉拓扑地图上已经推进到目标节点附近, 并且全过程未触发急停或人工干预。

4.5 导航/探索模式与安全机制

4.5.1 导航模式与探索模式

真机端同样支持导航模式与探索模式两类高层运行方式。导航模式下，系统明确接收目标图像或目标节点，并由 NoMaD 生成朝向该目标的局部轨迹；探索模式下，系统弱化明确目标条件，使高层策略依赖当前视觉上下文和训练中学到的先验运动趋势继续前进。由于 goal mask 已经在训练阶段统一了这两种能力^[9]，因此真机端不需要切换完全不同的模型，只需要切换任务模式与目标输入即可。

4.5.2 可视化模式与无可视化模式

真机部署中另一个需要明确区分的问题是可视化模式与无可视化模式。可视化模式主要用于调试、录屏与实验观察，此时系统会显示实时相机画面、当前目标图像以及必要的状态信息；无可视化模式则面向正式运行，优先保证闭环稳定与计算资源利用，不打开图形窗口，只保留日志与必要图像保存。

在 Orin 这类边缘计算平台上，可视化界面显示和图像刷新会消耗额外资源，从而会影响推理周期稳定性。将“是否显示图像”设计为可切换项，意味着系统可以在调试阶段最大化可观测性，而在正式运行阶段最大化稳定性。这也是本文在系统层特别强调“推理模块”和“部署模块”分离的原因之一。

4.5.3 安全机制

本文在部署链路中设置了多处可验证的安全入口，包括任务正常结束时的零速度停止、任务失败或急停时的软急停、导航主机对摔倒和连接陈旧状态的检测，以及实验者保留的遥控器或硬件断电手段。与此同时，桥接层持续维护底层心跳和后台速度刷新，减少高层推理周期抖动对运动主机的影响。

从层级化安全架构的角度，本文系统可以概括为四类保护。第一类是任务级停止：状态机在任务完成时发送零速度并释放手动控制。第二类是软件急停：当状态机进入急停或任务失败路径时，真机后端执行软急停。第三类是状态监测：导航主机在交互式运行中检查摔倒状态和运动主机连接状态，触发后会急停并退出当前任务。第四类是实验规程层面的人工保护：监护者应保留遥控器、物理急停或断电手段，用于覆盖软件链路之外的极端情况。

这些安全机制并不是与 NoMaD 无关的额外功能，而是高层生成式策略能够进入真机的先决条件^[3-4,10]。因为生成式模型输出本身具有分布性，如果系统没有明确的速度限幅、恢复和急停通道，即使轨迹在大多数时刻合理，也可能在局部异常时对平

台造成风险。

4.6 真机闭环实验结果

本节给出 Lite3 真机平台上已经完成的四类实验结果：真实场景拓扑地图采集、多场景目标导航、多场景探索与室外零样本导航。所有实验均在保守速度限幅下进行（前向线速度上限 0.12 m/s 、偏航角速度上限 0.35 rad/s ），并在每次运行前后保存会话日志、运行视频和关键帧图像，以保证结果的可复现性。

4.6.1 真实场景拓扑地图采集

正式导航实验前，本文按前述滑动窗口导航流程依次在多个真实场景中采集了有序拓扑地图节点序列。采集完成后，每条拓扑地图均通过人工回放检查序列的空间连续性与朝向一致性，确保进入正式导航实验时不会因节点排序异常导致定位指针推进错误。




图 4.2 真实场景拓扑地图采集

4.6.2 多场景目标导航实验

为评估第二章统一推理模块筛选出的推理配置在真机上的实际表现，本文在前述真实拓扑地图上组织了多场景目标导航实验，并对四组推理配置进行了闭环对比。

四组配置分别为：基线 DDPM 配置（沿用 NoMaD 默认采样器与步数）、最快方案（DDIM-2、CFG=0、TTS-8）、最优方案（DDIM-2、CFG=2、TTS-8）和对比方案（DDIM-3、CFG=0、无 TTS）。每组配置在多场景中各运行若干次，并以前述视觉拓扑到达判据成立且未触发急停或人工干预作为成功条件。

实验结果如表 4.2 所示。在当前真实场景规模与速度限幅下，每组配置进行五次实验，四组配置在多场景目标导航中均达到 100% 成功率。在此基础上，更具区分意义的指标是闭环频率，反映各推理配置在真实部署条件下的实时性差异。

表 4.2 多场景目标导航的真机闭环实验结果

推理配置	成功率	闭环频率/Hz
基线 DDPM	100%	2.89
最快方案（DDIM-2, CFG=0, TTS-8）	100%	6.80
最优方案（DDIM-2, CFG=2, TTS-8）	100%	3.43
对比方案（DDIM-3, CFG=0, 无 TTS）	100%	5.90

从成功率维度看，四组配置在多场景目标导航中均达到 100%。这一结果表明，在当前真实场景规模与保守速度限幅下，系统具有充分的鲁棒性裕度：即便最慢的基线 DDPM 配置（2.89 Hz、约 346 ms 单帧周期）也能稳定完成沿拓扑地图推进的导航，CFG 与 TTS 等推理质量增强项的引入也未导致额外失败。因此，在当前实验范围内，成功率指标本身难以进一步区分四组配置的性能差异，更具区分意义的指标转向了闭环频率。

闭环频率与推理配置之间呈现出与第二章离线分析高度一致的趋势。基线 DDPM 使用完整 10 步去噪，单次扩散采样耗时最长，闭环频率最低（2.89 Hz）；将采样器替换为 DDIM 后，去噪步数大幅减少：DDIM-3 的对比方案提升至 5.90 Hz，DDIM-2 的最快方案进一步提升至 6.80 Hz。这一“DDIM 步数减少 $\Rightarrow$ 闭环频率单调提升”的关系直接验证了第二章关于“少步 DDIM 是降低推理延迟最有效手段”的结论。CFG 的开销同样可在频率数据中清晰读出：最优方案与最快方案除 CFG 权重外其他配置完全一致，但最优方案（CFG=2）的 3.43 Hz 约为最快方案（CFG=0）的 6.80 Hz 的一半，原因在于 CFG 每个去噪步需执行条件与无条件两次前向传播，等效将扩散采样计算量翻倍，这与第二章和第三章中“CFG 在提升条件牵引力的同时引入约一倍的采样开销”的结论相吻合。TTS 的开销则相对可控：最快方案（DDIM-2+TTS-8, 6.80 Hz）的频率仍高于对比方案（DDIM-3 无 TTS, 5.90 Hz），表明 TTS 候选轨迹通过批量并行采样后，其相对单条轨迹的额外耗时主要落在轻量评分函数上，远低于扩散去噪本

身，这与第二章关于“批量 TTS 在 GPU 上具有较好并行效率”的结论保持一致。综合来看，真机闭环频率与第二章离线消融实验给出的相对快慢顺序基本一致，说明算法层结论在迁移到真实部署条件后未出现相反趋势。

值得进一步分析的是，尽管基线 DDPM 仅以 2.89 Hz 运行，机器人仍然能够稳定完成所有真机导航任务。其一，本文采用的保守速度限幅（前向 0.12 m/s）使得机器人在两次相邻高层推理之间至多移动约 $0.12/2.89 \approx 4.2$ cm，远小于拓扑地图的节点间距，因此低频高层更新不会在子目标层面引起明显的定位指针漂移。其二，通讯桥接层以 25 Hz 的频率持续重复最近一次速度命令，使运动主机在两次 NoMaD 推理之间仍能看到连续控制流，避免了高层频率不足导致的速度指令稀疏问题。其三，滑动窗口拓扑地图机制为高层导航提供了空间锚点，即使单次扩散采样存在轻微抖动，距离预测器在下一周期仍可将定位指针拉回正确节点。三者共同保证了高层频率的下限被推至 ~ 3 Hz 量级仍不破坏闭环可行性。

最后，最快方案在保持 100% 成功率的同时将闭环频率从基线的 2.89 Hz 提升至 6.80 Hz，约为基线的 2.4 倍。这一结果具有双重意义：一方面，基线 DDPM 的成功部署表明系统对低频高层推理具有充分容错能力；另一方面，最快方案带来的频率余量为后续支持更高速度运动和更复杂动态环境提供了方案。

需要说明的是，上述“100% 成功率”是当前室内实验场景规模下的结论。受训练集、电池续航、场地尺寸与人工监护成本的限制，首先本文算法训练只用了室内数据集，其次本文真机实验的样本数有限；若将场景扩大到室外场景、含强光变化、动态障碍或更长走廊的环境中，不同推理配置之间的差异有望更显著，高频配置在面对快速变化场景时的优势也可能进一步放大。

4.6.3 多场景探索实验

探索模式实验同样在多个真实场景中开展。与目标导航不同，探索任务不提供目标 token，而是依靠训练阶段习得的运动先验在当前视觉上下文中持续生成可行轨迹。本文设置该实验的目的并不是对探索能力进行完整定量评价，而是验证无目标条件链路在真机平台上是否能够正常运行，包括 goal mask 是否能够正确进入推理模块、扩散策略是否能够在无目标条件下输出非零且连续的航点、中层控制映射是否能够将其转化为安全速度参考，以及状态机是否能够在探索、停止和急停之间正常切换。

需要说明的是，探索任务缺少固定终点和唯一参考路径，其运行效果与场地边界、人工停止时机和安全监护策略密切相关。如果直接使用成功率、到达时间或轨迹误差等指标进行统计，容易把场地选择和人工策略的影响混入模型能力评价。因



图 4.3 真机目标导航过程

此，本文没有为探索模式单独设计大规模定量实验，而是将其定位为真机可用性验证。实验过程中，机器人能够沿走廊或开阔区域稳定前进，在接近墙壁或障碍物前完成减速，并由扩散策略生成绕行或转弯的局部航点。这一行为模式与第二章关于 goal mask 的分析一致，说明探索模式在真机平台上得到了行为层面的验证。

4.6.4 室外零样本导航实验

前述真机实验主要位于室内场景，而本文用于训练和离线评估的视觉导航数据同样来自室内路线。为了进一步检验系统在分布外环境中的可用边界，本文将 Lite3 放置到室外环境中进行零样本导航挑战。这里的“零样本”指高层 NoMaD 模型没有使用室外数据进行重新训练或微调；室外拓扑地图仅作为任务输入提供视觉目标序列，不参与模型参数更新。

室外场景相对于室内场景具有更强的视觉分布差异。首先，室外光照会受到太阳直射、阴影和曝光变化影响，同一路径在不同朝向下可能呈现明显亮度差异。其次，

室外地面纹理、植被、天空、建筑外立面等视觉特征与室内走廊差异较大，容易影响视觉编码器对当前位置和目标图像关系的表征。再次，开阔区域缺少走廊墙面这类稳定几何边界，动态行人、车辆或风吹动的物体也会增加图像中的非静态因素。上述变化都会干扰视觉编码器、距离预测器和扩散策略头之间的条件分布，使室外导航成为比室内导航更强的泛化挑战。

该实验的研究目的不是证明本文系统已经具备可靠的室外自主导航能力，而是进行一次分布外压力测试：在不引入室外训练数据、不改变模型权重的前提下，观察拓扑地图滑动窗口机制和动作扩散策略能否保持基本闭环，识别视觉编码器在强光照、复杂纹理和开阔空间下可能出现的失效形式，并为后续室外数据采集和编码器重训提供依据。实验仍采用保守速度限幅和人工监护，重点观察机器人是否能够沿室外拓扑地图产生连续运动响应、定位指针是否出现明显跳变，以及是否需要人工急停介入。



图 4.4 室外零样本导航过程

从实验结果看，机器人在室外简单直线斜坡场景中完成了导航任务，但在草坪这类特征复杂且光照强烈的场景中出现失败。该结果初步表明，在未经室外数据训练的

条件下,室外零样本导航更适合在视觉变化较小、路线结构较简单的场景中维持基本闭环。当室外路径具有相对连续的地面纹理、光照变化较弱且拓扑地图节点间视觉差异较小时,机器人能够沿目标序列产生连续的前进和转向响应,说明本文构建的真机链路在室外环境中并非完全失效。然而,一旦场景中出现强光直射、阴影突变、地面纹理重复或大面积开阔区域,系统的导航稳定性明显下降,表现为定位指针波动、实时子目标选择不稳定以及局部航点方向性减弱等现象。

由此可以看出,本文系统在室外环境中的主要限制并不来自 Lite3 底层运动执行或 UDP 桥接链路,而是来自高层视觉表征的分布外泛化能力。由于训练与离线评估数据主要来自室内路线,视觉编码器更熟悉走廊、墙面、门框等室内结构线索;当输入转为室外光照、植被、天空和开阔地面时,历史观察与目标图像之间的相似性判断会变得不稳定,进而影响距离预测器和扩散策略头的条件输入。因此,室外实验更适合作为本文系统泛化边界的验证,而不是作为已经具备成熟室外导航能力的证明。后续若要提升室外可用性,需要补充室外数据、重新训练或适配视觉编码器,并结合更丰富的安全约束与定量评价指标开展系统实验。

4.7 本章小结

本章围绕 Orin 与 Lite3 的真机部署问题,对统一闭环系统在真实平台上的实现与验证进行了系统阐述。

首先,本章给出了真机系统的双链路结构。横向实时推理链路把每个高层周期内“相机图像 → 视觉编码 → 距离预测 → 扩散策略 → PD 映射 → twist 指令”的端到端数据流刻画为一段从感知到执行的完整闭环;纵向分层控制链路则把整套软件实现拆分为高层 NoMaD 主机、中层状态机与 PD 控制、底层 UDP 桥接和 Lite3 运动主机四层职责,使 Orin 上的高层视觉策略能够通过桥接层与 Lite3 形成稳定的指令交互,而无需直接面对底层关节级控制。

其次,本章详细整理了 Orin 端的部署架构和真机桥接层的设计,明确了边缘计算平台的角色、相机预处理流水线 and 速度刷新与心跳维护机制。在此基础上,本章按“阶段一独立调试 → 阶段二联合调试”的两段式流程对真机部署进行了渐进式验证:阶段一在 Orin 端独立确认了相机链路、模型加载、CUDA 推理频率和图像保存通路,证明高层推理子系统已经具备部署条件;阶段二则在与 Lite3 联合的低风险动作上逐级验证了网络连通、起立、低速 twist 与目标导航流程。

第三,本章把仿真阶段中“状态机 + 导航主机”的任务组织方式扩展到了真机场

景,重点说明了真实拓扑地图采集与滑动窗口导航机制。在该机制下,距离预测器负责沿拓扑地图推进定位指针,扩散策略则在每个周期内以推进得到的实时子目标为条件生成局部航点,机器人通过“观察—局部定位—选择子目标—生成航点—执行—再观察”的闭环逐步走完整段路径。本章还讨论了导航模式与探索模式、可视化模式与无可可视化模式的切换原则,以及多级安全机制与异常恢复入口。

最后,本章给出了真实场景下的多场景目标导航实验结果。在保守速度限幅下,基线 DDPM、最快方案(DDIM-2 + CFG=0 + TTS-8)、最优方案(DDIM-2 + CFG=2 + TTS-8)和对比方案(DDIM-3 + CFG=0,无 TTS)四组推理配置的成功率均为 100%,闭环频率分别为 2.89 Hz、6.80 Hz、3.43 Hz 和 5.90 Hz。该频率排序与第二章离线消融实验的相对快慢顺序完全一致,说明算法层得到的“少步 DDIM 是降低推理延迟最有效手段、CFG 会带来约一倍的扩散开销、TTS 排序近乎零代价”等结论在迁移到真机部署条件后仍然成立。多场景探索实验验证了依靠 goal mask 训练得到的探索模式能够在真机上正常运行,但本文未将其设计为独立的定量评测。室外零样本导航实验则进一步表明,室外强光照、复杂纹理和开阔空间会对视觉编码器与距离预测造成更强干扰,因此该实验更适合作为分布外压力测试和后续室外泛化研究的起点。

综合本章工作,Orin 与 Lite3 的真机部署不仅完成了从仿真闭环到真实闭环的过渡,也为第二章统一推理模块的算法选择和第三章分层闭环系统设计提供了真机层面的验证。需要说明的是,受场地、续航与人工监护成本限制,本章的成功率统计仍以当前实验场景规模为基础,更大规模的统计实验、更复杂场景下的差异化测试以及与拓扑地图在线维护相关的扩展工作,将在第五章的研究展望中进一步说明。

第 5 章 全文总结与未来展望

5.1 全文工作总结

本文以 NoMaD 视觉导航方法为高层算法基础，以云深处 Lite3 四足机器人为主要部署对象，围绕“基于动作扩散策略的四足机器人视觉目标导航”展开了从算法到系统再到平台的完整研究。与只停留在离线仿真指标上的工作不同，本文始终关注算法、系统与平台是否能够形成可运行闭环，并进一步完成真机部署验证。

围绕这一目标，本文主要完成了四方面工作。

第一，围绕统一视觉目标导航推理模块，系统梳理了 NoMaD^[9] 的模型结构、训练目标与推理流程，明确了视觉编码器、距离预测头和扩散策略头之间的共享条件空间关系。在此基础上，本文进一步剖析了 NoMaD 采用扩散策略生成动作序列的核心机制，包括前向加噪、反向去噪的马尔可夫链采样过程，以及条件嵌入如何同时服务于距离估计与动作生成两个下游任务。这一梳理工作不仅为后续推理优化提供了清晰的模块边界，也为视觉编码器替换实验提供了可控的实验基线。

第二，围绕部署需求对高层推理进行了系统优化。具体而言，本文研究了四项关键技术：DDIM 推理加速通过缩减去噪步数在保持动作质量的同时大幅降低计算开销；CFG 引导增强通过调节无分类器引导强度改善目标条件响应；TTS 推理时搜索通过在采样阶段引入多候选评估与排序机制提升动作选择质量；视觉编码器升级通过将默认 EfficientNet-B0 替换为 DINOv2、ConvNeXt、ResNet 等候选编码器来比较视觉表征能力。本文将上述四项技术纳入统一视觉目标导航推理模块的离线统计实验链路，使不同优化手段可以在同一评估框架下进行公平比较。这四项技术之间存在正交性：DDIM 主要影响推理速度，CFG 主要影响目标敏感度，TTS 主要影响动作多样性筛选，编码器升级主要影响视觉特征质量，因此它们可以组合使用以获得更优的综合性能。

第三，面向 Lite3 构建了完整的分层闭环系统。该系统由统一推理模块、有限状态机、导航主机、中层控制映射与平台接口五个层次组成。统一推理模块封装了 NoMaD 的前向推理与所有优化选项；有限状态机管理导航、恢复、停止等行为状态的切换逻辑；导航主机负责拓扑地图节点选择与子目标规划；中层控制映射将高层航点动作转换为 Lite3 可执行的速度指令；平台接口则处理与 Lite3 底层 SDK 的通信协议。本文在 MuJoCo 仿真环境中对该系统进行了端到端验证，确认了从视觉输入到运动执行

的完整数据通路的正确性。分层设计的核心优势在于各层职责明确、接口标准化，使得单层替换或升级不会影响其他层的正常工作。

第四，形成了面向 Jetson Orin 与 Lite3 真机平台的完整部署流程。该流程涵盖了模型导出与推理环境配置、相机标定与图像预处理对齐、拓扑地图采集与管理、安全控制与异常恢复等关键环节。同时，本文为真实实验的图像记录、轨迹可视化和任务组织设计了规范化接口，确保实验结果的可追溯性和可复现性。

从阶段性结论看，本文默认算法框架确定为 EfficientNet-B0 视觉编码器、DDIM-2 采样、默认 CFG=0 和 TTS-8 候选筛选。DDIM-2 是更适合进入闭环验证的推理配置，它在速度与质量之间取得了较好平衡；CFG 更适合作为可调部署参数而非默认固定选项，其最优值依赖于具体场景的目标分布特性；TTS-8 能够以较低额外代价改善候选轨迹选择，TTS-16 可作为算力预算充足时的增强项；四个视觉编码器训练权重已经完成离线统计与 MuJoCo 闭环接入验证，但“最终部署最优编码器”的结论仍需结合真实相机分布、边缘设备时延和真机安全约束进一步确认。

5.2 主要贡献

本文的主要贡献可归纳为以下三点。

第一，建立了面向部署的统一视觉目标导航推理模块，将 DDIM、CFG、TTS 和视觉编码器替换纳入同一推理接口进行分析与控制。这一贡献的意义在于，现有工作通常只关注单一优化维度（如仅加速推理或仅替换编码器），缺乏将多种优化手段纳入统一框架进行系统评估的方法论。本文提出的统一模块使研究者能够在同一实验条件下量化不同优化组合的效果，为扩散策略在资源受限平台上的实用化部署提供了可操作的技术路径。

第二，构建了适用于 Lite3 的分层闭环系统，用状态机与导航主机把高层 NoMaD 策略组织成可恢复、可切换、可扩展的任务链路。这一贡献填补了从“扩散策略算法验证”到“四足机器人系统集成”之间的工程空白。与直接将策略输出映射为电机指令的端到端方案不同，分层架构保留了各层的可解释性和可调试性，使系统在真实部署中具备故障定位与在线调整能力。

第三，给出了 Orin 上的 Lite3 真机部署方案，并将图像记录、可视化与安全控制纳入统一 workflow，提升了系统复现性。这一贡献为后续研究者提供了从算法到真机的完整研究流程，降低了四足视觉导航研究的实验门槛，同时规范化的实验管理流程也为跨平台迁移与多次重复实验奠定了基础。

5.3 研究不足

本文仍存在三方面不足，需要在后续工作中加以改进。

第一，视觉编码器实验虽然已经接入四个训练权重并完成离线统计与 MuJoCo 闭环比较，但闭环扫描中引入了 MuJoCo 域内的路线稳定项，因此该结果更适合表明四套权重均可进入系统闭环，而不能单独作为真实部署最优编码器的最终证据。最终选择仍需要结合 Jetson Orin 端真实推理时延、真实相机图像分布和真机安全实验来判断。

第二，真机实验的正式统计表和大规模重复实验尚未完整。虽然本文已在 Lite3 真机上完成了系统通路验证和初步导航任务，但受限于实验场地可用时间和设备调度约束，尚未积累足够数量的重复试验以支撑统计显著性分析。这导致第四章部分实验结果仍以定性描述和代表性案例为主，缺乏如成功率置信区间、轨迹偏差分布等定量统计指标。

第三，本文拓扑地图仍主要依赖预先采集的视觉节点，尚未形成更强的在线更新与自维护能力。这一不足限制了系统在动态变化环境中的长期自主运行能力——当环境外观发生显著变化（如光照条件改变、障碍物移动）时，预采集的拓扑地图节点可能失效，导致子目标匹配质量下降，进而影响导航成功率。

5.4 未来展望

后续工作可从以下方向继续推进：(1) 完成视觉编码器在真实部署条件下的最终训练对比与选择。具体而言，需要在 Jetson Orin 与 Lite3 真机上分别测量 EfficientNet-B0、DINOv2-Small、ConvNeXt-Tiny、ResNet-50 等候选的推理延迟、图像分布鲁棒性、导航成功率和失败模式，从而形成兼顾性能与效率的最终选择。(2) 补齐真机统计实验，建立离线指标与真机任务成功率之间的更明确对应关系。这要求设计标准化的实验场景集（包含不同难度等级的导航任务），在每个场景下执行足够次数的重复实验。(3) 将统一推理模块与状态机扩展到 Tron1 等更多平台，验证分层结构的可迁移性。Tron1 作为双足人形机器人，其运动学约束与 Lite3 有本质区别，若分层系统仅需替换中层控制映射即可适配，则可有力表明本文架构设计的通用性与可扩展性。(4) 引入语言目标与多模态条件，使系统从 image-goal 进一步扩展到更灵活的任务表达。结合视觉-语言模型将自然语言指令编码为目标条件，可以使机器人接受“去走廊尽头的红色门”等语义级导航指令，大幅提升系统在人机协作场景中的实用价值。

综合来看，本文已经把原本主要面向轮式平台验证的 NoMaD 高层视觉导航策

略，扩展为一套面向 Lite3 四足平台的可分析、可仿真、可部署的研究链路：从统一视觉目标导航推理模块，到系统层面的分层闭环架构设计，再到平台层面的真机部署与实验管理。

参考文献

- [1] 裴凌, 熊超然. 具身导航概念、方法与挑战[J/OL]. 导航定位与授时, 2026, 13(1): 1-23. DOI: 10.19306/j.cnki.2095-8110.2026.01.001.
- [2] 杨钧杰, 孙浩, 王常虹, 等. 四足机器人研究综述[J]. 导航定位与授时, 2019, 6(5): 61-73.
- [3] HWANGBO J, LEE J, DOSOVITSKIY A, et al. Learning Agile and Dynamic Motor Skills for Legged Robots[J/OL]. Science Robotics, 2019, 4(26): eaau5872. DOI: 10.1126/scirobotics.aau5872.
- [4] LEE J, HWANGBO J, WELLHAUSEN L, et al. Learning Quadrupedal Locomotion over Challenging Terrain[J/OL]. Science Robotics, 2020, 5(47): eabc5986. DOI: 10.1126/scirobotics.abc5986.
- [5] ZHU Y, MOTTAGHI R, KOLVE E, et al. Target-Driven Visual Navigation in Indoor Scenes Using Deep Reinforcement Learning[C/OL]//2017 IEEE International Conference on Robotics and Automation (ICRA). 2017: 3357-3364. DOI: 10.1109/ICRA.2017.7989381.
- [6] SHAH D, EYSENBACH B, KAHN G, et al. ViNG: Learning Open-World Navigation with Visual Goals[C/OL]//2021 IEEE International Conference on Robotics and Automation (ICRA). 2021: 13215-13222. DOI: 10.1109/ICRA48506.2021.9561936.
- [7] SHAH D, SRIDHAR A, BHORKAR A, et al. GNM: A General Navigation Model to Drive Any Robot[C/OL]//2023 IEEE International Conference on Robotics and Automation (ICRA). 2023: 7226-7233. DOI: 10.1109/ICRA48891.2023.10161227.
- [8] SHAH D, SRIDHAR A, DASHORA N, et al. ViNT: A Foundation Model for Visual Navigation [C]//Proceedings of Machine Learning Research: Proceedings of the 7th Conference on Robot Learning (CoRL): vol. 229. PMLR, 2023.
- [9] SRIDHAR A, SHAH D, GLOSSOP C, et al. NoMaD: Goal Masked Diffusion Policies for Navigation and Exploration[C/OL]//2024 IEEE International Conference on Robotics and Automation (ICRA). 2024: 63-70. <https://arxiv.org/abs/2310.07896>.
- [10] CHI C, XU Z, FENG S, et al. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion [J/OL]. The International Journal of Robotics Research, 2025, 44(10–11): 1684-1704. <https://doi.org/10.1177/02783649241273668>. DOI: 10.1177/02783649241273668.
- [11] THRUN S, BURGARD W, FOX D. Probabilistic Robotics[M]. Cambridge, MA: MIT Press, 2005.
- [12] HESS W, KOHLER D, RAPP H, et al. Real-Time Loop Closure in 2D LIDAR SLAM[C/OL]//2016 IEEE International Conference on Robotics and Automation (ICRA). 2016: 1271-1278. DOI: 10.1109/ICRA.2016.7487258.
- [13] CAMPOS C, ELVIRA R, RODRÍGUEZ J J G, et al. ORB-SLAM3: An Accurate Open-Source Library for Visual, Visual-Inertial and Multi-Map SLAM[J/OL]. IEEE Transactions on Robotics, 2021, 37(6): 1874-1890. DOI: 10.1109/TRO.2021.3075644.
- [14] 毛军, 付浩, 褚超群, 等. 惯性/视觉/激光雷达 SLAM 技术综述[J/OL]. 导航定位与授时, 2022, 9(4): 17-30. DOI: 10.19306/j.cnki.2095-8110.2022.04.003.
- [15] ANDERSON P, CHANG A, CHAPLOT D S, et al. On Evaluation of Embodied Navigation Agents [J/OL]. arXiv preprint arXiv:1807.06757, 2018. <https://arxiv.org/abs/1807.06757>.
- [16] WIJMAN E, KADIAN A, MORCOS A, et al. DD-PPO: Learning Near-Perfect PointGoal Navigators from 2.5 Billion Frames[C/OL]//International Conference on Learning Representations (ICLR). 2020. <https://openreview.net/forum?id=H1gX8C4YPr>.

- [17] 陈铂垒, 康嘉绪, 钟萍, 等. 面向具身人工智能的物体目标导航综述[J/OL]. 软件学报, 2025, 36(4): 1715-1757. DOI: 10.13328/j.cnki.jos.007250.
- [18] 司马双霖, 黄岩, 何科技, 等. 视觉语言导航研究进展[J/OL]. 自动化学报, 2023, 49(1): 1-14. DOI: 10.16383/j.aas.c210352.
- [19] SAVINOV N, DOSOVITSKIY A, KOLTUN V. Semi-Parametric Topological Memory for Navigation[C/OL]//International Conference on Learning Representations (ICLR). 2018. <https://openreview.net/forum?id=SygwwGbRW>.
- [20] CHAPLOT D S, SALAKHUTDINOV R, GUPTA A, et al. Neural Topological SLAM for Visual Navigation[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 12875-12884. DOI: 10.1109/CVPR42600.2020.01289.
- [21] HO J, JAIN A, ABBEEL P. Denoising Diffusion Probabilistic Models[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): vol. 33. 2020. <https://arxiv.org/abs/2006.11239>.
- [22] SONG J, MENG C, ERMON S. Denoising Diffusion Implicit Models[C/OL]//International Conference on Learning Representations (ICLR). 2021. <https://openreview.net/forum?id=StlgiaRCHLP>.
- [23] HO J, SALIMANS T. Classifier-Free Diffusion Guidance[J/OL]. arXiv preprint arXiv:2207.12598, 2022. <https://arxiv.org/abs/2207.12598>.
- [24] REN H, ZENG Y, BI Z, et al. Prior Does Matter: Visual Navigation via Denoising Diffusion Bridge Models[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2025: 12100-12110. https://openaccess.thecvf.com/content/CVPR2025/html/Ren_Prior_Does_Matter_Visual_Navigation_via_Denoising_Diffusion_Bridge_Models_CVPR_2025_paper.html.
- [25] CAI W, PENG J, YANG Y, et al. NavDP: Learning Sim-to-Real Navigation Diffusion Policy with Privileged Information Guidance[J/OL]. arXiv preprint arXiv:2505.08712, 2025. <https://arxiv.org/abs/2505.08712>. DOI: 10.48550/arXiv.2505.08712.
- [26] ZHANG R, HOU J, CHENG C, et al. Self-Imitated Diffusion Policy for Efficient and Robust Visual Navigation[J/OL]. arXiv preprint arXiv:2601.22965, 2026. <https://arxiv.org/abs/2601.22965>. DOI: 10.48550/arXiv.2601.22965.
- [27] MIKI T, LEE J, HWANGBO J, et al. Learning Robust Perceptive Locomotion for Quadrupedal Robots in the Wild[J/OL]. Science Robotics, 2022, 7(62): eabk2822. DOI: 10.1126/scirobotics.abk2822.
- [28] REN J, DAI Y, LIU B, et al. Hierarchical Vision Navigation System for Quadruped Robots with Foothold Adaptation Learning[J/OL]. Sensors, 2023, 23(11): 5194. DOI: 10.3390/s23115194.
- [29] KAREER S, YOKOYAMA N, BATRA D, et al. ViNL: Visual Navigation and Locomotion Over Obstacles[C/OL]//2023 IEEE International Conference on Robotics and Automation (ICRA). 2023: 2018-2024. DOI: 10.1109/ICRA48891.2023.10160612.
- [30] STAMATOPOULOU M, LIU J, KANOULAS D. DiPeST: Diffusion-Based Path Planner for Synthesizing Trajectories Applied on Quadruped Robots[C/OL]//2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2024: 7787-7793. <https://arxiv.org/abs/2405.19232>. DOI: 10.1109/IROS58592.2024.10802677.
- [31] DING P, ZHAO H, ZHANG W, et al. QUAR-VLA: Vision-Language-Action Model for Quadruped Robots[C/OL]//Computer Vision – ECCV 2024. Springer, 2024: 352-367. <https://arxiv.org/abs/2312.14457>. DOI: 10.1007/978-3-031-72652-1_21.
- [32] JANNER M, DU Y, TENENBAUM J B, et al. Planning with Diffusion for Flexible Behavior Synthesis[C]//Proceedings of Machine Learning Research: Proceedings of the 39th International

- Conference on Machine Learning (ICML): vol. 162. PMLR, 2022: 9902-9915.
- [33] MA N, TONG S, JIA H, et al. Inference-Time Scaling for Diffusion Models beyond Scaling Denoising Steps[J/OL]. arXiv preprint arXiv:2501.09732, 2025. <https://arxiv.org/abs/2501.09732>.
- [34] ZHANG X, LIN H, YE H, et al. Inference-time Scaling of Diffusion Models through Classical Search[J/OL]. arXiv preprint arXiv:2505.23614, 2025. <https://arxiv.org/abs/2505.23614>.
- [35] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is All You Need[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 30. 2017: 5998-6008.
- [36] TAN M, LE Q V. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks[C]//Proceedings of Machine Learning Research: Proceedings of the 36th International Conference on Machine Learning (ICML): vol. 97. PMLR, 2019: 6105-6114.
- [37] OQUAB M, DARCET T, MOUTAKANNI T, et al. DINOv2: Learning Robust Visual Features without Supervision[J/OL]. Transactions on Machine Learning Research (TMLR), 2024. <https://openreview.net/forum?id=a68SUt6zFt>.
- [38] LIU Z, MAO H, WU C Y, et al. A ConvNet for the 2020s[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 11976-11986. DOI: 10.1109/CVPR52688.2022.01167.
- [39] HE K, ZHANG X, REN S, et al. Deep Residual Learning for Image Recognition[C/OL]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 770-778. DOI: 10.1109/CVPR.2016.90.
- [40] TODOROV E, EREZ T, TASSA Y. MuJoCo: A Physics Engine for Model-Based Control[C/OL]//2012 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2012: 5026-5033. DOI: 10.1109/IROS.2012.6386109.
- [41] RUDIN N, HOELLER D, REIST P, et al. Learning to Walk in Minutes Using Massively Parallel Deep Reinforcement Learning[C]//Proceedings of Machine Learning Research: Proceedings of the 5th Conference on Robot Learning (CoRL): vol. 164. PMLR, 2022: 91-100.

附录 A 人工智能工具使用情况说明

毕业设计（论文）标题：基于动作扩散策略的四足机器人视觉目标导航

学生姓名：陈样 学号：522031910056 指导教师：雷华明

一、本文使用的 AI 工具清单

序号	AI 工具名称	版本/型号	毕业设计（论文）中应用部分	人为判断过程说明
1	DeepSeek	V4	C2	人工对实验目标把控，调用 AI 工具进行本地实验与调优建议
2	DeepSeek	V4	D1	人工把握论文大纲与逻辑，AI 辅助
3	DeepSeek	V4	D2	人工核对正文内容与实验结果的一致性，AI 仅用于辅助表述整理。
4	DeepSeek	V4	D3	人工逐段检查语义、术语和格式，AI 用于语言润色建议。
5	DeepSeek	V4	E1	人工核验参考文献来源与格式，AI 用于辅助检查条目完整性。
6	DeepSeek	V4	E2	人工确认图表内容与论文数据对应关系，AI 用于辅助生成和排版建议。

注释：

^a 可以根据实际情况增删行数；

^b 可以对照“应用部分对照表”填写对应的编号表，若超过编号表内容，请根据实际情况填写；

^c 人为判断过程指的是依据何种方式判断 AI 工具生成的内容的准确性。

毕业设计（论文）中应用部分对照表

A. 研究准备阶段	A1. 选题与方向设定；A2. 文献检索与筛选
B. 研究设计阶段	B1. 研究思路设计；B2. 方法论构建；B3. 研究工具开发
C. 研究实施阶段	C1. 实验/数据分析；C2. 代码编写与调试；C3. 数学建模与计算
D. 论文写作阶段	D1. 大纲与逻辑优化；D2. 论文正文写作；D3. 语言与语法润色
E. 其他辅助环节	E1. 参考文献与格式；E2. 图表/多媒体生成；E3. 学术反馈与模拟答辩

学术诚信声明

本人承诺：论文核心观点、实验数据及结论均独立完成，AI 工具仅用于辅助性工作，已明确说明所有生成内容并在文中对应位置进行脚注标注。

承诺人：陈样

日期：2026 年 5 月 7 日

致 谢

行文至此，本科阶段的学业已近尾声。本科四年，我笑过、哭过，迷茫过、挣扎过，也坚定过。本科的最后半年，一切都在变好，科研上有了继续深耕的环境，生活也看见了未来的希望。

感谢导师在研究方向选择、论文写作和实验设计中给予的悉心指导与持续帮助。

感谢 NoMaD 研究团队公开相关方法与资料，为本文复现和后续研究提供了坚实的算法基础。

感谢云深处科技提供的 Lite3 四足机器人平台与技术支持，使本文能够将视觉导航研究从仿真推进到真机验证。

感谢实验室师兄在日常讨论、系统调试与真机实验中给予的无私帮助。初入科研时，我曾倍感忐忑，师兄们耐心指点使我突破瓶颈，顺利完成本课题。

感谢上海交通大学自动化与感知学院提供的学习与科研条件。

感谢智能感知工程专业，作为专业首届本科生，我曾无数次地怀疑这个专业是否能够给本科生足够的培养，但四年的学习与实践让我见证了它的快速成长与扎实积淀。在此，我不仅收获了系统的专业知识与工程能力，更结识了良师益友。

感谢自感 2253 班级的兄弟姐妹们，感谢 2253 卷帘门。每逢期末的相互扶持与挑灯夜战，必将成为我青春岁月中最温暖的印记。

感谢挚友同行，四载交大岁月，因你们而熠熠生辉。

感谢家人一直以来的理解与支持。感谢爸爸妈妈，感谢你们二十多年的养育之恩，以及始终如一的理解与鼓励，是我前行路上最坚实的底气。

感谢我的女朋友，这半年来，在我最困顿迷茫之时，是你的陪伴与鼓励让我重拾方向；无数个疲惫的夜晚，因你的理解与支持而不再难熬。你的温柔与坚定，是我坚持至今的重要力量。

最后感谢一直走在路上的我自己，我没有被困难打倒，我没有被压力击溃，我一直在坚持，我一直在成长。我是好样的！愿我带着这份坚韧与热爱，继续奔赴下一程山海！

VISUAL GOAL NAVIGATION FOR QUADRUPEDED ROBOTS BASED ON ACTION DIFFUSION POLICY

Background and Motivation

Visual goal navigation is a core task in embodied intelligence that connects perception with decision-making. Given the current visual observation and a goal image, the policy must output executable local motion without relying on high-precision maps or global localization, thereby achieving autonomous movement from the current viewpoint to the goal viewpoint. As robots are increasingly deployed in unstructured open-world environments such as campus patrol, indoor guidance, last-mile delivery and home service, navigation can no longer be reduced to a pure geometric path-planning problem on a known map. It must instead handle weak priors, partial observability, dynamic obstacles and ambiguous goal specifications, which has motivated a paradigm shift from classical Simultaneous Localization and Mapping (SLAM)-plus-planner pipelines toward learning-based, image-conditioned policies that consume raw visual observations directly.

Recently, general navigation models such as General Navigation Model (GNM), Visual Navigation Transformer (ViNT), and Goal Masked Diffusion Policies for Navigation and Exploration (NoMaD) have introduced diffusion policies into visual navigation, modelling the future local trajectory as a conditional distribution and generating multi-modal candidates through iterative denoising sampling. This formulation has significantly stronger expressive power than regression-based end-to-end policies that collapse multi-modal decisions (such as turning left or right at a T-junction) into a single mean output. By modelling the full distribution of feasible local trajectories, diffusion-based policies are able to preserve multi-modality, sample diverse candidates, and integrate naturally with test-time selection and guidance mechanisms. However, closed-loop validation of these models has so far concentrated on wheeled platforms (LoCoBot, TurtleBot, Jackal), while deployment pipelines targeting quadruped robots remain underexplored. Quadruped platforms differ substantially from wheeled ones in gait-induced jitter, control-loop frequency, body-posture coupling, foot-impact disturbance, and real-time safety requirements. These differences pose new challenges for the collaboration between high-level diffusion policies and mid-/low-level control

interfaces, and they cannot be addressed by simply re-routing the wheeled-robot velocity command to a quadruped’s locomotion controller.

Objectives and Approach

This thesis takes NoMaD as the high-level navigation core and the DeepRobotics Lite3 quadruped as the target deployment platform, and addresses three deployment-oriented questions: (i) how the visual encoder, distance-prediction head, and diffusion policy head are coupled in the NoMaD implementation and where inference-level optimizations are possible without retraining the model; (ii) whether, without retraining, sampling acceleration via Denoising Diffusion Implicit Model (DDIM), conditional guidance via Classifier-Free Guidance (CFG), test-time search via Test-Time Scaling (TTS), and visual encoder replacement can meaningfully improve policy usability for resource-constrained edge deployment; and (iii) whether these optimizations can be integrated into a hierarchical closed-loop system for Lite3 and validated through Multi-Joint dynamics with Contact (MuJoCo) simulation as well as real-world deployment on the Jetson Orin onboard computer. The technical roadmap proceeds through unified-inference-module construction and optimization, system-level integration, and deployment-level validation, corresponding respectively to Chapters 2, 3, and 4 of the thesis. A deliberate emphasis is placed on bridging the offline-evaluation versus closed-loop deployment gap, ensuring that every algorithmic conclusion is re-examined under realistic timing, safety, and platform constraints.

Main Contributions

Unified inference module. A unified offline statistical pipeline is built to compare DDIM inference acceleration, CFG enhancement, Test-Time Scaling (TTS) search, and visual encoder upgrades under a single evaluation protocol. Concretely, DDIM-2 attains about $4.84\times$ speedup over the Denoising Diffusion Probabilistic Model (DDPM)-10 baseline on the GoStanford evaluation set without notable trajectory-quality degradation, with the mean-squared deviation against the baseline trajectory distribution remaining below 0.022. The CFG analysis, derived from score-function modification, establishes a guidance-scale selection rule and shows that CFG roughly doubles the per-step compute while delivering only marginal Forward-Progress gain in the diffusion-policy regime; hence CFG is best treated as a tunable knob rather than a default-on component. The TTS analysis decomposes total

gain into a nearly zero-latency *scoring-based selection* component (which re-ranks the eight candidates already produced by a single diffusion batch) and a linearly priced but rapidly diminishing *candidate-pool expansion* component (which spawns extra batches to enlarge the pool). TTS-8 wins the three-factor joint ranking at minimal cost, providing a novel interpretation of inference-budget allocation as “re-rank cheaply first, expand only when necessary.” To make the ranking criterion explicit, the configuration-level score used in the TTS tables is defined as $S_{\text{rank}} = \overline{\text{FP}} - 0.050 \overline{\text{Latency}} - 0.350 \overline{\text{LA}} - 0.150 \overline{\text{Smooth}}$, where latency is measured in milliseconds, lateral deviation and smoothness are penalized, and smoothness acts mainly as a weak regularizer because it is computed from the mean second-order trajectory difference. Encoder upgrades use a two-stage framework to compare EfficientNet-B0, ResNet-50, DINOv2-Small, and ConvNeXt-Tiny on identical offline cases; the encoder $\times$ DDIM / CFG / TTS joint ablation establishes that DDIM-2 and CFG default-off remain robust across all four encoders, while TTS gain scales with the initial candidate diversity of the chosen encoder.

System layer. A hierarchical closed-loop system—comprising a unified inference module, an explicit finite-state machine, a navigation host, a mid-level navigation-point-to-velocity mapping, and a platform interface—supports both MuJoCo and real-robot backends through one set of high-level code. The state machine (idle / stand / navigate / explore / recovery / estop / completed / failed) is decoupled from the physical platform via a uniform interface, so that switching between MuJoCo and Lite3 only changes the backend implementation rather than the high-level logic. The navigation host supports both batched JavaScript Object Notation (JSON) plans and interactive single commands, allowing capture, topological map building, navigation, and exploration to be composed within a single experiment session. Mid-level mapping converts the diffusion policy’s local navigation points into bounded forward, lateral, and yaw velocity commands, respecting Lite3-specific safety envelopes ($v_x \leq 0.4$ m/s in simulation, $v_x \leq 0.12$ m/s during real-robot deployment). In MuJoCo closed-loop experiments, Lite3 physically reaches the target in point-navigation and multi-goal tasks under a 0.5 m Euclidean-distance threshold, while the exploration mode verifies that the goal-masked, target-free inference chain remains executable on the same system. The same unified inference module that handles the four offline optimizations is re-used at deployment time, demonstrating that the algorithm-layer

findings translate directly into operational system behaviour.

Deployment layer. For the Jetson Orin onboard host and the Lite3 upper-computer link, the thesis develops a staged commissioning procedure, multi-level safety mechanisms, and an image-recording convention. Stage 1 (Orin standalone commissioning) validates camera capture, model loading, inference benchmarking, and the end-to-end pipeline in isolation from the robot, so that any inference-side defect is discovered before the platform is energized. Stage 2 (Orin and Lite3 joint commissioning) progresses from network and heartbeat verification, through standup and low-speed twist tests, to interactive and goal-directed navigation under conservative speed limits. The bridging layer wraps the Lite3 Software Development Kit (SDK) with a 25 Hz velocity-refresh thread and a 5 Hz heartbeat thread, repeating the most recent clipped velocity between higher-level NoMaD inference cycles to guarantee continuous control flow even when the policy runs at single-digit hertz. Multi-level safety guards include Not a Number/infinity (NaN/Inf) clipping, magnitude limits, fallen-robot detection, and a connection-stale threshold of two seconds; any inference anomaly or platform fault is routed to a soft emergency stop. Real-robot experiments on multiple indoor scenes with pre-collected topological maps record closed-loop frequencies of 2.89 Hz (DDPM baseline), 6.80 Hz (DDIM-2 + CFG=0 + TTS-8), 3.43 Hz (DDIM-2 + CFG=2 + TTS-8), and 5.90 Hz (DDIM-3 + CFG=0, no TTS), with a 100% success rate across all four configurations under the present conservative speed setting. Unlike MuJoCo, the real robot does not use global ground-truth coordinates for success evaluation; success is determined by a visual-topological arrival rule in which the selected topological node reaches the goal node and the NoMaD distance head predicts a distance below the dimensionless threshold $\tau_{\text{arrive}} = 3.0$, with no emergency stop or manual intervention. The frequency ranking is fully consistent with the offline analysis in Chapter 2: DDIM step count dominates latency, CFG approximately halves the achievable rate, and TTS-8’s overhead is negligible because re-ranking eight already-generated candidates does not require an extra diffusion batch.

Experiments and Conclusions

Offline results indicate that DDIM-2 plus optional CFG and configurable TTS-8 is the most promising configuration to bring into closed-loop validation, and the encoder upgrade pipeline supplies a reusable framework for future visual-backbone exploration rather than a single best-encoder verdict. MuJoCo experiments confirm that the hierarchical system

can robustly organize quadruped navigation, multi-goal execution, exploration, recovery, and emergency-stop transitions through one shared control architecture. Stage-1 validation on Jetson Orin demonstrates the baseline feasibility of the real-robot pipeline (about 7 Hz benchmarked NoMaD inference, $\approx 151\text{--}157$ ms steady-state pipeline cycle once warm-up cost is amortized), and Stage-2 multi-scene results provide the first real-robot evidence that diffusion-policy-based image-goal navigation can run end-to-end on a Lite3 quadruped at single-digit hertz while still completing every commissioned trial. Crucially, the fact that even the slow 2.89 Hz baseline achieves 100% success demonstrates that the closed-loop system has substantial robustness margin: the conservative 0.12 m/s speed cap means each cycle’s displacement is only about 4 cm—far smaller than the topological map node spacing—so high-level latency tolerance is absorbed by the topological map sliding window and the 25 Hz bridge replay rather than manifesting as catastrophic drift.

Limitations and Future Work

Three limitations are explicitly acknowledged. First, the encoder upgrade conclusions remain offline statistics plus simulator validation, and a final real-robot-conditioned encoder ranking will require benchmarking inference latency, image-distribution robustness, and failure modes directly on the Orin/Lite3 stack with real cameras. Second, the present real-robot statistics, while sufficient to show that all four inference configurations succeed under the current scenario scale, do not yet include large-sample success-rate confidence intervals or formal trajectory-deviation distributions; expanding the experiment matrix to outdoor scenes, dynamic obstacles, and longer corridors should enhance differentiation between configurations and unlock the latency margin that the fastest scheme has reserved. Third, the topological map is still collected offline by an operator; an online maintenance loop that refreshes nodes when the environment changes would improve long-term autonomy. Future work will therefore focus on (i) finalizing the on-robot encoder choice with end-to-end real-world metrics, (ii) running large-scale repeated trials with formal statistics, (iii) generalizing the unified inference module and state machine to additional platforms such as the Tron1 humanoid robot to test cross-embodiment portability, and (iv) extending image-goal conditioning to language-grounded targets, allowing operators to issue natural-language commands such as “go to the red door at the end of the corridor” that get translated into NoMaD-compatible visual conditions.

The thesis extends NoMaD from a wheeled-platform research framework into an analyzable, simulatable, and deployable research pipeline for quadruped platforms, distilling a reusable inference-optimization protocol, a hierarchical closed-loop system organization, and a real-robot safety-guard checklist. Together, these artefacts provide a practical basis for subsequent research on diffusion-policy-based visual navigation for quadruped robots, and they lower the engineering threshold for follow-up work that wishes to validate algorithmic ideas under genuine on-robot conditions rather than only on offline benchmarks.