



上海交通大学硕士学位论文

人形机器人仿人运动训练与控制系统设计

姓 名：姚逸飞

学 号：123032910043

导 师：卢俊国教授

院 系：自动化与感知学院

学 科 / 专 业：控制科学与工程

申 请 学 位：工学硕士

2026 年 1 月 20 日

**A Dissertation Submitted to
Shanghai Jiao Tong University for the Degree of Master**

**DESIGN OF HUMAN-LIKE HUMANOID ROBOT
MOTION TRAINING AND CONTROL SYSTEM**

Author: Yifei Yao

Supervisor: Prof. Jun-Guo Lu

School of Automation and Intelligent Sensing

Shanghai Jiao Tong University

Shanghai, P.R. China

January 20th, 2026

上海交通大学

学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全知晓本声明的法律后果由本人承担。

学位论文作者签名：

日期： 年 月 日

上海交通大学

学位论文使用授权书

本人同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。

本学位论文属于：

☐ 公开论文

☐ 内部论文，保密 ☐ 1 年 / ☐ 2 年 / ☐ 3 年，过保密期后适用本授权书。

☐ 秘密论文，保密 ____ 年（不超过 10 年），过保密期后适用本授权书。

☐ 机密论文，保密 ____ 年（不超过 20 年），过保密期后适用本授权书。

（请在以上方框内选择打“√”）

学位论文作者签名：

指导教师签名：

日期： 年 月 日

日期： 年 月 日

摘 要

人形机器人凭借其拟人化的形态优势，在通用服务与复杂作业场景中展现出巨大的应用潜力。然而，赋予机器人类似人类的运动智能仍面临严峻挑战：针对不同人形机器人仿人运动的异构数据稀缺且难以跨形态复用、底层控制在人-机动力学失配下可泛化性不足、长程运动规划缺乏有效的语义指导和反馈修正，以及从仿真到真机的部署门槛高昂。针对上述问题，本文围绕重定向数据基座构建、底层鲁棒控制策略设计、高层生成式规划模型探索与自动化系统部署方案优化四个核心维度，构建了一套端到端的通用仿人运动训练与控制系统。本文的主要研究工作如下：

首先，针对人形机器人高质量运动数据匮乏及跨形态映射困难的问题，提出了一种基于几何表征的自适应运动重定向框架。通过构建可微的正逆运动学网络与形态匹配算法，实现了从标准人体数据到异构机器人本体数据的自适应映射，并建立了包含关节、连杆及接触状态的 HumanoidML3D 标准化数据规范。该方法有效弥合了形态鸿沟，通过网络优化和可微后处理实现了高效、准确的动作迁移，为后续模型训练构建了通用的数据基座。

其次，针对传统控制算法泛化性差及对参考轨迹依赖强的问题，结合强化学习与模仿学习的优势，设计了兼容动作模仿与自主探索的底层控制策略。提出了 Motion Mimic Transformer 策略骨干网络，通过注意力机制动态融合高频本体观测与稀疏参考动作；同时设计了包含“简化环境先模仿、复杂环境再强化”的两阶段训练范式。该控制器作为系统的底层执行单元，支持对重定向参考轨迹的高保真跟踪及仿人运动模式的在线切换，显著提升了机器人在复杂地形下的平衡能力与抗干扰能力。

此外，为了赋予机器人理解自然语言并进行长程运动规划的能力，提出了基于流匹配的实时动作生成与闭环控制架构。针对生成模型推理速度慢与底层控制频率高的矛盾，设计了基于流匹配的快速生成模型，并构建了分层式的 Diffusion-MPC 预测控制框架。该框架将物理世界的执行反馈引入规划流程，实现了高层语义规划与底层动力学执行的实时闭环协同，使机器人能够根据自然语言指令实时生成多样化、物理可行的全身动作序列。

最后，针对强化学习落地过程中奖励函数设计依赖专家经验及虚实迁移困难的工程痛点，提出了基于大语言模型的自动化训练与部署框架。系统利用大语言模型的推理能力自动生成与迭代奖励函数，并首创性地引入了同态评估器与半监督训练机

制，量化了仿真与现实的差距。通过构建包含仿真反馈、安全检查与真机评估的自动化闭环，实现了从奖励设计到真机部署的全流程自动化，有效解决了策略退化与冷启动问题。

本文在多种构型的机器人仿真环境及真机控制中验证了所提方法的有效性。实验结果表明，该系统设计显著降低了跨构型开发的边际成本，提升了机器人的运动智能水平与环境适应能力，具有良好的通用性与可拓展性。

关键词：人形机器人，运动重定向，模仿学习，扩散模型，虚实迁移，大语言模型

Abstract

Humanoid robots, leveraging their anthropomorphic advantages, demonstrate significant potential in general-purpose services and complex operational scenarios. However, endowing these robots with human-like motion intelligence remains a formidable challenge. Key obstacles include the scarcity and difficult cross-morphology reusability of heterogeneous motion data, insufficient generalizability of low-level control under human-robot dynamics mismatches, the lack of effective semantic guidance and feedback in long-horizon planning, and the high barrier to sim-to-real deployment. To address these challenges, this thesis presents an end-to-end anthropomorphic motion training and control system, focusing on four core dimensions: motion data retargeting, low-level control strategy design, high-level planning model exploration, and system deployment optimization. The main contributions of this work are as follows:

First, addressing the scarcity of humanoid motion data and the significant morphological discrepancies between humans and robots (or among heterogeneous robots), an adaptive motion retargeting framework based on geometric representation is proposed. By constructing differentiable forward and inverse kinematics networks, the algorithm achieves an adaptive mapping from standard human or heterogeneous robot data to the target robot's embodiment, establishing a data specification that includes joint, link, and contact states. Through network optimization and differentiable post-processing, the framework realizes highly efficient and accurate retargeting, supporting multi-source data processing and real-time mapping. This approach effectively bridges the morphological gap and provides a universal method for constructing high-quality, robot-specific motion datasets.

Second, targeting the poor generalization of traditional control algorithms and long model training cycles, a Transformer-based policy inference network and a two-stage Reinforcement Learning-Imitation Learning (RL-IL) training strategy are designed. The specialized network architecture effectively resolves challenges in temporal feature encoding and multi-data generalization, while the "imitate-first, reinforce-later" strategy offers a rapid model optimization pathway for distinct complexity levels. Furthermore, by introducing state augmentation and disturbance-aware training mechanisms, the controller serves as a robust low-

level execution unit. It supports high-fidelity tracking of retargeted reference trajectories and online switching of anthropomorphic motion modes, significantly enhancing the robot's balance and robustness across complex terrains.

Third, to enable natural language understanding and long-horizon motion planning, a motion generation and closed-loop control architecture based on Flow Matching is proposed. Leveraging the retargeting framework to build a unified low-level data representation compatible with RL observations, this work designs a Decoder-only Diffusion Transformer backbone tailored for robot motion states. This approach allows for training a diffusion model on isomorphic retargeted datasets and establishing a Diffusion-MPC framework via a hierarchical "diffusion model-RL policy" structure. By incorporating physical feedback into the planning loop, the system achieves online trajectory modification based on the robot's motion state. This method generates diverse, physically feasible whole-body motion sequences from semantic instructions, realizing the asynchronous coordination of high-level generative planning and low-level dynamic execution.

Finally, addressing the engineering pain points of manual reward function design and the difficulty of sim-to-real transfer in RL, an automated training and deployment framework based on Large Language Models (LLMs) is proposed. Utilizing the reasoning capabilities of LLMs, the system automatically generates and iterates reward functions. Combined with teacher-guided semi-supervised training and homomorphic evaluation, it quantifies the sim-to-real gap. A teacher sample selection mechanism is introduced to prevent policy degradation caused by LLM hallucinations and to avoid cold-start issues. Through simulation and real-world feedback, the LLM performs multi-turn Reasoning-Action (ReAct) iterative modifications to select the optimal policy for hardware verification, ultimately realizing a fully automated closed-loop from simulation training to real-world deployment.

The effectiveness of the proposed methods is validated across multiple robot configurations in both simulation and real-world environments. Experimental results demonstrate that this system design significantly reduces training costs, enhances the robot's motion intelligence and environmental adaptability, and exhibits strong scalability and potential for deployment.

Key words: Humanoid Robot, Motion Retargeting, Imitation Learning, Diffusion Model,

Sim-to-Real, Large Language Model

目 录

第 1 章 绪论	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	4
1.2.1 人形机器人动作重定向与数据生成	5
1.2.2 基于学习的全身运动控制	6
1.2.3 生成式动作规划与闭环控制	7
1.2.4 大模型辅助自动化训练与 Sim-to-Real 部署	7
1.3 主要研究内容.....	8
1.4 主要研究内容.....	9
1.5 论文章节安排.....	10
1.6 本章小结.....	11
第 2 章 基于动作捕捉数据的人形机器人自适应动作重定向	13
2.1 问题分析.....	13
2.2 自适应重定向的骨干网络设计.....	14
2.2.1 异构机器人形态学自适应匹配	14
2.2.2 基于物理约束的复合损失函数构建	16
2.3 训练细节与实验结果分析.....	20
2.3.1 数据处理流水线验证	20
2.3.2 与其他重定向方法的对比	24
2.3.3 扩展应用：基于单目视觉的动作重定向接口	26
2.4 本章小结.....	28
第 3 章 兼容动作模仿和自适应运动的机器人控制策略设计	31
3.1 问题分析.....	31
3.2 基于时序特征融合的策略基线网络.....	33
3.2.1 符号定义	33
3.2.2 轻量级时序特征编码器	34
3.2.3 专家-策略特征的门控融合机制	34

3.3 针对时空特征的 MMTransformer 策略网络	36
3.3.1 自适应序列化嵌入与 SwiGLU 投影	36
3.3.2 注意力掩码与动态推理机制	37
3.3.3 网络输出与超参数配置	38
3.3.4 两阶段模仿-强化学习策略 (Agger-MMPPPO) 训练架构	38
3.4 训练平台与环境设计	43
3.4.1 强化学习平台架构	43
3.4.2 课程学习与模仿奖励设计	45
3.4.3 训练优化策略	46
3.5 实验验证与结果分析	47
3.5.1 MMTransformer 骨干网络性能分析	47
3.5.2 DAgger-MMPPPO 算法效能评估	50
3.5.3 泛化性与迁移能力评估	52
3.6 本章小结	55
第 4 章 基于扩散模型的人形机器人全身运动生成与闭环控制	57
4.1 问题分析	57
4.2 人形机器人动作生成与闭环控制框架	58
4.2.1 数据集构建	59
4.2.2 动作扩散模型	61
4.2.3 轨迹规划与闭环控制	65
4.3 实验结果	67
4.3.1 实验设计	68
4.3.2 数据集表征完整性的消融分析	69
4.3.3 扩散模型性能分析	70
4.3.4 训练范式与超参数消融实验	72
4.3.5 闭环控制与动作追踪性能评估	74
4.4 本章小结	76
第 5 章 基于大语言模型的辅助训练与 Sim-to-Real 部署框架	79
5.1 问题引入	79
5.2 智能化训练与部署框架总体架构	80
5.2.1 系统组成与输入要求	80

5.2.2 形式化定义与算法流程	81
5.3 基于思维链的奖励函数自动化演进.....	81
5.4 融合参考策略的半监督强化学习训练策略.....	84
5.5 Sim-to-real 同态评估与安全部署机制	85
5.5.1 同态评估体系与策略筛选	85
5.5.2 安全检查机制与自动化真机闭环	86
5.6 实验验证与多构型适配分析.....	86
5.6.1 实验设置	86
5.6.2 模块功能验证分析	88
5.6.3 系统整体性能分析	90
5.7 本章小结.....	91
第 6 章 总结与展望	93
6.1 全文总结.....	93
6.2 未来展望.....	94
参考文献.....	97
致 谢.....	105
学术论文和科研成果目录.....	107

插图

图 1.1 人形机器人 G1 的拳击表演, ARN 新闻 ^[7]	2
图 1.2 不同厂商的人形机器人构型, CSDN ^[9]	3
图 1.3 本文各章节逻辑结构关系	10
图 2.1 自适应重定向算法工作管线	14
图 2.2 Unitree H1-2 机器人与人体关节的映射定义	15
图 2.3 H1-2 形态拟合结果	16
图 2.4 Turin HN 形态拟合结果	16
图 2.5 不同构型人形机器人的 SMPL+H 形态拟合效果	16
图 2.6 序列后处理效果示例	20
图 2.7 实验中使用的四种人形机器人及其基本参数	21
图 2.8 (a) H1-2 损失曲线 (Main Loss for H1-2)	23
图 2.9 (b) GR1 损失曲线 (Main Loss for GR1)	23
图 2.10 Unitree H1-2 和 Fourier GR1 机器人的 Pose Transformer 网络训练与验证 损失曲线	23
图 2.11 跨构型与跨动作的重定向效果定性展示	24
图 2.12 足部接触信号处理示意图	25
图 2.13 Isaac Sim 中的重定向动作仿真结果	25
图 2.14 基于 WHAM 的非训练样本视频动作重定向效果展示 (以《蜘蛛侠》为 例)。	28
图 3.1 MMTransformer 骨干网络框架图	32
图 3.2 Fused MLP 基线网络框架图	35
图 3.3 MMTransformer 的嵌入层设计细节	36
图 3.4 DAGger-MMPPO 算法架构示意图	39
图 3.5 GBC 平台与 Isaac Lab 环境的继承关系	44
图 3.6 四种算法配置在中等任务上的平均奖励曲线	52
图 3.7 分布外 (O.O.D.) 参考动作及其在 Isaac Sim 环境中的对应执行情况	54
图 3.8 部署于 MuJoCo 平台的训练策略仿真结果	55
图 4.1 动作生成与控制框架概述	59

图 4.2 HumanoidML3D 表征与 HumanML3D 方法的转换流程对比。	60
图 4.3 Diffusion Transformer 架构。	62
图 4.4 动作生成框架训练模式	63
图 4.5 动作生成框架控制器模式对比。	65
图 4.6 模型生成轨迹概览	71
图 4.7 MUJICA-C 在 Isaac Sim 下的闭环追踪效果展示	76
图 5.1 AnyBipe 框架架构图	80
图 5.2 LLM 奖励生成迭代过程示意图	83
图 5.3 实验涉及的三种双足机器人构型及自由度定义	87
图 5.4 教师指导训练（蓝）与纯 RL 训练（黄）的奖励及课程等级曲线对比	89
图 5.5 三种机器人在 5 轮迭代中的最佳生成策略及安全反馈可视化	90
图 5.6 基于 AnyBipe 最佳策略的 P1 机器人真机多地形测试	91

表 格

表 2.1 SMPL+H 关节与不同构型机器人的连杆映射关系及权重分配 21

表 2.2 SMPL+H 形态拟合结果 22

表 2.3 Pose Transformer 重定向精度 (末端位置误差, 单位: 米) 22

表 2.4 不同动作捕捉重定向流水线的性能对比 26

表 3.1 MLP 网络使用的主要数学符号定义 33

表 3.2 Transformer 网络使用的主要数学符号定义 33

表 3.3 模仿奖励 ($\hat{R}$) 组件汇总 46

表 3.4 骨干网络性能分析实验设置 48

表 3.5 骨干网络架构在 RL 和 IL 任务上的性能对比 49

表 3.6 DAgger-MMPPO 算法各配置在不同难度任务上的性能评估 51

表 3.7 分布内与分布外数据的跟踪性能 54

表 4.1 HumanML3D 与本文 HumanoidML3D 规范的数据表征对比。 60

表 4.2 不同数据表征组合对 Text-Motion 跨模态检索性能的消融实验结果 69

表 4.3 文本生成动作任务的主要实验结果 (所有机器人数据集的平均值) 70

表 4.4 不同训练范式下的生成质量与收敛性能对比 73

表 4.5 不同时间步采样分布对模型性能的影响 74

表 4.6 不同策略在仿真环境中的闭环追踪性能对比 75

表 5.1 核心环境评估器与奖励函数定义 88

表 5.2 不同 LLM 在各机器人任务上的代码生成成功率与奖励性能 88

表 5.3 点足机器人的同态评估指标示例 89

表 5.4 安全准则 (SA) 的检测精度与召回率 90

表 5.5 系统实验设置概览 90

表 5.6 各迭代轮次奖励成功率与人工设计基准的对比 91

算 法

算法 3.1 第一阶段：Dagger 策略预训练..... 40

算法 3.2 第二阶段：基于 Dagger 的策略迁移训练..... 41

算法 4.1 扩散模型预测控制（Diffusion-MPC）循环 66

算法 5.1 AnyBipe 自动化训练与部署流程 82

第1章 绪论

1.1 研究背景与意义

人形机器人 (Humanoid Robot) 是以人类身体构型为基础, 通过抽象并简化其运动特征从而搭建的, 具有模仿人类行为能力的一类特殊机器人。在人类社会中, 机器人通常被期待在各类复杂环境中辅助或替代人工作业, 而人形机器人更是被广泛视为最具潜力和应用前景的机型之一^[1]。究其原因, 一方面, 人形机器人以类似人类的结构和关节分布为特征, 能够在传统为人类设计的环境中 (如家庭、医院、工厂等) 自由移动和操作, 拥有很高的环境适应度; 另一方面, 在与人类进行协作或沟通的场景下, 其仿人外形往往能带来更自然的交流方式, 降低人机交互过程中的障碍^[2-3]。在此背景下, 对人形机器人姿态规划与运动控制算法的深入研究, 能够加速这类机器人向实用化与智能化方向发展, 为社会带来更多的便利与可能性。

从宏观角度来看, 人工智能 (Artificial Intelligence, AI) 在近十余年迎来快速发展, 尤其是深度学习、强化学习等领域持续突破, 使“机器人智能”不再局限于传统基于精确模型或规则设计的控制范式, 而开始更多地借鉴生物与人类的学习机制, 让机器人学会自主适应与决策^[4]。在人形机器人领域, 这种发展趋势与机器人本身具有的高自由度、多关节耦合特性相结合, 打开了更广阔的技术创新空间。不同于传统关节式或移动式机器人, 人形机器人需要在平衡、步态、交互等方面做大量的动态决策, 其与环境的耦合也更为紧密。由此引出研究者对高性能传感器、仿生结构设计以及新型智能控制策略的多维探索, 力图让人形机器人具备更加灵活、鲁棒的行为能力^[5]。

另一方面, 人形机器人作为“具身智能” (Embodied Artificial Intelligence, Embodied AI) 的重要载体, 其研究并不仅限于单纯提升关节控制精度或执行效率, 也涉及对身体形态、感知系统以及认知过程的综合考量。与传统刚性机器人相比, 人形机器人在尺寸、关节分布、传感器布局等方面更贴近人类, 这使得其在环境理解与人体动作模仿上有先天优势, 也对其控制过程提出了更高要求: 任何一个肢体动作的规划都与全身平衡控制密切相关, 稍有不慎便可能导致跌倒或动作失败。因此, 如何在高维、多关节的动作空间中实现对全身姿态的合理规划, 使其既能保持稳定又能完成复杂动作, 便成为整个人形机器人研究的关键课题之一^[6]。

与此同时, 社会对人形机器人在实际应用中的期望也不断提高。例如, 医疗护理



图 1.1 人形机器人 G1 的拳击表演，ARN 新闻^[7]

Figure 1.1 Boxing performance of Unitree G1 robot by ARN news.

与康复辅助场景期望人形机器人在床边或辅助步行中发挥作用，需要其理解患者的动作意图并精准、安全地与之交互；服务业希望它们在面对不同的室内环境和任务变动时，具备能够快速灵活学习与适应的能力；甚至在公共安全或灾害救援中，也期待人形机器人能够凭借人形结构更好地跨越瓦砾、攀爬楼梯，承担一些危险性高或重复性强的任务。随着这些应用场景的不断拓展，如何开发出具备可推广性的运动控制算法与姿态规划方法，使人形机器人不再局限于实验室或演示展览，而真正投入实际运营，成为产业界与学术界共同关注的目标^[8]。

在研究手段方面，现阶段对人形机器人的探索常借助高保真的仿真环境来进行大规模训练与测试，并通过在现实环境中的实验验证模型的可靠性与鲁棒性。这类以强化学习或模仿学习为主的研究思路，往往需要构建逼真的物理仿真以及完备的感知—控制回路，以让机器人在虚拟空间中“经历”各类干扰、斜坡、不规则地形等复杂情形，从而习得高水平的平衡保持与动作规划策略。通过对外部传感器信息（如视觉、力觉或多模态感知）的综合处理，结合深度神经网络强大的特征提取能力，机器人能够对瞬时状态做出近似实时的决策。再者，随着软硬件技术的不断成熟，以及“Sim-to-Real”（虚实迁移）方法的发展，人形机器人研究也逐渐走出实验室，着力于实现更高的落地性与商用化。种种迹象表明，对人形机器人仿人姿态规划与运动控制算法的深入研究，不仅是学术方向的前沿课题，也具备可观的商业价值和社会影响。

总的来说，人形机器人在结构和控制上的复杂性使之成为机器人研究的“珠穆朗玛峰”，考验着研究者在动力学分析、控制理论、机电一体化、人工智能等多方面的

水平。通过聚焦人形机器人仿人姿态规划与运动控制算法研究，一方面可以挖掘机器人在模仿人类行为机制及认知过程中的潜能，丰富和拓展具身智能的理论与实践；另一方面，也能为人形机器人走向商业化与规模应用提供更扎实的技术储备。在人机协作需求持续上升、社会老龄化加剧与个性化服务需求不断涌现的背景下，具备良好行动力与灵活任务执行能力的人形机器人将迎来更广泛的发展机遇。

Sanctuary: Appolo A1		Sanctuary AI: Phoenix		Figure: Figure 01	
身高: 173cm  负重: 25kg 体重: 73kg 运行: 4hours (可换电池) 行走速度: 1 m/s. 自由度: 41 (手 6 个) 感知: 深度相机 目标价: US\$ 50k		身高: 170cm  负重: 最大 25kg 体重: 70kg 运行: 5hours 行走速度: 最高 1.5 m/s. 自由度: 手部 20 个 感知: 深度相机 目标价: 未公开		身高: 168cm  负重: 20kg 体重: 60kg 运行: 5hours 行走速度: 1.2 m/s. 自由度: 41 (手 6 个) 感知: 未公开 目标价: 未公开	
Agibot: RAISE-A1		Tesla: Optimus gen2		Unitree: H1	
身高: 175cm  负重: 20kg 体重: 53kg 运行: 未公开 行走速度: 2 m/s. 自由度: 49 (手 12+5 被动) 感知: 深度 RGBD 相机 目标价: RMB 200K		身高: 173cm  负重: 20kg 体重: 63kg 电池: 2.3 千瓦时 行走速度: 最大 5 m/s. 自由度: 50 (手 11 个) 感知: 相机, 超声传感 目标价: US\$ 20K		身高: 180cm  负重: 20kg 体重: 47kg 电池: 850 瓦时 行走速度: 最大 3.4-5 m/s. 自由度: 18 (无手) 感知: 深度相机, 3D 雷达 目标价: US\$ 90K	
Fourier Intelligence: GR-1		IX: Neo		Agility Robotics: digit	
身高: 165cm  负重: 20kg 体重: 55kg 运行: 未公开 行走速度: 最大 5 m/s. 自由度: 40 (手 11) 感知: 深度相机 目标价: 未公开		身高: 165cm  负重: 20kg 体重: 30kg 运行: 2-4 小时 行走速度: 3 m/s. 自由度: 未公开 感知: 未公开 目标价: 未公开		身高: 175cm  负重: 15kg 体重: 65kg 运行: 未公开 行走速度: 1.5 m/s. 自由度: 22 感知: 深度相机, 3D 雷达 目标价: 未公开	
Xpeng: XP5		Kepler Exploration Robotics: Kepler		LIMX Dynamics: CL-1	
身高: 150cm  负重: 未知 体重: 未公开 运行: 2 小时 行走速度: 1-2 m/s. 自由度: 51 (手 11) 感知: 深度相机 目标价: 未公开		身高: 175cm  负重: 未知 体重: 85kg 运行: 未知 行走速度: 1-2 m/s. 自由度: 40 (手 12) 感知: 双目 3D 相机 目标价: Around US\$ 30K		身高: 未公开  负重: 未公开 体重: 未公开 运行: 未公开 行走速度: 1-2 m/s 自由度: 18 (无手) 感知: 深度相机 目标价: 未公开	

图 1.2 不同厂商的人形机器人构型, CSDN^[9]

Figure 1.2 Configuration of different humanoids by different companies

然而，尽管发展前景广阔，人形机器人从现在的研究重心，即底层运动控制和动作跟踪、遥操作走向真正的拟人化运动，实现真正的”具身智能“依然任重道远。由于人形机器人形态差异大（如图1.2所展示的），用于参考的动作数据稀缺，不同厂商之间的控制策略和训练框架差异大，因此实现从数据制备、模型训练到工程部署的仿人控制全链路是一项巨大的挑战，而这一挑战也构成了本文的研究驱动力。本文拟解

决的关键问题如下：

1. **形态学差异带来的数据获取和重定向挑战**：作为实现仿人运动的参考，人类动作捕捉数据丰富。然而，人体与机器人在骨骼比例、关节限位、自由度配置以及质量分布上存在本质差异。直接的几何映射往往会导致机器人动作僵硬、自碰撞甚至物理不可行。如何建立一套自适应的映射机制，将通用的人类数据转化为特定机器人的高质量训练数据，是实现智能化的第一道门槛^[10]。
2. **全身动作跟踪的人形机器人稳定控制**：解决了参考数据的来源，但将其转换成机器人的具体控制指令和动作依旧是一大挑战。人形机器人是典型的高维、欠驱动、非线性系统。在缺乏精确动力学模型的情况下，如何让机器人既能像人类一样灵活运动，又能具备极强的抗扰动能力，是控制层面的核心痛点^[11-12]。
3. **结合语义信息的动作规划与控制**：即使在拥有了良好的动作模仿控制器，人形机器人和人类的一大区别依然在于其没有根据语义信息，如“走几步”、“向前跑”等自然语言信息规划运动能力。现有的大语言模型（LLM）已经能做到给出自然语言指令，但是还缺乏像视觉-语言-动作模型（VLA）一样直接作用到电机动作的框架。如何构建一个中间层，利用生成式模型将抽象指令转化为符合物理规律的长程动作序列，并实现实时闭环控制，是连接“大脑”与“小脑”的关键。
4. **模型训练和虚实迁移的工程鸿沟**：人形机器人的仿人运动涉及大量复杂的工程任务，包括环境设计、模型训练，以及真机部署所需解决的，仿真与现实中存在的难以消除的物理参数差异（Sim-to-Real Gap）。而这些问题的解决高度依赖专家经验，调试成本高昂。何利用自动化手段降低部署门槛，实现安全、高效的真机迁移，是打通应用“最后一公里”的必经之路。

综上所述，本文旨在针对上述挑战，构建一套涵盖**数据准备——基础控制——生成规划——自动部署**的全栈式仿人运动控制框架，通过多学科技术的交叉融合，推动人形机器人运动智能的发展。

1.2 国内外研究现状

人形机器人的通用化控制与智能化部署是一个涵盖机械动力学、最优控制、计算机视觉及生成式人工智能的多学科交叉难题。为了厘清技术演进脉络并明确本文的研究切入点，本节将严格遵循“数据—控制—规划—部署”的技术逻辑，从人形机器人动作重定向与数据生成、基于学习的全身运动控制、生成式动作规划与闭环以及大

模型辅助自动化训练部署四个维度，对国内外研究现状进行深入综述与分析。

1.2.1 人形机器人动作重定向与数据生成

动作重定向 (Motion Retargeting) 旨在建立源域 (如人体 MoCap 数据) 至目标域 (如机器人关节空间) 的映射关系。由于人形机器人与人类在骨骼比例、自由度 (DoF) 配置及关节限位上存在显著的形态学差异 (Morphological Discrepancy)，直接的几何映射往往导致动作僵硬、自碰撞甚至物理不可行。因此，重定向技术是解决人形机器人“高质量运动数据稀缺”这一核心瓶颈的关键技术^[13]。现有的主流方法主要可分为基于优化的方法和基于物理/几何的方法。

基于优化的重定向方法将重定向过程建模为带有约束的非线性优化问题。此类方法通常通过引入质心 (CoM) 轨迹跟踪、末端执行器位置约束及动量平衡项来构建损失函数^[14-15]。例如，Darvish 等人提出的几何重定向框架，通过分层优化在保持接触状态一致性的前提下求解全身姿态^[16]。近期，He 等人提出的 ASAP 框架进一步结合了仿真与真实世界的物理约束，提升了动作的可行性^[9]。然而，此类方法存在显著**局限性**：由于优化求解是逐帧或短时窗进行的，极易导致时间轴上的动作不连续，产生高频抖动；同时，在处理异构映射时容易陷入构型奇异点，导致解算失败^[17]。

基于物理与逆运动学 (IK) 的方法则试图通过解析或数值手段，直接计算与人体关键点相匹配的机器人关节角度。早期的研究主要依赖几何 IK 求解，近年来则更多结合动力学仿真。例如，一些工作利用 MINK 等库进行加速求解，试图在逆运动学基础上增加接触特征约束^[18-19]。随着计算机视觉的发展，基于单目视觉的方案 (如 HumanPlus^[20]) 也开始尝试从视频中直接提取人体姿态并映射到机器人。但上述方法在通用性上仍面临挑战：传统 IK 方法在面对大规模数据集 (如 AMASS) 时实时性不佳，且通常需要针对每一台特定的机器人编写复杂、特化的配置方案，缺乏一套能够自动适应不同机器人形态的通用化框架^[21]。

综上所述，尽管现有的重定向技术在特定机型上已取得一定进展，但仍缺乏一种自适应、标准化且高效的数据生成范式。如何构建一套统一的流水线，无需繁琐的人工配置即可将大规模人体动作数据高质量地迁移至 Unitree H1、G1 或 Fourier GR1 等异构机器人上，并解决动作生成中的物理一致性与平滑性问题，是本文第二章重点解决的课题。

1.2.2 基于学习的全身运动控制

人形机器人的运动控制策略旨在实现稳定行走、抗扰动平衡及复杂的全身协调动作。根据技术路线的演进，现有的控制方法正从传统的基于模型控制向基于数据的学习型控制范式转变。

在早期研究中，基于模型的控制（Model-Based Control, MPC）占据主导地位。此类方法依赖于精确的动力学建模，通过全身控制（Whole Body Control, WBC）框架下的分层优化策略，实现了如 Atlas 机器人在复杂地形下的动态平衡^[22-23]。然而，人形机器人具有高维非线性特性，单纯依赖 MPC 往往受限于建模误差与巨大的实时计算瓶颈，难以在非结构化环境中兼顾全身协调与敏捷性。这促使学界逐渐转向数据驱动的方法。

随着计算能力的提升，强化学习（Reinforcement Learning, RL）因其强大的环境适应能力，已成为人形机器人控制的主流范式。DeepRL 通过智能体与环境的交互试错来优化策略，在四足机器人的地形适应任务中已取得突破性进展^[11]。在双足领域，RL 同样展现出超越传统控制的潜力：Cassie 机器人利用近端策略优化（PPO）算法掌握了复杂地形行走的盲视策略^[24]；Unitree H1 则通过大规模并行仿真实现了极强的抗扰动步态^[25]。然而，纯粹以奖励最大化为目标的 RL 方法往往导致策略收敛至局部最优，产生高频抖动、步态僵硬等“伪影”动作，且在高维空间中面临探索效率低下与冷启动（Cold-Start）周期过长的问题^[26]。

为了赋予机器人更自然、更类人的运动风格，模仿学习（Imitation Learning, IL）被广泛引入。DeepMimic^[27] 提出了基于物理的运动跟踪框架，利用奖励函数强制机器人复现参考动作。为了进一步摆脱对精确参考轨迹的强依赖，Peng 等人提出的 AMP（Adversarial Motion Priors）^[28] 利用对抗训练让机器人从非结构化的动作数据中学习运动风格，实现了高度自然的动作生成。然而，现有的 RL+IL 框架往往在“精准复现”与“自主平衡”之间难以取舍：强跟踪策略在参考数据缺失或环境突变时容易失效，而强鲁棒策略（如 AMP）往往丧失了对特定参考轨迹的精确复现能力。

此外，在策略网络架构方面，传统的控制策略多采用多层感知机（MLP）。近年来，基于 Transformer 的策略网络（如 Behavior Transformer）凭借其卓越的序列建模能力，被证明在处理多模态观测与长时序依赖方面优于传统的 MLP 网络^[29-30]。尽管如此，如何设计一种通用的 Transformer 骨干网络，使其既能处理高频的本体感知信息，又能融合稀疏的参考轨迹与语义指令，并在“高保真模仿”与“自主速度跟随”模式间实现平滑切换，仍是当前亟待解决的难点。本文将在第三章中重点探讨其解决

方案。

1.2.3 生成式动作规划与闭环控制

随着生成式人工智能 (AIGC) 的爆发, 如何利用生成模型赋予机器人长程、多样化且语义可控的动作规划能力, 成为了连接“高层认知”与“底层控制”的关键环节。

早期的动作生成主要基于循环神经网络 (RNN)^[31] 和变分自编码器 (VAE)^[32]。这些方法虽然实现了从自然语言到简单动作序列的映射^[33], 但受限于模型表达能力, 生成的动作往往缺乏多样性, 且在长序列生成中容易产生累积误差导致“滑步”或冻结。

扩散模型 (Diffusion Models) 的出现彻底重塑了这一领域。以 MDM (Motion Diffusion Model)^[34] 为代表的工作首次将扩散模型应用于人体动作生成, 展现了惊人的生成质量与语义对齐能力。随后, 相关研究在长序列生成^[35]及风格化编辑^[36]等方面取得了长足进展。**然而, 上述图形学领域的方法存在显著的落地障碍:**它们主要关注视觉效果, 缺乏对机器人运动学 (关节限位) 与动力学 (力矩、接触) 约束的考量, 导致生成的轨迹往往包含穿模或非物理现象, 无法直接用于控制实体机器人^[37]。

针对这一问题, Diffusion Policy^[38] 首次系统地将扩散模型引入机器人策略学习, 通过将动作序列建模为条件扩散过程, 并结合滚动时域控制 (Receding Horizon Control, RHC), 成功实现了视觉运动策略的闭环控制。该方法随后被迅速扩展至 3D 视觉操作^[39]及视觉-语言-动作 (VLA) 大模型中^[40]。**尽管如此, 将其应用于人形机器人全身运动控制仍面临严峻的“频率鸿沟”挑战:**扩散模型的迭代去噪过程通常耗时较长 (推理频率小于数 Hz), 难以匹配人形机器人底层电机控制对高频响应的需求。这种延迟会导致控制回路的相位滞后, 引发系统失稳。

近年来, 流匹配 (Flow Matching) 技术通过求解常微分方程 (ODE) 实现了极少步数的高效生成, 为解决这一实时性瓶颈提供了新的可能^[41]。目前, 如何结合 Flow Matching 的高推理速度与 MPC 的闭环校正能力, 构建面向人形机器人全身运动的实时生成式规划框架, 仍是该领域的前沿空白^[42], 也是本文第四章的研究重点。

1.2.4 大模型辅助自动化训练与 Sim-to-Real 部署

构建适配多构型人形机器人的通用控制系统, 不仅取决于算法本身的优劣, 更受限于训练流程的自动化程度与虚实迁移 (Sim-to-Real) 的可靠性。面对形态各异的机器人硬件与日益复杂的任务需求, 传统的依赖“人工设计奖励 + 手动整定仿真参数”

的开发范式，在效率与可扩展性上已面临严峻瓶颈。

在辅助训练与自动化设计方面，大语言模型（LLM）的引入正在重塑机器人的开发流水线。为了降低对专家领域知识的依赖，Eureka 框架^[43]创新性地利用 LLM 结合进化算法，实现了奖励函数的自动化编写与迭代。在感知层面，视觉-语言-动作模型（VLA）如 OpenVLA^[44] 和 AutoRT^[45] 尝试通过端到端训练实现对自然语言指令的直接动作预测。然而，现有的自动化方法多表现为“开环”特性：LLM 虽然能生成代码，但缺乏对物理世界动力学特性的直观感知（Physical Grounding）。在缺乏真实反馈的情况下，生成的系统往往在仿真中“过拟合”，导致策略难以泛化至不同构型的物理实体，且难以保证安全性。

在虚实迁移（Sim-to-Real）部署方面，为了将仿真中习得的能力迁移至真实机器人，传统的解决方案主要依赖域随机化（Domain Randomization, DR）和系统辨识。DR 方法通过在仿真中大幅随机化物理参数来覆盖真实世界的分布^[46-47]。Tobin 等人证明，经过充分随机化的策略能够迁移至真实机器人^[48]。但这种方法在处理异构机器人集群时显得力不从心：针对双足机器人的特定任务（如行走、跳跃），往往需要针对特定机型设计专门的随机化范围^[49]。这种高度依赖人工经验的“特化”调优过程，极大地阻碍了控制系统在不同构型机器人间的快速复用与推广。

迈向自动化闭环部署：近期的前沿工作开始尝试构建更智能的迁移流程，例如利用 LLM 根据仿真数据动态调整环境参数。然而，目前的部署流程仍缺乏一套量化的安全评估与反馈机制。如何在策略上机前自动评估其在特定构型上的潜在风险？如何将真机实验中的失败数据馈给系统以实现自我修正？构建包含同态评估器（Homomorphic Evaluator）的在线连续监控系统，实现从“奖励设计—仿真训练—安全评估—真机部署—反馈修正”的全链路自动化闭环，是降低人形机器人应用门槛、实现多构型通用的关键方向，也是本文第五章的核心贡献。

1.3 主要研究内容

针对人形机器人在高动态运动生成、复杂动作控制及虚实迁移部署中面临的数据稀缺、控制不稳、规划与执行频率失配以及部署门槛高等核心挑战，本文开展了系统性的研究。主要研究内容概括如下：

1.4 主要研究内容

针对人形机器人在高动态运动生成、复杂动作控制及虚实迁移部署中面临的数据稀缺、控制不稳、规划与执行频率失配以及部署门槛高等核心挑战,本文致力于构建一套通用的、模块化的人形机器人全栈运动控制框架。本文的主要研究内容按照“数据—控制—规划—部署”的自底向上逻辑,概括如下:

1. 数据层: 构建人形机器人自适应动作重定向与标准化数据生成范式

针对人形机器人与人体在形态学上的显著差异,提出了一种基于 Transformer 架构的轻量级自适应重定向框架。该框架摒弃了传统针对特定机型手动修改 URDF 的繁琐流程,通过多姿态联合优化算法,实现了 SMPL 人体模型参数与异构机器人构型的自动匹配。结合包含多级时域滤波、接触相位推断及镜像增强的后处理流水线,本文成功将大规模人体动作捕捉数据 (AMASS) 转化为符合动力学约束的通用机器人数据集 (HumanoidML3D)。此外,设计了基于单目视觉的通用动作接口,实现了从野外视频到不同构型机器人动作的“零样本”迁移,为系统构建了坚实的数据基座。

2. 控制层: 设计兼容动作模仿与自主探索的强鲁棒控制策略

为了解决传统 MLP 网络在多动作模仿中泛化能力差及对参考数据依赖强的问题,提出了一种名为 Motion Mimic Transformer (MMTransformer) 的策略骨干网络。该网络利用 SwiGLU 分组嵌入与自注意力机制,动态融合高频本体观测与稀疏参考动作特征。在此基础上,设计了 DAgger-MMPPO 两阶段训练算法,并引入课程学习机制,引导智能体从简化环境下的行为先验平滑过渡到全物理环境下的鲁棒控制,实现了控制器在“高保真动作模仿”与“自主速度指令跟随”模式间的无缝切换,构建了可靠的底层执行机构。

3. 规划层: 探索基于扩散模型的分层运动生成与实时规划框架

针对高层语义规划与底层控制之间的“频率与模态鸿沟”,提出了一种基于扩散模型的分层闭环控制架构。首先,基于 HumanoidML3D 定义了全状态数据表征规范,训练了形态无关的动作扩散模型。为了突破生成模型的实时性瓶颈,引入 Flow Matching (流匹配) 技术和知识蒸馏策略,显著提升了推理速度。进一步设计了实时扩散模型预测控制 (Diffusion-MPC) 算法,实现了低频语义生成与高频底层执行策略 (由 MMTransformer 充当) 的闭环协同,赋予了机器人理解自然语言指令并实时生成物理可行长程动作的能力。

4. 部署层: 开发基于大语言模型的自动化辅助训练与部署系统

为了降低强化学习奖励函数设计的门槛并提升 Sim-to-Real 的安全性，构建了名为 AnyBipe 的端到端自动化部署框架。该框架利用大语言模型（LLM）基于思维链（CoT）自动生成并迭代优化奖励函数代码。同时，提出了一种融合参考策略的半监督训练方法，有效解决了 LLM 生成奖励初期导致的“冷启动”难题。更为关键的是，设计了包含同态评估器（Homomorphic Estimator）和安全检查机制的自动化闭环，量化了仿真与现实的差距，实现了策略在 Unitree H1、Limx P1 等异构机器人上的安全、高效部署，打通了从算法到落地的“最后一公里”。

1.5 论文章节安排

本文的整体架构如图1.3所示，内容安排遵循“课题描述—算法设计—部署优化”的逻辑主线，共分为六章，具体安排如下：




图 1.3 本文各章节逻辑结构关系

Figure 1.3 Logical structure and relationship of chapters

- **第二章基于动作捕捉数据的人形机器人自适应动作重定向：**本章位于算法架构的最前端，重点解决“数据获取”问题。详细阐述自适应形态匹配算法与 Pose Transformer 网络，将人类动作转化为机器人的关节空间动作。该章节构建的“模仿学习数据集”与“扩散模型数据集”是第三章策略训练与第四章生成模型训

练的基础。

- **第三章兼容动作模仿和自适应运动的机器人控制策略设计**：本章利用第二章提供的模仿数据，构建兼容性强的 GBC 控制策略。详细介绍 MMTransformer 骨干网络与 DAgger-MMPPO 训练算法。该章节训练得到的策略不仅实现了鲁棒的运动控制，更作为“基础控制策略”被第四章调用，负责执行上层规划生成的参考轨迹。
- **第四章基于扩散模型的人形机器人全身运动生成与闭环控制**：本章构建基于语义的动作生成器。利用第二章的可微数据框架训练扩散模型，并引入流匹配技术以实现控制频率的对齐。该章节与第三章形成闭环：第四章生成的“参考运动轨迹”指导第三章的控制器运动，而第三章控制器的执行反馈又用于校正生成过程，从而实现“生成—执行”的实时闭环。
- **第五章基于大语言模型的辅助训练与 Sim-to-Real 部署框架**：本章服务于上述算法的工程落地。针对模型训练难、迁移难的问题，提出 AnyBiPe 自动化框架。利用 LLM 辅助设计环境变量与奖励函数并进行半监督训练，同时引入同态评估器构建 Sim-to-Real 反馈闭环，确保算法在真机上的安全部署。

1.6 本章小结

本章首先介绍了人形机器人在社会服务、灾难救援及人机协作等领域的广阔应用前景，指出了高维非线性控制、跨形态数据适配及虚实迁移等关键技术挑战。随后，从动作重定向、强化学习控制、生成式规划及大模型辅助决策四个维度，对国内外的研究现状进行了系统梳理，分析了现有方法的优势与不足。最后，明确了本文旨在构建一套涵盖数据生成、底层控制、高层规划及自动化部署的通用控制系统，并给出了具体的研究内容与章节安排，为后续章节的展开奠定了基础。

第2章 基于动作捕捉数据的人形机器人自适应动作重定向

2.1 问题分析

为了使形机器人 (Humanoid Robots) 能够精准地复现人类的全身复杂运动, 构建高质量、大规模的演示数据集至关重要。目前, 此类数据主要依赖于对 MoCP 数据的重定向计算获得。然而, 如何实现从人体运动空间到机器人关节空间的各种异构映射, 仍是当前研究的难点。

现有的主流方法通常基于几何约束或优化算法。例如, Unitree Retargeting Dataset 采用了 Lafan1 数据集^[50] 作为基准, 并利用 Interaction Mesh^[14] 框架结合传统的逆运动学 IK 求解器来生成机器人动作。这类方法的局限性在于其高度依赖于特定机器人的拓扑结构; 针对不同构型的机器人, 往往需要繁琐的人工调整以适配其几何参数, 泛化能力较弱。

另一种更为直接的策略是将重定向过程建模为约束优化问题。以 H2O^[51] 框架为例, 该方法将逆运动学简化为基于关节末端位置约束的目标函数, 通过梯度下降法直接搜索最贴合的关节角度。虽然该方法在计算流程上较为简洁, 但单纯的数值优化容易陷入局部极小值, 且缺乏对机器人自身运动学流形的先验约束。这导致求解出的最优解虽然在几何上满足末端位置要求, 但在运动学上可能处于奇异位置, 或表现出不自然的抖动, 难以捕捉从 MoCap 数据到机器人动作映射的内在平滑规律。

近年来, 基于优化的求解器取得了新的进展。例如 GMR^[52] 等基于 MINK 框架的重定向模型, 创新性地将重定向任务构建为一个二次规划 (Quadratic Programming, QP) 问题, 从而在计算效率上实现了显著提升。然而, 这一类方法在工程落地层面仍面临挑战: 它通常要求用户手动定义复杂的逆运动学关节映射表 (Joint Mapping Table)。对于每一种新的机器人构型, 甚至是不同的数据表示规范 (如 SMPL 参数化模型与 BVH 骨骼动画标准), 都需要单独进行配置文件编写与参数调试, 极大地限制了其在多构型场景下的通用性与部署效率。

综上所述, 现有方法在实时性、自动化程度以及对多构型机器人的自适应能力方面, 难以同时满足需求。针对上述痛点, 本研究提出了一种新型的动作捕捉-动作转换框架。本文设计了一个轻量级的神经网络, 旨在通过小参数量的模型直接回归在末端位置约束下的动作捕捉-动作非线性映射关系。此外, 为了确保生成动作的物理真实性, 本文在网络训练中引入了特定的动力学约束, 以保证转换后的机器动作不

仅在几何上精准，且在运动学上可行并保持时序上的连续平滑。本文的框架结构如图2.1所示。




图 2.1 自适应重定向算法工作管线

Figure 2.1 Processing pipeline for morphology adaptive retargeting algorithm

2.2 自适应重定向的骨干网络设计

2.2.1 异构机器人形态学自适应匹配

为了实现端到端的监督学习，必须构建从人体空间 $\mathbb{P}$ 到机器人空间 $\mathbb{A}$ 的可微监督链路。然而，直接利用人体动捕数据面临的主要障碍在于人体与机器人之间显著的几何尺寸与拓扑差异。例如，Unitree H1-2 机器人的大腿与小腿比例可能与标准人体解剖学统计数据不同，且其关节定义的零位姿态（Zero Pose）也往往与动捕数据的 T-Pose 或 A-Pose 不一致。

为此，本文在网络训练前引入了一个基于优化的形态学对齐步骤。

2.2.1.1 关节映射与运动学树构建

首先，本文需要建立人体骨骼关键点与机器人连杆之间的语义对应关系。AMASS 数据集采用 SMPL+H 参数化模型，包含 52 个骨骼节点（22 个躯干关节 + 30 个手部关节）。如图 2.2 所示，本文定义了一个映射表 $\mathcal{T}_{map}$ ，将 SMPL+H 的标准关节名称（如 'L_Hip', 'R_Ankle'）映射至具体机器人的 URDF 连杆名称（如 'left_hip_yaw_link', 'right_ankle_pitch_link'）。基于此映射，算法自动解析机器人的 URDF 文件并构建可微的运动学计算树。

2.2.1.2 基于加权多姿态优化的参数求解

为了消除几何差异，本文将形态学匹配建模为一个多变量优化问题。SMPL+H 模型的前向运动学 $\mathbf{FK}_{hm}$ 由 16 维形状参数向量 β （表征身高、胖瘦、臂展等体型特征）和 8 维动态混合形状参数 $\mathcal{D}$ （DMPLs，表征软组织变形）决定。考虑到机器人通常


```
# unitree h1-2 (SMPLH: URDF)
```

```
mapping_table = {
```

```
  'Pelvis': 'pelvis',
```

```
  'L_Hip': 'left_hip_yaw_link',
```

```
  'R_Hip': 'right_hip_yaw_link',
```

```
  'L_Knee': 'left_knee_link',
```

```
  'R_Knee': 'right_knee_link',
```

```
  'L_Ankle': 'left_ankle_pitch_link',
```

```
  'R_Ankle': 'right_ankle_pitch_link',
```

```
  'L_Shoulder': 'left_shoulder_pitch_link',
```

```
  'R_Shoulder': 'right_shoulder_pitch_link',
```

```
  'L_Elbow': 'left_elbow_link',
```

```
  'R_Elbow': 'right_elbow_link',
```

```
  'L_Wrist': 'left_wrist_pitch_link',
```

```
  'R_Wrist': 'right_wrist_pitch_link',
```

```
}
```




图 2.2 Unitree H1-2 机器人与人体关节的映射定义

Figure 2.2 Joint mapping from human to humanoid defined for Unitree H1-2.

具有固定的连杆长度，单纯调整 β 可能无法完全匹配机器人的绝对尺寸。因此，本文在优化变量中额外引入了一个全局缩放因子 $s \in \mathbb{R}^+$ 。

为了保证拟合出的形态参数在机器人的整个工作空间内均有效，避免对单一动作过拟合，本文采用多姿态联合优化策略，首先构建一个包含标准 T-Pose 和随机采样动作的参考集合 $\mathcal{M} = \{(p^m, a^m)\}$ ，并设计了如下加权损失函数：

$$\arg \min_{\beta, \mathcal{D}, s} \sum_{m \in \mathcal{M}} \sum_{j \in \mathcal{J}} w_j \|s \cdot (\text{FK}_{\text{hm}}^j(p^m, \beta, \mathcal{D}) - \mathbf{r}_{hm}) - (\text{FK}_{\text{hn}}^j(a^m) - \mathbf{r}_{hn})\|_2^2, \quad (2.1)$$

其中：

- $\mathcal{J}$ 为映射表中定义的关节集合；
- FK_{hm}^j 与 FK_{hn}^j 分别表示人体与机器人在关节 j 处的笛卡尔空间位置；
- $\mathbf{r}_{hm}$ 与 $\mathbf{r}_{hn}$ 分别为人体与机器人的根节点 (Root) 位置，用于消除绝对位置偏差，仅关注相对形态；
- w_j 为关节权重系数。为了确保机器人在执行任务时末端接触的精确性，本文在优化中采用了“末端优先”的加权策略。具体而言，给予双脚踝关节 (Ankles) 最高的权重 ($w = 4.0$)，手腕关节 (Wrists) 次之 ($w = 2.0$)，其余中间关节权重设为 $1.0 \sim 1.5$ 。

此外，针对机器人关节坐标系与 SMPL 定义不一致的问题（例如某些机器人的

肘关节零位与人体相差 90 度)，本文在计算损失前引入了预定义的旋转修正矩阵 R_{offset} 。优化过程使用 Adam 优化器，通过梯度下降迭代求解最优的 $\beta^*, \mathcal{D}^*, s^*$ 。

2.2.1.3 拟合结果与泛化性分析

通过求解上述优化问题，本文需要优化得到针对机器人构型的形态学参数 β ，这一优化过程如图 2.5 所示。实验优化后的 SMPL+H Mesh 模型在肩宽、腿长、脊柱高度等关键几何维度上与目标机器人（Unitree H1-2 及 Turin HN）实现了高度重合。该方法的显著优势在于其泛化性：对于任意构型的人形机器人，用户仅需提供图 2.2 所示的关节名称映射和少量的 T-Pose 关节角参考，无需手动测量连杆长度或修改 URDF 文件，算法即可自动计算出最佳匹配形态。这为后续大规模动捕数据的重定向提供了精确的物理一致性基础。




图 2.3 H1-2 形态拟合结果




图 2.4 Turin HN 形态拟合结果

图 2.5 不同构型人形机器人的 SMPL+H 形态拟合效果

Figure 2.5 SMPL+H shape fit for different humanoid architectures

2.2.2 基于物理约束的复合损失函数构建

为了确保生成的动作不仅在几何上精确，而且在运动学上可行且连续，本文设计了包含四项约束的复合损失函数。

末端距离损失 (End-Effector Distance Loss) 作为网络优化的主导项，该损失函数的基础目标是最小化机器人与人体在关键末端节点上的空间位置差异。这一约束的基础实现可以表示为：

$$L_{dist}(p) = \|\text{FK}_{hn}[f(p)] - \text{FK}_{hm}(p)\|_2, \quad (2.2)$$

然而，考虑到人体与人形机器人之间存在固有的构型与运动学域差异，仅约束笛卡尔空间的位置往往会导致机器人出现如手腕过度扭曲、脚踝接地角度异常等不自然的姿态。借鉴全身控制 (Whole-Body Control, WBC) 中对于任务空间位姿控制的思

想, 本文在优化位置的同时, 必须对末端执行器 (End-Effector, 主要定义为双手手腕与双脚脚踝) 的空间朝向进行约束。本文定义 $\text{FK}^{pos}(\cdot)$ 和 $\text{FK}^{rot}(\cdot)$ 分别为正运动学计算得到的末端位置向量与末端旋转矩阵。为了平衡位置追踪精度与姿态对齐的需求, 这一部分将该损失函数扩展为位置误差与朝向误差的加权组合:

$$L_{dist}(p) = \sum_{i \in \mathcal{E}} \left(\|\text{FK}_{hn,i}^{pos}[f(p)] - \text{FK}_{hn,i}^{pos}(p)\|_2^2 + \lambda_{rot} \|\text{FK}_{hn,i}^{rot}[f(p)] - \text{FK}_{hn,i}^{rot}(p)\|_F^2 \right), \quad (2.3)$$

其中, $\mathcal{E}$ 代表需要约束的末端关节集合 (如手腕、脚踝等), $\|\cdot\|_F$ 表示矩阵的 Frobenius 范数, 用于衡量两个旋转矩阵之间的距离, λ_{rot} 为平衡位置与朝向权重的超参数。通过这一复合约束, 网络能够引导机器人在保持末端位置精确的同时, 自动调整肢体角度以拟合人类自然的运动姿态。

关节限位约束 (Joint Limit Loss) 单纯的距离优化可能导致输出动作超出机器人的物理极限。为此, 本文结合 URDF 定义的硬件限位 (a_{min}, a_{max}) 与人类关节的生理活动范围, 构建如下惩罚项:

$$L_{limit}(p) = \|\max(a_{min} - f(p), 0)\|_2 + \|\max(f(p) - a_{max}, 0)\|_2, \quad (2.4)$$

动作扰动与平滑约束 (Action Disturbance Loss) 为了抑制高频抖动并增强模型鲁棒性, 本文引入 Lipschitz 连续性约束。借鉴 WGAN-GP^[53] 的思想, 本文避免计算高昂的谱范数, 而是通过惩罚随机高斯扰动 $\delta p \in \mathcal{N}(0, \sigma \cdot 2\pi)$ 下的输出差分变化率, 迫使网络学习平滑的运动流形:

$$L_{disturb}(p) = \frac{\|\text{FK}_{hn}[f(p)] - \text{FK}_{hn}[f(p + \delta p)]\|_2}{\|\delta p\|_2}, \quad (2.5)$$

对称性一致约束 (Symmetry Loss) 利用人体与机器人的结构对称性, 本文定义轴对称变换 $S(\cdot)$ 。对于输入动作 p 及其对称动作 $p' = S(p)$, 本文要求网络输出的末端位置在笛卡尔空间中保持相应的对称关系:

$$L_{sym}(p) = \|\text{FK}_{hn}[f(p')] - S(\text{FK}_{hn}[f(p)])\|_2, \quad (2.6)$$

最终的总损失函数为上述四项的加权和。此外, 针对膝关节、头部等单自由度关节, 框架还允许用户根据需求添加保角映射损失作为辅助约束。

基于形态拟合与自适应网络生成的微分逆运动学 (Differentiable IK) 模型, 虽然具备了将人体 Angle-Axis 序列投影到机器人关节空间的能力, 但其直接输出的原始动作序列在工程落地中仍面临诸多挑战。针对采样稀疏性、动力学不匹配以及 RL 训练对数据多样性的需求, 本研究设计了一套包含多级滤波、时空规范化与对称增强的后处理流水线。

2.2.2.1 多级时域滤波与轨迹平滑

为了消除高频噪声并保证关节轨迹的 C^2 连续性, 本文采用了“去离群-平滑-插值”的三级处理策略:

1. **离群值去除**: 由于神经网络在处理极端姿态时可能产生突变的预测值, 直接滤波会导致伪影扩散。因此, 本文首先引入 Hampel 滤波器, 通过计算滑动窗口内的中位数绝对偏差 (Mean Absolute Difference, MAD), 识别并替换偏离度超过 3σ 的异常帧。
2. **旋转流形平滑**: 针对四元数表示的根节点朝向 (Root Orientation), 普通的线性滤波可能破坏其单位范数约束。本文采用 Savitzky-Golay 滤波器 (窗口大小 11, 多项式阶数 3) 在 $SO(3)$ 切空间进行平滑处理, 并在滤波后强制执行四元数归一化与连续性修复, 以避免符号翻转导致的角度突变。
3. **低通滤波与重采样**: 最后, 利用球形线性插值 (Spherical Linear Interpolation, SLERP) 将序列重采样至目标帧率, 并应用截止频率为采样率 1/10 的低通滤波器滤除超越机器人驱动带宽的高频震动。

2.2.2.2 坐标系规范化与抗奇异处理

为了使生成的动作序列能够适配强化学习环境中的随机重置机制, 本文需要消除动作序列对绝对坐标的依赖。本文实施了轨迹规范化 (Trajectory Canonicalization): 对于每个动作序列, 计算其首帧的变换矩阵 T_{init} , 并将整个序列变换至以首帧为原点、首帧朝向为 X 轴正方向的局部坐标系中。

在处理基座的 Yaw 轴旋转提取时, 为了避免欧拉角表示中常见的万向节死锁问题, 特别是在机器人俯仰角 (Pitch) 接近 $\pm 90^\circ$ 的极端情况下, 算法会自动检测 $\cos(pitch)$ 的阈值。当检测到奇异性风险时, 自动切换至基于旋转矩阵元素的鲁棒解算逻辑, 确保基座航向角的计算在全构型空间内连续可导。

2.2.2.3 基于对称性的数据增强

为了进一步提升强化学习策略的鲁棒性并扩充有效样本量，本文利用人形机器人左右对称的形态学特征，开发了基于镜像对称的数据增强模块。该模块不仅对关节角度进行左右索引互换（如左髋 $\leftrightarrow$ 右髋），同时对基座的 Y 轴与 Roll、偏 Yaw 方向角进行符号翻转。通过这一操作，本文将可用数据集的规模扩充了一倍，并强制策略网络学习左右对称的运动特征。

2.2.2.4 面向强化学习的状态空间构建

为了辅助 RL Agent（特别是 Critic 网络）更好地理解环境状态，本文构建了包含多模态物理信息的参考集。

- **接触状态相位化**：通过监测足端末端执行器的全局线速度与离地高度来判定接触状态（阈值设为 $0.065m$ ）。为了提供明确的时序信号，本文将离散的二值接触状态拟合为连续的正弦/余弦相位波。
- **地形适应性高度修正**：考虑到不同动捕对象的身高差异，直接重定向可能导致机器人悬空或穿模。本文引入高度修正算法，计算机器人 Mesh 在当前姿态下的最低点，动态调整基座高度 z ，确保足底始终与地面恰当接触。

2.2.2.5 基于几何检索的周期性子序列提取

AMASS 数据集中包含了大量如行走、奔跑等具有明显周期性特征的动作。为了支持 RL 环境中的长时训练，本文需要从非结构化数据中提取可循环播放的周期性子序列（Cyclic Subsequence）。

本文假设一个理想的循环子序列，其起始帧 t_{start} 与结束帧 t_{end} 的动作状态应在欧氏空间中高度近似。基于此，本文提出了一种基于 KD-Tree 的高效检索算法：1. 对转换后的动作序列建立 **KD-Tree** 空间索引。2. 对于序列中的每一帧，在 KD-Tree 中检索其最近邻点，寻找满足以下约束的候选点对 (t_i, t_j) ：

$$\|\mathbf{a}_{t_i} - \mathbf{a}_{t_j}\|_2 < \varepsilon, \quad \text{s.t.} \quad |t_i - t_j| > \gamma \cdot L_{seq}, \quad (2.7)$$

其中 ε 为状态容差， γ 为最小循环长度比例（本研究取 0.2）， L_{seq} 为总序列长度。3. 为了防止 KD-Tree 在高维空间退化并加速搜索，本文引入了针对起始点与终点距离的剪枝策略，并在向序列中心扫描过程中采用早停（Early Stopping）机制。

图 2.6 中的红色与绿色虚线标记了算法自动识别出的最长循环子序列。该算法对于长度为 n 的序列，其平均时间复杂度控制在 $O(\log n)$ ，确保了大规模数据处理的高




图 2.6 序列后处理效果示例
Figure 2.6 Demonstration of sequence post processing

效性。最终提取的动作基元被序列化为 Pickle 文件，支持在后续的系统设计中被高效加载与复用。

2.3 训练细节与实验结果分析

本节将详细阐述训练过程中的具体参数设置，并对实验结果进行全面的定量与定性分析。首先，本节将验证数据处理流水线的有效性，随后展示所生成的重定向动作在不同构型机器人上的表现。

2.3.1 数据处理流水线验证

本小节旨在验证本文提出的动作捕捉数据处理流水线的有效性。首先，本小节将展示该方法在图 2.7 所示的四种不同构型人形机器人上的通用性。评估内容涵盖 SMPL+H 模型初始形态拟合的质量、姿态重定向网络的回归性能、后处理平滑的效果，以及最终生成动作在 Isaac Sim 仿真环境中的执行质量。此外，本小节还将重点验证网络对训练集外未见动作的泛化能力，为后续类似工作提供具有参考价值的基准指标。

2.3.1.1 关节映射与形态拟合

建立 SMPL+H 人体模型关节与目标机器人连杆之间的精确对应关系，是实现高质量姿态匹配的前提。针对每一个对应关系，本部分实验分配了一个 `joint_weight`




图 2.7 实验中使用的四种人形机器人及其基本参数
Figure 2.7 Robot names and parameters used in the experiment part.

权重参数，用于在形态拟合与重定向优化过程中调节其重要性。例如，给予末端执行器（End-effectors）更高的权重，有助于确保其最终位置的精确性与物理真实性。表 2.1 列出了四种机器人平台的详细关节映射及权重分配方案。

表 2.1 SMPL+H 关节与不同构型机器人的连杆映射关系及权重分配
Table 2.1 Correspondence of SMPL+H Joints to Robot Links and Assigned Weights

Joint Name	W.	Unitree H1-2	Turin V3	Fourier GR1	Unitree G1
Pelvis	1.0	pelvis	base_link	base_link	pelvis
Hip	1.0	hip_yaw	hip_yaw	thigh_pitch	hip_roll
Knee	1.5	knee	knee	shank_pitch	knee
Ankle	4.0	ankle_pitch	ankle_roll	foot_roll	ankle_roll
Toe	4.0	-	append_toe*	-	-
Shoulder	1.0	shoulder_pitch	arm_roll	upper_arm_roll	shoulder_roll
Elbow	1.5	elbow	elbow_pitch	lower_arm_pitch	elbow
Wrist	2.0	wrist_pitch	wrist_pitch	hand_roll	wrist_yaw

* 针对 Turin V3，增加了固定关节与虚拟连杆以优化脚部俯仰角回归。
¹ 为排版简洁，表中省略了所有映射名称的通配符前缀 ‘.*’ 和后缀 ‘_link’。
² W. 代表权重 (Weight)。

基于上述映射关系，算法首先进行形态学参数的优化，使 SMPL+H 模型在默认姿态与标准 T-Pose 下尽可能贴合机器人的几何结构。表 2.2 汇总了形态拟合的量化结果。表格反馈的极低的平均位置误差表明，通过合理的关节加权策略，本文的算法能够实现从人体模型到机器人运动学结构的精确映射，为后续的精细化重定向奠定了坚实基础。

表 2.2 SMPL+H 形态拟合结果
Table 2.2 SMPL+H Shape Fitting Results

Robot Name	Max Pos. E (cm)	Avg. Pos. E (cm)	Avg. Pose Loss
Unitree H1-2	1.73	0.86	0.074
Turin V3	1.86	0.91	0.082
Fourier GR1	1.18	0.47	0.040
Unitree G1	1.06	0.44	0.038

表 2.3 Pose Transformer 重定向精度 (末端位置误差, 单位: 米)
Table 2.3 Pose Transformer Retargeting Accuracy (End-Effector Position Error, in meters)

Robot Name	Max Position Error			Average Position Error			Median Position Error		
	Train	Val	Test	Train	Val	Test	Train	Val	Test
Train	Val	Test							
Unitree H1-2	0.4367	0.4305	0.4313	0.0563	0.0555	0.0548	0.0251	0.0232	0.0237
Turin V3	0.4486	0.4471	0.4464	0.0581	0.0565	0.0572	0.0266	0.0248	0.0254
Fourier GR1	0.2864	0.2746	0.2562	0.0476	0.0464	0.0428	0.0164	0.0156	0.0158
Unitree G1	0.2487	0.2324	0.2268	0.0432	0.0418	0.0416	0.0157	0.0144	0.0142

2.3.1.2 姿态重定向网络性能评估

为了训练 Pose Transformer 网络, 算法对整个 AMASS 数据集进行了间隔为 10 帧的采样, 并按 4:1 的比例划分为训练集与验证集。此外, 本文利用从 HumanAct12 数据集^[54] 回归得到的数据作为分布外 (Out-of-Distribution, OOD) 测试集, 以评估模型的泛化能力。训练过程中, 损失函数项 $\mathcal{L}_{dist}$ 、 $\mathcal{L}_{limit}$ 、 $\mathcal{L}_{disturb}$ 和 $\mathcal{L}_{sym}$ 的权重分别设为 5000.0、1000.0、100.0 和 1000.0。为了避免正则化项阻碍早期的优化进程, Action Disturbance Loss 的权重采用了退火策略, 从 100.0 逐渐增加至 200.0。所有模型均训练 100 个 epoch, 学习率为 $1e-4$ 。最终的重定向精度如表 2.3 所示。

实验结果表明, 配备躯干俯仰关节 (Torso Pitch Joint) 的 Fourier GR1 和 Unitree G1 模型在涉及躯干运动的动作上具有更好的拟合精度, 最大误差显著更低。相比之下, 缺乏该自由度的 H1-2 和 Turin V3 表现出稍高的最大误差。值得注意的是, AMASS 数据集中包含大量超出机器人运动学极限的动作。在这些情况下, Pose Transformer 能够在机器人的可行域内给出近似的最优解。中位误差显著低于平均误差这一事实证明了该流水线在处理大规模数据时的鲁棒性与高效性。此外, 模型在测试集上的优异表现, 结合图 2.10 中训练损失与验证损失的同步收敛趋势, 有力地证明了网络具备强大的泛化能力, 而非仅仅是对训练数据的过拟合。




图 2.8 (a) H1-2 损失曲线 (Main Loss for H1-2)




图 2.9 (b) GR1 损失曲线 (Main Loss for GR1)

图 2.10 Unitree H1-2 和 Fourier GR1 机器人的 Pose Transformer 网络训练与验证损失曲线
Figure 2.10 Training and validation loss curves on the Unitree H1-2 and Fourier GR1 robots.

为了直观验证流水线的效果, 图 2.11 展示了四种不同构型机器人在多种动作下的重定向结果。图中对比了最终的机器人动作、拟合后的 SMPL+H 模型以及原始人体参考动作, 清晰地展现了运动学映射的高保真度。




图 2.11 跨构型与跨动作的重定向效果定性展示

Figure 2.11 Qualitative retargeting results across different humanoids and motions

2.3.1.3 信号后处理与增强

尽管重定向网络精度很高，但由于源数据的离散采样特性，原始输出仍可能存在微小的抖动。如前文图 2.6 所示，本文的后处理平滑滤波器有效地抑制了这些噪声。为了进一步丰富用于学习鲁棒步态的专家数据，本文的流水线还引入了足部接触事件（Foot-contact Events）推断机制。通过分析基于正运动学（FK）计算得出的足部速度与高度，本文估计出地面的接触时刻，并将这一二值信号转换为连续的正余弦相位序列，以确保其可微性并与 RL 观测空间保持一致。如图 2.12 所示，相位转换点的参数可根据 RL 环境进行微调。该推断信号与 Isaac Sim 中的真实接触状态（Ground-truth）相比，一致性高达 94.8%（在 AMASS-ACCAD 等特定运动子任务上更是达到了 98.2%），证实了其作为演示数据的准确性。

图 2.13 展示了重定向动作在 Isaac Sim 中的最终仿真效果。实验证明，生成的动作流畅、运动学连贯且动力学可行，非常适合作为下游模仿学习任务的高质量示范数据。

2.3.2 与其他重定向方法的对比

为了凸显本方法的优势，本文将 GBC 重定向流水线与多种当前 SOTA（State of the art）的重定向方法进行了对比分析，结果如表 2.4 所示。其他方法的性能指标源自其对应的论文或开源代码仓库。本文的基准测试在配备 Intel i9-14900K CPU 和




图 2.12 足部接触信号处理示意图

Figure 2.12 The conversion of a binary foot-contact signal (top) into a continuous sine-cosine phase representation (bottom)




图 2.13 Isaac Sim 中的重定向动作仿真结果

Figure 2.13 Simulation of the retargeted motions in Isaac Sim

NVIDIA GeForce RTX 4090 GPU 的平台上进行。在下表中，FPS 一栏展示 CPU（左）和 GPU（右）的性能对比。FC 代表足部接触（Foot Contact），L P/V 表示局部坐标系下的位置和速度，而 W P/V 表示世界坐标系下的指标，Sym 表示对称性增强后的数据可用性。

表 2.4 不同动作捕捉重定向流水线的性能对比
Table 2.4 Comparison of different MoCap retargeting pipelines.

Method	FPS	Height Fix	FC	L P/V	W P/V	Sym.
H2O ^[10] , ASAP ^[55] , HOVER ^[56]	50 / -	IK	×	✓	✓	×
TWIST(GMR) ^[52]	60-70 / -	Ground Offset	×	✓	✓	×
HumanPlus ^[20]	- / 25	None	✓	✓	×	×
Ours	530-560 / 1700-1740	FK + EE Filter	✓	✓	✓	✓
Ours (JIT Trace)	800-820 / 3280-3300	FK + EE Filter	✓	✓	✓	✓

基准测试结果显示，GBC 重定向流水线在 CPU 和 GPU 上的计算速度均显著优于现有方法。这一极高的推理效率凸显了其在边缘计算场景下的应用潜力，使得直接在机器人机载处理器上部署重定向算法成为可能。此外，GBC 采用了基于正运动学（FK）与末端速度滤波的双重校验机制，不仅有效修正了源 MoCap 数据中的高度偏差，还保证了足部接触信号的准确性。在所有测试的运动序列中，该机制将浮空率（Floating Ratio，即经 FK 计算的最低足部高度高于地面的帧数比例）成功控制在 5% 以下。更进一步，本文的流水线为后续的强化学习阶段提供了更为丰富的数据支持，包括全局与局部的位姿、速度及角速度信息，以及针对所有动作类型的镜像对称增强数据，极大地提升了数据集的多样性与可用性。

2.3.3 扩展应用：基于单目视觉的动作重定向接口

尽管 AMASS 等动捕数据集提供了高质量的动作先验，但其数据采集环境通常受限于实验室场景，难以覆盖现实世界中极其丰富多样的动作类别（如复杂的街舞、特定体育竞技或影视特技动作）。为了打破这一数据瓶颈，本算法集成了一个基于单目 RGB 视频的非训练样本（In-the-Wild）动作重定向接口。该接口能够直接从互联网视频或用户拍摄的片段中提取具有绝对尺度的三维人体动作，并将其无缝迁移至任意构型的人形机器人上，从而极大拓宽了机器人动作数据的可用性与丰富性。

2.3.3.1 视觉姿态与全局轨迹联合估计

为了从单目视频中恢复准确的三维人体运动,本文集成了 WHAM (Reconstructing World-grounded Humans with Accurate 3D Motion)^[57] 框架。相比于传统的参数化人体网格恢复方法 (如 HMR, VIBE), WHAM 的核心突破在于其结合了基于深度学习的视觉里程计——深度图块视觉里程计 (Deep Patch Visual Odometry, DPVO)^[58]。

具体而言,给定一段单目 RGB 视频序列,系统首先利用特征提取网络回归每一帧的 SMPL 参数 (包括姿态 θ 与形状 β)。与此同时,DPVO 模块通过跟踪视频流中的稀疏特征图块 (Sparse Patches), 构建相机的 6-DoF 运动轨迹与稀疏场景点云。WHAM 通过一个时序融合网络,将相机自身的运动信息与人体在相机坐标系下的相对运动进行解耦与融合,从而解算出人体在世界坐标系下的精确全局轨迹 (Global Trajectory)。这一机制有效解决了传统视觉方法中常见的“脚步漂移 (Foot Sliding)”与全局位移漂移问题,为机器人提供了物理一致的根节点运动参考。

2.3.3.2 异构坐标系对齐与动作重映射

视觉算法输出的轨迹通常定义在相机初始化的任意世界坐标系中,而人形机器人的控制通常基于重力对齐的特定坐标系 (如 Z 轴向上)。为了实现两者的无缝对接,本文在接口中设计了一个自动化的坐标系对齐模块。

设 WHAM 输出的第 t 帧人体根节点旋转矩阵为 R_{wham}^t , DPVO 估计的初始全局对齐矩阵为 R_{init} (用于修正相机初始视角的倾斜)。为了将动作对齐至机器人的基座坐标系,本文引入修正矩阵 R_{align} (例如将 Y 轴向上转换为 Z 轴向上), 执行以下变换:

$$R_{root}^t = R_{align} \cdot R_{init} \cdot R_{wham}^t, \quad (2.8)$$

$$\mathbf{p}_{root}^t = R_{align} \cdot R_{init} \cdot \mathbf{p}_{wham}^t, \quad (2.9)$$

完成坐标系对齐后,本算法将提取并规范化后的 SMPL 姿态参数 θ 输入到前文所述的 **Pose Transformer** 网络中,直接回归出目标机器人的关节角度序列 $a_{robot}^{1:T}$ 。

2.3.3.3 基于正运动学的高度自适应修正

在从单目视觉空间映射到物理仿真空间的过程中,由于单目深度估计固有的尺度模糊性,直接重定向往往会导致机器人出现“悬空”或“足部穿模”现象。为此,本算法引入了基于机器人正运动学 (FK) 的动态高度修正机制。

对于每一帧 t , 本文首先利用预测的关节角度 a_{robot}^t 计算机器人所有足部连杆在当前基座高度下的笛卡尔空间位置。随后,计算足部最低点与地面的偏差,并动态调

整基座的 z 轴高度:

$$z_{offset}^t = \min_{k \in \mathcal{K}_{feet}} (\text{FK}_{robot}^{(z)}(a_{robot}^t, \text{link}_k)) - z_{ground}. \quad (2.10)$$

其中 $\mathcal{K}_{feet}$ 为机器人的足部连杆集合。该修正确保了机器人在执行高动态动作（如跳跃、侧翻）落地时，足底始终与地面保持恰当的接触关系。

如图 2.14 所示，本文展示了该接口处理高难度影视动作的能力。系统成功从电影片段中提取了复杂的舞蹈动作，并将其重定向至实际可执行的机器人动作，证明了该框架在处理非结构化视频数据时的鲁棒性与泛化能力。




图 2.14 基于 WHAM 的非训练样本视频动作重定向效果展示（以《蜘蛛侠》为例）。

Figure 2.14 Demonstration of in-the-wild video motion retargeting based on WHAM

2.4 本章小结

本章针对人形机器人运动重定向任务中存在的异构映射困难、人工配置繁琐以及泛化能力不足等问题，提出并验证了一套通用的自适应重定向框架。

首先，本章基于流形假设，设计了以 Transformer Encoder 为核心的轻量级回归网络，结合可微正运动学与多重物理约束损失函数，实现了从人体动作空间到机器人关节空间的端到端非线性映射。其次，为了克服人体与不同构型机器人之间的几何尺寸差异，提出了基于多姿态联合优化的形态学参数自适应匹配算法。该算法无需修改 URDF 文件即可自动建立精确的运动学对应关系，显著提升了方法的通用性。在工程实现层面，本章构建了包含多级时域滤波、接触相位推断及对称增强的完整后处理流水线，有效解决了动作捕捉数据的噪声与稀疏性问题，确保了生成动作的物理可行

性。此外，通过集成 WHAM 与 DPVO 算法，本章进一步将数据来源从实验室动作捕捉扩展至非训练样本单目视频，实现了对非结构化视频数据的“零样本”迁移。

实验结果表明，该框架在 Unitree H1-2、Fourier GR1 等多种主流人形机器人上均实现了高精度的姿态追踪与实时的推理速度，综合性能优于现有的 SOTA 方法。综上所述，本章所构建的高效、高保真数据生成流水线，为后续章节基于强化学习的动力学控制策略研究提供了高质量、大规模的专家演示数据支持。

第3章 兼容动作模仿和自适应运动的机器人控制策略设计

3.1 问题分析

本文在上一章中建立了一套高效的动作捕捉数据重定向流水线,获取了大量适配于目标机器人构型的专家演示数据。然而,数据的准备仅仅是第一步,实现仿人运动的核心挑战在于如何设计合理的控制策略,并在物理仿真环境中训练智能体 (Agent),使其既能精确跟踪这些参考动作,还能深入掌握人类运动背后的动力学逻辑并推广到相似运动中。更关键的是,研究中期望智能体具备在参考动作不可用(如数据中断)或不适用(如环境突变)时,能够平滑过渡到基于速度指令的自主控制模式,实现“模仿”与“探索”的有机统一。

“工欲善其事,必先利其器。”在设计策略阶段,选择合理有效的基础控制策略十分重要。鉴于强化学习 (RL) 在机器人控制领域的杰出表现,研究首先调研以 RL 为主的控制策略在该领域中的应用。在基于物理的动作模仿领域,以 PPO 为代表的深度强化学习算法通常采用多层感知机 (Multi Layer Perceptron, MLP) 作为策略网络的骨干。经典工作如 AMP^[28] 和 Perpetual Humanoid Control (PHC)^[59] 均证明了 MLP 在处理单一或少量动作模仿任务时的有效性。然而,这些方法通常将参考动作 (Reference Motion) 作为策略网络的观测量 (Observation) 显式输入强制添加。这种设计在处理理想数据时表现优异,但在实际应用中面临两个主要局限:

首先,传统 MLP 对参考数据的存在性与数据质量高度敏感。考虑到上一章所述的重定向流程侧重于计算效率,转换后的动作可能并未经过严格的物理仿真修正,因此与当前环境下的机器人真实动力学存在一定的域差异。传统的 MLP 缺乏自适应调整参考权重的机制,容易在强行拟合偏差数据时导致策略崩溃。此外,当参考输入消失(例如需要切换到速度指令控制)时,这种强耦合结构往往难以高效适应,导致控制失效。

其次,简单 MLP 在多动作泛化上存在固有瓶颈。虽然 MLP 推理效率高,但其固定的网络拓扑难以在单个策略网络中同时编码多种风格迥异的动作(如行走、蹲伏、跳跃)。前期实验表明,随着参考动作库的扩充,简单的全连接网络难以建立当前观测与高维参考动作之间复杂的非线性映射关系,极易导致多动作学习时的相互干扰与灾难性遗忘。

为了提升网络的时序建模能力,部分研究提出引入循环神经网络 RNN^[60]。虽然

RNN 利用历史记忆在一定程度上缓解了状态估计的不确定性，但其隐状态的更新机制主要侧重于时序连续性，在捕捉“当前观测”与“目标参考”之间的结构化空间关系上依然乏力。另一方面，一些基于序列建模的方法，如 Decision Transformer^[61] 等在离线 RL 中取得了进展，但在 PPO 这种等追求极高吞吐量和多并行仿真环境的算法中，将堆叠观测重构为符合 Seq2Seq 要求的长序列输入会带来巨大的显存与带宽开销。如果对序列进行压缩，则难以直接捕捉帧级别的精细动力学特征。

针对上述挑战，本章旨在探索一种能够兼顾鲁棒追踪与多动作泛化的网络架构设计。为了解决现有 MLP 在处理数据切换和偏差数据时的不足，本研究首先基于 MLP 架构进行了针对性改良，提出了一种基于时序特征融合的 **Fused Multi-Modal MLP**。该模型引入了轻量级的时序卷积编码器与主-客体门控融合机制，作为本研究的基线，有效解决了数据偏差下的追踪稳定性问题。在此基础上，为了进一步突破 MLP 在多动作表征上的瓶颈，本研究设计了 **Motion Mimic Transformer (MMTransformer)** 骨干网络（如图 3.1 所示）。该架构将机器人观测与参考动作视为不同的模态的 Token，利用 Self-Attention 机制动态建模身体部位之间、时序特征之间的关联，从而实现了单一策略对大规模复杂动作库的高保真模仿与在线切换。




图 3.1 MMTransformer 骨干网络框架图

Figure 3.1 Architecture for Motion Mimic Transformer

在此基础上，为了让模型更好地学习复杂的动作表征，本章引入了一个两阶段的在线强化学习训练策略，并引入了简化物理环境的预训练模式和复杂物理环境的半监督训练模式，使得模型能够快速收敛，并强化其对于有干扰数据的适应能力。

3.2 基于时序特征融合的策略基线网络

为了在对比实验中公平地评估 MMTransformer 的性能优势，实验中需要构建一个具备竞争力的 MLP 基线。针对传统 MLP 在处理高维时序数据和参考信号缺失时的固有缺陷，本章设计了 Fused Multi-Modal MLP。本节首先定义贯穿本章的符号体系，随后详细阐述该基线网络的时序编码与门控融合机制。

3.2.1 符号定义

在 Fused MLP 架构中，网络模型采用如表 3.1 所示的符号定义。

表 3.1 MLP 网络使用的主要数学符号定义
Table 3.1 Mathematical Notations Used in MLP

符号 (Symbol)	定义 (Definition)
$s_t \in \mathbb{R}^{n_{obs}}$	t 时刻机器人的本体观测，包含关节状态、IMU 数据等
$\hat{s}_t \in \mathbb{R}^{n_{ref_obs}}$	t 时刻专家的参考观测，包含期望的姿态、速度等
$b_{env} \in \{0, 1\}$	环境掩码，指示参考观测 $\hat{s}_t$ 在当前环境中是否可用 (1: 可用, 0: 缺失)
H	时序数据的历史窗口长度
$\mathcal{X}^{(k)}$	观测向量中的第 k 个物理特征组，如“基线速度”
$\mathbf{h}_s, \mathbf{h}_{\hat{s}}$	分别由本体网络和参考网络提取的高维隐空间特征
$\mathbf{g} \in [0, 1]^{D_{model}}$	用于融合不同模态特征的门控系数向量

而在 MMTransformer 架构中，网络模型则采用如下的符号定义：

表 3.2 Transformer 网络使用的主要数学符号定义
Table 3.2 Mathematical Notations Used in Transformer

符号 (Symbol)	定义 (Definition)
$s_t \in \mathbb{R}^{n_{obs}}$	t 时刻机器人的本体观测，包含关节状态、IMU 数据等
$\hat{s}_t \in \mathbb{R}^{n_{ref_obs}}$	t 时刻专家的参考观测，包含期望的姿态、速度等
$b_{env} \in \{0, 1\}$	环境掩码，指示参考观测 $\hat{s}_t$ 在当前环境中是否可用 (1: 可用, 0: 缺失)
$L = l_{history}$	时序数据的历史窗口长度
$n = n_{tokens}/n_{groups}$	嵌入层对特征向量的分类数量
$x_i, i \in [1, n]$	观测向量中的第 i 个物理特征组，由不同嵌入方式分类
E_i	对应 i 位的嵌入后向量
$\mathbf{h}_s, \mathbf{h}_{\hat{s}}$	分别由本体网络和参考网络提取的高维隐空间特征
$\mathbf{g} \in [0, 1]^{d_{model}}$	用于融合不同模态特征的门控系数向量
d_{in}	主网络数据的输入维度
d_{model}	主网络的隐藏层维度

3.2.2 轻量级时序特征编码器

在 Isaac Lab 等物理仿真环境中，环境观测通常被展平为一维向量。对于包含历史信息 H 的观测，直接的全连接层处理会导致参数量随 H 线性增长从而极大增加复杂度，且难以捕捉局部的时间相关性。为此，本研究在 Fused MLP 中引入了 Temporal Feature Encoder，该结构与后续 Transformer 中的 Embedding 层设计理念一脉相承，但采用了更符合 MLP 输入单维度特征的卷积实现，其结构如下：

对于本体观测 s_t （或参考观测 $\hat{s}_t$ ），模型首先根据物理语义^①将其解耦为 K 个独立的特征组 $\{X^{(1)}, X^{(2)}, \dots, X^{(K)}\}$ 。对于每一个包含时序信息的特征组 $X^{(k)}$ ，其原始维度为 $B \times (H \cdot D_k)$ ，其中 H 为序列时间长度， D_k 为对应时间步的特征维度。网络需要将其重塑为 $B \times D_k \times H$ 的时序张量，并执行以下编码操作：

1. **降维投影 (Latent Projection)**: 若特征维度 D_k 超过预设阈值（如 32），先通过线性层将其投影至低维空间，以去除冗余信息。
2. **时序卷积 (Temporal Convolution)**: 利用一维卷积网络 (Conv1D) 沿时间轴 H 提取高频动态特征（如速度的变化率、接触的瞬时状态）。
3. **自适应池化 (Adaptive Pooling)**: 通过池化层将变长的时间特征压缩为固定长度的特征向量。

该过程可形式化表示为：

$$\mathbf{z}^{(k)} = \text{Pool}(\sigma(\text{Conv1D}(\text{Linear}(X^{(k)})))), \quad (3.1)$$

其中 σ 为 ELU 激活函数。所有特征组的编码输出最终被拼接为总特征向量，分别记为 $\tilde{s}_t$ （处理后的本体观测）和 $\tilde{\hat{s}}_t$ （处理后的参考观测）。这种设计在大幅降低参数数量的同时，保留了关键的动力学时序特征。

3.2.3 专家-策略特征的门控融合机制

在模仿学习中，智能体需要平衡“保持自身平衡”与“跟随参考动作”这两个目标。传统的 MLP 直接将 s_t 与 $\hat{s}_t$ 拼接输入网络，这种强耦合结构使得网络难以区分信息的来源。当参考数据 $\hat{s}_t$ 因重定向偏差出现物理不可行，或在实际部署中信号丢失（即 $b_{env} = 0$ ）时，传统 MLP 往往因无法解耦而导致策略崩溃。

为了解决这一问题，本研究在 Fused MLP 中设计了门控融合机制。该机制包含两个独立的特征提取流：

^① 这里的语义信息是手动给定的。

- **主网络 (Temporal Encoder):** $f_{main}(s_t) \rightarrow \mathbf{h}_s$ 。仅接收本体特征，负责提取当前机器人的动力学状态，确保基础运动能力。
- **参考网络 (Ref Encoder):** $f_{ref}(\hat{s}_t) \rightarrow \mathbf{h}_{\hat{s}}$ 。仅接收参考特征，负责提取期望的运动意图。

两个网络的输出并非直接相加，而是通过一个可学习的门控网络进行动态加权。门控系数 $\mathbf{g}$ 由拼接后的特征计算得出：

$$\mathbf{g} = \text{Sigmoid}(\mathbf{W}_g [\mathbf{h}_s, \mathbf{h}_{\hat{s}}] + \mathbf{b}_g), \quad (3.2)$$

最终的融合特征 $\mathbf{h}_{fused}$ 计算如下：

$$\mathbf{h}_{fused} = (1 - \mathbf{g}) \odot \mathbf{h}_s + \mathbf{g} \odot (\mathbf{h}_{\hat{s}} \cdot b_{env}), \quad (3.3)$$

其中 $\odot$ 表示逐元素乘法。同时，本研究在公式中引入了环境掩码 b_{env} ，其定义为：

- 当参考可用 ($b_{env} = 1$) 且质量较高时，网络会自适应增大 $\mathbf{g}$ ，引导机器人跟随专家动作；
- 当参考缺失 ($b_{env} = 0$) 或物理不可行时，参考特征被掩码置零，且网络会自动减小 $\mathbf{g}$ ，使策略平滑退化为仅依赖 $\mathbf{h}_s$ 的本体控制模式。

网络的整体结构如图3.2所示，这一基线模型虽然仍基于 MLP 架构，但其显式的时序建模与门控解耦设计，已初步解决了数据偏差与模态缺失的问题，为后续引入更强大的 Transformer 架构提供了坚实的比较基准。




图 3.2 Fused MLP 基线网络框架图
Figure 3.2 Architecture for Baseline Fused MLP

3.3 针对时空特征的 MMTransformer 策略网络

尽管上一节提出的 Fused MLP 通过门控机制缓解了数据偏差问题，但 MLP 本质上是一种扁平化的特征处理方式，其固定的网络拓扑限制了特征交互的灵活性。这使得在处理包含多种运动策略（如混合行走、奔跑、跳跃）的任务时，MLP 难以在单一策略中同时编码多种动作的非线性映射关系，往往出现“灾难性遗忘”或平均化效应。

为了突破这些瓶颈，本节提出 MMTransformer 网络架构。该架构采用类似 BERT^[62] 的 **Encoder-Only** 结构，其核心思想是将本体观测 s_t 与参考观测 $\hat{s}_t$ 视为两种独立的模态，利用自注意力机制动态建模两者之间的空间关联。

3.3.1 自适应序列化嵌入与 SwiGLU 投影

Transformer 需要时序化，通常作为 Token 的输入，而已有的特征信息本身维度差异大，直接作为 Token 参与运算会由于归一化程度不同导致训练困难。因此，为了满足 Transformer 对序列化输入的硬性要求，同时保留物理数据的语义结构，本节设计了一套自适应的嵌入层（Embedding），如图 3.3 所示。




图 3.3 MMTransformer 的嵌入层设计细节
Figure 3.3 Embedding layers for MMTransformer.

其中，针对不同维度的观测数据，本研究采用了分层处理策略：

- **低维投影**：当观测量或参考量类别较少，不足以构成具有统计意义的长序列时，本研究采用线性投影策略。将维度为 d_{in} 的原始向量通过线性层映射为 $L \times d_{model}$ 的特征向量，随后 Reshape 为 (n_{token}, d_{model}) 的序列。
- **语义分组嵌入 (对应 Observation Embedding V2)**：当观测量维度较高且物理含义明确时，本研究将观测向量按物理属性拆分为多个特征组（如基座状态组、关节位置组等）。为了增强每个特征组内部的非线性表达能力，本研究引入了 LLaMA^[63] 中使用的 SwiGLU (Swish Gated Linear Unit) 激活函数。对于每一个观测组 $\mathbf{x}_i$ ，其 Token 嵌入 $\mathbf{E}_i$ 计算如下：

$$\mathbf{E}_i = \mathbf{W}_2(\text{Swish}(\mathbf{W}_1\mathbf{x}_i) \odot (\mathbf{W}_3\mathbf{x}_i)), \quad (3.4)$$

这些经过 SwiGLU 增强的特征向量最终被拼接形成长度为 N_{terms} 的语义序列。与 MLP 基线一致的是，这里的参考观测 $\hat{s}_t$ 的 Embedding 层结构与本体观测完全相同，但两个模块参数独立。

为了优化显存占用，当训练或推理阶段不涉及参考输入（即 $\hat{s}_t$ 为 None）时，参考输入对应的 Embedding 层将不会被实例化。此外，为了保留输入特征的位置信息，本研究在 Token 序列中叠加了可学习的位置编码 (Positional Embeddings)，从而增强网络特征表达能力。

3.3.2 注意力掩码与动态推理机制

通过前文的模块转换后的本体 Token 序列与参考 Token 序列通过特殊的 [SEP] 分隔符拼接，并在序列首部添加 [CLS] 标志位，用于聚合全局信息并捕捉模态间的关联。

为了处理强化学习环境中参考数据动态可用的特性，本研究引入了基于环境的二值掩码机制，其与上一节的 0-1 掩码类似，但其维度和 Transformer 的输入需求进行了对齐。对于批量中的每个环境 i ，定义二值变量 $b_{env}^{(i)} \in \{0, 1\}$ 表示参考数据是否可用。本研究首先生成一个长度为 L_{ref} 的全 1 序列，将其与 $(1 - b_{env}^{(i)})$ 相乘，从而得到用于 Transformer 注意力计算的 key_padding_mask。

- 当 $b_{env}^{(i)} = 1$ （参考可用）时，Mask 为 0，允许注意力机制关注参考 Token；
- 当 $b_{env}^{(i)} = 0$ （参考不可用）时，Mask 为 1，屏蔽所有参考 Token 的注意力计算。

特别地，当整个系统的参考输入为 None 时，对应参考部分的 Mask 被显式置为全屏蔽状态。此时，Transformer 自适应退化为仅处理本体观测的策略网络，其运算逻辑与传统的 Actor-Critic 完全一致。这种设计赋予了 MMTransformer 在“模仿学习”

与“自适应运动”之间无缝切换的能力。

3.3.3 网络输出与超参数配置

在多层 Transformer Encoder 处理后, [CLS] Token 的特征向量被提取并送入投影头 (Projection Head, 如图 3.1 右侧所示)。对于 Actor 网络, 该向量通过线性层投影为动作分布的均值 $\mu \in \mathbb{R}^{N_{dof}}$; 对于 Critic 网络, 则直接投影为标量值 $V \in \mathbb{R}^1$ 。

在实际网络实现中, 为了在特征表达能力与计算开销之间取得平衡, 本研究进行了如下配置: 网络深度通常为 2-4 层, 模型维度 d_{model} 设为 64-128, 注意力头数设为 4-8, 前馈网络 (FFN) 扩张比例为 4。当 $d_{model} = 64$ 且层数为 4 时, 其参数量与经典的 [512, 256, 128] MLP 相当, 但在多模态特征捕捉能力上具有显著优势。此外, 网络采用 GELU 激活函数, 并在输入端通过 RMSNorm (Root Mean Square Normalization)^[64] 对嵌入向量进行正则化, 有效消除了不同物理量纲 (如位置与速度) 数值差异导致的训练不稳定性。实验表明, 该构型在相同计算预算下, 展现出了比 MLP 更强大的泛化性能与收敛速度。

3.3.4 两阶段模仿-强化学习策略 (Agger-MMPPPO) 训练架构

尽管网络骨干的增强能够显著提升模型对复杂动作的学习容量, 但将参考动作映射为机器人可执行的动作指令依旧困难。智能体必须从复杂的数据流——包括关节角度、重力向量、执行器参考速度以及各连杆的位置与速度——中辨识出潜在的运动模式, 将这些信息与其自身的观测 s_t 建立关联, 从而在物理环境中生成恰当的响应。与直接遥操作 (Teleoperation) 不同, 这一过程更类似于将类人的运动模式“复制”到机器人上, 本研究将此过程定义为针对全身运动的行为克隆 (Behavior Cloning)。

由于人和机器人的动力学特征差异大, 直接应用专家数据集中的原始动作通常是不可行的; 例如, 参考人类 MoCap 数据可以通过肌肉控制实现很精妙的平衡, 但是机器人的执行器很有限, 难以复刻如此复杂的动作特征。为了解决这一问题, 本文采用在线 (On-policy) 强化学习算法, 使智能体能够通过与环境的直接交互来修正并精细化其行为。而在 On-policy 算法中, 由于 PPO 算法因其在连续控制任务中具有极好的稳定性, 通常作为机器人控制的基础策略, 因此本文同样采用这一结构。

本节将机器人的行为克隆任务形式化为一个马尔可夫决策过程 (Markov Decision Process, MDP), 由元组 $(\mathcal{S}, \hat{\mathcal{S}}, \mathcal{A}, R, \hat{R}, \mathcal{T}, \gamma)$ 表示。其中:

- $\mathcal{S}$ 代表智能体的状态空间;
- $\hat{\mathcal{S}}$ 是源自专家数据的参考状态空间。对于处于状态 $s_t \in \mathcal{S}$ 的智能体, 其对应的




图 3.4 DAGger-MMPPO 算法架构示意图

Figure 3.4 Diagram for DAGger-MMPPO algorithm

专家参考状态 $\hat{s}_t \in \hat{\mathcal{S}}$ 从专家数据集中检索获得（通常基于时间索引或状态匹配）；

- $\mathcal{A}$ 为智能体的动作空间；
- $R(s_t, a_t, s_{t+1})$ 表示内在的任务奖励函数（Task Reward）；
- $\hat{R}((s_t, \hat{s}_t), a_t, (s_{t+1}, \hat{s}_{t+1}))$ 代表用于行为克隆的模仿奖励（Imitation Reward）；
- $\mathcal{T}(s_{t+1}|s_t, a_t)$ 是状态转移概率分布；
- $\gamma \in [0, 1)$ 是未来奖励的折扣因子。

本研究的目标是利用智能体的观测 $o_t = O(s_t)$ 以及对应的参考观测 $\hat{o}_t = O(\hat{s}_t)$ 来训练策略 π 。策略定义如下：

$$a_t = \begin{cases} \pi(o_t, \hat{o}_t) & \text{if } \hat{o}_t \neq \text{None}, \\ \pi(o_t) & \text{if } \hat{o}_t = \text{None}. \end{cases} \quad (3.5)$$

该策略通过最大化结合了任务奖励 R 和模仿奖励 $\hat{R}$ 的混合目标函数进行优化。

然而，尽管 PPO 允许智能体通过物理交互持续优化策略，但在智能体的初始策略分布 π_0 、任务奖励的最优策略 $\bar{\pi}_R$ 以及模仿奖励的最优策略 $\bar{\pi}_{\hat{R}}$ 之间往往存在显著

的分布差异。对于主要依赖信赖域方法进行优化的 PPO 而言, 受到探索步长和邻域限制, 寻找一个能同时满足这些潜在冲突目标的全局最优解极具挑战性。对于 PPO, 每个目标的次优解可能位于策略空间中完全不同的区域, 而沿着当前最速下降方向引导优化的信赖域可能无法覆盖通向真实最优解的路径。

针对上述问题, 本节提出了 **DAgger-MMPPPO** 算法, 这是一个融合了数据集聚合 (Data Aggeration, DAgger) 思想与 PPO 训练逻辑的两阶段训练框架。

算法 3.1 第一阶段: DAgger 策略预训练

算法 3.1 Stage I: DAgger policy pretraining

Require: 专家数据 $\mathcal{D}_{\text{exp}}$ (提供 $\hat{\mathcal{S}}$); 初始参数 θ_0, μ_0 ; 观测函数 $O(\cdot)$;

1: 权重 $w_R, w_{\hat{R}}$ (且 $w_R \ll w_{\hat{R}}$); 超参数: N_{iter}, K, M, B 等.

2: 初始化 $\pi_\theta \leftarrow \theta_0, V_\mu \leftarrow \mu_0$;

3: 配置简化物理环境 (固定基座, 仅优化 $\hat{R}$). **for** 迭代次数 $n \leftarrow 0$ **to** $N_{\text{iter}} - 1$ **do**

4:

 使用 π_θ 采集样本集 $\mathcal{B} = \{(s_t, a_t, R_t^{\text{task}}, \hat{s}_t, s_{t+1}, \hat{s}_{t+1}, d_t)\}$.

5: 从 $\mathcal{B}$ 构建训练集 $\mathcal{B}_{\text{learn}}$:

 对每个转移样本, 执行替换:

$s'_t \leftarrow (\hat{s}_t^{\text{base}}, s_t^{\text{joint}}), s'_{t+1} \leftarrow (\hat{s}_{t+1}^{\text{base}}, s_{t+1}^{\text{joint}})$.

 计算模仿奖励 $\hat{R}_t \leftarrow \hat{R}(s'_t, \hat{s}_t, a_t, s'_{t+1}, \hat{s}_{t+1})$ 及任务奖励 R_t^{task} .

 计算有效奖励 $r_t \leftarrow w_R R_t^{\text{task}} + w_{\hat{R}} \hat{R}_t$.

6: 计算优势函数 A_t 并更新 $\mathcal{B}_{\text{learn}}$. **for** 轮次 $k \leftarrow 0$ **to** $K - 1$ **do**

 PPO 更新

7: 使用 $\mathcal{B}_{\text{learn}}$ 中的 M 个小批量数据优化 θ, μ .

8:

9:

10: **return** DAgger 预训练策略 $\pi_D \leftarrow \pi_\theta$.

第一阶段: DAgger 策略预训练 此阶段的首要目标是学习一个行为先验, 使其在暂时忽略复杂动力学平衡约束的前提下, 能够出色地完成纯动作模仿。本研究通过在简化的物理环境中训练一个逼近专家策略 $\bar{\pi}_{\hat{R}}$ 的初始策略来实现这一目标 (详见算法 3.1)。这个学习到的策略具有双重协同作用:

1. 首先, 它为第二阶段的全物理 PPO 探索提供了一个高质量的起点, 引导优化过程从 $\bar{\pi}_{\hat{R}}$ 的邻域出发, 向着与任务策略 $\bar{\pi}_R$ 的平衡点收敛, 从而有效缓解策略退化。
2. 其次, 它通过将状态到动作的映射内嵌于 Actor 网络中, 充当了一个高效的自动标注器, 从而避免在后续训练中进行计算昂贵的最近邻搜索或数据集查找。

为了实现这种两阶段的训练方案，本文将智能体的状态 s_t 划分为基座状态和关节状态： $s_t = (s_t^{\text{base}}, s_t^{\text{joint}})$ 。其核心策略是**解耦关节协调学习与基座控制学习**。在阶段一中，本文实施的对应环境简化包括：固定机器人的基座连杆，禁用所有物理地面交互，并将基础任务奖励 R 最小化，使优化过程完全偏向模仿奖励 $\hat{R}$ 。

在训练过程中，本研究利用取代策略来进一步隔离关节学习问题，其方案如下：在收集完轨迹后，模型将智能体观测到的基座状态 s_t^{base} 替换为专家的参考基座状态 $\hat{s}_t^{\text{base}}$ 作为策略输入。这种替换有效地模拟了一个被完美控制的基座的物理特性，迫使智能体专注于调整其关节状态 s_t^{joint} 以最大化 $\hat{R}$ 。该方法强制第一阶段的策略学习从可被修改的状态 s_t 到类专家动作 $\hat{a}_t$ 的直接回归，从而构建了后续训练阶段的基础运动先验。这一模式在图 3.4 的上半部分进行了展示。

算法 3.2 第二阶段：基于 DAgger 的策略迁移训练

算法 3.2 Stage II, Policy transfer based on DAgger algorithm

Require: DAgger 策略 π_D ; LoRA 参数 ψ_0 ; 优化器; 专家状态 $\hat{\mathcal{S}}$, 观测函数 $O(\cdot)$;

- 1: 模仿权重 w_{im} ; DAgger 因子 ρ (随时间衰减); PPO 超参数 $(\gamma, \lambda, N_{\text{iter}}, K, M, B, \epsilon_{\text{clip}})$.
 - 2: 初始化 Actor $\pi_\theta \leftarrow \pi_D$, Critic $V_\mu \leftarrow \mu_0$. 初始化 DAgger 网络 π_{Dagg} (冻结 π_D , LoRA $\psi \leftarrow \psi_0$).
 - 3: 配置全物理环境; 定义任务奖励 $\bar{R}_t = (R_t, \hat{R}_t)$.
for 迭代次数 $n \leftarrow 0$ **to** $N_{\text{iter}} - 1$ **do**
 - 4: 使用 $\pi_\theta(o_t, \hat{o}_t)$ 在奖励 $\bar{R}_t$ 下采集样本集 $\mathcal{B}$.
 - 5: 利用 $\bar{R}_t, V_\mu(o_t, \hat{o}_t)$ 和 $\text{GAE}(\gamma, \lambda)$ 计算优势函数 A_t . **for** 轮次 $k \leftarrow 0$ **to** $K - 1$ **do**
 DAgger-MMPPO 更新 **for** 随机抽取小批量数据 $\mathcal{B}_{\text{mini}}$ **do**
 - 6: 计算 Actor π_θ 的 $L^{\text{CLIP}}(\theta)$.
 - 7: 生成参考动作 $\hat{a}_m^{\text{Dagg}} \leftarrow \pi_{\text{Dagg}}(o, \hat{o})$.
 - 8: 利用 $\hat{a}_m^{\text{Dagg}}$ 计算 $L^{\text{KL}}(\theta)$. ▷ (公式 3.6)
 - 9: 更新总损失 $L^{\text{CLIP}}(\theta) \leftarrow L^{\text{CLIP}}(\theta) + w_{\text{im}} L^{\text{KL}}(\theta)$.
 - 10: 计算 Critic V_μ 的 $L^{\text{VF}}(\mu)$.
 - 11: 使用 $\nabla_\theta L^{\text{CLIP}}(\theta)$ 更新 Actor; 使用 $\nabla_\mu L^{\text{VF}}(\mu)$ 更新 Critic.
 - 12: 计算 $L_\psi^{\text{DAgger}}(a_m^{\text{Actor}}, \hat{a}_m^{\text{Dagg}}, \rho)$. ▷ (公式 3.7)
 - 13: 使用 $\nabla_\psi L_{\text{DAgger}}(\psi)$ 更新 LoRA 参数.
 - 14:
 - 15:
 - 16: 衰减 ρ .
 - 17:
 - 18: **return** 训练完成的策略 π_θ .
-

第二阶段：基于 DAgger 的策略迁移训练 尽管第一阶段的策略 π_D 在动作模仿上表现熟练，但其学习到的**动力学先验**是以简化的物理环境为条件的，因此无法直接

部署在全物理仿真中。为解决这一问题，第二阶段将这一专家先验适配到任务最优策略 $\bar{\pi}_R$ ，使其对复杂的物理交互具有鲁棒性。为了更好地实现这一目标，算法在 PPO 基础上增强了一个类 DAgger 的监督组件。这一过程可以被视为**教师-学生蒸馏 (Teacher-Student Distillation)**^[65-67] 的一种复杂变体，其中教师提供强大但不完美的控制先验，而学生学习如何在更复杂的现实中使该先验变得可行。这构成了本研究的 DAgger-MMPPO 核心训练框架（见图 3.4 下半部分及算法 3.2）。

在该阶段，模型基于先验 π_D 实例化了两个网络，分别对应“教师”和“学生”的职能：

- **DAgger 网络充当“教师”**：它体现了在简化环境中学到的动力学先验。其提供的专家控制动作在其理想化的世界中非常有效，但并未考虑现实世界的复杂性（如动态平衡或地面的反作用力、不同地形的影响等）。
- **主 Actor 网络充当“学生”**：其目标是通过 PPO 学习一个真实物理可行的策略。它将教师的建议动作作为具有梯度信号的参考（这一点区别于 RL 的观测量输入），但通过奖励强迫其学会对教师输出进行调整，以在全动力学环境中取得成功。

为了确保随着学生的探索，教师的指导仍然保持指导作用，本研究采用**低秩自适应 (Low-Rank Adaptation, LoRA)**^[68] 技术，根据学生的交互数据对教师网络进行微调。这创造了一个共生的学习过程：学生（Actor 动作 a_t ）学习将教师的理想化策略“落地”到现实中，而教师（DAgger 预测 $\hat{a}_t$ ）则同时被修正，提供越来越切合实际的指导。

对于 Actor 的优化，本研究考虑其策略 π_θ 与 DAgger 网络输出 π_D 之间的差异。直接计算 KL 散度比较耗时，因为 π_D 也需要从分布中采样。受该工作^[69] 中模仿损失设计的启发，则将 DAgger 网络的输出动作 $\hat{a}_t$ 视为狄拉克 δ 分布的均值。该 $\hat{a}_t$ 作为一个常数目标（在 Actor 优化期间不对 DAgger 网络反向传播梯度）。Actor 的模仿损失定义为这些目标动作在其策略 $\pi_\theta(\cdot|s_i)$ 下的负对数似然：

$$\begin{aligned} L_{\text{KL}}(\pi_\theta | \hat{\pi}_\theta) &= \mathbb{E}_{s_t \sim \mathcal{D}} [-\log \pi_\theta(\hat{a}_t | s_t)], \\ &\approx \frac{1}{N} \sum_{i=1}^N \left[\log \left(\sqrt{2\pi} \sigma_\theta(s_i) \right) + \frac{(\hat{a}_i - \mu_\theta(s_i))^2}{2\sigma_\theta(s_i)^2} \right], \end{aligned} \quad (3.6)$$

其中 $\hat{a}_i = \text{DAgger}(s_i)$ ， $\mu_\theta(s_i)$, $\sigma_\theta(s_i)$ 是 Actor 高斯策略的输出。期望是在一批 N 个状态上计算的。

对于 DAgger 网络的 LoRA 微调，引入了一个超参数 $\rho \in [\rho_{\min}, \rho_{\max}] \subset [0, 1]$ ，随

迭代进行退火。该 ρ 用于平衡 DAgger 网络的自洽性与其对 Actor 的适应性。DAgger 网络（输出 $\hat{a}_t^{\text{Dagg}}$ ）受到 Actor 动作 a_t^{Actor} 的引导。DAgger 损失主要定义为：

$$L_{\text{DAgger}}(\hat{a}_t^{\text{Dagg}}, a_t^{\text{Actor}}, \rho) = (1 - \rho) \|\hat{a}_t^{\text{Dagg}} - a_t^{\text{Actor}}\|_2^2, \quad (3.7)$$

该损失将 DAgger 网络的输出 $\hat{a}_t^{\text{Dagg}}$ 与 Actor 的 a_t^{Actor} 对齐。对齐强度由 $(1 - \rho)$ 缩放；随着 ρ 减小，向 Actor 策略靠拢的拉力增大。为了确保稳定性并防止 DAgger 网络过度受 Actor 影响（例如 Actor 早期探索时的噪声），其 LoRA 更新受到类似于 GAN 梯度惩罚的隐式正则化约束，作为梯度裁剪等显式措施的补充。因此，在低 ρ 值下，当 DAgger 网络的输出 $\hat{a}_t^{\text{Dagg}}$ 紧密匹配 a_t^{Actor} （最小化上述 L_{DAgger} 项）且网络满足这些稳定性标准（例如相关的惩罚梯度较小）时，其总体目标被认为已最小化。

3.4 训练平台与环境设计

为了实现与现代机器人强化学习生态系统的无缝集成，本研究采用 Isaac Lab 作为基础训练平台。相较于已被 NVIDIA 弃用的 Isaac Gym，Isaac Lab 采用了基于管理器（Manager-Based）的软件架构，将基础训练环境、物理仿真以及数据管理等核心功能封装为标准化的接口。这一架构极大地简化了不同机器人构型的适配流程。本节将详细阐述算法框架（以下简称 GBC）的基础系统设计、课程学习（Curriculum Learning）^[70] 与模仿奖励函数的设计，以及针对模仿训练实施的特定优化策略。

3.4.1 强化学习平台架构

Isaac Lab 具有解耦且封装良好的强化学习环境架构，这使得本研究可以通过继承其基础环境类来集成大部分功能。图 3.5 展示了本研究在现有框架中引入的自定义管理器及其继承关系。

为了实现参考数据集的高效加载与访问，本研究实现了 **RefDataBuffer** 类，负责将转换后的机器人参考动作数据集缓存至 GPU。该类维护一个驻留于 GPU 的缓冲区，存储独立的动作序列并管理每个强化学习环境对应的索引。它根据当前 RL 环境的时间步计算相应的参考数据索引，并支持循环数据索引，从而在保持低显存占用的同时实现高效检索。由于缓存的数据主要由微分量（如速度、加速度）组成，该类还实现了高效的在线积分算法以推导绝对状态，并利用 CUDA 线程 Warp-level Primitives 进行加速。这一设计确保了直接数据检索的查询复杂度为 $O(1)$ 。此外，获取绝对状态的积分过程通过利用缓存机制和局部（如相邻点）查找，通常也保持 $O(1)$ 的复杂度。




图 3.5 GBC 平台与 Isaac Lab 环境的继承关系

Figure 3.5 GBC platform relationship with Isaac Lab Environments.

仅在极少数最坏情况下（如环境重置需要从序列起始处重新积分），操作复杂度退化为 $O(N)$ ，不过该部分计算也通过 CUDA 算子进行并行执行优化。

类比于 Isaac Lab 标准的 Observation Manager，研究中实现了 **Reference Observation Manager**，专门用于管理参考状态 $\hat{s}_t$ 的查询与更新。该管理器在每个仿真步开始时被调用，刷新当前时间步的参考状态缓冲区，确保存储组件（如 Reference Buffer 和奖励函数）的访问延迟为 $O(1)$ 。此外，该管理器根据当前上下文中参考数据的存在性或可访问性，动态维护参考观测 $\hat{o}_t$ 及其对应的可用性掩码。用户可以通过指定数据集中的 term_name 加载所需的参考数据。管理器会根据这些项的物理属性（如与空间角度相关的角速度，或与位置相关的坐标及线速度），自动处理数据增强时的对称变换。本研究还允许用户选择性地配置每一项是否作为参考观测 $\hat{o}_t$ 的一部分输入给网络；未被指定为观测的项对 PPO 网络不可见，但仍可用于奖励计算。

为了确保可用参考信息与训练期间的动作指令保持一致，本研究重写了默认的 Command Manager。当当前环境存在可用的参考状态数据时，自定义的 Command Manager 会使用源自参考动作 $\hat{s}_t$ 的目标速度替换默认的随机指令生成（如目标线速度 v_x, v_y 和角速度 ω_z ）。这一修改旨在辅助智能体在训练过程中学习从参考速度到期望动作的映射关系。

该框架支持将现有的 Isaac Lab 训练任务快速扩展为模仿学习场景。用户可以继承环境的基线观测定义和物理描述，随后通过本研究提供的模仿学习库集成特定的配置——如参考状态规范、模仿奖励函数、AMP 网络以及对称设置，从而极大地简

化了新模仿学习实验的搭建流程。

3.4.2 课程学习与模仿奖励设计

直接模仿精确的关节构型和末端位置极具挑战性，容易导致初始探索阶段的奖励稀疏，从而阻碍收敛速度并削弱模仿动机。因此，本研究采用课程学习策略，使智能体从简单场景开始探索，随着模仿熟练度的提高逐步增加训练难度。为此，本研究设计了两种基于奖励函数调节和环境修正的课程：**标准方差课程 (Standard-variation Curriculum)** 和 **“幼儿学步”课程 (Toddler Curriculum)**，分别通过奖励塑形和交互式辅助实现分阶段学习。

3.4.2.1 标准方差课程 (Standard-variation Curriculum)

在该课程中，本研究将每个相关项的模仿奖励定义为指数函数。针对特定特征项 s_t^{term} 及其目标 $\hat{s}_t^{\text{term}}$ ，奖励计算如下：

$$R_t^{\text{term}} = \omega^{\text{term}} \exp\left(-\frac{\|s_t^{\text{term}} - \hat{s}_t^{\text{term}}\|^2}{2(\sigma_l^{\text{term}})^2}\right), \quad (3.8)$$

其中 ω^{term} 为权重因子， σ_l^{term} 为该项在课程等级 l 下的标准差。该奖励公式具有良好的性质：忽略乘数 ω^{term} ，函数值域为 $[0, 1]$ ，且较大的 σ_l^{term} 使得获取高奖励更为容易。用户可以指定初始标准差 σ_0^{term} 及其逐步衰减计划。本研究还定义了一个更新阈值 $\text{ratio} \in (0, 1)$ 。当归一化奖励 $R_t^{\text{term}}/\omega^{\text{term}}$ 在一定周期内持续达到或超过该比例时，标准差 σ_l^{term} 将减小，使得训练条件更为严苛。在初始阶段，这些项通常设定较大的 σ 以辅助策略快速探索至收敛方向；随着智能体状态逼近参考状态，获取奖励的难度逐步增加，以维持进一步精细化的动机并防止过早收敛于局部最优。

3.4.2.2 “幼儿学步”课程 (Toddler Curriculum)

为了促进策略从 DAgger 学习到的分布 π_D 平滑收敛至适应复杂物理环境的行为（特别是在涉及接触的初始交互阶段），本研究引入了“幼儿学步”课程。受幼儿学步车的启发，该课程提供辅助力支持。具体而言，当机器人基座高度 h^{base} 低于参考高度阈值 $(\hat{h}^{\text{base}} + \text{offset})$ 时，系统将在垂直 (z) 方向施加一个类弹簧力：

$$F_z^{\text{base}} = -k \cdot \text{clamp}\left((h^{\text{base}} - (\hat{h}^{\text{base}} + \text{offset})), -h_{\text{max}}, 0\right) - c \cdot \dot{h}^{\text{base}}, \quad (3.9)$$

为了防止非自然的加速度，最大辅助弹簧力（源自 $k \cdot h_{\text{max}}$ ）被限制在有界范围内。随着训练进程中模仿奖励的提升和跌倒次数的减少，参数 k 和有效辅助范围（如 h_{max} ）将逐渐减小，直至辅助力完全消失。

该课程的优势在于规避了复杂的物理模型（如悬吊装置）。辅助力仅作用于全局 z 轴，最大程度减少了对其他模仿行为的干扰。该策略主要旨在防止因次优动力学交互导致的早期跌倒，有效地允许智能体“先学会稳定的行走姿态，再精细化步态”。若动作偏差过大，机器人仍会跌倒，确保了终止条件在动作极其不完美时依然有效。该功能通过为 Isaac Lab 框架中新增 Physics Modifier Manager 实现，支持动态调整外力的通用方案。

3.4.2.3 模仿奖励设计

在课程学习基础上，更为重要的是模仿动作的奖励。表 3.3 总结了模仿奖励函数 $\hat{R}$ 的主要组成部分。鉴于本研究已将对称损失项直接纳入 PPO 目标（如前所述），这些模仿奖励组件的设计无需显式平衡对称身体部位的追踪，策略网络有望内在地学习到恰当的镜像响应。

表 3.3 模仿奖励 ($\hat{R}$) 组件汇总

Table 3.3 Summary of imitation reward ($\hat{R}$) components.

奖励类型	奖励项 (示例)	表达式
指数惩罚 (带课程 σ_t)	关节位置/速度, 基座线/角速度	$\omega \exp(-\frac{\ s_t - \hat{s}_t\ ^2}{2\sigma_t^2})$
指数惩罚 (无课程)	基座/连杆全局位置与速度, 目标高度	$\omega \exp(-\frac{\ s_t - \hat{s}_t\ ^2}{2\sigma^2})$
L2 范数偏差	重力方向, 末端执行器朝向	$-\omega \ s_t - \hat{s}_t\ ^2$
偏差变化率 L2 范数	关节加速度, 根节点追踪偏差率	$-\omega \ \dot{s}_t - \dot{\hat{s}}_t\ ^2$ ^a
二值匹配和 (逐帧)	足部接触状态 (二值)	$\omega \neg(s_t \oplus \hat{s}_t)$ ^b

^a $\dot{s}_t$ 表示 s_t 的时间导数。

^b $\oplus$ 为异或 (XOR) 算子，用于比较二值接触索引。

3.4.3 训练优化策略

为了提升学习效率和策略的泛化能力，本研究在训练过程中通过 Env Manager 集成了多项关键优化策略，旨在构建一个鲁棒且多样化的训练分布。

- **域随机化与参考随机化 (Domain and Reference Randomization):** 为了弥合仿真与现实的差距并提升鲁棒性，本研究应用了广泛的域随机化，包括随机化机器

人的物理属性（如负载质量）、执行器参数以及施加外部推力。此外，本研究在智能体观测和参考观测中均注入噪声，以鼓励策略即使在演示数据不完美的情况下也能掌握运动技能^[71]。

- **随机初始状态初始化 (Randomized Start-State Initialization):** 遵循 DeepMimic^[27] 的原则，本研究在每回合开始时随机化动作序列内的起始点。始终从固定点开始会导致策略偏差，而随机化初始状态鼓励智能体学习从轨迹中任意点恢复的鲁棒策略。本研究的 **RefDataBuffer** 类通过高效计算存储的微分运动数据的初始全局位姿、关节状态和速度，确保了即使在跳跃或翻滚等动态状态下也能实现正确的物理初始化。
- **随机动作选择 (Randomized Motion Selection):** 为了防止过拟合于少量动作，本研究在重置时随机分配参考动作序列。不同于部分框架为提高稳定性而在每轮训练中仅跟踪单个序列^[20,51]，本研究的方法将策略暴露于来自 AMASS 等数据集的多样化动作中。这显著增强了策略的泛化能力，正如本研究在跨数据集迁移任务中经验性观察到的那样。
- **模仿感知型提前终止 (Imitation-Aware Early Termination):** 标准的终止条件（如基座接触地面即重置）对于全身模仿是不够的，因为爬行等动作需要地面接触。为了防止智能体学习到非模仿的、仅为延长生存时间的行为（如偏离正常人类动作空间的行为），本研究引入了更严格的、感知模仿质量的终止条件。如果智能体的状态显著偏离参考（例如基座相对于重力的朝向或根节点高度出现巨大偏差），回合将立即终止。这确保了策略始终保持与演示数据的高度对齐。

3.5 实验验证与结果分析

3.5.1 MMTransformer 骨干网络性能分析

在建立了可靠的动作重定向流水线之后，本研究首先验证所提出的新型 PPO 骨干网络的收敛性能。为此，本研究在两种截然不同的场景下进行了对比分析：一个是侧重于指令跟随的标准强化学习（RL）任务，另一个是专注于跟踪特定参考动作的模仿学习（IL）任务。鉴于本研究的框架支持多种 MMTransformer 架构和嵌入策略，本研究选取了表 3.4 中详述的几种配置进行效能评估。

为了量化实验表现，本研究定义了以下评估指标：

- **针对 RL 任务:** 本研究衡量策略实现稳定且熟练运动的能力。
 - 稳定轮次 (*Stable Epoch, St-E*): 平均回合长度持续超过最大回合时长 90%

表 3.4 骨干网络性能分析实验设置
Table 3.4 Experiment setup for backbone analysis

组件	规格说明
任务	1. 强化学习 (RL): 基于 Isaac Lab 官方 Unitree H1 环境改编的 H1-2 构型移动任务, 目标是跟随给定的速度指令。 2. 模仿学习 (IL): 跟踪源自 ‘ACCAD/Male1Walking’ 数据集的两个动作: (a) 向前走并转弯, (b) 向后走。单次跟踪的回合长度上限设为 20 秒。 [†]
测试模型	1. MLP (Baseline): 标准 Fused MLP, 隐藏层为 [512, 256, 128]。在模仿任务中启用了 AMP。 2. MMT + Basic Emb.: 采用基础嵌入层的 Transformer 骨干网络。 3. MMT-MLP Hybrid: MMTTransformer 与 MLP 策略输出的加权融合策略。 4. MMT + Obs. Embedding V2: 采用高级分组嵌入层的 Transformer 骨干网络。 [‡]
观测空间	RL 观测: 线速度与角速度、重力投影、关节位置与速度、足部接触相位。 IL 参考观测: 参考线速度与角速度、参考重力投影、参考关节位置与速度、参考连杆位置与速度、参考高度、参考足部接触相位。
超参数	Transformer: $d_{\text{model}} = 256, N_{\text{layers}} = 2, N_{\text{heads}} = 8$. 训练设置: 使用固定随机种子 42 以确保环境随机化的一致性。

[†] 虽然本研究的数据处理流程支持无限长的动作序列, 但为了保证训练周期的效率, 本研究将单回合长度限制在 20 秒。

[‡] 在 V2 配置中, 观测按模态分组: (a) IMU 相关值 (角速度、重力), (b) 足部接触相位, (c) 所有关节状态, 以及 (d) 其他观测, 分为不同的组。

的训练轮次。这表明机器人已学会避免摔倒。¹

- 收敛轮次 (*Well-Trained Epoch, Su-E*): 速度跟踪奖励持续保持高位的轮次。本研究将其定义为速度跟踪奖励 R_{vel} 满足 $R_{\text{vel}} > 0.75$ 的时刻。奖励计算公式为:

$$R_{\text{vel}} = \exp\left(-\frac{\|\mathbf{v} - \mathbf{v}_{\text{target}}\|^2}{2\sigma^2}\right),$$

其中 $\sigma = 0.35$ 。

- 针对 **IL 任务**: 除上述指标外, 本研究还评估动作跟踪的保真度。
 - 跟踪达标轮次 (*Well-Tracked Epoch, Su-E*): 关节位置跟踪奖励 R_{pos} 持续超过 0.7 的轮次。该奖励函数采用类似的指数形式, $\sigma = 0.4$ 。
 - 动作相似度得分 (*Action Similarity Score*): 在训练至 10,000 次迭代时计算的得分, 用于衡量学习到的策略动作与专家演示的相似程度。该得分源自一个预训练的 AMP 风格判别器 (仅用于评估, 不参与策略训练)²。得分定

表 3.5 骨干网络架构在 RL 和 IL 任务上的性能对比

模型架构	RL 任务		IL 任务			
	稳定 轮次	收敛 轮次	稳定 轮次	收敛 轮次	跟踪达标 轮次	相似度 得分
1. MLP (Baseline) ^a	120	980	5770(2640)	> 1e4(7000)	∞ (> 1e4)	-0.42(0.62)
2. MMT + Basic Emb.	290	1400	560	∞	4490	0.24
3. MMT-MLP Hybrid	87	650	380	3420	3750	0.43
4. MMT + Grouped Emb. (V2)	95	720	160	1870	2510	0.89

^a 测试适应于 IL 任务的 MLP 时，括号内的值为启用 AMP 后的测试结果。

义为：

$$S_{\text{similarity}} = \frac{s_{\text{action}} - \bar{s}_{\text{neg}}}{s_{\text{pos}} - s_{\text{action}}}.$$

其中 s_{action} 是判别器对生成动作序列的打分， $\bar{s}_{\text{neg}}$ 是非专家数据的平均得分， s_{pos} 是专家数据的得分。得分越高，意味着生成的动作越能“欺骗”判别器，即越接近参考动作。

各模型架构在 RL 和 IL 任务上的表现汇总于表 3.5。本研究的结果分析如下：

- **MLP (Baseline):** 标准 MLP 架构在基础的指令跟随 RL 任务上表现熟练，能在合理的轮次内达到稳定和熟练水平。然而，它在多动作模仿学习任务上表现不佳。其简单的结构无法有效处理动作跟踪所需的高维、多模态参考观测，这是因为 MLP 本身网络容易在指标上过拟合的原因。当开启 AMP 的奖励辅助引导梯度信号后，MLP 的表现明显提升，其最终的 AMP 得分也显著高于基线。但是这一结构仍然不能很好地进行多动作协同训练，同时，其无法有效地进行模仿状态和自适应控制状态的切换。
- **MMT + Basic Emb.:** 基础 MMTransformer 架构虽在结构上更适合多模态融合，但在纯 RL 任务上的收敛速度较慢。这可能是由于参数空间较大，且朴素的嵌入策略 (Flatten) 未能保留观测数据的固有结构，导致优化难度增加。反之，其建模智能体与参考状态关系的能力使其成功完成了 MLP 无法应对的 IL 任务。
- **MMT-MLP Hybrid:** 这种混合模型通过可学习的加权融合结合了两个网络的输出，在分别训练 RL 和 IL 任务时均展现出令人印象深刻的性能，有效利用了两者的优势。然而，其关键局限在于 MLP 组件无法处理被掩码的输入 (Masked

① 回合长度记录了直到环境重置为止的时间。当该持续时间接近最大允许时间时，意味着智能体很少失败（如摔倒），因此可被视为稳定。

② 本研究训练了一个区分智能体观测与专家观测的判别器，但不将其输出作为策略的奖励信号，仅用于此最终评估指标。

Inputs), 而这正是在单一策略内切换参考基 (IL) 与无参考 (RL) 控制的核心机制。因此, 该架构不适合用于构建统一的学习框架。

- **MMT + Grouped Emb. (V2):** 本研究最终提出的架构有效解决了上述模型的短板。通过基于模态的分组和观测数据的卷积预处理引入归纳偏置 (Inductive Bias), 分组嵌入 (V2) 保留了基础嵌入中丢失的关键结构和时序信息。这使得其在 RL 任务上的表现超越了 MLP 基线, 并在 IL 任务上显著优于所有其他架构。该模型在信息处理、特征融合及动作生成方面的卓越能力, 证实了其作为复杂且统一的模仿学习策略骨干的适用性。

3.5.2 DAgger-MMPPO 算法效能评估

为了验证 GBC 框架在训练通用控制器方面的有效性, 必须对 DAgger-MMPPO 算法的核心设计进行严格的实证检验。本节重点评估两项关键技术组件的贡献: DAgger 网络在多动作跟踪中的引导作用, 以及“幼儿学步”课程设置在提升训练早期稳定性方面的作用。

为了在极具挑战性的边界条件下测试算法性能, 本研究并未选择轻量级机器人, 而是选择了 Unitree H1-2 作为本实验的分析平台。在所有测试构型中, H1-2 拥有最大的整机质量与身高, 其高惯量特性使得动力学控制与平衡维持变得异常困难。因此, 该平台上的训练收敛情况能最敏锐地反映出不同算法设计的性能差异。

以下将详细阐述本次评估的实验设计, 包括任务分级、课程设置、训练协议及消融组别。

3.5.2.1 实验任务分级与数据集构建

为了全面评估策略在不同复杂度动作下的表现, 本研究从 AMASS 数据库中构建了三个难度递增的任务集合, 旨在考察算法从基础运动到高动态特技的适应能力:

1. **简单任务:** 该任务集主要包含基础的、周期性的行走动作, 数据源自 AMASS 数据集中 ACCAD 子集的 Male1Walking_c3d 和 Male2Walking_c3d 子集。这类动作的动力学特性相对平稳, 主要用于验证算法在标准步态跟踪上的收敛速度与精度。
2. **中等任务:** 该任务集旨在模拟真实世界中多变的运动需求。本研究从整个 ACCAD 数据集中随机采样了一组多样化的动作序列 (但不含爬行等完全无法执行的子动作), 涵盖了变速行走、转向、下蹲以及非周期性的肢体运动。此任务考察策略在面对未见过的或非结构化动作时的泛化能力。

表 3.6 DAgger-MMPPPO 算法各配置在不同难度任务上的性能评估
Table 3.6 Performance evaluation for DAgger-MMPPPO on different task settings

算法配置	简单任务			中等任务			困难任务		
	St-E 轮次	Su-E 百分比	Cur-L 等级 ^a	St-E 轮次	Su-E 百分比	Cur-L 等级 ^a	St-E 轮次	Su-E 百分比	Cur-L 等级 ^a
MMPPPO (Baseline)	160	78.9%	3/2/4	430	82.5%	2/1/3	1300	61.2%	1/1/2
MMPPPO + DAgger	230	87.9%	3/3/5	560	87.7%	3/2/4	920	73.1%	2/1/4
MMPPPO + Toddler Curr.	140	90.9%	3/4/5	420	87.0%	2/3/5	740	82.7%	1/2/4
MMPPPO (Full)	200	90.9%	3/4/5	500	91.3%	3/3/5	810	82.7%	2/3/5

^a 课程等级显示顺序为：线速度 / 角速度 / 关节位置。

3. 困难任务:这是最具挑战性的测试集,在先前的数据上加入了 ACCAD/Martial Arts 目录。该集合包含大量涉及剧烈旋转、单腿支撑、踢腿甚至跳跃的复杂武术动作。这类动作对机器人的瞬时爆发力、角动量控制以及全身协调性提出了极高的要求,用于测试算法在物理极限附近的鲁棒性。

3.5.2.2 动态课程学习机制

为了引导智能体逐步掌握高精度的跟踪能力,本研究设计了一套基于奖励函数调整的多级动态课程。该课程通过逐步衰减表3.3所示奖励函数中的高斯核标准差 σ ,从宽容的模糊匹配逐步过渡到严苛的精确跟踪。

具体而言,本研究针对线速度、角速度和关节位置三个关键奖励项设定了如下退火计划:

- 线速度奖励 (Linear Velocity): σ 等级设定为 [0.5, 0.45, 0.42, 0.4, 0.35] m/s。
- 角速度奖励 (Angular Velocity): σ 等级设定为 [0.5, 0.45, 0.42, 0.4, 0.35] rad/s。
- 关节位置奖励 (Joint Position): σ 等级设定为 [0.75, 0.6, 0.5, 0.45, 0.4] rad。

为了防止策略在未掌握当前难度时过早进入下一阶段,本研究设定了严格的晋级阈值。仅当某一项奖励的归一化均值在当前阶段超过总指标的 70% 时,该项的课程等级才会提升。这一阈值与前文定义的“收敛”标准保持一致,确保了训练过程

这四种算法配置在三类任务上的对比结果如表 3.6 所示。

值得注意的是,AMASS 数据集包含一些运动学上极具挑战性 or 违反 H1-2 机器人构型终止条件的动作(如爬行、侧手翻、飞踢)。虽然本研究的框架可以通过跟踪速度和关节角度等关键量而非绝对空间坐标来学习执行这些动作的变体,但生成的行为可能与参考动作存在差异,无法实现完美跟踪。由于这些动作也被计入成功率计算,因此没有任何算法配置能达到 100% 的成功率。

从结果可以看出，在**简单任务**上，四种配置均表现有效，差异微小，但基线 MMPPO 学习较慢。引入 **DAgger** 后，策略需要更长的时间达到稳定状态。这是因为 DAgger 预训练的初始策略分布 π_D 与全物理环境的目标分布 π_R 并不完全对齐，且 π_D 较小的探索半径 σ 需要更多的训练来适应。然而，一旦稳定，其收敛速度明显快于基线。**幼儿学步课程**使得策略能极快地达到稳定；智能体只需在辅助力介入前避免即刻失稳，之后便不易跌倒。在这个有辅助的“悬吊”阶段——类似于 DAgger 训练环境——智能体能更有效地跟踪关节运动。一个副作用是，由于辅助力常在智能体已经倾斜时作用，线速度跟踪可能会受到轻微影响，而角速度跟踪则更为精准。

图 3.6 中**中等任务**的奖励曲线阐释了这些动态过程。带有幼儿学步课程的策略在每个课程阶段内迅速收敛，但在课程难度提升、辅助力减小时会出现性能下降，需要策略重新适应。这一过程映射了 DAgger 中从 π_D 到 π_R 的过渡，但以更小、更可控的步幅进行。相比之下，增强了 DAgger 的策略虽然初始稳定较慢，但随后展现出比基线更陡峭且稳定的学习曲线。最终，本研究的**完整 MMPPO 算法**协同了这些优势：DAgger 组件提升了训练效率和稳定性，而幼儿学步课程确保了通过分级难度的快速且结构化的进阶，从而产生了最鲁棒且性能最优的策略。图3.6展示了训练过程的奖励函数记录曲线。完整 MMPPO 算法（红色）表现出最快且最稳定的收敛。基线 MMPPO（蓝色）虽然逐渐提升但速率较慢。带有幼儿学步课程的策略（绿色）在每个阶段内迅速收敛，但在课程难度增加时会出现明显的性能下探。DAgger 增强策略（橙色）初始稳定耗时较长，但随后显示出比基线显著更快且更稳定的学习过程。




图 3.6 四种算法配置在中等任务上的平均奖励曲线
Figure 3.6 Average reward curve for four different experiment designs

3.5.3 泛化性与迁移能力评估

在这一最终实验部分，本研究评估 GBC 框架训练出的策略的泛化与迁移学习能力。本研究首先介绍训练期间用于增强策略鲁棒性的域随机化设置。随后，本研究将验证训练策略的以下关键特性：

1. 训练于**单一动作类型**的策略模仿分布外 (O.O.D.) 动作的能力。
2. 训练于**多种动作类型**的策略对 O.O.D. 动作的泛化能力。
3. 统一策略在禁用参考观测输入 (即 `ref_observation` 为 `None` 且对应 `Token` 被掩码, 如图 3.1 所示) 时, 仅依赖自身观测进行速度指令跟随的性能。

为了培养鲁棒且可迁移的策略, 本研究在训练期间采用了一套全面的域随机化技术。这包括变化动力学参数 (如负载质量 ± 5.0 kg; 关节刚度和阻尼乘数在 $[0.8, 1.2]$ 之间), 随机化每回合的初始状态以匹配参考动作中的随机点, 以及以随机间隔对机器人基座施加 ± 0.5 m/s 的外部推力。此外, 本研究在观测和参考观测项中加入均匀分布噪声, 以模拟传感器噪声和劣质演示输入, 从而增加训练策略的鲁棒性。

本研究的实验方案设计如下: 首先利用 ACCAD 子数据集的动作训练两个独立的策略: 一个针对**行走任务** (仅模仿行走动作), 另一个针对**中等任务** (模仿随机采样的动作, 同上一节)。然后, 本研究比较它们在分布内测试数据和由本研究自己录制的动作生成的 O.O.D. 轨迹上的平均跟踪误差。在确定表现更好的策略后, 本研究在 Isaac Sim 中禁用其参考观测输入, 评估其指令跟随行走能力。最后, 本研究将策略部署到 MuJoCo 仿真器中, 以评估其 Sim-to-Sim 迁移能力, 从而证明本研究的框架生成可部署策略的潜力。

用于评估的 O.O.D. 数据包括一个基础行走动作 (*O.O.D. Walking*) 和一个复杂的舞蹈序列 (*O.O.D. Dancing*), 如图 3.7 所示。这些动作使用 WHAM^[57] 捕捉, 并通过本研究的数据流水线处理以生成可执行动作。为了评估跟踪质量, 本报告跟踪 10 秒后的平均跟踪指数, 定义为 $\exp(-\|\text{err}\|^2/\sigma^2)$ 。该指数针对关节位置^①、线速度和角速度计算, 使用 $\sigma = 0.4$ 来表征策略跟踪状态的分布。为了专门验证策略跟踪复杂关节运动的能力, 本组实验使用 Fourier GR1 机器人。

表 3.7 展示了在行走任务和中等任务上训练的 Checkpoint 在分布内及 O.O.D. 数据上的表现。

结果表明, 仅在行走数据上训练的策略具有一定的迁移能力, 但在面对差异巨大的 O.O.D. 舞蹈动作时泛化失败。相比之下, 在中等任务 (更多样化) 上训练的策略学习到了更丰富的运动基元。虽然其在特定任务上的跟踪保真度可能略低于专用模型, 但其泛化性能远超后者, 使其能够成功跟踪并执行新颖的舞蹈动作。这也突显了一点: 当参考速度与机器人能力不匹配时, 策略会优先模仿关节位置和足部接触模式以维持物理稳定性, 这是由本研究的奖励函数设计所塑造的行为。

① 对于多关节机器人, 误差为关节位置差的 L2 范数, 反映了跟踪过程中最大的关节角度偏差。




图 3.7 分布外 (O.O.D.) 参考动作及其在 Isaac Sim 环境中的对应执行情况
Figure 3.7 Example of O.O.D. reference motions and corresponding replay in Isaac Sim

表 3.7 分布内与分布外数据的跟踪性能

数据输入	行走任务 Ckpt.			中等任务 Ckpt.		
	关节指数	线速度指数	角速度指数	关节指数	线速度指数	角速度指数
训练分布	0.867	0.741	0.656	0.824	0.682	0.610
O.O.D. 行走	0.833	0.702	0.845	0.817	0.688	0.801
O.O.D. 舞蹈	0.282	0.329	0.364	0.724	0.597	0.633

注：直接转换的参考动作并非总是动力学可行的。本研究的 RL 策略学习模仿最接近的动力学可行运动，因此跟踪指数不会达到 1.0。较高的指数仍表明与原始动作更相似。来自 WHAM 的线速度和角速度是通过 SLAM 估计的，包含固有的不准确性。

此外，本研究在禁用参考输入的情况下评估了训练策略的性能。行走任务和中等任务的策略均能跟随速度指令进行基础移动。由于训练集中行走数据量有限，策略能够一致地跟踪速度指令的方向，但速度跟踪的精度仍有提升空间。值得注意的是，当接收到侧向速度指令时，中等任务策略会尝试执行侧跳（其训练数据中存在的动作），而行走任务策略则不会。部分测试效果如图3.8所示，第一列 (H1-2) 展示了在行走任务上训练的策略在禁用参考输入时执行指令跟随行为（前进、后退、转弯）。第二列 (G1) 展示了中等任务策略跟踪从其训练分布中采样的动作时的模仿能力。第三列 (G1) 展示了策略对 O.O.D. 数据的泛化能力；虽然与分布内参考动作相比，足部接触和部分关节跟踪精度有所下降，但仍能完成跟踪任务。

最后，为了评估策略的 Sim-to-Sim 迁移能力，本研究针对两个特定平台重新训练了 Checkpoint。在行走任务上训练的策略在 Unitree H1-2 上进行了验证，而在更复杂的中等任务上训练的策略则在更灵活的 Unitree G1 上进行了验证。随后，本研究选择 G1 的 Checkpoint 部署到 MuJoCo 仿真器中^①。如图 3.8 所示的结果表明，本研究

① Fourier GR1 未用于此 Sim-to-Sim 验证，因为即使用官方转换工具也无法从提供的 URDF 生成可靠的 MJCF




图 3.8 部署于 MuJoCo 平台的训练策略仿真结果
Figure 3.8 Simulation results in MuJoCo platform

的策略能够有效地控制 G1 机器人在 MuJoCo 中的运动，成功执行基于参考的跟踪和无参考的指令跟随。这种成功的迁移证实了学习到的策略并未过拟合于 Isaac Sim 环境，并且在不同的仿真器中具备鲁棒性，预示了其在 Sim-to-Real 部署中的巨大潜力。

3.6 本章小结

本章聚焦于解决强化学习在机器人动作模仿任务中面临的“模仿”与“探索”难以兼顾、多动作泛化能力弱以及策略对参考数据质量高度敏感等核心挑战。本研究从网络架构设计、训练算法优化以及仿真平台构建三个维度出发，提出了一套完整的解决方案，实现了从单一动作跟踪到复杂多动作泛化及自主指令跟随的跨越。

本章的主要工作与贡献总结如下：

- **网络架构创新**：首先构建了基于时序特征融合的 Fused MLP 基线，通过门控机制初步解决了参考数据缺失时的策略崩溃问题。在此基础上，提出了核心架构 Motion Mimic Transformer (MMTransformer)。该架构利用 SwiGLU 分组嵌入与自注意力机制，将本体观测与参考动作视为独立模态进行动态建模，有效突破了传统 MLP 在处理高维时空特征时的瓶颈，赋予了策略在“高保真模仿”与“自主速度控制”之间无缝切换的能力。
- **训练算法设计**：针对复杂物理环境下策略难以收敛的问题，提出了 DAgger-

模型，导致跨平台测试不可行。

MMPPO 两阶段训练框架。第一阶段在简化动力学环境中快速获取行为先验 (Behavioral Prior); 第二阶段结合 DAgger 思想与 LoRA 微调技术, 构建了“教师-学生”蒸馏机制, 引导策略从理想化运动平滑迁移至全动力学环境, 显著提升了样本效率与训练稳定性。

- **课程学习与系统实现:** 基于 Isaac Lab 开发了高效的模仿学习训练平台, 并设计了“幼儿学步” (Toddler Curriculum) 与动态方差课程。这种分级难度机制有效缓解了训练初期的奖励稀疏问题, 使得智能体能够像人类学习运动技能一样, 循序渐进地掌握平衡控制与精细动作跟踪。
- **实验验证:** 通过在 Unitree H1/G1 及 Fourier GR1 等多构型机器人上的广泛实验, 验证了 MMTransformer 在多动作学习任务上显著优于传统 MLP 架构。同时, 消融实验证实了 DAgger-MMPPO 算法在处理高难度动作 (如武术动作) 时的鲁棒性。Sim-to-Sim 迁移与分布外 (O.O.D.) 动作测试进一步表明, 本章提出的方法具备良好的泛化能力, 能够适应未见过的复杂参考动作及跨仿真平台部署。

综上所述, 本章提出的网络架构与训练框架为基于物理的动作模仿提供了强有力的技术支撑, 也为后续章节中将这些能力迁移至真实机器人平台奠定了坚实的理论与实践基础。

第4章 基于扩散模型的人形机器人全身运动生成与闭环控制

4.1 问题分析

本文的前两章逐步构建了人形机器人通用控制的基础设施。第二章提出的自适应重定向框架解决了从人类动作捕捉数据到异构机器人运动数据的离线转换问题,为实验提供了宝贵的机器人本体动作数据集 (Robot-Native Dataset); 第三章设计的 GBC 控制器则充当了一个鲁棒的“小脑”,赋予了机器人在物理仿真中执行复杂参考动作的能力。

然而,仅拥有“数据的转换能力”和“动作的执行能力”尚不足以构成一个具备高度自主性的智能体。目前的系统仍缺乏一个能理解高层语义指令(如自然语言)、并能据此生成长程、多样化运动规划的“大脑”。将生成式模型,如扩散模型 (Diffusion Model),引入人形机器人控制领域是解决这一缺失的有效途径。但在将这一想法与现有的强化学习控制器架构集成时,面临着以下三个核心挑战。

生成空间的形态鸿沟 现有的动作生成研究大多集中在基于 SMPL 等标准人体模型的运动生成上^[34,72-75]。尽管这些模型在生成高质量人体动画方面表现优异,但直接将其应用于机器人控制存在显著的“形态鸿沟”(Morphology Gap)。

传统思路通常采用“先生成后映射”的策略,即先利用条件约束通用扩散模型生成人体动作^[38],再通过逆运动学或重定向算法映射到机器人上^[59,76]。然而,这种方法高度依赖源域(人)与目标域(机器人)之间的形态相似性。正如第二章所述,当机器人具有非人特征(如反关节腿、特殊的连杆比例)时,直接映射生成的动作往往不仅丢失了语义信息,更会导致物理上的不可行,例如自碰撞或违反关节限位。

由于在第二章已经实现了将大规模人体数据转化为机器人本体数据的能力,本章主张一种范式转换:不再让机器人去适应人体生成的动作,而是训练一个生成模型直接在机器人的本体空间内进行规划。这就要求本文的生成架构必须是形态无关的,能够直接学习并输出适配特定机器人构型的动作序列。

状态表征的异构性与物理约束缺失 将扩散模型从计算机视觉或单纯的动作动画领域迁移到机器人控制时,面临的第二个挑战是状态表征的异构性。传统的文本生成动作 (Text-to-Motion) 数据集通常仅包含基础运动学信息(如关节旋转角度)。然而,

对于一个处于物理环境中的机器人而言，其状态表征必须包含运动观测所需的完整信息，包括关节位置、关节速度、连杆状态（Link States）以及与环境交互的接触状态（Contact States）^[21,77]。对于运动学数据，如果仅在关节空间进行扩散生成，忽略连杆在笛卡尔空间的速度与位置，生成的动作往往缺乏物理真实感，容易产生非自然的滑步（Skating）或抖动。而要生成更复杂的数据，其编码则更加困难。机器人本体数据包含了动作空间（Action Space）和任务空间（Task Space）两种截然不同的数据模态，在同一空间内也有，对应的均值和方差差异明显。如何在扩散模型的去噪过程中同时约束这几种异构特征，使其满足刚体动力学约束（例如，生成的关节角度与其对应的末端位置必须通过正运动学一致），是一个亟待解决的问题。因此，本文需要设计一种新的网络架构和损失函数体系，能够显式地处理并约束这些异构的机器人本体状态。

生成与控制的频率鸿沟 即便解决了形态和表征问题，将扩散模型部署为实时控制器还面临着严峻的“频率鸿沟”（Frequency Gap）。扩散模型面对的是**生成速度的瓶颈**：标准的扩散模型采样算法（如 DDPM 或 DDIM）^[78-79]通常需要数十次甚至上千次的迭代去噪才能生成一个高质量样本。这意味着单次推理可能耗时数百毫秒甚至数秒。

而执行策略内含的是**控制频率的需求**：本文在第三章中训练的强化学习策略通常需要在 30Hz 至 50Hz 的频率下运行，而底层的电机控制频率更是高达 1000Hz。如果直接将扩散模型作为每一步的控制器，其推理延迟将导致严重的控制滞后，使系统无法响应环境的动态变化。因此，本章不仅需要关注生成的质量，更需要关注生成的效率。本章需要探索如流匹配（Flow Matching）等加速采样技术^[41]，并设计一种分层控制架构，让低频运行的扩散模型作为“规划器（Planner）”，与高频运行的 RL “执行器（Executor）”协同工作，从而实现实时的闭环控制。

4.2 人形机器人动作生成与闭环控制框架

本框架如图 4.1 所示，包含三个核心模块：(1) **数据集构建（Dataset Preparation）**，负责将标准人体动作数据 x^{SMPL} ^[80] 转换为类似 HumanML3D 的格式 x^{hm} ^[21]，进而转化为特定机器人的域 $x^{hn} \in \mathbb{R}^{J \times D_J + L \times D_L}$ 。此举弥补了人体数据与非统一机器人连杆/关节状态之间的差异。该模块还实现了重建映射 $f^{Recon} : x^{hn} \rightarrow x^{hm}$ 。(2) **动作扩散模型（Motion Diffusion）**，根据文本 c_{text} 、前缀序列 x_{pref}^{hn} 和目标位置等输入条件生成动作序列 $x_0^{hn} = \{X_i^{hn}\}_{i=0}^N$ 。(3) **轨迹规划（Trajectory Planning）**，将生成的 x_0^{hn} 转化为可执




图 4.1 动作生成与控制框架概述

Figure 4.1 Overview of the diffusion controller framework

行的强化学习 (RL) 控制策略 π 。该模块通过实现相应的开环和闭环控制器，解决了缓慢的 DPM 去噪过程与高频控制需求之间的不兼容性。类似于 HumanML3D 处理 AMASS 数据集的方式，本文提出的 HumanoidML3D 数据表征亦可从任何 SMPL 格式数据导出。利用第二章 2 所述 GBC 提供的可微 IK 网络，可将 SMPL 表征离线转换为机器人坐标系下的数据，生成根节点 (Root)、关节 (DoF)、连杆 (Link) 和接触 (Contact) 四类表征。后两者通过 GBC 内实现的 PyTorch 正运动学 (FK) 库计算得出。反之，利用训练好的逆 GBC 网络 (将 DoF 信息映射回轴角表示)、SMPL 身体模型及预定义的坐标系变换，可实现从 HumanoidML3D 表征到 HumanML3D 表征的在线转换，并保持梯度流动 (如蓝色箭头所示)。仅离线进行的逆运动学步骤 (红色箭头) 避免了 HumanML3D 到 HumanoidML3D 方向的在线转换需求。

4.2.1 数据集构建

数据转换路径如图 4.2 所示。除体型外，SMPL 动作由根节点平移 $x_c \in \mathbb{R}^3$ 和轴角关节姿态 $p \in \mathbb{P}$ 定义。尽管转换为 x^{hm} 的方法已相当成熟，但将其转化为 x^{hn} 面临三个挑战：(1) 将通用人体骨骼转换为机器人特定的运动学结构，这通常涉及欠驱动问题；(2) 处理坐标系 (Y 轴向上转为 Z 轴向上) 和特征 (如 6D 旋转转为 1-DoF) 的变换，包括末端执行器状态的计算；(3) 将绝对根节点表征转换为增量控制特征 (如线速度/角速度) 并推导接触相位。




图 4.2 HumanoidML3D 表征与 HumanML3D 方法的转换流程对比。

Figure 4.2 Comparison of the conversion pipeline for our HumanoidML3D representation with the HumanML3D approach.

为解决上述挑战，本文利用第二章提出的 GBC 框架中的可微 IK 网络 $g: \mathbb{P} \rightarrow \mathbb{A}$ ，将人体姿态 p 映射到机器人 DoF 状态 $\mathbb{A}$ 。随后，利用机器人的正运动学（FK）模型、变换后的根节点平移 x_c^{hn} 和旋转 q_c^{hn} ，计算连杆空间位置、速度（通过微分获得）以及足部接触状态。

因此，本流程将数据组织为四个部分（根节点 M1、关节 M2、连杆 M3、接触 M4），并将其命名为 **HumanoidML3D** 规范。如表 4.1 所详述，该格式优先采用局部坐标表征，并移除了人形机器人中不存在的特征（如脚趾），从而构建起和标准的 HumanML3D 格式的一一对应关系。

表 4.1 HumanML3D 与本文 HumanoidML3D 规范的数据表征对比。

Table 4.1 Comparison of data representations between HumanML3D and our HumanoidML3D specification.

HumanML3D 表征	原始组成 (维度)	HumanoidML3D 表征	新组成 (维度)	特殊处理 (控制目标)
根节点表征 M1 (Root Representation)	角速度 ω_y (1) 线速度 v_x, v_z (2) 高度 h_y (1)	根节点表征 (Root Representation)	线速度 v_x, v_y (2) 角速度 ω_z (1) 高度 h_z (1)	坐标系变换。 (速度指令, 基座高度)
关节局部表征 M2 (Joint Local Rep.)	关节旋转 (22×6) 关节局部速度 (22×3)	关节 (自由度) 表征 (Joint/DoF Rep.)	DoF 姿态 (n_{dof}) DoF 速度 (n_{dof})	通过 IK 网络重定向。 (关节位置, 关节速度)
关节全局表征 M3 (Joint Global Rep.)	关节旋转不变位置 (22×3)	连杆表征 (Link Rep.)	局部坐标系连杆位置 (n_{links}) 局部坐标系连杆速度 (n_{links}) (可选) 根节点朝向 (3)	定位于根坐标系的参考位置与速度。 (局部连杆位置/速度)
接触表征 M4 (Contact Representation)	脚跟与脚尖接触 (4)	接触表征 (Contact Representation)	脚跟接触正弦相位 (2) 脚跟接触余弦相位 (2)	移除“脚趾”，转换为连续相位。 (接触相位)

在基础实现之上，人形机器人动作生成的一个关键扩展是**在线可微重建映射**：

$$f^{Recon} : x^{hn} \rightarrow x^{hm}, \quad (4.1)$$

虽然根节点和接触信息经过精心设计满足了梯度传播的有效性（例如通过矩阵变换、

‘atan’计算、均值方差变换等), 但关节到关节的映射更为复杂, 单纯前向网络 g 无法确保在反变换回原始分布时依然可以保持可微性, 因为对复杂的非线性函数 g 的求逆操作通常是不可解的。为此, 本文改进了第二章2中的 GBC IK 网络。原始 GBC 编码器 $g^{IK} : \mathbb{P} \rightarrow \mathbb{A}$ 通过 Transformer 编码器架构强制连杆位置一致性并将轴角表示转换为 DoF 动作。本文通过添加一个与编码器设计对称的解码器 $f_{recon} = (g^{IK})^{-1} : \mathbb{A} \rightarrow \mathbb{P}$ 将其扩展为自编码器 (AutoEncoder)^[81], 并使用以下两个损失函数联合训练:

$$\begin{aligned} L^{Recon} &= \|p - f_{recon}[g^{IK}(p)]\|_2^2, \\ L^{FK} &= \|\mathbf{FK}^{hn}(p) - \mathbf{FK}^{hn}(f_{recon}[g^{IK}(p)])\|_2^2. \end{aligned} \quad (4.2)$$

其中, L^{FK} 目标确保即使在难以精确重建轴角 p 的情况下 (例如由于欠驱动特性), 通过 $\mathbf{FK}$ 导出的位置仍能与原始动作匹配。最终得到的 f^{Recon} 包含逐维变换、IK 网络计算及坐标变换等, 具备在线计算能力且完全可微, 能够从 x^{hn} 高保真地重建 x^{hm} , 为后续的知识蒸馏奠定了基础。

此外, 本文利用 HumanML3D 的处理技术 (切片、平滑等) 增强了原始数据源^[77], 并扩展了第二章2中的所使用的前向运动学库以自动处理末端执行器, 同时增加了可微镜像映射。这确保了 HumanoidML3D 既适用于控制, 又能高保真地重建 HumanML3D, 且仅需特定的机器人配置文件 (通常为 URDF 模型)。

4.2.2 动作扩散模型

基础去噪模型 建立数据流程后, 核心任务是条件引导的动作生成。MDM^[34]将人形动作生成建模为去噪扩散概率模型 (DDPM)^[78], 为此提供了坚实的基础。扩散过程被建模为马尔可夫加噪过程 $\{x_t\}_{t=0}^T$, 其中 x_0 是来自数据集的长度为 N 的动作序列, T 是总加噪步数。条件概率分布为:

$$q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_{t-1}, (1 - \bar{\alpha}_t)\mathbf{I}), \quad (4.3)$$

其中 $\bar{\alpha}_t \in (0, 1)$ 为固定超参数。当 T 较大时, 可近似认为 $x_T \sim \mathcal{N}(0, \mathbf{I})$ 。本文沿用 MDM 的方法逆转此过程, 从 x_T 去噪以重建 x_0 。不同于预测噪声 ϵ , 本文遵循 Ramesh 等人^[82]的方法直接预测原始序列 $\hat{x}_0$ 。简单的优化目标^[78]为:

$$L^{simple} = E_{x_0 \sim q(x_0|c), t \sim [1, T]} [\|x_0 - G(x_t, t, c)\|_2^2], \quad (4.4)$$

基础扩散 Transformer (DiT) 模型 本文的基线模型是 MDM 中的 DiT 编码器^[34]。然而, 为实现自回归预测, 参考^[76,83], 本文设计了一个 Transformer 解码器 (图 4.3)。




图 4.3 Diffusion Transformer 架构。

Figure 4.3 Structure of Diffusion Transformer (DiT).

在每一步 t ，模型接收清晰的前缀 x_{pref} 和噪声序列 x_t 。HumanoidML3D 输入通过分离函数分解为关节组和连杆组，分别嵌入后拼接作为解码器输入，同时保持前缀和序列长度固定。采用这一 Decoder 架构的优势在于其通过时序掩码强制靠前时间步的动作无法看到靠后时间步的信息，保障了连续自回归生成的因果性。

模型的引导条件被视作不同于动作信息的额外模态，通过交叉注意力机制注入。文本条件 c_{text} 使用 DistilledBERT^[62] 编码并投影到 $\mathbb{R}^{N_{tokens}, d_{model}}$ ，其中 d_{model} 是 Transformer 的维度。遵循^[76]，本文添加了末端执行器位置条件 $c_j \in \mathbb{R}^3$ （基座或执行器 j 相对于初始帧的最终姿态）。根据 ClosD^[76] 的改进，该目标在任务局部坐标系中进行条件化。布尔标志用于控制此信号的存在，目标的可达性通过航向角 θ_j 和高度约束来保证。该条件也被投影到与文本条件相同的维度，随后与时间及文本嵌入融合（通过拼接或相加），形成 DiT 的最终特征向量。

辅助损失 标准 MDM^[34] 包含基础几何损失（如关节位置、足部接触等），本文针对机器人运动学对其进行了调整，并新增了两项运动学损失（图 4.4）。首先，改进的目标位置 MSE 损失 (L^{targ}) 计算执行器 j 的相对位置和航向与其目标 c_j 和 θ_j 的一致性。位置和方向均通过 MSE 进行惩罚，其中角度的 MSE 采用角度差形式而非原始




图 4.4 动作生成框架训练模式

Figure 4.4 Motion generation training modes.

值。

$$L^{targ} = \sum_{j \in J} [\lambda_p \|\mathbf{FK}^{hn}(\hat{x}_0)_j - c_j\|_2^2 + \lambda_t \|\theta^{hn}(\hat{x}_0)_j - \theta_j\|_2^2], \quad (4.5)$$

其次，由于关节（DoF）和连杆的数量并不相同（大部分连杆定义的坐标系中心是重合的，全部计算会造成信息冗余，不利于高效的自回归），本文提出了数据一致性约束。这确保了关节和连杆信息所代表的运动学特征在去噪过程中保持一致。否则，模型容易导致关节运动特征发散（因为低维 DoF 特征仅占总数据维度的一小部分，回归效果可能不理想；即使 L^{simple} 很小，实际关节差异也可能很大）或训练收敛缓慢。本文利用第二章2中的前向运动学 $\mathbf{FK}$ 检查来自关节表征 (x^{joint}) 和连杆表征 (x^{link}) 的特征是否一致。利用 $\mathbf{FK}(x^{joint})$ 和 $\mathbf{ReCon}(x^{link})$ 分别从这两个信息源重建目标位置，最终的一致性损失为：

$$L^{cons} = \|\mathbf{FK}((\hat{x}_0)^{joint}) - \mathbf{ReCon}((\hat{x}_0)^{link})\|_2^2, \quad (4.6)$$

流匹配 (Flow Matching) 尽管扩散概率模型 (DPM) 在重建方面表现出色，但其复杂的 ODE/SDE 求解限制了推理速度，而推理速度对于实时控制至关重要。虽然

DDIM(Deep Denoising Implicit Model)^[79]提供了一种减少采样步数的方法，但其求解过程仍然效率欠佳，同时求解 SDE 需要大量的循环运算，这对于高 batch size 的强化学习环境是明显的劣势。在此背景下，流匹配 (FM)^[41]作为一种扩散变体应运而生。FM (具体而言是条件流匹配, Conditional Flow Matching, CFM) 通过学习确定性的连续归一化流 (Continuous Net Flows, CNFs)^[84]，允许 ODE(Ordinary Differential Equations) 求解器在极少步数内恢复原始序列 $x_1 \sim q(x_1)$ (对应 DPM 中的 x_0)。

其相应的条件概率路径定义为：

$$p_t(x | x_1) = \mathcal{N}(x | \mu_t(x_1), \sigma_t(x_1)^2 \mathbf{I}), \quad (4.7)$$

其中 $t \in [0, 1]$ ， $\mu_t : [0, 1] \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ 和 $\sigma_t : [0, 1] \times \mathbb{R} \rightarrow \mathbb{R}_{>0}$ 分别表示随时间变化的均值和方差。在 $t = 0$ 时， μ 和 σ 分别为 0 和 1；在 $t = 1$ 时，分别为 x_1 和 σ_{min} 。CFM 学习目标向量场 $u_t = \frac{d\psi_t}{dt}$ ，其中 ψ_t 是路径 $x_t = \psi_t(x_0)$ (注：FM 中的 x_0 为初始噪声)。网络 v_t 的 CFM 损失为：

$$L^{CFM}(\theta) = \mathbb{E}_{t, q(x_1), p(x_0)} \left[\|v_t(\psi_t(x_0)) - \frac{d}{dt}\psi_t(x_0)\|_2^2 \right], \quad (4.8)$$

在实践中，这被简化为线性插值 ($\sigma_{min} = 0$)：

$$\mu_t(x_1) = tx_1, \text{ 以及 } \sigma_t = 1 - t. \quad (4.9)$$

这使得 ODE 求解极为高效。方程 (4.9) 中的轨迹可整理为：

$$\psi_t(x_0) = (1 - t)x_0 + tx_1, \quad (4.10)$$

类似于 DPM 中的 $\hat{x}_0$ 预测^[82]， x_1 (即 DPM 中的 $\hat{x}_0$) 可以直接从网络输出计算得出。这一设计使得所有 DPM 设计的辅助损失均可直接复用。 v_t 的架构继承自 DiT，仅将时间嵌入从离散改为连续。因此，本框架兼容支持 DPM 和 CFM 两种训练模式。

模型训练设计 本文的扩散模型训练流程如图 4.4 所示。在“直接扩散”模式 (右图) 中，从 HumanoidML3D 采样 (动作, 文本) 对，以及 DPM 的时间步 $t \in [0, T]$ 或 FM 的 $t \in [0, 1]$ 。采样的序列长度为 $N_p + N_s$ (分别为前缀和目标长度)，并在时间上进行分割。采样的文本条件 c_{text} 用于重建目标序列 $\hat{x}_0$ (对于 FM 为 x_1)。

然而，MDM 是一项高度成熟的工作。从零开始训练 Humanoid MDM 无法利用在复杂人体数据上训练出的模型所具备的优良先验 (如足部接触、动作平滑度、姿态稳

定性)。知识蒸馏 (KD)^[65]使我们能够迁移这些优化的物理先验。此外, HumanoidMDM 的数据维度随 DoF 和连杆数量变化, 这意味着扩散训练的标准差可能无法充分描述数据分布。KD 也解决了前述由低 DoF 维度引起的数据发散和训练困难问题。

本文设计的 KD 分支如图 4.4 (左图) 所示。目前, 该分支仅支持 DPM 模式, 因为参考的预训练 MDM 是基于 DPM 的 (若有合适的预训练 CFM 模型, 此方法亦完全可迁移至 CFM)。

在 KD 模式下, 采样 x_0^{hn} 并加噪至 x_t^{hn} , 然后通过重建函数 f^{Recon} 转换为 x_t^{hm} 。冻结的预训练 MDM G_{ref} 输出重建的 $\hat{x}_0^{hm}$, 而目标 DiT G 输出恢复的 $\hat{x}_0^{hn}$ 。接着对该输出也应用 f^{Recon} , 得到 $\hat{x}_0^{hn \rightarrow hm}$ 。主损失函数从 L^{simple} 替换为以下软标签损失 (Soft Label Loss):

$$L^{soft} = \|f^{Recon}(G(x_t^{hn})) - G_{ref}(f^{Recon}(x_t^{hn}))\|_2^2, \quad (4.11)$$

4.2.3 轨迹规划与闭环控制




图 4.5 动作生成框架控制器模式对比。

Figure 4.5 Comparison of diffusion controller modes.

尽管扩散模型生成了运动学上合理的动作, 但将这些参考转化为可执行的动作仍具挑战性。扩散生成的动作缺乏动力学感知, 难以直接转化为控制策略 π 。为填补这一空白, 本文采用了第三章3所述 GBC 框架中的 MLP 模仿学习策略 π_θ 作为底层控制器, 由于 MLP 对计算负担更低且参数占用更小, 更适合与显存占用较多的

扩散模型进行融合实验。该策略在 RL 环境中使用参考动作 L2 奖励和 AMP^[28]对抗奖励进行训练。它以机器人状态和参考动作（DoF 位置/速度、根节点状态等）为输入，输出 PD 目标。由于 π_θ 是在第二章中重定向的 AMASS 数据上训练的，因此与 HumanoidML3D 格式完全兼容。这使得 π_θ 能够修正扩散规划与动力学执行之间的物理差异，从而实现针对不同机器人配置的扩散控制。

算法 4.1 扩散模型预测控制 (Diffusion-MPC) 循环

算法 4.1 Diffusion-MPC Control Loop

Require: 生成器 $g_{CFM}(v_\theta, \cdot)$, 策略 π_θ , 频率 $f_{RL}, f_{diff}, f_{MPC}$

Require: 长度 N_p, N_s ; 任务 $C_{text}, \mathcal{R}_{task}$; 比率 $\gamma_{freq} \leftarrow f_{diff}/f_{RL}$

Require: 实时假设: $t_{gen} < T_{MPC} \ll T_s/2$

```

1: 全局变量:  $x$  (原子变量),  $\mathcal{H}$  (双端队列,  $N_p$ ),  $T_{ref}$  (原子变量)
2:  $s_0 \leftarrow \text{EnvReset}(); \mathcal{H}.\text{fill}(s_0)$ 
3:  $c \leftarrow (\text{Sample}(C_{text}), \text{SampleTarget}(\mathcal{R}_{task}, s_0))$ 
4:  $x \leftarrow g_{CFM}(v_\theta, c)$  ▷ 初始生成 (无前缀)
5:  $T_{ref} \leftarrow 0$  ▷ 跟踪索引 (RL 步骤)
6: 并发启动: RL 与 MPC
7: procedure RL ▷ 线程 1: RL 控制 while Training do
8:    $t_{ref} \leftarrow \text{Read}(T_{ref})$ 
9:    $s_{target} \leftarrow \text{Read}(x)[\min(\lfloor t_{ref} \cdot \gamma_{freq} \rfloor, N_s - 1)]$ 
10:   $a_t \leftarrow \pi_\theta(\text{ObserveEnv}(), s_{target})$ 
11:   $s_{t+1} \leftarrow \text{StepEnv}(a_t)$ 
12:   $\mathcal{H}.\text{push}(s_{t+1})$  ▷ 更新历史
13:   $\text{Increment}(T_{ref})$ 
14:   $\text{Wait}(T_{RL})$  ▷ 等待  $T_{RL}$ 
15:
16:
17: procedure MPC ▷ 线程 2: MPC 重规划 while Training do
18:    $\text{Wait}(T_{MPC})$  ▷ 等待  $T_{MPC}$ 
19:    $t_{start} \leftarrow \text{time}()$ 
20:    $x_{pref} \leftarrow \text{Downsample}(\mathcal{H}, N_p, f_{diff})$ 
21:    $c \leftarrow (\text{Sample}(C_{text}), \text{SampleTarget}(\mathcal{R}_{task}, \mathcal{H}))$ 
22:    $x_{new} \leftarrow g_{CFM}(v_\theta, (x_{pref}, c))$  ▷ 自回归
23:    $t_{gen\_s} \leftarrow \text{time}() - t_{start}$  ▷ 测量延迟
24:    $\text{Write}(x, x_{new})$  ▷ 覆盖全局轨迹
25:    $\text{Write}(T_{ref}, \lfloor t_{gen\_s} \cdot f_{RL} \rfloor)$  ▷ 重置索引
26:
27:   =0

```

采样器对比 本扩散模块支持三种采样模式：1000步 DDPM、10步 DiP/DDIM 采样器^[76]和4步 CFM (Euler) 求解器。1000步 DDPM 非实时，生成9.8秒序列（196帧 @ 20FPS）需数秒。10步 DiP 采样器虽快，但在扩展到并行 RL 训练所需的大批量（如4096个环境）时性能显著下降。相比之下，CFM 求解器的延迟与批次大小无关（batch-agnostic），使其成为实时、大规模并行闭环控制的唯一可行方案。

控制模式 基于上述分析，本文设计了三种控制模式，如图4.5所示。**DDPM**：由于采样延迟过高（1000步），仅能进行开环运行，生成单一固定的参考序列供 RL 策略跟随。**DDIM**：通过将上一条执行轨迹作为自回归前缀，实现了低频（< 2 Hz）闭环控制。高延迟可能导致跟踪误差。**流匹配 (FM)**：作为实时（高达50Hz）的扩散模型预测控制（Diffusion-MPC）运行，使用生成模型作为预测核心。它利用即时反馈以极低的延迟修正轨迹。为优化计算成本，实际实现中采用了较低的频率，但仍显著快于 DDIM 控制器。1000步 DPM 仅限于开环控制（生成一条完整轨迹供 π_θ 跟踪）。DiP 控制器可通过将上一条轨迹的末端用作下一条的 x_{pref} 来生成连续序列，但其延迟问题仍阻碍了与 RL 的高效协同训练。

然而，CFM 高效且对批次大小不敏感的 ODE 求解器实现了真正的实时扩散模型预测控制（Diffusion-MPC）^[85]。如算法4.1详述，该方法运行两个并发循环：(1) 高频 RL 策略（ π_θ ，频率 f_{RL} ）跟踪共享的全局轨迹 x 。(2) 低频 MPC 循环（频率 f_{MPC} ）通过采样新条件（ c_{text}, c_{loc} ）并使用当前执行历史 $\mathcal{H}$ 作为自回归前缀 x_{pref} ，不断重规划该轨迹 x 。

此方法的关键在于生成延迟满足 $t_{gen} < T_{MPC} \ll T_s/2$ 。为补偿此延迟，在写入新轨迹后，RL 策略的跟踪索引（ T_{ref} ）立即重置为等效的 RL 步数延迟（ $\lfloor t_{gen} \cdot f_{RL} \rfloor$ ）（算法4.1）。这种延迟补偿结合基于实际执行历史 $\mathcal{H}$ 的重规划，有效减轻了跟踪误差并确保了动作的连续性。

4.3 实验结果

本文的实验环境基于 IsaacLab^[86]构建。通过继承上一章所述 ‘ObservationManager’ 类（如图4.1所示），本文实现了 Diffusion-MPC 控制器。这一自定义管理器允许 RL 策略 π_θ 实时访问生成的轨迹 x 。与那些重定向人类扩散模型的方法不同，本方法直接生成机器人的原生动作。这一特性确保了来自 π_θ 的历史信息 $\mathcal{H}$ 与用于生成前缀 x_{pref} 的扩散数据是严格同步的，从而彻底消除了转换带来的延迟。

4.3.1 实验设计

4.3.1.1 数据集设计评估

针对数据重定向模块, 本文主要评估图4.2中所设计四个表征的必要性。其中根节点表征和关节局部表征对于运动而言是不可或缺的, 因此不可移除。实验主要验证通过前向运动学和环境设置可计算的关节全局表征和接触表征对于动作-文本特征匹配的影响, 实验采用 T2M^[21]所设计的运动学空间匹配框架, 通过评估动作-文本双向检索任务中的 R-Precision (Top-k) 和中位排名 (Median Rank), 可以直观地量化不同数据表征对模态对齐的影响。实验控制训练时间为 40 轮次, 并评估如下三组实验设置的差异

- **无空间语义 (Exp 1):** 实验的最低控制基础版本, 仅保留根节点特征和关节局部特征。
- **无接触信息 (Exp 2):** 仅移除足部接触的 2 维度数据。
- **完整数据 (Exp 3):** 保留了完整的数据集设计方案。

4.3.1.2 扩散模块评估

针对扩散模块, 本文在三种不同的机器人配置上进行了文本生成动作 (Text-to-Motion) 任务的测试, 分别为: Unitree H1-2、Unitree G1 以及 Fourier GR1。本文报告了 DiT 架构在对应这三种配置的 HumanoidML3D 数据集上训练后的性能表现, 所有指标均为三种机器人的平均值。实验评估了以下几种训练方法:

- **MDM-1000:** 采用原始 MDM 编码器架构^[34], 扩散步数设置为 $T = 1000$ 。
- **MDM-KD-1000:** 在与 MDM-1000 相同的条件下, 通过知识蒸馏 (Knowledge Distillation, KD) 技术, 从预训练的 MDM 模型中蒸馏得到的架构。
- **DiP-10:** 遵循 DiP 方法^[76], 但使用了本文设计的自回归解码器。设置前缀长度 $N_p = 20$, 生成长度 $N_s = 40$, 其余控制变量与 DiP 原论文保持一致。
- **DiP-KD-10:** 通过知识蒸馏从预训练的 ClosD 模型中训练得到的 DiP-10 模型。
- **FM-Euler-4 / FM-Midpoint-10:** 使用流匹配 (Flow Matching) 训练的解码器模型 (参数量与上述模型一致), 分别对比了 4 步 Euler ODE 求解器与 10 步 Midpoint 求解器的性能。

所有模型均在单张 NVIDIA GeForce RTX 4090D GPU 上进行训练, 最大训练步数为 350,000 步。单个模型的训练时长均未超过 12 小时。

4.3.1.3 轨迹规划模块评估

针对轨迹规划模块, 本文使用配置为 Fourier GR1 的预训练 GBC 策略 π_θ , 验证了 Diffusion-MPC 控制器的执行性能。实验对比了**零样本 (zero-shot)** 预训练策略 (即直接执行) 与经过**微调 (fine-tuned)** 后的策略的跟踪性能。微调过程在包含 $n_{envs} = 4096$ 个环境的 RL 场景中共进行了 2000 次迭代, 使用相同的硬件设备, 且全过程在 4 小时内完成。由于 Diffusion-MPC 控制器始终能够提供稳定的参考输入, RL 策略 π_θ 被简化为一个基础的多层感知机 (MLP) 网络, 无需处理参考轨迹不可用的极端情况。

4.3.2 数据集表征完整性的消融分析

为了验证本文提出的 HumanoidML3D 数据规范中各组成部分的必要性, 特别是连杆状态 (Link Representation) 与接触状态 (Contact Representation) 对于跨模态语义对齐的贡献, 我们基于 Fourier GR1 机器人的数据集进行这一消融实验。其中, 完整目标数据的组成维度为 265 维: 前 4 维表示根节点信息, 对应 32 自由度的 4 至 68 维为转换为正余弦连续值的关节局部表示, 68 至 263 维是关节全局表示, 最后 2 维为接触信息表示。采用编码器的隐空间维度均为 1024, 学习率和 Batch size 的超参数完全一致, 实验得到的统计结果如下:

表 4.2 不同数据表征组合对 Text-Motion 跨模态检索性能的消融实验结果
Table 4.2 Ablation on different combination of dataset features

配置 (Config)	包含模块	Text-to-Motion			Motion-to-Text		
		R@1 ↑	R@3 ↑	MedR ↓	R@1 ↑	R@3 ↑	MedR ↓
Exp 1 (无空间语义)	M1 + M2	5.90	13.54	17.0	5.21	14.24	16.0
Exp 2 (无接触信息)	M1 + M2 + M3	6.25	15.62	15.0	6.94	16.55	16.0
Exp 3 (完整信息)	All (M1-M4)	6.44	17.20	16.0	7.75	17.59	15.0

实验结果表明, 数据集中不同特征组对文本-动作匹配任务具有不同程度的贡献。首先, 在移除脚接触特征 (2 维) 后, 文本到动作检索 (T2M) 的 R@1 准确率从 6.44% 下降至 6.25%, 相对下降 2.9%; 动作到文本检索 (M2T) 的 R@1 准确率从 7.75% 下降至 6.94%, 相对下降 10.5%。这表明脚接触信息虽然维度较少, 但对运动语义理解, 特别是在动作到文本的检索任务中起到了重要的辅助作用。其次, 当进一步移除关节位置和速度等空间特征 (195 维) 后, 模型性能出现显著下降: T2M 的 R@1 和 R@3 分别下降 8.4% 和 21.3%, M2T 的 R@1 和 R@3 分别下降 32.8% 和 19.0%。这一结果充分说明, 空间特征是文本-动作匹配的关键信息, 仅依靠关节角度的正余弦编码

(68 维) 无法充分表达运动的空间特性和动态特征。综上所述, 本文提出的多层次数据表示方案, 包含根节点运动状态、关节角度、空间位置与速度、以及脚接触状态等互补特征, 是实现高质量文本-动作匹配的必要条件, 验证了数据集设计的合理性和有效性。

4.3.3 扩散模型性能分析

表 4.3 文本生成动作任务的主要实验结果 (所有机器人数据集的平均值)

Table 4.3 Main results for text-to-motion generation, averaged across all robot datasets.

方法	R 精度 (Top 3)↑	FID ↓	多样性 →	滑步 [mm]↓	总耗时 [s] (bs 1/512/4096) ↓	最大帧率 (Per Frame) ↑
GT (真值)	0.808	0.004	19.814	206×10^{-3}	-	-
MDM Original ^[34]	0.719	0.423	19.02	330×10^{-3}	-	2.5
DiP Original ^[76]	0.777	0.283	18.42	629×10^{-3}	0.092/3.017/27.882	3500
MDM-1000 (本文)	0.717	0.822	22.82	15.05×10^{-3}	7.740/-/-	4.2
MDM-KD-1000 (本文)	0.762	0.465	26.91	4.42×10^{-3}	7.740/-/-	4.2
DiP-10 (本文)	0.745	6.037	19.47	11.59×10^{-3}	0.084/2.862/24.401	476.19
DiP-KD-10 (本文)	0.771	3.852	18.76	6.94×10^{-3}	0.084/2.862/24.401	476.19
FM-Euler-4 (本文)	0.783	1.578	19.23	16.01×10^{-3}	0.024/0.019/0.019	1.358×10^6
FM-Midpoint-10 (本文)	0.799	0.804	20.29	14.27×10^{-3}	0.093/0.080/0.080	3.225×10^5

本文在 HumanML3D 基准上对扩散模块进行了全面评估。遵循 Guo 等人^[87]的方法, 本文训练了一个文本-动作编码器 (Glove) 以建立真值 GT 指标^①。报告的具体指标包括 **R 精度 (R-precision)** (用于衡量文本与动作的相似度)、**FID** (用于衡量分布相似度) 以及**多样性 (Diversity)** (用于衡量动作的丰富程度)。

此外, 本文还报告了源自 PhysDiff^[88]的物理指标, 包括**穿模 (Penetration)**、**悬浮 (Floating)** 和**滑步 (Skating)** (单位: mm)。由于本文采用的高效 GBC 流程使用了固定的参考高度, 导致穿模和悬浮指标在这一预 RL 阶段尚不准确 (这些误差将在后续阶段由 RL 策略利用接触数据进行修正)。然而, 鉴于本模型生成的轨迹具备运动学感知能力, 本文重点报告**滑步**指标, 以验证模型在无需交互反馈的情况下生成物理上合理的动作序列的能力。

为了评估生成的实时性能, 本文还报告了在不同批次大小 (1, 512, 4096) 下生成完整序列 (长度为 40) 所需的**总时间 (Total time, ms)**, 以及最大单帧推理的**帧率 (FPS)**。对于先前工作的 FPS 数据, 本文直接引用了其原始论文中的数值。

表 4.3 中的真值 (GT) 指标证实, HumanoidML3D 格式凭借其更低维的数据表征, 实现了更强的文本-动作相关性。同时, GBC 重定向过程也在本质上提升了数据的多样性。

① 为综合考量不同机器人配置及匹配器训练带来的差异, 此处报告的指标为所有数据集的平均值。

实验结果表明, 基于原始 MDM 架构的模型 (MDM-1000) 虽然能够逼近目标分布 (在知识蒸馏 KD 下具有更好的 FID 表现), 但在 R 精度上的提升非常有限, 且深受生成时间过长这一问题的困扰。DiP 的实现虽然在 FID 指标上显示出一定的偏差, 但仍能良好地建模动作的时间特征, 且知识蒸馏 (KD) 进一步提升了其生成质量。然而, DiP 的推理速度受到大批量尺寸的严重制约 (瓶颈效应明显), 这表明其与大规模并行 RL 训练的兼容性较差。

相比之下, 本文提出的流匹配 (FM) 模型在 R 精度、FID 和多样性方面均表现出卓越的性能。至关重要的是, 其推理性能与批次大小无关 (如表 4.3 中 FM-Euler-4 一行所示), 这使其成为实时控制的理想选择。此外, 本文报告的滑步指标比未修正的基线模型 (如 DiP Original) 好一个数量级, 这充分证实了 GBC 重定向流程中运动学优化的有效性。




图 4.6 模型生成轨迹概览

Figure 4.6 Diffusion model generated trajectories

图4.6展示了是实验所用的扩散模型 (FM 版本) 在不同机器人型号和不同提示词下生成的轨迹, 分别展示了 H1-2 的拳击 (左上)、H1-2 的举手 (中上)、Fourier GR1 的踢腿 (右上)、H1 的快速行走 (左下)、G1 的绕圈行走 (中下) 和 G1 的侧踢 (右下)。实验表明, 目前扩散模型生成的序列平滑且稳定, 符合人类的动作特征, 且其运动学空间特征也十分自然, 适宜于实机部署。

4.3.4 训练范式与超参数消融实验

针对基于 Flow Matching (FM) 的生成模型在机器人动作生成领域的应用研究尚处于起步阶段, 直接套用图像生成领域的范式未必最优。受 He 等人关于去噪模型特征学习能力的研究^[89]启发, 本文对比了多种训练配置以确定最佳的超参数组合。此外, 本文参考了 Pi0^[90] 和 Gr00t^[91] 两个在机器人 VLA (Vision-Language-Action) 领域的代表性工作, 针对公式 (4.10) 中的时间步 t 的采样分布进行了深入探究。

4.3.4.1 预测目标与损失函数的对比分析

为了验证 He 等人^[89]提出的关于去噪模型预测对象对还原效果的影响, 本文设计了四组对比实验。评估指标除了常规的 Top-3 R-Precision 和 FID 外, 针对 Baseline 实验中观察到的动作抖动现象, 本文额外引入了**能量比率** E_r 。 E_r 定义为生成动作的能量与真实动作能量的期望之比, $E_r = \mathbb{E}[\mathcal{E}_{\text{exp}}] / \mathbb{E}[\mathcal{E}_{\text{baseline}}]$, 其中能量计算方式为动作序列加速度的平方和: $\mathcal{E} = \sum \|\ddot{x}\|^2$ 。

四类对比实验设置如下:

1. **Pred u_t Loss u_t** : 这是最基础的 FM 预测范式。DiT 模型直接输出对速度场 u_t 的预测, 损失函数采用 MSE 衡量预测值 $\hat{u}_t$ 与目标速度场 u_t 之间的误差。
2. **Pred u_t Loss x_1** : 模型预测速度 u_t , 但在计算损失时, 利用公式 (4.10) 将其积分或映射转换为对数据样本 x_1 的估计值, 并与去噪前的真实值 (Ground Truth) 进行比较。这种方式更关注最终生成结果的空间位置精度。
3. **Pred x_1 Loss u_t** : 模型直接预测去噪后的原始数据 $\hat{x}_1$, 但在计算梯度时, 将其转换回对应的速度场 $\hat{u}_t$ 并计算速度场的损失。这种配置让网络在学习数据分布表征 (预测 x_1) 的同时, 通过速度场损失约束其变化轨迹的平滑性, 试图在语义还原与动力学一致性之间取得平衡。
4. **Pred x_1 Loss x_1** : 在非 FM 模型 (如经典 DDPM) 中, 这是 MDM 系列最标准的实现。模型直接预测目标数据 $\hat{x}_1$ 并基于此计算损失。He 等人的研究^[89]指出, 在学习的隐空间维度较大或特征较为复杂的情况下, 这一配置往往能取得最为理想的预测效果。

实验结果如表 4.4 所示。结果表明, 采用 Pred x_1 Loss x_1 的配置在所有指标上均表现最优。特别是能量比率 E_r 降至 0.15, 显著缓解了 Baseline 中存在的动作抖动问题, 且模型收敛速度最快 (100k 步)。

表 4.4 不同训练范式下的生成质量与收敛性能对比

Table 4.4 Comparison of generation quality and convergence under different training paradigms

配置 (Config)	Top-3 R-Prec ($\uparrow$)	FID ($\downarrow$)	Energy Ratio (E_r)	收敛轮数	Loss
Pred u_t Loss u_t	0.68	7.44	1.00	200,000	0.24
Pred u_t Loss x_1	0.73	4.28	0.62	140,000	0.07
Pred x_1 Loss u_t	0.75	2.76	0.34	100,000	0.18
Pred x_1 Loss x_1	0.77	1.49	0.15	100,000	0.05

注：收敛轮数指模型验证集 Loss 不再下降时的训练步数。

4.3.4.2 时间步 t 的采样分布策略

在 Flow Matching 的训练过程中，时间步 $t \in [0, 1]$ 的采样分布直接决定了模型在不同噪声水平下的训练权重。本文对比了以下三种采样形式：

1. **均匀分布 (Uniform Distribution)**: 采样方式为 $t \sim U[0, 1]$ 。这也是部分基础实验 (Baseline) 采用的配置。需要注意的是，采样范围不包含 $t = 1$ ，这是因为在由预测的 x_1 推导流匹配向量场 u_t 时，根据 FM 的插值公式 $x_t = tx_1 + (1 - t)x_0$ ，其梯度表达式存在如下关系：

$$u_t = \frac{x_1 - x_t}{1 - t}, \quad (4.12)$$

显而易见，分母项 $(1 - t)$ 会导致在 t 趋近于 1 时数值不稳定，进而引发训练发散。

2. **Beta 分布**: 该分布策略在 Pi0^[90] 的工作中被提出。鉴于机器人的运动控制对稳定性有极高要求，动作生成的误差往往在扩散过程的末期（即 t 接近 0 的去噪初期）影响最为显著，因此需要赋予该区间更大的训练权重。Beta 分布的概率密度函数表达式如下：

$$p(t) = \frac{t^{\alpha-1}(1-t)^{\beta-1}}{B(\alpha, \beta)}, \quad \text{其中 } B(\alpha, \beta) = \int_0^1 u^{\alpha-1}(1-u)^{\beta-1} du. \quad (4.13)$$

参考 Pi0 的配置，本文设定 $\alpha = 1.0, \beta = 1.5$ ，并设置截断阈值 $\text{cutoff} = 0.999$ 以避免端点处的数值问题。

3. **Logit-Normal 分布**: 在 Gr00t^[91] 中，特征的时间步采样遵循 $\text{logit}(t) \sim \mathcal{N}(\mu, \sigma^2)$ 。这是因为在生成过程的中间阶段（ t 居中时），数据从纯噪声向有意义的动作流形转变，此时的动力学变化最为剧烈且包含最多的语义信息，因此应将采样重心集中在这一区域。作为一个典型的偏态分布，Logit-Normal 具有重尾 (Heavy-tailed) 的优秀性质，能够确保在覆盖整个时间轴的同时，重点关注高梯度的中

间区域。实验中，本文取 $\mu = -0.8, \sigma = 0.8$ 。

基于前文实验结论，即直接预测 x_1 并计算 x_1 的损失是当前最适合的 Flow Matching 训练范式，本文以此为基线配置，进一步定量评估了不同时间步 t 采样分布对模型性能的影响。

实验结果如表 4.5 所示。从表中数据可以看出，不同采样策略对训练效率和生成质量均有显著影响：

- **Uniform (均匀分布)**：作为基准，其各项指标表现处于中等水平。
- **Logit-Normal (Gr00t)**：该分布取得了最低的训练损失 (0.03)，推测其分布特性可能更贴合某些长尾数据分布。然而，其收敛速度与均匀分布持平，且在生成质量指标 (FID) 上不如 Beta 分布。
- **Beta (Pi0)**：实验发现，Pi0 所采用的 Beta 分布配置展现出了最高的训练效率。尽管其 Loss 下降幅度略逊于 Logit-Normal，但在收敛速度上具有绝对优势（仅需 70,000 步），且在 Top-3 R-Precision (0.79) 和 FID (0.80) 两项关键性能指标上均达到了最佳水平。这验证了在机器人控制任务中，增加对低噪声区间 (t 接近 0) 的训练权重有助于显著提升动作生成的精度与稳定性。

表 4.5 不同时间步采样分布对模型性能的影响

Table 4.5 Impact of different time step sampling distributions on model performance

采样分布 (Sampling)	Top-3 R-Prec ($\uparrow$)	FID ($\downarrow$)	收敛轮数	Loss
Uniform (基准)	0.77	1.49	100,000	0.05
Logit-Normal (Gr00t)	0.79	1.38	100,000	0.03
Beta (Pi0)	0.79	0.80	70,000	0.04

注：所有实验均基于 Pred x_1 Loss x_1 范式进行。

4.3.5 闭环控制与动作追踪性能评估

为了验证本文提出的生成与控制框架在物理环境中的实际执行能力，本节进一步在 Isaac Sim 仿真环境中评估了系统在闭环条件下的追踪成功率与运动质量。实验设置了以下三组对比实验以验证不同模块的贡献：

1. **MDM-RO (基准)**：MDM Retargeting Open-loop。作为基础对照组，该方法直接使用 MDM 模型离线生成的动作序列，经重定向 (Retargeting) 后作为固定参考轨迹，输入到底层控制器进行开环追踪。
2. **MUJICA-O (开环)**：MUJICA Open-loop。该组使用本文微调后的 MUJICA 模型生成动作，但采用开环控制策略，即控制器仅追踪预先生成的轨迹，不涉及在

线重规划。

3. **MUJICA-C (闭环): MUJICA Closed-loop.** 这是本文提出的完整闭环框架。该方法利用 Isaac Sim 中的在线状态反馈，通过 MUJICA 模型进行自回归式的实时重规划，实现了生成与控制的深度耦合。

为了全面考察算法在不同运动特征下的表现，我们选取了以下三组具有代表性的文本提示词进行测试：

- **P1:** “The person is walking in zig-zag pattern.” (折线行走)，主要考察基础移动与转向能力。
- **P2:** “The person is walking in circles.” (圆形行走)，主要考察持续转向与路径保持能力。
- **P3:** “The person is dancing in circles.” (圆形舞蹈)，主要考察复杂全身协调与高动态平衡能力。

实验采用的量化评估指标包括： E_{MPIPE} 表示关节位置追踪误差，单位为弧度 (rad)，反映了机器人实际执行动作与生成参考动作之间的一致性；成功率 (Success Rate, SR) 计算方式为未触发早停机制 (Early Termination) 的环境数占总测试环境数的比例，其中早停通常由动作追踪误差过大或机器人发生跌倒等物理失效触发。

实验结果如表 4.6 所示。可以看出，MDM-RO 基准由于缺乏对机器人本体形态的适应，在所有任务上的追踪误差均较大，且在复杂的舞蹈任务 (P3) 中成功率极低 (仅 7%)。相比之下，本文提出的闭环框架 MUJICA-C 在所有指标上均取得了显著优势。特别是在高难度的 P3 任务中，闭环控制将追踪误差降低至 0.09 rad，并将成功率提升至 91%，充分证明了实时重规划对于处理复杂物理交互的必要性。

表 4.6 不同策略在仿真环境中的闭环追踪性能对比

Table 4.6 Comparison of closed-loop tracking performance in simulation

方法	P1 (折线行走)		P2 (圆形行走)		P3 (圆形舞蹈)	
	E_{MPIPE} (↓)	成功率 (↑)	E_{MPIPE} (↓)	成功率 (↑)	E_{MPIPE} (↓)	成功率 (↑)
MDM-RO (基准)	0.23	0.68	0.34	0.42	0.26	0.07
MUJICA-O (开环)	0.17	0.82	0.23	0.78	0.31	0.64
MUJICA-C (闭环)	0.04	0.97	0.06	0.94	0.09	0.91

注： E_{MPIPE} 单位为 rad；成功率指未触发早停的测试比例。

图 4.7 进一步直观展示了 MUJICA-C 框架在 P3 (舞蹈) 任务上的闭环追踪效果。可视化结果表明，追踪器能够在闭环控制下极好地复现生成的舞蹈动作。与开环生成

相比，闭环机制有效修复了原始生成动作中可能存在的脚部穿透、悬浮以及非自然滑步等物理瑕疵，修正后的轨迹追踪误差明显更低。需要说明的是，为了确保动作更加物理可行，追踪误差在理论上很难降至 0，但这正是系统具备物理感知与修正能力的体现。




图 4.7 MUJICA-C 在 Isaac Sim 下的闭环追踪效果展示
Figure 4.7 Closed-loop tracking results of MUJICA-C in Isaac Sim

4.4 本章小结

本章重点探讨了如何将基于扩散模型的生成式人工智能引入人形机器人控制系统，以赋予机器人理解自然语言指令并生成长程、多样化运动规划的能力。针对现有生成模型应用于机器人领域时面临的“形态鸿沟”、“状态表征异构性”以及“生成与控制频率鸿沟”三大核心挑战，本文提出了一套完整的解决方案，并得出以下主要结论：

首先，为解决形态与表征问题，本章构建了 **HumanoidML3D** 数据规范。利用第二章提出的 **GBC** 框架中的可微正逆运动学网络，本文建立了一套在线可微的数据重构与映射流程。该流程不仅将通用的 **SMPL** 人体数据转化为适配特定机器人构型的本体数据（包含关节、连杆及接触状态），还支持从机器人数据高保真地反向重建人体动作，从而有效弥合了形态差异，并为跨模态语义对齐提供了完整的物理状态表征。实验表明，包含接触与连杆信息的完整数据表征对于提升文本-动作检索精度至关重要。

其次，针对生成模型的训练与实时性问题，本章引入了知识蒸馏与流匹配技术。

通过知识蒸馏,模型成功迁移了在大规模人体数据上预训练的物理先验,显著提升了生成动作的自然度与物理合理性。更为关键的是,针对实时控制需求,本章采用流匹配替代了传统的扩散概率模型。实验结果证实,基于 Euler 求解器的 4 步流匹配模型不仅在生成质量 (FID、R Precision) 上优于传统方法,更实现了与批次大小无关的极低推理延迟,解决了大规模并行环境下的计算瓶颈。此外,通过对比 Kaiming He、Pi0 及 Gr00t 等工作的训练范式,本文确定了以“预测 x_1 计算 x_1 损失”配合“Beta 时间采样分布”的最佳训练策略,进一步提升了模型的收敛效率与生成精度。

最后,本章设计并验证了分层式的 **Diffusion-MPC** 闭环控制架构。该架构让低频运行的扩散模型作为“规划器”进行自回归式的轨迹重规划,与高频运行的 GBC 策略“执行器”协同工作。在 Isaac Sim 仿真环境中的闭环测试表明,该系统能够根据自然语言指令(如折线行走、圆形舞蹈)实时生成并追踪复杂的全身动作。相比于开环基准,闭环控制显著降低了追踪误差,有效修正了滑步、穿模等物理瑕疵,证明了该框架在动态物理环境中的鲁棒性与有效性。

综上所述,本章工作成功构建了一个端到端的、形态无关的且具备实时响应能力的人形机器人生成与控制系统,为实现具身智能体的高层语义理解与底层物理执行的有机统一奠定了坚实基础。

第 5 章 基于大语言模型的辅助训练与 Sim-to-Real 部署框架

5.1 问题引入

本文的前几章致力于构建人形机器人通用控制系统的核心算法模块。第二章提出了自适应重定向技术，解决了异构形态机器人之间的数据共享与迁移问题，构建了高质量的机器人本体数据集；第三章基于 GBC 框架设计了鲁棒的底层执行策略，实现了对参考动作的高保真跟踪；第四章则引入了扩散模型作为高层规划器，赋予了机器人长程动作生成与指令跟随的能力。这一系列工作打通了从“数据”到“规划”再到“控制”的算法链路。

然而，要将这些先进的控制算法真正部署到现实世界中多种构型的机器人上，仍然面临着巨大的工程挑战。随着先进控制算法、物理仿真技术和计算能力的融合，机器人技术虽然取得了显著进步^[92-93]，特别是双足仿人机器人因其拟人化的结构在通用任务中展现出巨大潜力^[94]，但其控制策略的开发门槛依然极高。

目前的控制策略主要依赖于传统的基于模型的控制或强化学习 (RL) 方法^[95]。其中，RL 通过与环境的交互试错来学习复杂的运动技能，在模拟环境中表现尤为出色。尽管如此，RL 算法的训练和部署流程仍然是一项艰巨的任务。设计有效的奖励函数不仅需要深厚的领域知识，还需要针对具体任务目标和现实世界的安全约束进行精细的调整^[96]。这一过程涉及大量的“奖励塑形 (Reward Shaping)”工作，往往依赖于工程师的先验经验和反复试错^[97]，消耗了大量的人力与时间成本。

此外，从仿真到现实 (Sim-to-Real) 的鸿沟是阻碍 RL 策略落地的另一大难题。由于物理仿真无法完美模拟真实世界的动力学特性，仿真中表现优异的策略在真机上往往失效甚至引发安全事故^[98]。虽然域随机化 (Domain Randomization) 等技术试图通过增加鲁棒性来弥合这一差距，但其参数配置同样依赖于专家经验。

为了降低这一过程中的人力负载，将大语言模型 (LLMs) 引入机器人开发流程成了一种极具前景的解决方案。已有研究展示了 LLMs 在代码生成^[99]、动作规划^[100]以及通过反馈改进流程^[43]方面的潜力。然而，目前尚缺乏一个完全自动化的、覆盖从“奖励设计”到“训练监督”再到“真机部署”全流程的统一框架。

针对上述问题，本章提出了 *AnyBipe* 框架——一个面向双足机器人的大语言模型驱动端到端训练与部署系统。该框架旨在利用 LLMs 广博的知识库，自动化地完成奖励函数设计、训练过程监控以及策略的持续优化。如图 5.1 所示，*AnyBipe* 包含三个互

联的模块：LLM 奖励生成、半监督 RL 训练以及自动化评估反馈。特别地，为了解决 RL 训练的冷启动问题，该框架能够无缝集成第三章训练好的 GBC 策略作为参考教师（Teacher Policy），加速新任务的收敛；同时，引入了“同态评估器（Homomorphic Evaluator）”这一新指标，用于量化仿真与现实之间的差距，从而实现安全、高效的 Sim-to-real 闭环部署。




图 5.1 AnyBipe 框架架构图
Figure 5.1 Anybipe framework pipeline.

本章将详细阐述 *AnyBipe* 的设计原理与实现细节，并通过在不同自由度的双足机器人（Limx P1, Unitree H1, Turin Robot）上的实验，验证其在减少人工干预、提升策略性能以及实现自动化 Sim-to-Real 迁移方面的有效性。

5.2 智能化训练与部署框架总体架构

本节将详细阐述 *AnyBipe* 框架的设计细节。该框架旨在通过自动化流程增强奖励函数设计、促进半监督强化学习训练，并实现自动化的评估与反馈闭环。

5.2.1 系统组成与输入要求

作为一个通用的支持框架，*AnyBipe* 由三个相互连接的核心模块组成：LLM 驱动奖励生成模块、教师指导的半监督训练模块以及基于同态映射的评估反馈模块。为了启动该流程，用户需要提供以下基础输入：

- 机器人的 URDF 模型文件；
- 自然语言形式的任务描述（例如“让机器人尽可能快地直线行走”）；
- 基于 Isaac Gym 或 Isaac Lab 的强化学习基础环境（与第三、四章环境兼容）；

- 用于真机部署的控制平台，如 ROS^[101]。

此外，为了弥合仿真与现实的数据差异，本研究在真机端部署了一个运行时数据收集器——状态追踪器（State Tracker）。该组件负责实时采集关键的本体感受数据，包括 IMU 读数、关节位置、速度以及力矩信息，为后续的同态评估提供数据支撑。

5.2.2 形式化定义与算法流程

本研究将 AnyBipe 的引导训练过程建模为一个增强的马尔可夫决策过程 (MDP)，定义为元组 $M = (\mathcal{S}, \mathcal{A}, \mathcal{T}, R, \pi_{ref}, \beta)$ 。其中：

- $\mathcal{S}$ 和 $\mathcal{A}$ 分别表示状态空间和动作空间；
- $\mathcal{T}$ 代表训练环境动态；
- R 是由 LLM 生成的待优化奖励函数；
- π_{ref} 是参考策略（Reference Policy）。此处 π_{ref} 起到了连接前文的关键作用：它可以是第三章中训练好的 GBC 策略，也可以是传统控制算法或简单的人工示教轨迹。
- β 是控制参考策略影响权重的超参数，用于在半监督训练中调节“探索”与“利用”的平衡。

整个框架的执行流程如算法 5.1 所示。利用精心设计的提示工程框架，本研究首先引导 LLM 根据用户提供的模式生成兼顾功能性与安全性的奖励函数代码。随后，这些奖励函数被加载到修改后的 RL 环境中，并在参考策略 π_{ref} 的辅助下进行训练以解决冷启动问题。表现最优的策略将通过同态评估器（Homomorphic Estimator）进行验证，以评估其安全性和 Sim-to-real 迁移性能。最终，所有的评估结果被编译为反馈提示词（Feedback Prompts），用于指导 LLM 在下一轮迭代中修正奖励函数。

5.3 基于思维链的奖励函数自动化演进

本模块的设计建立在 Eureka 算法^[102] 的奖励函数生成机制之上，该机制利用预定义的环境与任务描述 $\mathcal{D}(\mathcal{T})$ ，使 LLM 能够自主地优化奖励函数。然而，Eureka 在初始可用性方面存在不足，往往需要多轮迭代才能生成可运行的训练代码。此外，它容易忽视仿真训练环境 $\mathcal{T}$ 与真实环境 $\mathcal{R}$ 之间的差异，导致生成的奖励函数计算开销大、实际效果差，甚至可能引发未定义的危险行为^[103]。尽管已有研究尝试利用奖励感知物理先验（Reward Aware Physics Prior, RAPP）和 LLM 引导的域随机化^[43] 来改善这一问题，但对于双足行走这类高动态任务而言，现有的安全约束考量仍然不足。

算法 5.1 AnyBiPe 自动化训练与部署流程

```

1: 先决条件: 训练环境  $\mathcal{T}$ , 部署环境  $\mathcal{R}$ , 机器人状态追踪器  $st$ 
2: 输入要求: 环境描述  $\mathcal{D}(\mathcal{T})$ , 提示词集  $p$ , 训练环境评估器  $\mathfrak{E}_{train}$ , 同态评估映射函数  $\mathcal{F}$ , 安全评估标准  $SA$ , MDP 定义  $\mathcal{M}$ , 大语言模型 LLM, 反馈编译器 COMPILE
3: 可选输入: 人工设计的参考奖励函数  $\mathbf{R}_{ref}$ , 参考策略 (如前序章节工作)  $\pi_{ref}$ , 附加提示词  $p_{add}$ , 关键观测因子  $obs_c$ 
4: 超参数: 迭代次数  $N$ , 奖励候选数量  $K$ , 最佳样本比例  $c_{bs}$ , 教师模型系数  $\beta$ , 环境评估系数  $c_e$ , 观测因子系数  $c_{obs}$ 
5: 输入任务: 任务描述  $\mathcal{D}$ 
6:  $\mathbf{R}_{ref} \leftarrow$  若预定义存在 则使用参考奖励 否则为空
7:  $\pi_{ref} \leftarrow \text{RL}(\mathbf{R}_{ref})$  或用户定义策略 若存在 否则为空
   for  $i \leftarrow 1$  到  $N$  do
8:
   

▷ 模块 1: 奖励函数生成


9:  $p_{in} \leftarrow p + p_{add} + p_{feedback}$ 
10:  $\mathbf{R} \leftarrow \text{LLM}(\mathcal{D}, \mathcal{D}(\mathcal{T}), p_{in}, \mathbf{R}_{ref})$ 
11:
   

▷ 模块 2: 半监督 RL 训练


12:  $\Pi, \text{Obs} \leftarrow \mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{T}, \mathbf{R}, \pi_{ref}, \beta)$ 
13:
   

▷ 模块 3: 自动化评估与反馈


14:  $n_{bs} \leftarrow \lceil c_{bs} \cdot K \rceil$ 
15:  $p_{feedback} \leftarrow \text{None}$ 
16:  $\text{Criterion} \leftarrow c_e \cdot \mathfrak{E}_{train}(\Pi) + \sum c_{obs} \cdot \text{Obs}$ 
17:  $\mathbf{R}_{bs}, \pi_{bs} \leftarrow_{\text{Criterion}} (\mathbf{R}, \Pi)$ 
18:  $\hat{\mathbf{R}}_{bs} \leftarrow \mathcal{F}(\mathbf{R}_{bs})$ 
   forall  $\pi, \hat{\mathbf{R}}$  in  $\pi_{bs}, \hat{\mathbf{R}}_{bs}$  do
19:
   

▷ Sim-to-Real 部署

 $\pi_{real} \leftarrow (\mathcal{T} \rightarrow \mathcal{R})(\pi)$ 
20:  $\mathfrak{E}_{sim} \leftarrow \text{EVAL}_{sim}(\hat{\mathbf{R}}(st(O)), \pi_{real})$ 
21:  $p_{feedback} += \text{COMPILE}(p, \mathfrak{E}_{sim})$ 
   if  $SA(\mathfrak{E}_{sim})$  为  $True$  then
   —
   安全检查通过
22:  $\mathfrak{E}_{real} \leftarrow \text{EVAL}_{real}(\hat{\mathbf{R}}(st(O)), \pi_{real})$ 
23:  $p_{feedback} += \text{COMPILE}(p, \mathfrak{E}_{real})$ 
24:
25:
26:  $\mathbf{R}_{ref}, \pi_{ref} \leftarrow_{\text{Criterion}} (\mathbf{R}_{bs}, \pi_{bs})$ 

▷ 更新参考策略


27:  $p_{feedback} += \text{COMPILE}(p, \pi_{ref})$ 
28:
29: 输出: 最佳策略  $\pi$ , 最佳奖励函数  $\mathbf{R} = 0$ 

```

为了解决上述问题，本研究开发了一套鲁棒的上下文构建机制，旨在辅助 LLM 生成可靠且安全的奖励函数。本研究采用了迭代式的 ReAct (Reason + Act) 框架^[104]，利用真实世界的性能反馈来持续优化生成的代码。提示词工程被结构化为三个阶段：系统提示 (System Prompt)、任务规范 (Task Specification) 和反馈 (Feedback)。

系统提示阶段负责生成针对 RL 环境的知识提示，并应用少样本提示 (Few-shot Prompting) 技术^[105] 来引导奖励函数的创建。所有的环境变量 (如“根节点状态”、“足部高度”、“刚体状态”等) 均被编入参考表 (Reference Table) 中，以防止 LLM 调用不存在的变量，并增强其与环境描述 $\mathcal{D}(\mathcal{T})$ 的融合度。针对人形机器人行走等复杂任务，用户可以通过“编码参考 (Coding References)”指南添加自定义提示，使 LLM 能够从人类提供的示例中学习，进而生成针对特定任务的代码。此外，“编码限制 (Coding Restrictions)”部分提供了负面提示 (Negative Prompts)，用于强制执行接触力、关节限位和力矩阈值等安全约束。实验表明，LLM 能够有效地整合这些约束与变量，构建出高效的奖励函数，展现了强大的上下文追踪能力和指令遵循能力^[106]。




图 5.2 LLM 奖励生成迭代过程示意图

Figure 5.2 Demonstration of LLM reward generation iterations

任务规范阶段在初始时刻提供必要的训练细节，包括机器人描述、关键参数（如基座高度、平均腾空时间）以及奖励函数编写技巧的介绍。在首轮迭代之后，该阶段将转换为一个综合评估方案，作为反馈提示词输入给 LLM。该提示词包含多个组成部分：奖励函数的性能表现、同态评估器与奖励函数的一致性，以及对安全约束的遵

守情况。为了确保价值对齐，评估器融入了预定义的人类偏好，例如人为观测因子 (obs_c) 以及标记为“gt” (ground-truth) 的用户定义观测项，以确保不同 LLM 生成的奖励函数之间具有评估一致性。系统还会追踪成功率以识别表现最优的样本，并据此指导 LLM 调整具体的奖励项及其系数。此外，本研究引入自一致性 (Self-Consistency) 技术^[107] 辅助 LLM 评估单个奖励项的有效性，并进行必要的修正。对于无法执行的代码，系统会提取与奖励文件相关的错误日志作为反馈，并附带调整建议，以进一步完善奖励函数。

为了优化生成过程，本研究引导 LLM 采用思维链 (Chain-of-Thought, CoT) 格式^[108] 输出奖励函数，该格式包含了对其实实现逻辑的逐步解释。这种方法促使 LLM 深度思考奖励函数背后的逻辑，从而更容易识别并解决潜在问题。本研究指示模型将生成的代码放置在输出末尾的代码块中，随后通过脚本处理去除 `<think>` 标签并提取目标代码。实验结果表明，CoT 方法显著提升了 LLM 检测和修复代码问题的能力，从而生成更加可靠且有效的奖励函数。

5.4 融合参考策略的半监督强化学习训练策略

在初始训练阶段，由于缺乏外部反馈，LLM 生成的奖励项往往存在尺度不合理 (poorly scaled) 的问题，导致策略收敛缓慢——这一挑战被称为“冷启动”问题。引入参考策略 (Reference Policy) 可以提供关键的引导，帮助策略网络快速朝向目标优化方向收敛。本节概述了对标准强化学习 (RL) 训练流程的改进，该改进以 Legged Gym 仿真环境和近端策略优化 (PPO) 算法^[109] 为基础。我们假设存在一个源自可行功能的基线策略 π_{ref} ，并为此设计了兼容三种“教师”输入的接口：传统控制方法（如模型预测控制 MPC 或全身控制 WBC）、预训练的神经网络策略 (PyTorch 或 ONNX 格式)，以及简单的运动分布（如正弦波发生器）。

为了增强 PPO 算法，我们对其核心的截断 (Clip) 损失函数进行了如下调整：

$$L^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t [\min(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon)\hat{A}_t) + \beta \text{KL}[\pi_{\text{ref}}(\cdot|s_t), \pi_{\theta}(\cdot|s_t)]], \quad (5.1)$$

其中 $r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)}$ 为概率比率， $\hat{A}_t$ 为 t 时刻的优势函数估计值， ϵ 是一个较小的正数常量， β 用于加权参考策略与 PPO 当前策略之间的 KL 散度。 $\hat{\mathbb{E}}_t$ 表示对时间步的期望。

这一改进确保了训练策略在优化过程中保持与参考策略的分布相似性。尽管将

π_{ref} 直接整合进 PPO 的概率框架较为复杂, 但考虑到在给定状态 s_t 和上一动作 a_{t-1} 的条件下, 参考动作 a_t 通常具有确定性特征, 我们将其近似为狄拉克 (Dirac) 分布。在拥有充足观测样本的情况下, KL 散度 $\hat{\mathbb{E}}_t [\text{KL}(\pi_{\text{ref}}, \pi_\theta)]$ 可简化为:

$$\frac{1}{N} \sum_{i=1}^N \left[\log(\sqrt{2\pi\sigma_{\theta,i}^2}) + \frac{(a_{\text{ref}} - \mu_{\theta,i})^2}{2\sigma_{\theta,i}^2} \right]. \quad (5.2)$$

其中, $\mu_{\theta,i}$ 和 $\sigma_{\theta,i}^2$ 分别代表策略 π_θ 在第 i 步的均值与方差, a_{ref} 为参考动作。该近似在数据量充足时成立, 且系数 β 应设定为较小值, 旨在引导策略跳出局部极小值的同时, 避免过度限制策略的自主探索能力。

在 *AnyBipe* 框架中, 我们提供了一套标准模板, 用于将现有的各类策略作为教师函数集成到 RL 训练流程中。若设定了人工设计的奖励函数作为基准 (Ground Truth), 系统会优先对其进行训练, 并将所得策略作为初始教师策略。用户亦可通过该模板接口导入自定义的外部策略。在每一轮迭代结束后, 如果当前表现最优的训练策略通过了安全检查, 系统将其自动更新为新的参考策略。这种机制不仅实现了人工设计策略与 LLM 生成策略的对比, 验证了评估指标的准确性, 还通过监控奖励项修改后的行为表现, 有效防止了策略性能的退化。

5.5 Sim-to-real 同态评估与安全部署机制

传统的类 Eureka 算法通常仅收集训练阶段的反馈用于下一代策略生成, 而将生成策略的检查与部署工作留给工程师人工完成。相比之下, 本框架利用 Python、Bash 和 C++ 脚本实现了全流程的自动化, 不仅实施了鲁棒的安全检查, 还提供了一种称为“同态评估器 (Homomorphic Estimator)”的数值度量标准。该评估器能够量化仿真与现实之间的差距, 从而使 LLM 能够识别出影响部署性能的关键奖励项。

5.5.1 同态评估体系与策略筛选

为了客观评估策略性能, 我们定义了一组在所有迭代代次中保持一致的、带有 Ground Truth 标签的观测集合。在我们的实验中, 该集合包括线速度、角速度和存活时间。这些指标的乘积构成了环境评估器 $\mathfrak{E}_{\text{train}}$, 用于衡量策略的成功程度。此外, 用户还可以定义自定义的观测/奖励因子, 称为人为观测因子 obs_c , 并赋予相应的权重 c_{obs} 。这些因子的加权和用于计算总分, 以便对策略进行仿真验证和部署验证的排序:

$$\mathbf{R}_{bs}, \Pi_{bs} =_{n_{obs}} \left(c_e \cdot \mathfrak{E}_{train}(\Pi) + \sum c_{obs} \cdot \text{Obs}_c \right). \quad (5.3)$$

该过程将 LLM 生成的奖励函数转化为新的评估器，这些评估器在训练环境和仿真/真实环境中保持一致。这种一致性机制提供了 Sim-to-real 迁移鸿沟（Sim-to-Real Gap）的量化度量，从而帮助 LLM 有针对性地改进其奖励设计策略。

5.5.2 安全检查机制与自动化真机闭环

为了确保现实世界的安全性，被选中的策略在被 ROS 编译系统调用之前，必须通过一项被称为 SA 的安全检查。用户需利用我们提供的模板实现 SA，该模板负责评估仿真数据中的关键物理量，如关节力矩、位置偏差和地面接触力等。

- **通过检查**：若所有检查项均通过，SA 返回 True，脚本将自动编译并执行真机部署代码。
- **未通过检查**：若任一检查项失败，脚本将识别失败的具体条款并生成反馈提示词（Feedback Prompt）返回给 LLM。

真机评估器（Reality Evaluator）的工作原理与仿真评估器类似，负责收集和评估真机运行数据。在部署过程中，用户可以监控运行状态，一旦检测到危险行为可触发停止。外部急停（External Stops）将被系统记录并视为部署失败；否则，部署被视为成功。这些步骤产生的评分将共同决定最终最佳策略的选择：

$$R_{best}, \pi_{best} = \arg \max [[\mathcal{F}(\mathbf{R}_{bs})_{sim} + \mathcal{F}(\mathbf{R}_{bs})_{real}](\mathcal{T} \rightarrow \mathcal{R})(\Pi_{bs})]. \quad (5.4)$$

除去最终的真机部署阶段可能需要人工监督（尽管该阶段也可通过视觉语言模型 VLMs 和摄像头替代人工功能以实现完全自主），整个循环均自动运行。评估、安全检查和代码部署程序均无需人工干预。得益于 LLM 在处理零样本生成任务^[110]方面的强大潜力，该框架甚至不需要初始参考奖励或预存策略即可启动。这使得 AnyBipe 既可作为机器人工程师微调奖励函数的工具，也支持为缺乏先验 RL 实现的新型机器人从零开始开发控制策略。

5.6 实验验证与多构型适配分析

5.6.1 实验设置

为了全面评估 AnyBipe 框架的通用性与有效性，我们在三种具有显著构型差异的双足机器人上进行了实验（如图 5.3 所示）：

- **Limx Dynamics P1**: 6 自由度 (DoF) 的点足式机器人。
- **Unitree H1**: 10 DoF 的双足仿人机器人 (仅下半身)。
- **Turin Robot**: 29 DoF 的全尺寸仿人机器人 (训练时激活 12 个下肢自由度, 其余固定)。

每个机器人的初始提示词设置各不相同, 旨在模拟不同程度的先验知识场景: P1 使用成熟的人工设计奖励函数作为对比基准 (Ground Truth); Unitree H1 使用人工函数作为初始模板; 而 Turin 机器人作为全新的构型, 无先验 RL 实现, 仅使用从开源 humanoid-gym 项目部分适配的通用模板, 且无基准奖励或参考策略。

我们测试了包括 OpenAI GPT-4o、Anthropic Claude-3.5-Sonnet 和 Deepseek-R1 在内的多种主流 LLM, 以验证提示词框架的兼容性。训练在配备 4 块 NVIDIA RTX 3090 的 GPU 服务器上进行。每个任务迭代 $N = 5$ 轮, 每轮生成 $K = 16$ 个样本, 并筛选前 15% (3 个最佳样本) 进入下一轮。得益于高效的 GPU 分配算法, 包括 LLM 生成和评估时间在内, 共计 80 次训练运行在 8 小时内完成。值得强调的是, 为了展示极低的人力投入, 整个实验过程由框架全自动执行, 仅在最终生成图表时使用了生成的策略和检查点。

对于两款仿人机器人 (H1, Turin), 主要依赖仿真评估与安全检查 (SA) 反馈; 对于 P1, 则进行了真机部署测试以验证自动化部署流程。GPU 服务器直接连接机器人控制器, MuJoCo 和 Gazebo 仿真环境以无头模式 (Headless Mode) 运行。




图 5.3 实验涉及的三种双足机器人构型及自由度定义
Figure 5.3 Robot and DOF definitions

表 5.1 列出了作为奖励函数的通用环境评估器。这些评估器在整个训练和评估过程中保持形式不变, 作为衡量策略性能的客观标准。

表 5.1 核心环境评估器与奖励函数定义
Table 5.1 Examples of important rewards

奖励名称	数学表达式
生存奖励	$R_{surv} = \int_0^{t_{term,i}} dt$
线速度跟踪	$R_{vel} = \exp(-\frac{\ v - v_{ref}\ ^2}{\sigma_l^2})$
角速度跟踪	$R_{angl} = \exp(-\frac{\ \omega - \omega_{ref}\ ^2}{\sigma_a^2})$
总成功率	$R_{succ} = R_{surv} \cdot R_{vel} \cdot R_{angl}$

5.6.2 模块功能验证分析

在展示整体框架效果之前，我们首先对各个核心模块（LLM 生成、半监督训练、同态评估、安全检查）进行了独立验证。

5.6.2.1 LLM 生成性能评估

我们测试了不同 LLM 基座在提示词设计及增强下的表现。生成 Temperature^①统一设为 **0.4**。我们定义了两个关键指标：成功率（SR，即可执行代码占总生成代码的比例）和最大归一化奖励成功率（Max S.，即 R_{succ} 除以每环境步数，取三次实验平均值）。如表 5.2 所示，Deepseek-R1 和 Claude-3.5-Sonnet 展现出了最佳性能，特别是在代码可执行率上接近或超过 90%。

表 5.2 不同 LLM 在各机器人任务上的代码生成成功率与奖励性能

Table 5.2 Number of run-able code / total generation on different bot tasks, success rate, max normalized reward success for different LLMs

模型名称	P1	H1	Turin	SR	Max S.
GPT-4o	228/240	173/240	52/240	62.9%	0.824
Claude-3.5	232/240	213/240	201/240	89.7%	1.032
Deepseek-R1	-/-	232/240	211/240	92.3%	1.060

5.6.2.2 教师指导训练的有效性

为了验证参考策略的作用，我们以 P1 机器人为例，对比了无教师指导的纯 PPO 训练与教师指导下的半监督训练。参考策略选用了在平坦地形上训练了 5000 轮的人工设计策略，测试环境为复杂的三维网格（Trimesh）地形。教师系数设为 $\beta = 0.5$ 并开启课程学习。图 5.4 清晰地展示了教师指导模型（蓝线）相比纯 PPO（橙线）具有更稳定的训练过程，奖励增长更快且波动更小，有效解决了冷启动问题。

① LLM 调用时所需配置的、用于控制随机性的超参数。




图 5.4 教师指导训练（蓝）与纯 RL 训练（黄）的奖励及课程等级曲线对比

Figure 5.4 Reward success, terrain level for teacher guided and original RL training with human-engineered rewards, using P1 as example

5.6.2.3 同态评估与 Sim-to-real 一致性

表 5.3 展示了 P1 训练中同态评估器的实际数据。每一列分别代表 Isaac Gym 中的奖励值、Gazebo 中的同态测量值、真机中的测量值以及真机跟踪结果的映射。结果表明，同态评估器能够客观反映仿真与现实的差异（例如真机上的静态站立时间偏差），为 LLM 提供了修正依据。

表 5.3 点足机器人的同态评估指标示例

Table 5.3 Examples of homomorphic evaluation for pointfoot robot

指标名称	Gym (训练)	Gazebo (仿真)	Reality (真机)	映射值 (实测/目标)
线速度跟踪	0.8893	0.9138	0.8504	0.86 (1.0) m/s
角速度跟踪	0.7652	0.6500	0.6013	0.06 (0.10) rad/s
足间距	-0.31	-0.00	-0.00	> 0.1m (> 0.1m)
静态站立	-5.35	-6.16	- 11.20	5.8 (30) s
生存时间	0.86	1.0	1.0	30 (30) s

5.6.2.4 安全检查 (SA) 准则验证

我们定义了两个级别的安全准则：**基础准则**（包括跌倒、自碰撞、违反关节/力矩限制）和**警告准则**（包括接触力过大、动作频率过高、重力投影偏差过大）。通过人工标定真值并计算平均精度 (AP) 和召回率 (AR)，如表 5.4 所示，SA 在所有机器人任务上均保持了极高的检测精度 (AP > 94%)，证明了自动化部署的安全性保障。

表 5.4 安全准则 (SA) 的检测精度与召回率

Table 5.4 Precision and recall for safety criterion in percentage form

机器人	AP	AR	S-AP	S-AR	SR (S-SR)
P1 Pointfoot	94.3	96.4	100.0	92.6	58.7 (26.2)
Unitree H1	100.0	97.5	93.3	84.0	65.4 (18.8)
Turin Robot	97.6	96.1	83.8	93.9	52.9 (15.4)




图 5.5 三种机器人在 5 轮迭代中的最佳生成策略及安全反馈可视化

Figure 5.5 Best generation policies for 5 iterations evaluated in training and evaluating environments

对于 P1，展示了真机评估结果。图片下方的文字表示每轮迭代后的安全检查 (SA) 反馈，颜色代表严重程度：红色为不安全，黄色为警告，绿色为通过。

5.6.3 系统整体性能分析

实验设置概览如表 5.5 所示。图 5.5 直观展示了随迭代进行的最佳策略演进过程。可以清晰地看到，AnyBipe 能够引导 LLM 逐步修正不安全的行为（如 P1 的跌倒、H1 的自碰撞），最终生成通过所有安全检查的策略。特别是对于 Turin 机器人，在零样本无参考的情况下，框架成功探索出了稳定的行走步态。

表 5.5 系统实验设置概览

Table 5.5 Framework experimental set-up

机器人	LLM 模型	训练迭代	仿真环境	真机环境
P1 Pointfoot	GPT-4o	5,000	Gazebo	✓
Unitree H1	Claude-3.5	2,000	MuJoCo	×
Turin Robot	Deepseek-R1	2,000	MuJoCo	×

表 5.6 进一步量化了这一过程。我们将迭代过程中的奖励成功率 $\mathcal{E}_{train}$ 与人工设计的基准 (Human Engineered) 进行了对比。结果显示，经过 3-4 轮迭代后，AnyBipe 自动生成的奖励函数在性能上已经超越了人工设计的 SOTA 方案。对于 Turin 机器人，

框架在完全无参考的情况下实现了从 10.2 到 67.0 的巨大性能飞跃。

表 5.6 各迭代轮次奖励成功率与人工设计基准的对比
Table 5.6 Reward success over iterations compared to human engineered ones

任务名称	Iter 0	Iter 1	Iter 2	Iter 3	Iter 4	人工设计基准
P1 Pointfoot	14.7 (5.5)	7.1 (6.3)	9.2 (8.7)	15.5 (11.2)	25.6 (20.8)	19.2 (19.2)
Unitree H1	0.0097 (0.0035)	21.2 (12.4)	25.2 (21.7)	25.0 (22.4)	25.8 (24.9)	23.7 (23.7)
Turin Robot	10.2 (1.96)	52.3 (42.9)	58.1 (51.8)	66.3 (55.4)	67.0 (57.8)	无 (None)

格式为：批次最大值 (批次平均值)。

最后，图 5.6 展示了 P1 机器人在真实世界中不同地形（平地、草地、斜坡等）上的行走实验。这证明了通过 AnyBipe 训练出的策略不仅在仿真中表现优异，而且具备强大的 Sim-to-Real 迁移能力，能够适应复杂的现实环境。



图 5.6 基于 AnyBipe 最佳策略的 P1 机器人真机多地形测试

Figure 5.6 Reality experiments for P1 conducted on different terrains, adopting AnyBipe’s best policy

5.7 本章小结

本章针对人形机器人控制系统在落地过程中面临的奖励工程繁琐、训练冷启动困难以及 Sim-to-real 迁移安全性不足等痛点，提出了一套基于大语言模型的端到端训练与部署框架——AnyBipe。

本章的主要工作总结如下：

- **全流程自动化框架构建**：成功利用大语言模型实现了从任务描述到真机部署的全自动化闭环。通过提供标准化的接口，框架允许用户注入编码参考并集成预训练模型作为指导，并兼容现有的强化学习框架，减少了使用成本。
- **半监督学习与冷启动优化**：提出了融合参考策略的改进 PPO 算法，利用教师指导的半监督学习机制，有效解决了 LLM 生成奖励函数权重不合理导致训练初期的冷启动问题，大幅提升了训练收敛速度与策略稳定性。

- **Sim-to-real 闭环与同态评估：**依据实际工程中可能存在的风险项设计了同态评估器与自动安全检查机制。通过整合仿真与真实世界的测试反馈，框架不仅实现了无人工监督的 Sim-to-Real 迁移，还能为 LLM 提供可量化指标的物理反馈，指导奖励函数的持续迭代与优化。
- **多构型适配验证：**在 Limx P1、Unitree H1 以及 Turin Robot 三种不同构型机器人上的实验证明，该框架具备极强的通用性与泛化能力，能够引导机器人在复杂环境中习得鲁棒的运动技能，并微调其训练特征使其适用于真机部署。

尽管该框架在自动化训练与部署方面展现了巨大潜力，但仍存在一定的局限性，例如目前的观测空间尚未充分整合视觉感知因素，且基础 RL 环境的构建仍依赖于人工模板辅助选择而非完全由 LLM 生成。未来的工作将尝试引入视觉语言模型以提升安全判定的精度，并进一步探索环境生成的自动化，从而构建更加智能、通用的机器人控制系统开发生态。

第6章 总结与展望

6.1 全文总结

本文围绕人形机器人仿人运动控制系统中的四个核心挑战，即：人体动捕数据到机器人动作的形态鸿沟、底层控制策略的鲁棒性和泛化性缺失、结合语义信息指引的长程运动规划匮乏以及真机部署迁移的机械工作繁杂，展开了系统性的研究。通过构建从数据重定向、控制策略设计与优化、语义引导生成式规划到自动化训练部署的全栈技术链路，本文旨在提升人形机器人的运动智能水平与环境适应能力，并显著降低工程开发的复杂度。本文的主要工作概括如下：

1. 针对人形机器人仿人运动数据匮乏且人与机器人形态差异大的问题，提出了一套无需人工繁琐配置的自适应运动重定向框架与规范化的机器人本体运动数据集构建方法。通过设计基于形态表征的运动学优化算法，本文解决了从标准人体 SMPL 模型到异构机器人模型之间相互转换的数据迁移难题，建立了一套包含关节位置、速度、连杆状态及接触相位的数据规范。这不仅为后续的数据训练提供了高质量、物理一致的本体数据，更从根本上打破了机器人硬件构型对数据复用的限制，构建了通用的数据基座。
2. 为了将离线的运动学数据转化为机器人可执行的动力学策略，研究了基于两阶段强化学习-模仿学习的底层控制算法。针对传统模仿学习在动力学失配下鲁棒性差的问题，本文设计了基于 Motion Mimic Transformer 骨干网络的 GBC 控制器，并引入了状态增强与抗扰动训练机制。该控制器作为连接上层规划与下层驱动的关键小脑，实现了对重定向参考轨迹的高保真跟踪，使机器人具备了在复杂地形下的稳定运动能力，有效填补了运动学规划与动力学执行之间的鸿沟。
3. 针对传统控制算法缺乏语义引导的长程运动规划能力的问题，将生成式人工智能引入机器人控制回路，构建了基于扩散模型的长程动作生成与规划架构。在动作生成方面，采用了流匹配技术替代传统的扩散概率模型，并探索了最优的训练范式，显著提升了生成的实时性与质量。进一步地，通过设计分层式的 Diffusion-MPC 架构，本文实现了低频生成规划与高频动作执行的异步协同，赋予了机器人根据稀疏的自然语言指令实时生成长程、连贯且多样化全身动作的能力。
4. 为了解决强化学习落地过程中奖励函数设计依赖人工经验、训练冷启动困难以

及真机部署安全性差的工程痛点,本文提出了 AnyBipe 自动化训练与部署框架。利用大语言模型的推理能力与思维链技术,本文实现了奖励函数的自动化生成与迭代优化。同时,通过引入教师指导的半监督训练机制与同态评估器,该框架不仅解决了 RL 训练的冷启动问题,更量化了仿真与现实的差距,实现了从现实的状态反馈中搜索出最有效的改进方式,完成了从仿真训练到真机部署的全自动闭环。这一设计在多种构型的机器人上验证了系统的通用性与安全性,证明了该方法论在降低实机实验门槛方面的有效性。

6.2 未来展望

尽管本文在人形机器人的生成与控制方面取得了一定的成果,但要实现真正的具身智能 (Embodied AI),仍有广阔的空间值得探索。基于本文的研究基础与当前的行业痛点,未来的研究工作将重点聚焦于以下四个方向:

第一,从单纯的动作模仿拓展至物体交互 (HOI, Human Object Interaction) 与场景交互 (HSI, Human Scene Interaction)。目前的生成与控制主要集中在自身的运动 (Locomotion) 与姿态变换上,尚未深入涉及与环境的物理交互。未来的工作应致力于让机器人将生成的动作与具体的物理场景相结合,例如在行走中避开动态障碍物、操作具体的工具或搬运物体。通过引入场景的几何与语义信息,使机器人的运动不再是“空中楼阁”,而是具备实际作业能力的具身交互。

第二,探索基于生成式规划的全序列 Vision-Language-Action (VLA) 流程。现有的人形机器人 VLA 方案大多采用割裂的控制模式,即上身使用 VLA 模型进行规划,下身依赖独立的 RL 策略维持平衡,这导致上下身协调性差,难以应对高动态全身任务。本文提出的 Diffusion-MPC 架构具备全序列生成的潜力,未来可进一步引入视觉-语言多模态输入,直接由模型输出全身协调的关节动作或末端位姿,实现真正意义上的端到端全身 VLA 控制,以应对更复杂的全身协同操作任务。

第三,研究基于视频演示与持续学习 (Continuous Learning) 的技能获取机制。依靠现有的有限数据集进行训练,难以覆盖现实世界中无穷无尽的长尾任务。未来的研究应关注如何让机器人具备持续学习的能力,即不依赖于预先标注好的动捕数据,而是通过观察人类视频 (YouTube 等互联网数据) 或少量的人类示教,通过自监督或少样本学习的方式快速掌握新技能,从而实现机器人技能库的自主进化与扩充。

第四,构建高保真的世界模型 (World Model) 以解决 Sim-to-Real 迁移难题。尽管仿真训练高效,但高昂的仿真时间成本与现实鸿沟依然存在。未来应基于现有的

机器人控制数据，构建基于循环状态空间模型（RSSM）的机器人世界模型。通过在潜在空间中对环境动力学进行建模与预测，不仅可以辅助强化学习进行更高效的样本训练，还能在离线阶段进行大规模的“想象”训练，从而降低对高频物理仿真的依赖，提升策略在真实物理世界中的适应性与鲁棒性。

参考文献

- [1] 朱秋国, 熊蓉. 人形机器人技术现状及场景应用思考[J/OL]. 机器人产业, 2023(04): 14-19. DOI: 10.19609/j.cnki.cn10-1324/tp.2023.04.005.
- [2] ADAMS B, BREAZEALE C, BROOKS R A, et al. Humanoid robots: A new kind of tool[J]. IEEE Intelligent Systems and Their Applications, 2000, 15(4): 25-31.
- [3] 刘泽宇. 人形交互式服务机器人研究现状及发展趋势[J/OL]. 中国战略新兴产业, 2018(12): 75. DOI: 10.19474/j.cnki.10-1156/f.003450.
- [4] WANG X, WANG S, LIANG X, et al. Deep reinforcement learning: A survey[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 35(4): 5064-5078.
- [5] SAEEDVAND S, JAFARI M, AGHDASI H S, et al. A comprehensive survey on humanoid robot development[J]. The Knowledge Engineering Review, 2019: e20.
- [6] DUAN J, YU S, TAN H L, et al. A survey of embodied ai: From simulators to research tasks[J]. IEEE Transactions on Emerging Topics in Computational Intelligence, 2022, 6(2): 230-244.
- [7] ARN News. Advanced Humanoid Robot to be Piloted in Abu Dhabi in 2026[Z]. <https://www.dubaieye1038.com/news/local/advanced-humanoid-robot-to-be-piloted-in-abu-dhabi-in-2026/>. Accessed: 2026-01-13. 2026.
- [8] 白静. 布局人形机器人赛道推进智能产业创新发展——解读《人形机器人创新发展指导意见》[J/OL]. 中国科技产业, 2024(01): 30-31. DOI: 10.16277/j.cnki.cn11-2502/n.2024.01.006.
- [9] ManiLab. 全球人形机器人公司盘点与对比[EB/OL]. 2024. https://blog.csdn.net/weixin_41628708/article/details/137525774.
- [10] HE T, LUO Z, HE X, et al. OmniH2O: Universal and dexterous human-to-humanoid whole-body teleoperation and learning[J]. arXiv preprint arXiv:2406.08858, 2024.
- [11] HWANGBO J, LEE J, WELLHAUSEN L, et al. Learning Agile and Dynamic Motor Skills for Legged Robots[J]. Science Robotics, 2019, 4(26): Art. no. eaau5872.
- [12] PENG X B, ABBEEL P, LEVINE S, et al. DeepMimic: Example-guided deep reinforcement learning of physics-based character skills[C]//ACM Transactions on Graphics (TOG): vol. 37: 4. ACM, 2018: 1-14.
- [13] DARVISH K, PENCO L, RAMOS J, et al. Teleoperation of humanoid robots: A survey[J]. IEEE Transactions on Robotics, 2023, 39(3): 1706-1727.
- [14] NAKAOKA S, KOMURA T. Interaction mesh based motion adaptation for biped humanoid robots[C/OL]//2012 12th IEEE-RAS International Conference on Humanoid Robots (Humanoids 2012). 2012: 625-631. DOI: 10.1109/HUMANOIDS.2012.6651585.
- [15] BIN HAMMAM G, WENSING P M, DARIUSH B, et al. Kinodynamically consistent motion re-

- targeting for humanoids[J]. *International Journal of Humanoid Robotics*, 2015, 12(04): 1550017.
- [16] DI FAVA A, BOUYARMANE K, CHAPPELLET K, et al. Multi-contact motion retargeting from human to humanoid robot[C]//2016 IEEE-RAS 16th international conference on humanoid robots (humanoids). 2016: 1081-1086.
- [17] PENCO L, CLÉMENT B, MODUGNO V, et al. Robust real-time whole-body motion retargeting from human to humanoid[C]//2018 IEEE-RAS 18th International Conference on Humanoid Robots (Humanoids). 2018: 425-432.
- [18] AYUSAWA K, MORISAWA M, YOSHIDA E. Motion retargeting for humanoid robots based on identification to preserve and reproduce human motion features[C]//2015 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2015: 2774-2779.
- [19] ZHANG Z, NIU Y, YAN Z, et al. Real-time whole-body imitation by humanoid robots and task-oriented teleoperation using an analytical mapping method and quantitative evaluation[J]. *Applied Sciences*, 2018, 8(10): 2005.
- [20] FU Z, ZHAO Q, WU Q, et al. HumanPlus: Humanoid shadowing and imitation from humans[C]//Conference on Robot Learning (CoRL). 2024: 2828-2844.
- [21] GUO C, ZOU S, ZUO X, et al. Generating Diverse and Natural 3D Human Motions From Text[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 5152-5161.
- [22] HOLKAR K S, WAGHMARE L M. An overview of model predictive control[J]. *International Journal of control and automation*, 2010, 3(4): 47-63.
- [23] SENTIS L, KHATIB O. A whole-body control framework for humanoids operating in human environments[C]//Proceedings 2006 IEEE International Conference on Robotics and Automation, 2006. ICRA 2006. 2006: 2641-2648.
- [24] SIEKMANN J, GODSE Y, FERN A, et al. Sim-to-real learning of all common bipedal gaits via periodic reward composition[C]//2021 IEEE International Conference on Robotics and Automation (ICRA). 2021: 7309-7315.
- [25] CHEN Z, HE X, WANG Y J, et al. Learning smooth humanoid locomotion through lipschitz-constrained policies[J]. *arXiv preprint arXiv:2410.11825*, 2024.
- [26] KALAKRISHNAN M, BUCHLI J, PASTOR P, et al. Learning, planning, and control for quadruped locomotion over challenging terrain[C]//2011 IEEE International Conference on Robotics and Automation. 2011: 236-241.
- [27] PENG X B, ABBEEL P, LEVINE S, et al. DeepMimic: Example-guided deep reinforcement learning of physics-based character skills[J/OL]. *ACM Trans. Graph.*, 2018, 37(4): 143:1-143:14. DOI: 10.1145/3197517.3201311.
- [28] PENG X B, MA Z, ABBEEL P, et al. Amp: Adversarial motion priors for stylized physics-based character control[J]. *ACM Transactions on Graphics (ToG)*, 2021, 40(4): 1-20.

- [29] SHAFIULLAH N M, CUI Z, ALTANZAYA A A, et al. Behavior transformers: Cloning k modes with one stone[J]. Advances in neural information processing systems, 2022, 35: 22955-22968.
- [30] LEE S, WANG Y, ETUKURU H, et al. Behavior generation with latent actions[J]. arXiv preprint arXiv:2403.03181, 2024.
- [31] LIN A S, WU L, CORONA R, et al. Generating animated videos of human activities from natural language descriptions[J]. Learning, 2018, 1(2018): 1.
- [32] PETROVICH M, BLACK M J, VAROL G. Action-conditioned 3d human motion synthesis with transformer vae[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10985-10995.
- [33] TEVET G, GORDON B, HERTZ A, et al. Motionclip: Exposing human motion generation to clip space[C]//European Conference on Computer Vision. 2022: 358-374.
- [34] TEVET G, RAAB S, GORDON B, et al. Human motion diffusion model[J]. arXiv preprint arXiv:2209.14916, 2022.
- [35] SHAFIR Y, TEVET G, KAPON R, et al. Human motion diffusion as a generative prior[J]. arXiv preprint arXiv:2303.01418, 2023.
- [36] SAWDAYEE H, GUO C, TEVET G, et al. Dance like a chicken: Low-Rank stylization for human motion diffusion[J]. arXiv preprint arXiv:2503.19557, 2025.
- [37] GAT I, RAAB S, TEVET G, et al. Anytop: Character animation diffusion with any topology[C]//Proceedings of the Special Interest Group on Computer Graphics and Interactive Techniques Conference Conference Papers. 2025: 1-10.
- [38] CHI C, XU Z, FENG S, et al. Diffusion policy: Visuomotor policy learning via action diffusion [J]. The International Journal of Robotics Research, 2023: 02783649241273668.
- [39] ZE Y, CHEN Z, WANG W, et al. Generalizable humanoid manipulation with 3d diffusion policies [J]. arXiv preprint arXiv:2410.10803, 2024.
- [40] ZHU M, ZHU Y, LI J, et al. Scaling diffusion policy in transformer to 1 billion parameters for robotic manipulation[C]//2025 IEEE International Conference on Robotics and Automation (ICRA). 2025: 10838-10845.
- [41] LIPMAN Y, CHEN R T, BEN-HAMU H, et al. Flow matching for generative modeling[J]. arXiv preprint arXiv:2210.02747, 2022.
- [42] PAN C, YI Z, SHI G, et al. Model-based diffusion for trajectory optimization[J]. Advances in Neural Information Processing Systems, 2024, 37: 57914-57943.
- [43] MA Y J, LIANG W, WANG H, et al. DrEureka: Language model guided sim-to-real transfer[C]//Robotics: Science and Systems (RSS). 2024.
- [44] LIU B, JIANG Y, ZHANG X, et al. LLM+P: empowering large language models with optimal planning proficiency[EB/OL]. 2023. <https://arxiv.org/abs/2304.11477>. arXiv: 2304.11477 [cs.AI].

- [45] WANG G, XIE Y, JIANG Y, et al. Voyager: An open-ended embodied agent with large language models[EB/OL]. 2023. <https://arxiv.org/abs/2305.16291>. arXiv: 2305.16291 [cs.AI].
- [46] TOBIN J, FONG R, RAY A, et al. Domain randomization for transferring deep neural networks from simulation to the real world[C]//2017 IEEE/RSJ international conference on intelligent robots and systems (IROS). 2017: 23-30.
- [47] PENG X B, ANDRYCHOWICZ M, ZAREMBA W, et al. Sim-to-real transfer of robotic control with dynamics randomization[C]//2018 IEEE international conference on robotics and automation (ICRA). 2018: 3803-3810.
- [48] MURATORE F, RAMOS F, TURK G, et al. Robot learning from randomized simulations: A review[J]. *Frontiers in Robotics and AI*, 2022, 9: 799893.
- [49] DUAN H, MALIK A, DAO J, et al. Sim-to-real learning of footstep-constrained bipedal dynamic walking[C/OL]//2022 International Conference on Robotics and Automation (ICRA). 2022: 10428-10434. DOI: 10.1109/ICRA46639.2022.9812015.
- [50] HARVEY F G, YURICK M, NOWROUZEZAHRAI D, et al. Robust Motion In-Betweening[J]. 2020, 39(4).
- [51] HE T, LUO Z, XIAO W, et al. Learning human-to-humanoid real-time whole-body teleoperation [C]//. 2024.
- [52] ZE Y, CHEN Z, ARAÑŠJO J P, et al. TWIST: Teleoperated Whole-Body Imitation System[J]. arXiv preprint arXiv:2505.02833, 2025.
- [53] GULRAJANI I, AHMED F, ARJOVSKY M, et al. Improved training of wasserstein gans[J]. *Advances in neural information processing systems*, 2017, 30.
- [54] GUO C, ZUO X, WANG S, et al. Action2motion: Conditioned generation of 3d human motions [C]//Proceedings of the 28th ACM International Conference on Multimedia. 2020: 2420-2428.
- [55] HE T, GAO J, XIAO W, et al. Asap: Aligning simulation and real-world physics for learning agile humanoid whole-body skills[J]. arXiv preprint arXiv:2502.01143, 2025.
- [56] HE T, XIAO W, LIN T, et al. Hover: Versatile neural whole-body controller for humanoid robots [J]. arXiv preprint arXiv:2410.21229, 2024.
- [57] SHIN S, KIM J, HALILAJ E, et al. Wham: Reconstructing world-grounded humans with accurate 3d motion[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 2070-2080.
- [58] TEED Z, LIPSON L, DENG J. Deep patch visual odometry[J]. *Advances in Neural Information Processing Systems*, 2023: 21657-21673.
- [59] LUO Z, CAO J, KITANI K, et al. Perpetual humanoid control for real-time simulated avatars[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 10895-10904.
- [60] NI T, EYSENBACH B, SALAKHUTDINOV R. Recurrent model-free rl can be a strong baseline for many pomdps[J]. arXiv preprint arXiv:2110.05038, 2021.

- [61] CHEN L, LU K, RAJESWARAN A, et al. Decision transformer: Reinforcement learning via sequence modeling[J]. Advances in neural information processing systems, 2021, 34: 15084-15097.
- [62] DEVLIN J, CHANG M W, LEE K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers). 2019: 4171-4186.
- [63] TOUVRON H, LAVRIL T, IZACARD G, et al. Llama: Open and efficient foundation language models[J]. arXiv preprint arXiv:2302.13971, 2023.
- [64] ZHANG B, SENNRICH R. Root mean square layer normalization[J]. Advances in Neural Information Processing Systems, 2019, 32.
- [65] HINTON G, VINYALS O, DEAN J. Distilling the knowledge in a neural network[J]. arXiv preprint arXiv:1503.02531, 2015.
- [66] RUSU A A, COLMENAREJO S G, GULCEHRE C, et al. Policy distillation[J]. arXiv preprint arXiv:1511.06295, 2015.
- [67] TANG R, LU Y, LIU L, et al. Distilling task-specific knowledge from bert into simple neural networks[J]. arXiv preprint arXiv:1903.12136, 2019.
- [68] HU E J, SHEN Y, WALLIS P, et al. Lora: Low-rank adaptation of large language models.[J]. ICLR, 2022, 1(2): 3.
- [69] YAO Y, HE W, GU C, et al. AnyBipe: An automated end-to-end framework for training and deploying bipedal robots powered by large language models[Z/OL]. 2025: 14790-14797. DOI: 10.1109/IROS60139.2025.11246492.
- [70] BENGIO Y, LOURADOUR J, COLLOBERT R, et al. Curriculum learning[C]//Proceedings of the 26th annual international conference on machine learning. 2009: 41-48.
- [71] BROWN D S, GOO W, NIEKUM S. Better-than-demonstrator imitation learning via automatically-ranked demonstrations[C]//Conference on robot learning. 2020: 330-359.
- [72] JIANG B, CHEN X, LIU W, et al. Motiongpt: Human motion as a foreign language[J]. Advances in Neural Information Processing Systems, 2023, 36: 20067-20079.
- [73] PENG X, XIE Y, WU Z, et al. Hoi-diff: Text-driven synthesis of 3d human-object interactions using diffusion models[C]//Proceedings of the Computer Vision and Pattern Recognition Conference. 2025: 2878-2888.
- [74] CHEN X, JIANG B, LIU W, et al. Executing your commands via motion diffusion in latent space [C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 18000-18010.
- [75] DWIVEDI S K, SUN Y, PATEL P, et al. Tokenhmr: Advancing human mesh recovery with a tokenized pose representation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2024: 1323-1333.

- [76] TEVET G, RAAB S, COHAN S, et al. Cload: Closing the loop between simulation and diffusion for multi-task character control[J]. arXiv preprint arXiv:2410.03441, 2024.
- [77] MAHMOOD N, GHORBANI N, TROJE N F, et al. AMASS: Archive of motion capture as surface shapes[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 5442-5451.
- [78] HO J, JAIN A, ABBEEL P. Denoising diffusion probabilistic models[J]. Advances in neural information processing systems, 2020, 33: 6840-6851.
- [79] SONG J, MENG C, ERMION S. Denoising diffusion implicit models[J]. arXiv preprint arXiv:2010.02502, 2020.
- [80] LOPER M, MAHMOOD N, ROMERO J, et al. SMPL: A Skinned Multi-Person Linear Model [J]. ACM Trans. Graphics (Proc. SIGGRAPH Asia), 2015, 34(6): 248:1-248:16.
- [81] HINTON G E, SALAKHUTDINOV R R. Reducing the dimensionality of data with neural networks[J]. science, 2006, 313(5786): 504-507.
- [82] RAMESH A, DHARIWAL P, NICHOL A, et al. Hierarchical text-conditional image generation with clip latents[J]. arXiv preprint arXiv:2204.06125, 2022, 1(2): 3.
- [83] CHEN R, SHI M, HUANG S, et al. Taming diffusion probabilistic models for character control [C]//ACM SIGGRAPH 2024 Conference Papers. 2024: 1-10.
- [84] CHEN R T, RUBANOVA Y, BETTENCOURT J, et al. Neural ordinary differential equations[J]. Advances in neural information processing systems, 2018, 31.
- [85] KOUVARITAKIS B, CANNON M. Model predictive control[J]. Switzerland: Springer International Publishing, 2016, 38(13-56): 7.
- [86] NVIDIA. Isaac Sim[CP/OL]. 4.5.0. <https://github.com/isaac-sim/IsaacSim>.
- [87] GUO C, ZOU S, ZUO X, et al. Generating diverse and natural 3d human motions from text[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 5152-5161.
- [88] YUAN Y, SONG J, IQBAL U, et al. Physdiff: Physics-guided human motion diffusion model[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2023: 16010-16021.
- [89] LI T, HE K. Back to basics: Let denoising generative models denoise[EB/OL]. 2025. <https://arxiv.org/abs/2511.13720>. arXiv: 2511.13720 [cs.CV].
- [90] BLACK K, BROWN N, DRIESS D, et al. $\pi 0$: A vision-language-action flow model for general robot control. CoRR, abs/2410.24164, 2024. doi: 10.48550[J]. arXiv preprint ARXIV.2410.24164,
- [91] BJORCK J, CASTAÑEDA F, CHERNIADEV N, et al. Gr00t n1: An open foundation model for generalist humanoid robots[J]. arXiv preprint arXiv:2503.14734, 2025.
- [92] ACOSTA B, YANG W, POSA M. Validating robotics simulators on real-world impacts[J/OL]. IEEE Robotics and Automation Letters, 2022, 7(3): 6471-6478. DOI: 10.1109/LRA.2022.31743

- 67.
- [93] ŠUTINYS E, SAMUKAITĖ-BUBNIENĖ U, BUČINSKAS V. Advanced applications of industrial robotics: New trends and possibilities[J/OL]. *Applied Sciences*, 2022, 12(1): 135. DOI: 10.3390/app12010135.
- [94] CIARDO F, WYKOWSKA A. Humanoid robot passes for human in joint task experiment[C/OL]//*Science Robotics*: vol. 7: 68. 2022. DOI: 10.1038/d43978-022-00100-6.
- [95] LOBBEZOO A, KWON H J. Simulated and real robotic reach, grasp, and pick-and-place using combined reinforcement learning and traditional controls[J/OL]. *Robotics*, 2023, 12(1). <https://www.mdpi.com/2218-6581/12/1/12>. DOI: 10.3390/robotics12010012.
- [96] ERNST D, LOUETTE A. Introduction to reinforcement learning[J]. *Business & Information Systems Engineering*, 2024, 66(1): 111-126.
- [97] HSU K C, REN A Z, NGUYEN D P, et al. Sim-to-Lab-to-Real: Safe reinforcement learning with shielding and generalization guarantees[J/OL]. *Artificial Intelligence*, 2023, 314: 103811. DOI: <https://doi.org/10.1016/j.artint.2022.103811>.
- [98] Salvato, Erica and Fenu, Gianfranco and Medvet, Eric and Pellegrino, Felice Andrea. Crossing the reality gap: A survey on sim-to-real transferability of robot controllers in reinforcement learning [J/OL]. *IEEE Access*, 2021, 9: 153171-153187. DOI: 10.1109/ACCESS.2021.3126658.
- [99] SHAH N, GENC Z, ARACI D. StackEval: benchmarking LLMs in coding assistance[C]//*The Thirty-eight Conference on Neural Information Processing Systems Datasets and Benchmarks Track*.
- [100] XIA W, WANG D, PANG X, et al. Kinematic-aware Prompting for Generalizable Articulated Object Manipulation with LLMs[C/OL]//*2024 IEEE International Conference on Robotics and Automation (ICRA)*. 2024: 2073-2080. DOI: 10.1109/ICRA57147.2024.10610744.
- [101] QUIGLEY M, CONLEY K, GERKEY B, et al. ROS: an open-source Robot Operating System [C]//*ICRA workshop on open source software*: vol. 3: 3.2. 2009: 5.
- [102] MA Y J, LIANG W, WANG G, et al. Eureka: Human-Level reward design via coding large language models[J]. *arXiv preprint arXiv: Arxiv-2310.12931*, 2023.
- [103] KIM Y, OH H, LEE J, et al. Not only rewards but also constraints: Applications on legged robot locomotion[J]. *IEEE Transactions on Robotics*, 2024.
- [104] YAO S, ZHAO J, YU D, et al. React: Synergizing reasoning and acting in language models[J]. *arXiv preprint arXiv:2210.03629*, 2022.
- [105] BROWN T, MANN B, RYDER N, et al. Language models are few-shot learners[J]. *Advances in neural information processing systems*, 2020, 33: 1877-1901.
- [106] OUYANG L, WU J, JIANG X, et al. Training language models to follow instructions with human feedback[J]. *Advances in neural information processing systems*, 2022, 35: 27730-27744.
- [107] WANG X, WEI J, SCHUURMANS D, et al. Self-consistency improves chain of thought reasoning

- in language models[J]. arXiv preprint arXiv:2203.11171, 2022.
- [108] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. Advances in neural information processing systems, 2022, 35: 24824-24837.
- [109] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[J]. arXiv preprint arXiv:1707.06347, 2017.
- [110] KOJIMA T, GU S S, REID M, et al. Large language models are zero-shot reasoners[J]. Advances in neural information processing systems, 2022, 35: 22199-22213.

致 谢

行文至此，落笔之时，我的硕士研究生生涯也即将画上句号。回首在交大求学的两年半时光，从初入科研的懵懂到如今的独立探索，这一路走来，离不开师长、同门、挚友及家人的支持与陪伴。纸短情长，谨以此文，向所有帮助过我的人致以最诚挚的谢意。

首先，我要衷心感谢我的导师卢俊国教授。卢老师治学严谨、学识渊博，是他将我领进了科研的大门。在我迷茫时，是卢老师的耐心指导为我指明了方向；在我遇到困难时，是卢老师的鼓励与支持让我有了坚持下去的勇气。卢老师在学术上对我的严格要求，以及在生活中对我的亲切关怀，都将成为我受益终身的财富。

感谢我的同门师兄弟，是你们让枯燥的科研生活充满了温暖与活力。特别感谢朱震师兄和富威师兄，你们在科研思维和工作规划上给予了我极大的启迪与指导，让我少走了许多弯路；感谢嘉晨师兄、弘毅师兄、嘉恒师兄，在我完成科研论文的过程中，是你们无私的建议与帮助，让我得以顺利攻克难关。感谢与我并肩作战的同届挚友：王守超、陈晨、肖俊凯、李文博。感谢你们在项目合作中的鼎力支持，更感谢你们这两年半风雨同舟的陪伴。那些一起熬过的夜、讨论过的难题，都将成为我们共同的珍贵回忆。感谢我的师弟浩俊、文韬、成元，你们活跃的思维常常给我带来科研灵感的火花，感谢你们在实验和讨论中给予的帮助，祝愿你们在未来的科研道路上硕果累累。

感谢我的室友和朋友们。感谢胡小雨，在我数次陷入人生低谷时，是你一直陪伴在我身边，听我倾诉，给我支持，让我有力量重新站起来。感谢刘竞轩以及我的其他朋友们，是你们的欢声笑语让我的交大生活变得如此绚丽多彩，不再单调。

感谢曾经的那段情感经历。感谢曾经的陪伴，虽然离别后的那段时光让我经历了漫长的压抑与沉淀，但正是这段经历，让我学会了在逆境中重塑自我，也让我看清了自己内心真正的追求，看到了未来全新的可能。凡是过往，皆为序章，感谢你让我成为了更好的自己。

饮水思源，感谢母校上海交通大学的培养。感谢自动化系每一位指导过我的老师。特别感谢王景川老师，是您在我本科期间的指引，领导我最初踏入了科研的道路，这份知遇之恩，学生铭记在心。

最后，我要将最深切的感激献给我的父母。无论我身在何处，无论我做何决定，

你们永远是最坚强的后盾。感谢你们二十多年如一日的养育之恩，感谢你们无条件的爱与包容，让我能够无后顾之忧地追逐梦想。

未来的路还很长，我将带着这份感激与责任，继续前行。

学术论文和科研成果目录

学术论文

Yao Y., He. W, Gu. C, Du. J, Tan. F, Zhu. Z, Lu. J, AnyBipe: An Automated End-to-End Framework for Training and Deploying Bipedal Robots Powered by Large Language Models[C]. 2025 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), Hangzhou, China, 2025, pp. 14790-14797, doi: 10.1109/IROS60139.2025.11246492.

Yao Y., Luo. C, Du. J, Lu.J GBC: Generalized Behavior-Cloning Framework for Whole-Body Humanoid Imitation[J]. (To Be Submitted, Arxiv Preprint At arXiv:2508.09960), doi: <https://doi.org/10.48550/arXiv.2508.09960>

Yao Y., He. W, Chen Y., Du J., Lu. J, GBC-MUJICA: A Universal Framework for Real-Time Whole-Body Diffusion Predictive Control of Cross-Morphology Humanoids[C]. Robotics: Science and Systems (RSS), 2026 (OpenReview 摘要已注册, 终稿待上传, 提交日期不晚于 2026.01.30) .

Lu. J, Tan. F, Zhu. Z, **Yao Y.**, Zhang. Q, Han. X, Length-Adaptive PPO-based RLHF for Non-Uniform UAV Control[J]. Neurocomputing , 2026 (在审) .